人工智能与地理数据挖掘

第一讲　绪论

孙伟 sunwei29@mail.sysu.edu.cn

地理科学与规划学院

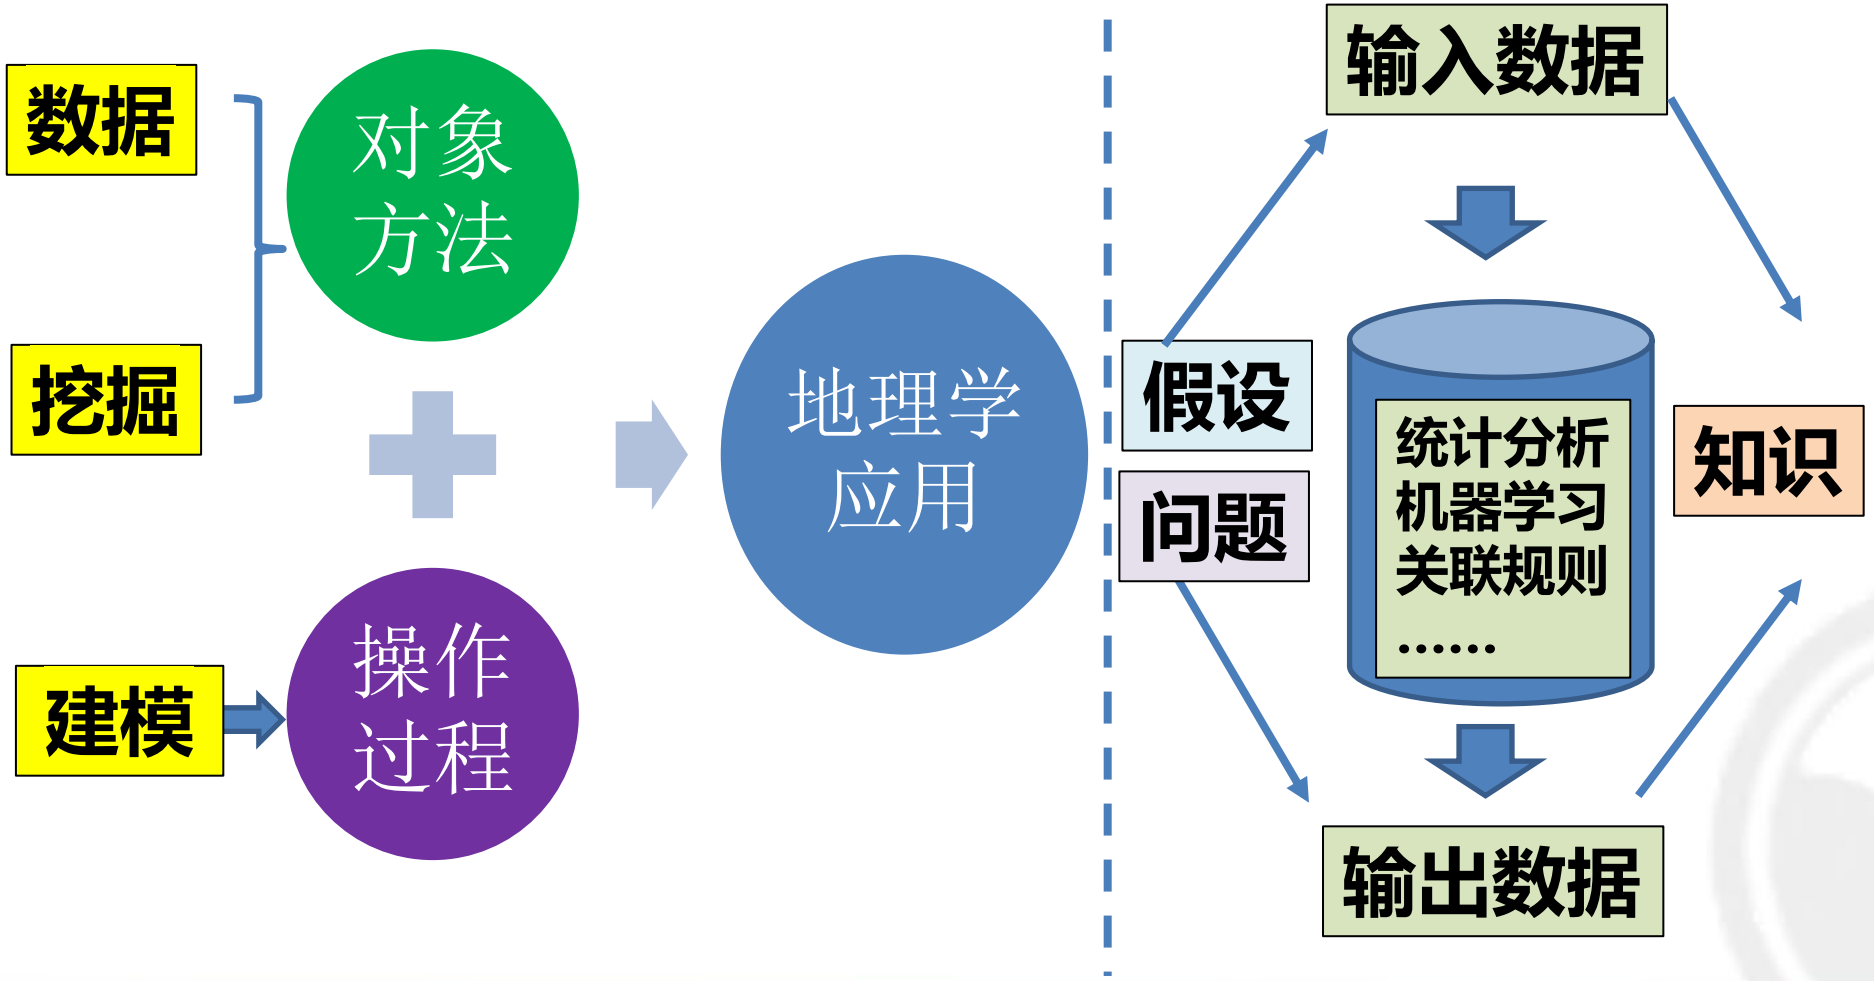
中山大學 SUN YAT-SEN UNIVERSITY

2026.02

思考?

- 哪些地学问题需要挖掘?
- 数据从哪里来?
- 什么是数据? （现在）特征? 数据之间关系
- 数据往哪里去?（怎么去? ）
- 什么是数据挖掘方法?
- 什么是数据建模过程?

数据挖掘与建模的核心内容

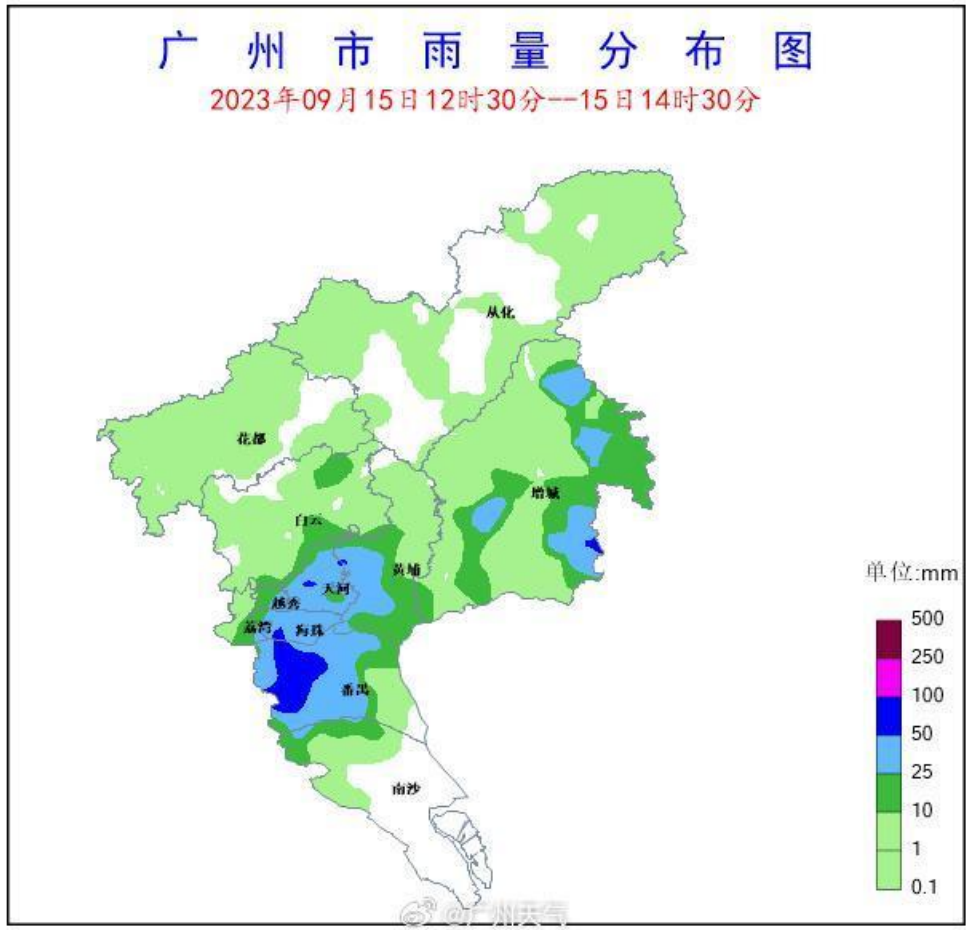


主要内容

1. 可以应用的地学问题
2. 数据产生和特征
3. 数据挖掘方法概述
4. 数据建模过程概述
5. 小结

地学问题的应用

2023年广州9月15日暴雨





从数据挖掘的角度看，上面两个气象预报应用是什么问题?

2023年广州9月15日暴雨



当你在户外

1 暴雨来临，不要走地下通道或高架桥下的通道。

2 市民在户外积水中行走时，要注意观察，贴近建筑物行走，防止跌入窨井或地坑。

3 暴雨天气里，请远离高大树木，不要在高大树木下避雨，不要在公园开阔广场使用手机和无线设备。

4 在路上被洪水冲倒，尽量屏住呼吸，寻找并抓住地面凸起物站起来；他人被洪水冲倒，在保证自身安全情况下帮助他人。



当你在室内

1

如果居住在低洼处，可因地制宜采取门口放置挡水板、配置小型抽水泵、准备沙袋等预防措施，提前做好暴雨防范准备。

2

“室内三不宜”：
暴雨发生时，不宜敞开门窗；
不宜使用淋浴冲凉和触摸金属管道；
不使用家用电器，切断电源。

3

洪水到来时，来不及转移的，要迅速找一些门板、桌椅、大块泡沫塑料等漂浮物扎成筏



当你在开车

1 暴雨中驾车应减速慢行，打开雨雾灯，注意避开积水区、避开落地广告牌、变压器、电线杆等危险区域；警惕井盖、下水道等。

2 车辆切忌冒险涉水，水深未知路段应下车探索或绕行，不可盲目强制通行。

3 遇有前方积水或交通管制路段，服从交警指挥；发现路面有漩涡，一定要绕行。

4 发现路面已有大量积水，应立刻打开车门电子中控锁车锁，做好随时下车的准备。如判断车辆无法继续行驶，要立即靠边停车；若车辆在积水中熄火，立即关闭全车电源，及时撤离积水区域。

央视新闻

从数据挖掘的角度看，这个气象预报应用是什么问题？

2021年郑州7月暴雨的问题

持续时间长：连续四天出现大范围强降水天气，并且强降水仍将持续
累计雨量大：全省平均降雨量113.5毫米。
强降水范围广：全省共有4098个雨量站降水量超过50毫米，大于100毫米的有1923个，大于250毫米的有606个。
强降水时段集中：强降水时段主要从18日夜间开始，北部、中部、西部地区普降暴雨、大暴雨，局地特大暴雨。
具有极端性：降水量达到历史极值，千年一遇。



2021年郑州7月暴雨的问题

数据	性质	信息/知识	知识/智慧
强降水	定性	连续四天出现大范围强降水天气，并且强降水仍将持续	持续时间长
多少毫米	定量：数值	全省平均降雨量113.5毫米。	累计雨量大
多少毫米的有几个	属性分段统计	全省共有4098个雨量站降水量超过50毫米，大于100毫米的有1923个，大于250毫米的有606个。	强降水范围广
暴雨、大暴雨、特大暴雨	类别数据	强降水时段主要从18日夜间开始，北部、中部、西部地区普降暴雨、大暴雨，局地特大暴雨。	强降水时段集中
极值	随机变量	降水量达到历史极值，千年一遇	具有极端性

降水/ 暴雨预报的问题

程度: 降雨量
位置: 重点气象站
时间: 小时/天/1周/2周/月/2月/季/年/百年

输出

预报模型（统计方法、机器学习、数值模拟）

预报员经验

模型

短期因素：冷暖气团、峰面、季风、副热带高压、气旋、台风

长期因素：大气环流、太阳活动、海气相互作用

输入

径流/洪水/水文的中长期预报的问题

程度: 年度最高水位/流量
位置: 重点断面
时机: 最高水位日期/入汛期等

输出

预报模型（机器学习的回归方法）

预报员经验

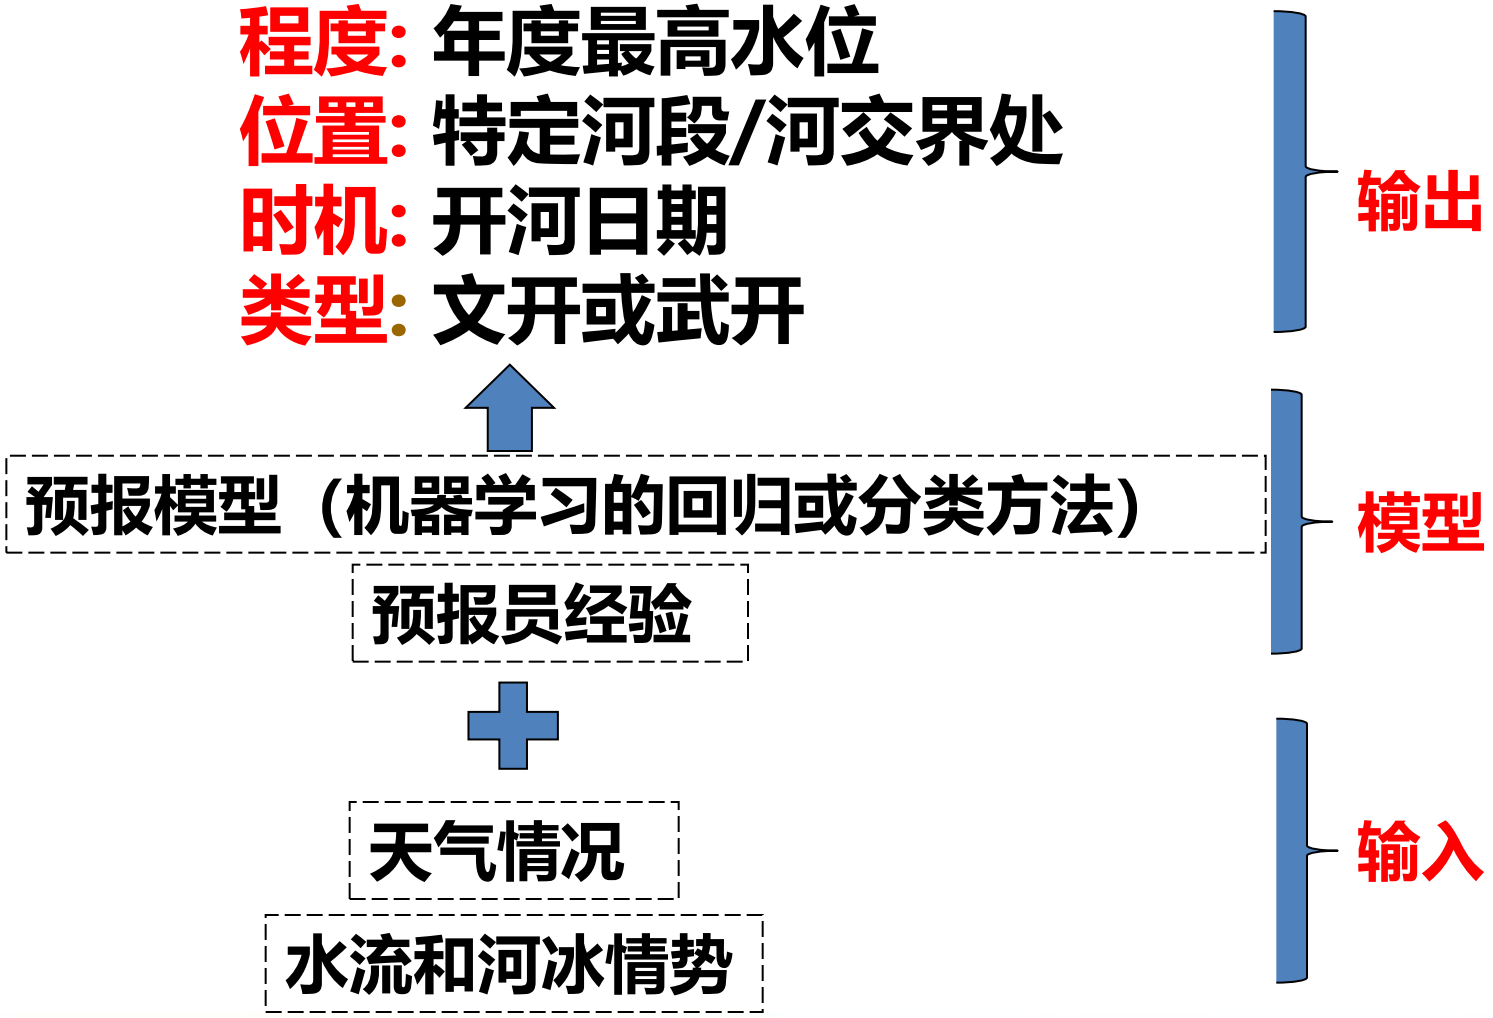
模型

直接因素：降水和蒸发

间接因素：大气环流、太阳活动、海气相互作用

输入

河冰或凌汛的中长期预报的问题



空气质量预报的问题

浓度: 空气污染物的浓度或空气质量指数（PM_{10}，$PM_{2.5}$，臭氧，SO_2浓度等）

时间：不同时间尺度

位置: 重点站点

输出

预报模型（机器学习的回归或分类方法）

预报员经验

模型

污染因素：前期污染物的浓度

气象因素：前期和预测的风速、风向、降雨、气温等

输入

土壤水分的遥感反演问题

兴趣变量:不同时空分辨下的土壤水分

输出

反演模型（机器学习的回归方法）

模型

影响因素：土壤特征、植被特征、气象特征（降雨、风速以及蒸散等）➔影响土壤水分的变量以及受土壤水分影响的变量

电磁波谱特征：光学反射率特征、热红外特征、微波后向散射系数特征、微波亮度温度特征等

输入

植被的遥感分类问题

兴趣变量:是否是植被或特定植被类型 — 输出

↑

机器学习的分类方法
目视解译 — 模型

+

影响因素：植被指数、多时相信息、综合多源遥感数据（光学与雷达数据）及纹理、地形、光谱等辅助信息、三维地形辅助、融入混合像元 — 输入

要素1
数据产生和特征

为什么需要数据挖掘?

- **数据爆炸但知识缺乏：** 互联网、移动互联网、物联网、智慧城市
- **科学发展范式：** 经验科学、理论科学、计算科学、数据科学
- **数据科学发展阶段：** 数据搜集、数据访问、数据仓库、数据挖掘

什么是数据挖掘?

- **定义：把数据转换成有用的信息和知识。**
-



什么是数据、信息、知识和智慧?

概念	含义	与表格数据关系	举例
数据	符号、事实和数字（未经加工和修饰的特征）	表格的单元格	113.5毫米
信息	经过提炼、经过和解释的数据	单个或多个表格行/列的比较描述	大于250毫米的有606个
知识	结构化和有价值的信息	单元格/行/列 比较描述+推理（脱离数据的描述）	西部地区普降暴雨
智慧	总结的知识	脱离表格的规律性描述	降水量达到历史极值

知识（结构化和有价值的信息）的分类

- **预测(prediction)**

  预测一个（将来的）事物的性质。

- **描述(description)**

  用一些变量体现事物的主体特征，使之容易理解。

- **解释(explanation)**

  用深层的知识（概念）形成一个事物的描述。

- **优化(optimization)**

  寻求一个复杂问题的最佳解决方案。

- **探索(exploration)**

  用于支持进一步发现知识的过程。

数据挖掘的对象：表格数据

数据集/关系数据库:由数据对象组成

关系数据库

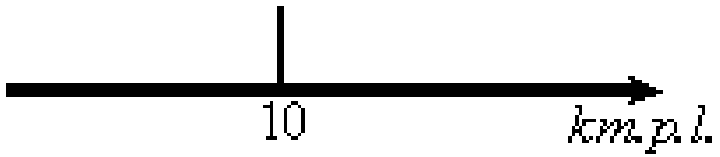
- **行：数据对象、样本、样品、实例、数据点**
- **列：数据属性、变量、特征、标签、字段**

	X1	X2	Y
A	0.23	1.6	11
B	0.45	3.6	21
C	0.87	4.8	33
D	0.98	5.9	45

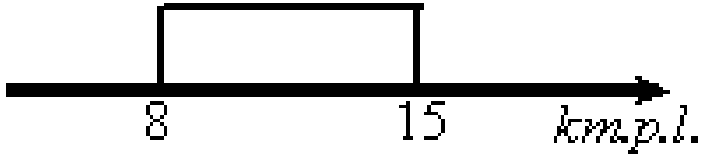
数据挖掘的对象？

- **数据挖掘的对象**：任何类型。
  - **结构化数据**：关系数据库（二维表格数据）➔本课程主要研究对象
  - **半结构化数据/异构性数据**：数据结构不规则或不完整，没有预定义的数据模型，不方便用二维表格来表现的数据。
    - 文本、多媒体、空间数据、某些时序、Web数据

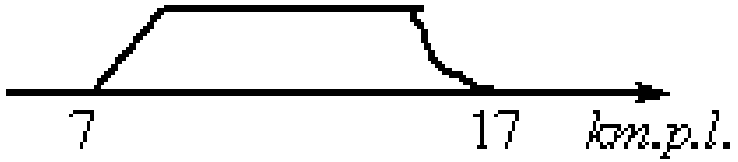
不确定性数据对象



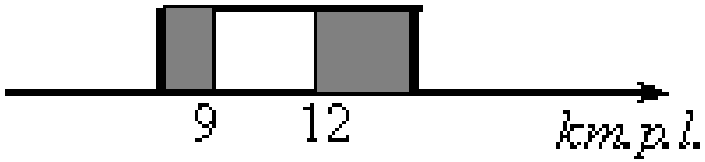
(a) 数字



(b) 数据间隔



(c) 基于模糊集



(d) 源于粗糙集

缺了一种不确定性数据？

中山大學
SUN YAT-SEN UNIVERSITY

要素2
数据挖掘方法的概论

数据挖掘方法?

- 异常分析/特异群组分析/演变分析
- 关联规则
- 聚类
- 降维
- 特征选取
- 分类
- 回归

统计分析

机器学习

机器学习的定义

- **定义**：教计算机执行人和动物与生俱来的活动：从经验中学习。
- **特点**：
  - **数据驱动**：机器学习算法使用计算方法直接从数据中“学习”信息，而不依赖 于预定方程模型。
  - **与样本量关系**：当可用于学习的样本数量增加时，这些算法可自 适应提高性能。
- **适用性**：涉及大量数据和许多变量的复杂任务或问题，但没有现成的处理公式或方程式时，可以考虑使用机器学习

哪些机器学习方法？（类别）

大类	要点	适用性	类别	功能	方法
无监督学习（聚类）	仅基于输入数据对数据进行分组和解释	只对X进行计算	硬聚类	基于未标记响应的输入数据（X），输出是不同类别；其中每个数据点只属于一类	K-均值 模糊C 均值 ANN
			软聚类	其中每个数据点可属于多类	
			降维	减少属性个数	PCA
监督式学习	基于输入和输出数据开发预测模型	对X和Y同时计算	分类	基于标记响应的输入数据（X和Y），输出是不同类别；预测离散的响应	判别分析 kNN ANN/深度学习 CART SVM
			回归	基于标记响应的输入数据（X和Y），输出是具体数值；预测连续的响应	MLR /NLR kNN ANN/深度学习 CART SVM

无监督学习方法：硬聚类

方法	工作原理	使用时机
k-均值	数据分割为 k 个相互排斥的类。点在多大程度上适合划入一个类由该点到类中心距离来决定(类中心与数据中的点可以不契合）。	● 当聚类的数量已知时 ● 适用于大型数据集的快速聚类
k-中心点	与 k-均值类似，选用类中离平均值最近的对象作为中心(类中心与数据中的点契合）。	• 当聚类的数量已知时 • 适用于分类数据的快速聚类 • 扩展至大型数据集
层次聚类	通过分析成对点之间的相似度并将对象分组到一个二进制的层次结构树，产生聚类的嵌套集。	• 当不知道的数据中有多少类时 • 想要可视化地指导数据选择
自组织映射	基于神经网络的聚类，将数据集变换为保留拓朴结构的 2D 图。	• 采用 2D 或 3D 可视化高维数据 • 通过保留数据的拓扑结构（形状）降低数据维度

硬聚类特点：一个点只能属于1个类

无监督学习方法：软聚类

方法	工作原理	使用时机	特点
模糊 c-均值	当数据点可能属于多个类时进行基于分割的聚类。	• 当聚类的数量已知时 • 适用于模式识别 • 当聚类重叠时	聚类中心 （类似于k-均值）：一个点在一个类中的隶属度
高斯混合模型	基于分割的聚类，数据点来自具有一定概率的不同的多元正态分布。	• 当数据点可能属于多个类时 • 当聚集的类具有不同的大小且含有相关结构时	一个高斯分布的模型，给出一个点在一个类中的概率

软聚类特点：一个点可能属于多个类

有监督学习方法：分类

方法	工作原理	使用时机
逻辑回归	适合可以预测属于一个类或另一个类的二元响应概率的模型。 因为逻辑回归比较简单，所以常用作二分类问题的起点。	• 当数据能由一个线性边界清晰划分时 • 作为评估更复杂分类方法的基准
k 最近邻 (kNN)	kNN 根据数据集内类的最近邻关系划分对象的类别。kNN预测假定相互靠近的对象是相似的。距离量度（如欧氏、绝对值、夹角余弦和 Chebychev 距离）用来查找最近邻。	• 当需要简单算法来设立基准学习规则时 • 当无需太关注 训练模型的内存使用时 • 当无需太关注训练模型的预测速度时

有监督学习方法：分类

方法	工作原理	使用时机
支持向量机(SVM)	通过搜索能将全部数据点分割开的判别边界（超平面）对数据进行分类。当数据为线性可分离时，SVM 的最佳超平面是在两个类之间具有最大边距的超平面。如果数据不是线性可分离，则使用损失函数对处于超平面错误一边的点进行惩罚。SVM 有时使用核变换，将非线性可分离的数据变换为可找到线性判定边界的更高维度。	• 适用于正好有两个类的数据（借助所谓的纠错输出码技术，也可以将其用于多类分类） • 适用于高维、非线性可分离的数据 • 当您需要一个简单、易于解释、准确的分类器时
神经网络	受人脑的启发，神经网络由高度互连的神经元网络组成，这些神经元将输入与所需输出相关联。通过反复修改联系的强度，对网络进行训练，使给定的输入映射到正确的响应。	• 适用于高度非线性系统建模 • 当数据逐渐增多，而您希望不断更新模型时 • 当您的输入数据可能有意外变动时 • 当模型可解释性不是主要考虑因素时

有监督学习方法：分类

方法	工作原理	使用时机
判别分析	判别分析通过发现特征的线性组合来对数据分类。判别分析假定不同的类根据高斯分布生成数据。 训练判别分析模型涉及查找每个类的高斯分布的参数。分布参数用来计算边界，边界可能为线性函数或二次函数。这些边界用来确定新数据的类。	• 当您需要易于解释的简单模型时 • 当训练过程中的内存使用是需要关注的问题时 • 当需要快速预测的模型时
决策树	利用决策树预测对数据响应的方法是，按照树中根节点（起始）到叶节点的顺序自上而下的决策。树由分支条件组成，在这些条件中，预测元的值与训练的权重进行比较。分支的数量和权重的值在训练过程中确定。附加修改或剪枝可用来简化模型。	• 当需要易于解释和快速拟合的算法时 • 最小化内存使用 • 当不要求很高的预测准确性时

有监督学习方法：回归

方法	工作原理	使用时机
线性回归	一项统计建模技术，用来描述作为一个或多个预测元变量的线性函数的连续应变量。因为线性回归模型解释简单，易于训练，所以通常是第一个要与新数据集拟合的模型。	• 当您需要易于解释和快速拟合的算法时 • 作为评估其他更复杂回归模型的基准
非线性回归	是一种有助于描述实验数据中非线性关系的统计建模技术。通常将非线性回归模型假设为参数模型，将该模型称为非线性方程。“非线性”是指拟合函数是多个参数的非线性函数。	• 当数据有很强的非线性趋势，不容易转化成线性空间时 • 适用于自定义模型与数据拟合
广义线性模型	广义线性模型是使用线性方法的非线性模型的一种特殊情况。 它涉及输入的线性组合与输出的非线性函数（连接函数）拟合。	• 当因变量有非正态分布时，比如始终预期为正值的因变量

有监督学习方法：回归

方法	工作原理	使用时机
SVM 回归	类似于 SVM 分类算法，但经过改良，能够预测连续响应。不同于查找一个分离数据的超平面，SVM 回归算法查找一个偏离测量数据的模型，偏离的值不大于一个小数额，采用尽可能小的参数值（使对误差的敏感度最小）。	• 适用于高维数据（将会有大量的预测元变量）
回归树	回归的决策树类似于分类的决策树，但经过改良，能够预测 连续响应。	• 当预测元为无序类别（离散）或表现非线性时
神经网络/深度学习	神经元网络结构，利用特定算法进行训练获取权重和偏置等参数	• 适用于低维数据➔浅层神经网络 • 适用于高维数据➔深度学习

机器学习为何可以分类或预测?

大类	数据性质	输入	输出	原则
无监督学习	已知	未标记响应的输入数据（X1观测值）	不同类别/标记（Y1模拟值）	调整模型结构，使得：类间差异大；类内差异小
	未知	未标记响应的输入数据（X2观测值）	不同类别/标记（Y2模拟值）	用Y2模拟值来代替Y2观测值
有监督学习	已知	标记响应的输入数据（X1观测值和Y1观测值）	类别/数值的响应（Y1模拟值）	比较Y1观测值和Y1模拟值的差异，调整模型结构
	未知	标记响应的输入数据（X2观测值）	类别/数值的响应（Y2模拟值）	用Y2模拟值来代替Y2观测值

假设：基于已知数据建立的聚类、分类或者回归的关系，对于未知数据也是成立的。

如何选择一种机器学习方法?

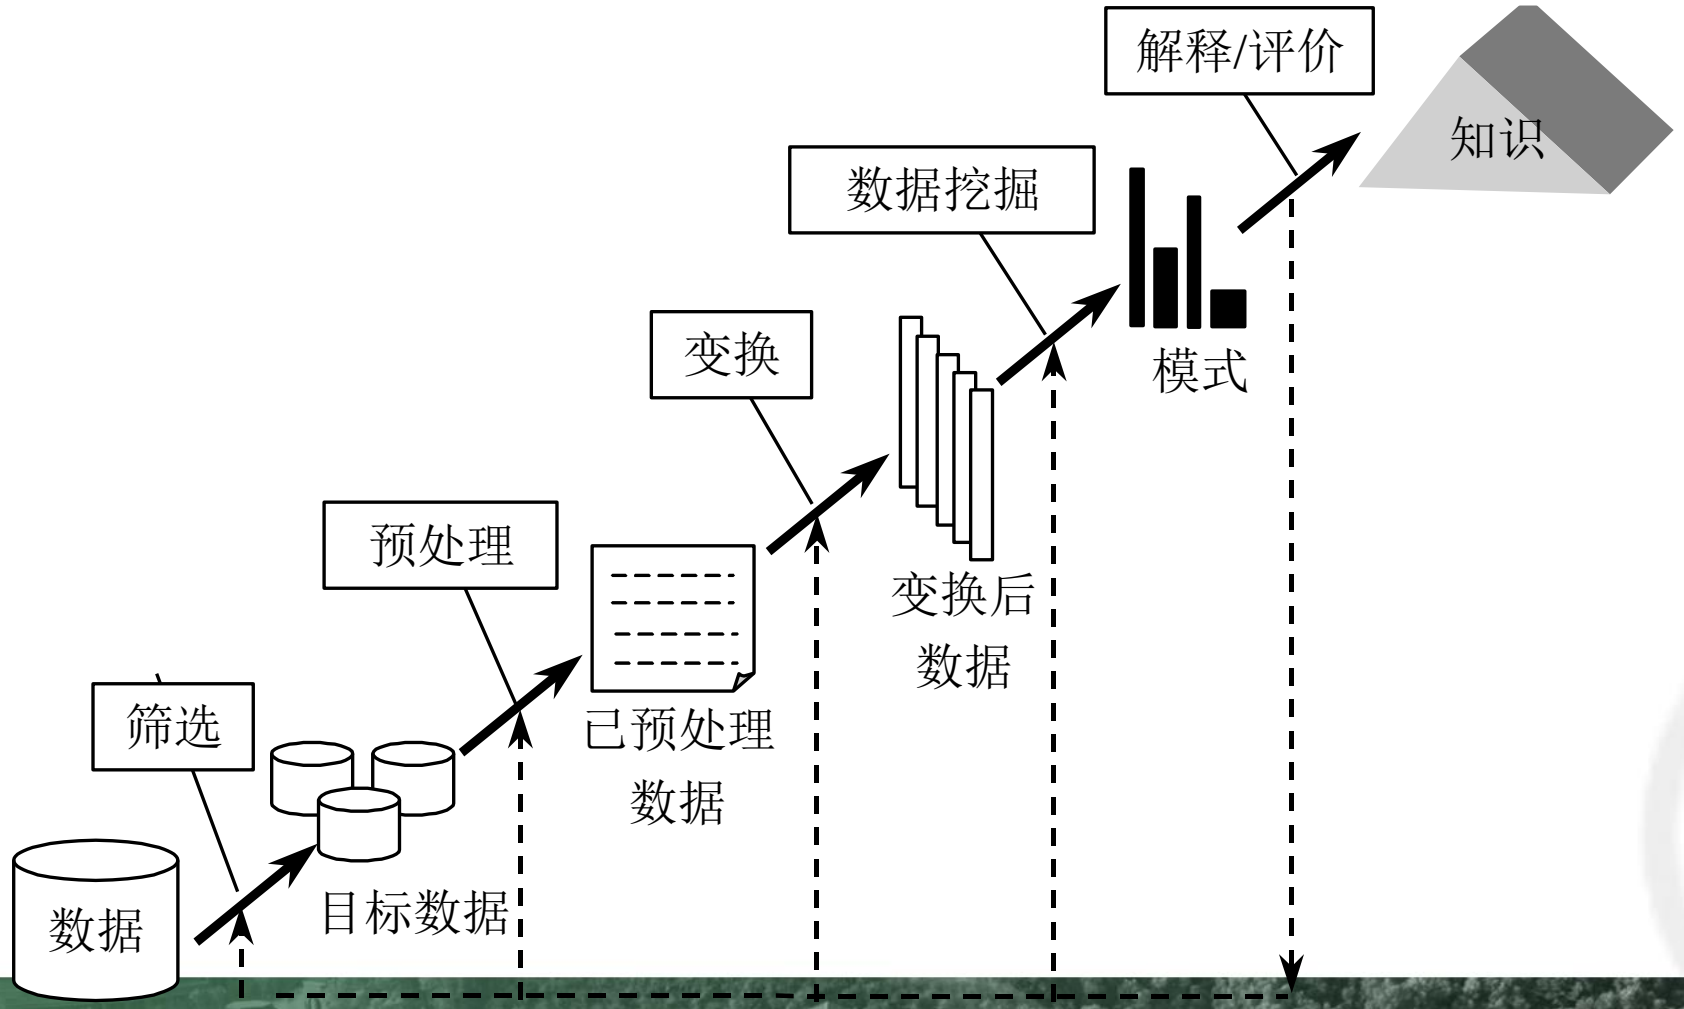
- 无监督学习还是有监督学习?
- 想要探查数据，但还没有特定目标或不确定数据包含什么信息。或者想减少数据维度➔只有X数据，无监督学习
  - 每个数据点只属于一类：硬聚类
  - 每个数据点可属于多类：软聚类
- 已知的输入数据集合（训练集）和已知的对数据的响应（输出），然后训练一个模型，为新输入数据的响应生成合理的预测。即尝试去预测现有数据的输出➔有X和Y数据，监督式学习
  - 预测离散的响应：分类
  - 预测连续的响应：回归
- 根据机器学习方法的优缺点和建模需要的匹配程度➔选择具体机器学习方法

要素3
数据建模过程概述

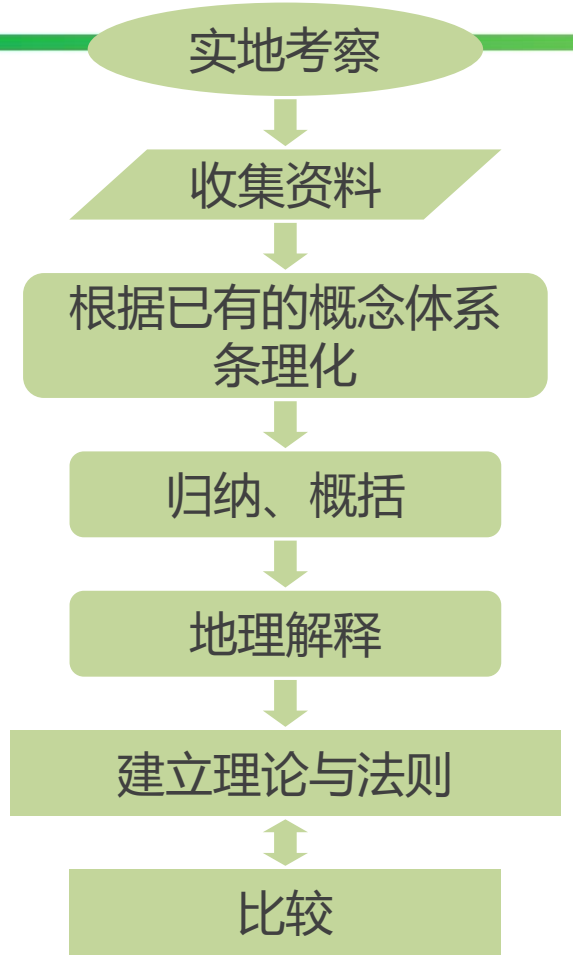
数据挖掘的一般步骤

- **三个步骤：数据准备、规律寻找和规律表示。**
- **数据准备是从相关的数据源中选取所需的数据并整合成用于数据挖掘的数据集；**
- **规律寻找是用某种方法将数据集所含的规律找出来；**
- **规律表示是尽可能以用户可理解的方式（如可视化）将找出的规律表示出来。**

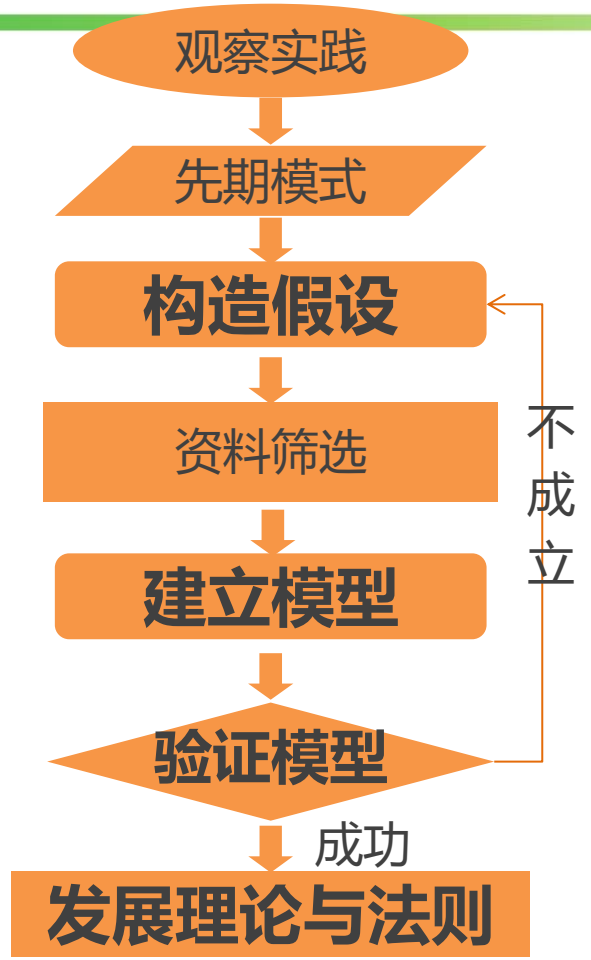
数据挖掘过程



建模过程



传统地理学方法



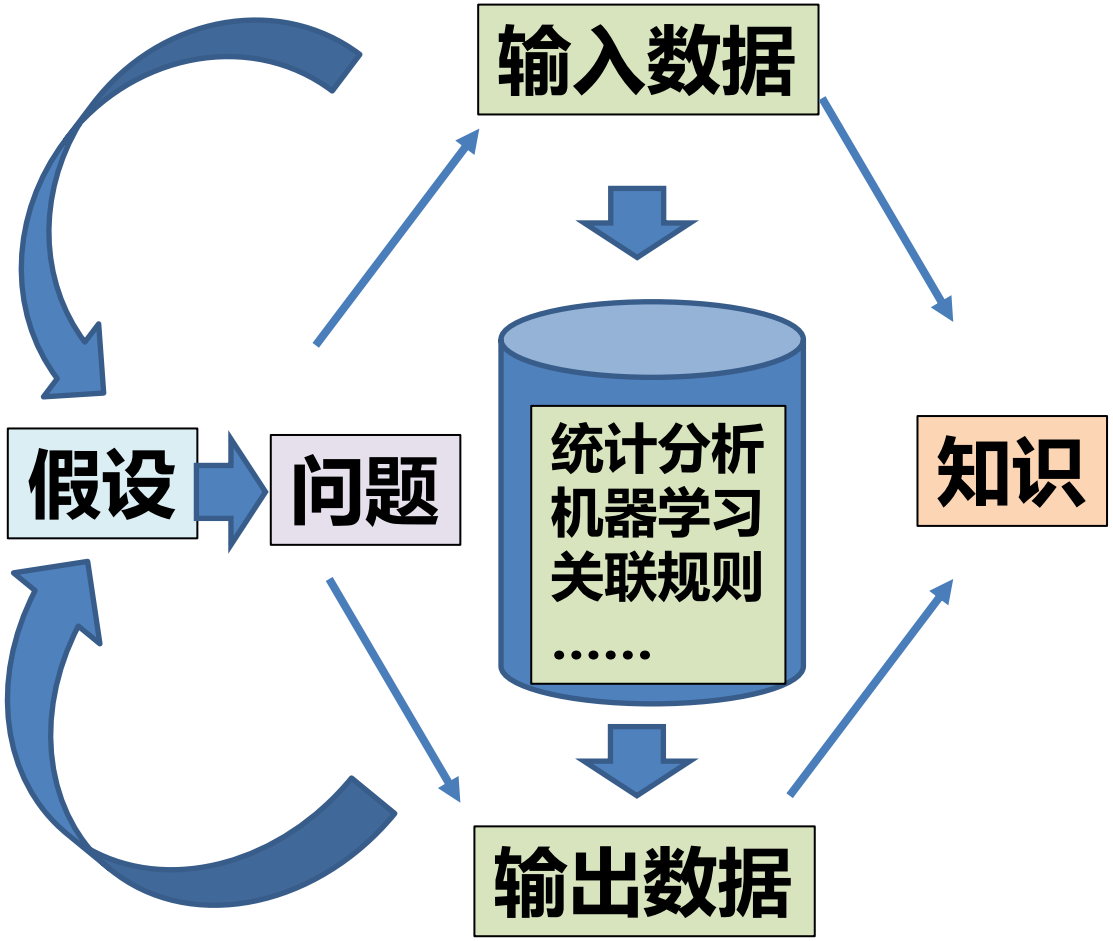
现代地理学方法

现代地理学研究的四个步骤

无论哪个步骤都涉及到地理数据的**收集**、**处理**和**分析**

QQ群

数据挖掘的建模过程



表格数据的数据集格式

	X1	X2	X3	X4	X5	Y1	Y2
训练集	1.4	11	2010	123	0.12	11.2	1
	2.1	22	1345	546	0.89	22.4	2
	3.1	33	2435	432	076	44.6	4
	4.6	44	6734	231	0.34	66.3	6
	……	……	……	……	……	……	……
验证集	5.7	55	4532	724	0.56	99.1	9
	8.3	66	3879	567	0.82	120.2	10
测试集	……	……	……	……	……	……	……
未知集	6.7	35	5132	624	0.45	?	?
	……	……	……	……	……	?	?

- 在数据挖掘中，往往需要将数据集整理为图中的标准形式。其中，X_1至X_p 为自变量，Y 为因变量。
- 训练集和验证集：含有自变量和因变量的值，用于训练和验证模型。
- 需要预测的未知数据集：只含有自变量的值，不含因变量的值，所以需要将模型应用于预测数据集，以预测因变量的值。

构建分类/回归预测模型基本步骤

步骤	功能
数据预处理	自变量太多的问题➔数据降维 / 输入变量选择 数据间的数量级差别过大问题 ➔数据标准化
数据分割方法	将原始数据分割成训练集P和验证集Q 或者采用交叉检验/留一法/自助法
初始化模型	初始化模型结构
训练模型	制定特点训练参数
	选择特定率定算法来训练模型，获取最优参数值
预测	训练集预测
	验证集预测
性能评估	数据后处理
	训练集和验证集的预测性能的评估 分类性能指数（错误率、精度） 回归性能指数（相关性指数、MSE，RMSE等）
	假设检验：残差的检验/性能指数差异的检验

输入变量选择(特征选取)

方法	要点
排序过滤法（filter）	根据线性相关系数或非线性相关系数对自变量进行排序，进而选择相关性较高的自变量
逐步回归	依次添加或移除特征，直到预测精度没有改进为止。
顺序特征选择	迭代地添加或移除预测元变量并评估每次变动对模型性能的影响。
正则化	使用收缩估计量，通过将冗余特征权重（系数）减至零消除冗余特征。
近邻元分析 (NCA)	查找每个特征在预测输出中的权重，以便能够丢弃权重较低的特征。

数据降维方法

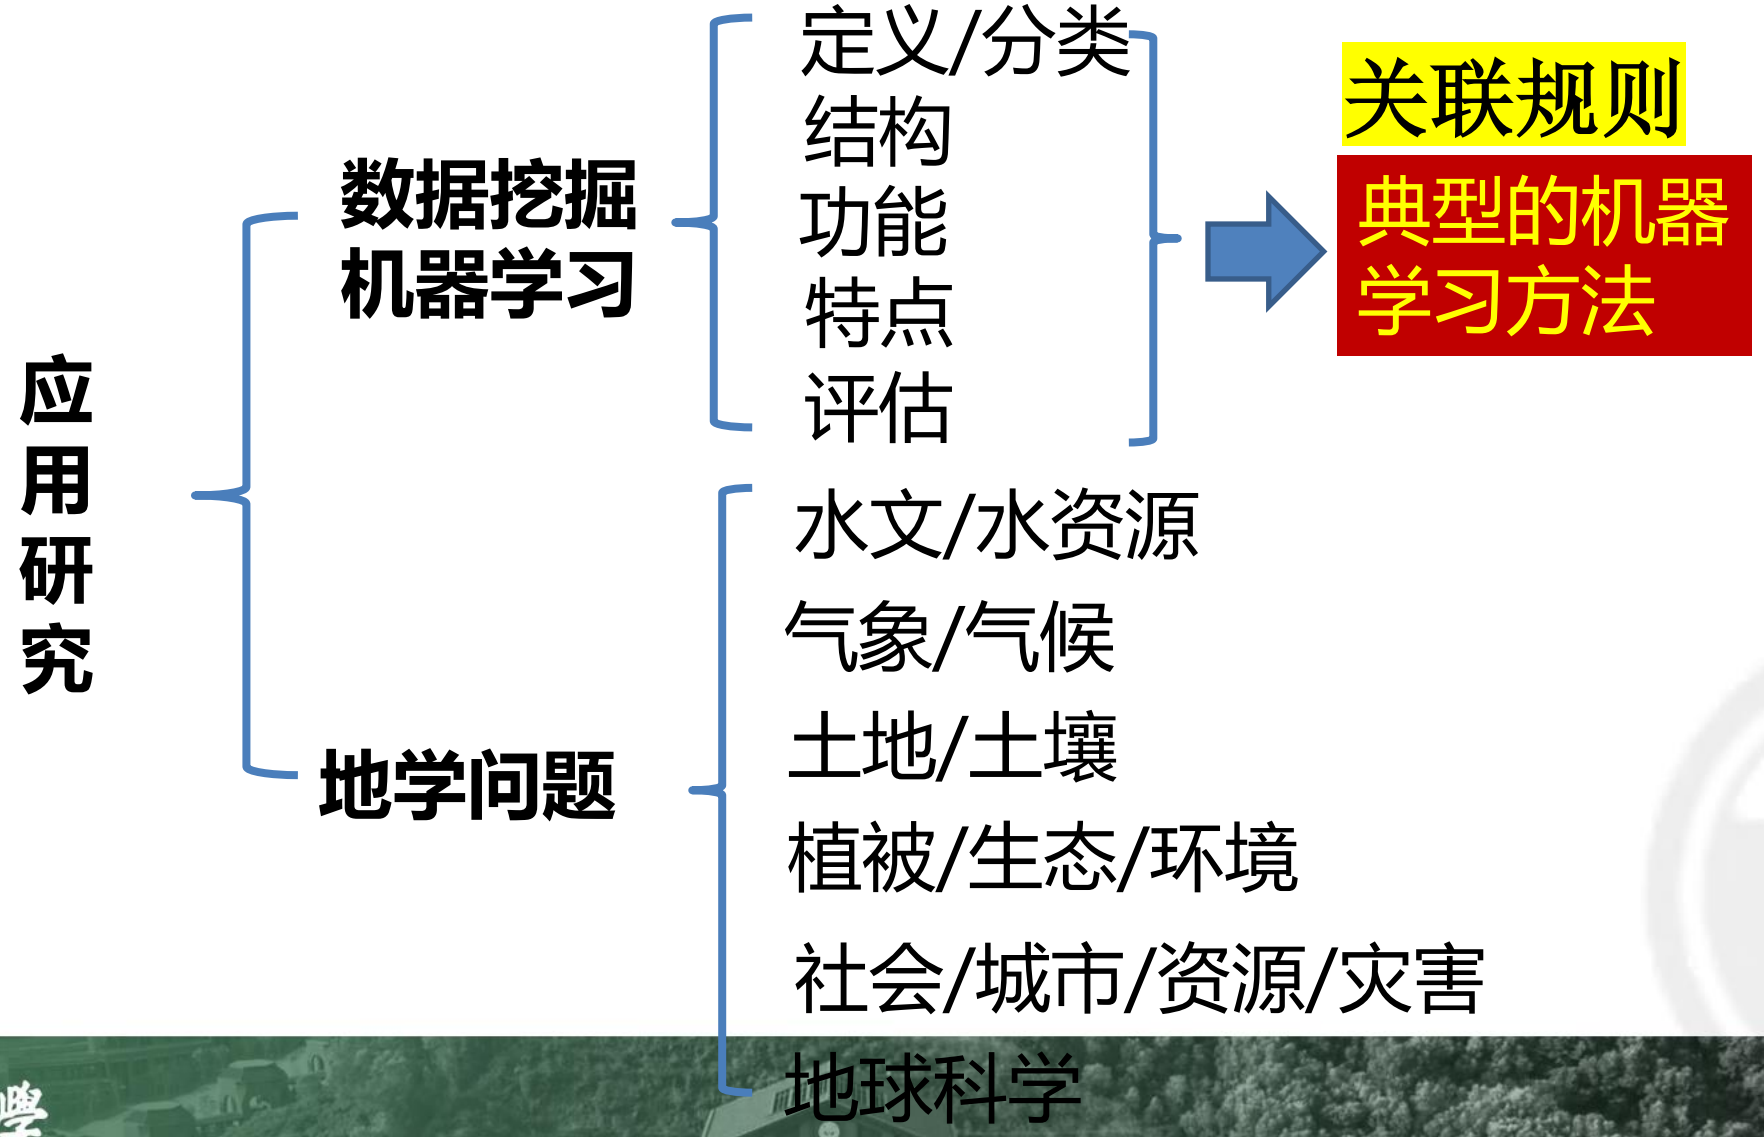
方法	要点	本质	特点
主成分分析(PCA)	对数据执行线性变换，使高维数据集中的绝大多数方差或信息被前几个主成分捕获。第一个主成分将会捕获大部分方差，然后是第二个主成分，以此类推。	主成分：自变量的线性组合	每个主成分都是原始变量的线性组合。因为所有主成分互不相关，所以没有冗余信息。
因子分析	识别您的数据集中各变量之间潜在的相关性，提供数量较少的未被发现的潜在因子或公共因子的一种表现方式。	自变量：因子的线性组合	已测变量依赖数量较少的未发现（潜在）因子。因为每个因子都可能影响多个变量，所以称为公因子。假定每个变量都取决于公因子的线性组合。
非负矩阵分解	当模型项必须代表非负数（比如物理量）时使用。	原始输入矩阵分解成正交的矩阵	

数据集划分方法

方法	要点	适用性
留出法	直接将数据集划分为两个互斥集合 训练/测试集划分要尽可能保持数据分布的一致性 一般若干次随机划分、重复实验取平均值 训练/测试样本比例通常为2:1~4:1	适合大数据集
交叉验证法	将数据集分层采样划分为k个大小相似的互斥子集，每次用k-1个子集的并集作为训练集，余下的子集作为测试集，最终返回k个测试结果的均值，k最常用的取值是10. k折交叉验证通常随机使用不同的划分重复p次，称为p次k折交叉验证	适合中等数据集或小数据集
留一法	假设数据集D包含m个样本，若令 k=m，则得到留一法	适合小数据集 不受随机样本划分方式的影响；结果往往比较准确
自助法	以自助采样法为基础，对数据集D有放回采样m次得到训练集；没取到样本做验证集	数据集较小、难以有效划分训练/测试集时很有用；由于改变了数据集分布可能引入估计偏差；

5. 小结

课程导图


应用研究
数据挖掘
机器学习
定义/分类
结构
功能
特点
评估
关联规则
典型的机器学习方法
地学问题
水文/水资源
气象/气候
土地/土壤
植被/生态/环境
社会/城市/资源/灾害
地球科学

数据挖掘/机器学习的典型方法

类别	聚类/降维	回归	分类	生成
线性方法	相关性 主成分分析 因子分析	多元线性回归	Logistic回归 判别分析	
最近邻	k均值聚类	kNN		
树型	层次聚类	决策树： 回归树	决策树： 分类树	深度 森林
密度	DBSCAN			
神经网络	SOM	ANN		
核函数		SVM（SVR）	SVM（SVC）	
图论	谱聚类	概率图模型	概率图模型	GNN
随机变量	高斯混合		贝叶斯分类	GAN
模糊数	模糊C 均值聚类	模糊逻辑模型 ANFIS	模糊逻辑模型	FDNN
深度学习	自动编码器	CNN，LSTM、Transformer		

思考

- 数据挖掘方法在地理科学中还有哪些应用?
- 数据挖掘、机器学习、统计分析的区别?
- 机器学习模型的结构三要素？自变量和因变量的关系怎么建立？线性关系和非线性关系?
- 数据挖掘/机器学习的功能？除了聚类、分类和回归，机器学习方法还有哪些功能?
- 评估数据挖掘方法的性能，看验证集还是训练集？机器学习怎么做统计检验?
- 怎么选择数据挖掘方法？数据有没有Y？看性能还是结构？数据集和模型的匹配？选择浅层学习和深度学习?
- 数据挖掘方法缺点是什么？数据挖掘怎么能够揭示或解释机理？和数值模拟模型相比，数据挖掘的优缺点是什么?