人工智能与地理数据挖掘

第三讲 数据预处理与可视化

孙伟 sunwei29@mail.sysu.edu.cn

地理科学与规划学院

中山大學 SUN YAT-SEN UNIVERSITY

2026.03

主要内容

1. 数据预处理简介
2. 数据清洗
3. 数据集成
4. 数据缩减
5. 数据变换
6. 图形画法及举例
7. 小结

数据预处理简介

数据预处理的定义和目的

数据预处理是指在数据挖掘的主要处理以前，先对原始数据进行必要的清理、集成、转换、离散和归约等一系列的处理工作，以达到挖掘算法进行知识获取所要求的最低规范和标准。

数据预处理是数据分析、数据挖掘等工作的前期准备，用以确定数据挖掘的类型，提高挖掘质量。

为什么需要数据预处理?

- **前因1：数据质量：由于现实生产和实际生活以及科学研究的多样性、不确定性、复杂性等➔采集到的原始数据比较散乱，不符合挖掘算法进行知识获取所要求的规范和标准**
- **前因2：数据污染：一种由人们故意的或偶然的行为造成的对原始数据的完整性和真实性的损害,是对真实数据的扭曲。**
- **后果：原始数据主要具有以下特征：不完整性、含噪声、杂乱性（不一致性）**

原始数据的特征

特性	含义	产生的原因
不完整	有些数据属性的值丢失的情况，还有可能缺失必需的数据。	系统设计缺陷或者使用过程中的人为因素所造成的：如输入时认为不重要；理解错误，或者设备故障导致删除，历史记录或修改的数据可能被忽略等等
含噪声	数据具有不正确的属性值，包含错误或存在偏离期望的离群值。	收集数据的设备故障，数据输入或数据传输中可能出现错误等等；命名约定或数据代码不一致，或输入字段的格式不一致；存在大量的模糊或随机信息
杂乱/不一致	系统间数据存在较大的不一致性	原始数据是从各个实际应用系统中获取的，由于各应用系统的数据缺乏统一标准的定义，数据结构也有较大的差异
	数据的重复和信息的冗余	合并来自不同的应用系统中的数据

数据预处理的主要任务

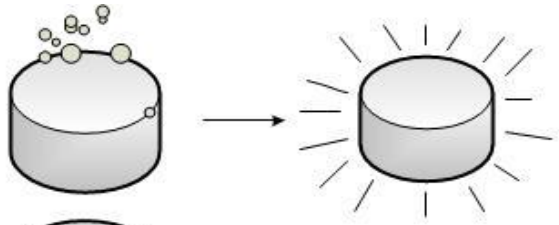
任务	含义	产生的原因
数据清洗	Cleaning	填补遗漏的数据值、平滑有噪声数据、识别或除去异常值，以及解决不一致问题
数据集成	Integration	将不同数据库中的数据集成入一个数据仓库中存储。有时还需数据清理以消除数据冗余
数据缩减	Reduction	在不影响挖掘结果的前提下，通过数值聚集、删除冗余特性的办法压缩数据，提高挖掘模式的质量，降低时间复杂度
数据变换	Transfor-mation	将数据转换成适合于挖掘的形式，如将属性数据按比例缩放，使之落入一个比较小的特定区间（对那些基于距离的挖掘算法尤为重要）。具体方法包括平滑处理、聚集处理、数据泛化处理、规格化、属性构造

数据预处理的主要任务

- **数据清洗/清理**：填写缺失值， 平滑噪声数据 、识别或删除离群， 并解决不一致问题等
- **数据集成**： 整合多个数据库， 多维数据集或文件等
- **数据缩减/归约**： 降维、减少样本量、数据压缩等
- **数据转换**：规范化、离散化、生成概念层次结构等

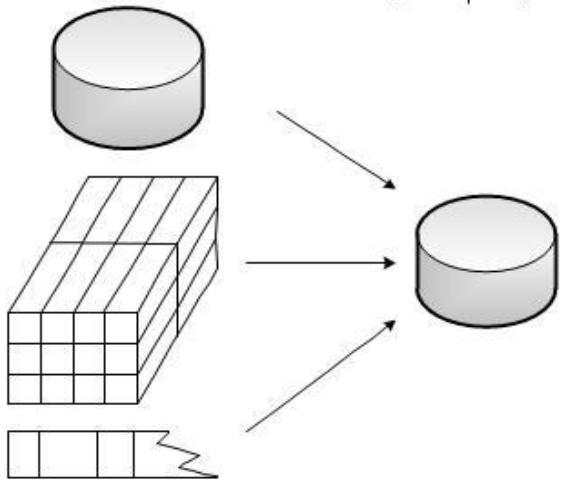
数据预处理主要任务的图例

数据清理



查漏补缺

数据集成



加法

数据变换

-2, 32, 100, 59, 48 → -0. 02， 0. 32, 1. 00, 0. 59, 0. 48

乘/除法

数据缩减/归约

属性

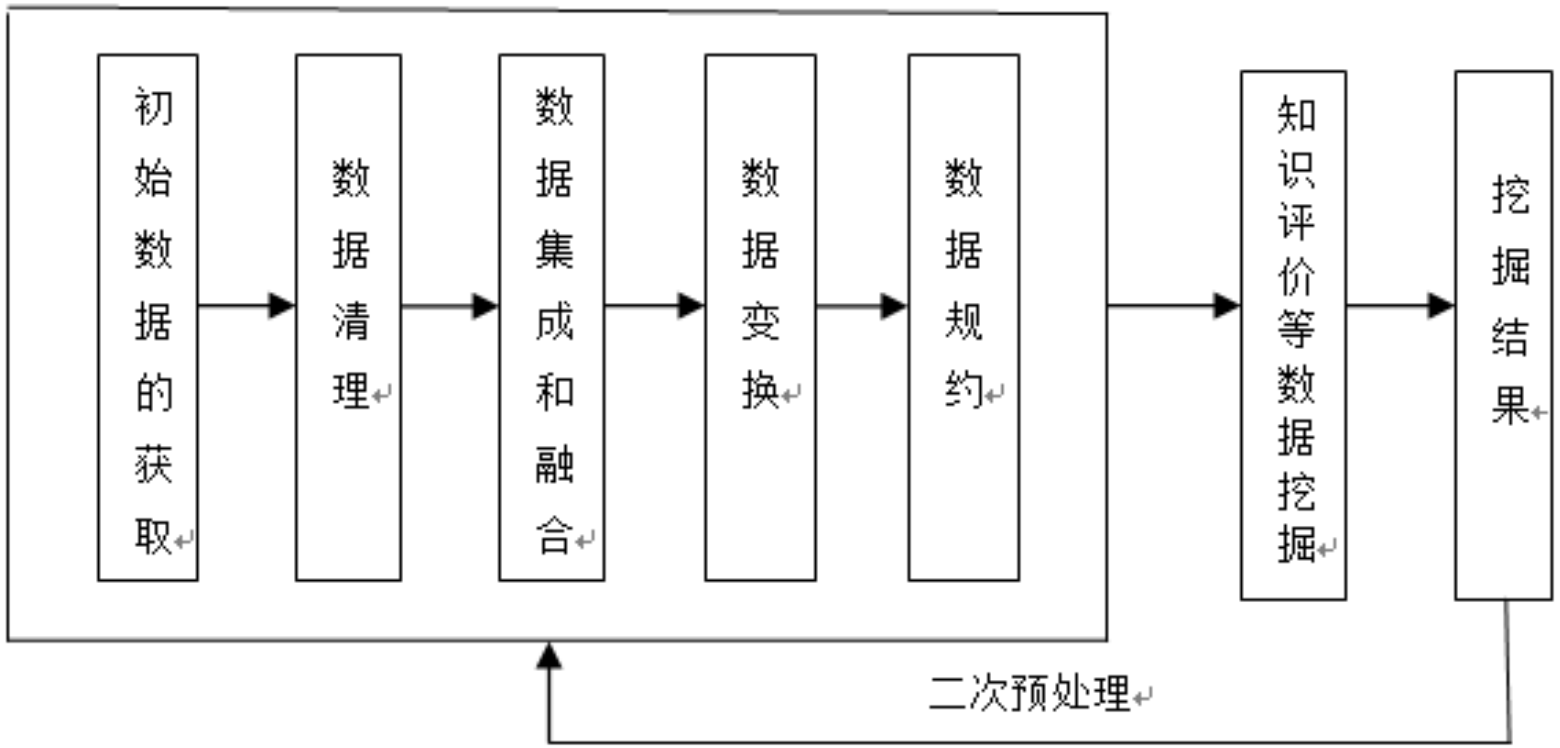
	A1	A2	A3	…	A126
事务 T1					
T2					
T3					
T4					
⋮					
T2000					

→

	A1	A3	…	A115
事务 T1				
T4				
⋮				
T1456				

减法

数据预处理的过程



数据清洗

数据清洗的原因

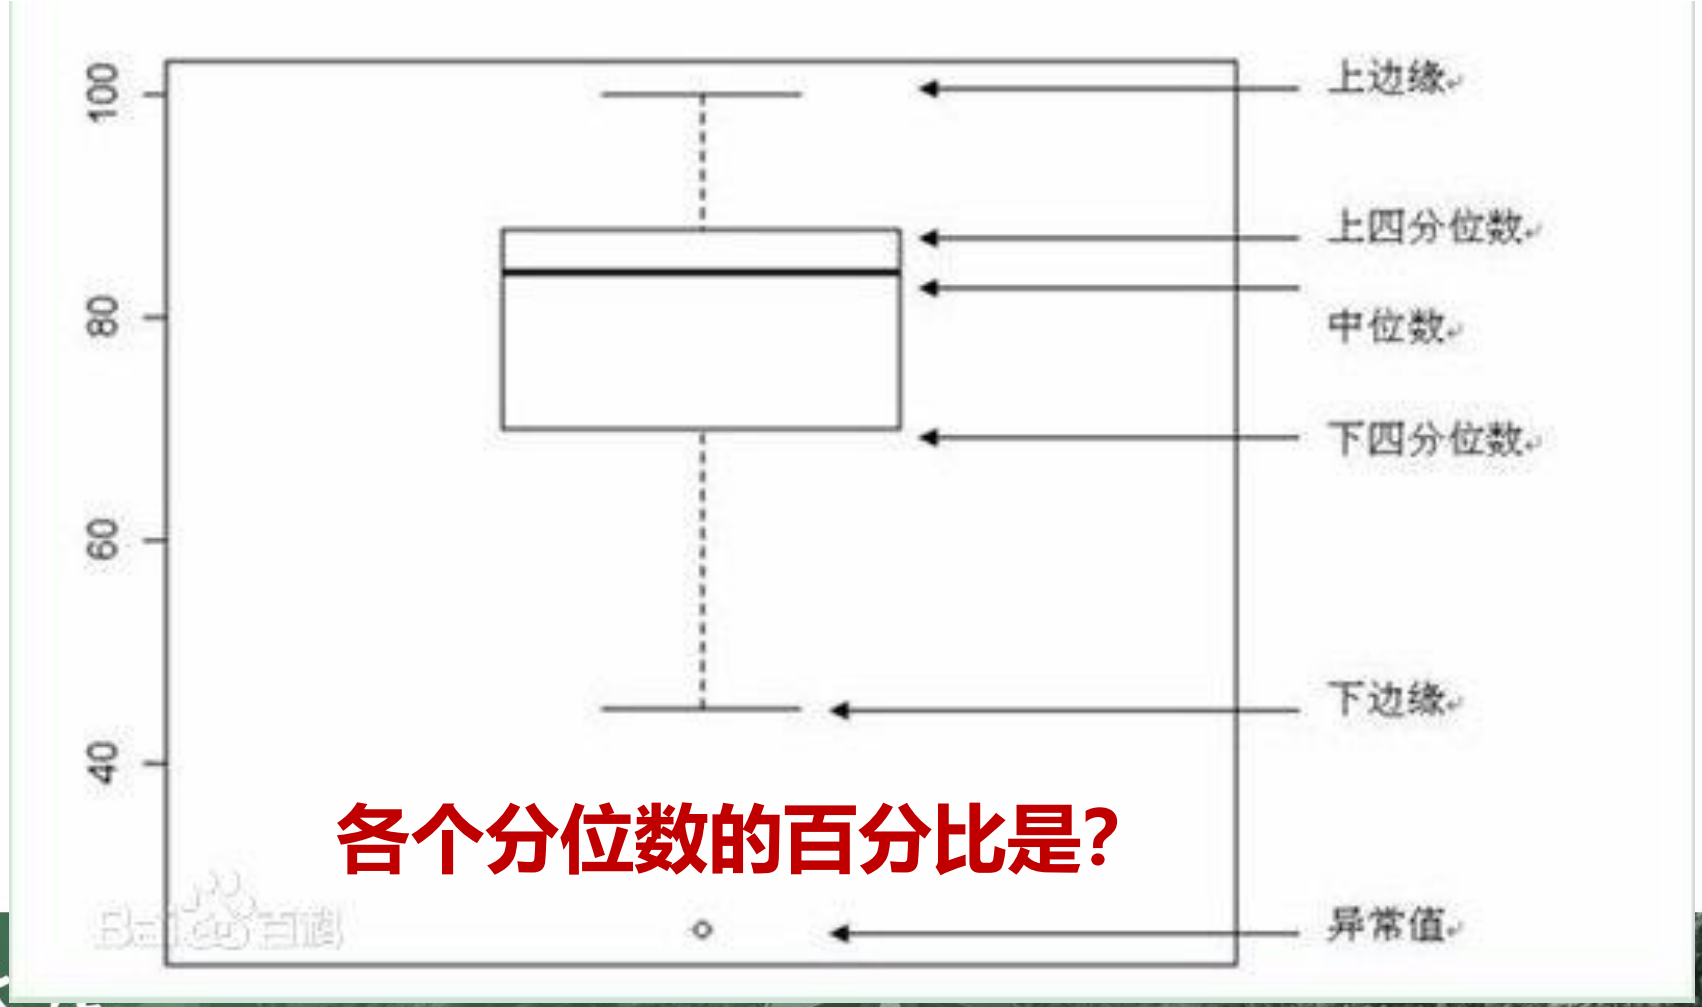
- **不完整的**： 缺少属性值， 缺乏某些属性值， 或只包含总数据
  - 风速=“”(丢失的数据)
- **含嘈杂的瞟音， 错误或离群数据**
  - 降雨量= -10 (错 误)
- **不一致的代码或不符的名称**
  - 年龄= “42” 和 生日= "03/07/1997"
  - 曾经评级 1,2,3 现在评级 "A, B, C"

（1）如何处理缺少数据?

- **忽略数据点**:
  - 当**类标签缺少时**通常这么做 （监督式学习中训练集缺乏类标签）
  - 当每个属性**缺少值比例比较大**时， 效果非常差
- **手动填写**： 工作量大
- **自动填写**:
  - 使用属性的**相邻值**填充空缺值
  - 使用属性的**平均值**填充空缺值
  - **最有可能的值**： 基于诸如贝叶斯公式或决策树推理（**什么问题?** ）

（2）如何处理噪声数据?

- **箱形/盒状图检测离群数据：删除离群点**



各个分位数的百分比是?

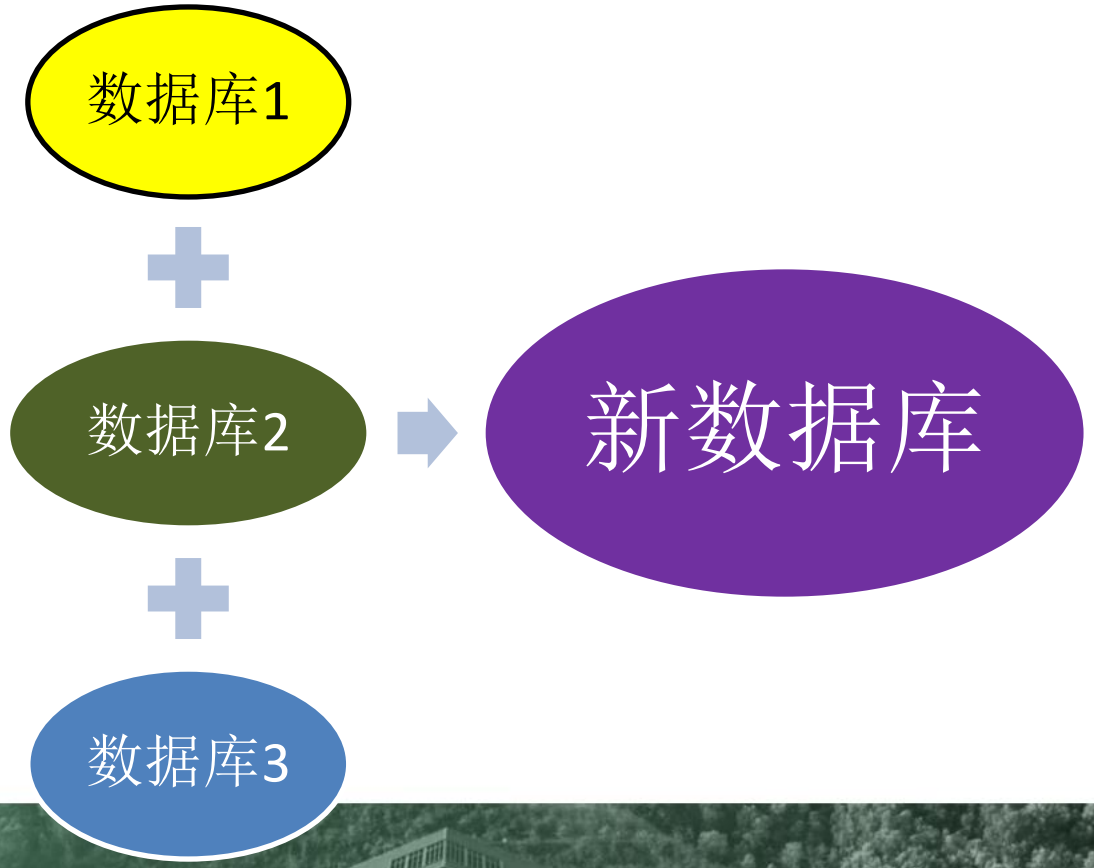
（3）如何处理不一致数据?

- 不一致的代码或不符的名称
  - 年龄= “42” 和 生日= "03/07/1997"
  - 曾经评级 1,2,3 现在评级 "A, B, C"
- • 方法
  - 计算推理➔循环+属性关系判断
  - 局部替换➔小循环+数据替换
  - 全局替换➔大循环+数据替换

数据集成

数据集成

- 将来自多个数据源的数据组合成一个连贯的数据源



数据集成的三种形式

形式	含义	举例/备注
模式集成	根据相同属性，整合来自不同来源的元数据（数据点/对象）	相同ID的数据不同属性进行合并
实体识别	识别来自多个数据源的同一真实世界的实体	中文名和英文名表达的同一实体
数据冲突检测和解决	• 对于同一个真实世界的实体， 来自不同源的属性值 • 可能的原因： 不同的表述， 不同的尺度，	公制与英制单位不同，实际上是同一属性

数据集成如何处理?

- **整合多个数据库经常发生数据冗余**
  - Object identification： 相同的属性或对象可能有不同的名字在不同的数据库中
  - .Derivable data： 一个属性可能是 “派生” 的另一个表中的属性，
- **数据集成的处理方法**：
  - 同一数据对象的可以拥有不同属性
  - 通过**相关性分析或协方差分析**可以检测到冗余的属性（**连续变量**）或者**卡方检验**（**离散变量**）
  - 将来自多个数据源的冗余属性用其一代替即可

数据缩减/归约

数据缩减

- **数据缩减的原因**
  - 由于数据仓库可以存储TB的数据， 因此在一个完整的数据集上运行时， 复杂的数据分析可能需要一个很长的时间➔需要降低时间复杂度
  - 过多数据会造成信息收集困难，导致模型复杂程度增高➔需要降低空间复杂度
- **数据缩减的形式**：
  - **降维**（减少属性/特征）
  - **减少样本量**（减少数据对象/降数据）
  - **数据压缩**：数据重新编码

降维

- **降维的原因**
  - 数据稀疏， 维度高
  - 高维用基于规则的分类方法
  - 采用浅层模型， 但是训练集属性较多，样本较少
  - 需要可视化
- **降维的处理方法**：
  - 主成份分析（属性的组合代替原属性；线性变换等价于坐标旋转，求解椭球体主轴问题）
  - 因子分析

减少样本量的处理方法

- **简单随机抽样(Simple Random Sampling)**
  - 相等的概率选择
  - 不放回抽样(Sampling without replacement)：一旦对象被选中，将其删除
  - 有放回抽样(Sampling with replacement)：选择对象不会被删除
- **分层抽样**
  - 每组抽相同个数
  - 用于偏斜数据

中山大學 SUN YAT-SEN UNIVERSITY

数据转换

数据转换的处理方法规范化

典型的处理方法

- **规范化**： 按比例缩放到一个具体区间(一般0到1之间)
- **离散化**：连续型数据（浮点数）的离散成类别（整数）
- **特征构造**：旧特征换成新特征

数据转换的处理方法1：规范化

原因：属性数量级对模型的影响

定义：函数映射：指给定的属性值更换了一个新表示方法，每个旧值与新的值可以被识别。

处理方法

- **规范化：按比例缩放到一个具体区间(一般0到1之间)**
  1) **最小 - 最大规范化** **v'**=(v-min)/(max-min)*(new_{max}-new_{min})+new_{min}
  2) **Z得分正常化** **v'**=(v-v均值)/v标准差
  3) **小数定标规范化** **v'**=v/ 10^j

公式1)和2)存在的问题?

数据转换的处理方法2：离散化

非监督离散化

- **等宽法：** 根据属性的值域来划分， 使每个区间的宽度相等
- **等频法：** 根据取值出现的频数来划分， 将属性的值域划分成个小区间并且要求落在每个区间的样本数目相等
- **聚类：** 利用聚类将数据划分到不同的离散类别

数据转换的处理方法3：特征构造

原因

1. 当数据质量不高、特征信息不明显➔新特征
2. 当既有连续数据，又有离散数据时➔哑编码

方法：

- 单调变换（如对数变换、 指数变换等）
- 比例特征（x1/x2）
- 线性组合（$a_1x_1+a_2 x_2$）
- 时间数据类型：季节/星期
- 时间序列：小波分析/信号处理

Matlab图形画法及举例

Matlab图形画法及举例

Matlab 基本二维画图

Matlab 基本三维画图

Matlab 定制图

Matlab 基于地图的散点图

基本二维曲线图：Matlab

命令	图形	备注
plot(t,y,str)	二维曲线图	散点图、曲线图
axis([x_{min} x_{max} y_{min} y_{max}])	坐标轴范围	控制画图区域
grid on；grid off	背景网格	位置对比
title('string')	图名标注	图上方写图名
xlabel('str'); ylabel('str')	坐标轴标注	横纵坐标标注
legend('str1','str2',...)	图例标注	不同图形添加图例
text(x,y, 'string')	文字标注	坐标 (x,y) 写文字
figure;subplot(m,n,p)	多图	新图；多个子图
plotyy(t_1,y_1,t_2,y_2)	双坐标轴图	两套序列关系
hold on; hold off	重叠图	经常使用

二维图：Matlab

命令	图形	备注
loglog(x_1,y_1,...)	对数图	变量是对数
semilogx(y) semilogy(...)	半对数图	
stairs(x,y)	阶梯图	类似柱状图
area(x,y)	填充绘图	百分比
pie(x)	饼状图	随时间变化的百分比
feather(u,v)	羽状图	
comet	慧星状图	

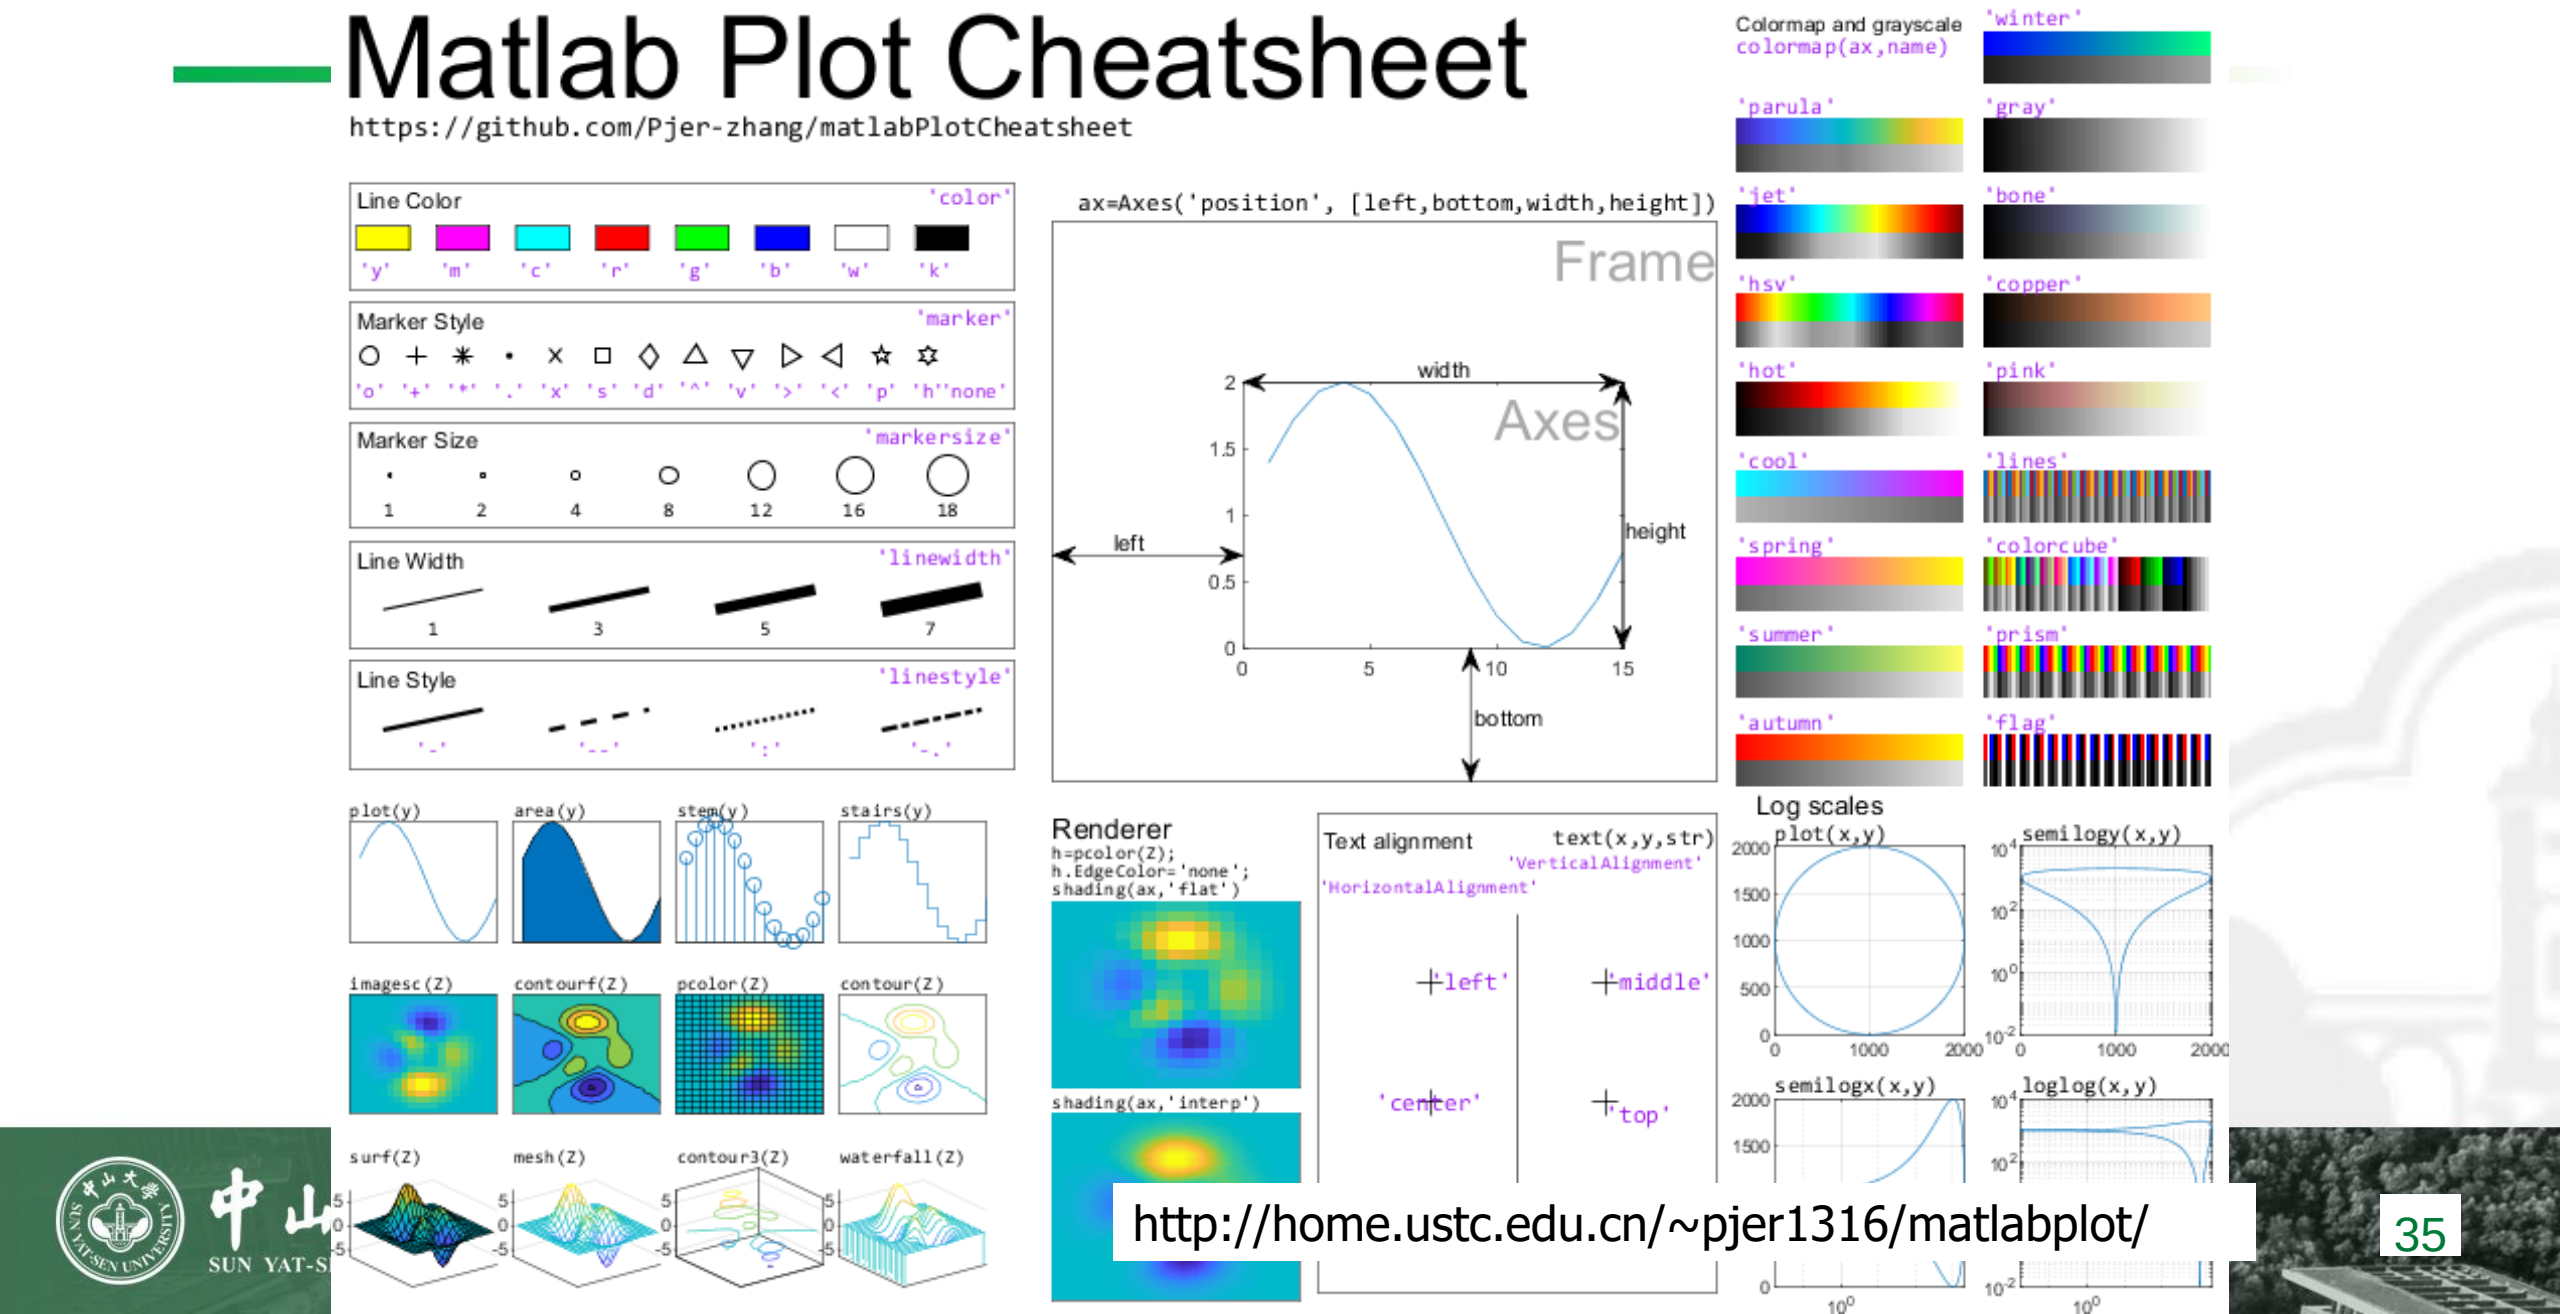
二维图：Matlab

命令	图形	备注
bar(x,y)，barh(...)	二维条形图	柱状图
hist(y,x)	直方图	描述统计特征
pareto(y,x)	Pareto图	排列图
errorbar(x,y,l,u)	误差限图	
stem(x,y)	火柴杆图	类似柱状图
polar(theta,rho)	极坐标图	多维比较图
compass(u,v)	罗盘图	
spy(s)	稀疏模式图	

常用三维图：Matlab

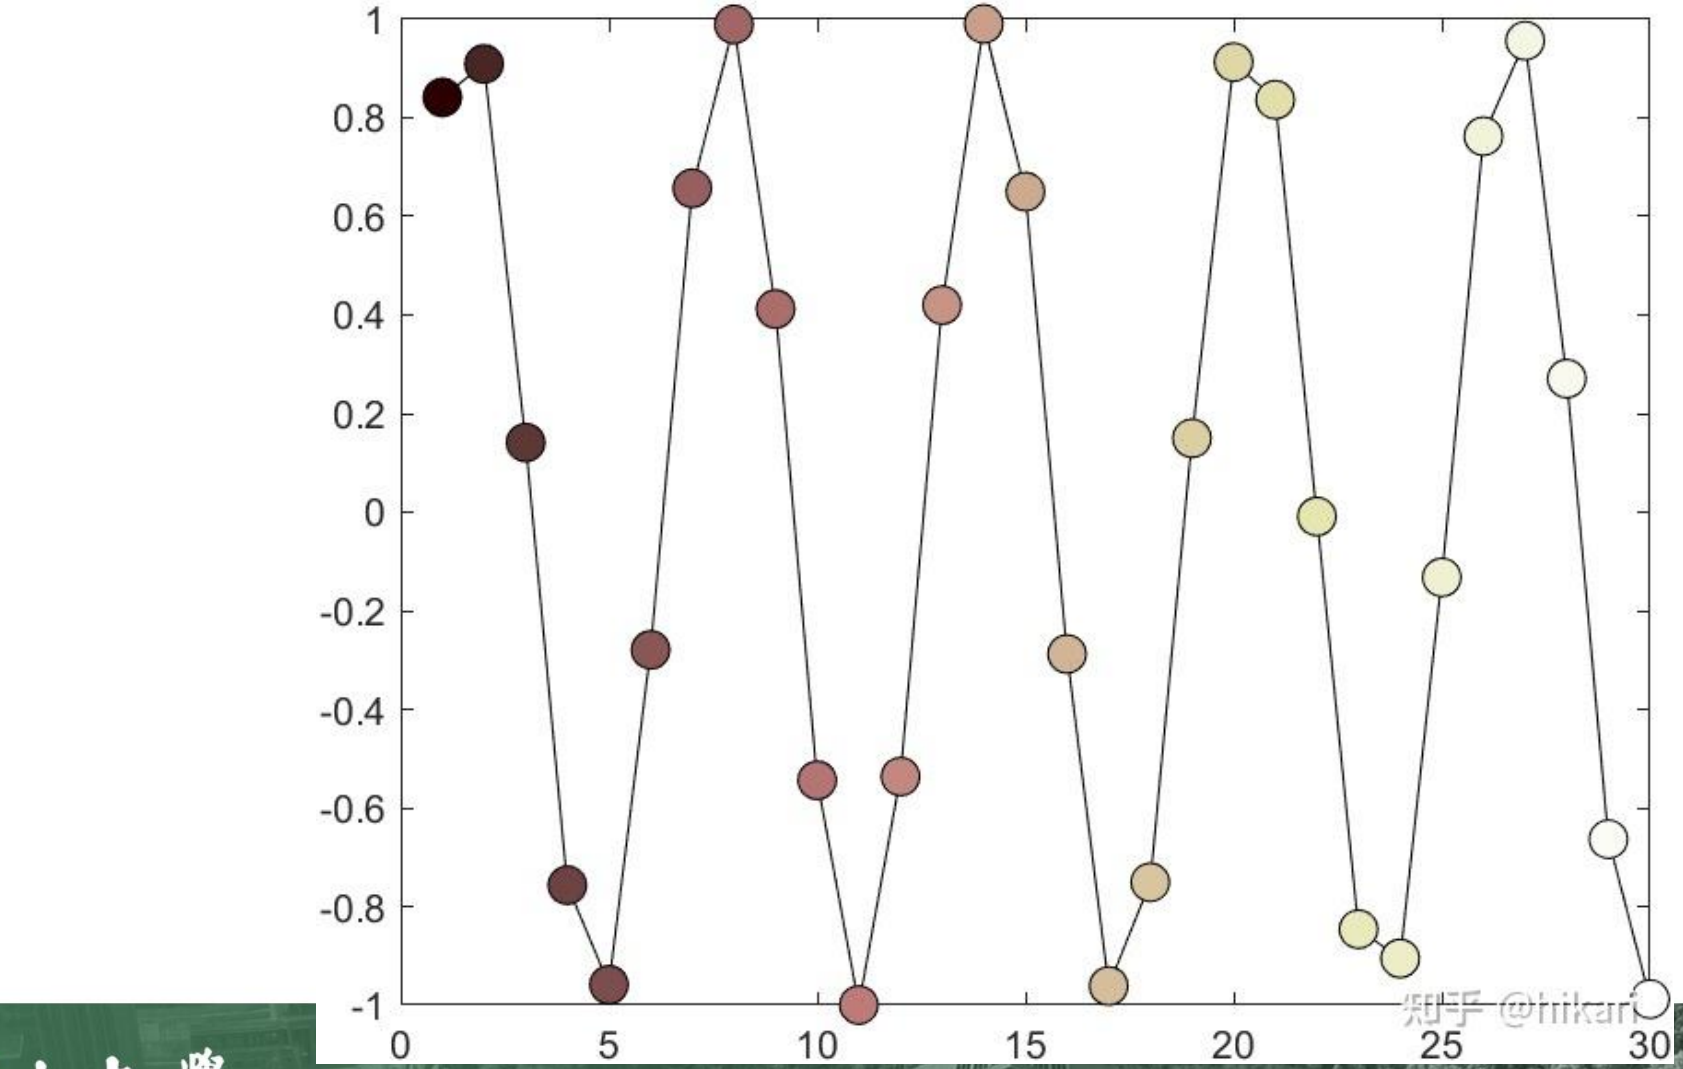
命令	图形	备注
plot3(x,y,z)	三维曲线	类似于二维曲线
mesh(X,Y,Z)	曲面的网格图	由矩阵 X,Y,Z 所确定的曲面的网格图
[X,Y]=meshgrid(x,y)	网格生成函数	配合mesh使用
surf(X,Y,Z)	着色表面图	参数含义同 mesh
sphere (n)	单位球面	n 代表网格的多少
colormap(s)	图形着色方案	s 为字符串，表示所采用的色系

Matlab画图速查表



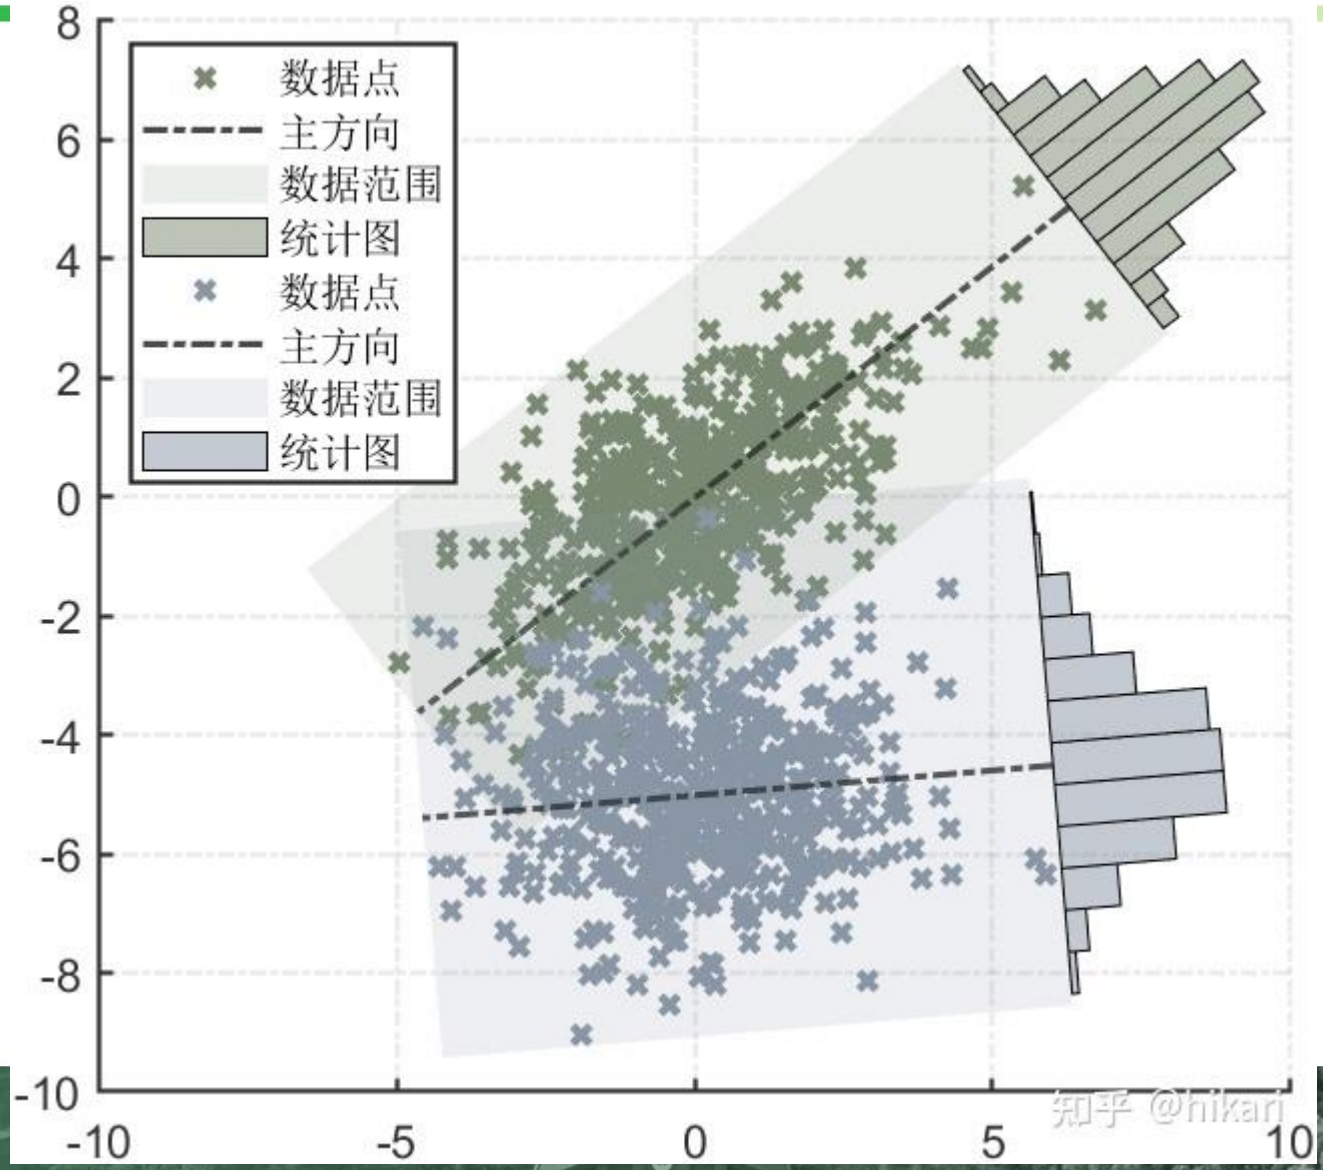
http://home.ustc.edu.cn/~pjer1316/matlabplot/

Matlab渐变的maker：示例

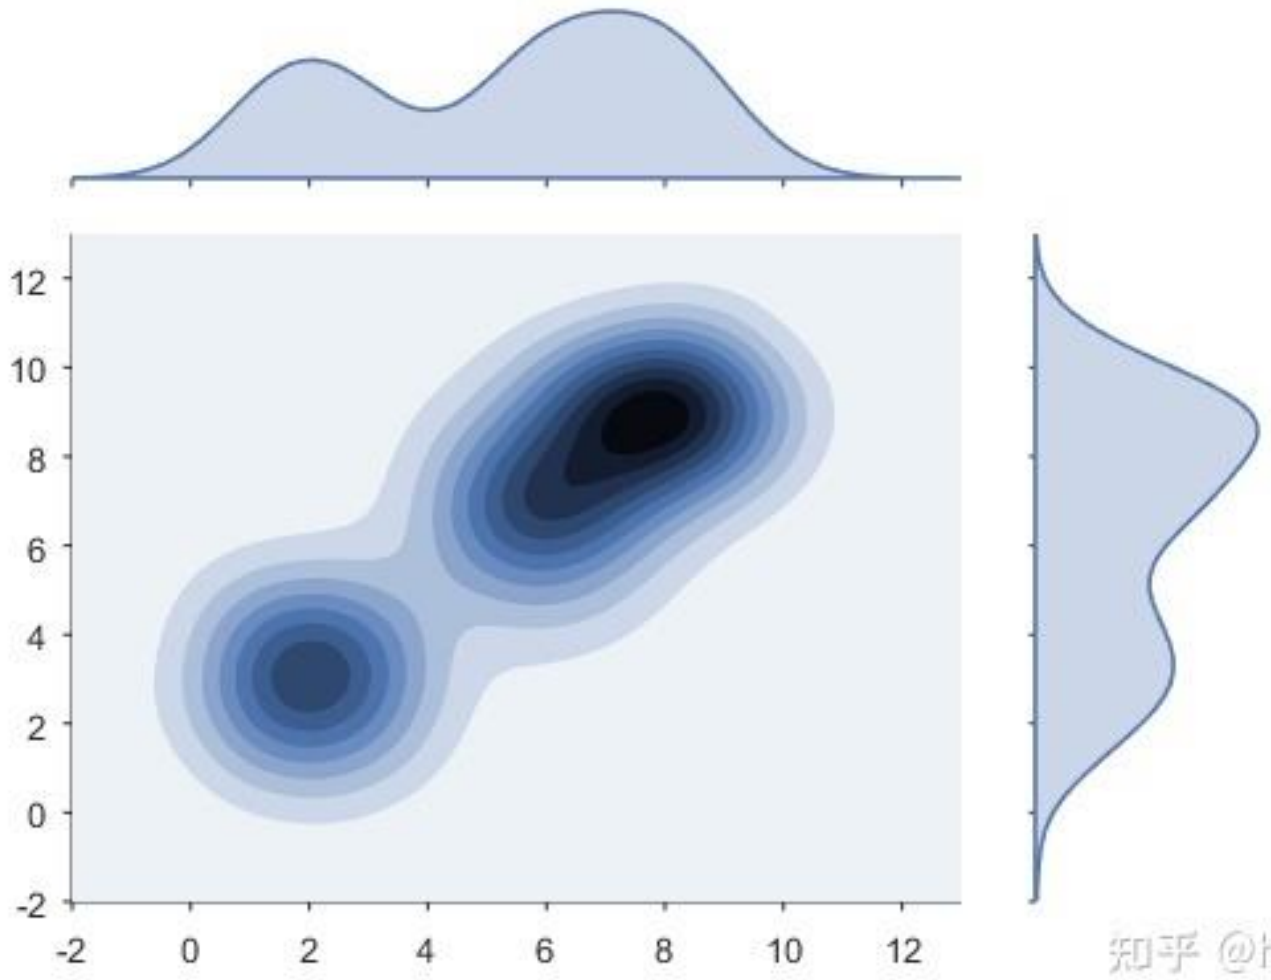


https://zhuanlan.zhihu.com/p/567783934

Matlab二维散点主方向直方图：示例

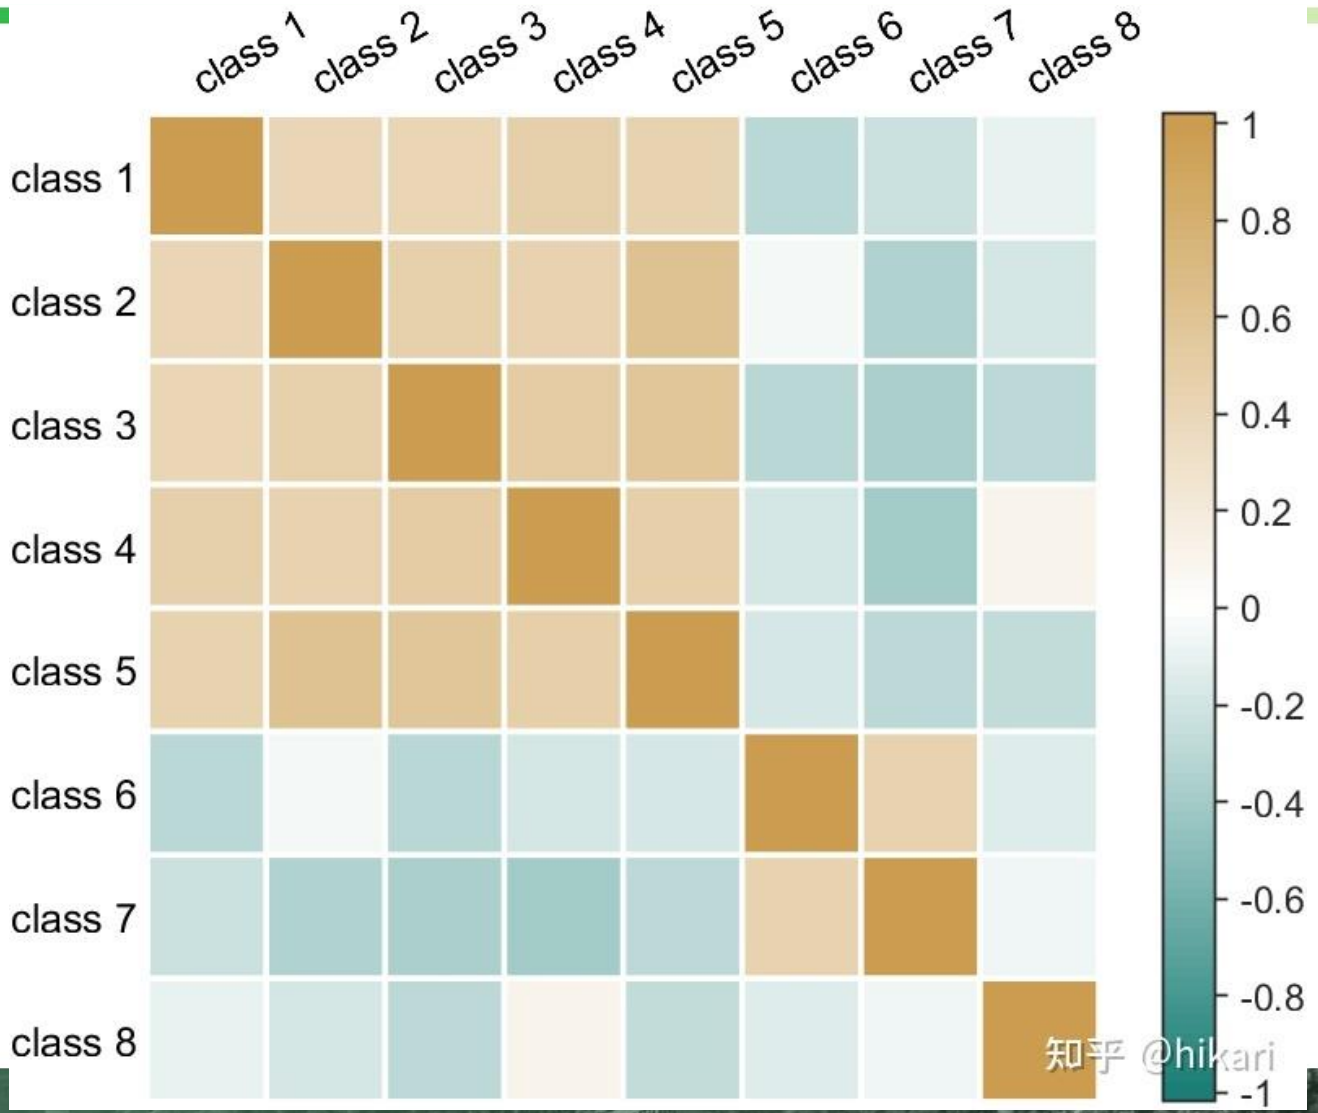


Matlab散点密度图(二维核密度)：示例

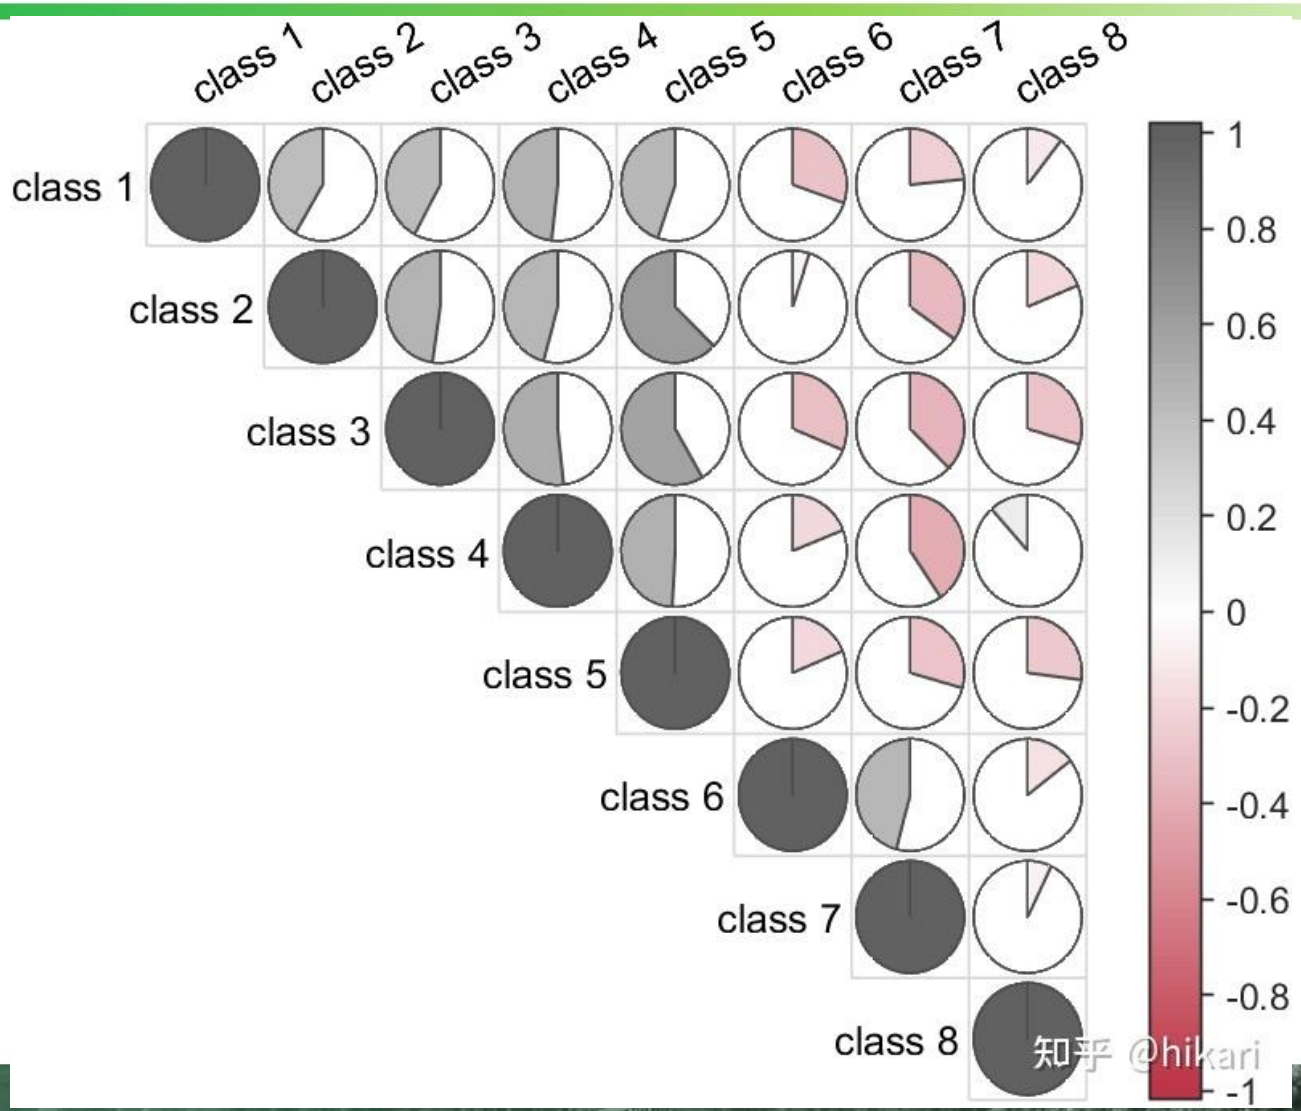


https://zhuanlan.zhihu.com/p/411829577

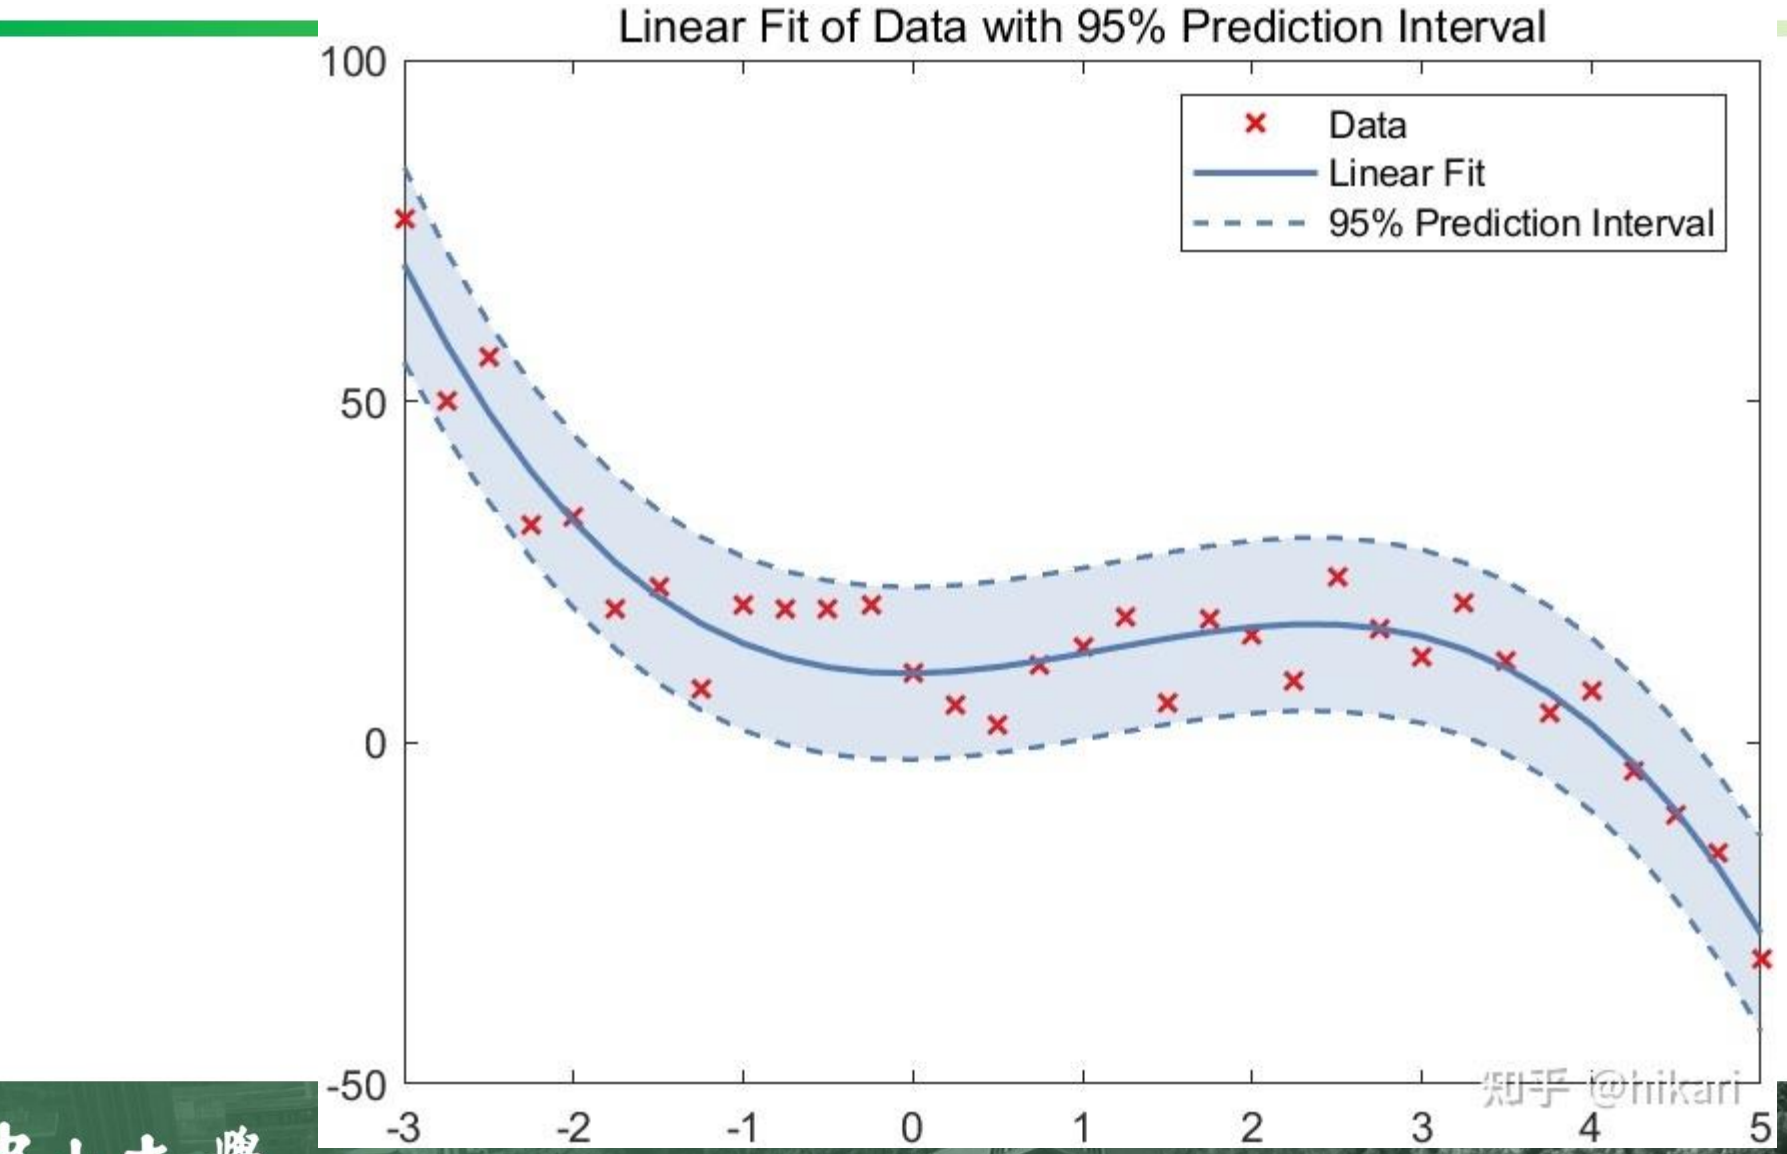
Matlab相关系数矩阵图：示例1



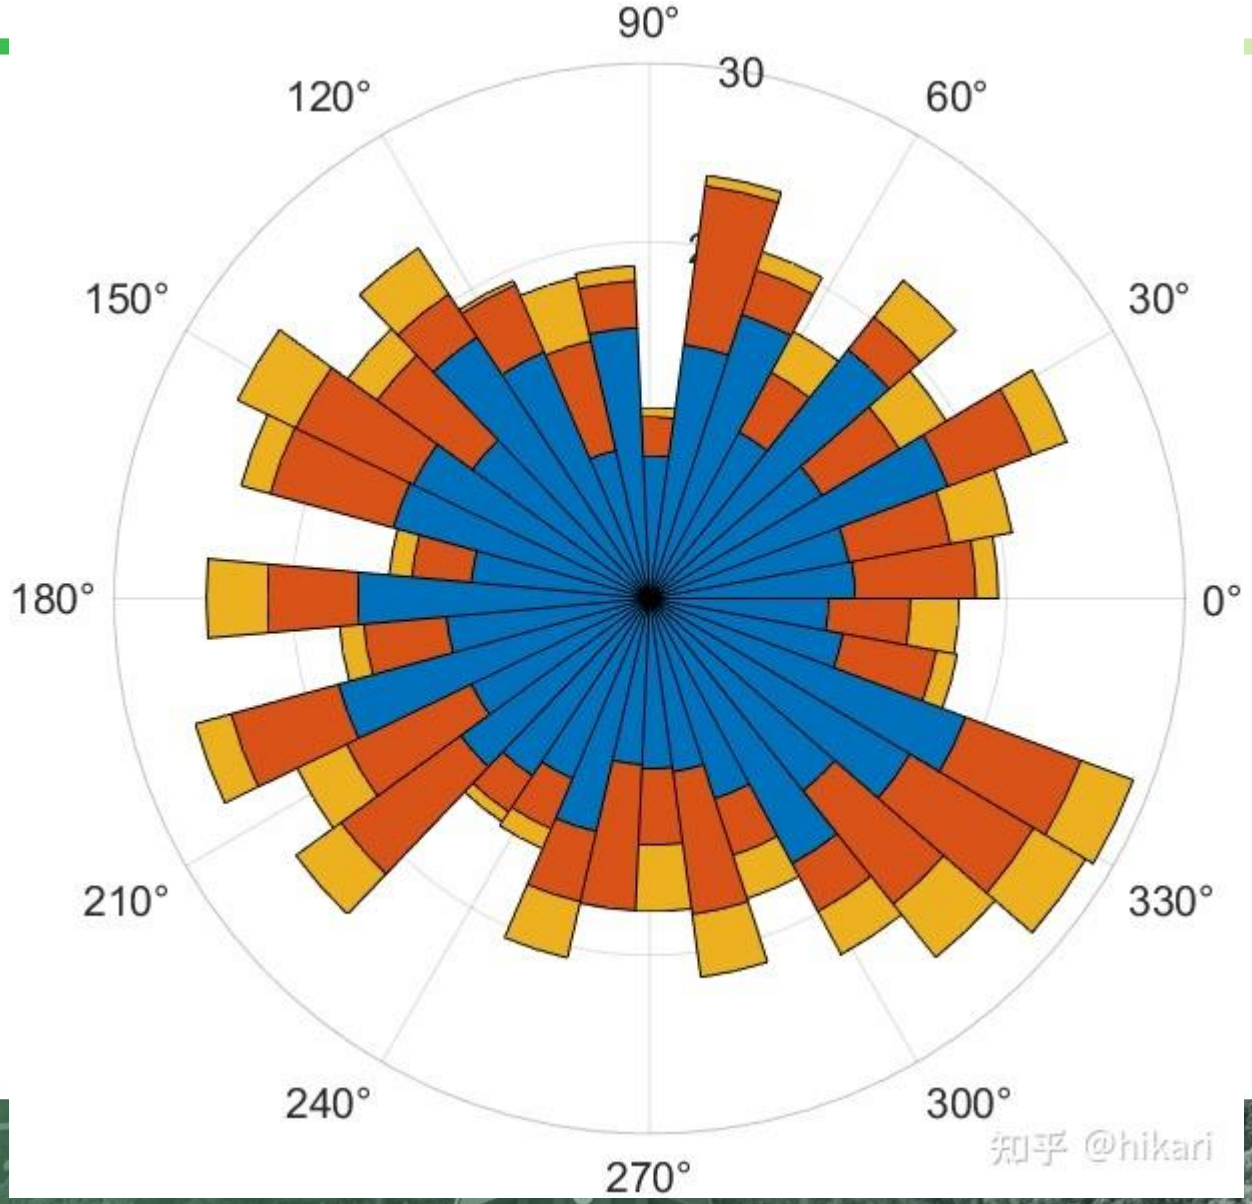
Matlab相关系数矩阵图：示例2



Matlab填充图：示例

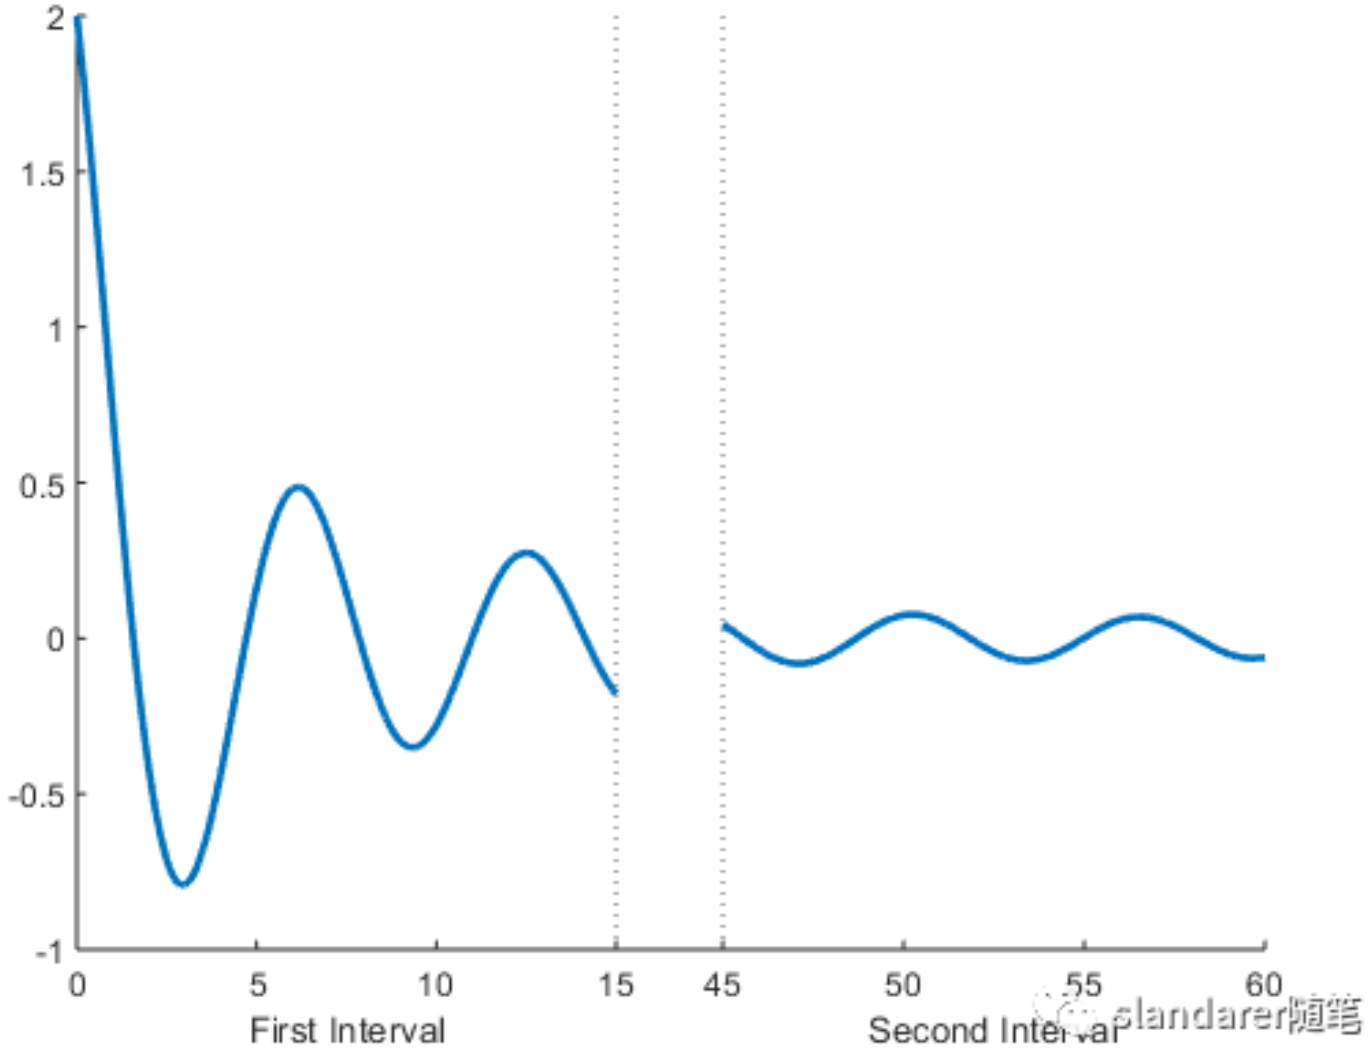


Matlab极坐标堆叠柱状图：示例



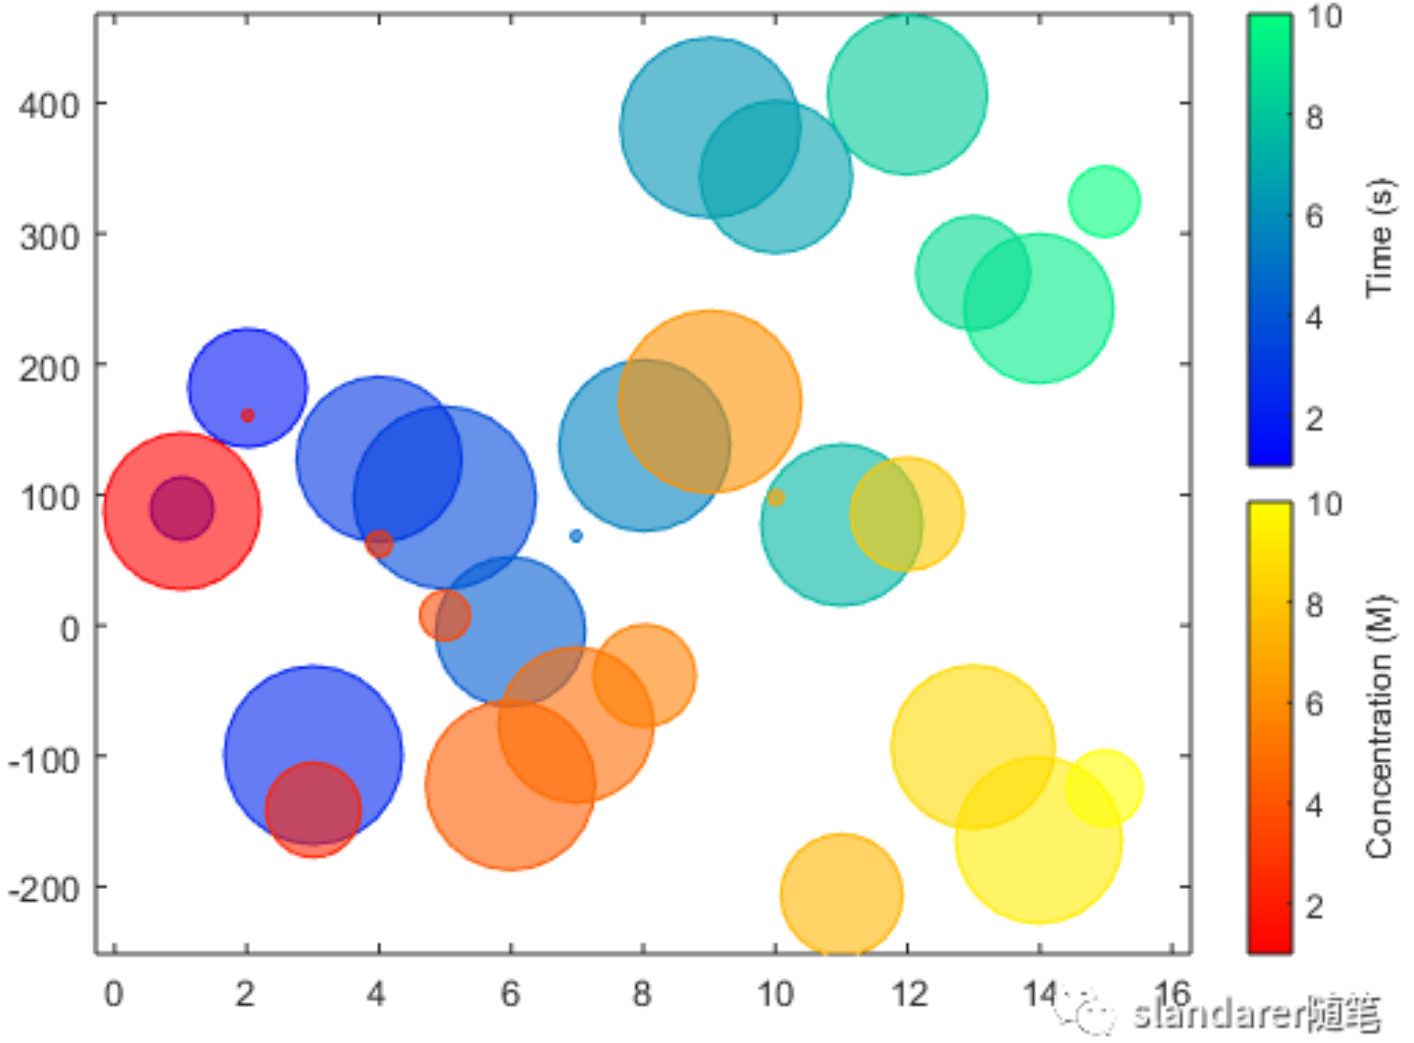
https://zhuanlan.zhihu.com/p/548265243

Matlab截断坐标轴：示例1



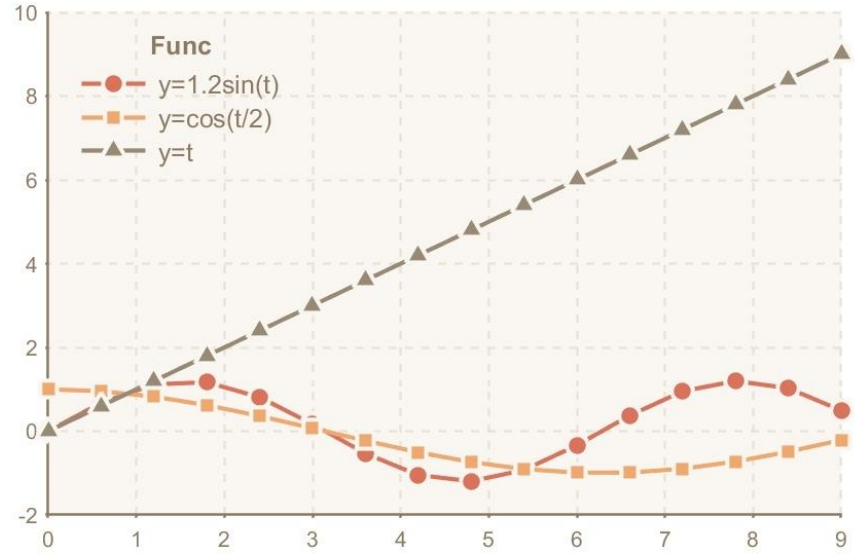
slandarer随笔

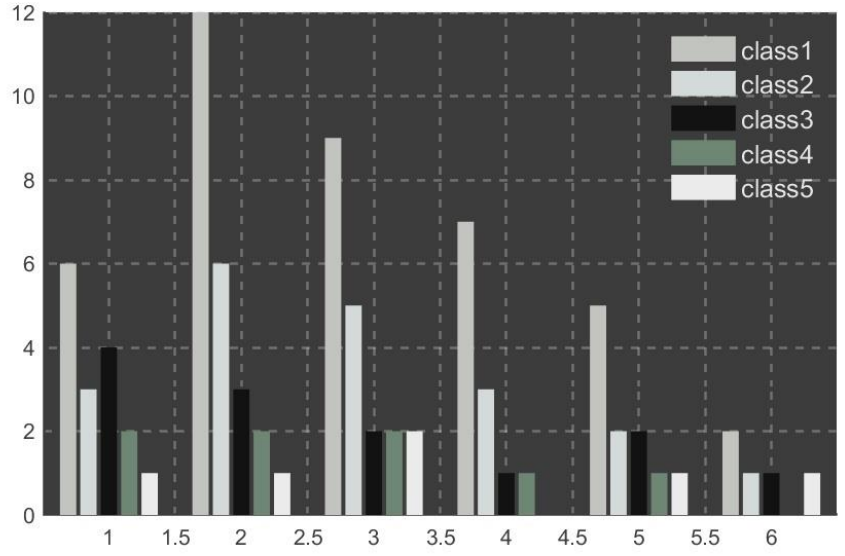
Matlab截断坐标轴：示例2

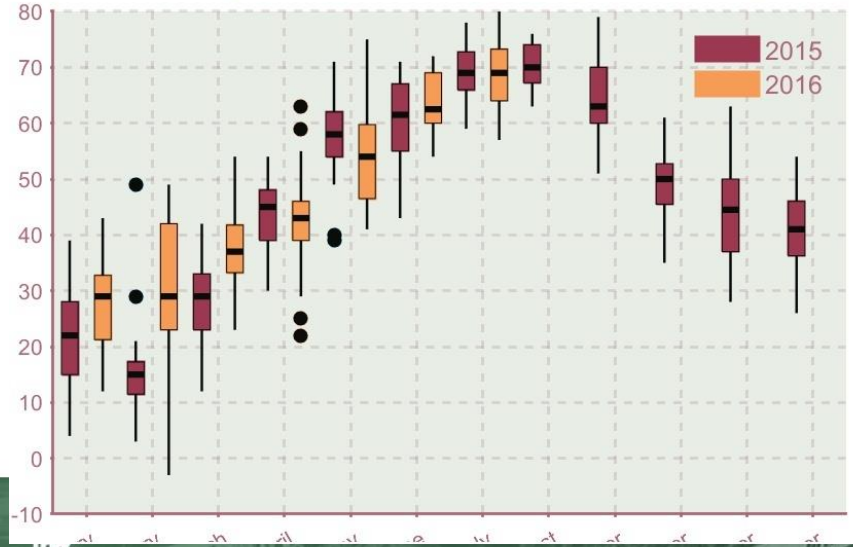


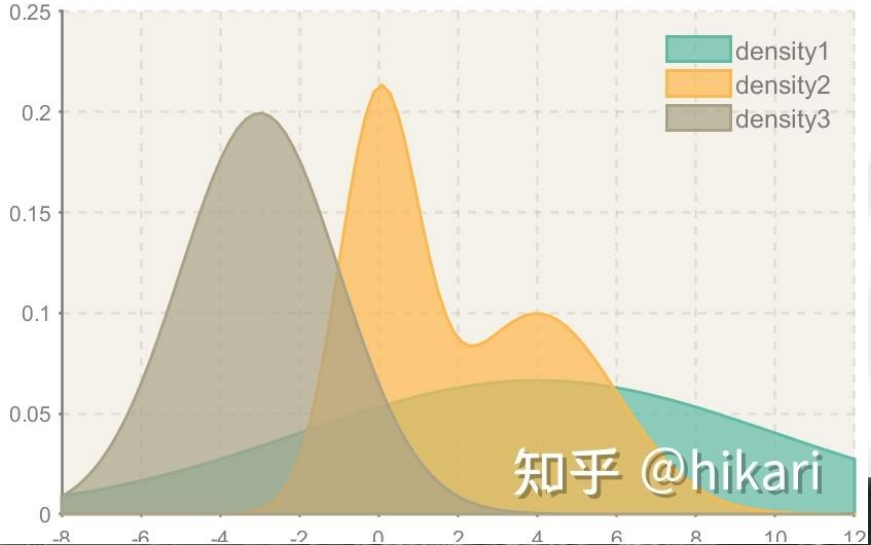
slandarer随笔

Matlab修饰的ggtheme风格：示例



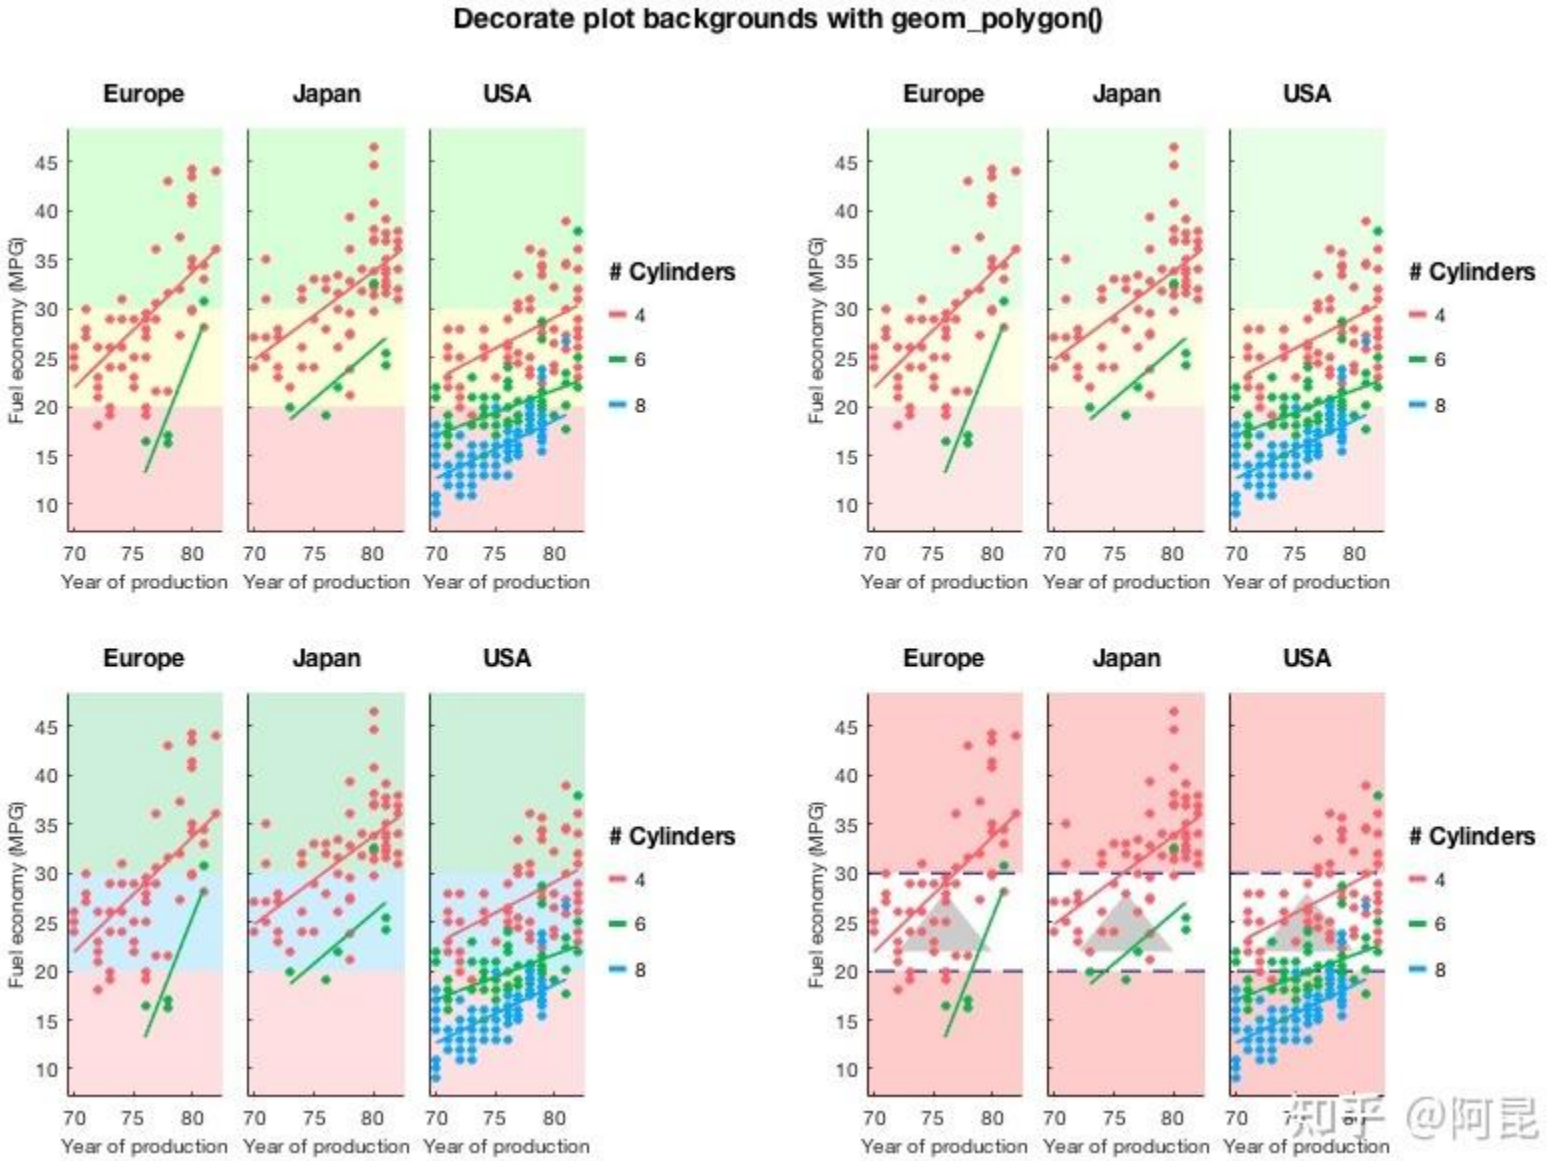






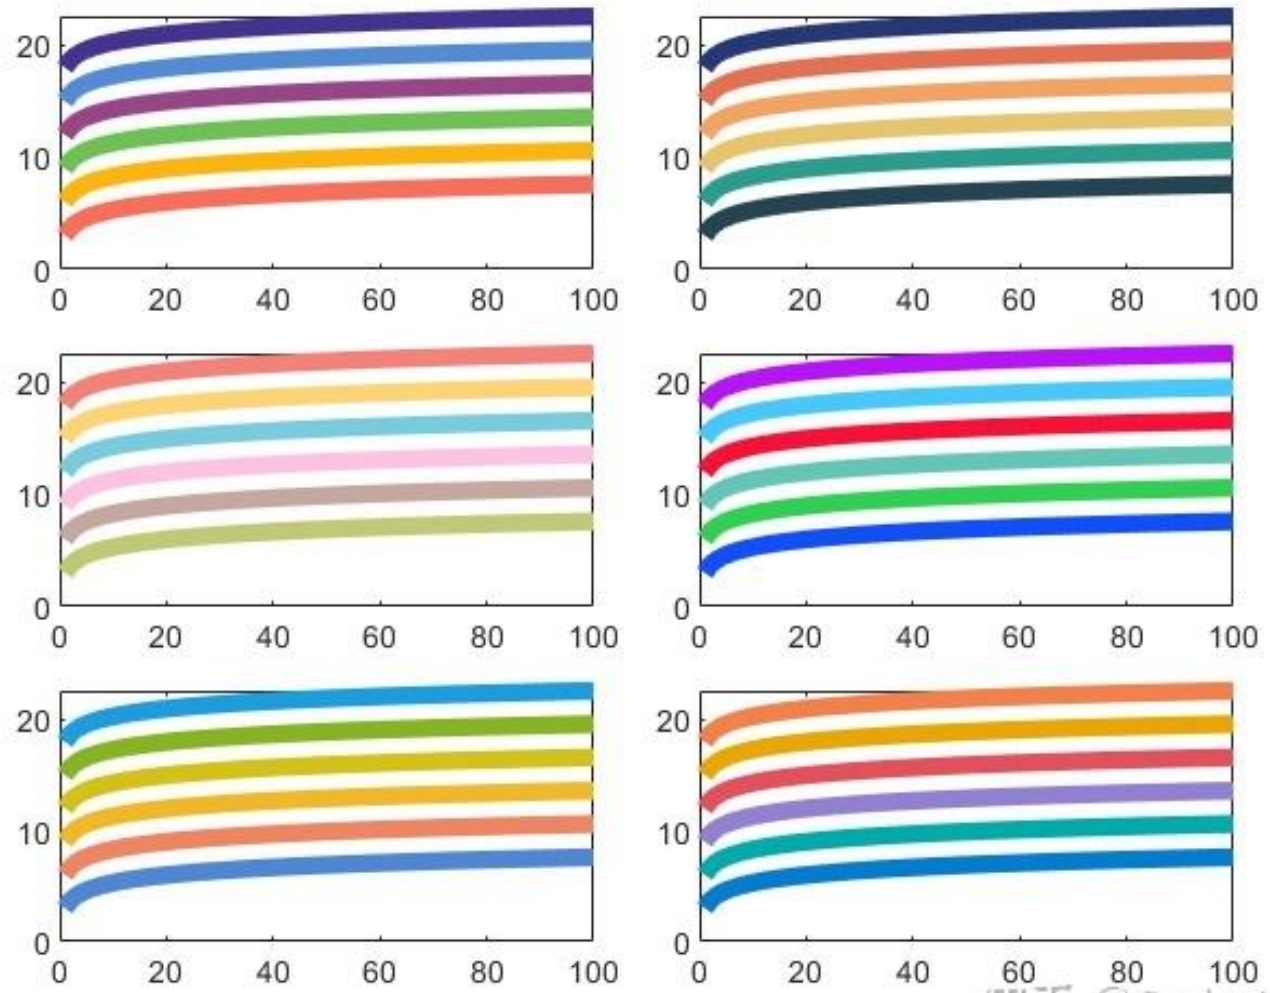
https://mp.weixin.qq.com/s/42XnXHyA3-OZVplQAMTAiA

Matlab的ggplot2工具箱：gramm



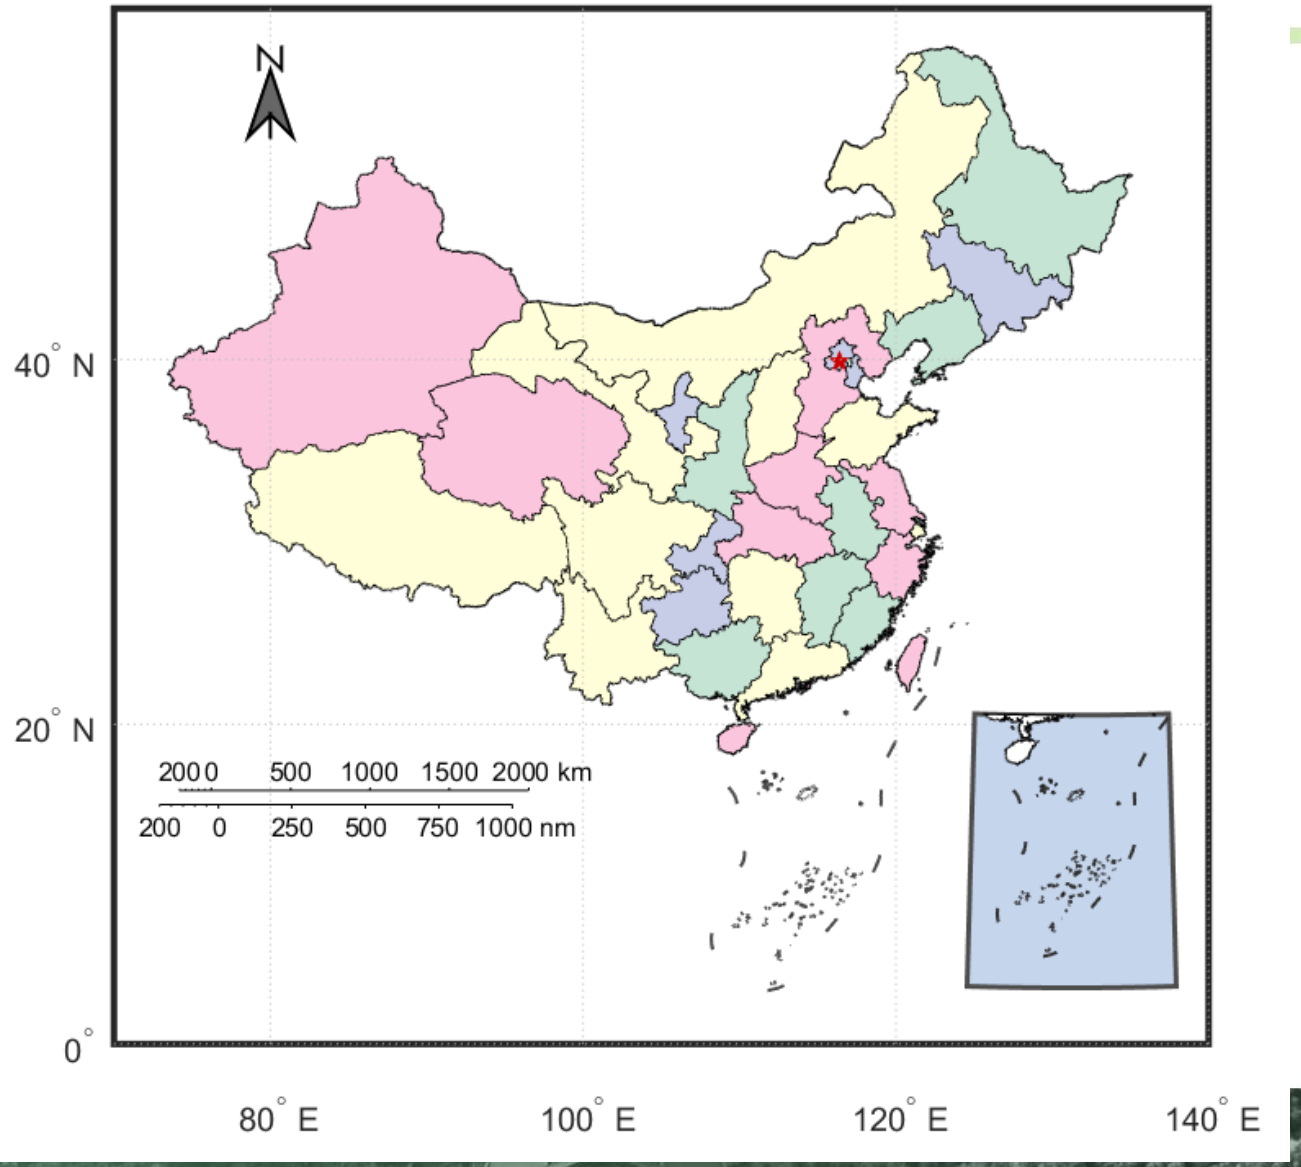
https://github.com/piermorel/gramm

Matlab的配色

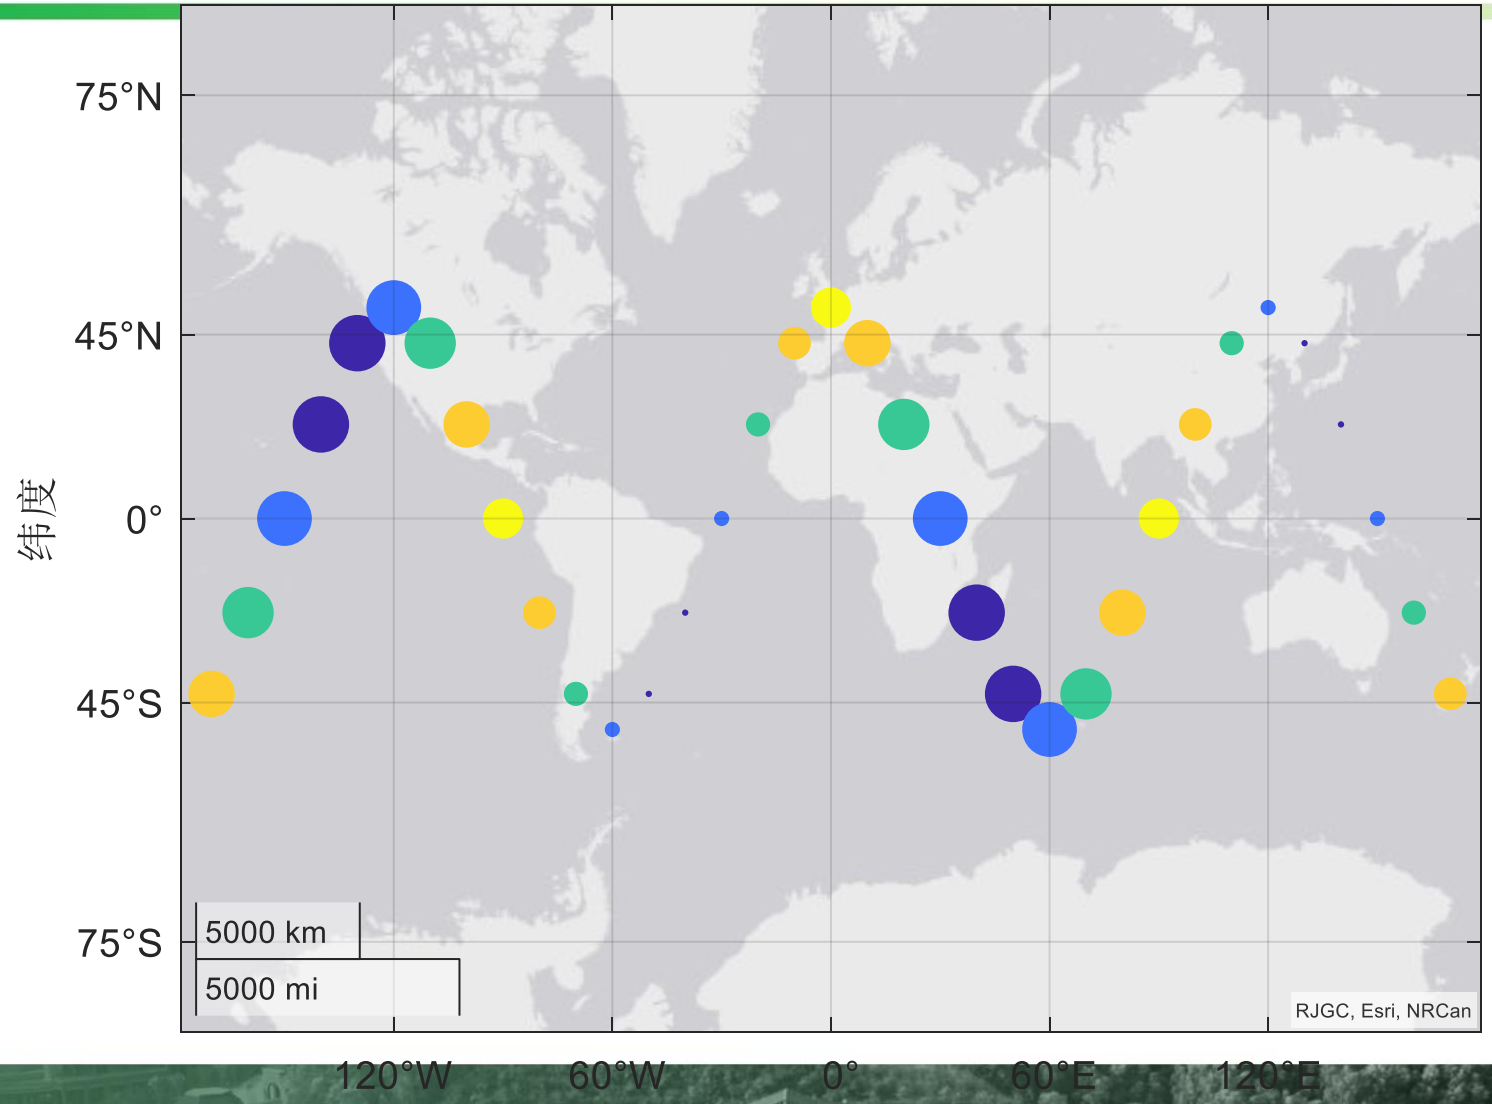


知乎 @CoderMan

Matlab中国地图绘制：示例

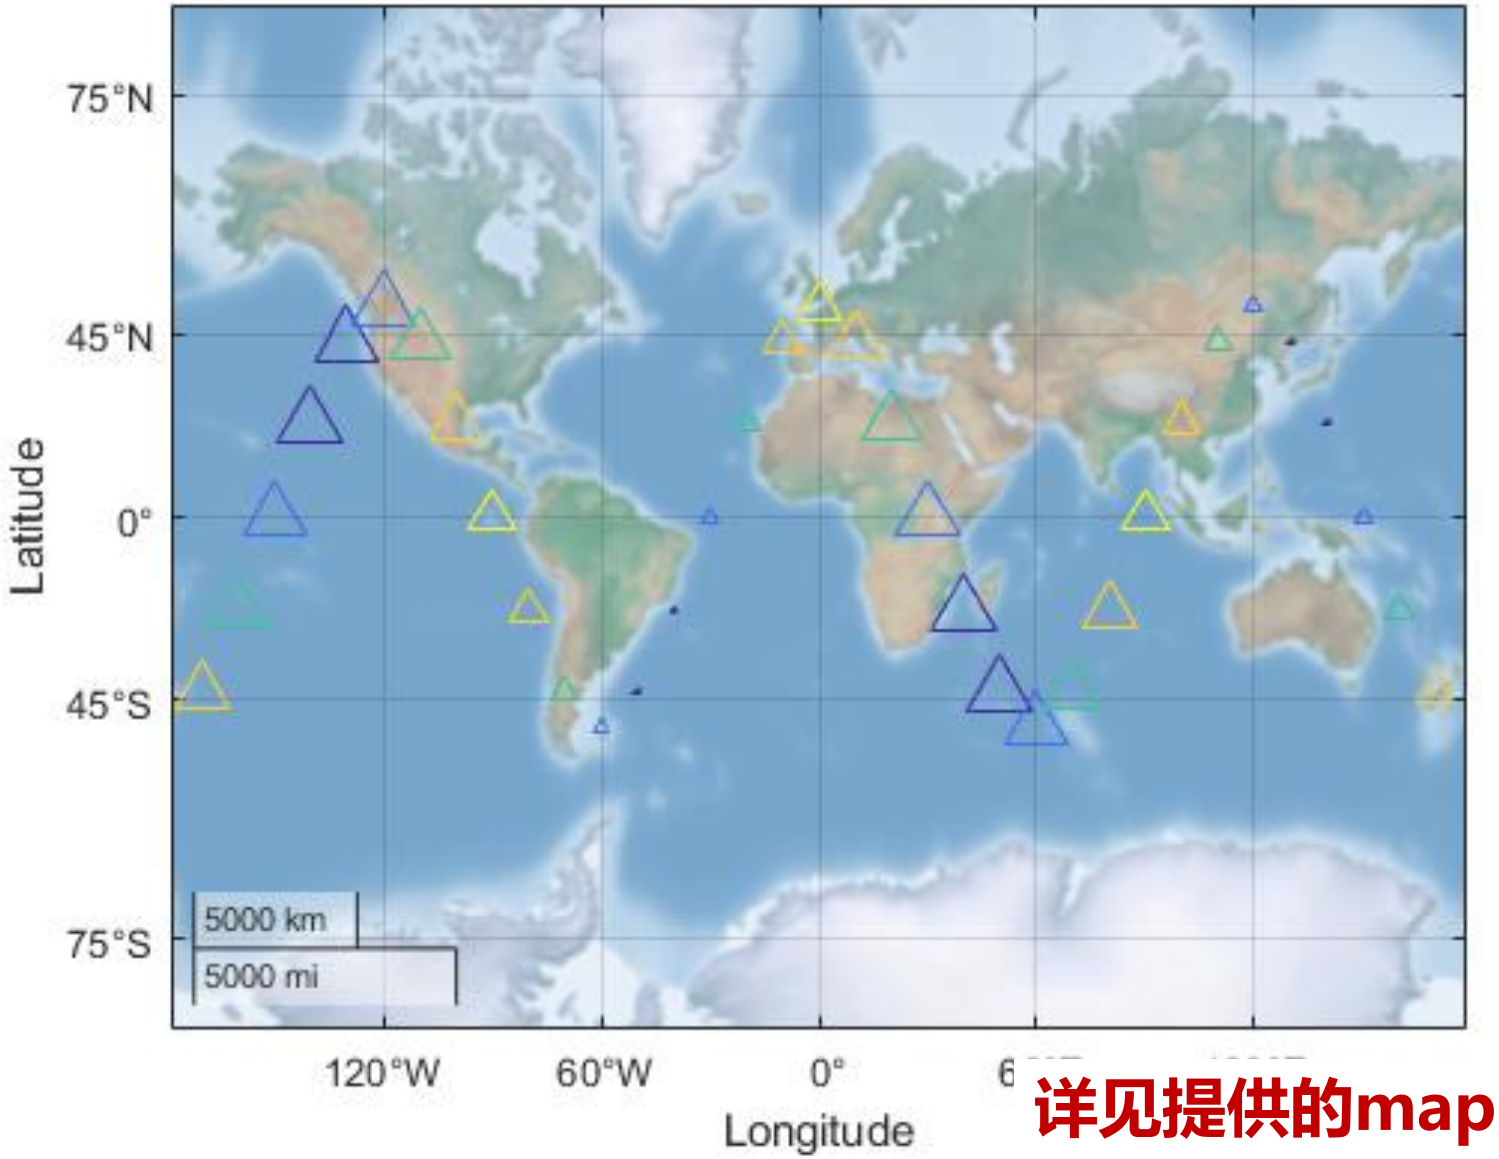


Matlab基于地图的散点图：示例1在



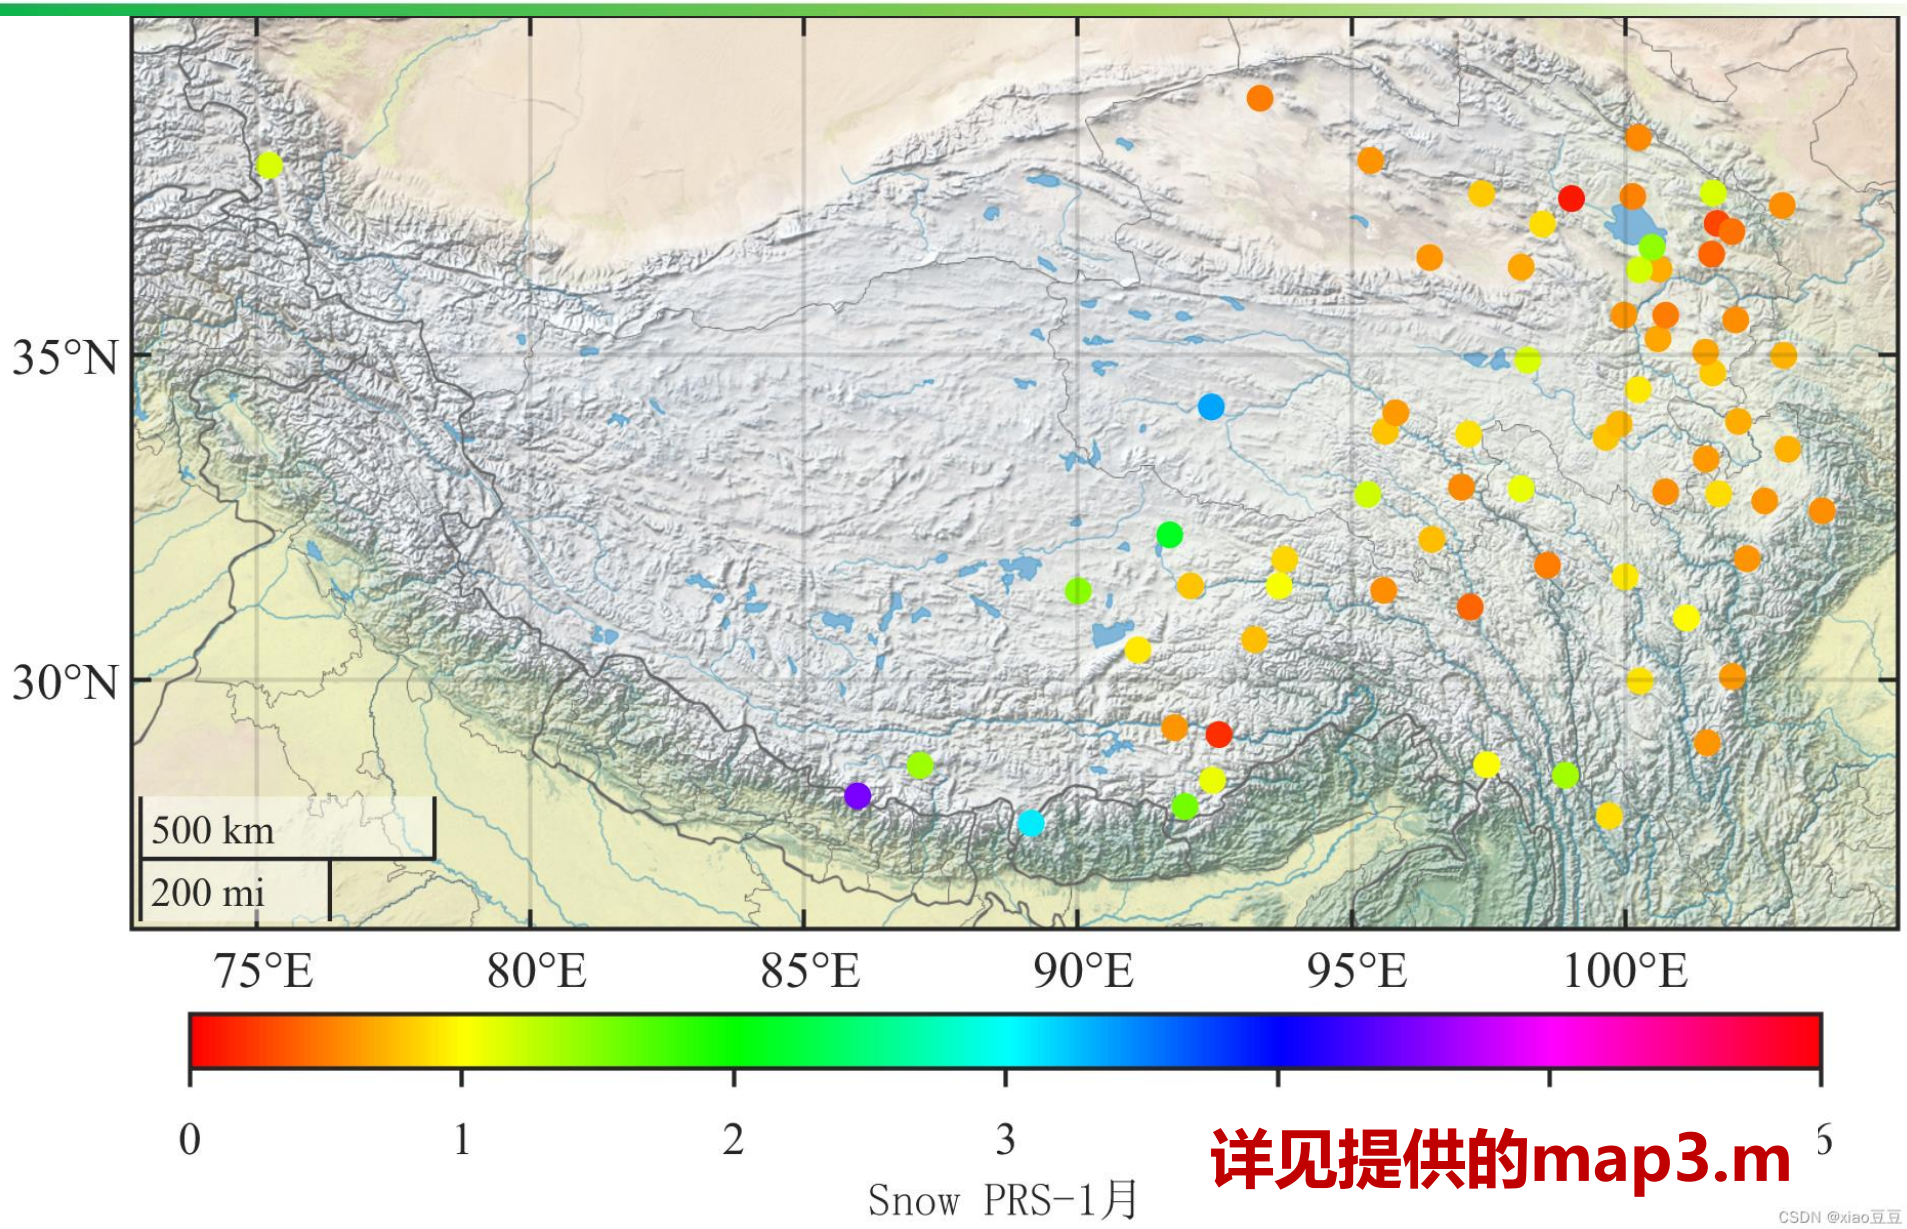
详见提供的map1.m

Matlab基于地图的散点图：示例2



详见提供的map2.m

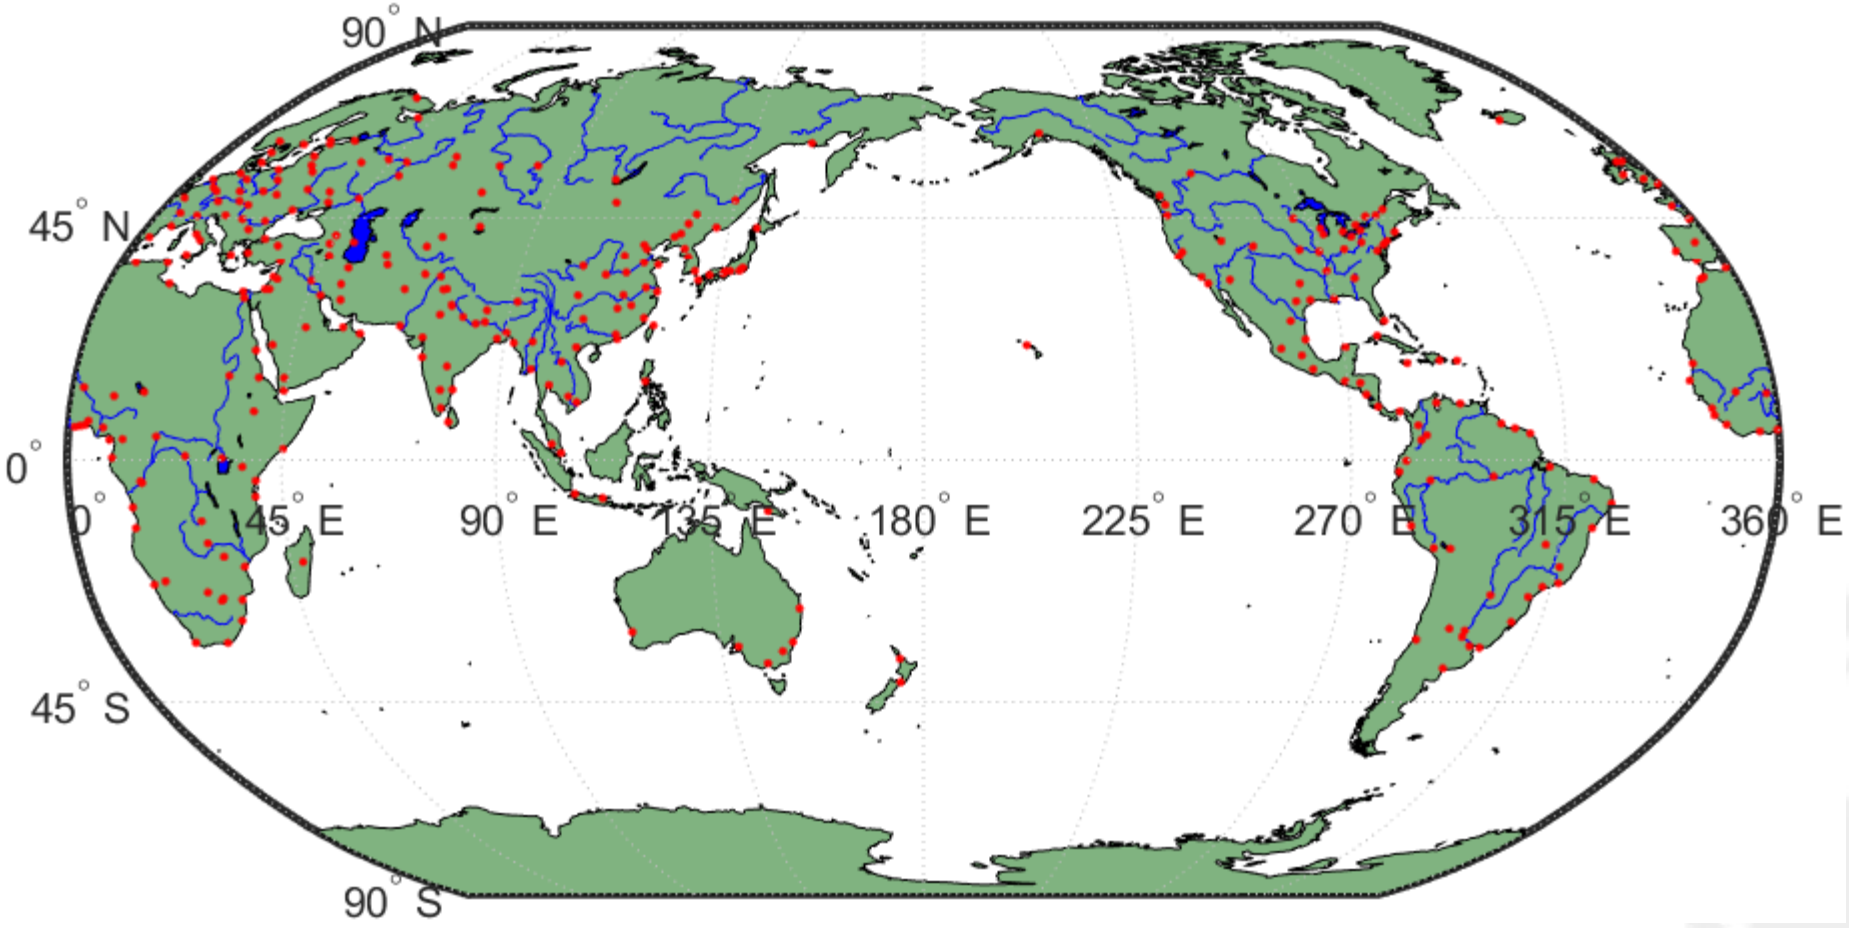
Matlab基于地图的散点图：示例3



详见提供的map3.m

CSDN @xiao豆豆

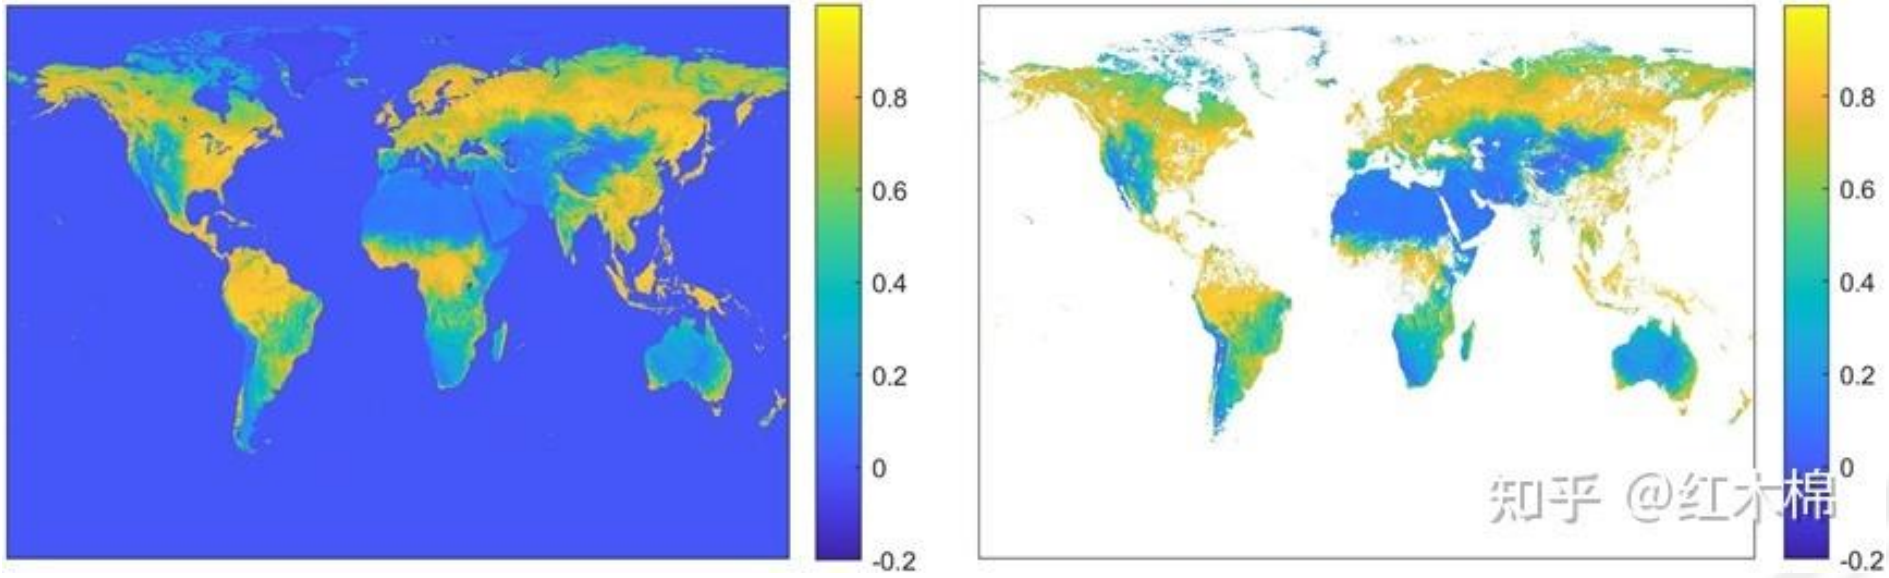
Matlab基于地图的散点图：示例4



比官网还要详细的地图绘制教程

https://mp.weixin.qq.com/s?__biz=Mzg4MTcwODk5Ng==&mid=2247485140&idx=1&sn=7ffe614acab02df59d013f74bd5b19c3&chksm=cf609c7ff8171569a0e5057b9893de6d7ee9b11bc99def77a54234a36b787a8214b3ee14a41a

Matlab基于地图的数据处理：示例



中大自地15级本科生的知乎专栏“基于MATLAB的地理数据处理”
https://www.zhihu.com/column/c_1500863916602871808

Python图形画法及举例

Python绘图包举例

包	功能	备注
ggplot	基于R的绘图系统ggplot2	R的ggplot2绘图模仿
matplotlib	二维绘图库：点线、散点、样式、坐标系、数学之心、等高线、热力图、饼图、分图显示、scatter 3D、wireframe 3D、surface 3D、contour 3D、经济柱形图、人口柱形图、股票图	Matlab绘图模仿
seaborn	用于制作有吸引力且信息丰富的统计图形的库	封装了matplotlib
pandas	最初被作为金融数据分析工具而开发出来，为时间序列分析提供了很好的支持。 名称来自于面板数据（panel data）和python数据分析（data analysis）。	封装了matplotlib的画图和numpy的计算
pandas profiling	生成具有可视化功能的统计分析报告，以进行快速数据分析	

Python绘图包举例

包	功能	备注
altair	基于Vega Lite的声明性统计可视化	
bokeh	用于Python的交互式Web绘图	
Chartify	Bokeh包装，使数据科学家更容易创建图表	
diagram	使用UTF8字符的文本模式图	
glumpy	OpenGL科学可视化库	
holoviews	来自注释数据的复杂和声明性可视化	
ipychart	Jupyter Notebook中使用Chart.js	
mayai	用Python进行交互式科学数据可视化和3D绘图	

Python绘图包举例

包	功能	备注
missingno	提供灵活的数据可视化工具集，允许基于matplotlib快速直观地总结数据集的完整性	
plotly	基于plotly.js的交互式网络可视化	
PyQtGraph	交互式实时2D/3D/图像打印和科学/工程小部件。	
PyVista –	通过可视化工具包（VTK）的流线型界面进行3D绘图和网格分析	
toyplot	儿童级别的Python绘图工具包，具有成人级别的目标	
three.py	基于PyOpenGL的易于使用的3D库。灵感来自Three.js	
veusz	Python多平台GUI绘图工具和图形库	
VisPy	基于OpenGL的高性能科学可视化	
vtk	3D计算机图形、图像处理和可视化，包括Python界面	
pyechars	基于Echarts库的Python绘图库	

Python的地理数据绘图

气象绘图加强版：

- 折线图、散点图、柱状图、坐标名、刻度、轴
- 等值线、Colorbar、框线的添加
- 多样Colorbar、三维地图
- 白化（裁剪）杂谈、底图的添加
- 地理桑基图（sankey）、子图坐标系统
- 3D图形迁移
- 图例、缓冲区、辅助线型

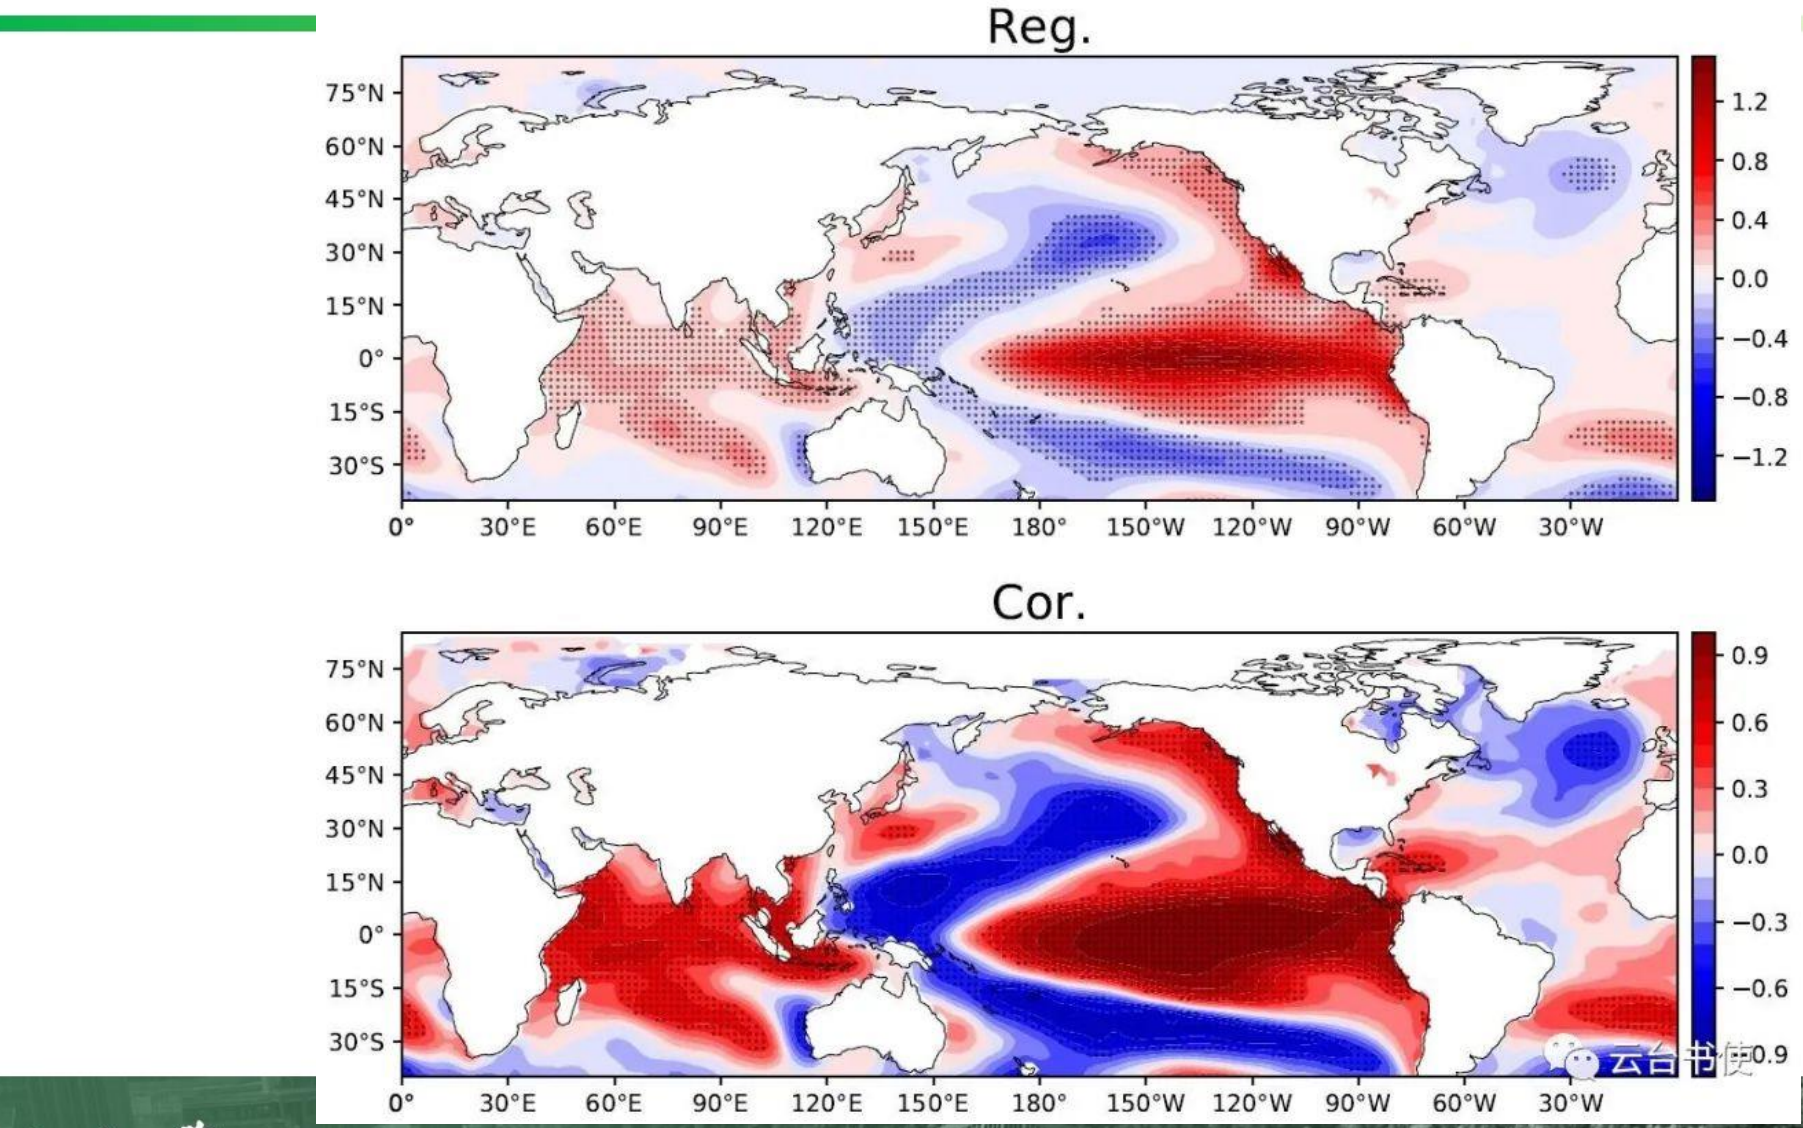
网址：

https://mp.weixin.qq.com/s/TSHselOjueB4eH8uWdFk9w





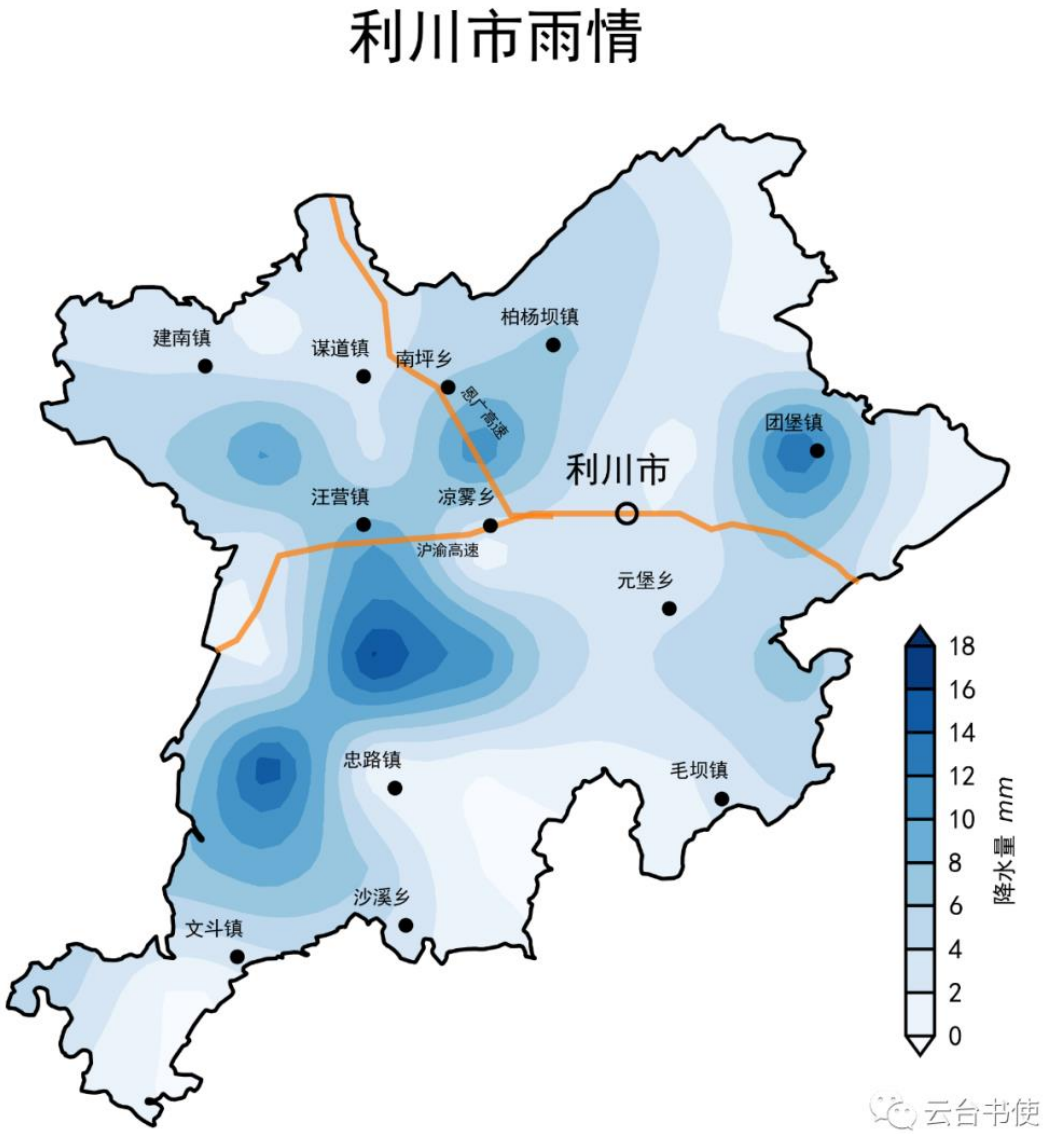
Python基于地图的插值图：示例1



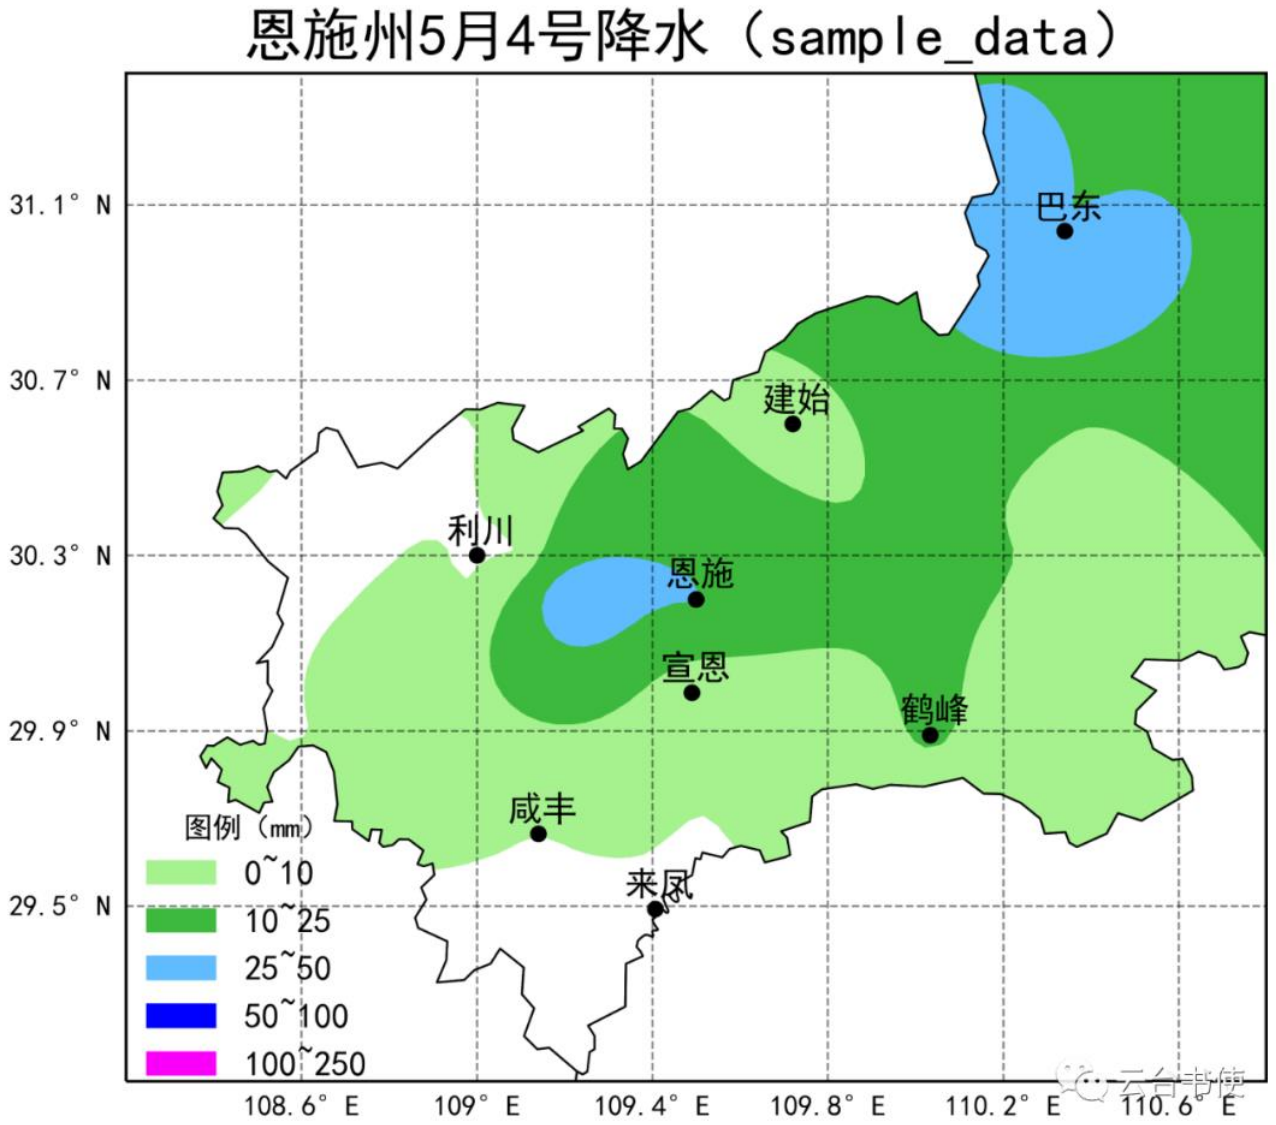
云台书使

http://bbs.06climate.com/forum.php?mod=viewthread&tid=92816&extra=page%3D1

Python基于地图的插值图：示例2



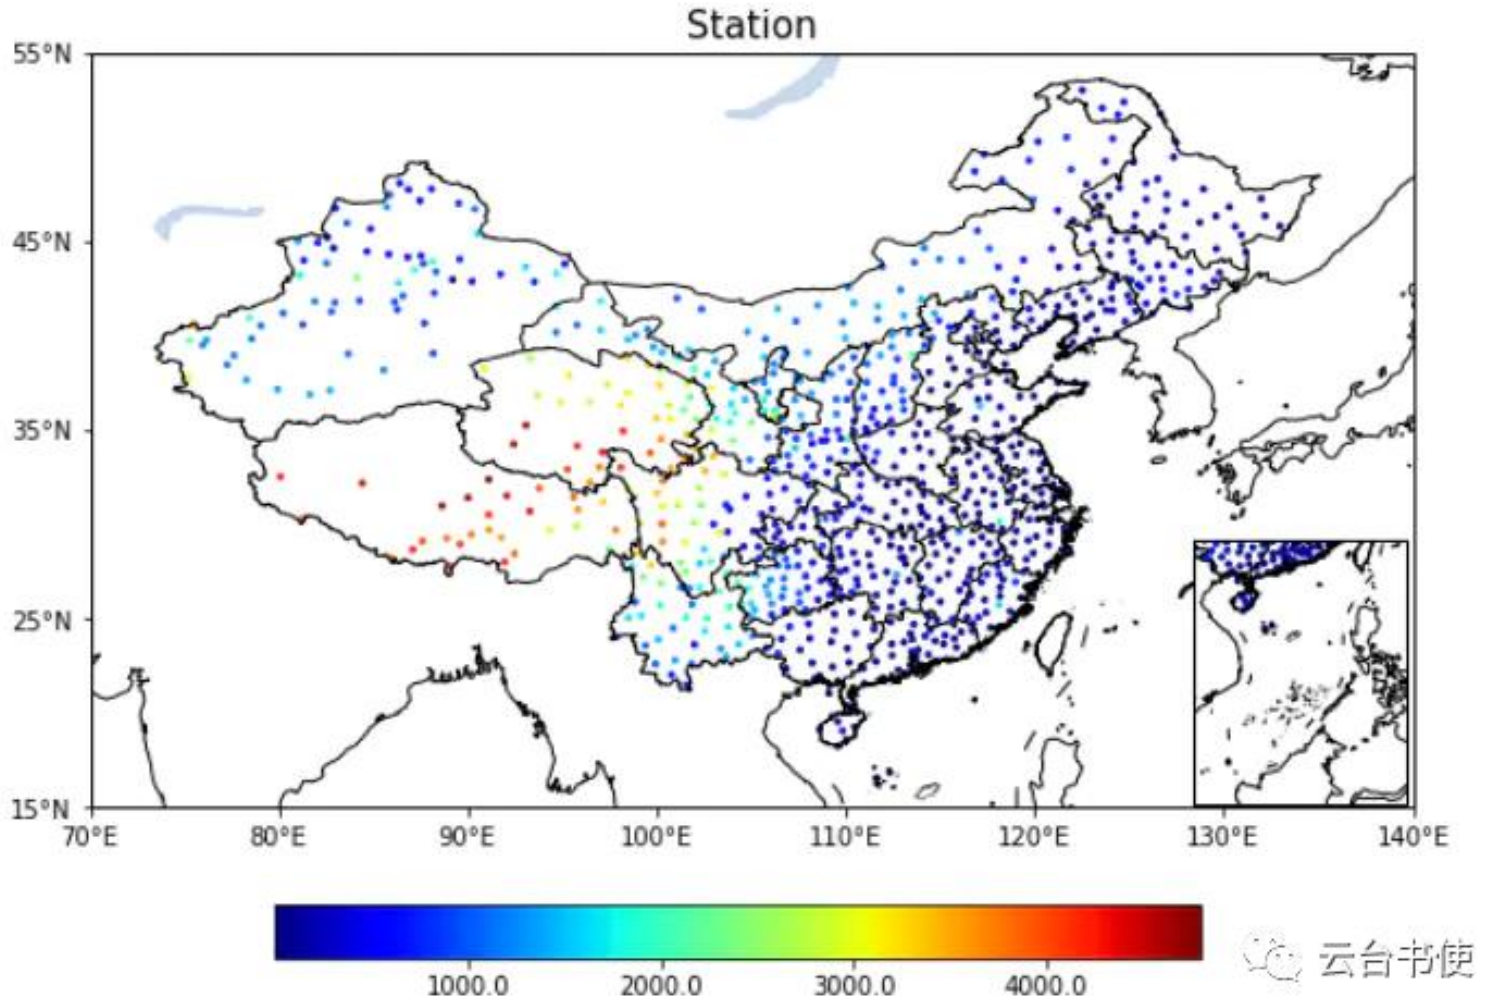
Python基于地图的插值图：示例3



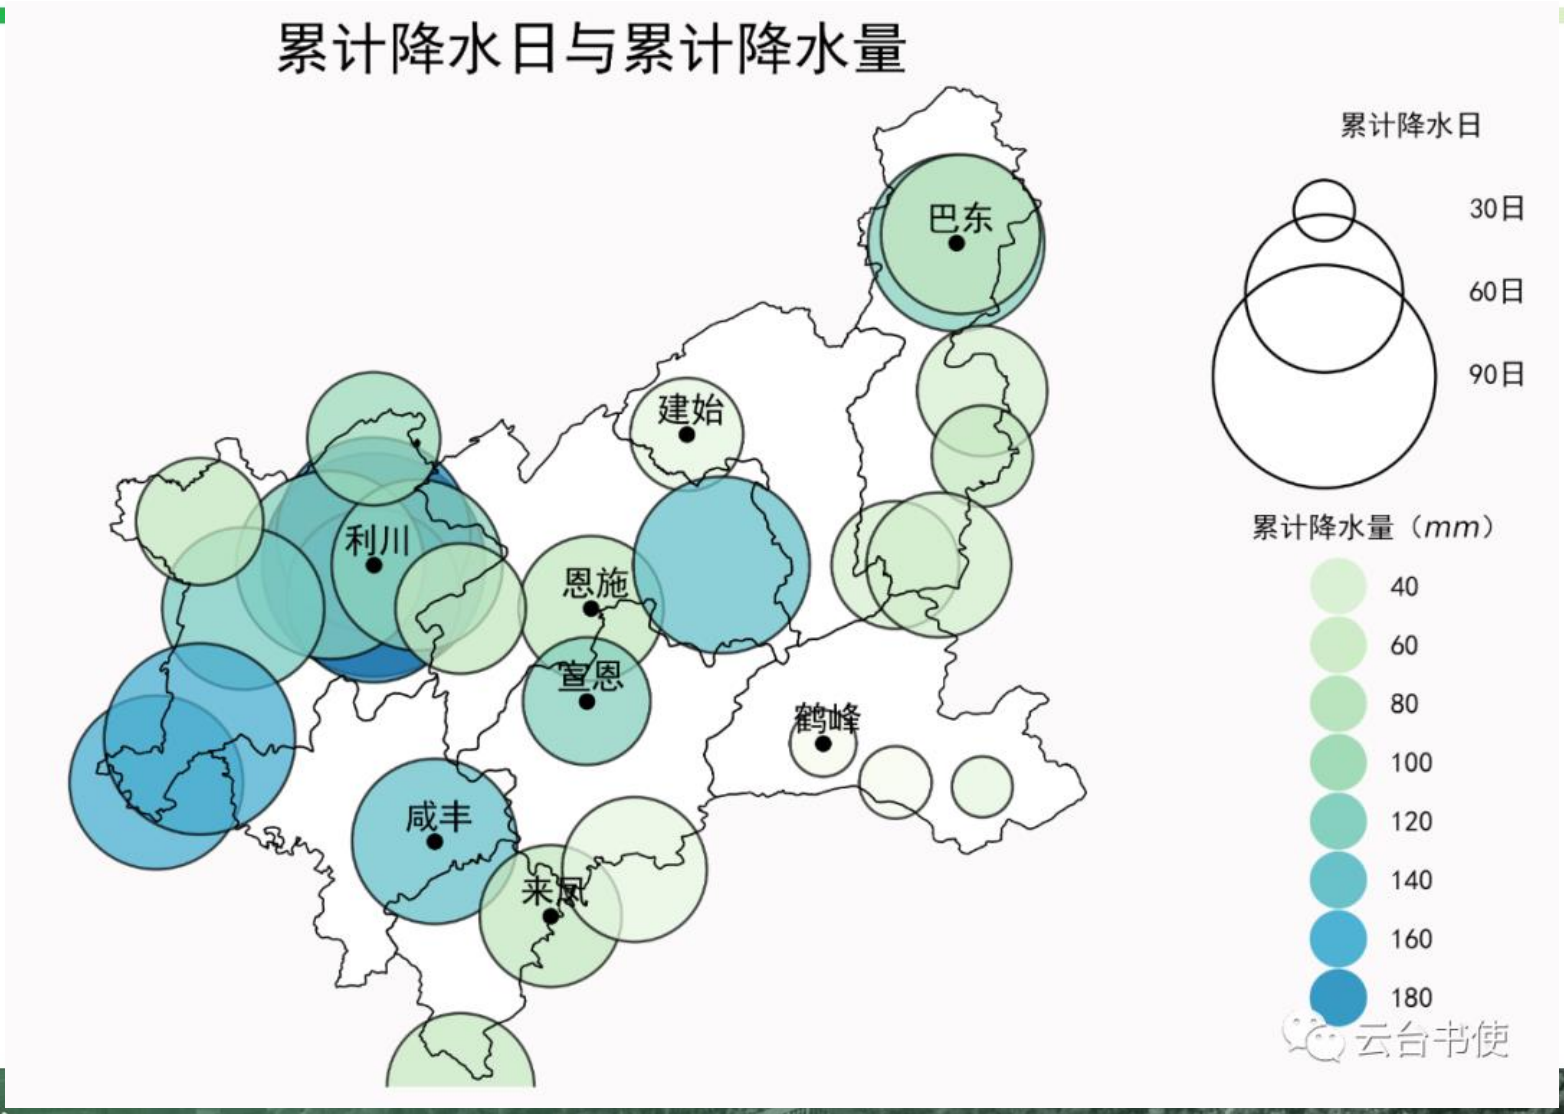
云台书使

https://mp.weixin.qq.com/s?__biz=MzIxODQxODQ4NQ==&mid=2247484024&idx=1&sn=6fe0d87f0f8bbbf086a0cf66db8ad34b&chksm=97eb9e22a09c17344b5a00c3862bd341670fede4635a67a16477e163081ee64fd7ae136cee88

Python基于地图的散点图：示例1

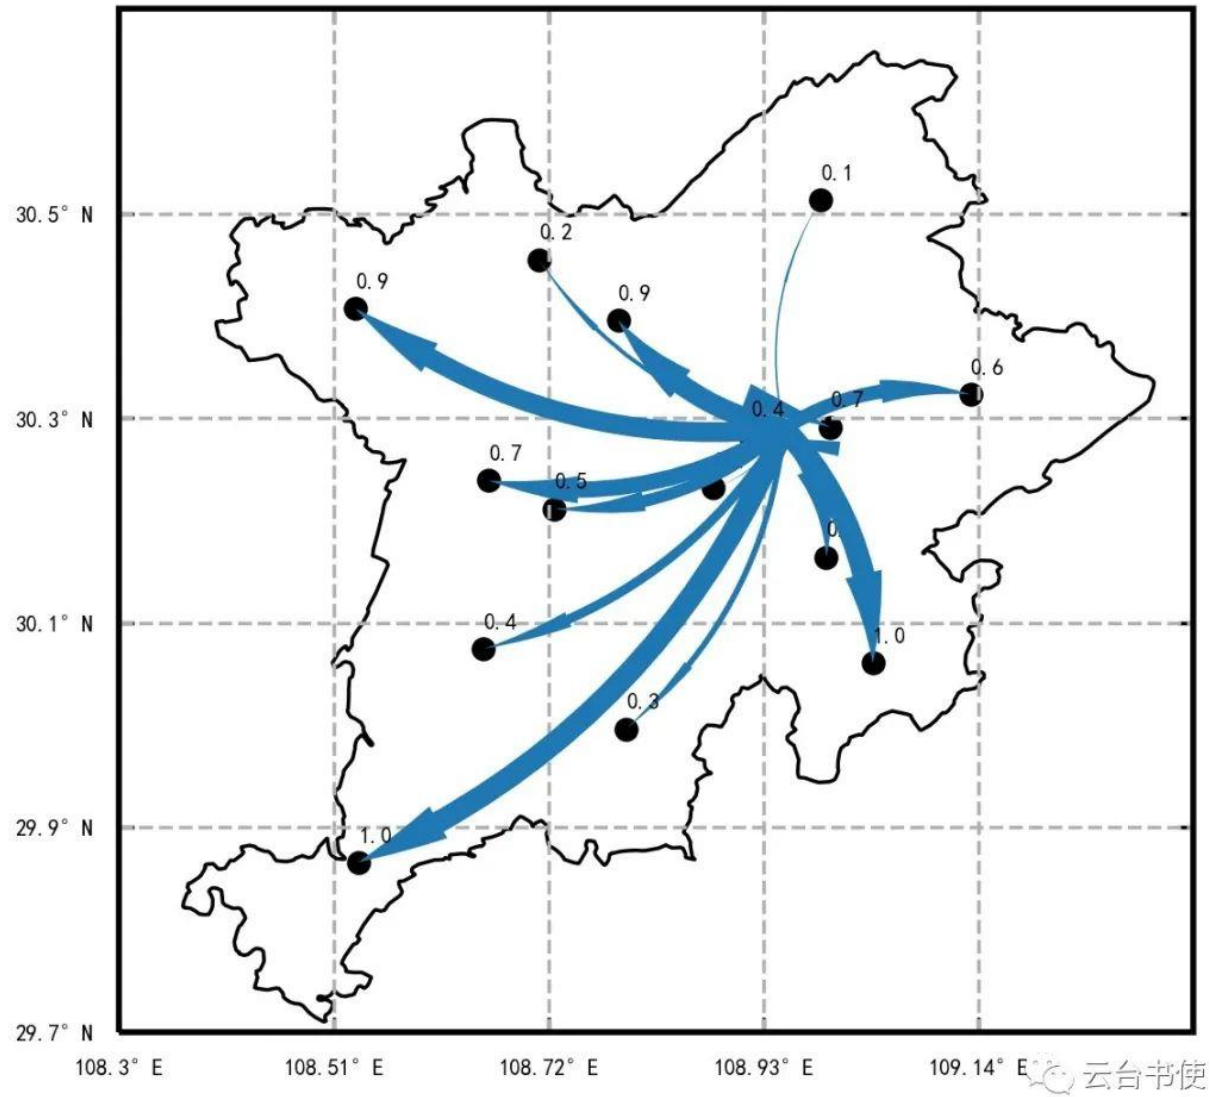


Python基于地图的散点图：示例2



https://mp.weixin.qq.com/s?__biz=MzIxODQxODQ4NQ==&mid=2247483990&idx=1&sn=d87aa08d6d03ee2af2e79a852b5d45da&chksm=97eb9e0ca09c171aff07a1fca448de87ae004786372353f5fc9e4033126cbd928d2e6e38ff3f

Python基于地图的散点图：示例3

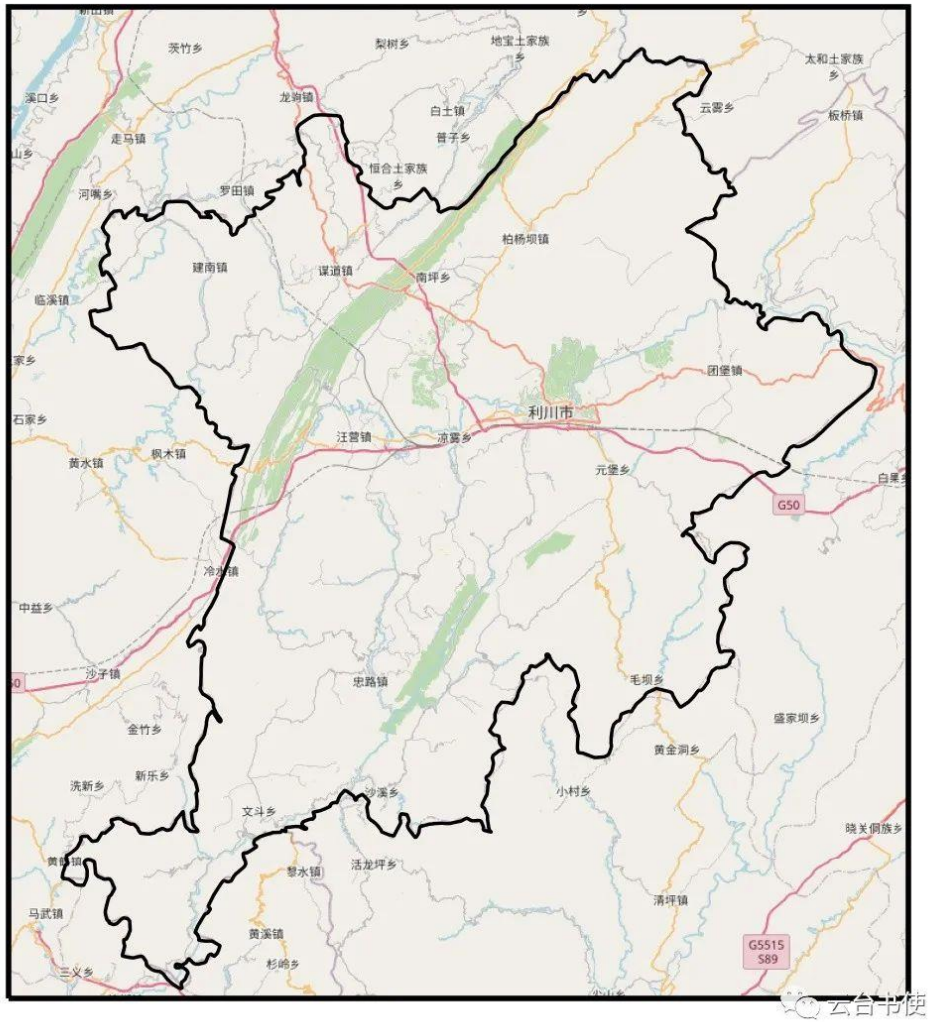


云台书使

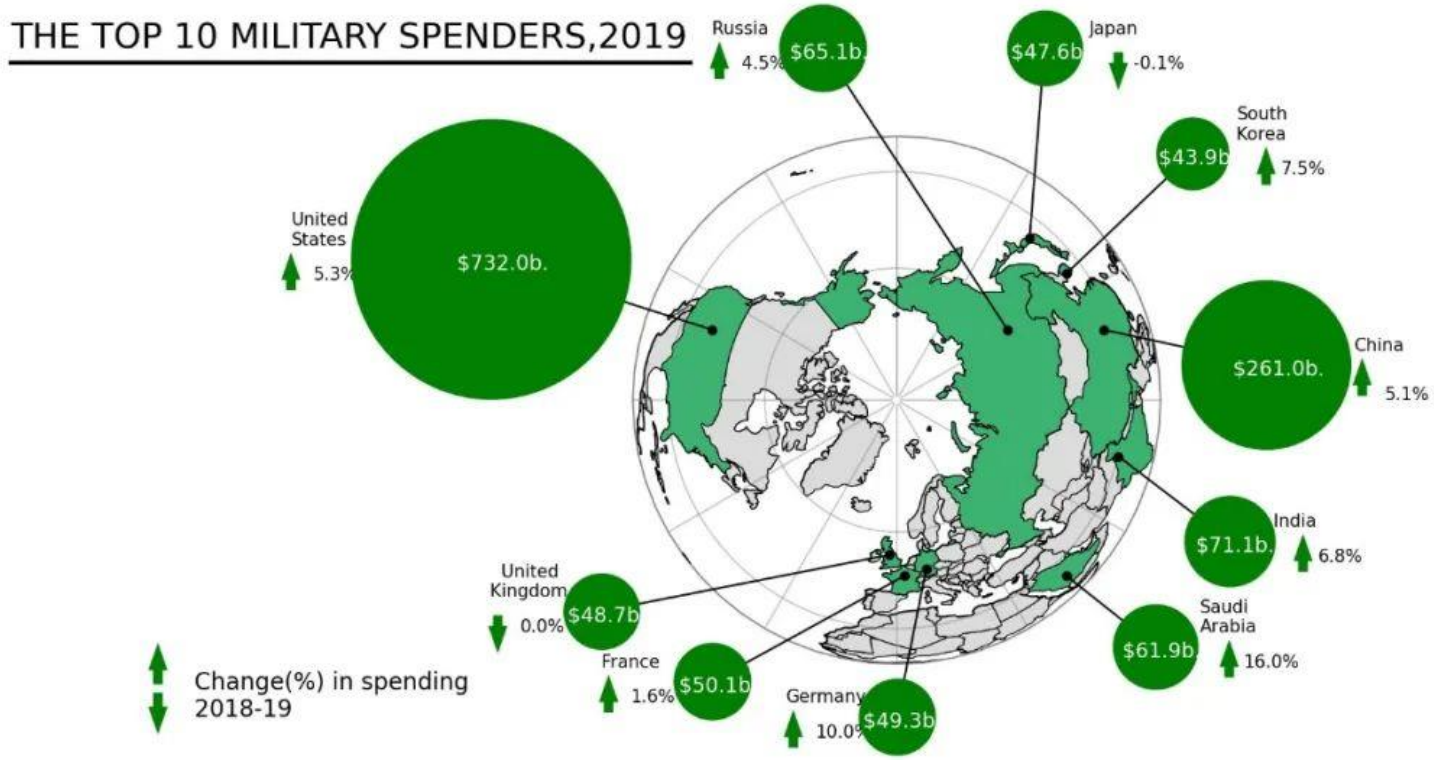
https://mp.weixin.qq.com/s?__biz=MzIxODQxODQ4NQ==&mid=2247484527&idx=1&sn=4e9d637a301a06582c098134a7b157f6&chksm=97eb9835a09c11233d939ff488215876112d67d7cbc73f384a5d3240db3abd4e6b3ea66de8ce

Python的叠加图：示例

利川shp地图与OSM瓦片地图叠加



Python的投影图：示例



https://mp.weixin.qq.com/s?__biz=MzIxODQxODQ4NQ==&mid=2247484373&idx=1&sn=b4636757fdf11505d1d7c323dcae6156&chksm=97eb9f8fa09c16999483751560ba74ca29bcff39ead54b9accb0f7db2c593cfcf9ed807d4656

练习

练习：了解数据预处理和可视化

目的：生成一个随机表格数据，进行预处理和可视化。

1. **生成数据**：
   - **Data1**：100×1列，1到10000整数，不重复，**站点S1**
   - **Data2**：100×4列，**站点S2**（与S1范围相同，但重新随机生成，故存在差异），**温度T**（-10，45）；**降雨P**（0，1000）；**虚拟变量Y**（10*T+P）；
2. **数据污染**： Data2的T列20行，P列40行，Y列60行分别设定为NaN
3. **数据清洗**：找到空缺位置，使用属性的相邻值填充T和P列空缺值，计算Y列空缺值

练习：了解数据预处理和可视化

4. **数据集成**：将Data1和Data2按照相同站点合并成Data 3
5. **数据缩减**：计算Data3的T列、P列分别与Y列的相关系数；将Data3放回抽样40个样本成Data4
6. **数据变换**：将Data3的T、P列、Y列按照最小 - 最大规范化转换成Data5（范围在0到1之间）
7. **可视化**：画出和比较Data3和Data4的四列分布图（2×2）和按照S列排序以后的序列图（2×2）；画出Data5的3列分布图（3×1）；

小结

思考

- 为什么需要数据预处理?
- 数据预处理的主要任务?
- Matlab画二维和三维图的基本命令?
- Python画二维和三维图的基本命令
- R语言画图?

Matlab画图参考网站

- **官方画图示例**

  https://ww2.mathworks.cn/products/matlab/plot-gallery.html

  https://ww2.mathworks.cn/matlabcentral/profile/authors/3166380

- **第三方介绍**
- MATLAB | MATLAB不会画图？官方团队来教你！

Matlab画图参考网站

- **有哪些好用的绘图软件推荐?**
  https://www.zhihu.com/question/39417414/answer/2695071131
- **基于MATLAB的地理数据处理**
  https://www.zhihu.com/column/c_1500863916602871808
- **Gramm (完整数据可视化工具箱, ggplot2/R-like)**
  https://ww2.mathworks.cn/matlabcentral/fileexchange/54465-gramm-complete-data-visualization-toolbox-ggplot2-r-like
- **Matlab案例代码解析**
  https://www.zhihu.com/column/c_1491138434131083264
- **你在科研中用什么软件作图?**
  https://www.zhihu.com/question/268877581/answer/2277678667

Python参考网站

- **matplotlib 官网 https://matplotlib.org/**
- **气象绘图加强版 https://mp.weixin.qq.com/s/TSHselOjueB4eH8uWdFk9w**
- **Cartopy气象领域Python制图的必学库** https://www.heywhale.com/mw/project/5f1a4df794d484002d2db14a
- **Cartopy 官网 https://scitools.org.uk/cartopy/docs/latest/**