人工智能与地理数据挖掘

第四讲 聚类分析

孙伟 sunwei29@mail.sysu.edu.cn

地理科学与规划学院

中山大學 SUN YAT-SEN UNIVERSITY

2026.03

目录

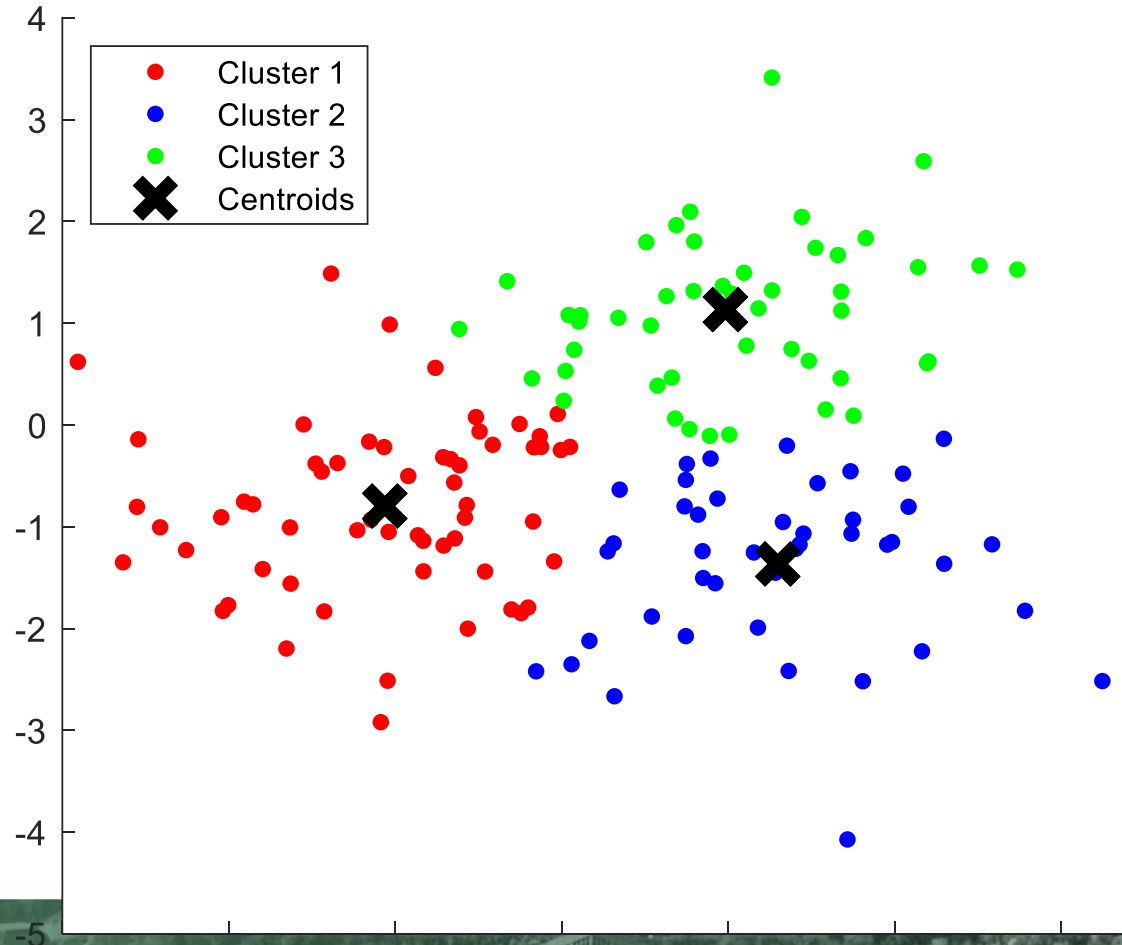
1. 聚类分析概述
2. 层次聚类
3. K均值聚类
4. DBSCAN
5. 评估和优化
6. 案例研究
7. 小结

1.聚类分析概述

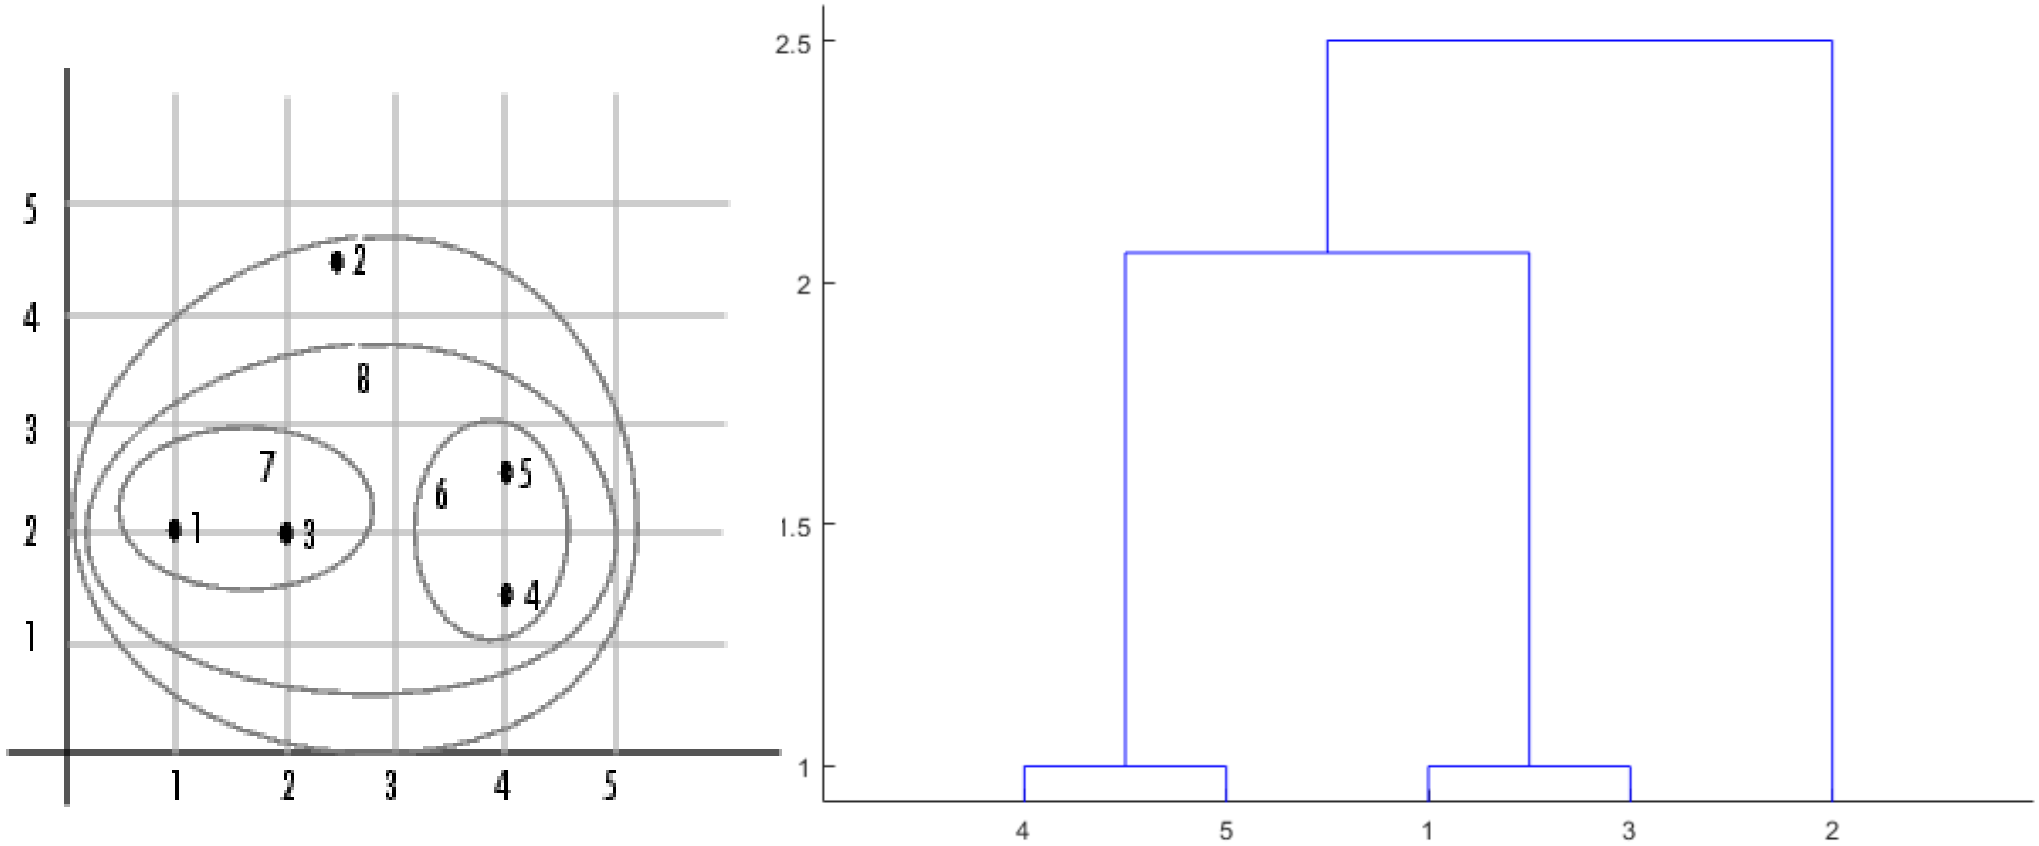
例子1：2维原始数据



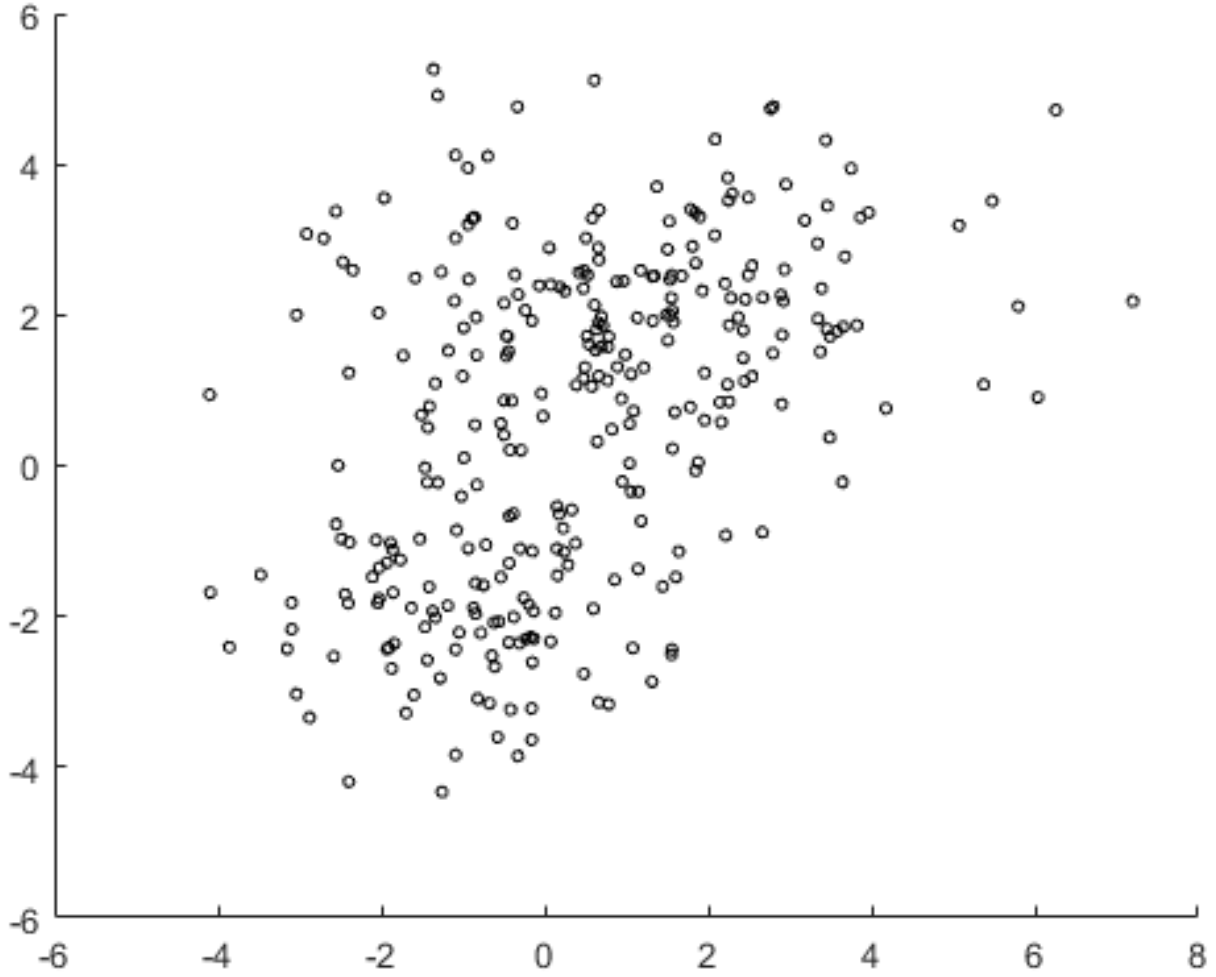
例子1：k均值聚类结果


Cluster 1
Cluster 2
Cluster 3
Centroids
4
3
2
1
0
-1
-2
-3
-4
-5
-3
-2
-1
0
1
2
3
4

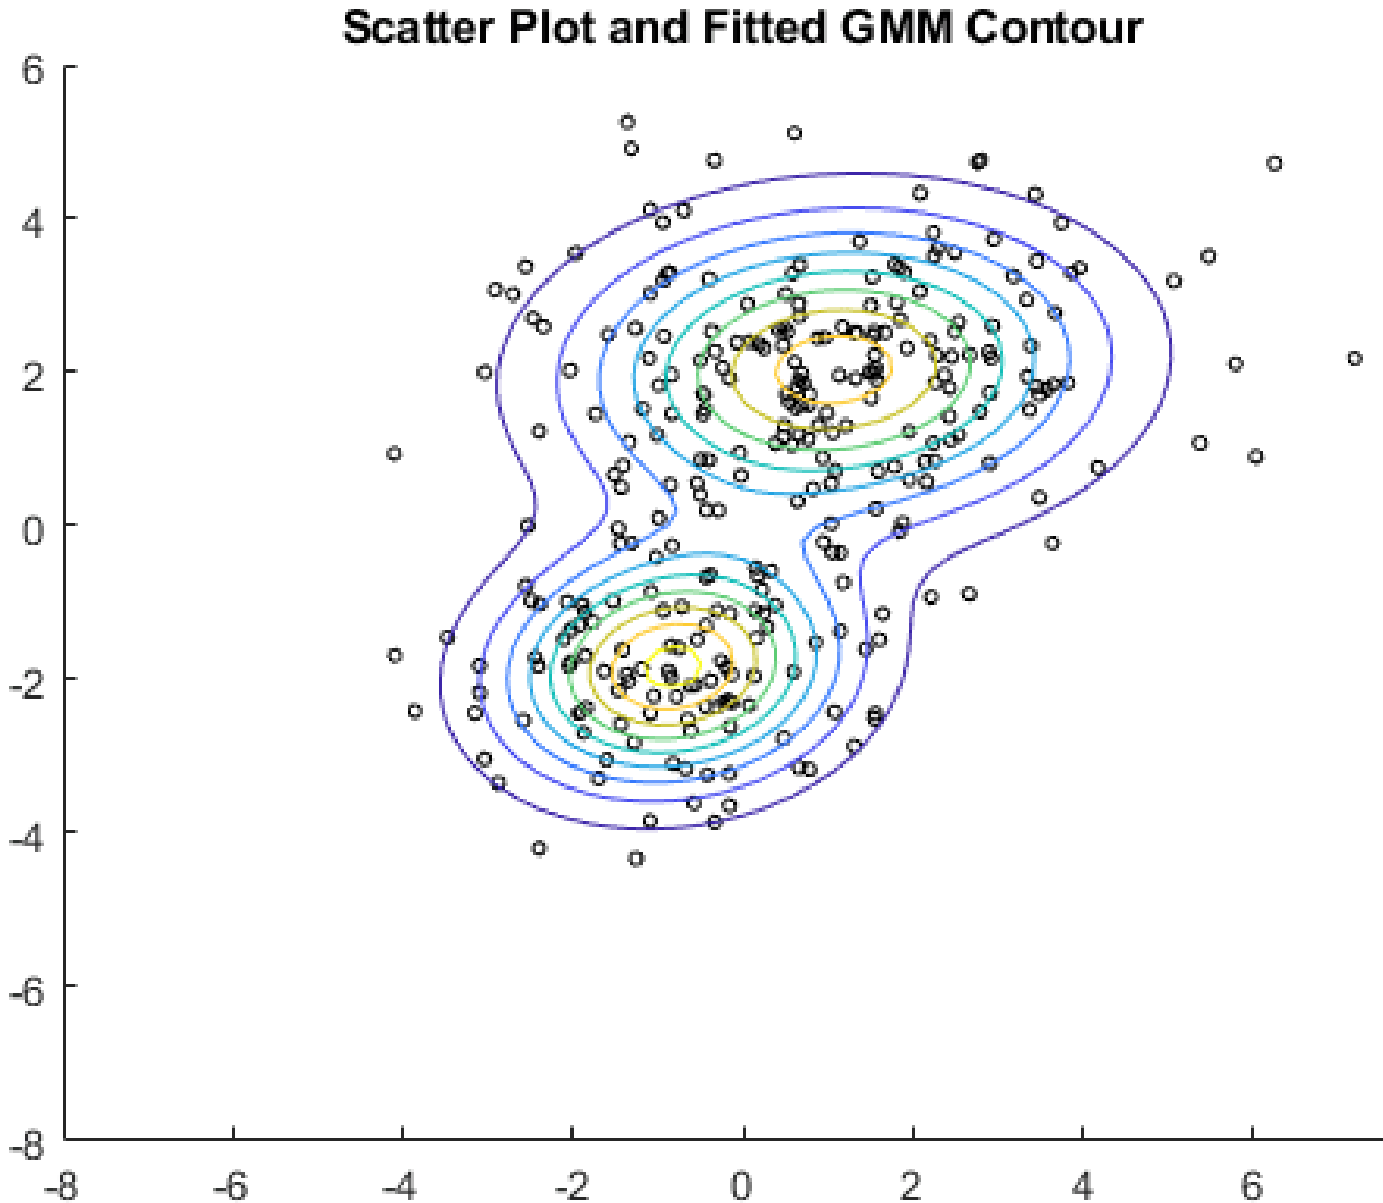
例子2： 层次聚类法



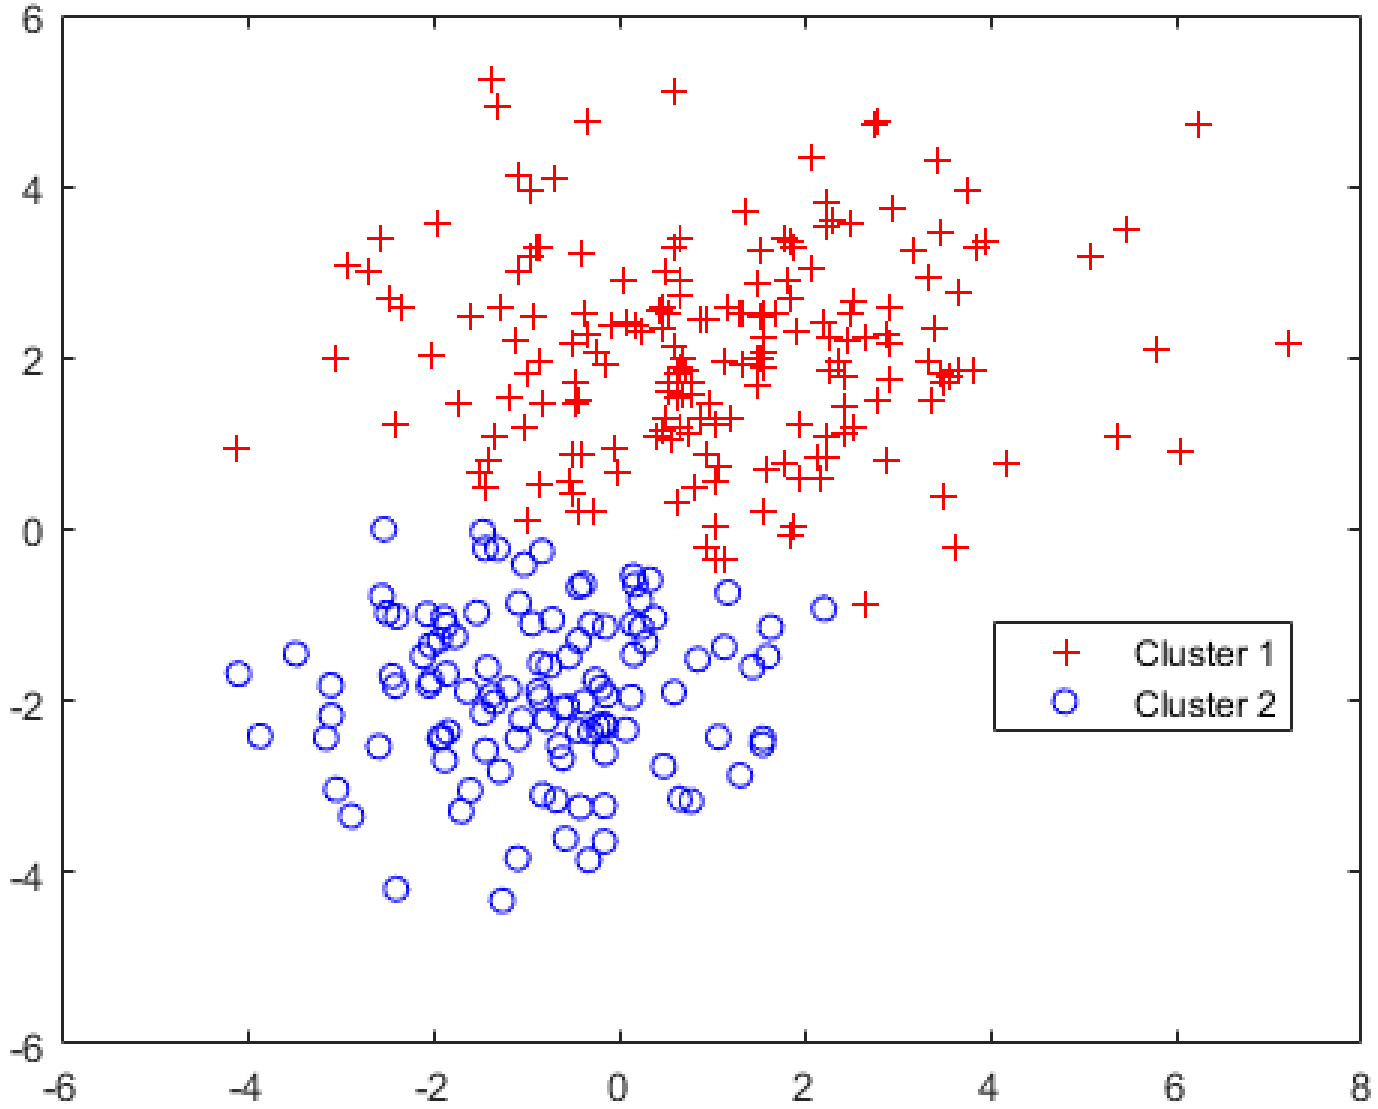
例子3： 2维原始数据



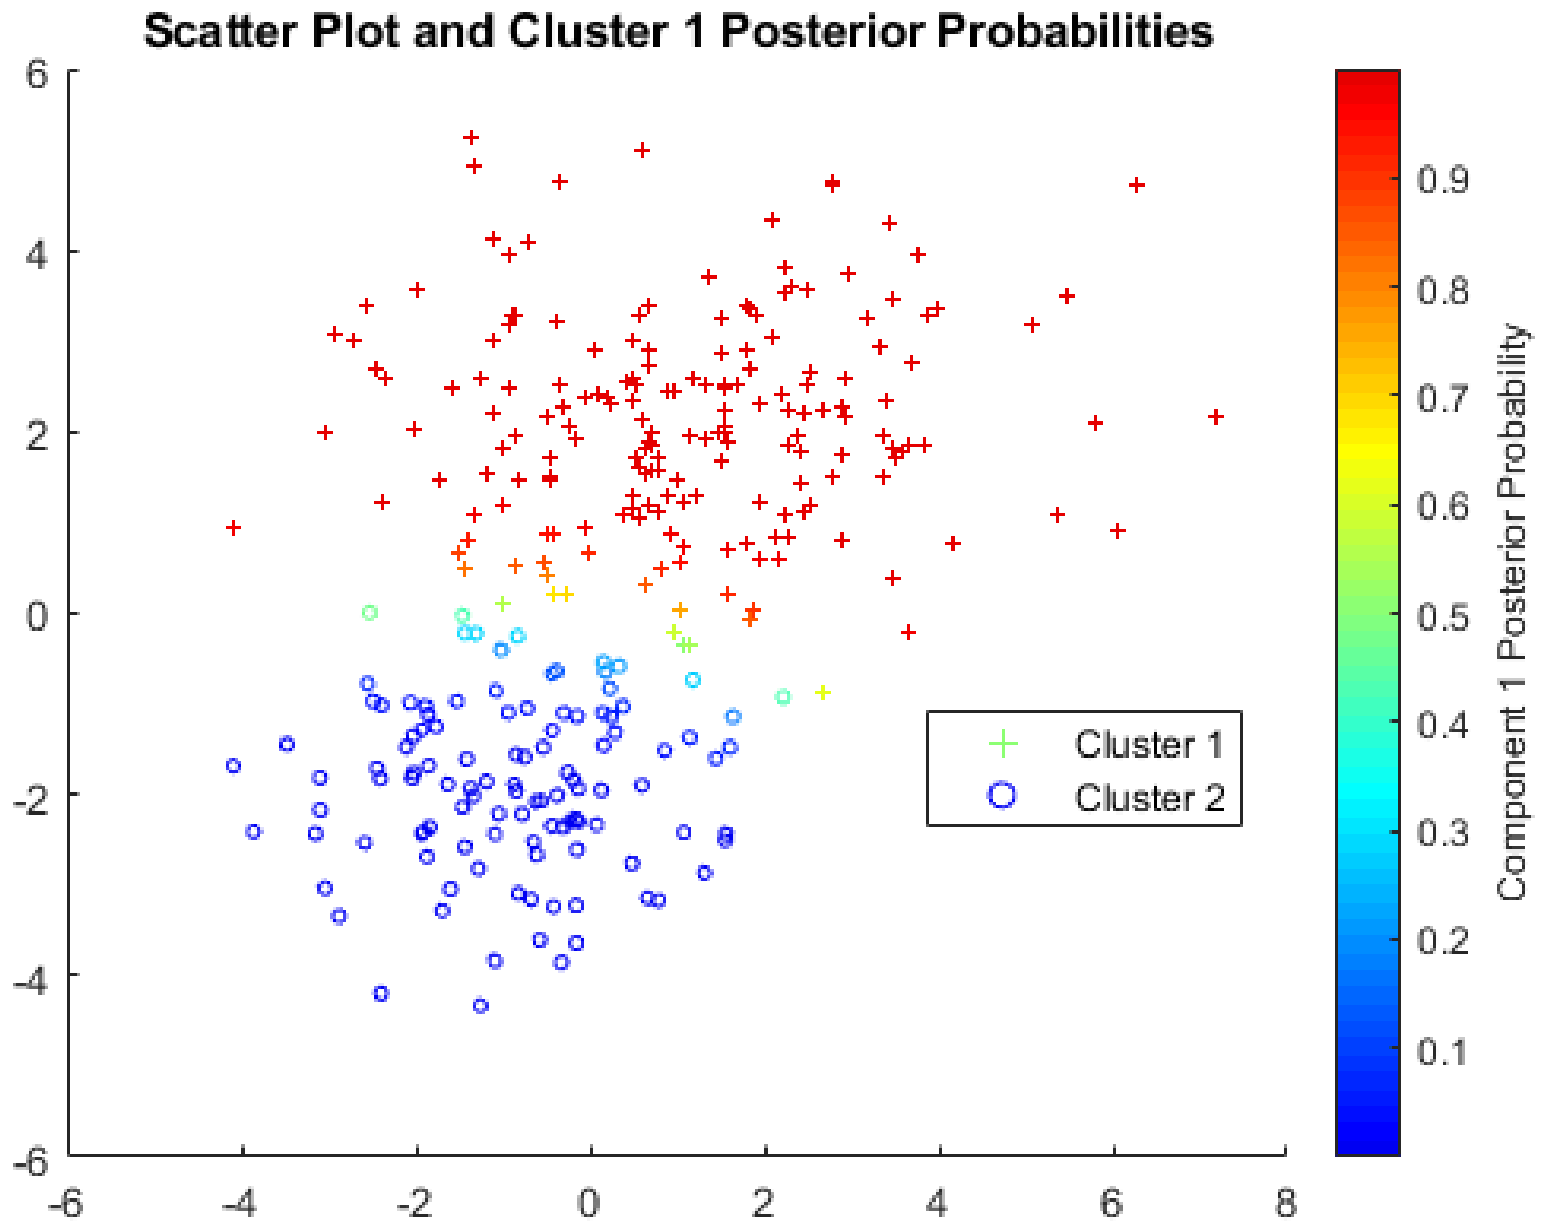
例子3：高斯混合概率密度等值线图



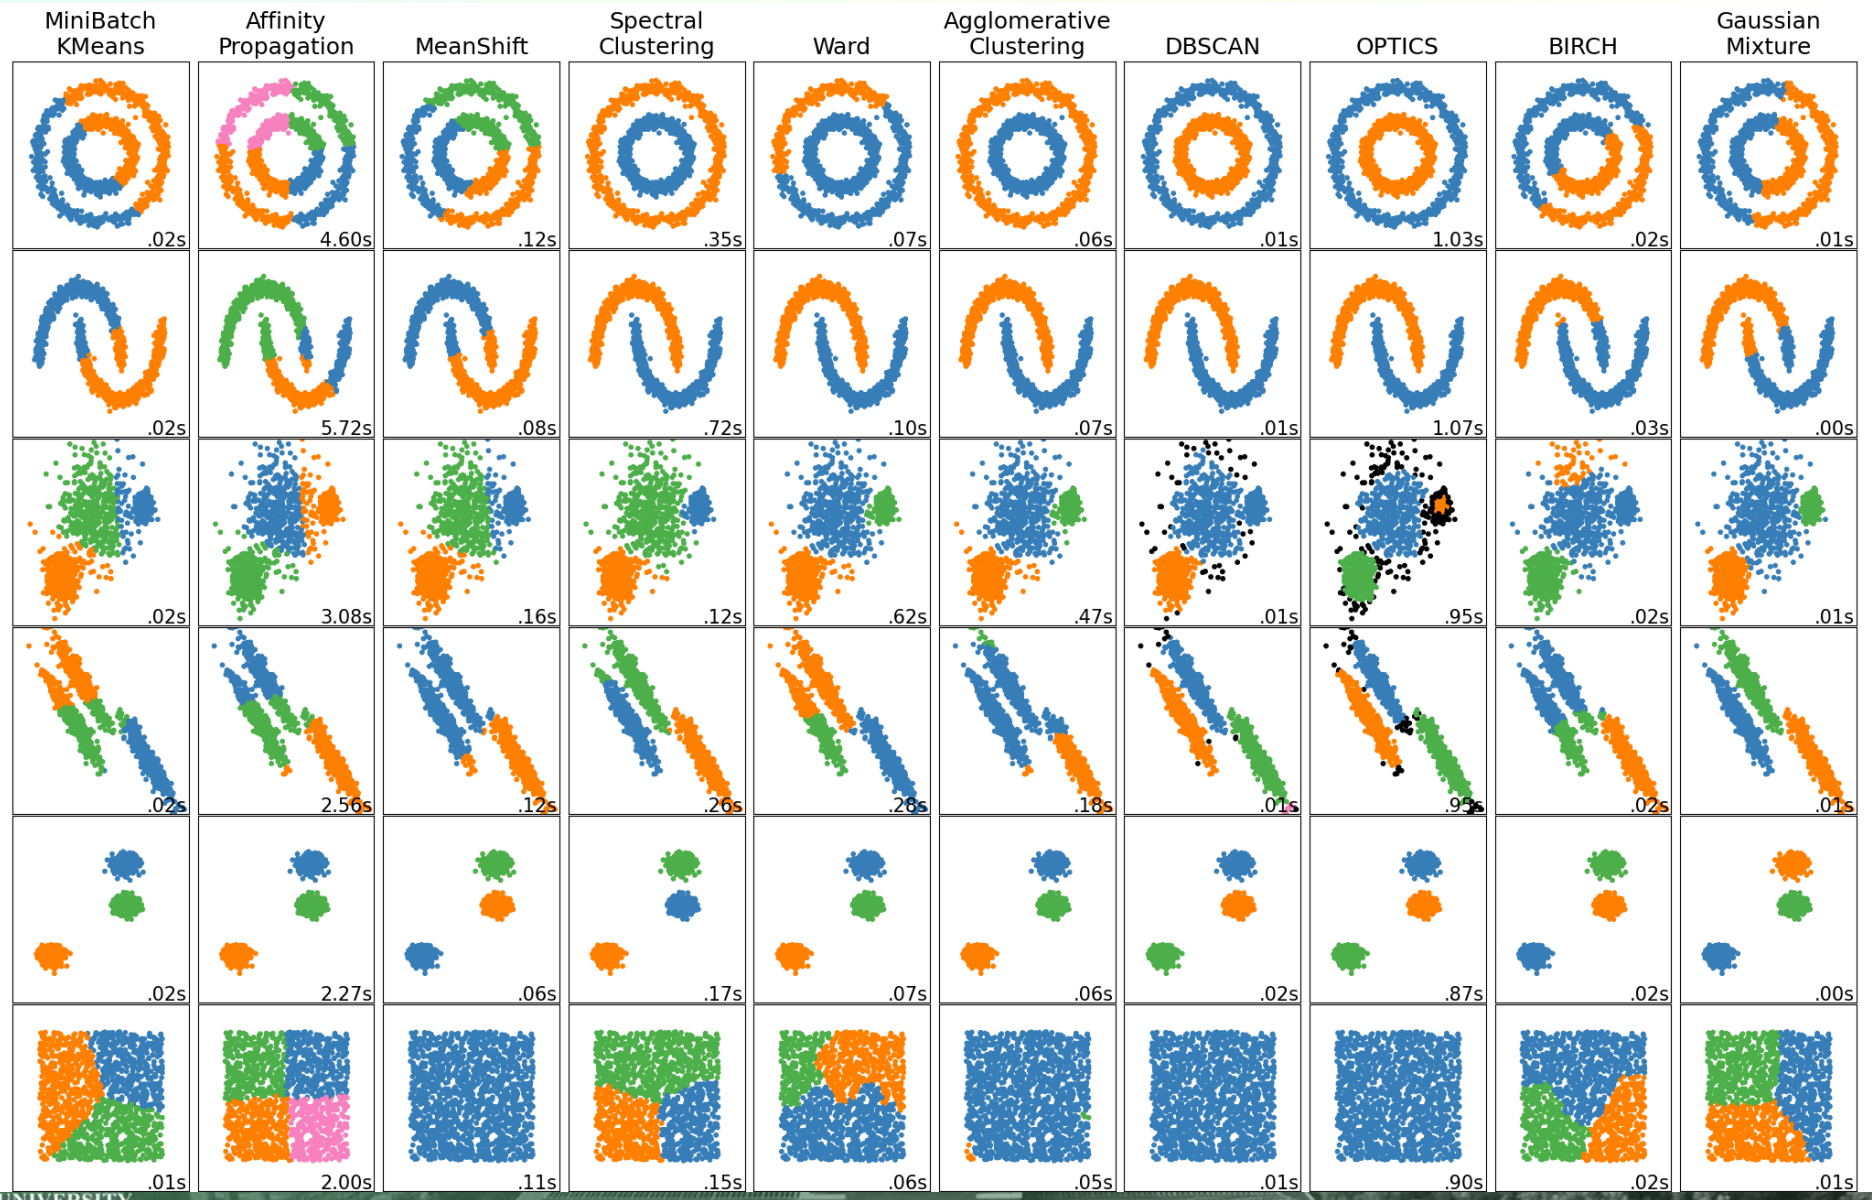
例子3：高斯混合模型的硬聚类结果



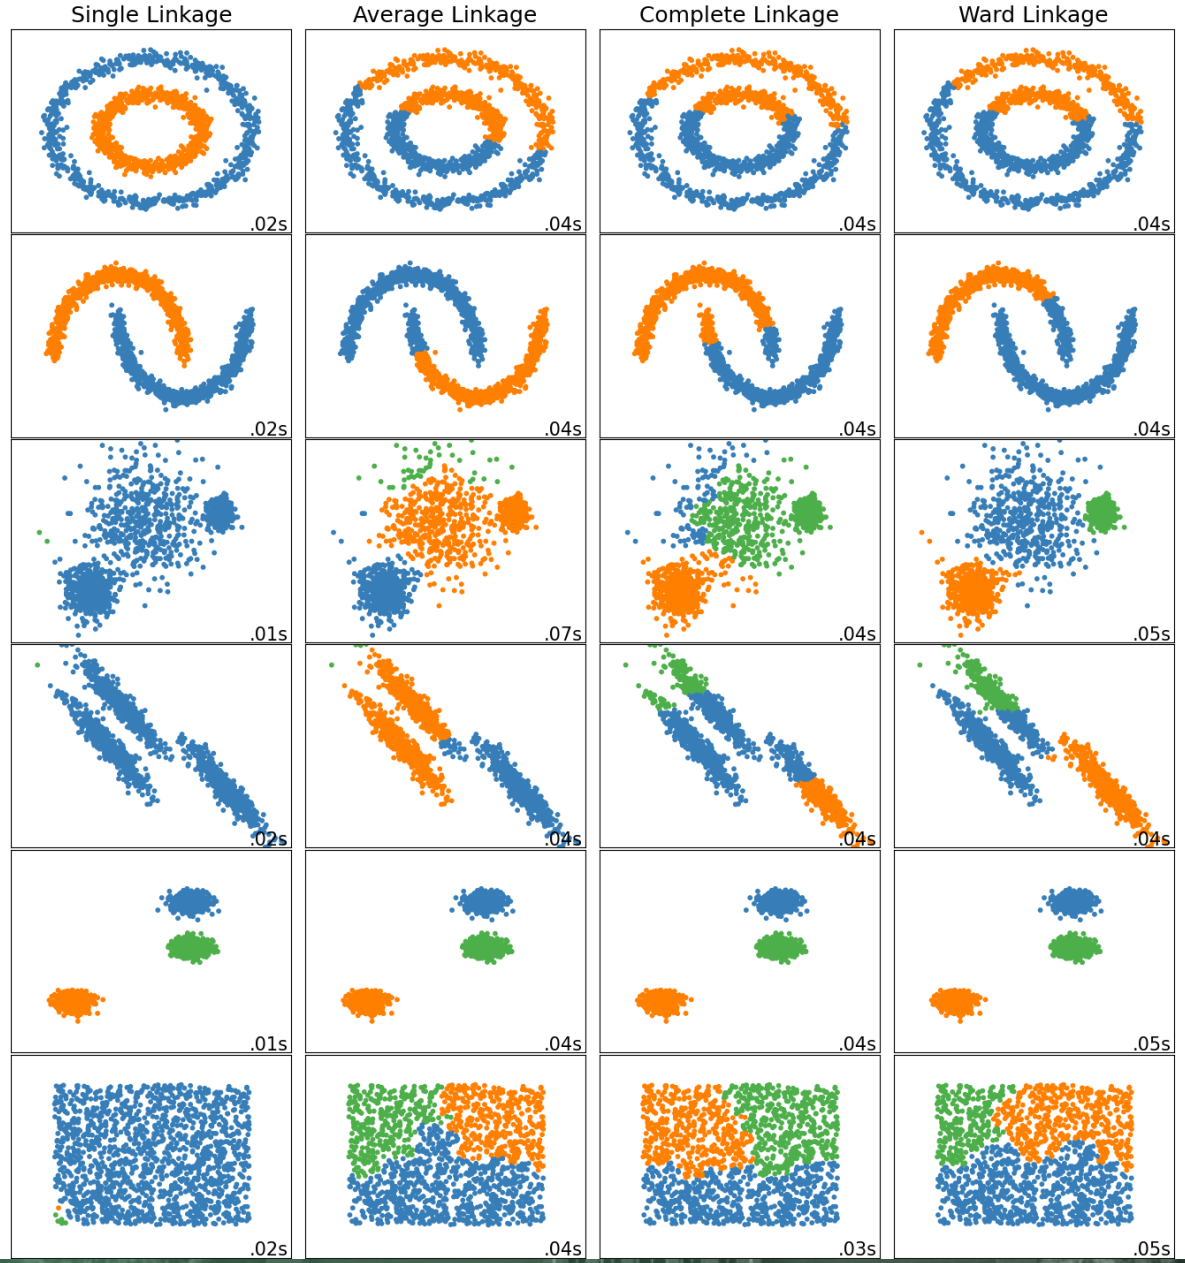
例子3：高斯混合模型的软聚类结果



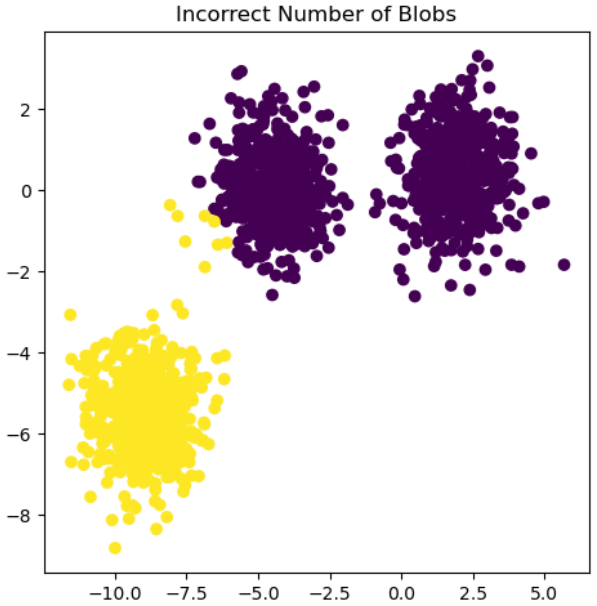
例子4：不同方法对不同数据集的聚类结果

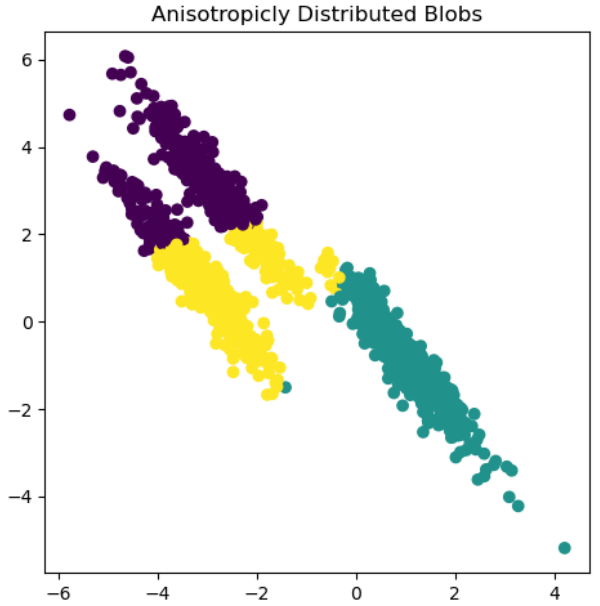


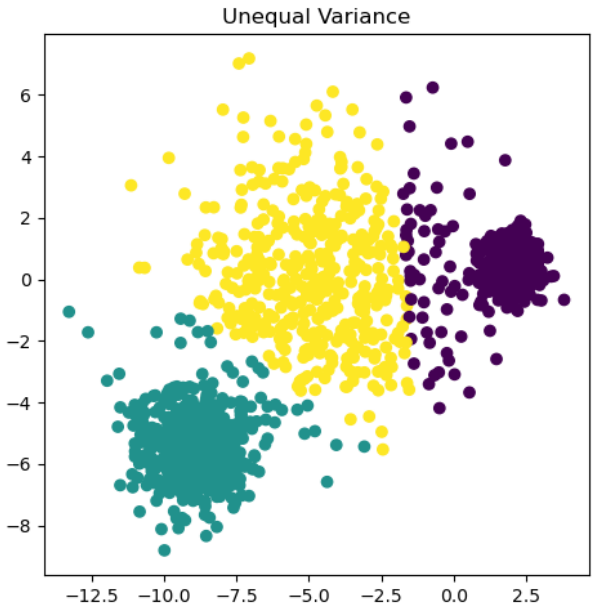
例子5：不同合并策略的层次聚类的结果

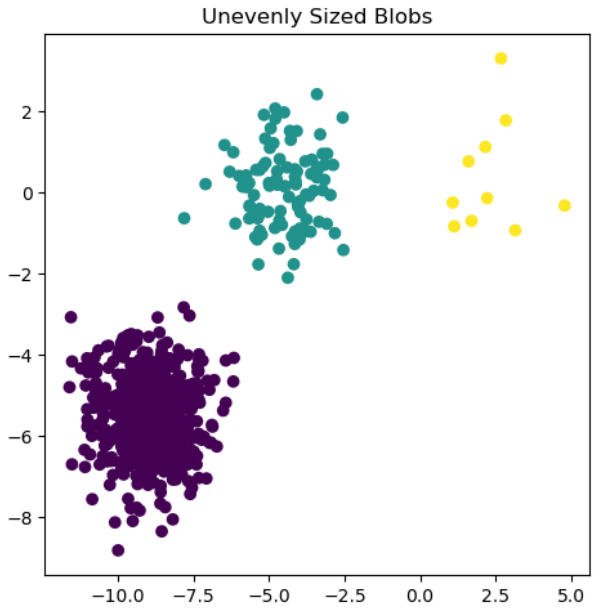


例子6：层次聚类法的不完美结果









聚类的直观印象

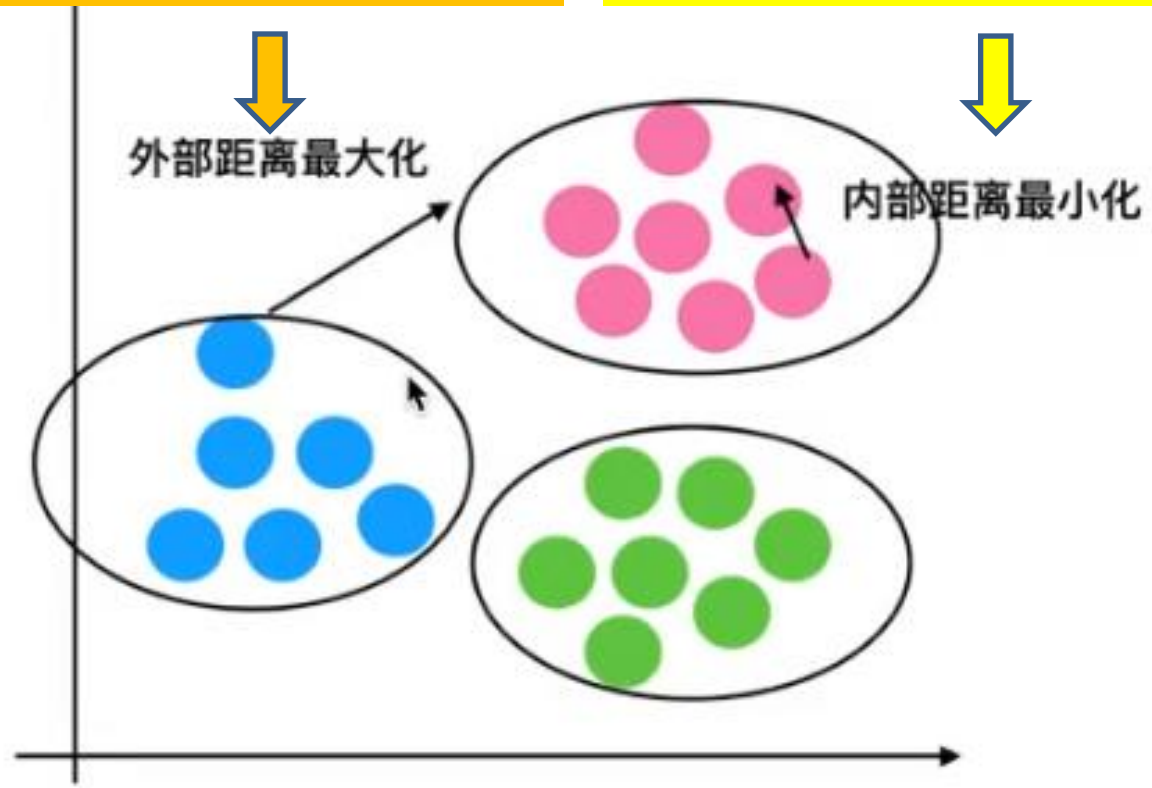
- **不同数据集，不同聚类方法**
  - 不同方法对不同数据集的聚类结果不尽相同
  - 相同方法对不同数据集的聚类效果也不同
- **相同数据集，不同聚类方法**
  - 不同方法效果可能不同或相同
  - 特定方法可能效果较好
- **相同数据集，相同聚类方法，不同合并策略**
  - 不同合并策略的聚类结果可能相同或不同
  - 特定数据集，特定合并策略可能效果较好

聚类（分析）的含义

- 英文： Cluster analysis or clustering
- 定义1:
  - 把“对象”分成不同的类别（簇，组，类）
  - 这些类不是事先给定的，而是直接根据数据的特征确定的
  - 把相似的东西放在一起（加标签），从而使得
    - 类别内部的“差异”尽可能小
    - 类别之间的“差异”尽可能大
- 定义2：按照对象之间的“相似”程度把对象划分成多个子集。

聚类（分析）的优化目标

类别之间的“差异”尽可能大　　类别内部的“差异”尽可能小



聚类（分析）的思考问题

不清楚某个样本属于哪一类？

➔样本数据放在X里面，用Y来存储类别，没有Y值 ➔无监督的学习

不清楚2个样本是否属于同一类？

➔如何定义样本和样本的相似性？ ➔2个距离 ➔样本之间，样本组成的类别之间的距离？

不清楚所有样本有几类？

➔怎么确定几类？ ➔最极端的情况是几类？
➔类内和类间的距离比较

样本或变量之间的相似性（距离）

- 聚类分析中是用“距离”或“相似系数”来度量对象之间的相似性，然后按对象的“相似”程度分类
- 根据样本测度变量之间的相似性程度
  - 可以使用夹角余弦、Pearson相关系数等工具，也称为相似系数
  - 变量间的相似系数越大，说明它们越相近
- 根据变量来测度样本(或类)之间的相似程度
  - 使用“距离” (欧式、马氏、切比雪夫等)
  - 离得比较近的归为相同类，
  - 离得比较远的放在不同类

（两个）变量之间的相似性的计算方法

中文	英文	公式
夹角余弦	Cosine distance	$\cos\theta_{xy} = \frac{\sum_i x_i y_i}{\sqrt{\sum_i x_i^2 \sum_i y_i^2}}$
皮尔逊相关系数	Pearson Correlation distance	$r_{xy} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2 \sum_i (y_i - \bar{y})^2}}$

问题：样本之间和变量之间的相似性计算方法是否可以互换?

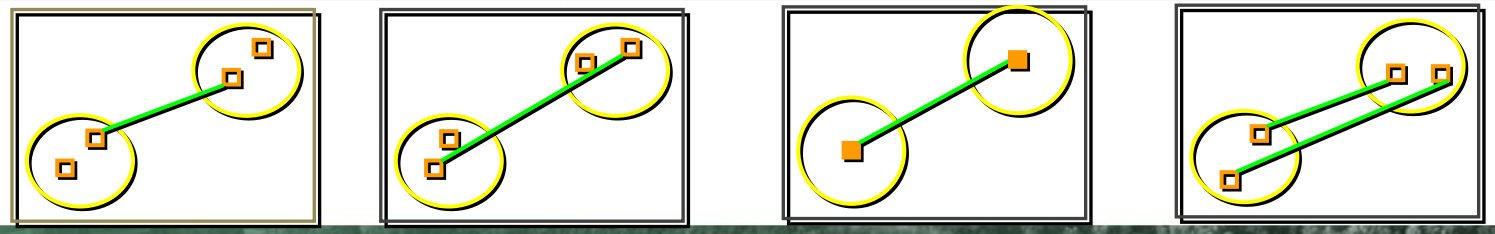
样本点（两点）间距离的计算方法

中文	英文	公式
欧氏距离	Euclidean distance	$\sqrt{\sum_{i=1}^{p}(x_i-y_i)^2}$
平方欧氏距离	Squared Euclidean distance	$\sum_{i=1}^{p}(x_i-y_i)^2$
街区距离	City Block distance	$\sum_{i=1}^{p}\lvert x_i-y_i\rvert$
切比雪夫距离	Chebychev distance	$\max\lvert x_i-y_i\rvert$
马氏距离	Mahalanobis distance	$d=\sqrt{(y-\mu)\sum^{-1}(y-\mu)'}.$
闵可夫斯基距离	Minkovski distance	$\sqrt[q]{\sum_{i=1}^{p}\lvert x_i-y_i\rvert^q}$

最常用的是平方欧氏距离

样本类（多点）间距离的计算方法

中文	英文	公式
最短距离法	(Nearest neighbor)	用两个类别中各个数据点之间最短的那个距离来表示两个类别之间的距离
最长距离法	(Furthest neighbor)	用两个类别中各个数据点之间最长的那个距离来表示两个类别之间的距离
中心法	(Centroid clustering)	用两个类别的中心（质心/重心）之间的距离来表示两个类别之间的距离
组间平均距离	(Between-groups linkage)	用两个类别中间各个数据点之间的距离的平均来表示两个类别之间的距离
离差平方和法	(Ward's method)	使各类别中的离差平方和较小，而不同类别之间的离差平方和较大（递推公式）



聚类分析的类型：样本或变量?

- 聚类分析的“对象”可以是所观察的多个样本，也可以是针对每个样本测得的多个变量
- 按照变量对所观察的样本进行分类称为Q型聚类➔例如：按照多项经济指标(变量)对不同的地区(样本)进行分类
- 按照样本对多个变量进行分类，则称为R型聚类➔例如：按照不同地区的样本数据对多个经济变量进行分类
- 两种聚类没有什么本质区别，实际中人们更感兴趣的通常是根据变量对样本进行分类(Q型聚类)

无监督学习方法：硬聚类方法举例

方法	工作原理	使用时机
k-均值	数据分割为 k 个相互排斥的类。点在多大程度上适合划入一个类由该点到类中心距离来决定(类中心与数据中的点可以不契合）。	● 当聚类的数量已知时 ● 适用于大型数据集的快速聚类
k-中心点	与 k-均值类似，选用类中离平均值最近的对象作为中心(类中心与数据中的点契合）。	• 当聚类的数量已知时 • 适用于分类数据的快速聚类 • 扩展至大型数据集
层次聚类	通过分析成对点之间的相似度并将对象分组到一个二进制的层次结构树，产生聚类的嵌套集。	• 当不知道的数据中有多少类时 • 想要可视化地指导数据选择
自组织映射	基于神经网络的聚类，将数据集变换为保留拓朴结构的 2D 图。	• 采用 2D 或 3D 可视化高维数据 • 通过保留数据的拓扑结构（形状）降低数据维度

硬聚类特点：一个点只能属于1个类

无监督学习方法：软聚类方法举例

方法	工作原理	使用时机	特点
模糊c-均值	当数据点可能属于多个类时进行基于分割的聚类。	• 当聚类的数量已知时 • 适用于模式识别 • 当聚类重叠时	聚类中心 （类似于k-均值）：一个点在一个类中的隶属度
高斯混合模型	基于分割的聚类，数据点来自具有一定概率的不同的多元正态分布。	• 当数据点可能属于多个类时 • 当聚集的类具有不同的大小且含有相关结构时	一个高斯分布的模型，给出一个点在一个类中的概率

软聚类特点：一个点可能属于多个类

聚类分析方法的选择

- 样本（Q型）/变量（R型）聚类?
- 样本属于单类（硬聚类）/多类（软聚类：模糊聚类或高斯混合模型）？
- 类别个数已知（ kmeans ）或未知（分层聚类）？
- 样本形状凸形（kmeans或分层聚类）或非凸形(DBSCAN或谱聚类)?
- 距离能够计算（基于距离）或不能直接计算（基于众数）？
- 噪音干扰小或大（K中心点或DBSCAN）？

聚类分析的典型方法

方法	英文名	含义
层次聚类法/系统聚类法	Hierarchical clustering	事先不确定要分多少类，而是先把每一个对象作为一类，然后一层一层进行分类；根据运算的方向不同，层次聚类法又分为合并法和分解法，两种方法的运算原理一样，只是方向相反。
K均值聚类/快速聚类	k-means clustering	事先指定聚类类别k，然后随机选择k 个样本点，每个样本点初始地代表一个类的平均值或中心，对剩余每个样本点，根据其到类中心的距离，被划分到最近的类；然后重新计算每个类的平均值. 不断重复划分过程，直到所有的样本都不能再分配为止.
基于密度的含噪数据空间聚类	Density-based spatial clustering of applications with noise (DBSCAN)	使用基于密度的方法来计算数据中任意形状的簇和离群值（噪声）；不需要簇数的先验知识，簇也不一定是球状（凸形）的；对于基于密度的异常值检测也很有用，可以识别不属于任何簇的点；识别三种点：核心点 ,边界点和噪声点 。
模糊C均值聚类	Fuzzy C-means clustering	将n个样品划分为 c 类，记V={v1,v2,.....,vc}为 c 个类的聚类中心，在模糊划分中，每一个样品不是严格的划分为某一类，而是以一定的隶属度属于某一类，根据隶属度来确定样品的归属。

3. 层次聚类

层次聚类的原理

- 事先不确定要分多少类（簇/组）
- 而是先把每一个对象（或者所有对象）作为一类，然后一层一层进行分类；
- 根据运算的方向不同，层次聚类法又分为
  - 合并法（初始假设为n类）
  - 分解法（初始假设为1类）
- 两种方法的运算原理一样，只是方向相反。

合并法的步骤

- 将每一个样本作为一类，如果是k个样本就分成k类
- 按照某种方法度量样本之间的距离，并将距离最近的两个样本合并为一个类别，从而形成了k-1个类别
- 再计算出新产生的类别与其他各类别之间的距离，并将距离最近的两个类别合并为一类。
- 如果类别的个数仍然大于1，则继续重复这一步，**直到所有的类别都合并成1类**为止

- 总是先把离得最近的两个类进行合并
- 合并越晚的类，距离越远
- 事先并不会指定最后要分成多少类
- 把所有可能的分类都列出，再视具体情况选择一个合适的分类结果

分解法的步骤

- 先把所有的对象(样本或变量)作为一大类，然后度量对象之间的距离或相似程度，并将距离或相似程度最远的对象分离出去，形成两大类(其中的一类只有一个对象)
- 再度量类别中剩余对象之间的距离或相似程度，并将最远的分离出去，
- 不断重复这一过程，**直到所有的对象都自成一类为止**

- 分解方法原理与合并法相反
- 事先并不会指定最后要分成多少类

层次聚类的MATLAB 实现方法

No	方法	主要命令	含义
第1种	单函数法	clusterdata	根据不同样品距离，不同的类间距离，综合求解层次聚类。包含了pdist, linkage, 和 cluster 函数。
第2种	多函数法	pdist	计算样品之间的某种距离
		squareform	计算距离矩阵
		linkage	根据某种类间距离法进行聚类
		dendrogram	画出聚类谱系图
		cophenet	计算Cophenetic相关系数，判断聚类效果（接近1越好）
		cluster	计算类别编号结果

clusterdata函数的调用格式

格式	用途
T = clusterdata (X,cutoff)	returns cluster indices for each observation (row) of an input data matrix X, given a threshold cutoff for cutting an agglomerative hierarchical tree that the linkage function generates from X. X是原始数据矩阵; Cutoff<2：不一致性指数临界值 Cutoff>2：用户定义的最大类别数。
T = clusterdata (X,Name,Value)	specifies additional options using one or more name-value pair arguments.

clusterdata的'Distance' 参数

Metric	Description
'euclidean'	Euclidean distance (default)
'squaredeuclidean'	Squared Euclidean distance. (This option is provided for efficiency only. It does not satisfy the triangle inequality.)
'seuclidean'	Standardized Euclidean distance. Each coordinate difference between observations is scaled by dividing by the corresponding element of the standard deviation, S = nanstd(X).
'mahalanobis'	Mahalanobis distance using the sample covariance of X, C = nancov(X)
'cityblock'	City block distance
'minkowski'	Minkowski distance. The default exponent is 2. To use a different exponent P, specify P after 'minkowski', where P is a positive scalar value: 'minkowski',P.
'chebychev'	Chebychev distance (maximum coordinate difference)
'cosine'	One minus the cosine of the included angle between points (treated as vectors)
'correlation'	One minus the sample correlation between points (treated as sequences of values)
'hamming'	Hamming distance, which is the percentage of coordinates that differ
'jaccard'	One minus the Jaccard coefficient, which is the percentage of nonzero coordinates that differ
'spearman'	One minus the sample Spearman's rank correlation between observations (treated as sequences of values)

clusterdata的'Linkage'参数

Algorithm	Description
'average'	Unweighted average distance (UPGMA)
'centroid'	Centroid distance (UPGMC), appropriate for Euclidean distances only
'complete'	Farthest distance
'median'	Weighted center of mass distance (WPGMC), appropriate for Euclidean distances only
'single'	Shortest distance
'ward'	Inner squared distance (minimum variance algorithm), appropriate for Euclidean distances only
'weighted'	Weighted average distance (WPGMA)

多函数法的典型代码

```
%层次聚类分析
%最长距离法&欧式距离
X=[16.2  1492  2000  -8.2  6.2
15.7  970   2209  -20.6  1.9
……
16.3  976   1239  -4.6   5.6];
D=pdist(X,'euclid');          %计算样品之间的欧式距离
M=squareform(D);              %排出距离矩阵
Z=linkage(D,'complete');      %根据最长距离法聚类
H=dendrogram(Z);              %画出聚类谱系图
xlabel('City');               %谱系图的横轴标签
ylabel('Scale');              %谱系图的纵轴标签
C=cophenet(Z,D);              %计算Cophenetic相关系数
T=cluster(Z,3);               %指定类别数目
```

pdist(X, Distance)中的Distance参数

表 6-2-1 不同距离的 Matlab 表示及其对应的语法格式

距离类别	Matlab 表示	语法格式
欧氏距离（Euclidean distance）	euclidean	D=pdist(X); D=pdist(X,'Euclid')
标准欧氏距离（standardized Euclidean distance）	seuclidean	D=pdist(X,'SEuclid')
街区距离（city block distance）	cityblock	D=pdist(X,'City')
马氏距离（Mahalanobis distance）	mahalanobis	D=pdist(X,'Mahal')
闵可夫斯基距离（Minkowski distance）	minkowski	D=pdist(X,'Minkow',r)
夹角余弦（1-cosine）	cosine	D=pdist(X,'cos')
相似系数（1-correlation）	correlation	D=pdist(X,'correl')
汉明距离（Hamming distance）	hamming	D=pdist(X,'ham')
Jaccard 距离（1-Jaccard coefficient）	jaccard	D=pdist(X,'jac')
切比雪夫距离（Chebychev distance）	chebychev	D=pdist(X,'cheby')

中山 SUN YAT-SEN UNIVERSITY

linkage(X,method)的method参数

表 6-2-2　不同方法的 Matlab 表示及其对应的语法格式

距离类别	Matlab 表示	语法格式
最短距离法（nearest distance）（最基本、最常用，系统默认的方法）	single	Z=linkage(M); Z=linkage(M,'single')
最长距离法（furthest distance）	complete	Z=linkage(M,'complete')
平均距离法（group average，unweighted average distance，UPGMA）	average	Z=linkage(M,'average'); Z=linkage(M,'avera')
加权平均法（weighted average distance，WPGMA）	weighted	Z=linkage(M,'weighted')
重心法（unweighted center of mass distance，UPGMC）	centroid	Z=linkage(M,'centroid'); Z=linkage(M,'cent')
中间距离法（weighted center of mass distance，WPGMC）	median	Z=linkage(M,'median'); Z=linkage(M,'med')
离差平方和法［inner squared distance（minimum variance algorithm）］	ward	Z=linkage(M,'ward'); Z=linkage(M,'wa')

层次聚类：距离的选择

- **点间距离**：精度加权距离或标准化欧式距离是合适的
- **类间距离**：重心法、平均法和权重法（加权平均法）是合适选择；最短距离法太收缩；最长距离法太扩展
- **变量的量纲**要统一。变量的**量纲差异较大**的话，采用标准化的数据；或者采用标准化的距离（精度加权距离或者标准化欧式距离）
- **变量存在相关性**的时候，可以考虑采用马氏距离或基于主成分得分的类间距离方法
- Cophenetic相关系数的值在【0，1】之间；**聚类效果**好，Cophenetic值越高，但聚类结果不一定是最优的；

4. K均值聚类

K-均值聚类 VS 层次聚类

- **层次聚类**事先不需要确定要分多少类，聚类过程一层层进行，最后得出可能的类别结果，最终根据具体情况确定最后需要的类别。
  - 可绘制出树状聚类图，方便直观选择类别
  - 缺点是计算量较大，对大批量数据的聚类效率不高

- **K-均值聚类**事先需要确定要分的类别数据，计算量要小得多，**效率比层次聚类要高**，也被称为**快速聚类**

K-均值聚类的步骤

- **第1步：确定要分的类别数目K**
  - 需要研究者自己确定
  - 在实际应用中，往往需要研究者根据实际问题反复尝试，得到不同的分类并进行比较，得出最后要分的类别数量
- **第2步：确定K个类别的初始聚类中心**
  - 要求在用于聚类的全部样本中，选择K个样本作为K个类别的初始聚类中心
  - 与确定类别数目一样，原始聚类中心的确定也需要研究者根据实际问题和经验来综合考虑
  - SPSS和Matlab会自动指定初始聚类中心

K-均值聚类的步骤

- **第3步：根据k个中心进行分类**
  - 根据确定的K个初始聚类中心，依次计算每个样本到K个聚类中心的距离（如欧氏距离）
  - 并根据距离最近的原则将所有的样本分到事先确定的K个类别中
- **第4步：根据k个新中心重新分类**
  - 根据所分成的K个类别，计算出各类别中每个变量的均值，并以均值点作为新的K个类别中心。
  - 根据新的中心位置，重新计算每个样本到新中心的距离，并重新进行分类

K-均值聚类的步骤

- **第5步：重复第4步，直到满足终止聚类条件为止**
  - 迭代次数达到研究者事先指定的最大迭代次数(SPSS隐含的迭代次数是10次；Matlab默认100代)
  - 新确定的聚类中心点与上一次迭代形成的中心点的最大偏移量小于指定的量(SPSS隐含的是0.02)

●K-均值聚类法是根据事先确定的K个类别反复迭代直到把每个样本分到指定的里类别中。

●类别数目的确定具有一定的主观性，究竟分多少类合适，需要研究者对研究问题的了解程度、相关知识和经验。

K-均值聚类的步骤示例：1维数据

问题：对如下数据 [2,4,10,12,3,20,30,11,25]，采用K-均值聚类进行聚类分析

初始化：

- 假设k=2，既最终分成2个聚簇；
- 取前两个数据点[2,4]作为两个聚簇的初始中心点

步骤	m1	m2	K1 聚簇1	K2 聚簇2
1)	2	4	[2,3]	[4,10,12,20,30,11,25]
2)	2.5	16	[2,3,4]	[10,12,20,30,11,25]
3)	3	18	[2,3,4,10]	[12,20,30,11,25]
4)	4.75	19.6	[2,3,4,10,11,12]	[20,30,25]
5)	7	25	[2,3,4,10,11,12]	[20,30,25]

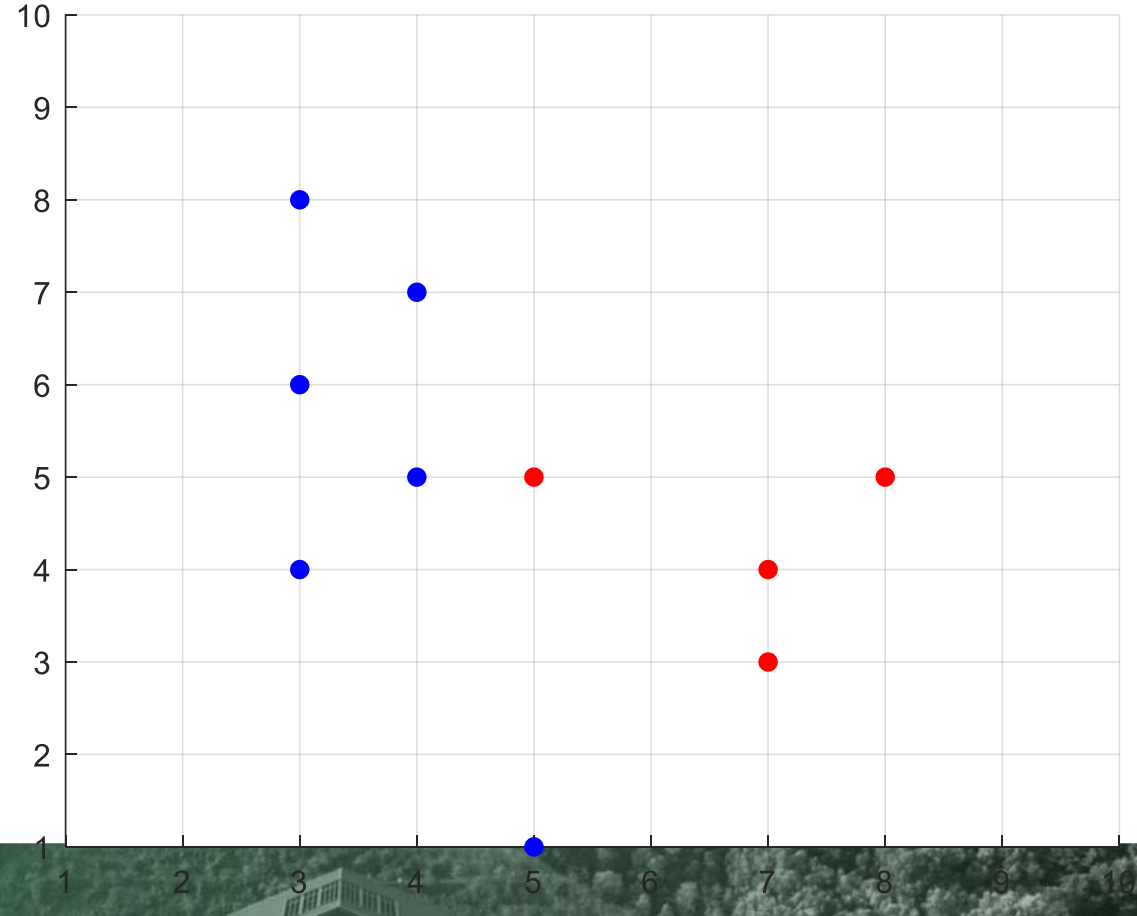




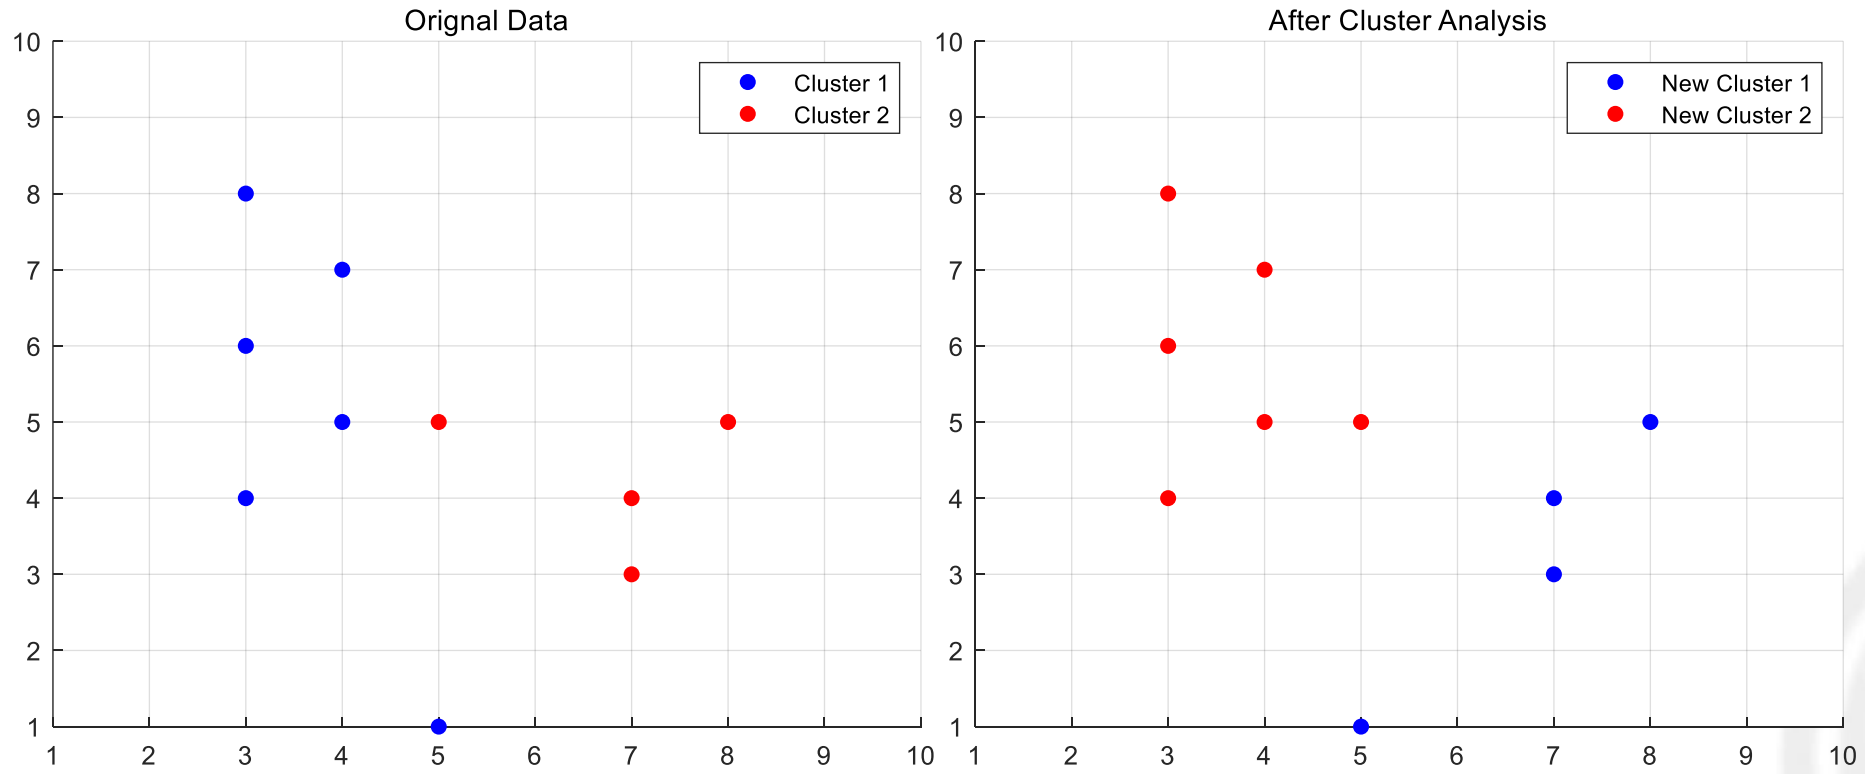
K-均值聚类的步骤示例：2维数据

问题：对如下2D数据，采用K-均值聚类进行聚类分析

x=[3 3 3 4 4 5 5 7 7 8]
y=[4 6 8 5 7 1 5 3 4 5]



K-均值聚类的步骤示例：2维数据



K-均值聚类的MATLAB 实现方法

主要命令	含义
kmeans	将n个点（或观测）分为k类。聚类过程是动态的，通过迭代使得每个点与所属类中心距离的和达到最小。默认情况下，kmeans采用平方欧式聚类。
silhouette	根据聚类结果绘制轮廓，从轮廓中看出那个点的分类是否合理。 S(i)=(min(b)-a)/max(a,min(b)) a是第i个点与同类的其他点之间的平均距离； b为一个向量，其元素是第i个点与不同类的类内各点之间的平均距离。 分类效果判断： 轮廓值S(i)的取值范围为[-1,1]，S(i)的值越大，说明第i个点的分类越合理，当S(i)<0时，说明第i个点的分类不合理，还有比目前分类更合理的分类。

kmeans函数的调用格式

格式	用途
IDX=kmeans(X,k)	将n个点（或观测）分为k类，输入参数X为n × p的矩阵，矩阵的每一行对应一个点，每一列对应一个变量。输出参数IDX是一个n × 1的向量，其元素为每个点所属类的类序号。
[IDX,C]=kmeans(X,k)	返回k个类的重心坐标矩阵C，C是一个k × p的矩阵，第i行元素为第i类的类重心坐标。
[IDX,C,sumd]=kmeans(X,k)	返回类内距离（即类内各点与类重心距离之和）向量sumd，sumd是一个1 x k的向量，第i个元素为第i类的类内距离之和。

kmeans函数的调用格式

格式	用途
[IDX,C,sumd,D]=kmeans(X,k)	返回每个点与每个类重心之间的距离矩阵D，D是一个n x k的矩阵，第i行第j列的元素是第i个点与第j类的重心之间的距离
[.....]=kmeans(...,param1,val1,param2,val2,....)	允许用户设置更多的参数及参数值，用来控制kmeans函数所用的迭代算法。param1，param2，...，为参数名，val1，val2，...,为相应的参数值

kmeans的参数

参数名	参数值	说明
‘distance’	‘sqEuclidean’	平方欧式距离（默认情况）
	‘cityblock’	绝对值距离
	‘cosine’	把每个点作为一个向量，两点距离为1减去两个向量夹角余弦
	‘correlation’	把每个点作为一个数值序列，两点间距离为1减去两个数值序列的相关系数
	‘Hamming’	即不一致字节所占的百分比，仅适用于二进制数据
‘emptyaction’	‘error’	把空类作为错误对待(默认情况)
	‘drop’	去除空类，输出参数C和D中相应值用NaN表示
	‘singleton’	生成一个只包含最远点的新类
‘onlinephase’	‘on’	执行在线更新(默认情况)
	‘off’	不执行在线更新
‘options’	由statest函数创建的结构体变量	用来设置迭代算法的相关选项
‘replicates’	正整数	重复聚类的次数
‘start’	‘sample’	随机选择k个观测点作为初始凝聚点
	‘uniform’	在观测值矩阵X中随机并均匀地选择k个观测点作为初始凝聚点
	‘cluster’	从X中随机选择10%个子样本，进行聚类运算，确定凝聚点。
	‘Matrix’	若为kxp的矩阵，用来设定k个初始聚类点。若为kxpxm的3维数组，则重复进行m次聚类，每次聚类通过相应页上的二维数组设定k个初始凝聚点

中山大学 SUN YAT-SEN UNIVERSITY



silhouette函数的调用格式

格式	用途
Slihouette (X,clust)	根据样本矩阵X和聚类结果绘制轮廓图。 X是一个n x p的矩阵，矩阵的每一行对应一个观测值，每一列对应一个变量。 clust是聚类的结果，可以是由每个观测所属的类序号构成的数值向量，也可以是由类名称构成的字符矩阵或字符串元胞数组。
s=silhouette（X,clust)	返回轮廓值向量s，他是以n x 1的向量，其元素为相应点的轮廓值。此时不绘制轮廓。
[s,h]=slihouette(X,clust)	绘制轮廓图，并返回轮廓值向量s和图形句柄h。
[……]=silhouette(X,clust, metric)	指定距离计算的方法，绘制轮廓图。输入参数metric为字符串或距离矩阵，用来指定距离计算的方法或距离矩阵（和cLust对应）。

Silhouette的metric参数

metric参数取值	说明
‘Euclidean’	欧式距离
‘sqEuclidean’	平方欧式距离(默认情况)
‘cityblock’	绝对值距离
‘cosine’	把每个点作为一个向量，两点距离为1减去两个向量夹角余弦
‘correlation’	把每个点作为一个数值序列，两点间距离为1减去两个数值序列的相关系数
‘Hamming’	汉明距离
‘Jaccard’	不一致的非零坐标所占的百分比
Vector	上三角形式的距离矩阵对应的距离向量

4. DBSCAN

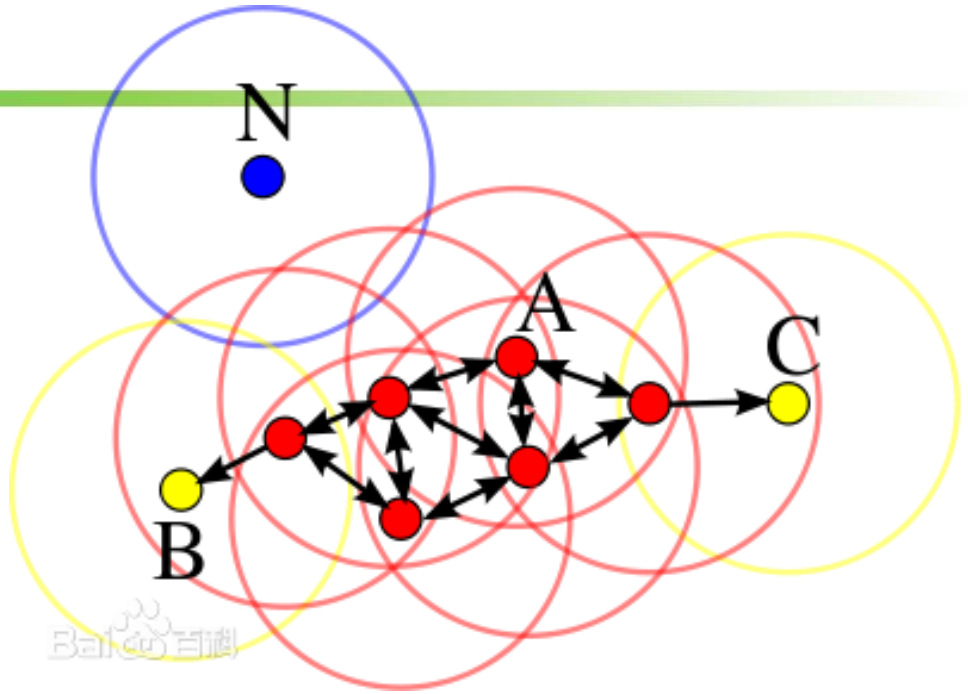
DBSCAN的定义

- DBSCAN全名：基于密度的含噪数据空间聚类 （Density-Based Spatial Clustering of Applications with Noise）
- 异同点：DBSCAN与划分和层次聚类方法不同，是一个代表性的基于密度的聚类算法。
- 原理：
  - 将簇定义为密度相连的点的最大集合，
  - 能够把具有足够高密度的区域划分为簇，
  - 并可在噪声的空间数据库中发现任意形状的聚类。

DBSCAN的优缺点

- **优点：**
  - 计算量小于Kmeans和层次聚类
  - 不需要簇数的先验知识
  - 簇也不一定是球状（凸形）的
  - 对于基于密度的异常值检测也很有用，可以识别不属于任何簇的点。
- **缺点：**
  - 参数敏感和较难确定(特别是对于高维数据）。
  - 当数据密度不均匀时，全局密度参数不能刻画内在的聚类结构

DBSCAN的三种点



Eps邻域：样本半径Eps内的邻域➔**图中红圈的半径**

核心点（core point）：如果对象的Eps邻域至少包含最小数目MinPts的对象，则称该对象为核心点（对象）➔**图中A点**

边界点（edge point）：边界点不是核心点，但落在某个核心点邻域内➔**图中B点或C点**

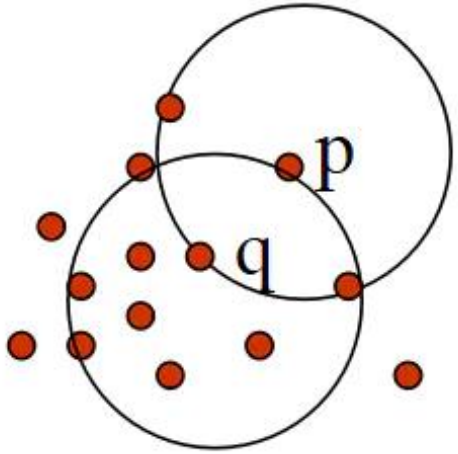
噪音点（outlier point）：不是核心或边界点的任何点➔**图中N点**;

DBSCAN的密度可达和相连

概念	定义	解释
直接密度可达	对于样本集合D，如果样本点q在p的E邻域内，并且p为核心对象，那么对象q从对象p直接密度可达。	从核心点p出发，q不一定是核心点，所以是非对称的
密度可达	对于样本集合D，给定一串样本点$p_1,p_2....p_n$，$p=p_1,q=p_n$,假如对象p_i从p_{i-1}直接密度可达，那么对象q从对象p密度可达。	密度可达是直接密度可达的传递闭包，并且这种关系是非对称的。
密度相连	存在样本集合D中的一点o，如果对象o到对象p和对象q都是密度可达的，那么p和q密度相连。	密度相连是对称关系。

DBSCAN目的是找到密度相连对象的最大集合。

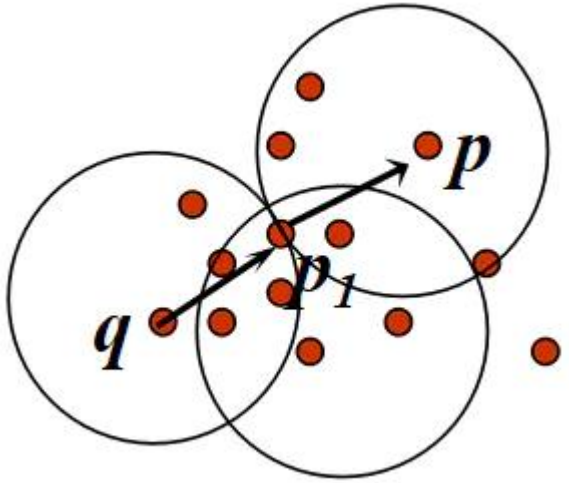
密度可达和相连：举例1



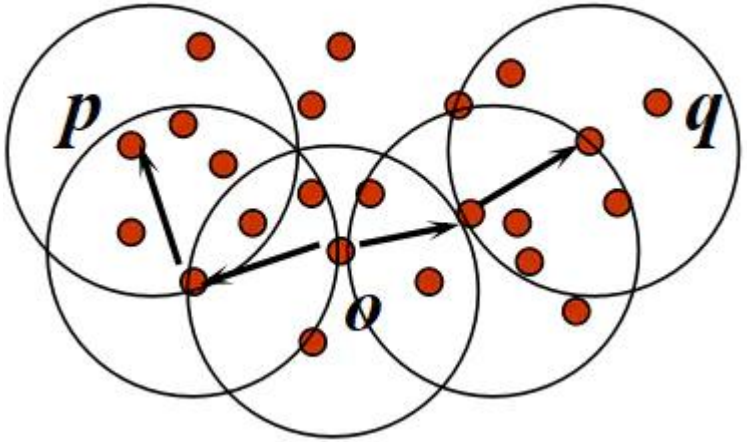
MinPts = 5

Eps = 1 cm

p从q(核心点)直接密度可达



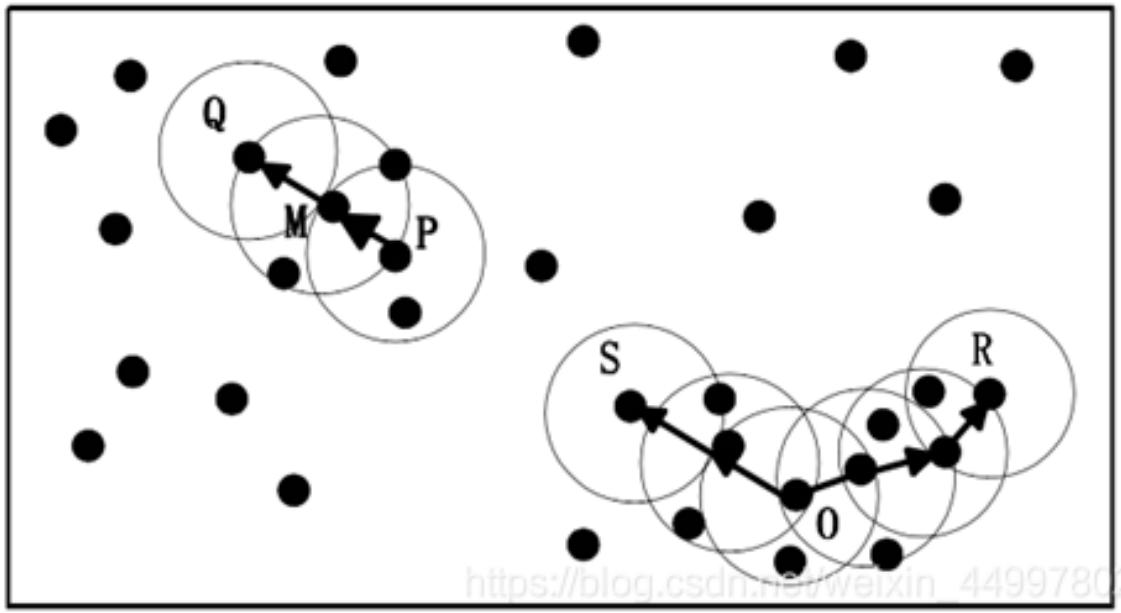
p从对象q密度可达



p和q密度相连

密度可达和相连：举例2

如图所示：Eps用一个圆圈的半径表示，设MinPts=3，请分析Q,M,P,S,O,R这5个样本点之间的关系



M、P、O和R点：各点的Eps近邻均包含3个或以上点➔核心点
M是从P“直接密度可达”；而Q则是从M“直接密度可达”➔Q是从P“密度可达”；但P从Q不是“密度可达”(非对称)。
S和R从O是“密度可达”的➔R和S均是“密度相连”（对称）

DBSCAN的算法描述1（4步骤）

- **输入**：包含n个对象的数据库，半径eps，最少数目MinPts;
- **输出**：所有生成的簇，达到密度要求。

1. 从数据库中抽出一个**未处理的点**;
2. IF抽出的点是**核心点** THEN 找出所有从该点密度相连的对象，形成一个簇（**内部循环**）；
3. ELSE 抽出的点是**边缘点(非核心对象)**，跳出本次循环，寻找下一个点;
4. 重复步骤1-3，直到处理完**所有的点**。

DBSCAN的算法描述2（5步骤）

1. 从输入数据集中X，选择第一个未标记的观测值x1作为当前点，并将第一个聚类标签C初始化为 1。
2. 找到当前点的 eps邻域内的点集。这些点是邻居。
   - 如果邻居数小于minpts，则将标记为噪声点（如果噪声点稍后满足其他点约束，则重新分配，通常是边界点）。转到步骤 4。
   - 否则，将当前点标记为属于簇C的核心点。
3. 迭代每个邻居（新的当前点）并重复步骤 2，直到找不到可以标记为属于当前簇C的新邻居。
4. 选择X中下一个未标记点作为当前点，C=C+1。
5. 重复步骤 2-4，直到标记X中的所有点。

DBSCAN的MATLAB 实现方法

主要命令	含义
设定参数	minpts：至少大于属性个数+1。 Epsilon：看图调整或者通过k距离图给个初始值
dbscan	将n × p的X数据矩阵中的观测值划分为多个簇。 根据邻域搜索半径的阈值eps和minpts识别核心点所需的最小邻居数，对观测值（或点）进行聚类。 该函数返回一个n ×1 向量（ idx)，其中包含每个观测值的聚类索引。

dbscan函数的调用格式

格式	用途
idx = dbscan(X,epsilon, minpts)	将n × p的X数据矩阵中的观测值划分为多个簇。根据邻域搜索半径的阈值eps和minpts识别核心点所需的最小邻居数，对观测值（或点）进行聚类。Idx是n ×1 向量，包含每个观测值的聚类索引。
idx = dbscan(X,epsilon, minpts,Name,Value)	使用一个或多个名称-值对参数指定附加选项。例如，可指定'Distance','minkowski','P',3在 DBSCAN 算法中使用指数为3的 Minkowski 距离度量。
idx = dbscan(D,epsilon, minpts,'Distance', 'precomputed')	返回D观测值之间预先计算的成对距离的簇索引向量 。D可以是pdist或pdist2输出，或更一般的符合pdist或pdist2分别输出格式的相异度矢量或矩阵。

DBSCAN的MATLAB代码例子

参考

https://ww2.mathworks.cn/help/stats/dbscan-clustering.html

（含有k距离图画法）

https://ww2.mathworks.cn/help/stats/dbscan.html

5. 评估和优化

聚类分析的评估方法

方法	类别（Y）真实值	评估对象		备注
		总体	单个数据点	
外部评估	已知	纯度/正确率/准确率 错误率	单点类别比较	计算混淆矩阵
	未知（参考模型给出）	Jaccard系数 FM指数 Rand指数		把参考模型的计算结果当成真值；计算混淆矩阵
内部评估	未知	轮廓系数（单点均值） 组内点到中心点SSE CH指数（方差比） DB指数 Dunn指数	单点轮廓值	簇内距离最小； 簇间距离最大；

轮廓（Silhouette）

参考周志华《机器学习》P198～199

单点轮廓（Silhouette）值的计算

以第i个点（目标点）为研究对象进行计算

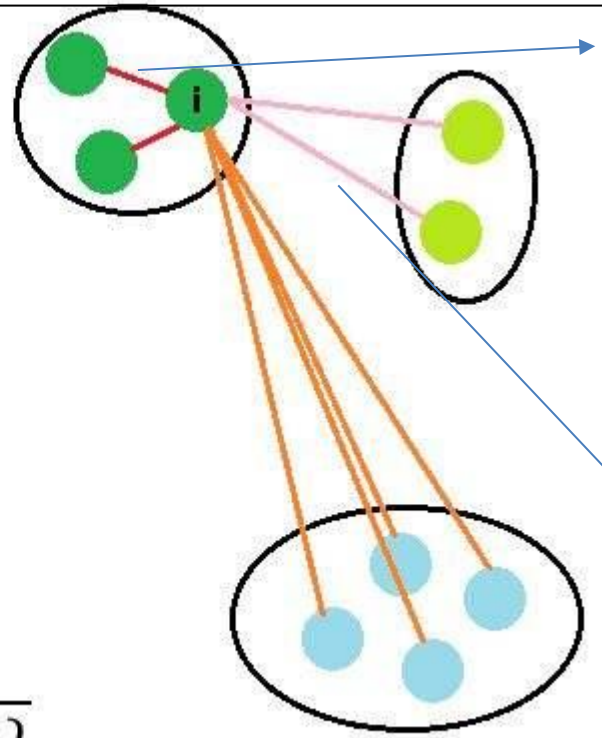
a是第i个点与同类的其他点之间的平均距离；

b为一个向量，其元素是第i个点与其他类内各点之间的平均距离

$$a(i) = \text{avg}\{\ \}$$

$$b(i) = \min\left\{\begin{array}{l}\text{avg}\{\ \}\\ \text{avg}\{\ \}\end{array}\right.$$

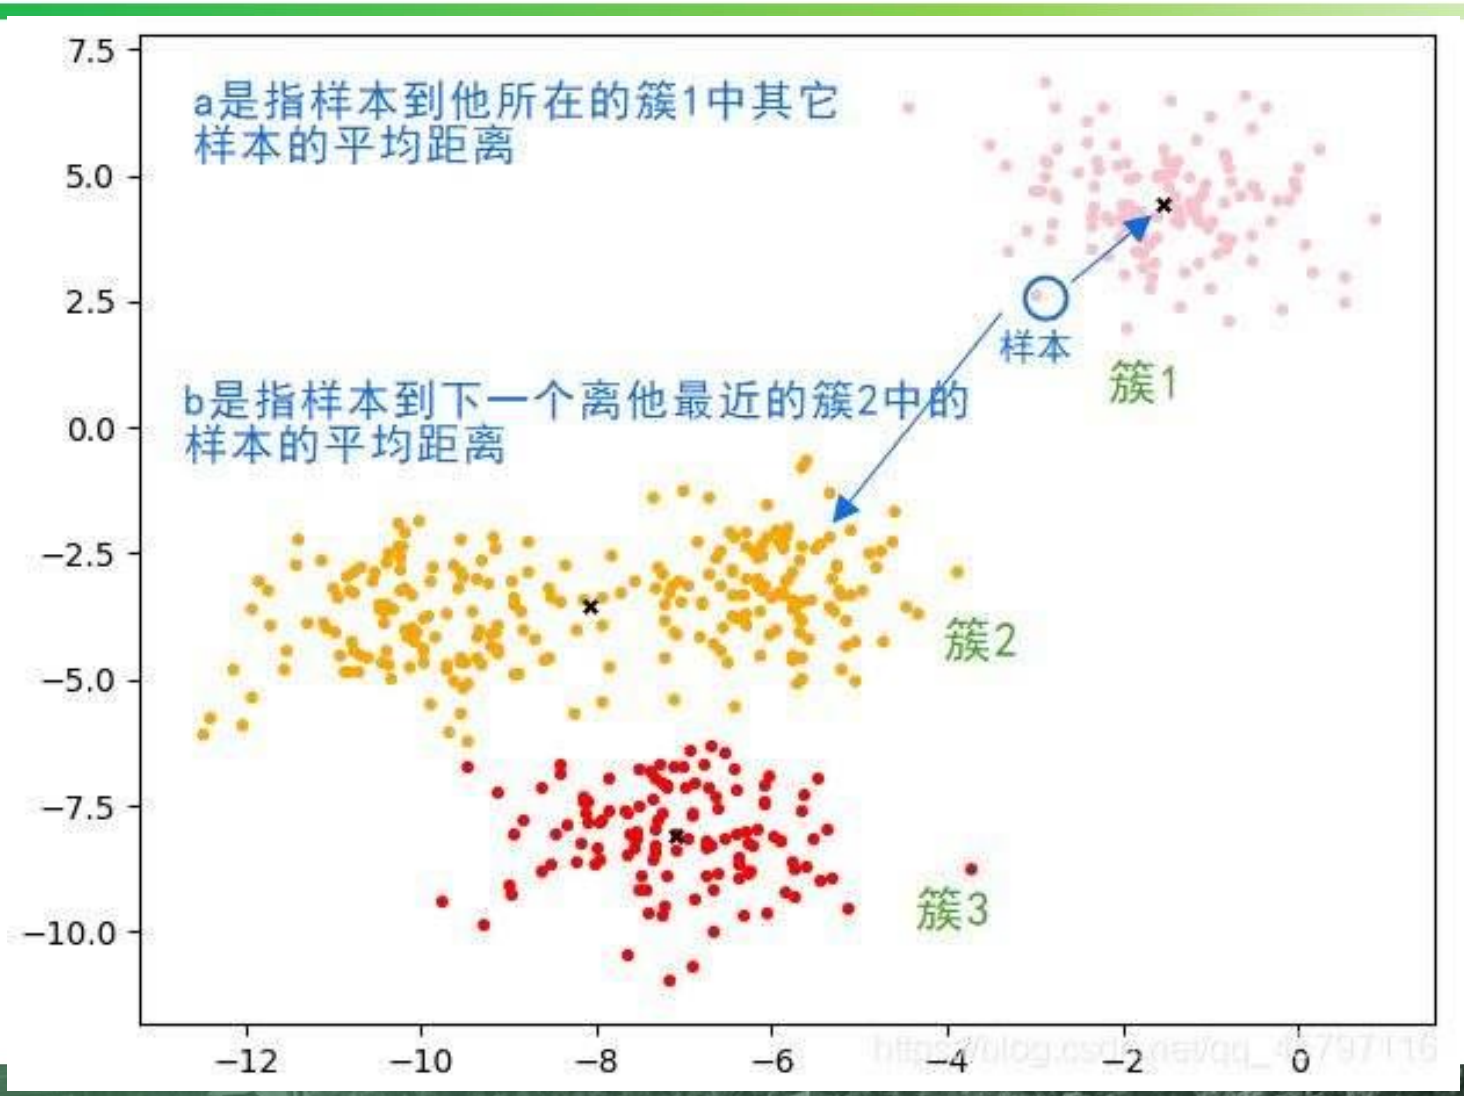
$$S(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$



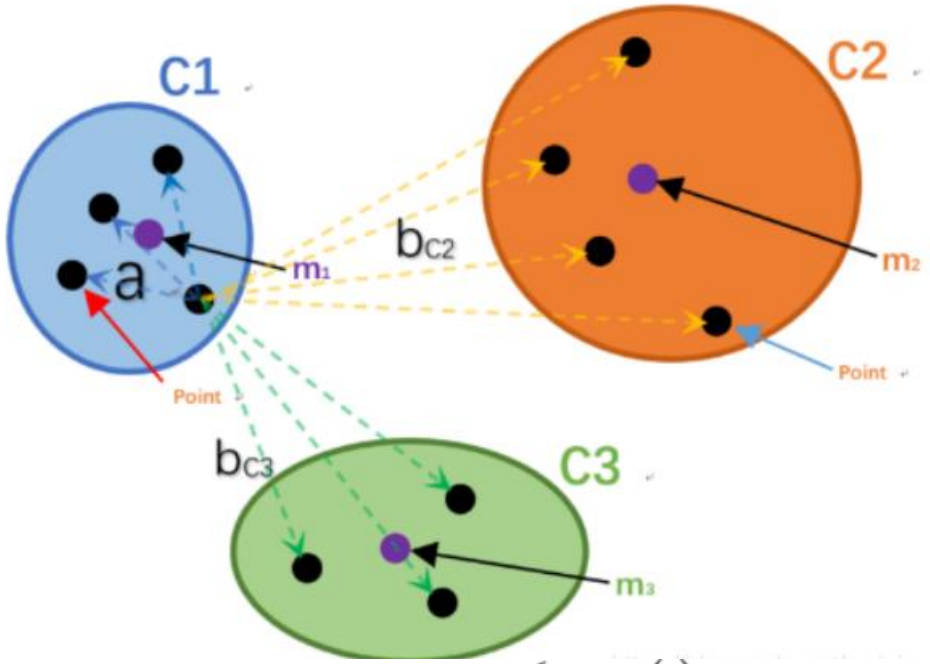
a(i):目标点到同类各点间距离均值

b(i):目标点到最近的类，与该类各点间距离均值

单点轮廓（Silhouette）值的计算



单点轮廓（Silhouette）值的计算



$$s(i)=\frac{b(i)-a(i)}{\max\{a(i),b(i)\}}$$

$$s(i)=\begin{cases}1-\dfrac{a(i)}{b(i)}, & a(i)<b(i) \\ 0, & a(i)=b(i) \\ \dfrac{b(i)}{a(i)}-1, & a(i)>b(i)\end{cases}$$

(0，1]

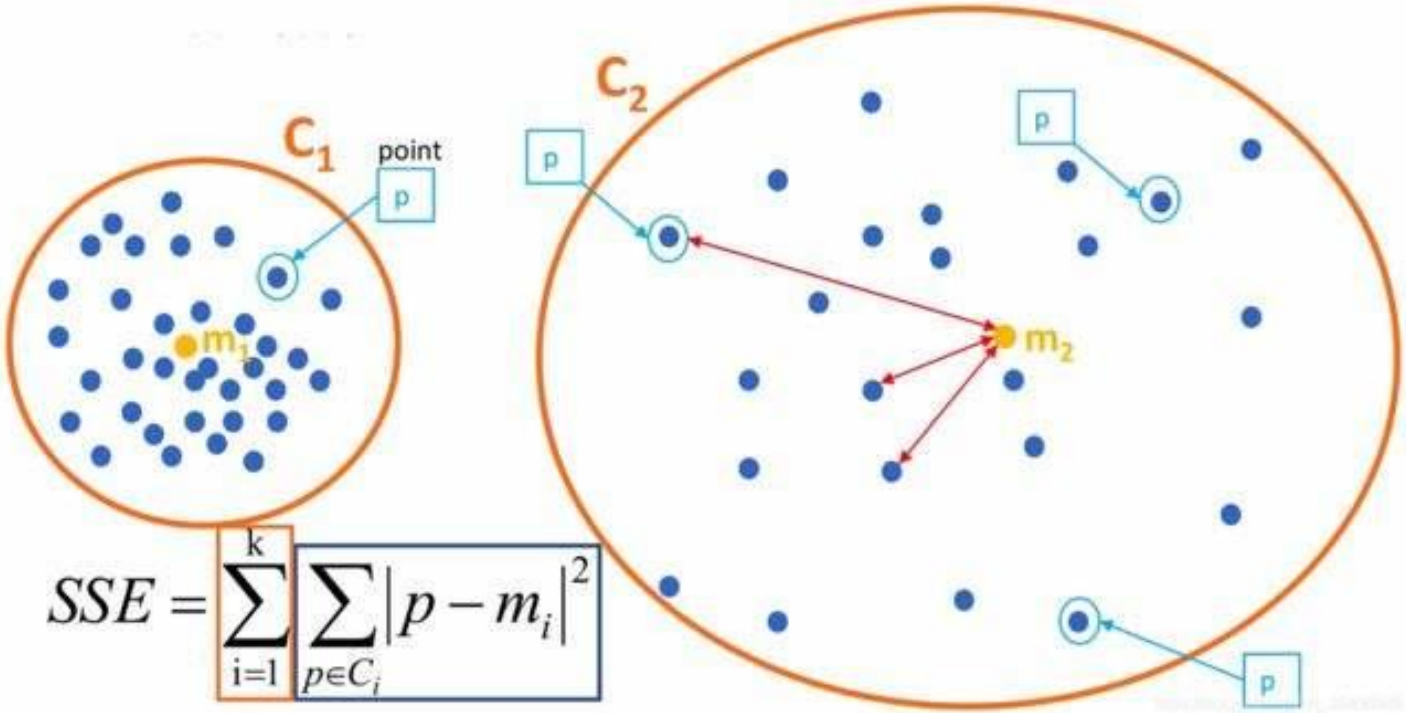
0

[-1，0)

https://blog.csdn.net/wj1298250240

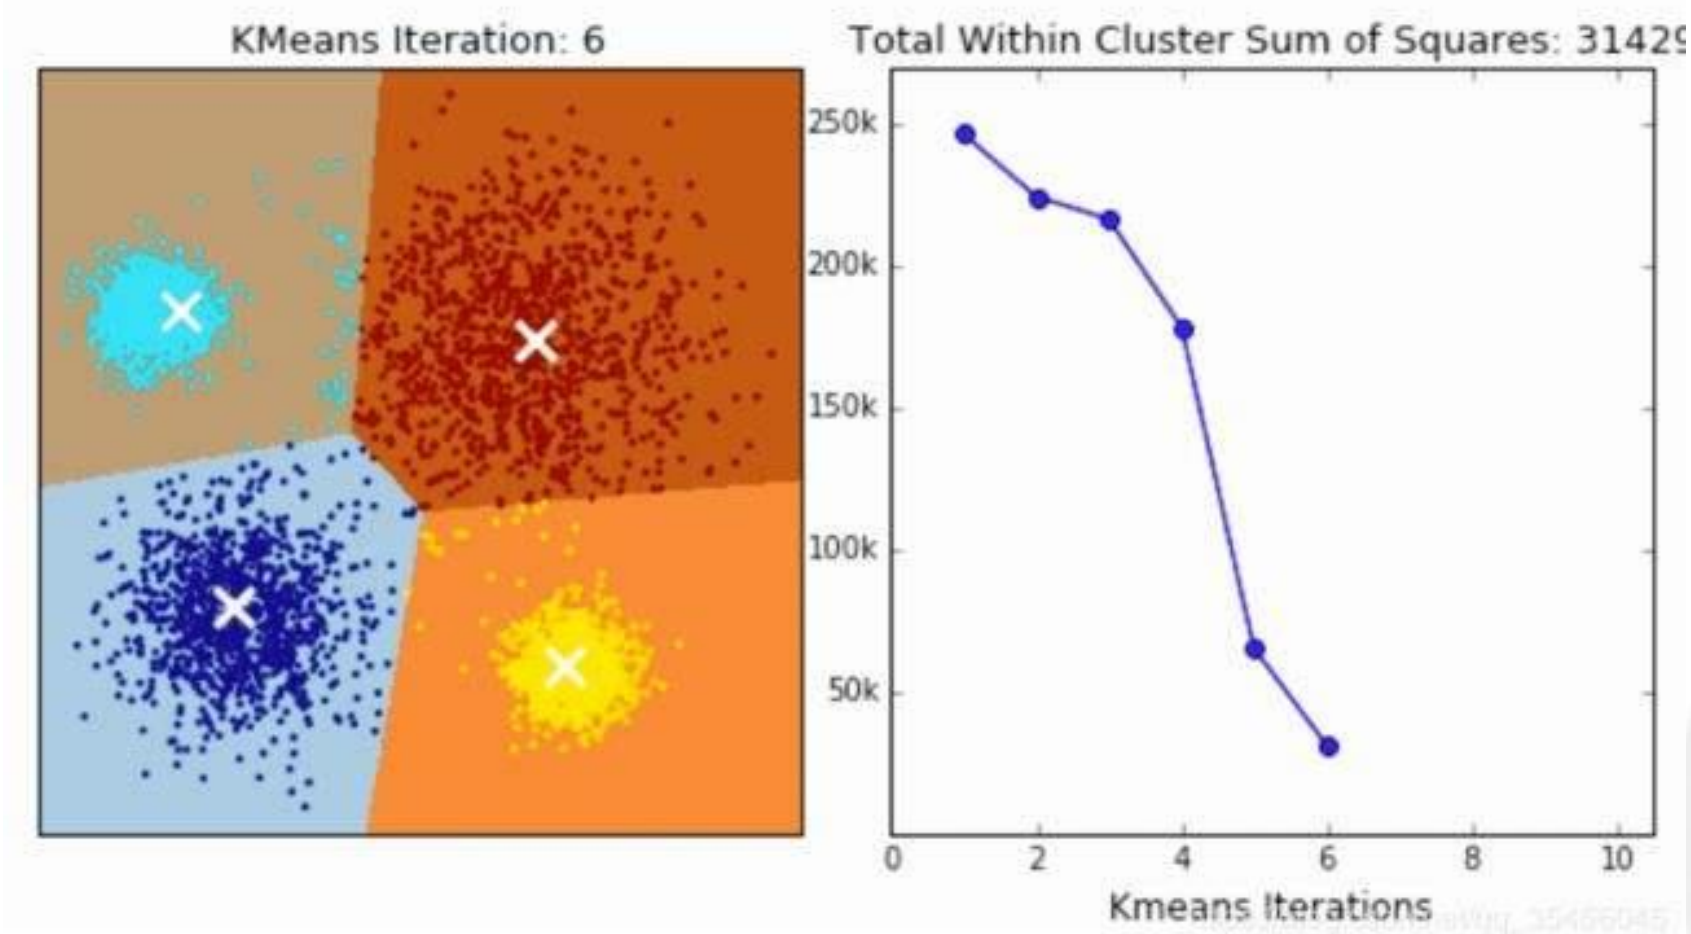
最佳值为1，最差值为-1。接近0的值表示重叠。
负值通常表示样本已分配给错误的聚类

SSE的计算



$$SSE = \sum_{i=1}^{k} \sum_{p \in C_i} |p - m_i|^2$$

SSE随K的变化


KMeans Iteration: 6
Total Within Cluster Sum of Squares: 3142
250k
200k
150k
100k
50k
0
2
4
6
8
10
Kmeans Iterations

6. 案例研究

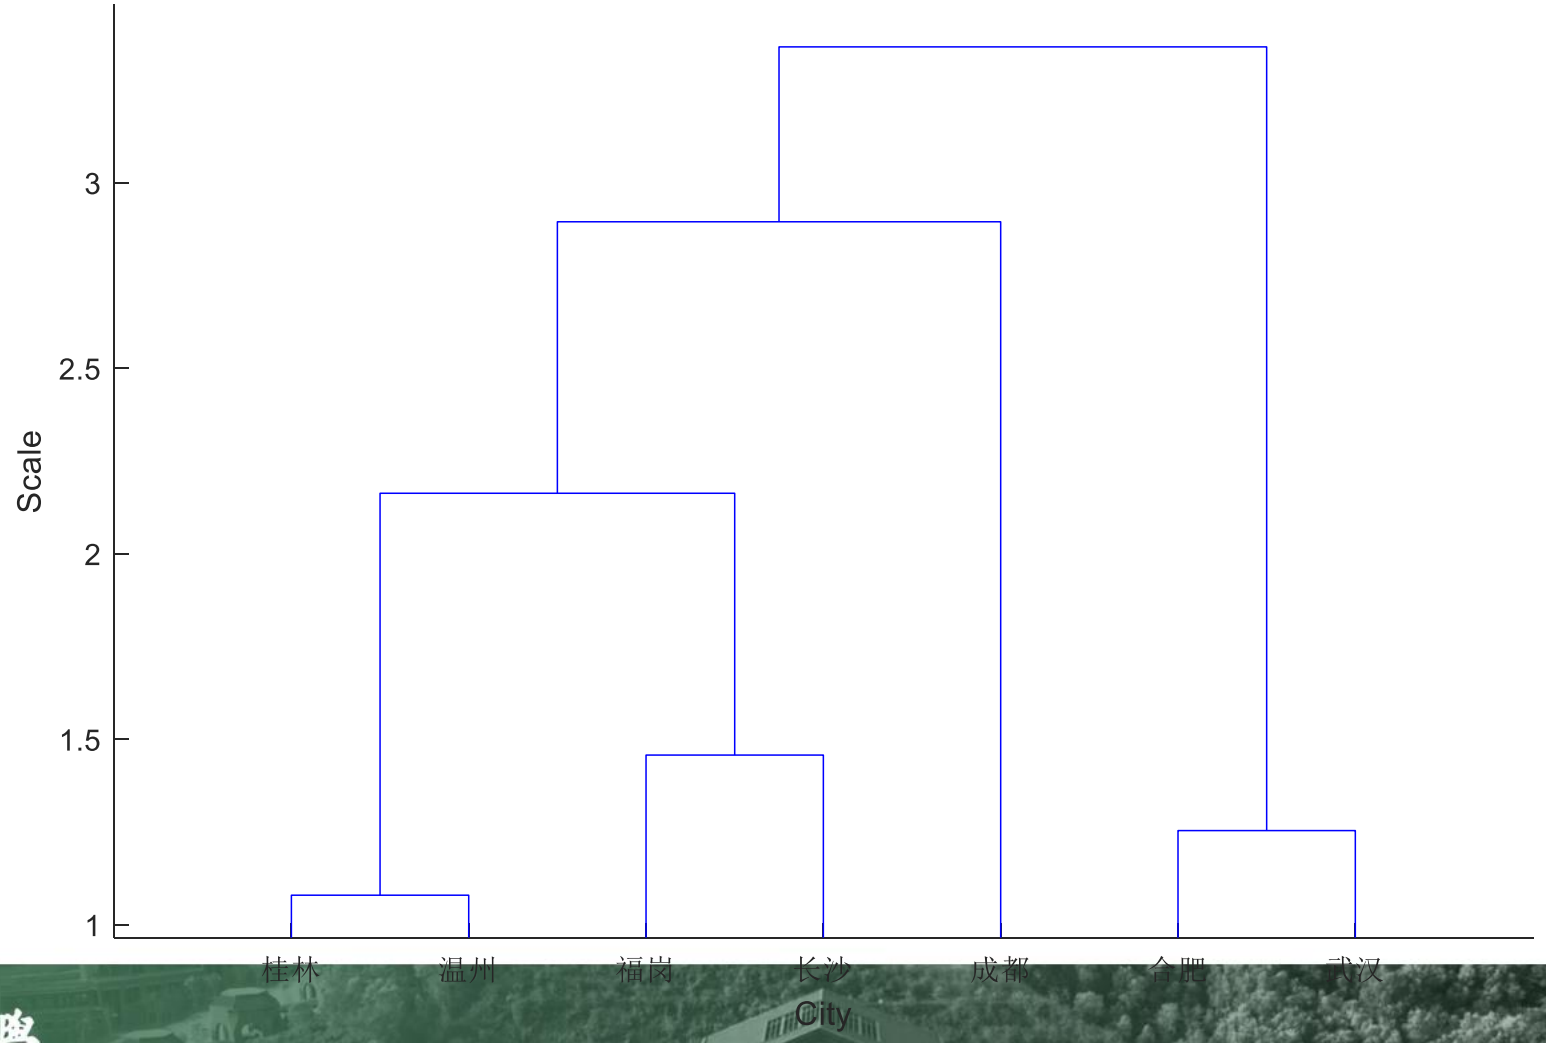
案例问题1：找到适合引种的地点

从日本引进福冈甜橘，候选地点是 合肥、武汉、长沙、桂林、温州、成都，请根据这些条件找到最相似的适合引种的地点。

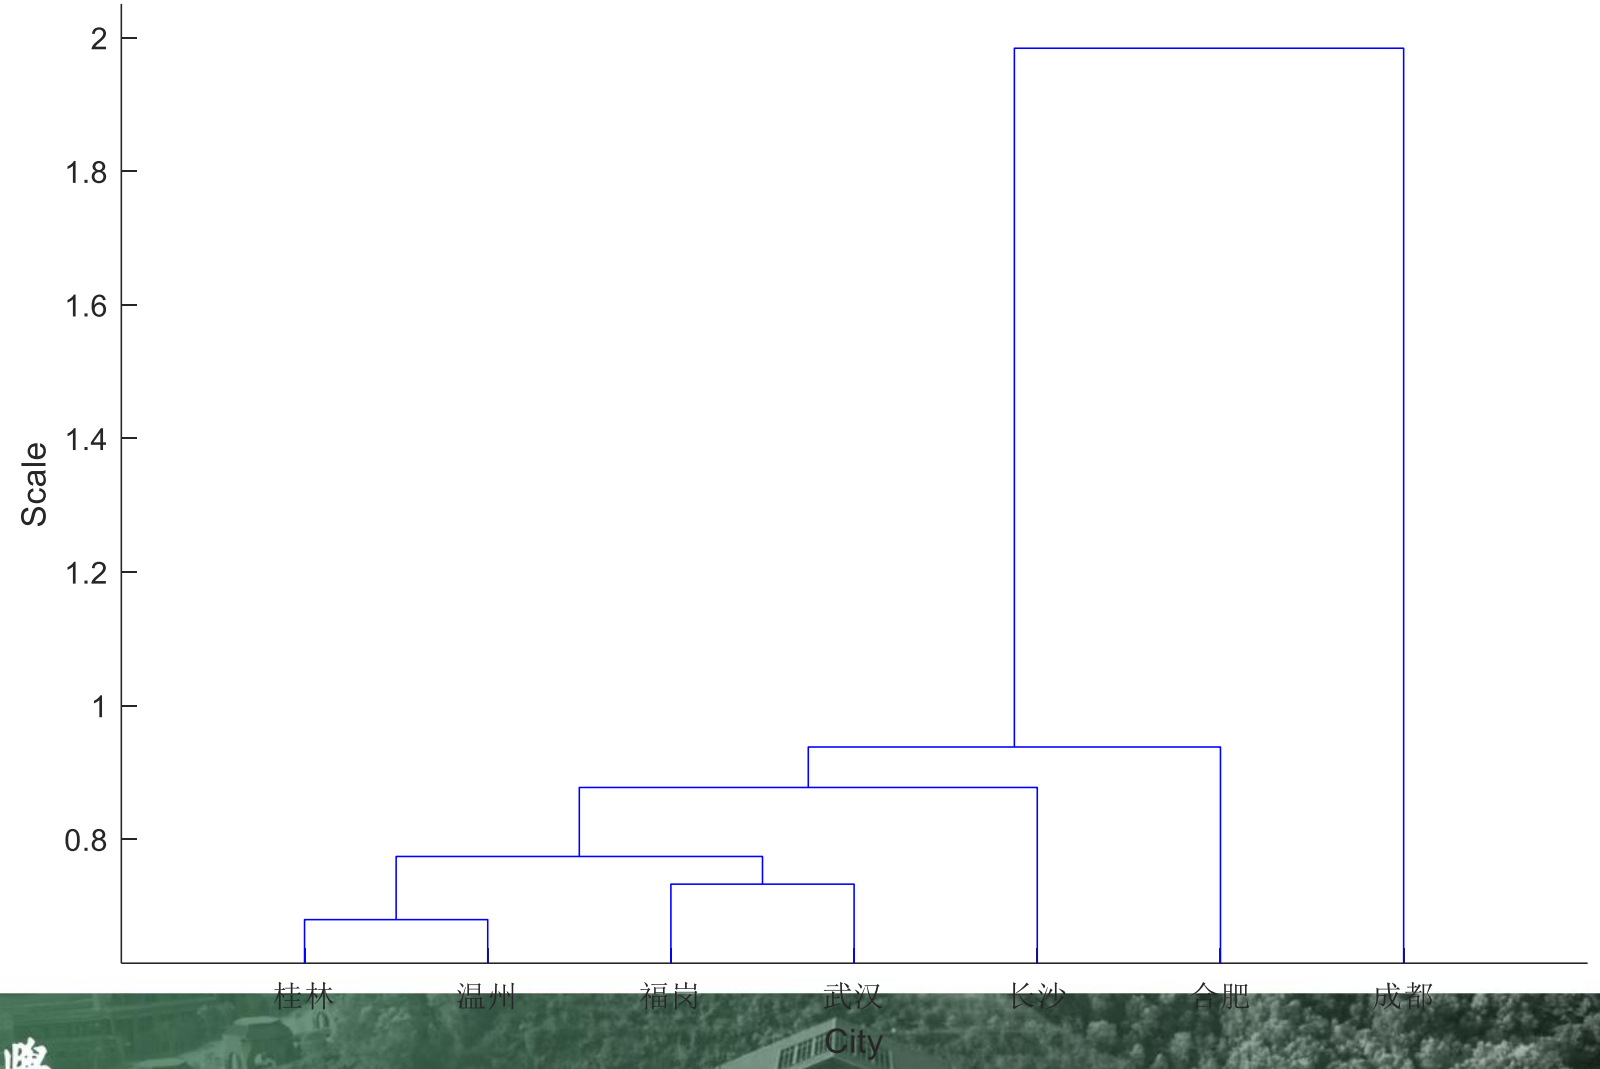
表 6-1-1　变量的原始数据

变量	福冈	合肥	武汉	长沙	桂林	温州	成都
	1	2	3	4	5	6	7
年平均气温/℃	16.2	15.7	16.3	17.2	18.8	17.9	16.3
年平均降水量/mm	1 492	970	1 260	1 422	1 874	1 698	976
年日照时数/h	2 000	2 209	2 085	1 726	1 709	1 848	1 239
年极端最低气温/℃	-8.2	-20.6	-17.3	-9.5	-4.9	-4.5	-4.6
一月平均气温/℃	6.2	1.9	2.8	4.6	8.0	7.5	5.6

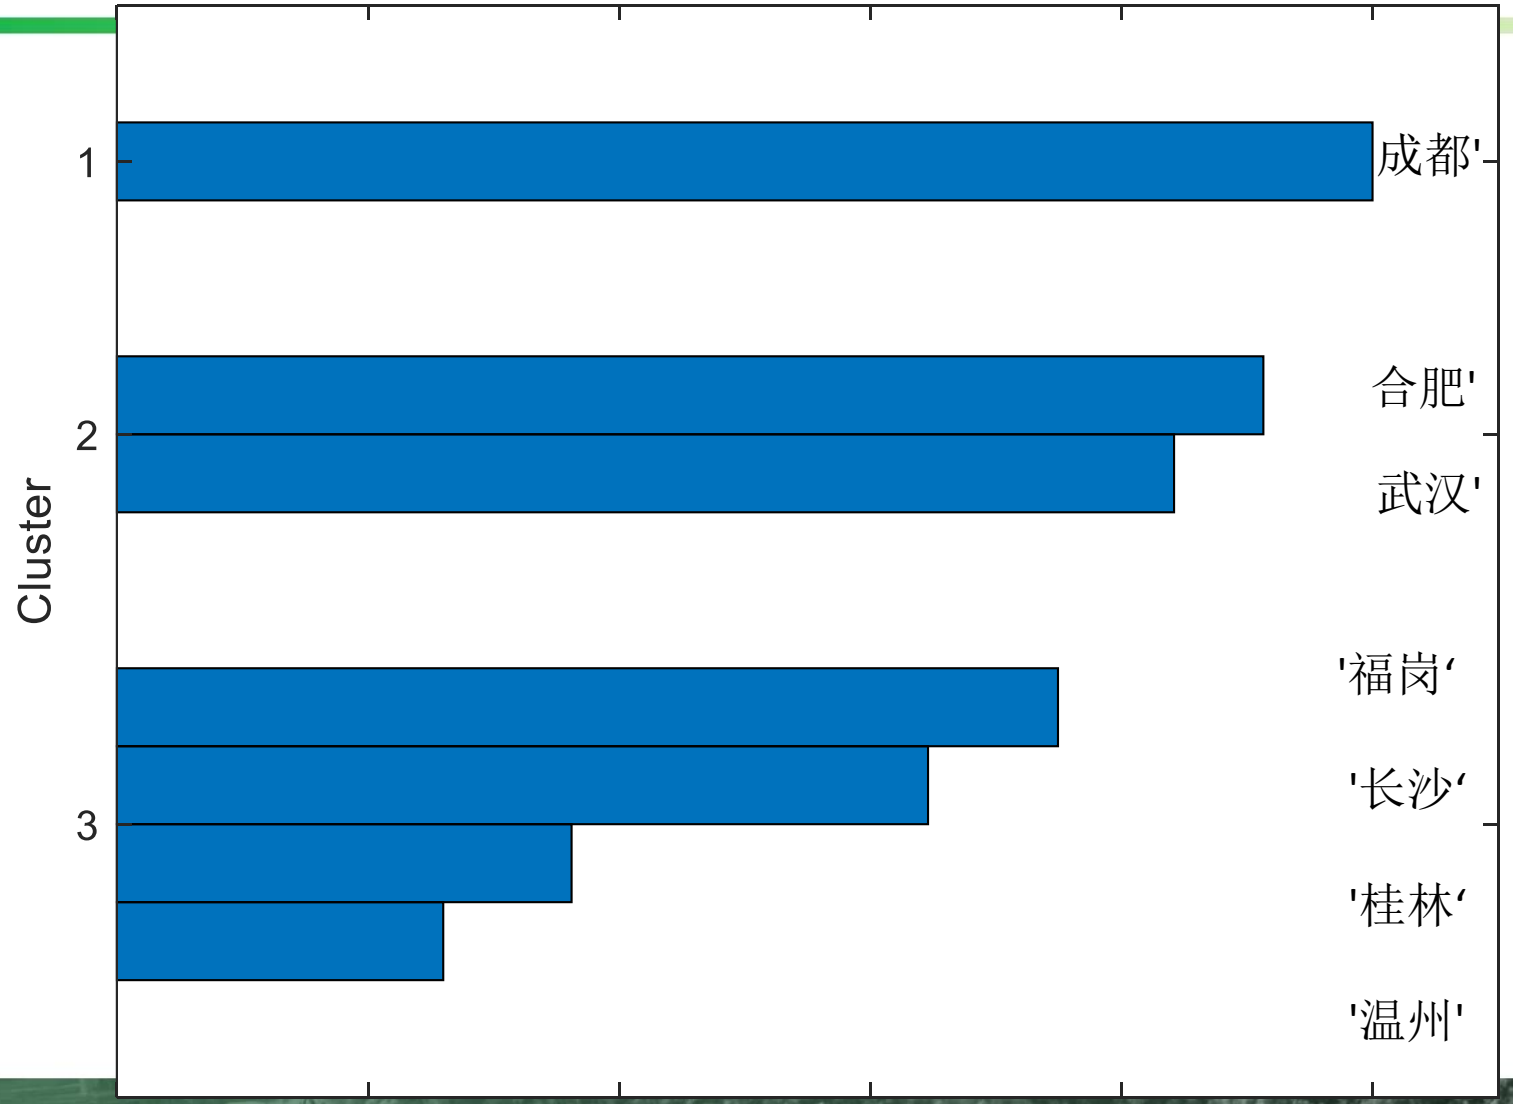
层次聚类：中心法&标准欧式距离



最短距离法&基于主成分的标准欧式距离



K-均值聚类



案例问题2：Fisher 鸢尾花数据

- **数据**：20 世纪 20 年代，植物学家收集了 150 个鸢尾花标本（三个品种各取 50 个标本）的萼片长度、萼片宽度、花瓣长度和花瓣宽度的测量值。这些测量值被称为 Fisher 鸢尾花数据集。
- **问题**：忽略品种信息，仅使用原始数据进行聚类。
- **方法**：K 均值和层次聚类法
- **提示**：在此数据集中，每个观测值都来自一个已知的品种，因此已经有明显的方法对数据进行分组。将聚类得到的簇与实际的品种进行比较，以了解这三种鸢尾花是否具有不同的特性。
- **代码**：openExample('stats/clusterdemo')

7. 小结

层次聚类的MATLAB 实现方法

No	方法	主要命令	含义
第1种	单函数法	clusterdata	根据不同样品距离，不同的类间距离，综合求解层次聚类。包含了pdist, linkage, 和 cluster 函数。
第2种	多函数法	pdist	计算样品之间的某种距离
		squareform	排出距离矩阵
		linkage	根据某种类间距离法进行聚类
		dendrogram	画出聚类谱系图
		cophenet	计算Cophenetic相关系数
		cluster	计算类别编号结果

K-均值聚类的MATLAB 实现方法

主要命令	含义
kmeans	将n个点（或观测）分为k类。聚类过程是动态的，通过迭代使得每个点与所属类中心距离的和达到最小。默认情况下，kmeans采用平方欧式聚类。
silhouette	根据聚类的结果绘制轮廓，从轮廓中可以看出那个点的分类是否合理。 S(i)=min(b)-a/max(a,min(b)) a是第i个点与同类的其他点之间的平均距离； b为一个向量，其元素是第i个点与不同类的类内各点之间的平均距离。 轮廓值S(i)的取值范围为[-1,1]，S(i)的值越大，说明第i个点的分类越合理，当S(i)<0时，说明第i个点的分类不合理，还有比目前分类更合理的分类。

DBSCAN的MATLAB 实现方法

主要命令	含义
设定参数	minpts：至少大于属性个数+1。 Epsilon：看图调整或者通过k距离图给个初始值
dbscan	将n × p的X数据矩阵中的观测值划分为多个簇。 即根据邻域搜索半径的阈值eps和minpts，识别核心点所需的最小邻居数，对观测值（或点）进行聚类。 该函数返回一个n ×1 向量（idx)，其中包含每个观测值的聚类索引。

思考题

- 聚类的目的和特点是什么?
- 哪些常用的聚类方法?
- 聚类之前是否要对数据进行标准化?
- 怎么选择点间和类间的距离?
- 怎么评价和判断聚类的效果?
- 还有其他聚类方法吗?
- 聚类和分类的区别是?

延伸阅读

Matlab官网中关于聚类分析的介绍

https://ww2.mathworks.cn/help/stats/cluster-analysis.html

Fisher 鸢尾花数据的聚类分析

https://ww2.mathworks.cn/help/stats/cluster-analysis-example.html

Python的scikit-learn 包关于聚类分析的介绍

https://scikit-learn.org/stable/modules/clustering.html