人工智能与地理数据挖掘

第五讲 降维

孙伟 sunwei29@mail.sysu.edu.cn

地理科学与规划学院

中山大學 SUN YAT-SEN UNIVERSITY

2026.4

机器学习的典型方法

类别	聚类/降维	回归	分类	生成
线性方法	相关性 主成分分析 因子分析	多元线性回归	Logistic回归 判别分析	
最近邻	k均值聚类	kNN		
树型	层次聚类	决策树： 回归树	决策树： 分类树	深度 森林
密度	DBSCAN			
神经网络	SOM	ANN		
核函数		SVM（SVR）	SVM（SVC）	
图论	谱聚类	概率图模型	概率图模型	GNN
随机变量	高斯混合		贝叶斯分类	GAN
模糊数	模糊C 均值聚类	模糊逻辑模型 ANFIS	模糊逻辑模型	FDNN
深度学习	自动编码器	CNN，LSTM、Transformer		

目录

1. 降维方法概述
2. 主成份分析
3. 因子分析
4. 案例分析
5. 小结

1.降维方法概述

降维定义?

降维(dimension reduction)

定义：通过某种数学变换，将原始高维属性空间转变为一个低维“子空间”（subspace)。

为什么需要降维?

1. 解决存在多个自变量而且某些变量之间有共线性的原始问题
2. 用更少的自变量去描述原始问题
   - 去掉一些自变量
   - 构造一些更少的新自变量
3. 减少到几个主成份（新自变量）？
4. 是否根据因变量对自变量降维（特征选取）

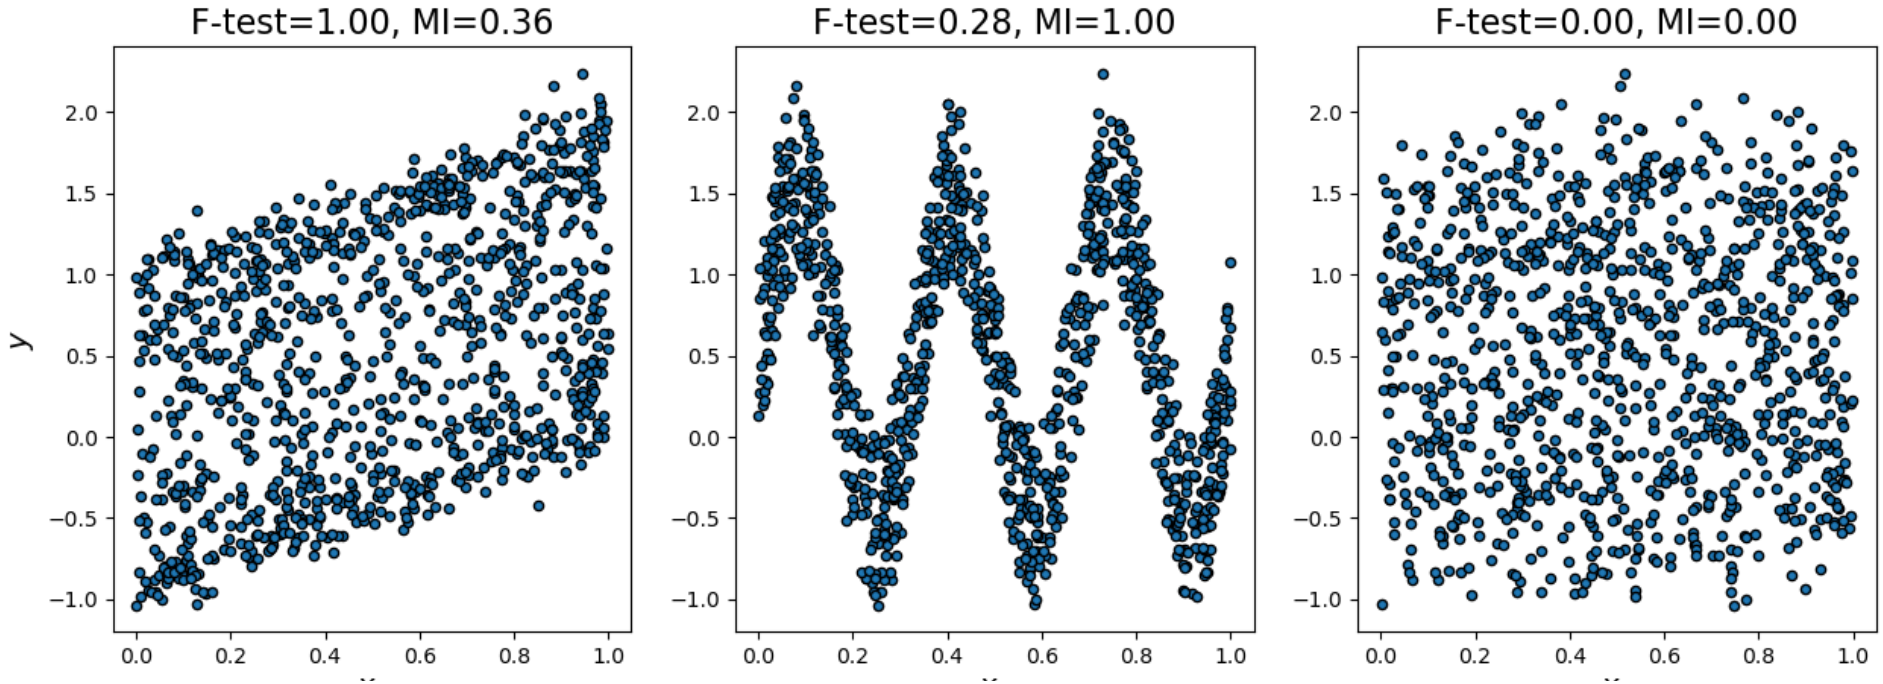
怎么降维?

思路	原理	方法	解释
不构造新的特征	从n维特征中去除其余n-k特征，保留k个特征	相似性分析,R型聚类，或其他统计检验	1）根据某种指数，描述n维特征两辆之间的相似性 2）过于相似的特征只保留其中一个
构造新的特征	将n维特征映射到k维上(k<n) ➔重新构造出来的全新k维特征➔多少个k合适? k维是正交特征（主成分）➔怎么保证正交?	主成分分析（PCA）或 因子分析（FA）	1）构造n个正交的特征 2）将n个新特征（新自变量）按照某种性能指数进行排序， 3）量化每个特征的描述能力 4）选取足够描述数据的前面k个新特征

降维以后能做什么？

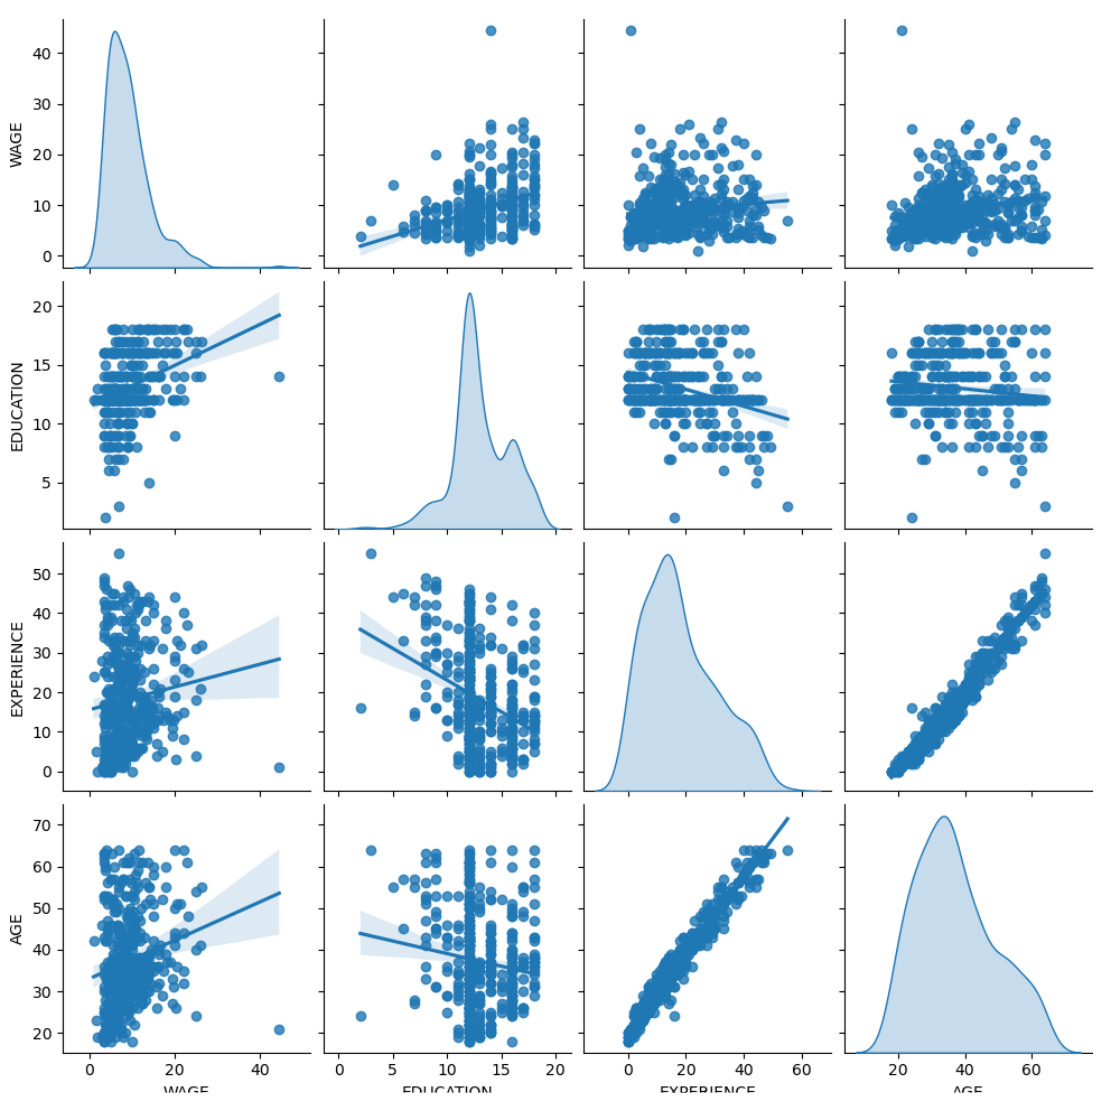
1. 将**数据**投影到新轴（更少的原自变量或新自变量）组成的空间上
   ➔**2-3维新空间中的散点图，观察其分布**
2. 将**旧轴**（原自变量）投影到新轴（更少的原自变量或新自变量）组成的空间上➔**2-3维新空间中的射线，观察其分布和相互关系**
3. 构造新的特征➔获得载荷矩阵➔分析**新旧自变量关系**➔推测**新自变量的含义。**
4. 根据更少的原自变量或新自变量，**进一步建模**，减少噪声数据，节省数据存储，缩小模型体积，缩短训练时间

不构造新X例子1：X和Y（属性）相关性



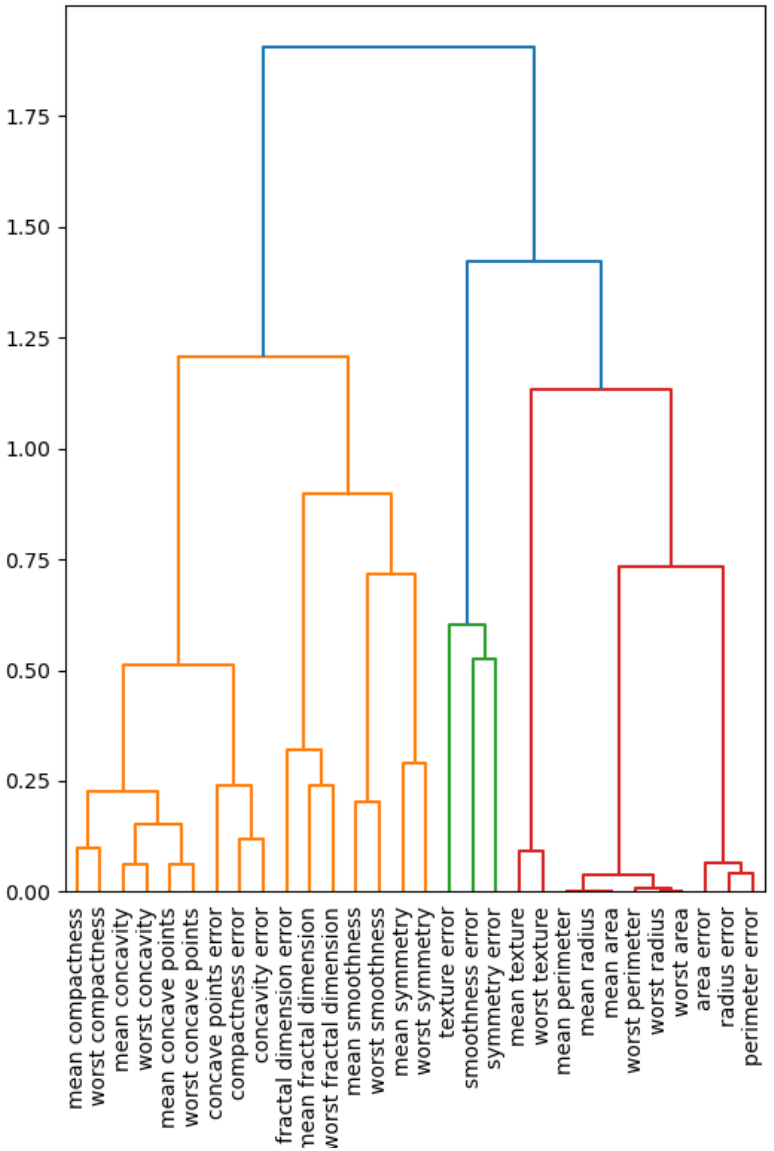
- **F检验**：检验两组数据（X和Y）之间的线性关系，原假设是” X和Y不存在显著的线性关系“。返回F值和p值；p值小于0.05或0.01的X和Y显著线性相关。
- **互信息法（MI）**：检验每个特征与标签之间的任意关系（包括线性和非线性关系）的过滤方法。 https://scikit-learn.org/stable/auto_examples/feature_selection/plot_f_test_vs_mi.html

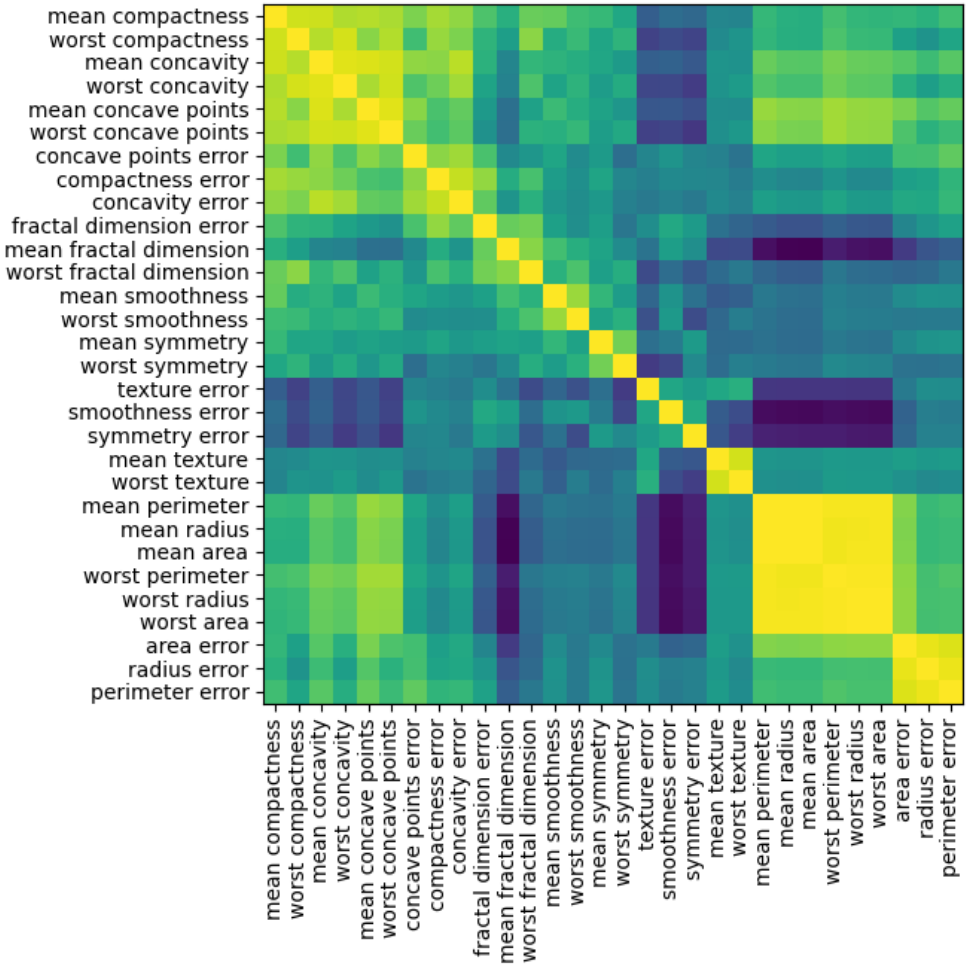
不构造新X例子2： 3X和1Y相关性



https://scikit-learn.org/stable/auto_examples/inspection/plot_linear_model_coefficient_interpretation.html

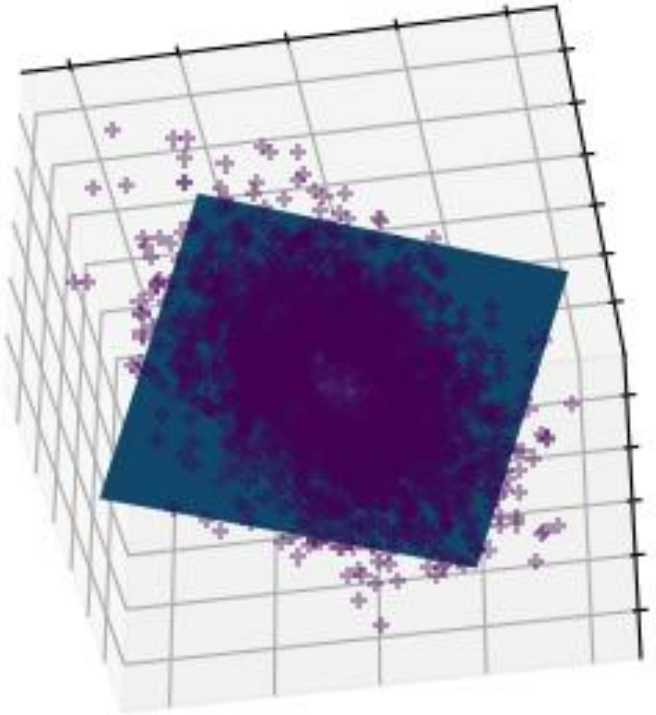
不构造新X例子3：属性聚类和属性相关性

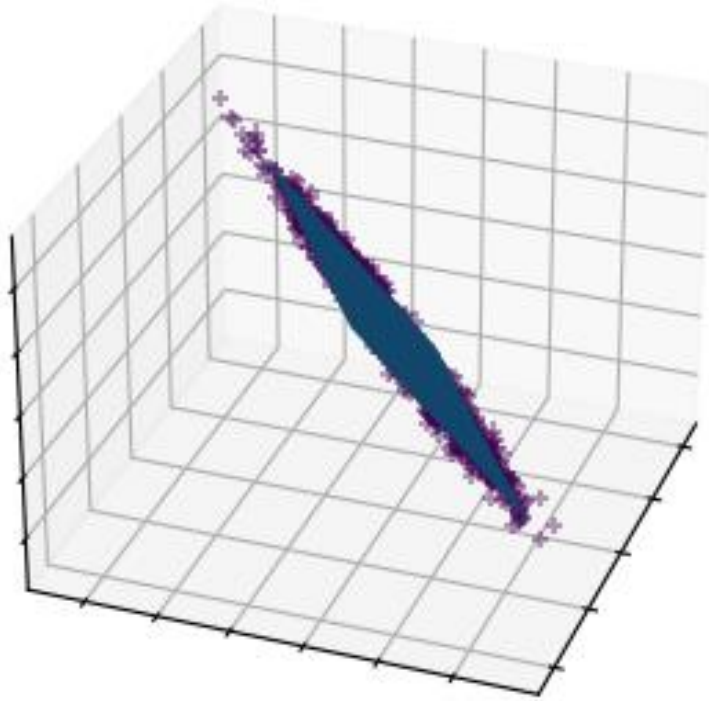




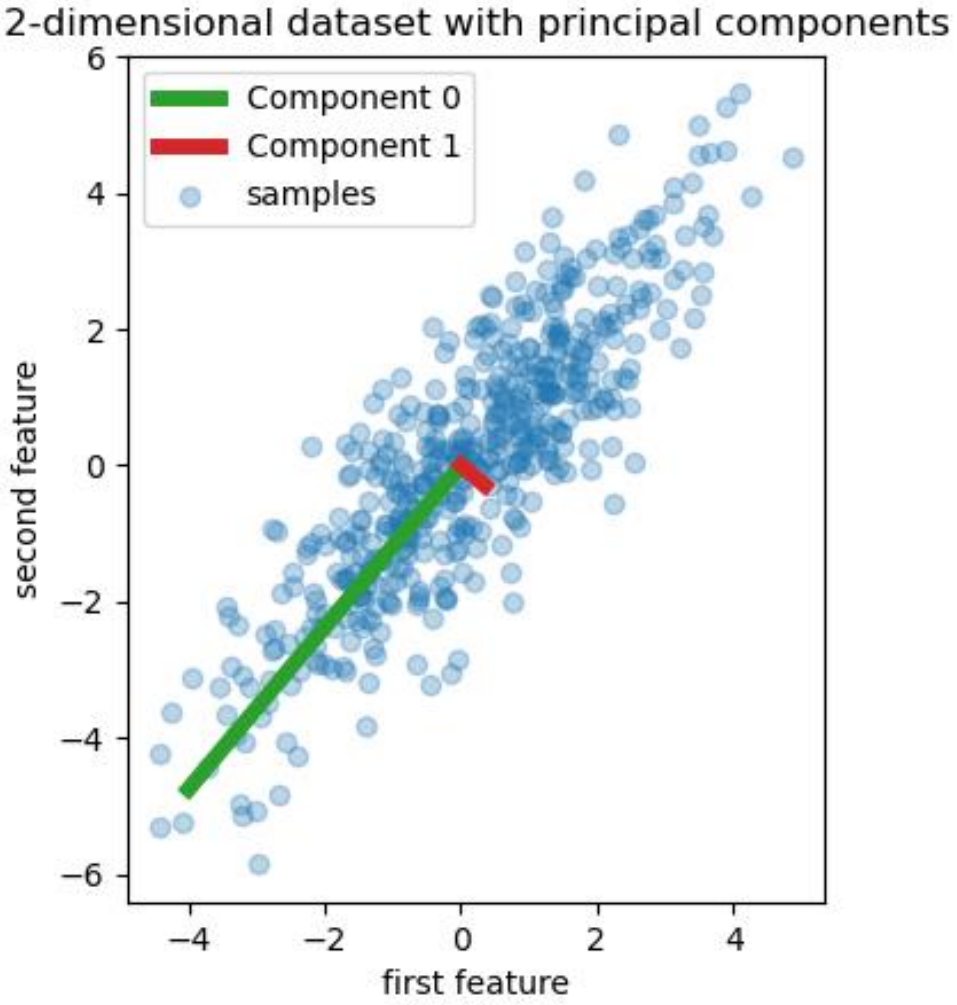
scikit-learn.org/stable/auto_examples/inspection/plot_permutation_importance_multicollinear.html

构造新X的例子1：3X换成2新X（主成份）





构造新X的例子2：2X换成1个主成份



降维（无监督）举例

方法	英文名	含义	适用条件
主成分分析	Principal component analysis，PCA	综合变量既要能尽可能多地反映原来变量的信息，又要彼此互不相关（正交）	某些求解要求自变量是正态分布的；部分自变量存在多重共线性
因子分析	Factor Analysis，FA	将原始变量分解为少数几个因子，以再现原始变量与因子之间关系；因子最好正交	某些求解要求自变量是正态分布的；部分自变量存在多重共线性
非负矩阵分解	Non-negative Matrix Factorization NMF或NNMF	NMF能够找到一个非负矩阵W和一个非负矩阵H的乘积近似等于矩阵V中的值，即 V(n,m)=W(n,k)*H(k,m)	原始数据矩阵中所有元素均为非负数（非负矩阵V=特征W × 系数H）
独立成分分析	Independent Component Analysis，ICA	一组混合的观测信号中分离出独立信号。 ICA认为观测信号是若干个统计独立的分量的线性组合，ICA要做的是一个解混过程。	自变量可以是非正态分布或至少不全是正态的

特征选取（有监督）举例

方法	英文名	含义	适用条件
过滤法	Filter	使用评价准则来增强特征与类的相关性，削减特征之间的相关性. 评价函数分成4 类: 距离度量、信息度量、依赖性度量以及一致性度量.	与后续算法无关，直接利用所有训练数据的统计性能评估特征，速度快，但评估与后续学习算法的性能偏差较大.
封装法	Wrapper	通过搜索策略，获得那些使模型能取得较高性能的特征即可	利用后续学习算法的训练准确率评估特征子集，偏差小，计算量大，不适合大数据集
逐步回归分析	Stepwise Regression Analysis	将变量逐个引入模型，进行F检验/t检验，以确保每次引入新的变量之前回归方程中只包含显著性变量。反复迭代，直到最后得到的解释变量集是最优的。	属于Wrapper 自变量是正态分布的 部分自变量存在多重共线性

2. 主成份分析

主成分分析（PCA）的概述

英文： Principal Component Analysis, PCA)

目的：

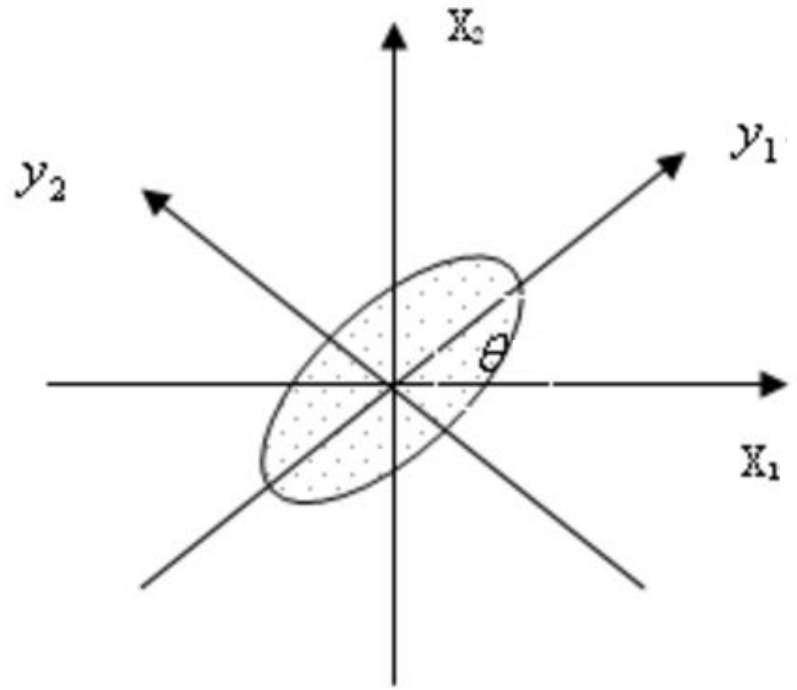
- 降低原变量的共线性的消极影响，
- 约减变量和系统降维➔复杂分析过程简化
- 对系统的发展进行综合评价，或者寻找某种隐含的因果关系、揭示自然规律等。

PCA的基本思想

- 将原来的变量进行线性组合，作为新的综合变量
- 尽可能地代表原来变量的信息量➔“信息”用方差来测量，即希望var (F1)越大，表示F1包含的信息越多。
- 彼此之间互不相关➔如果第一主成分（记为F1 ）不足以代表原来p个变量的信息，再考虑选取F2 即第2个线性组合，要求cov(F1, F2)=0，称F2为第二主成分，依此类推。
- n个变量最多可提取n个主成分，为了简化数据，通常小于n。
- 提取出的主成分能包含主要信息即可，不一定非要有准确的实际含义（可解释性可能降低）。

PCA的几何解释

假设有n个样品，每个样品有两个变量，即**在二维空间中讨论主成分的几何意义**。设n个样品在二维空间中的分布大致为一个椭圆，



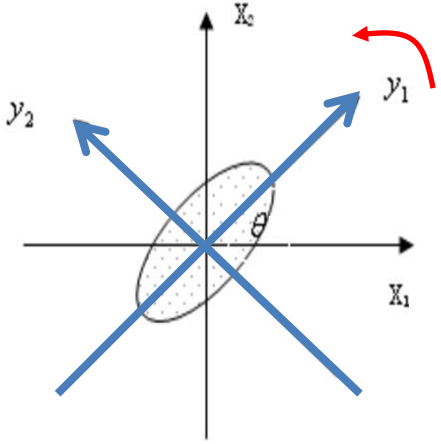
主成分几何解释图

PCA的几何解释

- 将坐标系**正交旋转一个角度θ**，使其椭圆长轴方向取坐标y_1，在椭圆短轴方向取坐标y_2，旋转公式为：

$$\begin{cases} y_{1j} = x_{1j}\cos\theta + x_{2j}\sin\theta \\ y_{2j} = x_{1j}(-\sin\theta) + x_{2j}\cos\theta \end{cases}$$

$$j = 1,2\cdots n$$



- 写成矩阵形式为：

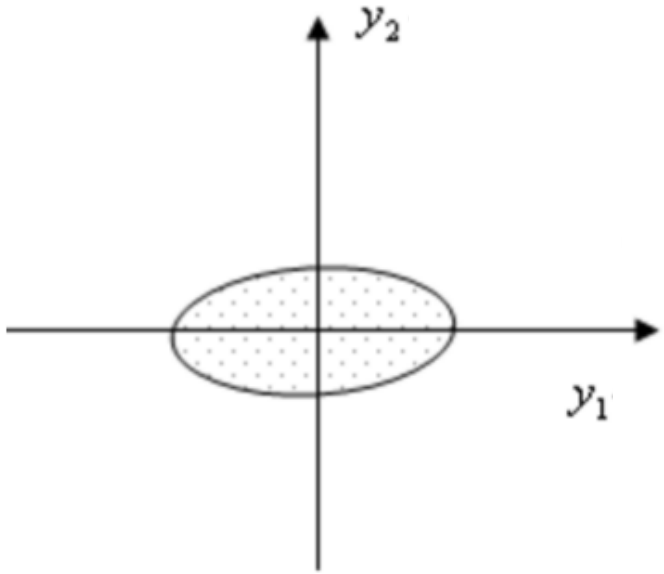
$$Y = \begin{bmatrix} y_{11} & y_{12} & \cdots & y_{1n} \\ y_{21} & y_{22} & \cdots & y_{2n} \end{bmatrix}$$

$$= \begin{bmatrix} \cos\theta & \sin\theta \\ -\sin\theta & \cos\theta \end{bmatrix} \cdot \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1n} \\ x_{21} & x_{22} & \cdots & x_{2n} \end{bmatrix} = U \cdot X$$

- 式中U为坐标旋转变换矩阵，它是正交矩阵，即有$U' = U^{-1}$，$UU' = I$，即满足$\sin^2\theta + \cos^2\theta = 1$。

PCA的几何解释

- 经过旋转变换后，得到下图的新坐标：



主成分几何解释图

- 新坐标y_1–y_2有如下性质：

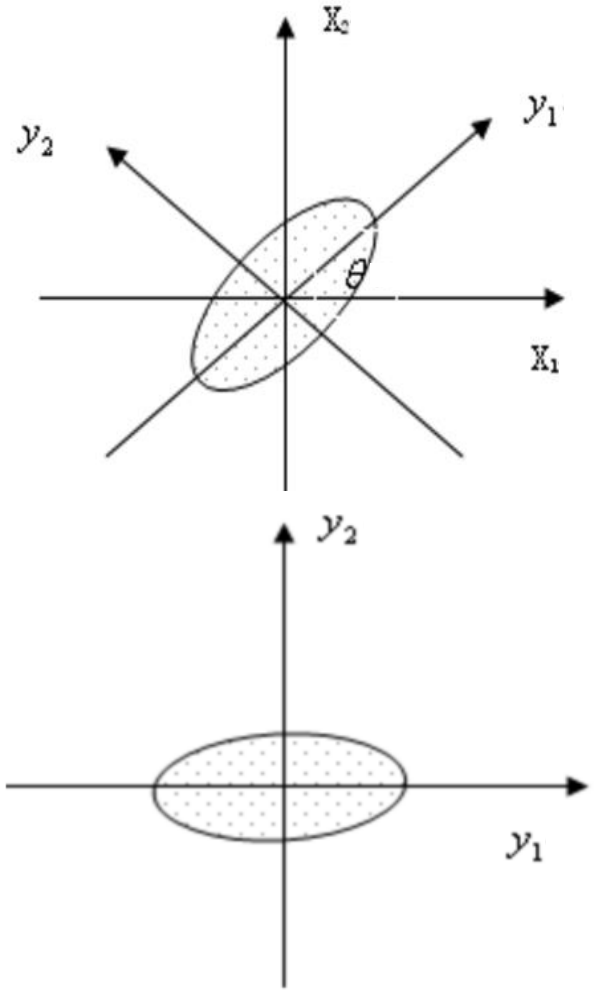
(1) n个点的坐标y_1和y_2的相关几乎为零。

(2) 二维平面上的n个点的方差大部分都归结为y_1轴上，而y_2轴上的方差较小。

y_1和y_2称为原始变量x_1和x_2的综合变量。由于n个点在y_1轴上的方差最大，因而将二维空间的点用在y_1轴上的一维综合变量来代替，所损失的信息量最小，由此称y_1轴为第一主成分。y_2轴与y_1轴正交，有较小的方差，称它为第二主成分。

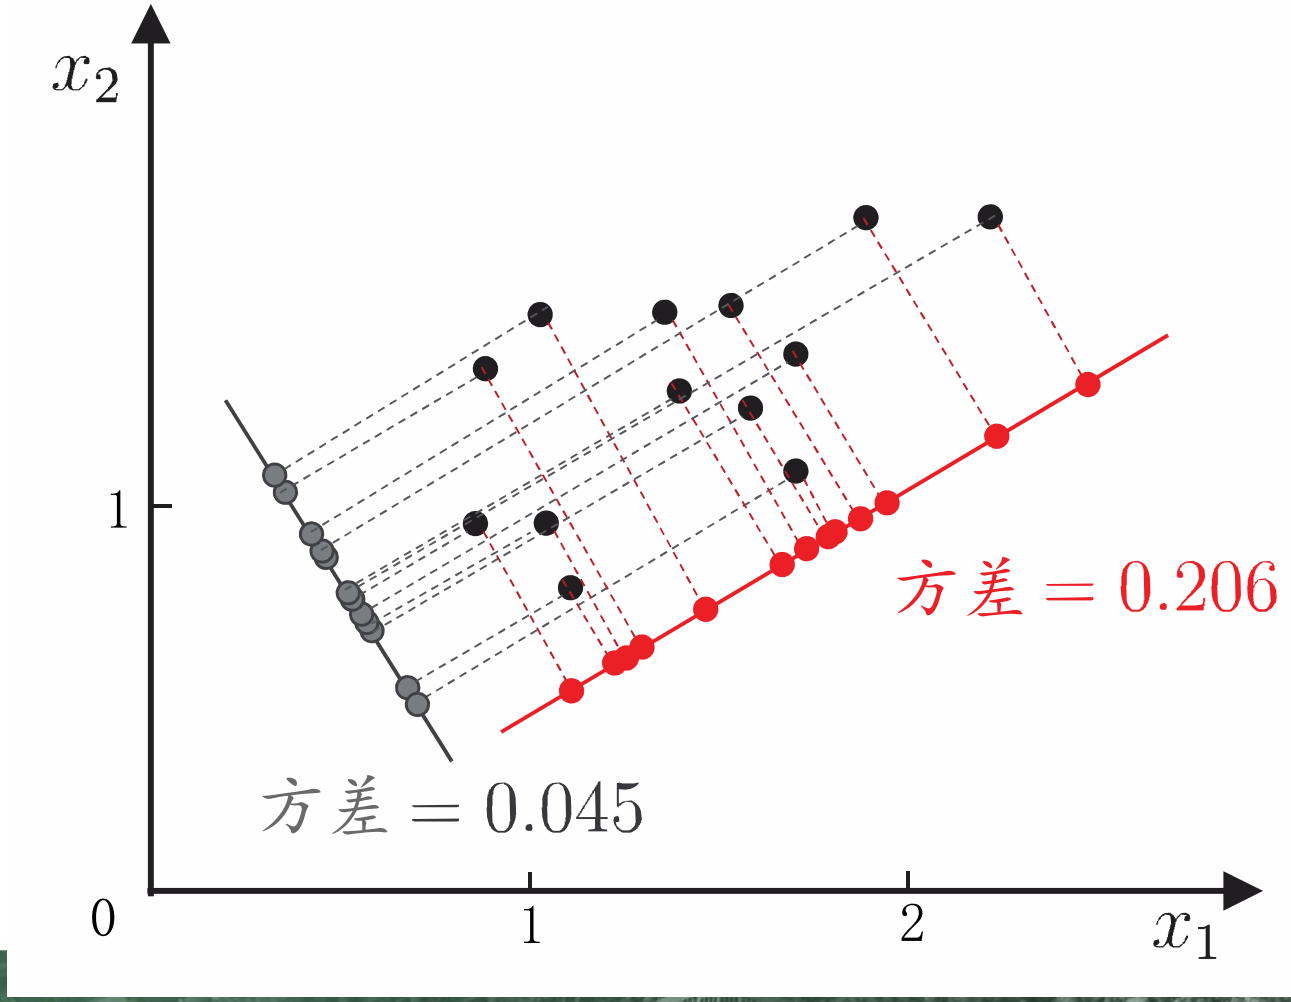
PCA的几何解释

- 当坐标轴和椭圆的长短轴平行，那么**代表长轴的变量就描述了数据的主要变化**，而**代表短轴的变量就描述了数据的次要变化**。
- 但是，原始坐标轴通常并不和椭圆的长短轴平行。因此，需要寻找椭圆的长短轴，并进行变换，使得新变量和椭圆的长短轴平行。
- 如果长轴变量代表了数据包含的大部分信息，就用该变量代替原先的两个变量（舍去次要的一维），降维就完成了。
- 椭圆（球）的长短轴相差得越大，降维越好。



主成分几何解释图

PCA的直观解释



PCA的数学表达：元素形式

主成分y和原始变量x之间的关系

综合

$$\begin{cases} y_1 = a_{11}x_1 + a_{12}x_2 + \cdots + a_{1p}x_p \\ y_2 = a_{21}x_1 + a_{22}x_2 + \cdots + a_{2p}x_p \\ \vdots \\ y_p = a_{p1}x_1 + a_{p2}x_2 + \cdots + a_{pp}x_p \end{cases}$$

a_{ij}为第i个主成分y_i和原来的第j个变量x_j之间的线性相关系数，称为载荷(loading)。

中山大學 SUN YAT-SEN UNIVERSITY

PCA的求解的思路

对于正交属性（新自变量/新轴）空间中的样本点，如何用一个超平面对所有样本进行恰当的表达？这里这个超平面应该有两个性质：

I.最近重构性：重构后的样本映射回原空间，与原样本的距离都足够的近；

II.最大可分性：样本在这个超平面上的投影尽可能分开。

PCA的数学表达：矩阵形式

- **最大可分性**

$$y_i = \mathbf{W}^{\mathrm{T}}\boldsymbol{x}_i$$

- **样本点 $\boldsymbol{x}_i$在新空间中超平面上投影是 $\mathbf{W}^{\mathrm{T}}\boldsymbol{x}_i$，若所有样本点的投影能尽可能分开，则应该使得投影后样本点的方差最大化。若投影后样本点的方差是**

$$\sum_i \mathbf{W}^{\mathrm{T}}\boldsymbol{x}_i\boldsymbol{x}_i^{\mathrm{T}}\mathbf{W}$$

- **优化目标**

$$\max_{\mathbf{W}} \quad \mathrm{tr}(\mathbf{W}^{\mathrm{T}}\mathbf{X}\mathbf{X}^{\mathrm{T}}\mathbf{W})$$
$$\text{s.t.} \quad \mathbf{W}^{\mathrm{T}}\mathbf{W} = \mathbf{I}.$$

矩阵的迹
(特征值的和)

优化求解：使用拉格朗日乘子法得到

$$\mathbf{X}\mathbf{X}^{\mathrm{T}}\mathbf{W} = \lambda\mathbf{W}.$$

只需对协方差矩阵 $\mathbf{X}\mathbf{X}^{\mathrm{T}}$ 进行特征值分解，并将求得的特征值排序：$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_d$ 再取前d'个特征值对应的特征向量构成 $\mathbf{W} = (\boldsymbol{w}_1, \boldsymbol{w}_2, \ldots, \boldsymbol{w}_{d'})$ 这就是主成分分析的解。

PCA求解的一般算法

输入： 样本集 $D = \{\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_m\}$;
低维空间维数 d'.

过程：

1: 对所有样本进行中心化: $\boldsymbol{x}_i \leftarrow \boldsymbol{x}_i - \frac{1}{m}\sum_{i=1}^{m} \boldsymbol{x}_i$;
2: 计算样本的协方差矩阵 $\mathbf{X}\mathbf{X}^{\mathrm{T}}$;
3: 对协方差矩阵 $\mathbf{X}\mathbf{X}^{\mathrm{T}}$ 做特征值分解;
4: 取最大的 d' 个特征值所对应的特征向量 $\boldsymbol{w}_1, \boldsymbol{w}_2, \ldots, \boldsymbol{w}_{d'}$.

输出： 投影矩阵 $\mathbf{W} = (\boldsymbol{w}_1, \boldsymbol{w}_2, \ldots, \boldsymbol{w}_{d'})$.

PCA求解的几个定义

概念	相关计算
原始数据X	原始数据或其标准化
协方差矩阵E	计算E的特征值和特征向量
E第i行的特征值	第i 个主成分的方差
特征值的大小顺序	主成分的方差顺序➔主成分顺序
E第i行的特征向量	第i 个主成分的系数矩阵

MATLAB 实现PCA方法1： 定义法

步数	命令	含义
1	mean std	将原始数据标准化
2	corrcoef/ cov	计算协方差矩阵或者相关系数矩阵
3	eig	计算协方差矩阵的特征值和特征向量
4	diag cumsum	计算主成分的累计方差贡献
5	开平方根 矩阵	计算主成分载荷和方差
6	矩阵运算	计算主成分得分，并将其标准化
7	plot	绘图：特征值折线图；主成分载荷图或者特征向量图；主成分得分图
8	矩阵	简单的检验

MATLAB 实现PCA方法2：单命令PCA

命令	含义	备注
PCA	求出主成分	核心计算
pareto	得到特征值的百分比和累计百分比（主成分的排序关系和解释能力）	选几个PC
gname	得到载荷图上的变量标识 (主成分和原变量关系图) 主成分得分图上的样品标签 (主成分和样本的关系图，即样本在主成份空间散点图)	观察新坐标轴下的投影
pcacov	求特征值、特征向量、方差贡献百分比	选几个PC
pcares	给定主成分数量下的残差分析	
battest	Bartlett检验（一种卡方检验）	

pca函数的调用格式

格式	用途
coeff = pca(X)	返回 n×p 数据矩阵 X 的主成分系数，也称为载荷。X 的行对应于观测值，列对应于变量。系数矩阵是 p×p 矩阵。coeff 的每列包含一个主成分的系数，并且这些列按成分方差的降序排列。默认情况下，pca 将数据中心化，并使用奇异值分解 (SVD) 算法。
coeff = pca(X,Name,Value)	使用由一个或多个 Name,Value 对组参数指定的用于计算和处理特殊数据类型的附加选项，返回上述语法中的任何输出参数。 例如，您可以指定 pca 返回的主成分数或使用 SVD 以外的其他算法。

pca函数的调用格式

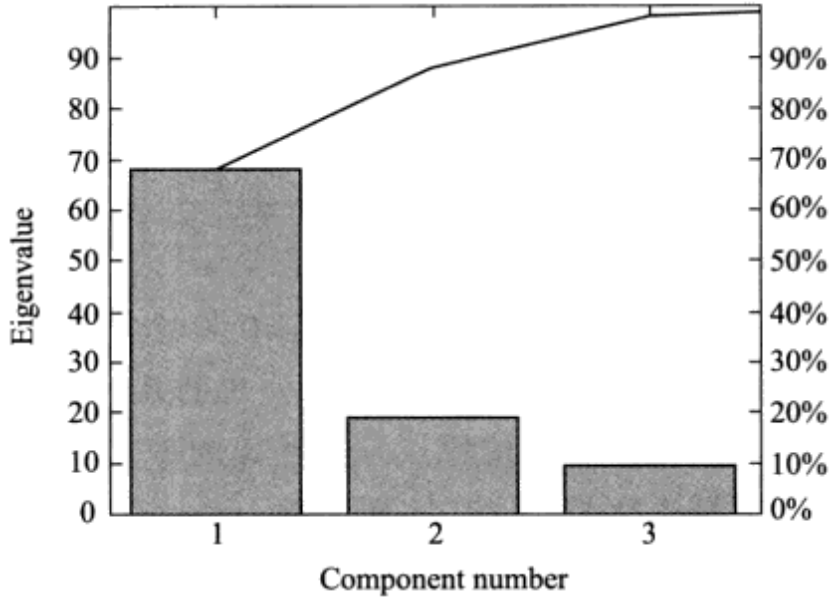
格式	用途
[coeff,score,latent] = pca(___)	还在 score 中返回主成分分数，在 latent 中返回主成分方差。您可以使用上述语法中的任何输入参数。主成分分数是 X 在主成分空间中的表示。score 的行对应于观测值，列对应于成分。主成分方差是 X 的协方差矩阵的特征值。
[coeff,score,latent,tsquared] = pca(___)	返回 X 中每个观测值的 Hotelling T 方统计量。
[coeff,score,latent,tsquared,explained,mu] = pca(___)	返回 explained（即每个主成分解释的总方差的百分比）和 mu（即 X 中每个变量的估计均值）。

pca函数的输入和输出参数

格式	用途
X	标准化的原始数据矩阵；
coeff	特征向量构成的正交矩阵； 按成分方差的降序排列主成分系数
score	X在主成分空间中的得分；
Latent	主成分方差；特征值矩阵的对角线元素； X 的协方差矩阵的特征值
tsquared	标准化的主成分得分到平均位置的距离平方，即Hotelling的T平方统计量
explained	即每个主成分解释的总方差的百分比
mu	X 中每个变量的估计均值

pareto函数

- 特征值的百分比（柱形图）和累计百分比（折线图）。
- 从柱形图：各个主成分的方差贡献量，
- 折线图：提取几个主成分后的方差累计贡献。

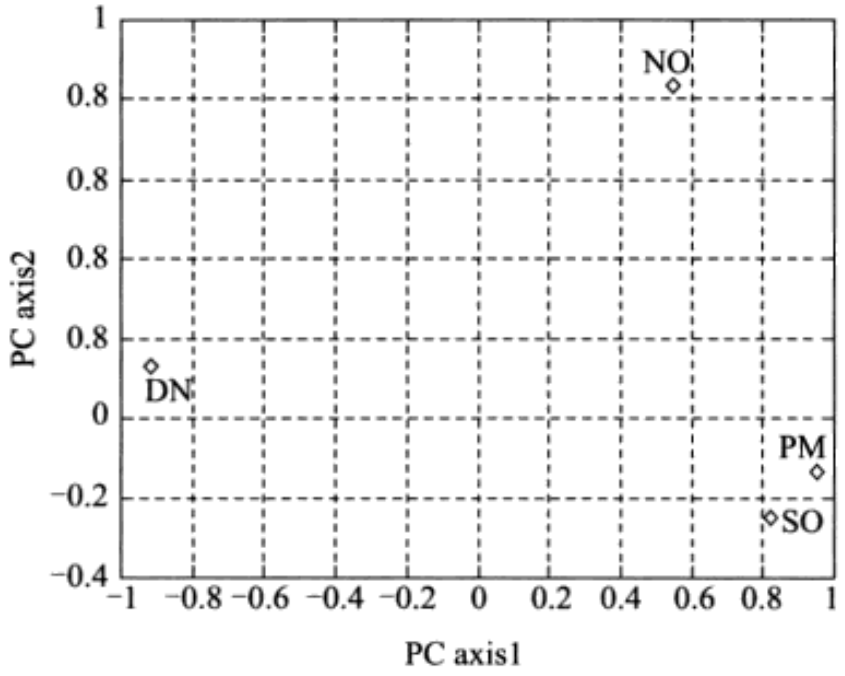


决定主成分数量的方法之一：以累计方差贡献不低于80%为标准(有时可以根据具体情况将标准降低到70%)；

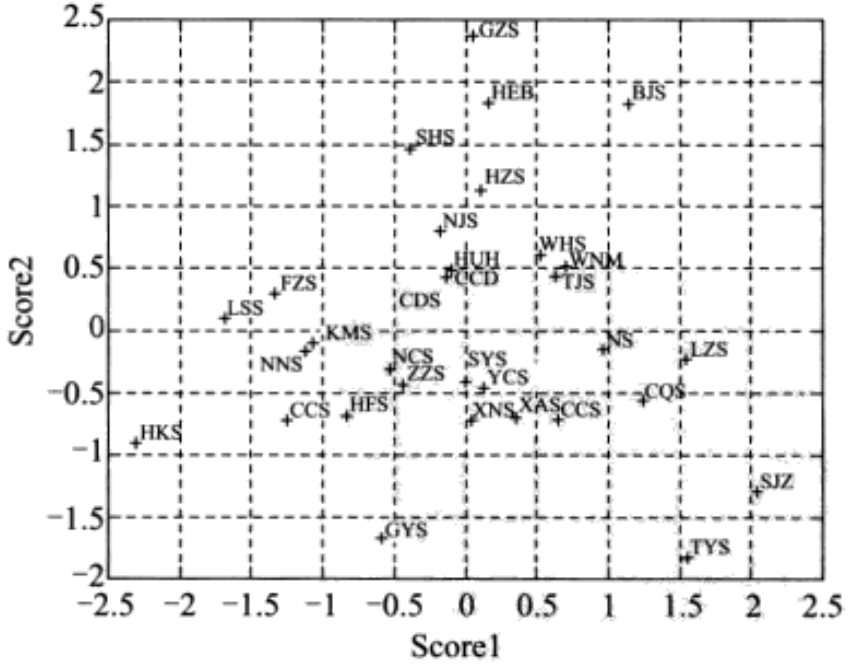
中山大
SUN YAT-SEN UNIV

gname 函数

带变量标识的主成分载荷图



带样品标识的主成分得分图



标识散点：图上出现两条十字交叉的定位线，移动鼠标，定位线的交叉点也跟着 移动。**选中需要给出标志的数据点，点击，即可出现变量标签。退出标识**：如果不想再标识散点，**连续按Esc键退出**即可。

中山大学 SUN YAT-SEN UNIVERSITY

如何确定主成分（PC）的数量?

一般按照如下原则决定主成分数量的多少：

- **一是以协方差矩阵特征值(也是主成分得分的方差)大于1为标准，或者根据特征值折线图上的明显转折点来判断；**
- **二是以累计方差贡献不低于80%为标准(有时可以根据具体情况将标准降低到70%)；**
- **三是以公因子方差相差不大为判据；**
- **四是借助Bartlett检验进行判断。**

不管采用何种标准，都要以提取主成分的公因子方差相差不大为前提，都可以将主成分残差分析、相关系数残差分析等作为辅助分析判据。一般情况下，可以将上面的两种乃至更多的标准结合起来使用。

3.因子分析

因子分析概述

英文： Factor Analysis

定义：

1. 每个已测变量等于数量较少的未发现（潜在）因子的线性组合。
2. 每个因子都可能影响多个变量，所以称为公因子。

因子分析和主成分分析的公式对比

原始变量x和因子f之间的关系

分解

$$\begin{cases} x_1 = a_{11} f_1 + a_{12} f_2 + \cdots + a_{1k} f_k + \varepsilon_1 \\ x_2 = a_{21} f_1 + a_{22} f_2 + \cdots + a_{2k} f_k + \varepsilon_2 \\ \vdots \\ x_p = a_{p1} f_1 + a_{p2} f_2 + \cdots + a_{pk} f_k + \varepsilon_p \end{cases}$$

f：公因子

a_{ij}：第个i变量与第j个因子之间的线性相关系数，反映变量与因子之间的相关程度，也称为载荷(loading)。

ε：特殊因子(公因子以外的因素影响)

因子分析的特点

- 原已测变量包含重叠信息，相互依赖；
- 因子个数一般少于原始变量个数
- 因子并非原始变量的简单取舍，而是一种新的综合
- 因子通常是未发现/不容易测量的潜在变量
- 因子之间一般没有线性关系（正交），也可以有线性关系（斜交）
- 因子能够反映众多原始变量的主要信息。
- 因子具有明确解释性（专业分析）

因子分析和主成分分析的异同点

- ✓ 与主成分分析类似，它们都是要找出少数几个新的变量来代替原始变量。
- ✓ 主成分分析中的主成分个数与原始变量个数是一样的，即有几个变量就有几个主成分，**只不过最后我们确定了少数几个主成分而已**。
- ✓ 而**因子分析则需要事先确定要找几个成分**，也称为因子(factor)，然后将原始变量分解为少数的几个因子，以再现原始变量与因子之间的关系，一般来说，**因子的个数会远远少于原始变量的个数。**

因子分析和主成分分析的异同点

- ✓ **因子分析可以看作是主成分分析的推广和扩展，但它对问题的研究更深入、更细致一些。实际上，主成分分析可以看作是因子分析的一个特例。**
- ✓ **因变量和因子个数的不一致，使得不仅在数学模型上，而且在实际求解过程中，因子分析和主成分分析都有着一定的区别，计算上因子分析更为复杂。**
- ✓ **因子分析可能存在的一个优点是：在对主成分和原始变量之间的关系进行描述时，如果主成分的直观意义比较模糊不易解释，主成分分析没有更好的改进方法；因子分析则额外提供了“因子旋转(factor rotation)”这样一个步骤，可以使分析结果尽可能达到易于解释且更为合理的目的。**

基本因子分析模型的矩阵形式

上式可以写为矩阵形式

$x=Af+\varepsilon$

其中

$A=(a_{ij})$ p行 x m列， 称为因子载荷矩阵；

$f=(f_1,f_2,\ldots,f_m)'$为公共因子向量；

$\varepsilon=(\varepsilon_1,\varepsilon_2,\ldots..\varepsilon_p)$称为特殊因子向量

中山大學 SUN YAT-SEN UNIVERSITY

基本因子分析模型

设p维总体$x=(x_1,x_2,\ldots,x_p)'$

因子分析的一般模型为

$$\begin{cases} x_1 = a_{11}f_1 + a_{12}f_2 + \cdots + a_{1k}f_k + \varepsilon_1 \\ x_2 = a_{21}f_1 + a_{22}f_2 + \cdots + a_{2k}f_k + \varepsilon_2 \\ \vdots \\ x_p = a_{p1}f_1 + a_{p2}f_2 + \cdots + a_{pk}f_k + \varepsilon_p \end{cases}$$

$f_1,f_2,\ldots,f_m$为m个公共因子（因子出现在每个原始变量与因子的线性组合中，因此称为*公因子*）；

ε_i是变量$x_i(i=1,2,\ldots,p)$所独有的特殊因子，他们都是不可观测的隐变量，代表公因子以外的因素影响。

$a_{ij}(p \times m)$为变量x_i的公共因子f_i上的载荷，它反映了公共因子对变量的重要程度，对解释公共因子具有重要的作用。系数a_{ij}为第个i变量与第k个因子之间的线性相关系数，反映变量与因子之间的相关程度，也称为载荷(loading)。

因子分析的评价

因子载荷矩阵 → 公共因子的解释
因子旋转方法

因子得分矩阵 → 单个/总因子得分
共性/特殊方差➔海伍德现象

公共因子的解释

- 因子分析的主要目的是对公共因子给出符合实际意义的合理解释，解释的依据就是因子载荷矩阵的各列元素的取值。
- 当因子载荷阵某一列上各元素的绝对值差距较大时，并且绝对值大的元素较少时，则该公共因子就易于解释；
- 反之，公共因子的解释就比较困难➔此时可以考虑对因子和因子载荷进行旋转（例如正交旋转），使得旋转后的因子载荷阵的各列元素的绝对值尽可能向两极分化，这样就使得因子的解释变得容易。

因子旋转方法

因子旋转方法有**正交旋转**和**斜交旋转**两种

- **正交旋转**是指坐标轴始终保持垂直90度旋转，这样**新生成的因子仍可保持不相关**。
- **斜交旋转**坐标轴的夹角可以是任意的，因此新生成的因子不能保证不相关。因此实际应用中更多地使用正交旋转。

因子旋转方法：最大方差旋转

一种普遍使用的正交旋转法：**最大方差旋转**。

- 这种旋转方法的目的是使因子载荷阵每列上的各元素的绝对值（或平方值）尽可能地向两极分化，
- 即少数元素的绝对值（或平方值）取尽可能大的值，而其他元素尽量接近于0 。

因子得分

因子载荷矩阵是各个原始变量的因子表达式的系数，表达提取的公因子对原始变量的影响程度，描述的是**各项指标变量（x）**与**提取的公因子(F)**之间的关系

- **例如** X1=a11*F1+ a12*F2+ a13*F3,
- 其中X1为指标变量1，a11、a12、a13分别为与变量X1在同一行的因子载荷，F1、F2、F3分别为提取的公因子)。

因子得分矩阵表示**提取的公因子(F)**与**各项指标变量（x）**之间的关系，在某一公因子上得分高，表明该指标与该公因子之间关系越密切。

- (如F1=b11*X1+b12*X2+b13*X3)
- 原始数据在所对应的各个公共因子的得分
- 常用的求因子得分的方法：加权最小二乘法和回归法。

载荷矩阵和得分矩阵的区别

因子得分(factor score)是每个因子在每个样本上的具体取值，由下列因子得分函数给出因子得分，是各变量的线性组合

得分矩阵

$$\begin{cases} f_1 = b_{11}x_1 + b_{12}x_2 + \cdots + b_{1p}x_p \\ f_2 = b_{21}x_1 + b_{22}x_2 + \cdots + b_{2p}x_p \\ \vdots \\ f_k = b_{k1}x_1 + b_{k2}x_2 + \cdots + b_{kp}x_p \end{cases}$$

载荷矩阵

$$\begin{cases} x_1 = a_{11}f_1 + a_{12}f_2 + \cdots + a_{1k}f_k + \varepsilon_1 \\ x_2 = a_{21}f_1 + a_{22}f_2 + \cdots + a_{2k}f_k + \varepsilon_2 \\ \vdots \\ x_p = a_{p1}f_1 + a_{p2}f_2 + \cdots + a_{pk}f_k + \varepsilon_p \end{cases}$$

单个/总因子得分：每个样本

- 利用**单个共因子（fi）得分**，对样本进行评价和排序

$$\begin{cases} f_1 = -0.105x_1 + 0.180x_2 + 0.300x_3 + 0.372x_4 - 0.104x_5 + 0.281x_6 \\ f_2 = 0.430x_1 + 0.171x_2 - 0.026x_3 - 0.237x_4 + 0.429x_5 + 0.022x_6 \end{cases}$$

- 用每个共因子的方差贡献率做权重，对每个因子进行加权，然后加总得到每个样本的**总因子得分**

$$F = \frac{\lambda_1}{\lambda_1 + \lambda_2} f_1 + \frac{\lambda_2}{\lambda_1 + \lambda_2} f_2 \qquad F = 0.691141 f_1 + 0.308859 f_2$$

共性方差与特殊方差

根据因子分析的矩阵形式

$x=Af+\varepsilon$

xi的方差var(xi)由两部分组成，
公共因子f对xi方差的贡献，称为**共性方差**；
特殊因子ε对xi方差的贡献，称为**特殊方差**。
每个原始变量的方差都被分成了共性方差和特殊方差两部分。

Heywood（海伍德）现象

- 如果x的各个分量都已经标准化了，则其方差=1。
  - 即共性方差与特殊方差的和为1。
  - 也就是说共性方差与特殊方差均大于0，并且小于1。

- 但在实际进行参数估计的时候，**共性方差的估计**可能会等于或超过1，
  - 如果等于1，就称之为海伍德现象，
  - 如果超过1，称之为超海伍德现象。超海伍德现象意味着某些特殊因子的方差为负，表明肯定存在问题。

Heywood（海伍德）现象

- **造成超海伍德现象现象的可能原因**包括：
  - 共性方差本身估计的问题；
  - 太多的共性因子，出现了过拟合；
  - 太少的共性因子，造成拟合不足；
  - 数据太少，不能提供稳定的估计；
  - 因子模型不适合这些数据。
- **当出现（超）海伍德现象时**，应对估计结果保持谨慎态度。
  - 可以尝试增加数据量，
  - 或改变公共因子数目，让公共因子数目在一个允许的范围内变动，观察估计结果是否有改观；
  - 还可以尝试用其他多元统计方法进行分析，比如主成分分析。

因子分析的主要步骤

- 数据检验
- 因子提取
- 因子命名
- 因子旋转
- 因子得分

数据检验

因子分析要求样本的个数要足够多

一般要求样本的个数至少是变量的5倍以上。同时，样本总数据量理论要求应该在100以上

用于因子分析的变量必须是相关的

如果原始变量都是独立的，意味着每个变量的作用都是不可替代的，则无法降维

检验方法

计算各变量之间的相关矩阵，观察各相关系数。若相关矩阵中的大部分相关系数小于0.3，则不适合作因子分析

使用Kaiser-Meyer-Olkin检验(简称KMO检验)和 Bartlett球度检验(Bartlett's test of sphericity)来判断(SPSS将两种检验统称为“KMO and Bartlett's test of sphericity”)

数据检验：变量相关性检验

Bartlett球度检验

以变量的相关系数矩阵为基础，假设相关系数矩阵是单位阵(对角线元素不为0，非对角线元素均为0)。

如果相关矩阵是单位阵，则各变量是独立的，无法进行因子分析

KMO检验

用于检验变量间的偏相关性，KMO统计量的取值在0～1之间

如果统计量取值越接近1，变量间的偏相关性越强，因子分析的效果就越好

KMO统计量在0.7以上时，因子分析效果较好；KMO统计量在0.5以下时，因子分析效果很差

因子提取：载荷矩阵的求解方法

Principal components(主成分法)：多数情况下可以使用该方法(SPSS的默认选项)。通过主成分分析的思想提取公因子，它假设变量是因子的线性组合

Unweight Least Square(不加权最小平方法)：该方法使实际的相关矩阵和再生的相关矩阵之差的平方和达到最小

Generalized Least Square(加权最小平方法)：用变量值进行加权，该方法也是使实际的相关矩阵和再生的相关矩阵之差的平方和达到最小

Maximum Likelihood(最大似然法)：该方法不要求数据服从正态分布，在样本量较大时使用较好

Principal Axis Factoring(主轴因子法)：该方法从原始变量的相关性出发，使得变量间的相关程度尽可能地被公因子解释

因子提取:因子数量的确定

- **因子数量**的确定
  - 用公因子方差贡献率提取：与主成分分析类似，一般累计方差贡献率达到80%以上的前几个因子可以作为最后的公因子
  - 用特征根提取：一般要求因子对应的特征根要大于1，因为特征根小于1说明该共因子的解释力度太弱，还不如使用原始变量的解释力度大
- 实际应用中，因子的提取要结合具体问题而定，在某种程度上，取决于研究者自身的知识和经验

因子命名

因子命名是因子分析重要一步

- 一个因子包含了多个原始变量的信息，它究竟反映了原始变量的哪些共同信息?
- 因子分析得到的因子的含义是模糊的，需要重新命名，以便对研究的问题作出合理解释
- 通过考察观察因子载荷矩阵并结合实际问题完成
- 命名已经不是统计问题。它需要研究者自身的专业素质和对实际问题背景的了解程度，这需要更多的实践经验

因子旋转

观察因子载荷矩阵

- 如果因子载荷a_{ij}的绝对值在第i行的多个列上都有较大的取值(通常大于0.5)，表明原始变量与多个因子都有较大的相关关系，意味着原始变量xi需要由多个因子来共同解释
- 如果因子载荷aij的绝对值在第j列的多个行上都有较大的取值，则表因子fi能共同解释许多变量的信息，而对每个原始变量只能解释其中的少部分信息，表明因子不能有效代表任何一个原始变量，因子的含义模糊不清，难以对因子给出一个合理的解释➔需要进行因子旋转，以便得到更加合理的解释

因子旋转

- 因子旋转(factor rotation)的目的是使因子的含义更加清楚，以便于对因子的命名和解释
- 旋转的方法有正交旋转和斜交旋转两种
  - SPSS提供5种旋转方法，其中最常用的是Varimax(方差最大正交旋转)法
  - Matlab也提供多种旋转方法，默认是方差最大正交旋转法

因子旋转：SPSS中的旋转方法

- Varimax(方差最大正交旋转)：最常用的旋转方法。使各因子保持正交状态，但尽量使各因子的方法达到最大，即相对的载荷平方和达到最大，从而方便对因子的解释
- Quartimax(四次方最大正交旋转)：该方法倾向于减少和每个变量有关的因子数，从而简化对原变量的解释
- Equamax(平方最大正交旋转)：该方法介于方差最大正交旋转和四次方最大正交旋转之间
- Direct Oblimin(斜交旋转)：该方法需要事先指定一个因子映像的自相关范围
- Promax：该方法在方差最大正交旋转的基础上进行斜交旋转

因子旋转：Matlab中的旋转方法

‘none’：不进行旋转
‘equamax’：Orthomax旋转的特殊情况
‘orthomax’：最大方差旋转法
‘parsimax’：Orthomax旋转的1个特殊情况（默认）
‘pattern’：执行斜交旋转（默认）或正交旋转
‘procrustes’：执行斜交旋转（默认）或正交旋转
‘promax’：执行一次斜交procrustes旋转
‘quartimax’：Orthomax旋转的一个特殊情况
‘Varimax’：Orthomax旋转的以特殊情况

因子分析的MATLAB 实现方法

No	方法	主要命令	含义
第1种	正交变换法（随机变量分布没有要求）	PCA	求得特征向量构成的正交矩阵E，得到主成分载荷矩阵A， A经过正交旋转后获得正交因子解
第2种	最大似然法（随机变量服从正态分布）	factoran	基于原始数据或其协方差矩阵，进行最大似然公因子分析
		rotatefactors	按照某种标准（方差极大、四次方最大、平均最大、最大节约）对主成分或因子载荷的旋转
		rotatefun	定义一种因子载荷矩阵的旋转方法

求解方式对比

M文件	含义	主要语句	因子个数
FA_01_PCA.m	通过PCA求因子分析解	[E,score,eigv,T]=pca(X); C=sqrtm(lambda); A=E*C;	未知
FA_02_2F.m	从原始数据矩阵出发，factoran求最大似然解	[Lambda,Psi,T,Stats,F]= factoran(X,2,'Score','wls');	2
FA_02_3F.m		[Lambda,Psi,T,Stats,F]= factoran(X,3,'Score','wls');	3
FA_03_COV.m	从协方差矩阵出发，用factoran求最大似然解	[Lambda,Psi,T,Stats]= factoran(cov(X),2,'Xtype','cov');	2

factoran函数的调用格式

格式	用途
lambda= factoran（X，m）	返回包含m个公共因子模型的载荷矩阵lambda。输入参数X是n行d列的矩阵，每行对应一个观测，每列对应一个变量。m是一个正整数，表示模型中公共因子的个数。输出参数lambda是一个d行m列的矩阵，第i行第j列元素表示第i个变量在第j个公共因子上的载荷。
[lambda,psi]= factoran（X,m）	返回特定方差的最大似然估计psi，psi是包含d个元素的列向量，分别对应d个特定方差的最大似然估计。
[lambda，psi，T]= factoran（X，m）	返回m行m列的载荷旋转矩阵T

factoran函数的调用格式

[lambda,psi,T,stats]=factoran（X,m）	返回一个包含模型检验信息的结构体变量stats，模型检验的原假设是H0：因子数=m。输出参数stats包括4个字段，其中stats.loglike表示对数似然的最大值，stats.def表示误差自由度，stats,chisq表示近似卡方检验统计量，stats.p表示检验的p值。对于给定的显著性水平a，若检验的p值大于显著性水平a，则接受原假设H0，说明用含有m个公共因子的模型拟合原始数据是合适的，否则，拒绝原假设，说明拟合是不合适的。
[lambda,psi,stats,F]=factoran（X,m）	返回因子得分矩阵F。F是一个n行m列的矩阵，每一行对应一个观测的m个公共因子的得分。如果X是一个协方差矩阵或相关系数矩阵，则factoran函数不能计算因子得分。factoran函数用相同的旋转矩阵计算载荷阵lambda和因子得分F。
[.....]=factoran(.....,param1,val1,param2,val2,.....)	允许用户指定可选的成对出现的参数名和参数值，用来控制模型的拟合和输出，可用的参数名与参数值详见factoran的帮助。

4. 案例分析

2. 中国省区市发展的因子分析案例

- ✓利用8项经济指标对2004年中国部分省市区进行因子分析（m=8,n=31）。
- ✓8项指标可以分为两大类：
  - 一是反映生产情况即投入和产出方面的指标，包括全社会固定资产投资额，GDP和工业增加值
  - 二是反映居民生活方面的指标，包括职工平均工资，城镇居民消费性支出、农村居民消费性支出以及两个价格指数（居民消费价格指数、商品零售价格指数）

表 5-1-2　中国 31 个省、区、市的 8 项经济指标（2004 年）

地区	GDP/亿元	工业增加值/亿元	全社会固定资产投资/亿元	职工平均工资/元	城镇居民消费性支出/元	农村居民消费性支出/元	居民消费价格指数（2003 年为 100）	商品零售价格指数（2003 年为 100）
北京	4 283.31	1 259.5	2 528.21	29 674	12 200.40	4 616.94	100.95	99.25
天津	2 931.88	1 395.6	1 245.66	21 754	8 802.44	2 642.11	102.25	100.83
河北	8 768.79	2 459.2	3 218.76	12 925	5 819.18	1 834.92	104.25	103.17
山西	3 042.41	1 242.8	1 443.88	12 943	5 654.15	1 636.46	104.14	103.06
内蒙古	2 712.08	776.8	1 787.95	13 324	6 219.26	2 082.57	102.94	102.70
辽宁	6 872.65	2 255.7	2 979.59	14 921	6 543.28	2 072.95	103.46	101.88
吉林	2 958.21	994.3	1 169.10	12 431	6 068.99	1 971.21	104.09	103.51
黑龙江	5 303.00	1 619.6	1 430.82	12 557	5 567.53	1 837.37	103.84	102.83
上海	7 450.27	3 427.0	3 050.26	30 085	12 631.03	6 328.85	102.15	100.91
江苏	15 403.16	6 447.5	6 557.05	18 202	7 332.26	2 992.55	104.06	102.25
浙江	11 243.00	4 173.4	5 781.35	23 506	10 636.14	4 659.11	103.86	102.68
安徽	4 812.68	1 082.2	1 935.25	12 928	5 711.33	1 813.71	104.50	102.75
福建	6 053.14	1 845.8	1 892.92	15 603	8 161.15	3 015.58	104.05	102.73
江西	3 495.94	617.8	1 713.20	11 860	5 337.84	2 095.48	103.52	102.99
山东	15 490.73	6 498.3	6 970.62	14 332	6 673.75	2 389.27	103.64	102.85

续表

地区	GDP/亿元	工业增加值/亿元	全社会固定资产投资/亿元	职工平均工资/元	城镇居民消费性支出/元	农村居民消费性支出/元	居民消费价格指数（2003 年为 100）	商品零售价格指数（2003 年为 100）
河南	8 815.09	2 332.7	3 099.38	12 114	5 294.19	1 664.09	105.40	105.66
湖北	6 309.92	1 664.7	2 264.81	11 855	6 398.52	2 088.98	104.92	104.10
湖南	5 612.26	1 198.1	2 072.56	13 928	6 884.61	2 472.29	105.07	103.93
广东	16 039.46	7 086.4	5 870.02	22 116	10 694.79	3 240.78	102.97	102.92
广西	3 320.10	595.6	1 236.51	13 579	6 445.73	1 928.60	104.39	103.93
海南	769.36	102.7	317.05	12 652	5 802.40	1 745.35	104.41	103.37
重庆	2 665.39	579.7	1 537.05	14 357	7 973.05	1 853.94	103.67	101.37
四川	6 556.01	1 546.5	2 818.42	14 063	6 371.14	2 015.72	104.89	103.75
贵州	1 591.90	438.4	865.23	12 431	5 494.45	1 296.34	103.98	103.19
云南	2 959.48	881.2	1 291.54	14 581	6 837.01	1 571.04	106.02	104.73
西藏	211.54	14.4	162.36	30 873	8 338.21	1 470.70	102.68	100.69
陕西	2 883.51	870.7	1 508.89	13 024	6 233.07	1 618.05	103.05	102.48
甘肃	1 558.93	505.1	733.94	13 623	5 937.30	1 464.34	102.33	102.07
青海	465.73	132.4	289.18	17 229	5 758.95	1 676.44	103.15	102.56
宁夏	460.35	147.0	376.20	14 620	5 821.38	1 926.82	103.69	102.82
新疆	2 200.15	616.9	1 147.15	14 484	5 773.62	1 689.91	102.71	100.75

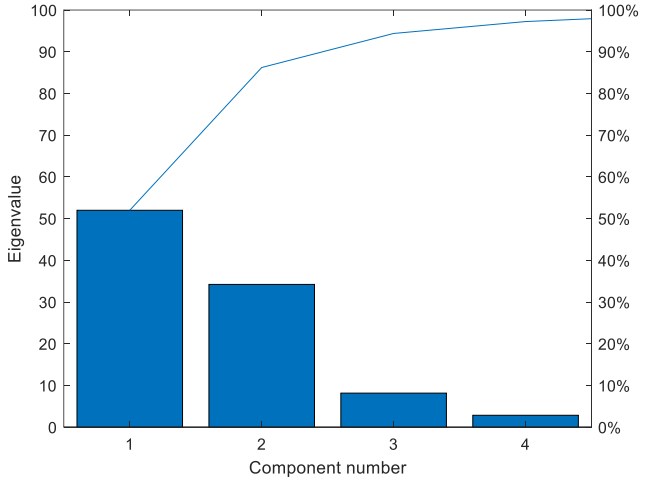
资料来源：《中国统计年鉴——2005》，见 http://www.stats.gov.cn/tjsj/ndsj/2005/indexch.htm。

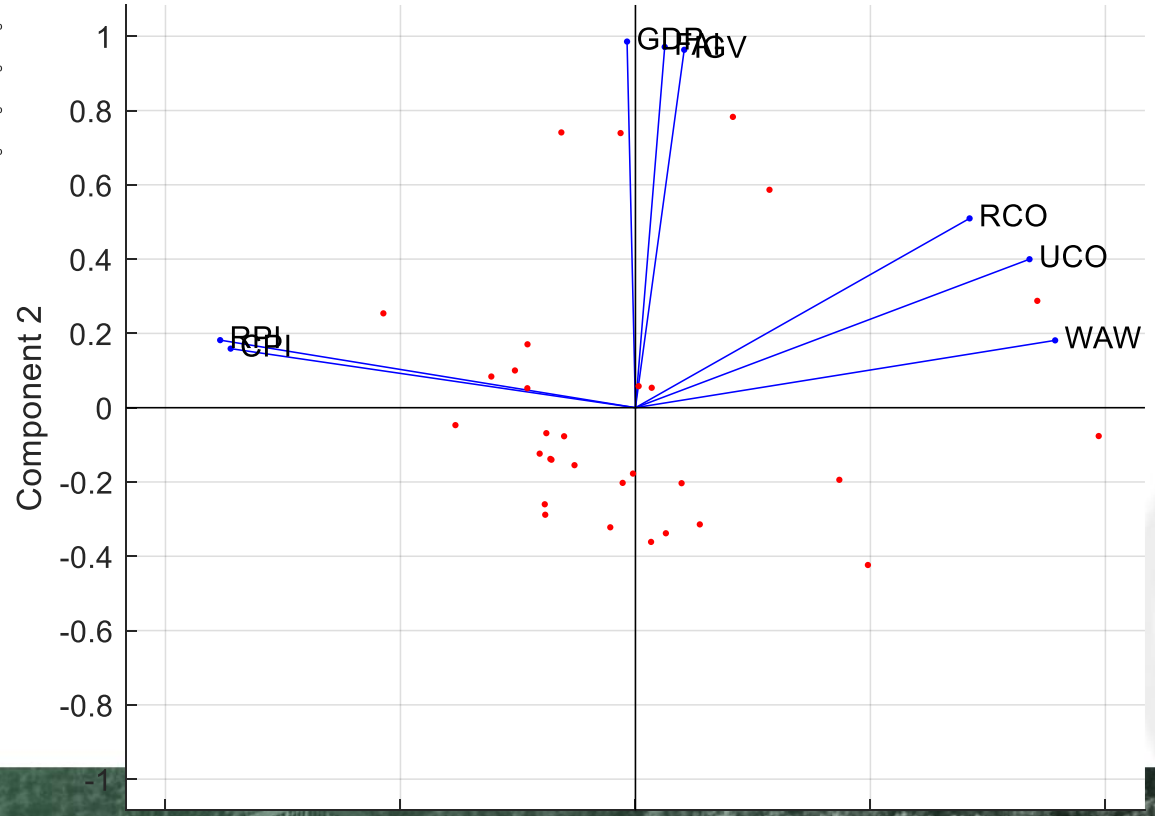
中国省区市发展的数据文件

所有数据（城市名/样本名、变量名和八个指标）存储在 Regions2004.m

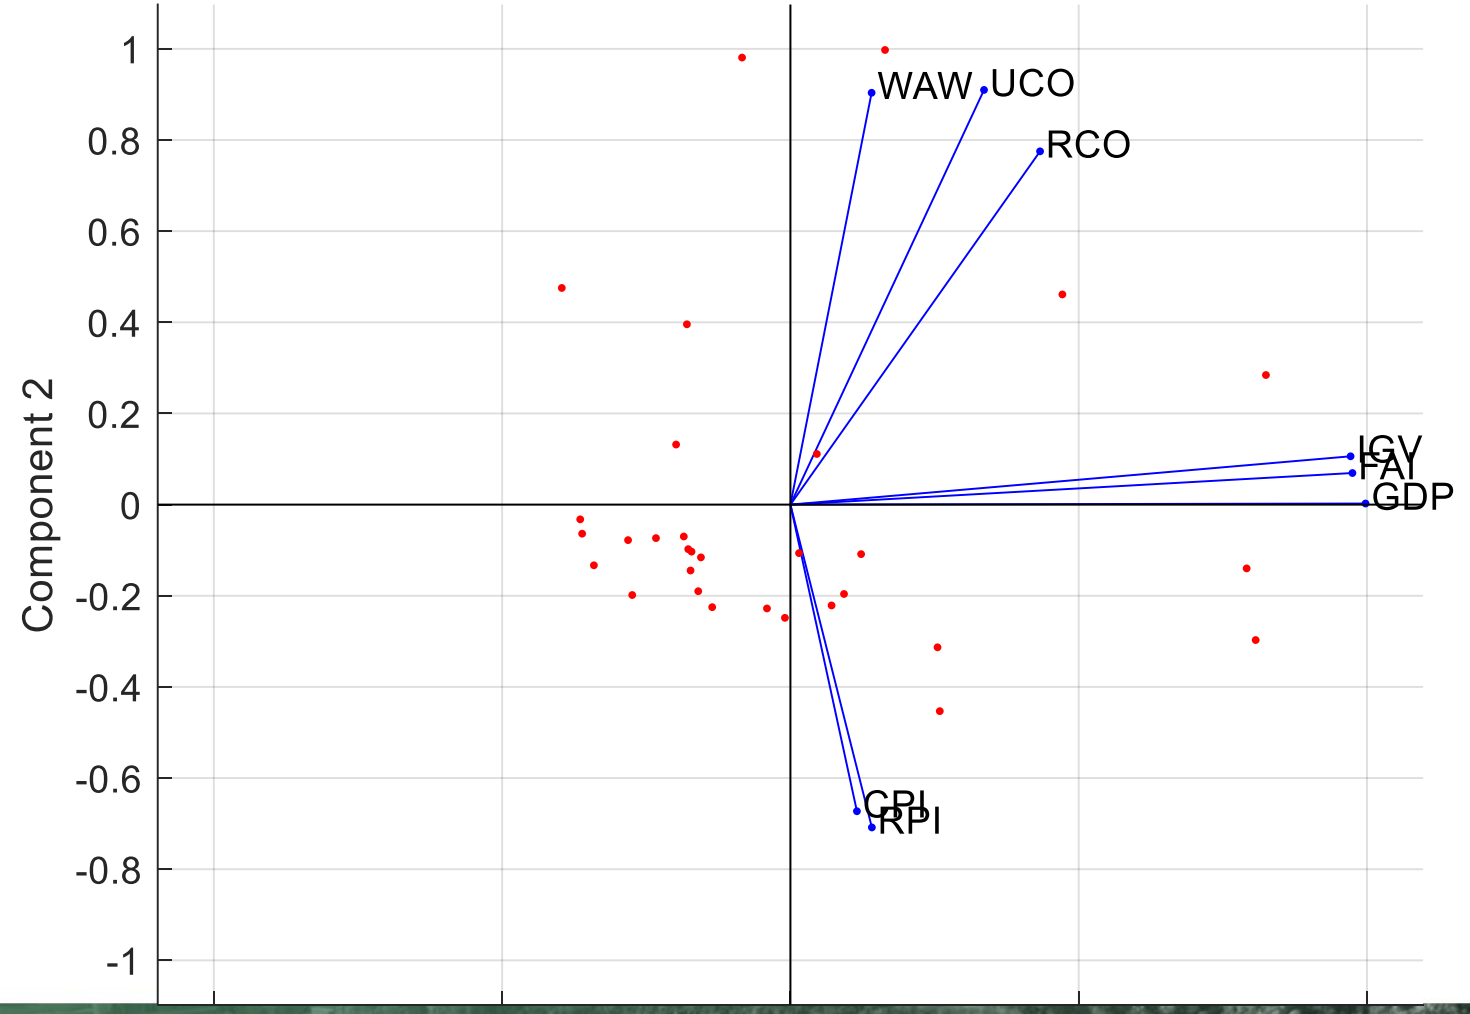
```
%regions2004.m
casename=['BJS';'TJS';'HBS';'SXJ';'NMG';'LNS';'JLS';'HLJ';'SHS';'JSS';'ZJS';'AHS';'FJS';'JXS
varname=['GDP';'IGV';'FAI';'WAW';'UCO';'RCO';'CPI';'RPI'];
data=[4283.31   1259.5  2528.21    29674   12200.40    4616.94     100.95  99.25
2931.88     1395.6  1245.66     21754   8802.44     2642.11     102.25  100.83
8768.79     2459.2  3218.76     12925   5819.18     1834.92     104.25  103.17
3042.41     1242.8  1443.88     12943   5654.15     1636.46     104.14  103.06
2712.08     776.8   1787.95     13324   6219.26     2082.57     102.94  102.70
6872.65     2255.7  2979.59     14921   6543.28     2072.95     103.46  101.88
2958.21     994.3   1169.10     12431   6068.99     1971.21     104.09  103.51
5303.00     1619.6  1430.82     12557   5567.53     1837.37     103.84  102.83
7450.27     3427.0  3050.26     30085   12631.03    6328.85     102.15  100.91
```

分析结果对比 – PCA法求解

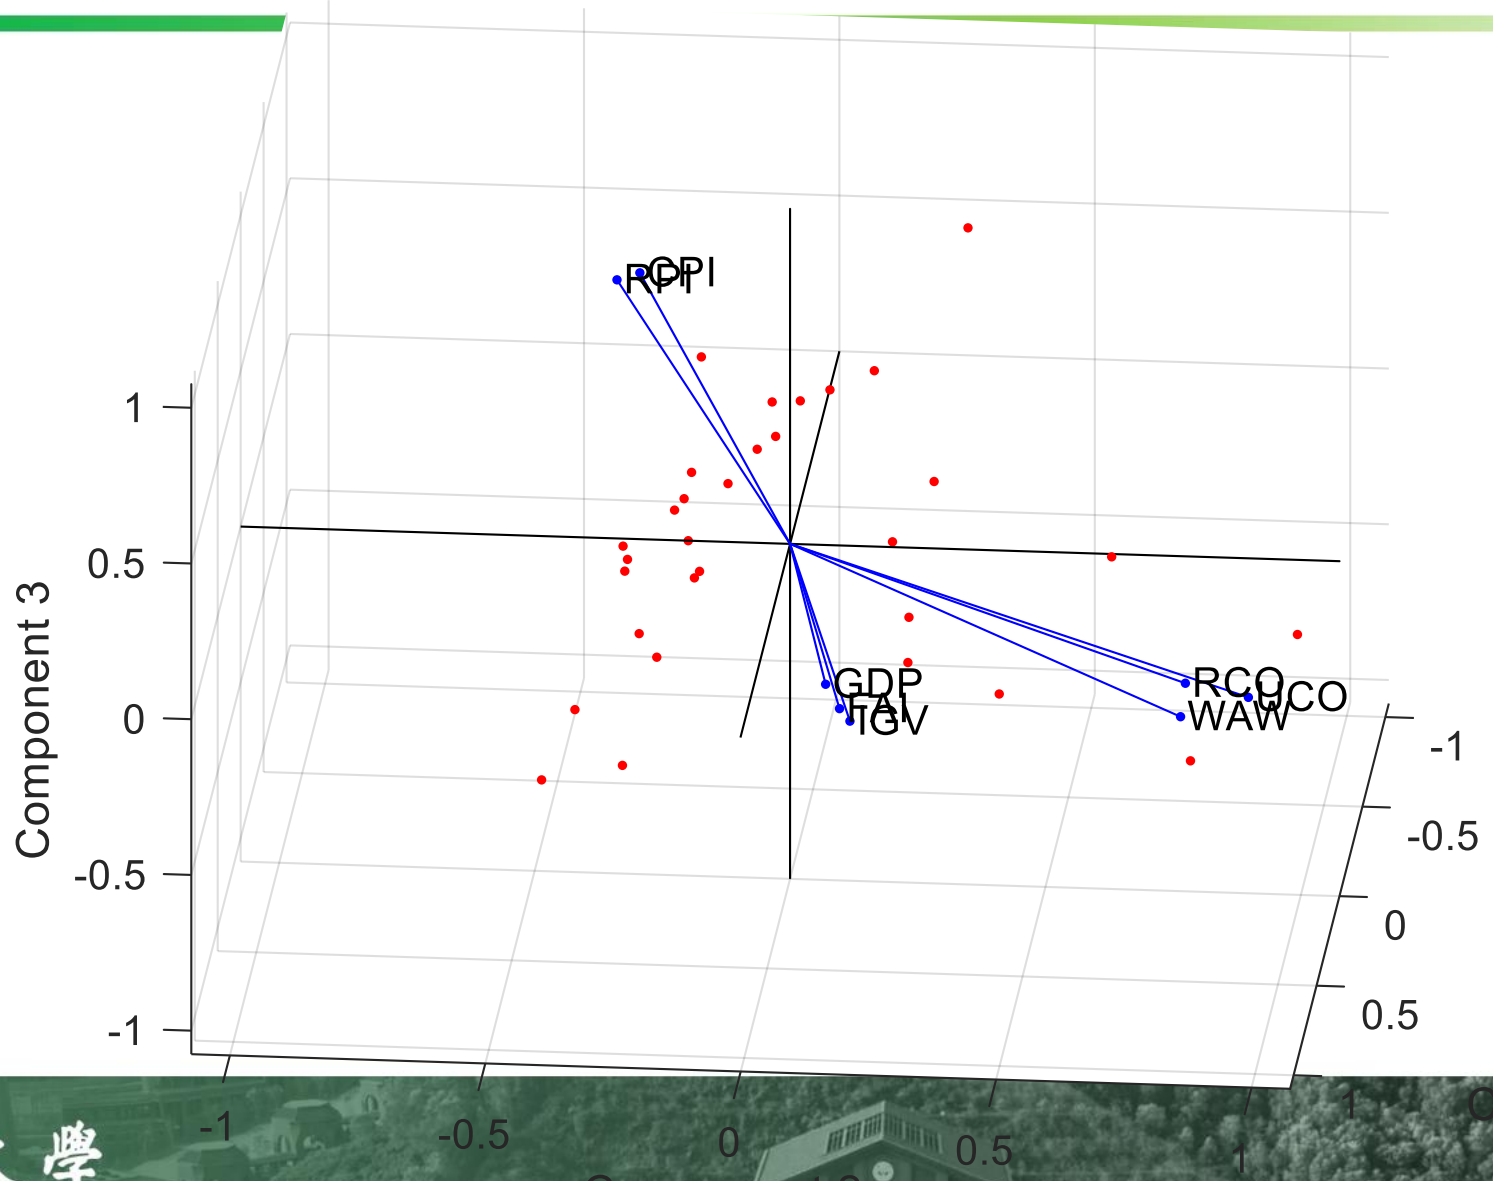




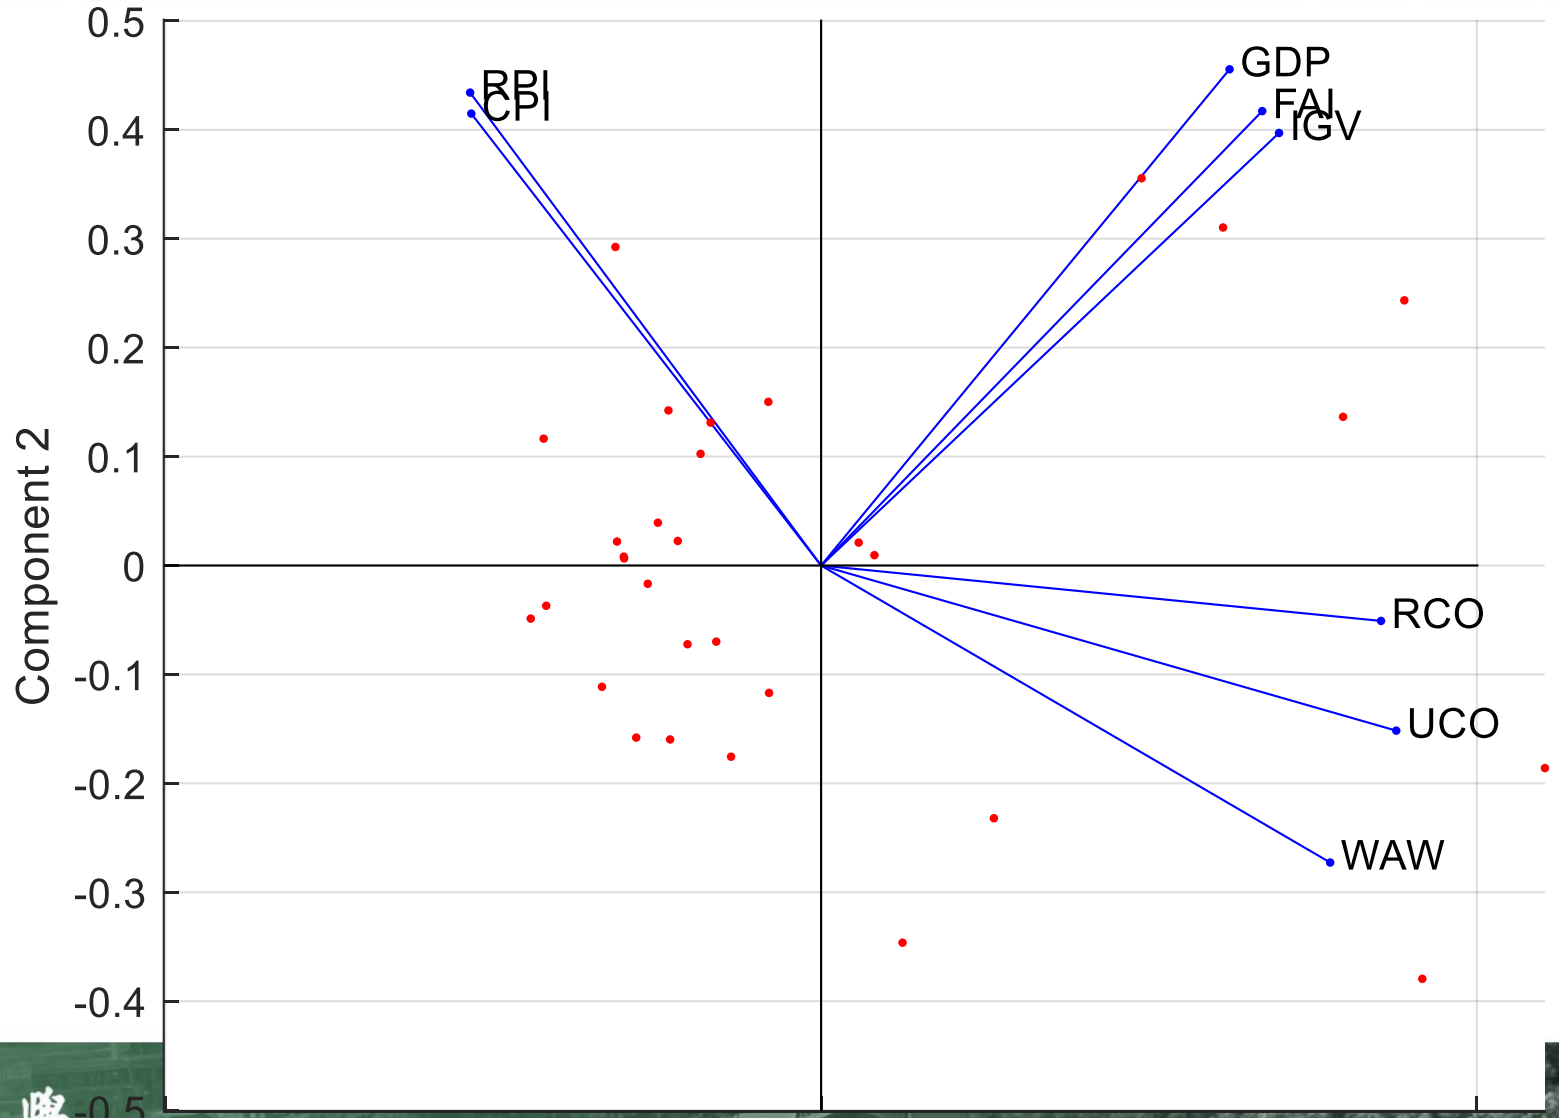
factoran求最大似然解 – 2因子



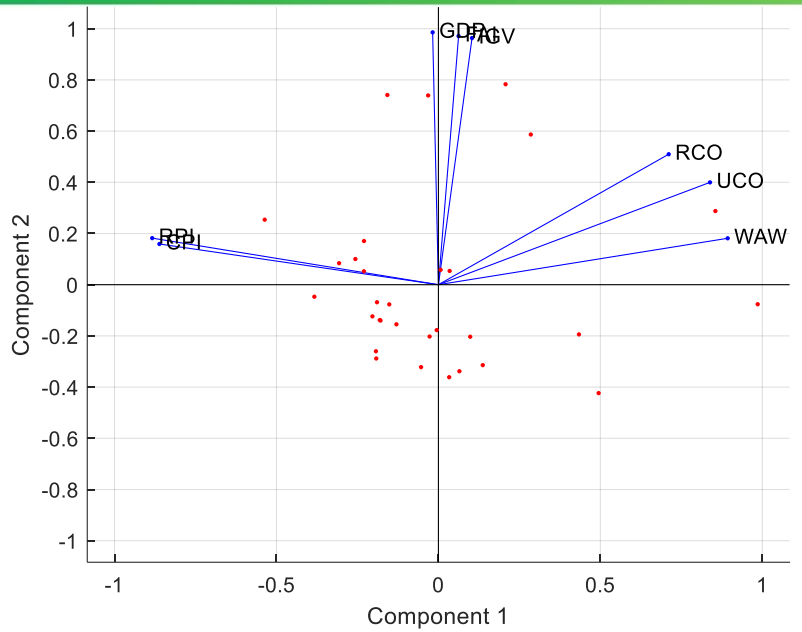
factoran求最大似然解 – 3因子

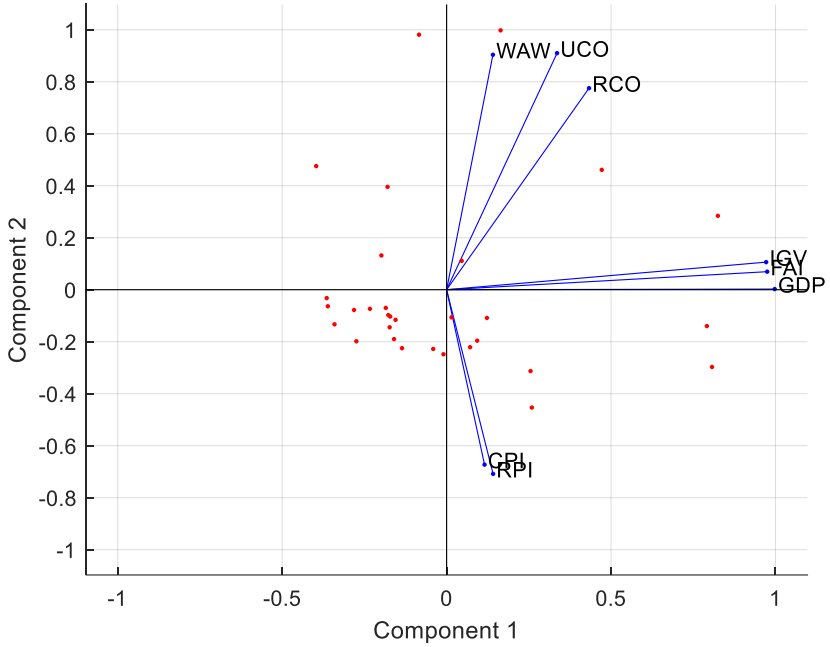


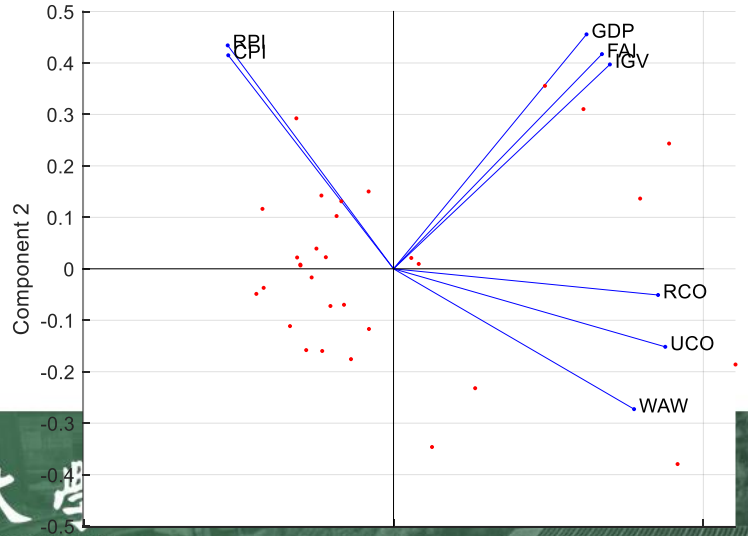
factoran求最大似然解(COV) – 2因子



因子载荷与得分双重散点图的比较







7. 小结

因子分析和主成分分析的公式对比

主成分y和原始变量x之间的关系

综合

$$\begin{cases} y_1 = a_{11}x_1 + a_{12}x_2 + \cdots + a_{1p}x_p \\ y_2 = a_{21}x_1 + a_{22}x_2 + \cdots + a_{2p}x_p \\ \vdots \\ y_p = a_{p1}x_1 + a_{p2}x_2 + \cdots + a_{pp}x_p \end{cases}$$

a_{ij}为第i个主成分y_i和原来的第j个变量x_j之间的线性相关系数，称为载荷(loading)。

原始变量x和因子f之间的关系

分解

$$\begin{cases} x_1 = a_{11}f_1 + a_{12}f_2 + \cdots + a_{1k}f_k + \varepsilon_1 \\ x_2 = a_{21}f_1 + a_{22}f_2 + \cdots + a_{2k}f_k + \varepsilon_2 \\ \vdots \\ x_p = a_{p1}f_1 + a_{p2}f_2 + \cdots + a_{pk}f_k + \varepsilon_p \end{cases}$$

a_{ij}为第个i变量与第k个因子之间的线性相关系数，反映变量与因子之间的相关程度，也称为载荷(loading)。ε为特殊因子(公因子以外的因素影响)

PCA 和FA的比较

	主成份	因子分析
	数据在每个主成份上的方差尽可能大（样本分的最开的投影轴）	找到与原始变量最线性相关的公共因子
	通过综合指标解释样本之间的离散程度	通过公共因子解释原始变量间的相关性
	主成份为原始变量的线性组合，不考虑其他外在变量	原始变量为因子的线性组合，考虑特殊因子
	估计是唯一的	结果不唯一，可以通过因子旋转寻找最容易解释的公共因子
	后果的指标	前因的要素

PCA 的MATLAB 实现：单命令

命令	含义
PCA	求出主成分
pareto	可以得到特征值的百分比和累计百分比（主成分的排序关系和解释能力）
gname	可以得到载荷图上的变量标识 (主成分和原变量关系图) 主成分得分图上的样品标签 (主成分和样本的关系图，即样本在主成份空间散点图)
pcacov	求特征值、特征向量、方差贡献百分比
pcares	给定主成分数量下的残差分析
battest	Bartlett检验（一种卡方检验）

因子分析的MATLAB 实现方法

No	方法	主要命令	含义
第1种	正交变换法（随机变量分布没有要求）	PCA	求得特征向量构成的正交矩阵E，得到主成分载荷矩阵A， A经过正交旋转后获得正交因子解
第2种	最大似然法（随机变量服从正态分布）	factoran	基于原始数据或其协方差矩阵，进行最大似然公因子分析
		rotatefactors	按照某种标准（方差极大、四次方最大、平均最大、最大节约）对主成分或因子载荷的旋转
		rotatefun	定义一种因子载荷矩阵的旋转方法

小结

- **适用条件**：主成分分析和因子分析都是多元分析中处理降维的两种统计方法。只有当原始数据中的变量之间具有较强的相关关系时，降维的效果才会明显，否则不适合进行主成分和因子分析
- **选择标准**：主成分和因子的选择标准应结合具体问题而定。在某种程度上取决于研究者的知识和经验，而不是方法本身
- **结果解释**：即使得到了满意的主成分或因子，在运用它们对实际问题进行评价、排序等分析时，仍然要保持谨慎，因为主成分和因子毕竟是高度抽象的量➔含义不一定比原始变量清晰
- **相互关系**：因子分析可以看作是主成分分析的推广和扩展，而主成分分析则可以看作是因子分析的一个特例。
- **实际使用**：
- 1）自变量与因变量相关性调成一致
- 2）代码和统计软件（如SPSS）同时使用，相互验证。

思考题

- 主成分分析和因子分析的异同点
- 主成分分析和因子分析是否能和其他方法连用?
- 什么情况下使用因子分析和主成分分析?

推荐的慕课

- 多元统计分析 （厦门大学）
- https://www.icourse163.org/learn/XMU-1206305809

- 多元统计分析 （上海财经大学）
- https://www.icourse163.org/course/SHUFE-1003381022