人工智能与地理数据挖掘

第六讲 线性模型

孙伟 sunwei29@mail.sysu.edu.cn

地理科学与规划学院

中山大學 SUN YAT-SEN UNIVERSITY

数据挖掘/机器学习的典型方法

类别	聚类/降维	回归	分类	生成
线性方法	相关性 主成分分析 因子分析	多元线性回归	Logistic回归 判别分析	
最近邻	k均值聚类	kNN		
树型	层次聚类	决策树： 回归树	决策树： 分类树	深度 森林
密度	DBSCAN			
神经网络	SOM	ANN		
核函数		SVM（SVR）	SVM（SVC）	
图论	谱聚类	概率图模型	概率图模型	GNN
随机变量	高斯混合		贝叶斯分类	GAN
模糊数	模糊C 均值聚类	模糊逻辑模型 ANFIS	模糊逻辑模型	FDNN
深度学习	自动编码器	CNN，LSTM、Transformer		

目录

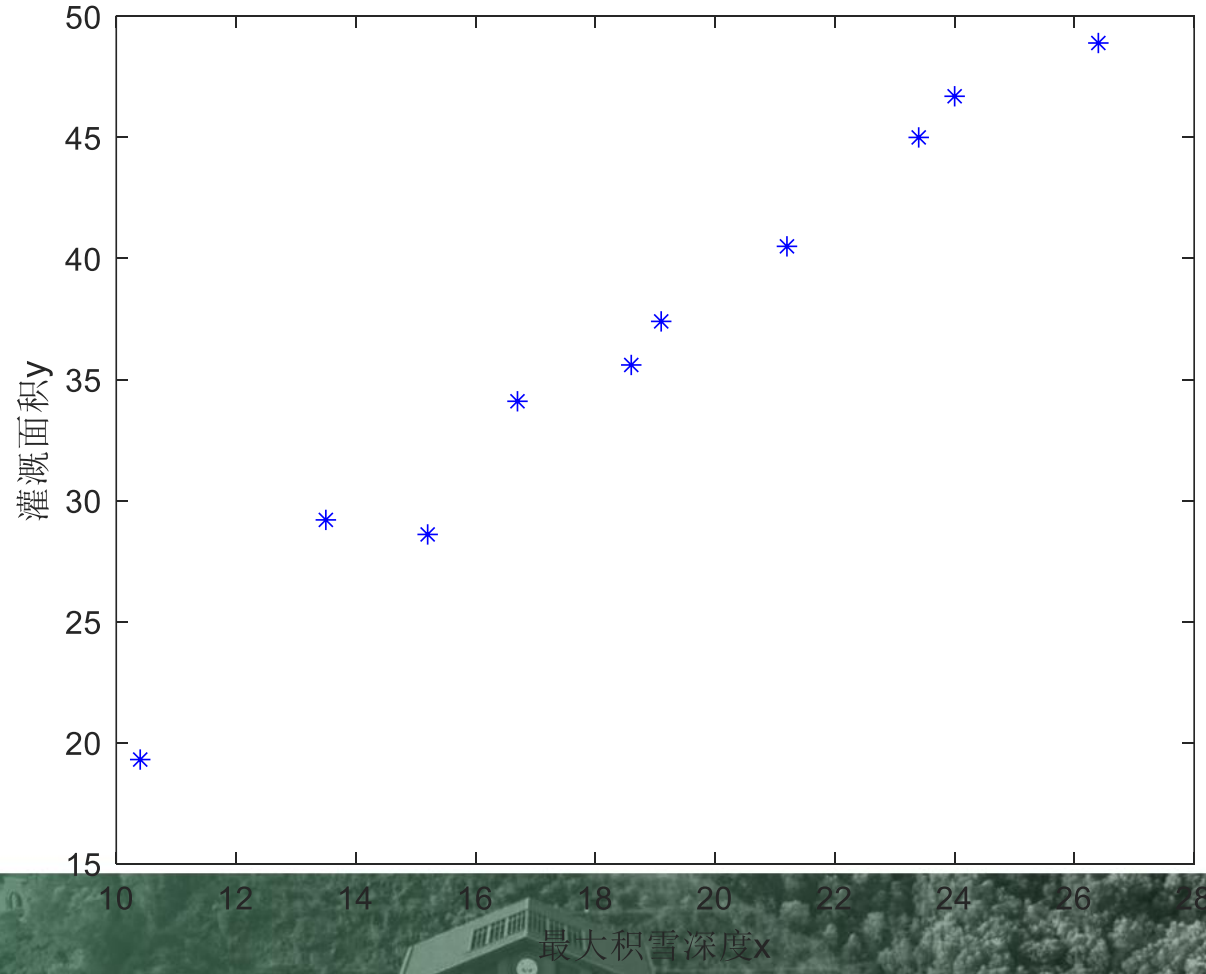
1. 线性模型概述
2. 一元线性回归
3. 多元线性回归
4. 非线性回归
5. 二元分类及其多元推广
6. 判别分析
7. 评估标准
8. 案例研究
9. 小结



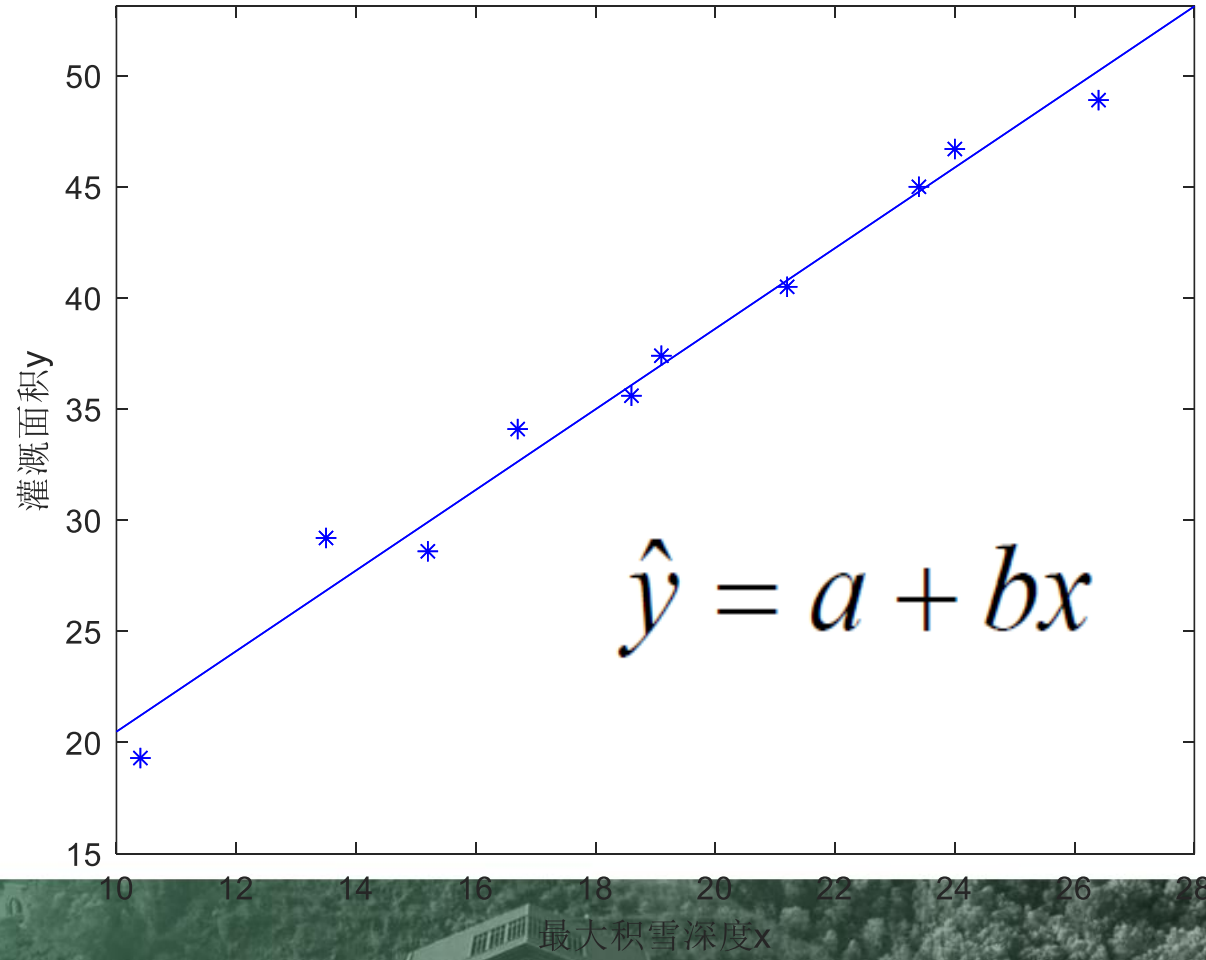


1. 线性模型概述

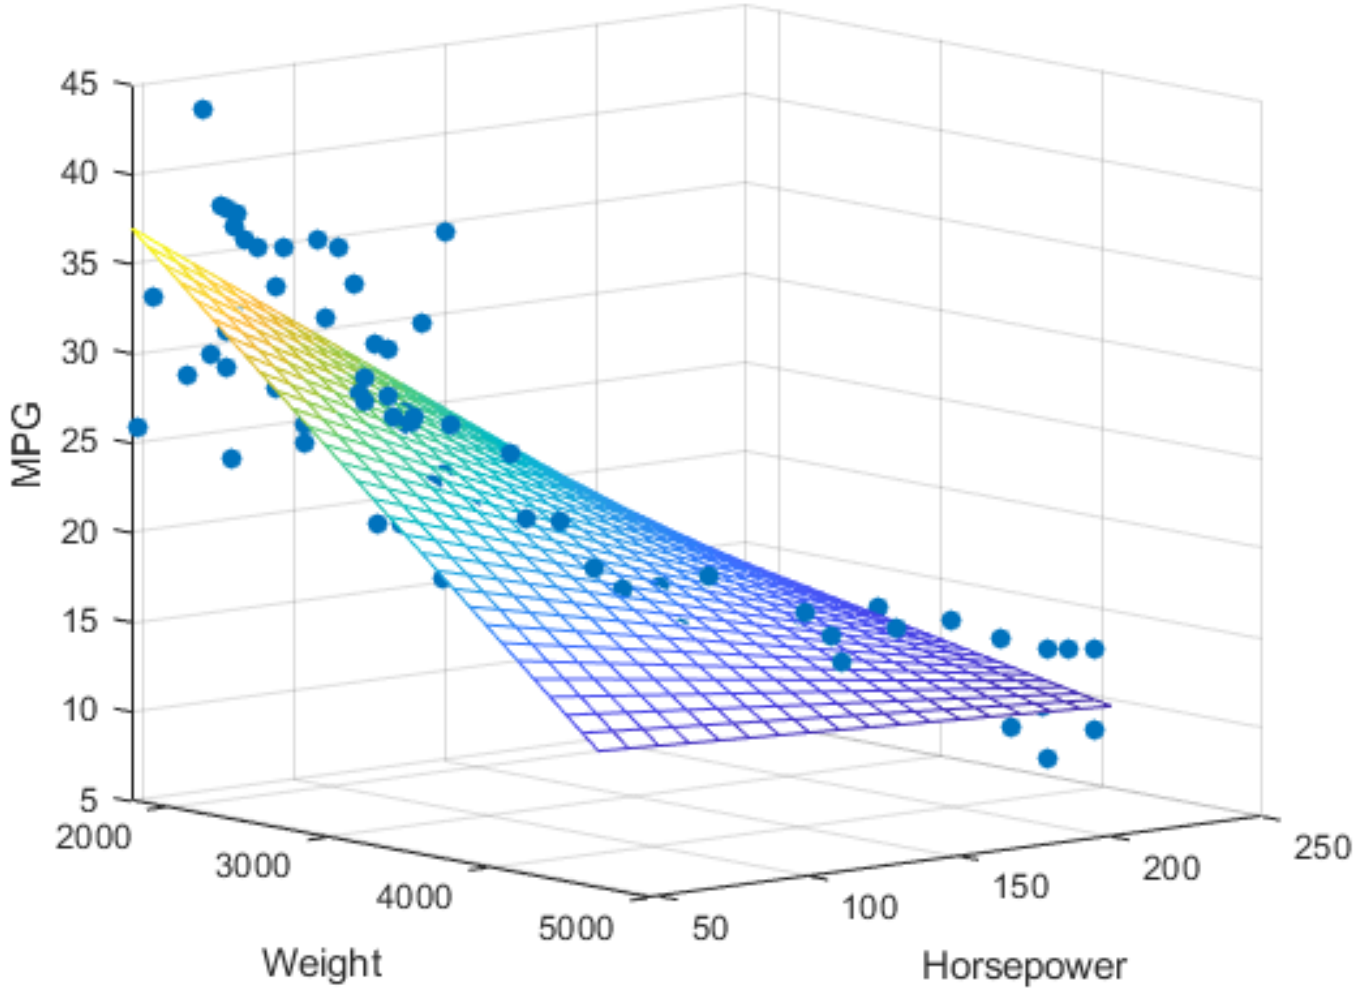
例子：自变量/因变量



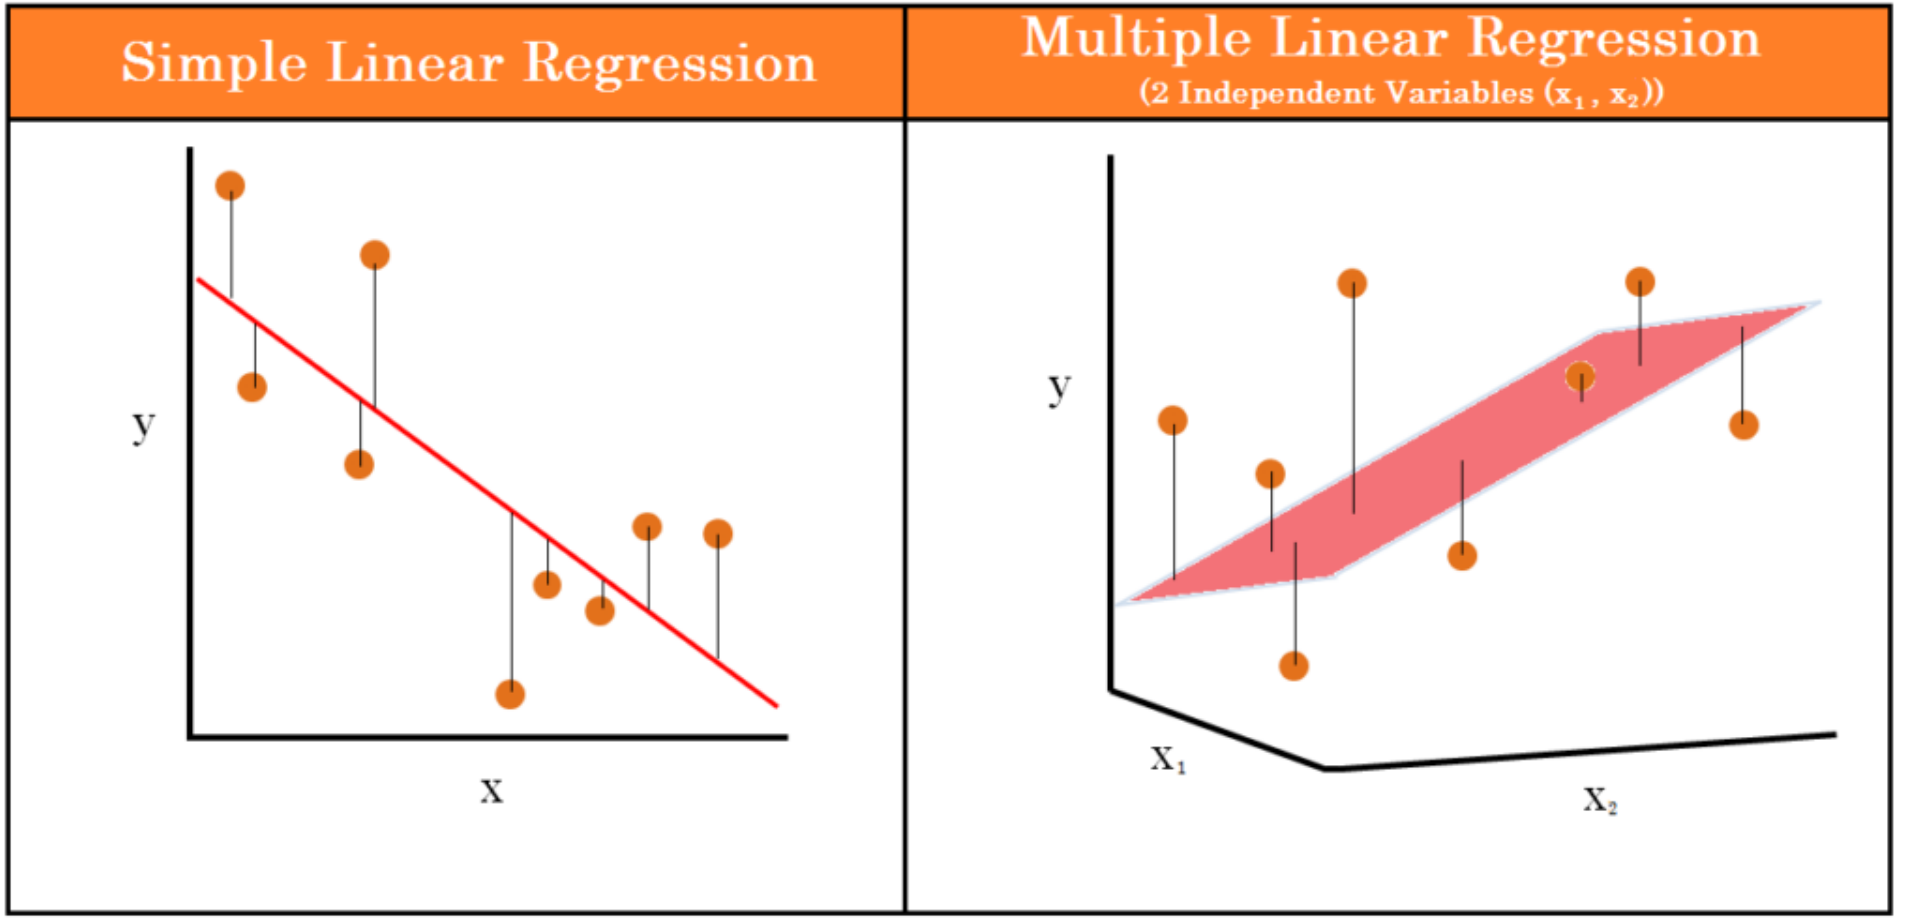
例子：一元回归关系


灌溉面积y
50
45
40
35
30
25
20
15
10
12
14
16
18
20
22
24
26
28
最大积雪深度x
$\hat{y} = a + bx$

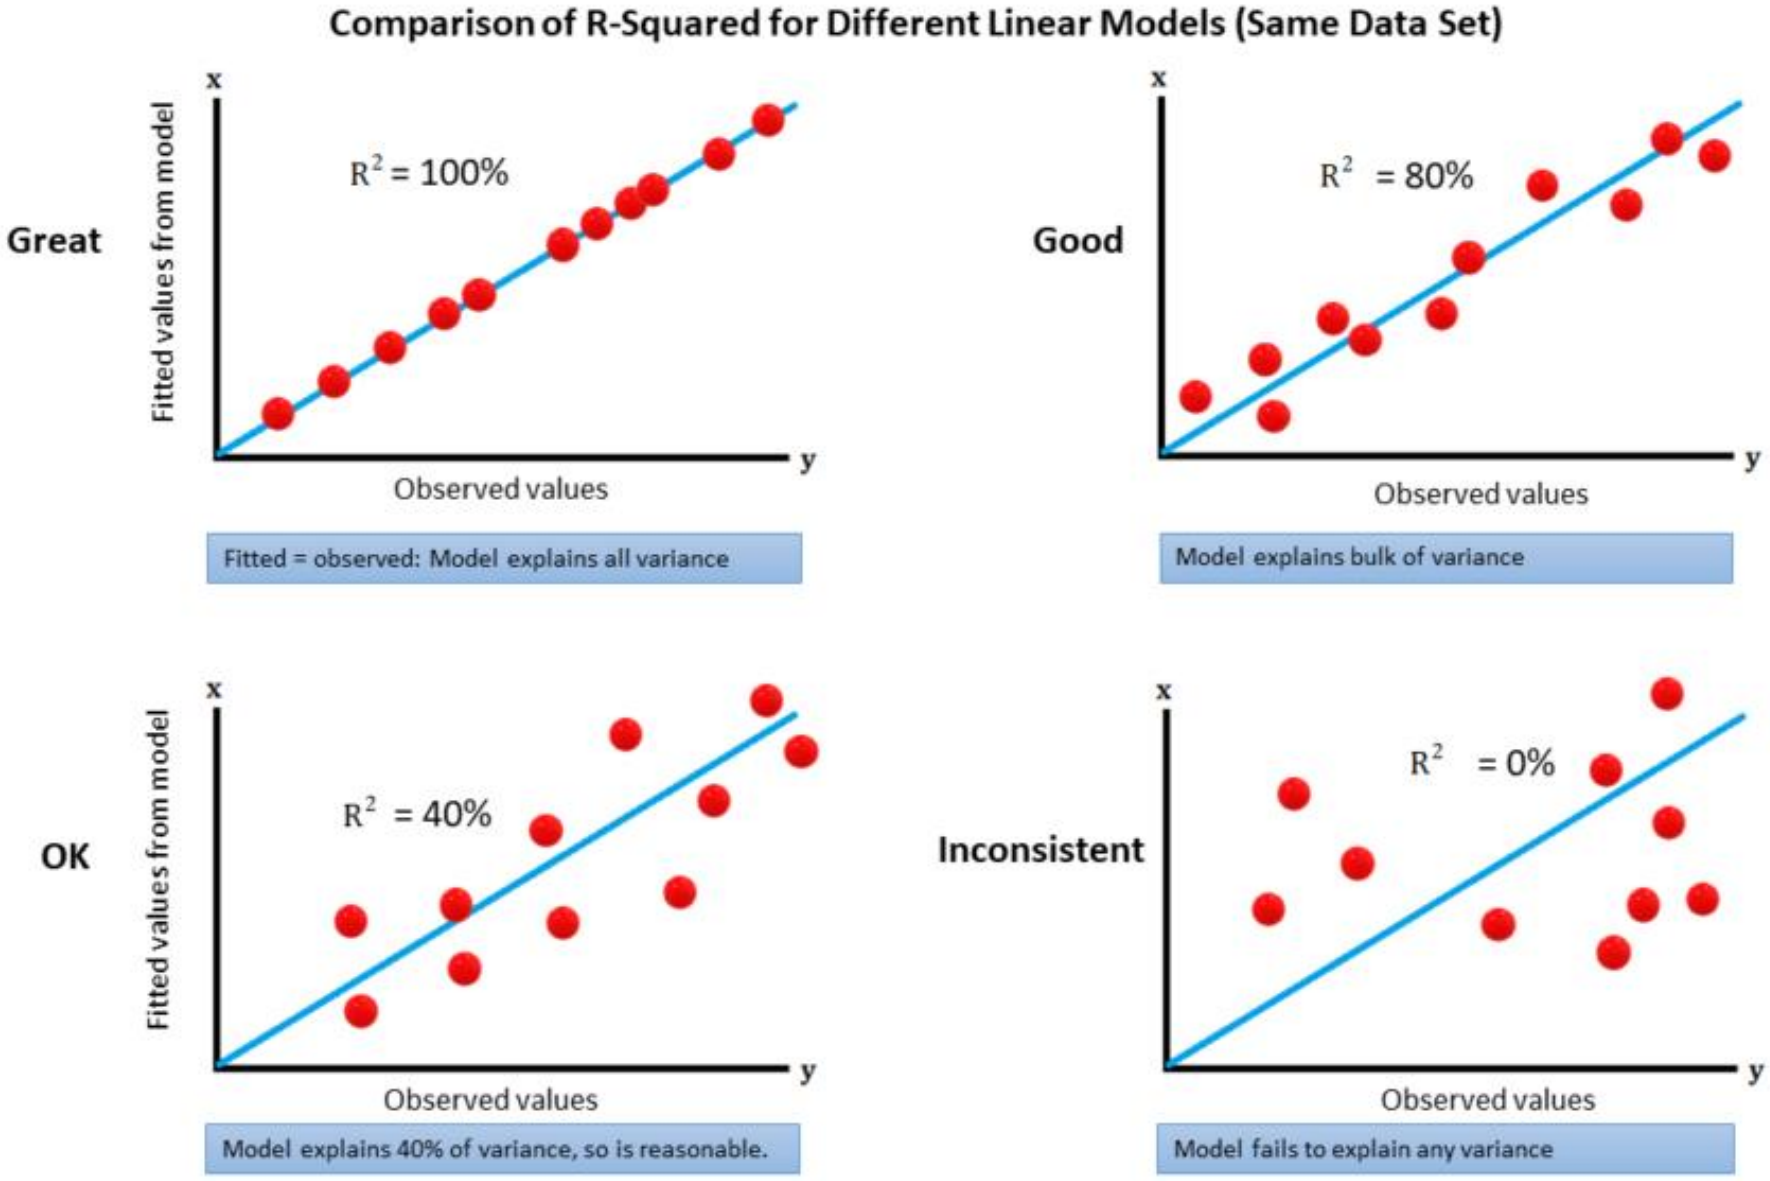
例子：二元回归关系


MPG
45
40
35
30
25
20
15
10
5
2000
3000
4000
5000
Weight
50
100
150
200
250
Horsepower

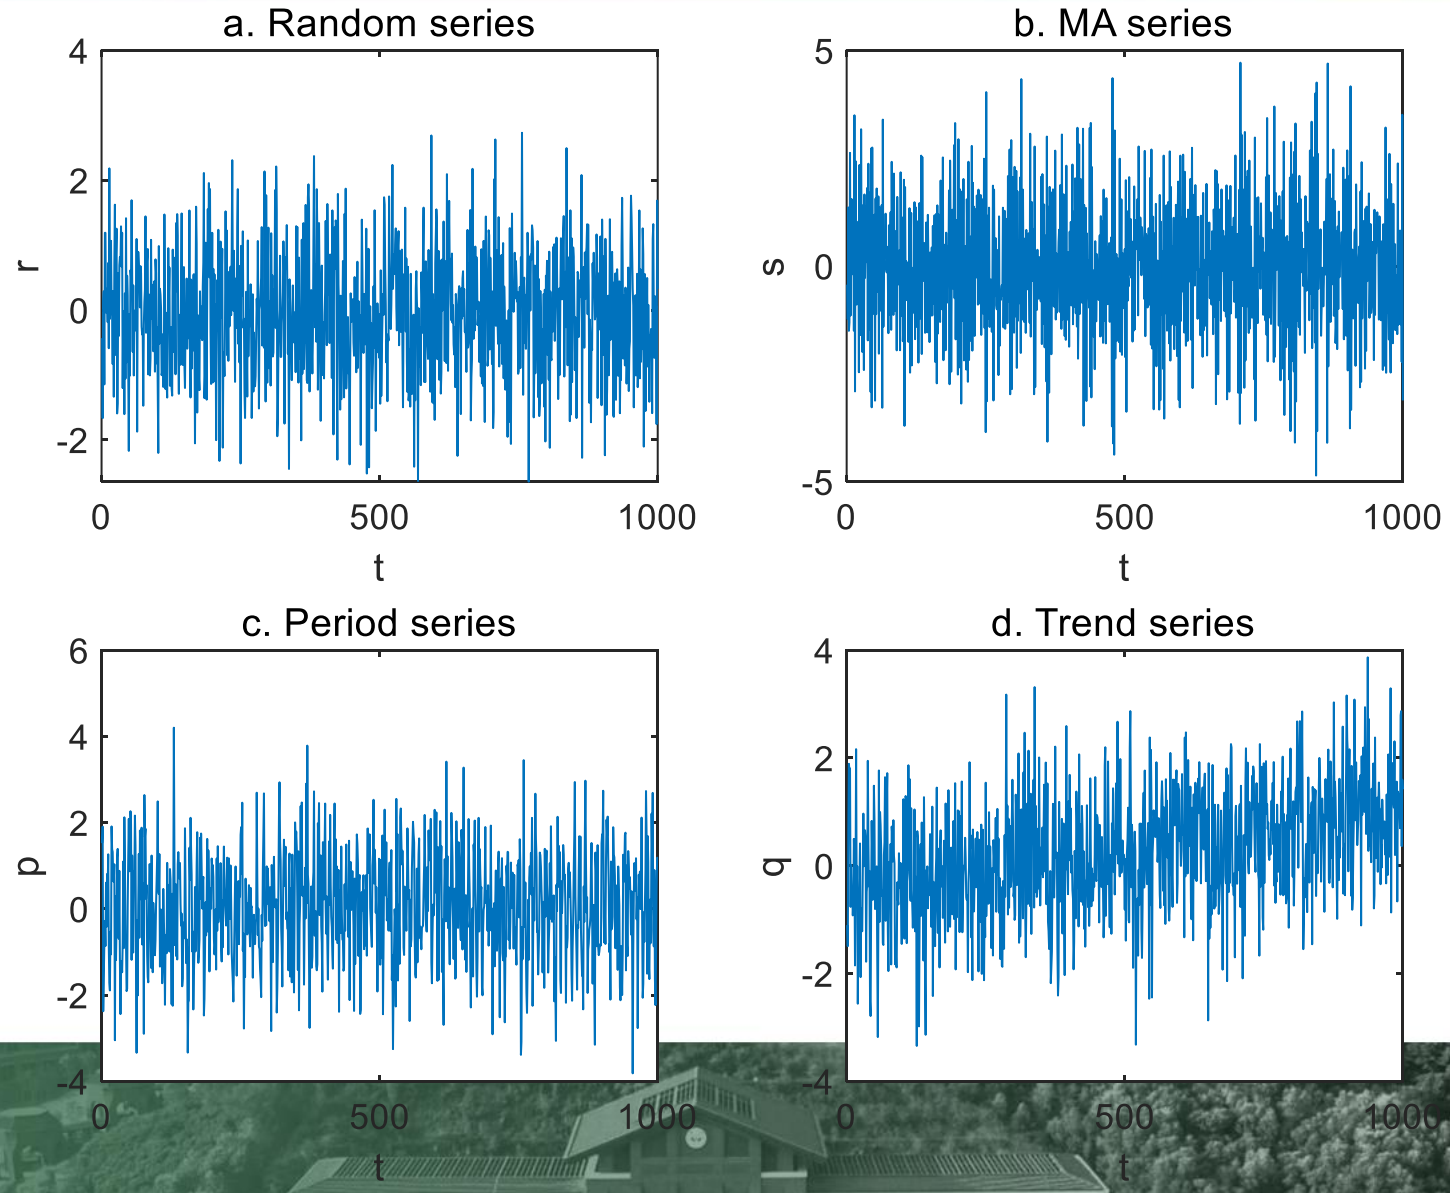
例子：回归的残差


Simple Linear Regression
y
x
Multiple Linear Regression
(2 Independent Variables (x_1, x_2))
y
X_1
X_2

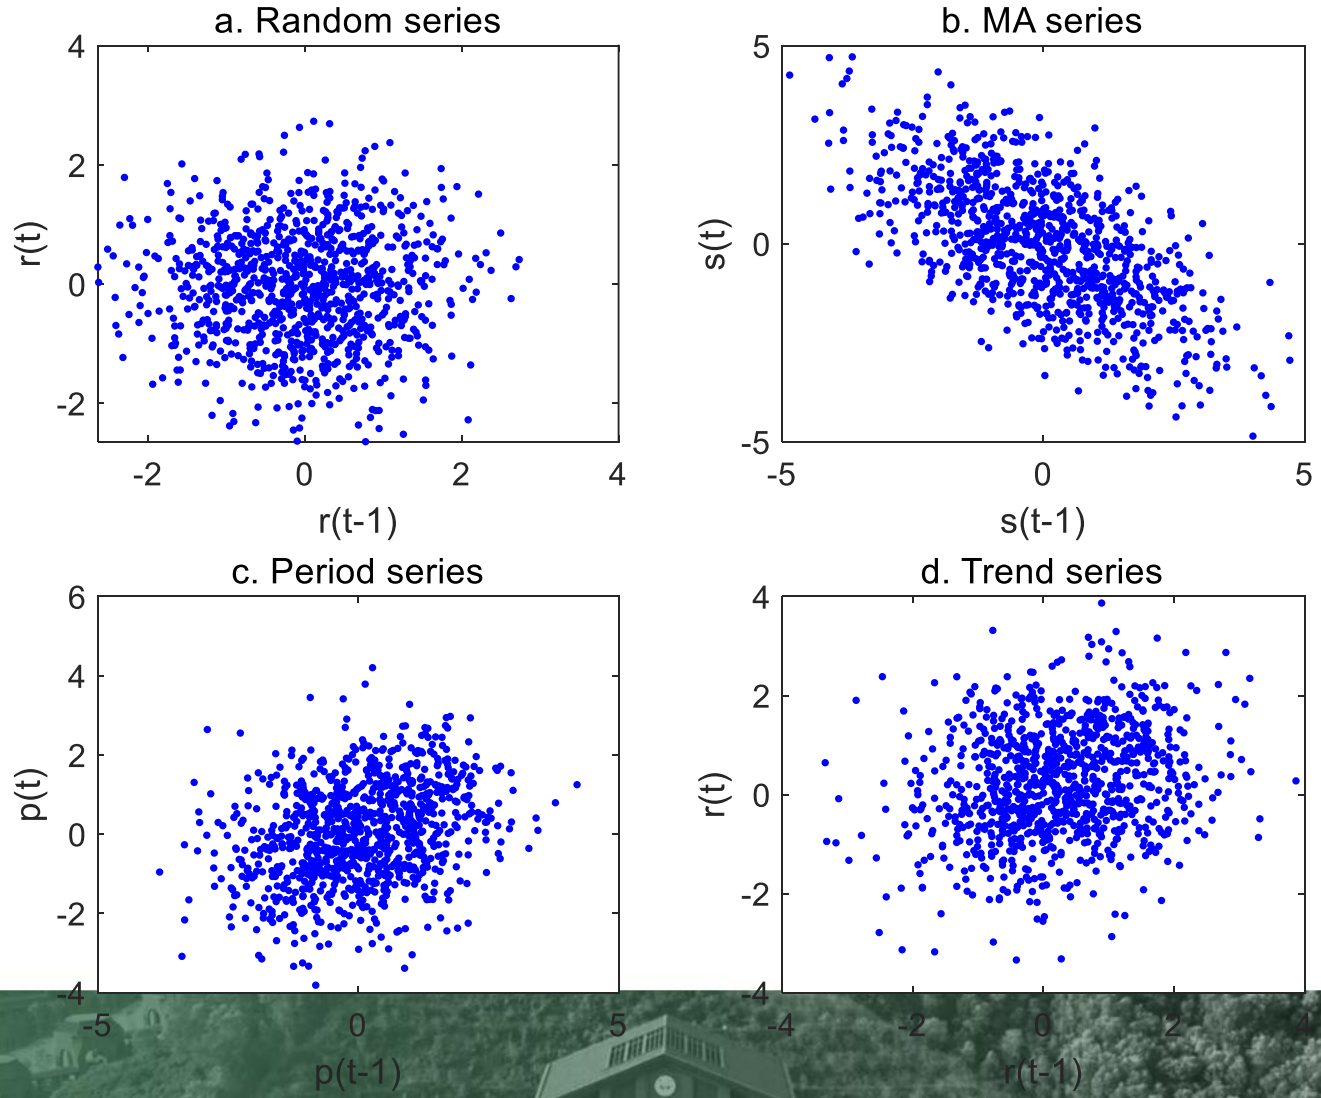
例子：回归与线性相关性


Comparison of R-Squared for Different Linear Models (Same Data Set)
Great
Fitted values from model
x
y
R^2 = 100%
Observed values
Fitted = observed: Model explains all variance
Good
R^2 = 80%
Observed values
Model explains bulk of variance
OK
Fitted values from model
R^2 = 40%
Observed values
Model explains 40% of variance, so is reasonable.
Inconsistent
R^2 = 0%
Observed values
Model fails to explain any variance

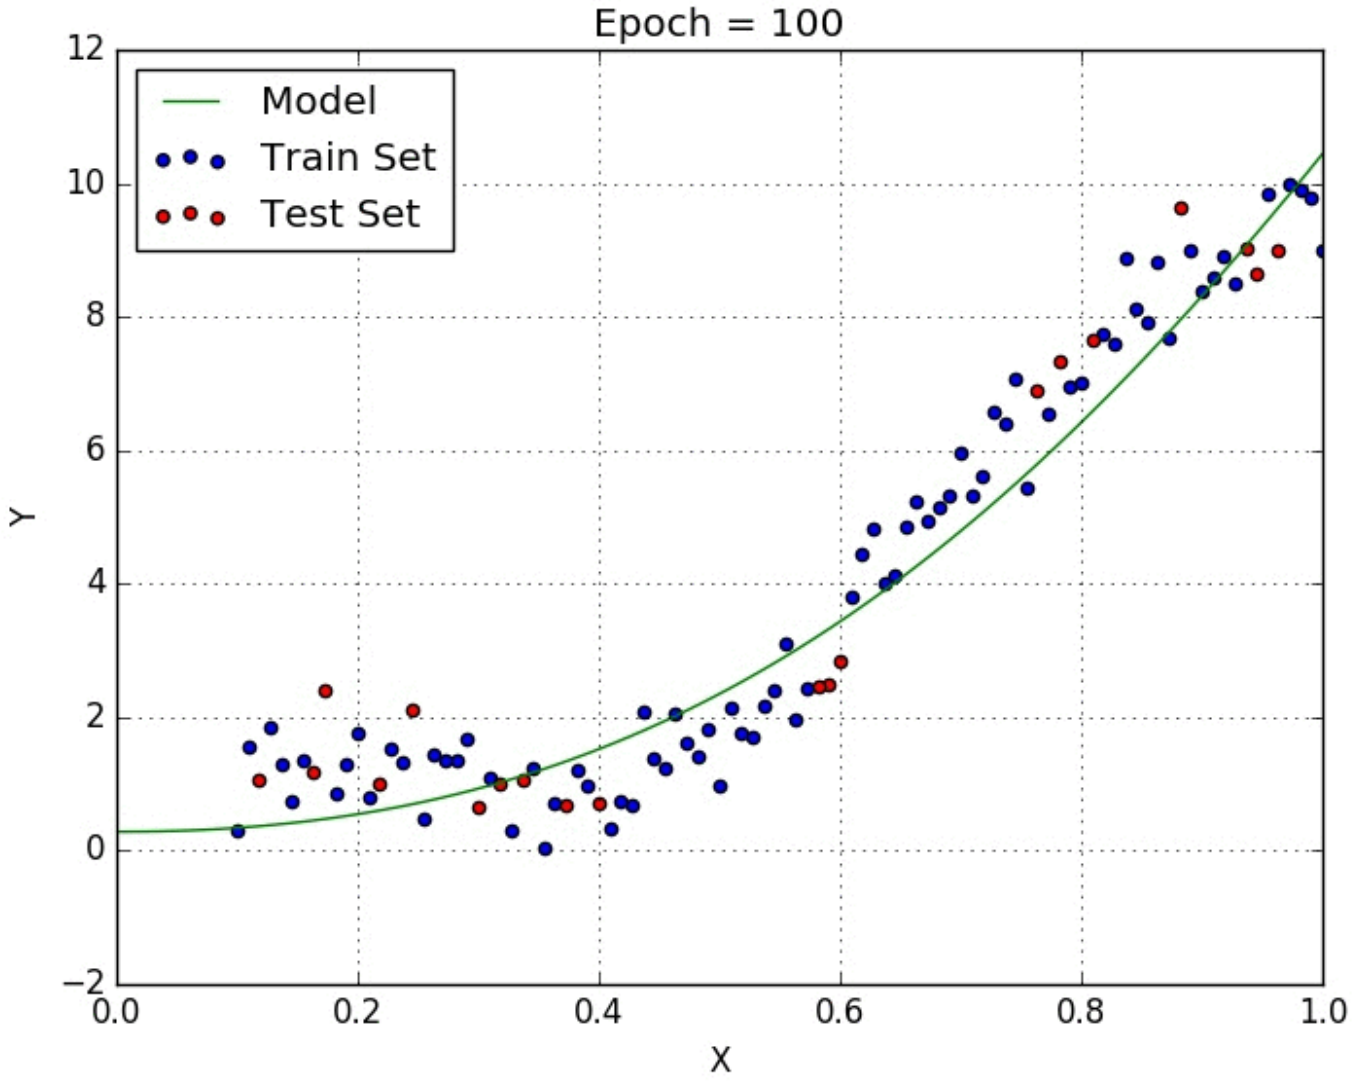
例子：时间序列


a. Random series
r
t
b. MA series
s
t
c. Period series
p
t
d. Trend series
q
t

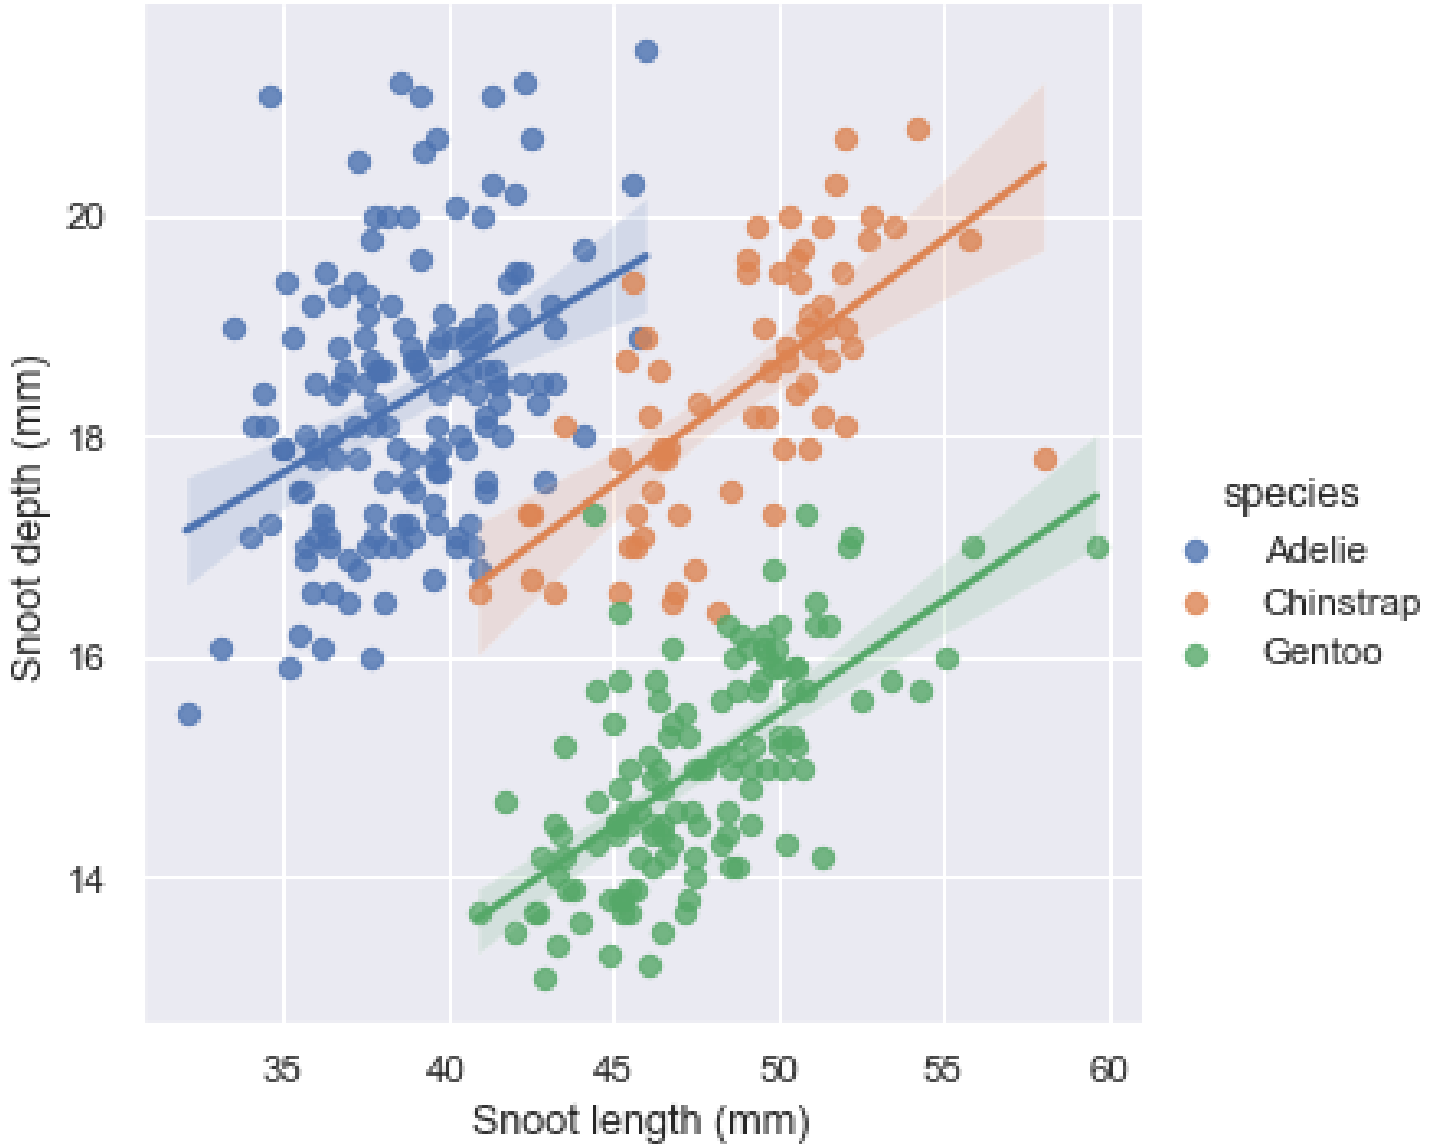
例子：时间序列自相关散点图



例子：曲线拟合


Epoch = 100
Model
Train Set
Test Set
12
10
8
6
4
2
0
−2
Y
0.0
0.2
0.4
0.6
0.8
1.0
X

例子：先聚类后回归


Snoot depth (mm)
20
18
16
14
35
40
45
50
55
60
Snoot length (mm)
species
Adelie
Chinstrap
Gentoo

思考

1. 多维数据的关系（解释、回归、分类）？
2. 线性回归的表达式、原理和构建步骤?
3. 怎么用Matlab构建线性回归模型?
4. 怎么用Matlab验证回归是否有统计意义？（显著性检验）
5. 一元到多元，线性到非线性，给回归分析带来变化?
6. 有了异常点的数据怎么办？有无统计方法剔除异常点?
   有无统计方法可以在异常点存在下建立回归模型?
   Matlab怎么实现?

2.一元线性回归

什么是回归分析

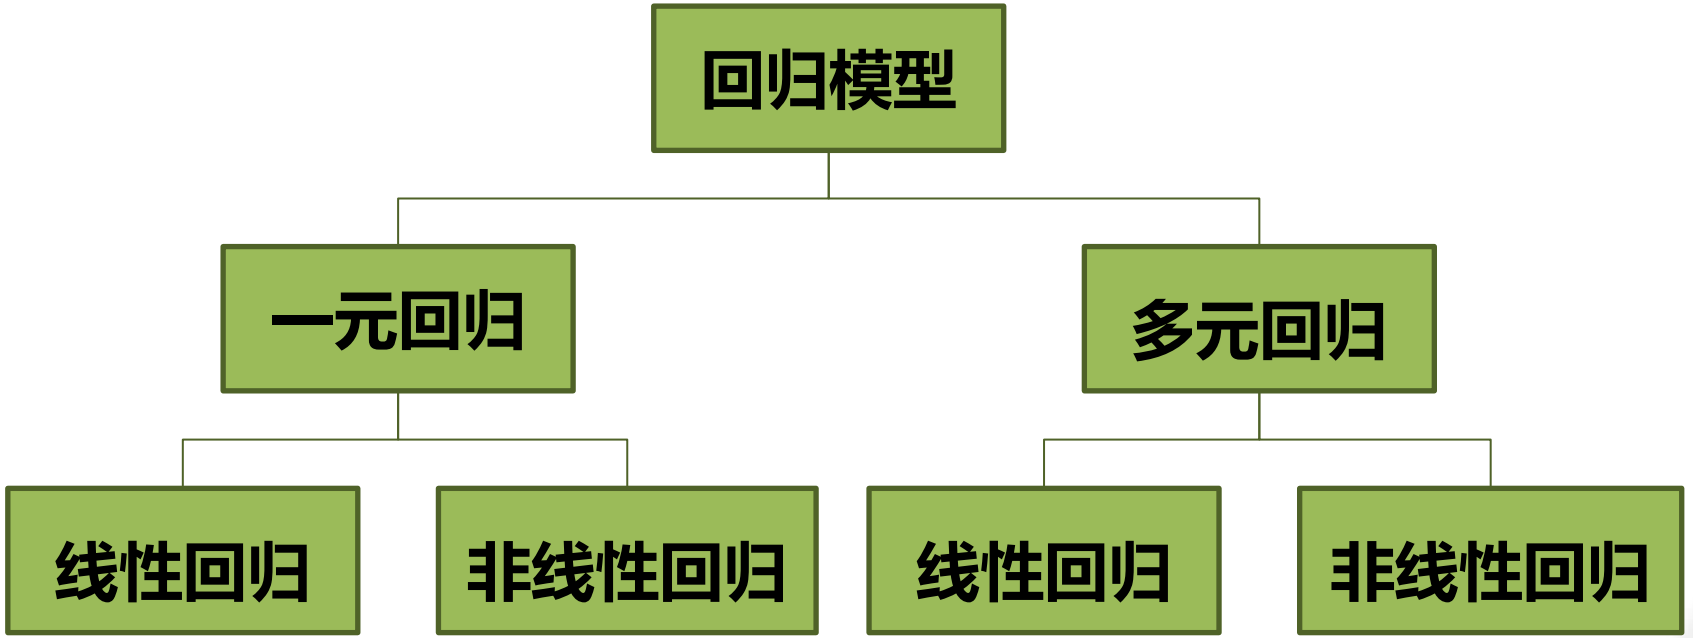
- 回归分析是用来寻找若干变量之间**统计联系关系**的一种方法，利用找到的统计关系对某一变量作出未来时刻的估计，称为预报量。

  易测易控的要素 ⇨ 难以控制和测量的要素

  预报因子X　　预报量Y

- 包括**线性**回归和**非线性**回归、**一元**回归和**多元**回归。

回归模型的类型



模型结构

一元回归分析

处理两个变量（预报量和预报因子）之间的关系。

y_t 被称作因变量	x_t 被称作自变量
(dependent variable)	(independent variable)
被解释变量	解释变量
(explained variable)	(explanatory variable)
结果变量	原因变量
(effect variable)	(causal variable)

模型结构

一般来说，对样本数为n的预报量y与预报因子x，如果认为y与x是一种统计线性关系，预报量y的估计量与x有如下关系：

$$\hat{y}_i = a + bx_i \quad i = 1,2,\ldots,n \qquad (1)$$

或者写为一般的回归方程：

$$\hat{y} = a + bx$$

中山大學 SUN YAT-SEN UNIVERSITY

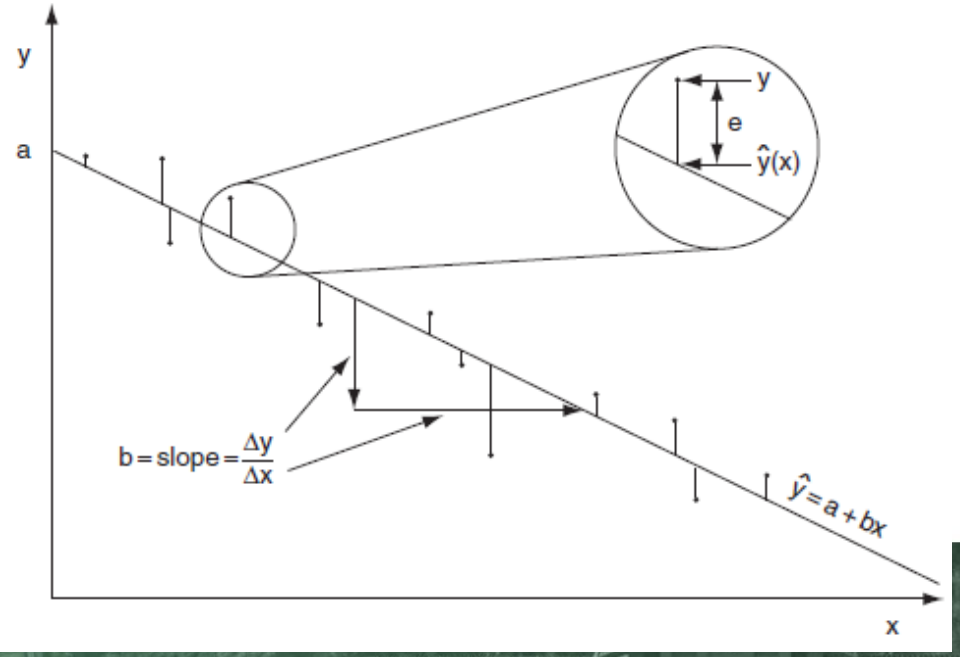
模型结构

■ a是截距，b是斜率

■对所有的x_i，若 $\hat{y}_i$ 与 y_i的残差最小，就认为(1)所确定的直线能最好地代表所有实测点的分布规律。为了消除残差符号的影响，可以用残差的平方来 反映残差的绝对值偏离情况。

求解方法：最小二乘法

通过散点图，由一条直线大致体现两个变量间的关系
这条直线满足，预报量与真实值之间误差最小
达到**误差最小**的方式是，**残差平方和最小化**
误差是观察值与真实值之间的差；**残差**是观察值与模型估计值之间的差



$$y = \alpha + \beta x + \varepsilon$$

$$\hat{y} = a + bx$$

求解方法

■全部观测值与回归估计值的残差平方和Q记为

$$Q(a, b) = \sum_{t=1}^{n} (y_i - \hat{y}_i)^2$$

■Q值刻画了全部观测值与回归直线的偏离程度，越小越好。a和b是待定系数，根据微积分学中的极值原理，要求：

$$\frac{\partial Q}{\partial a} = 0 \qquad \frac{\partial Q}{\partial b} = 0$$

求解方法

■满足上面关系的Q值最小。整理得到：

$$\begin{cases} -2\sum_{i=1}^{n}(y_i - a - bx_i) = 0 \\ -2\sum_{i=1}^{n}(y_i - a - bx_i)x_i = 0 \end{cases}$$

■上式称为求回归系数的**标准方程组**。展开：

$$\begin{cases} na + b\sum_{i=1}^{n} x_i = \sum_{i=1}^{n} y_i \\ a\sum_{i=1}^{n} x_i + b\sum_{i=1}^{n} x_i^2 = \sum_{i=1}^{n} x_i y_i \end{cases}$$

求解方法

回归系数也可直接表示为：

$$\begin{cases} a = \bar{y} - b\bar{x} \\ b = \dfrac{\sum_{i=1}^{n} x_i y_i - \frac{1}{n}(\sum_{i=1}^{n} x_i)(\sum_{i=1}^{n} y_i)}{\sum_{i=1}^{n} x_i^2 - \frac{1}{n}(\sum_{i=1}^{n} x_i)^2} = \dfrac{\sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}}{\sum_{i=1}^{n} x_i^2 - n\bar{x}^2} = \dfrac{S_{xy}}{S_x^2} \end{cases}$$

计算部分非常简单，用软件实现也非常简单，重要的是如何对回归中的方差进行分析，这关系到我们怎么解读回归计算的结果，同时也是回归分析的显著性检验的基础

3.多元线性回归

多元回归分析

- **一元 VS 多元**：多元线性回归分析是一元线性回归分析的推广，或者说一元线性回归分析是多元线性回归分析的特例。
- 多元回归分析的两步求解法
- **第一步：参数估计**：一元线性回归分析有三种基本途径，其中有两种可用于多元线性回归：
  - 一是**矩阵运算方法**；
  - 二是**回归分析工具箱regress的运用**。
- **第二步：统计检验**：对于多元线性回归，统计检验的内容相对复杂。

Matlab中回归参数估计的三种求解途径

求解途径	基本命令	自变量
矩阵运算	/	一元回归 多元回归
多项式拟合	polyfit (求参数) polyval (求y预测值)	一元回归
调用回归分析工具箱	regress	一元回归 多元回归

多元回归的检验

总离差平方和=回归平方和+残差平方和

TSS=ESS+RSS

1）最小二乘拟合 Min （RSS）

2）相关系数统计量（可决系数）

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS}$$

调整的可决系数（adjusted coefficient of determination）

$$\overline{R}^2 = 1 - \frac{RSS/(n-k-1)}{TSS/(n-1)}$$

3）F统计量

$$F = \frac{ESS/k}{RSS/(n-k-1)}$$

总结：多元回归的检验

一元回归	检验含义	多元回归	检验含义
F检验	F、R和t检验选一即可，完全等价；方程的显著性检验	F检验	方程的显著性检验，旨在对模型中被解释变量与解释变量之间的线性关系在总体上是否显著（拟合优度）
相关系数检验	检验模型的整体拟合优度 自变量对因变量的解释程度	校正的相关系数	检验模型的整体拟合优度
		偏相关系数	扣除其他变量间接影响的情况下，揭示出各个自变量对因变量的直接影响程度或解释能力
t 检验	变量的显著性检验：每个解释变量对被解释变量的影响都是显著的； 参数的置信区间：在一次抽样中所估计的参数值离参数的真实值有多“近”。		
标准误差检验	检验模型的预测精度		
DW检验	样本属于有序的时间序列或者空间序列，检验残差序列是否为随机序列		

多元回归的多重共线性

- **模型:** $y = w_0 + w_1x_1 + w_1x_2 + \cdots + w_px_p$

- **如果两个自变量共线性 $x_1 \approx k\ x_2$**
- $y = w_0 + （w_1k + w_1）x_2 + \cdots + w_px_p$
- **则$w_1k + w_1$可以取多个值**
- **一般的，如果X之间存在共线性，w的最小二乘估计 $(X^TX)^{-1}X^Ty$**
- **X之间共线性会导致w的估计不稳定**

多元回归求解的正则化

求解途径	最小化的优化目标	备注
一般回归	残差平方和	如果X^TX是奇异的，回归则无解或无穷多解
Lasso	残差平方和+系数*权重绝对值和（一阶范数）	权重容易变成0或1，可实现特征选择，较高的求解速度
Ridge	残差平方和+系数*权重平方和（二阶范数）	具有较高的准确性、鲁棒性以及稳定性
Elastic-Net	残差平方和+系数1*权重绝对值和（一阶范数）+系数2*权重平方和（二阶范数）	

4. 非线性回归

非线性模型参数估计

- 现实世界中很少出现严格意义的线性关系。人们日常见到的线性关系模型都是**对非线性的近似**，或者某种**非线性关系线性化**的结果。
- **线性回归模型**的表达式是比较单一的，
- **非线性回归模型**的

1. 形式千变万化。
2. 选择和构建不像线性模型那样有比较固定的套路。

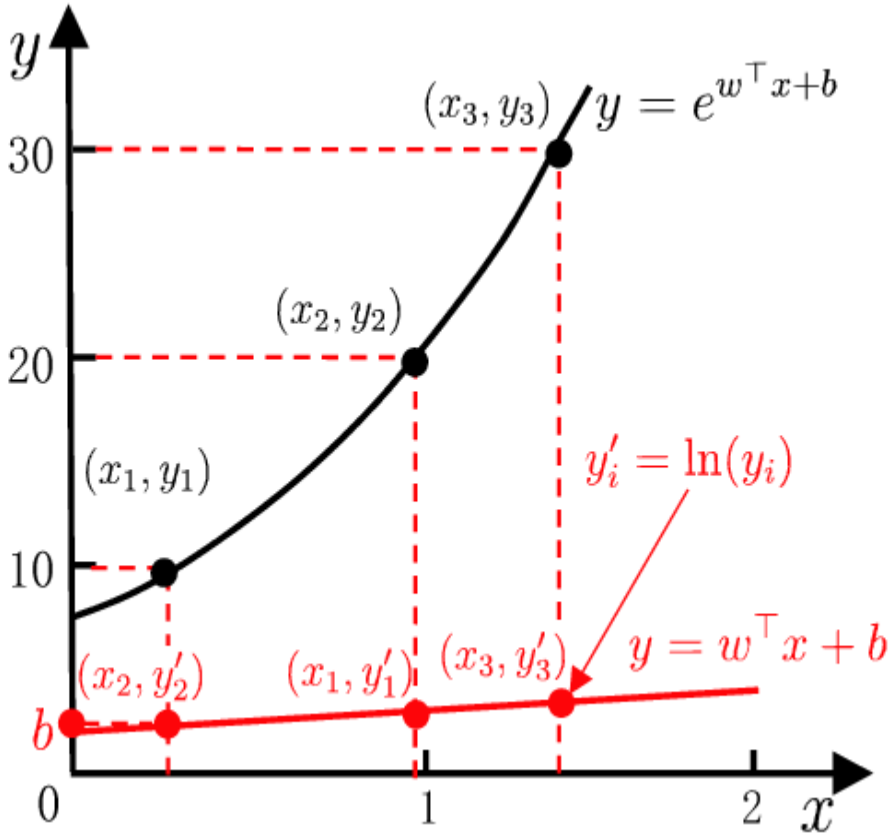
常见的、可以线性化的非线性模型

模型	数学方程	转化关系	线性表示
指数模型	$y = ae^{bx}$	$y' = \ln y,\ a' = \ln a$	$y' = a' + bx$
对数模型	$y = a + b\ln x$	$x' = \ln x$	$y = a + bx'$
幂指数模型	$y = ax^b$	$x' = \ln x,\ y' = \ln y,\ a' = \ln a$	$y' = a' + bx'$
正态模型	$y = ae^{bx^2}$	$x' = x^2,\ y' = \ln y,\ a' = \ln a$	$y' = a' + bx'$
对数正态模型	$y = ae^{b(\ln x)^2}$	$x' = (\ln x)^2,\ y' = \ln y,\ a' = \ln a$	$y' = a' + bx'$

常见的、可以线性化的非线性模型

模型	数学方程	转化关系	线性表示
双曲线模型1	$\frac{1}{y}=a+\frac{b}{x}$	$x'=\frac{1}{x},\quad y'=\frac{1}{y}$	$y'=a+bx'$
双曲线模型2	$\frac{1}{y}=a+bx$	$y'=\frac{1}{y}$	$y'=a+bx$
Logistic模型	$y=\frac{1}{1+ae^{-bx}}$	$y'=\ln(\frac{1}{y}-1),\quad a'=\ln a$	$y'=a'-bx$
抛物线模型	$y=a+bx+cx^2$	$x'=x^2$	$y=a+bx+cx'$
生产函数	$y=ax^bz^c$	$x'=\ln x,\ y'=\ln y,\ z'=\ln z,\ a'=\ln a$	$y'=a'+bx'+cz'$
Gamma函数	$y=ax^{-b}e^{-cx}$	$x'=\ln x,\ y'=\ln y,\ a'=\ln a$	$y'=a'-bx'-cx$
其他函数	……	……	……

指数模型 转换 对数线性模型



$$\ln(\boldsymbol{y}) = \boldsymbol{wTx} + \boldsymbol{b}$$

$$\boldsymbol{y'} = \boldsymbol{wTx} + \boldsymbol{b}$$

广义线性模型

广义线性回归 (generalized linear regression)：将线性回归的预测值做一个非线性的函数变化去逼近真实值

$$y = g^{-1}\left(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b\right)$$

g 称为联系函数（link function)

对数线性回归：将真实值的对数作为线性回归逼近的目标

$$y = \exp(\boldsymbol{wTx} + \boldsymbol{b})$$ **或 ln(y)= $w^T x+b$**

g为指数函数

广义线性/非线性模型的求解

- 借助MATLAB估计某些非线性模型的参数，
- 基于线性化处理的最小二乘计算（直线拟合）➔全局效果更好
- 基于非线性方程运用迭代算法（曲线拟合）➔模型标准误差更低

5. 二元分类及其多元推广

二元分类模型

- **二元分类模型**
  - 将分类标记与线性回归模型输出联系起来函数
  - 输出是0或1
- **二元分类的多元推广**
  - 将多元分类拆分成多个二元分类➔将多个二元分类结果进行集成
  - 寻找分类函数/投影方向，最大化 组间方差/ 组内方差

单位阶跃函数

■ 最理想二元分类函数：**单位阶跃函数**

■ 输出：

$$y = \begin{cases} 0, & z < 0; \\ 0.5, & z = 0; \\ 1, & z > 0, \end{cases}$$

■ 预测值大于零就判为正例，

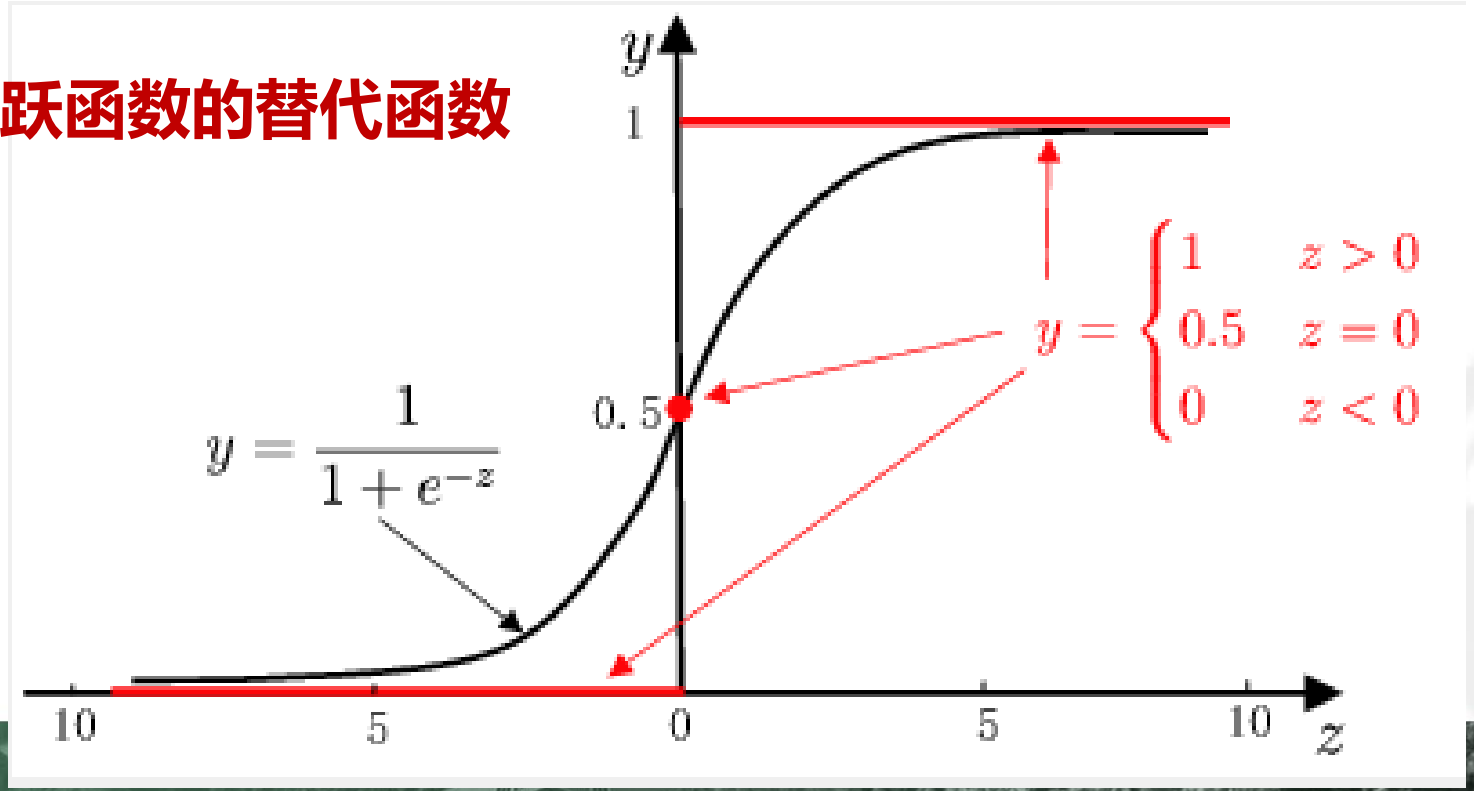
■ 预测值小于零就判为反例，

■ 预测值为临界值零则可任意判别为正例或反例

■ 缺点: 不连续

logistic回归函数

- 又叫对数几率(log odds)函数
- 或Sigmod函数
- 单位阶跃函数的替代函数



logistic回归函数的不同形式的公式

$$f(x) = \frac{1}{1+e^{-x}} \qquad f(x) = \frac{e^{x}}{1+e^{x}}$$

$$p = \frac{\exp(a + b_1x_1 + b_1x_2 + \cdots + b_p\mathrm{x}_p)}{1 + \exp(a + b_1x_1 + b_1x_2 + \cdots + b_p\mathrm{x}_p)}$$

$$\frac{p}{1-\mathrm{p}} = \exp(a + b_1x_1 + b_1x_2 + \cdots + b_p\mathrm{x}_p)$$

$$\ln(\frac{p}{1-\mathrm{p}}) = a + b_1x_1 + b_1x_2 + \cdots + b_p\mathrm{x}_p$$

logistic回归特点:概率形式输出

$$p(y=1|x)=\frac{1}{1+e^{-(w^Tx+b)}}$$

单调递增，值域为(0， 1)➔输出可作为概率值。y或p是x分类为某一类别概率的大小。

- y或p越接近1➔x为类别1的可能性越大。
- y或p越接近0 ➔x不属于该类别的概率越大。

根据具体应用设置一个阈值，

- 大于该阈值的输入数据x都归属到某个类别，
- 小于该阈值的输入数据x都归属到另外一个类别。

logistic回归特点:对数几率（优势)

p 理解为 x 为正例的概率；1 − p 理解为x为负例的概率

$\frac{p}{1-p}$ 几率(odds，优势)， x为正例可能性的相对优势

$ln(\frac{p}{1-p})$ 对数几率函数（对数优势函数？）

如果x 属于正例的概率大于其属于负例的概率，即p (y=1| x) > 0.5，则输入数据x可被判断属于正例。等价于p (y=1| x) / p (y=0| x) > 1，即log（ p (y=1| x)/ p (y=0| x) ） > $log1$ =0，也就是$w^T x$ + b > 0成立（ x属于正例时） 。

logistic回归特点：广义线性

$$ln(\frac{p}{1-p}) = w^T x + b$$

广义线性模型。

线性回归模型输出结果去逼近（拟合）真实标记结果的对数几率（优势）

在预测时，线性函数$w^T x$ + b取值是否大于0（x通过一定阈值进行判断）来判断输入数据x的类别归属。

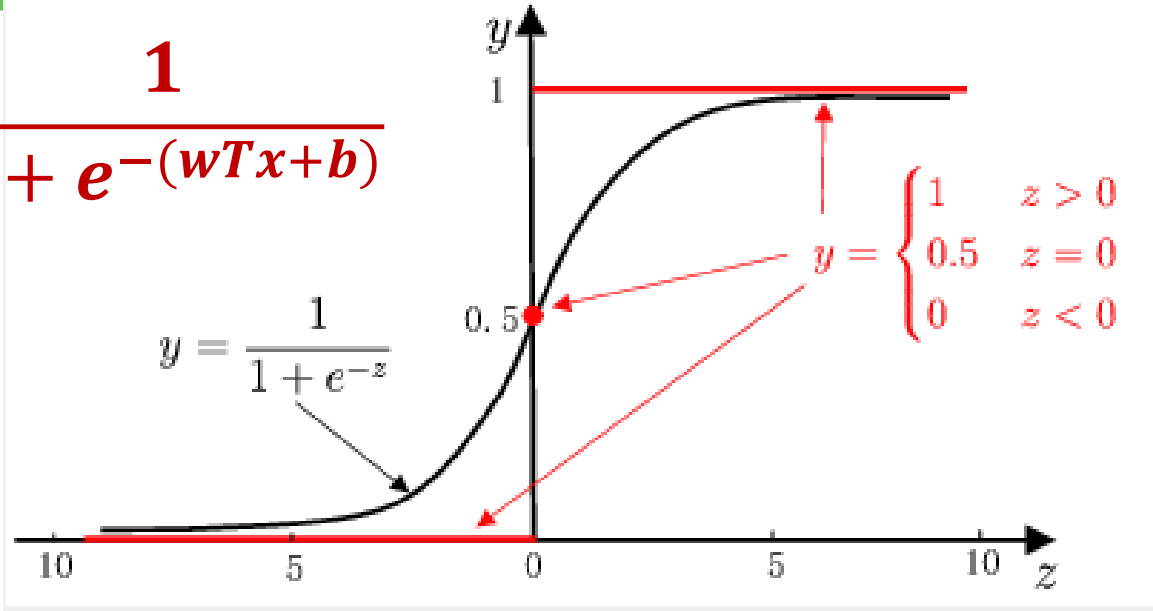
logistic回归特点:数据特征加权累加

$$f(x) = \frac{1}{1+e^{-z}} = \frac{1}{1+e^{-(wTx+b)}}$$

- z 是输入数据x和回归函数的参数w相乘结果（x各维度进行加权叠加）。
- 对输入z取值范围没有限制，
- 但当z大于一定数值后，函数输出无限趋近于1，
- z小于一定数值后，函数输出无限趋近于0。
- 特别地，当z = 0 时，函数输出为0.5。

logistic回归特点：非线性变化

$$y = \frac{1}{1+e^{-z}} = \frac{1}{1+e^{-(wTx+b)}}$$



- x各维度加权叠加之和（z）结果取值在0附近时，函数输出值的变化幅度比较大（函数值变化陡峭），且是非线性变化。
- 各维度加权叠加之和（z）结果取值很大或很小时，函数输出值几乎不变化。

logistic回归函数的求解

- 模型结构已知，求解就是参数估计
- 1）转换成线性回归，用线性回归方法求解
- 2）构造损失函数就是对数似然的相反数。目标最小化损失函数，用迭代算法（如梯度下降法）来求解模型的参数

$$cost(h_\theta(x), y) = \begin{cases} -log(h_\theta(x)) & \text{if } y=1 \\ -log(1-h_\theta(x)) & \text{if } y=0 \end{cases}$$

$$h_\theta(x) = P(y=1|x;\theta)$$

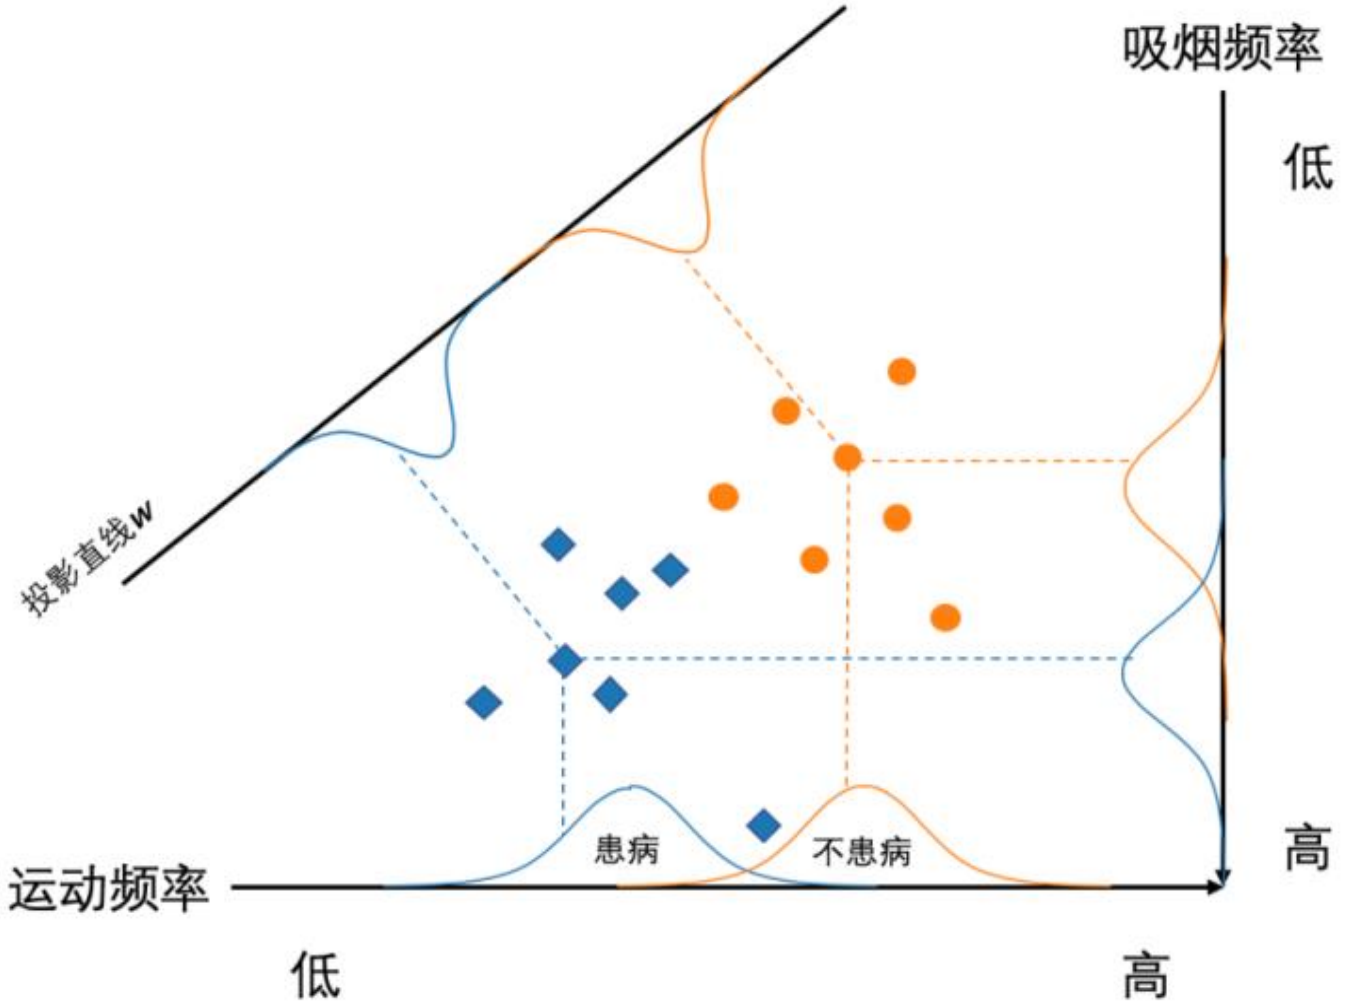
https://blog.csdn.net/bdhaha_2015

logistic回归函数的一般特点

- 多种形式，比如对数几率（优势)函数
- 单调可微、任意阶可导
- 无需事先假设数据分布
- 可得到“类别”的近似概率预测
- 可以转换成线性回归或构造损失函数进行求解
- 用回归的方法解决分类的问题
- 通常是二元分类，可以推广到多元分类

6. 判别分析

例子：线性判别分析



判别分析的定义

- **英文：** Linear Discriminant Analysis（LDA）
- **定义1：** 在分类确定的条件下，根据某一研究对象的各种特征值判别其类型归属问题的一种**多变量统计分析方法**。
- **定义2：** **狭义判别分析（找出判别规则：找规则）+分类分析（给出分类结果：给结果）**
  - **狭义判别分析：** 旨在寻找一种判别规则，利用变量的函数（判别函数）来描述和解释两组或多组群体间的区别；
  - **分类分析：** 利用判别函数在新观测上的取值，找到该观测最有可能属于的类别，从而预测一个新观测对象的类别

判别分析的基本原理

- **基本原理**：是按照一定的判别准则，建立一个或多个判别函数，用研究对象的大量资料确定判别函数中的待定系数，并计算判别指标。据此即可确定某一样本属于何类。
- **从机器学习角度看：一种分类方法，属于有监督学习。**
  - **因变量**为类别数据，有多少类别就有多少类别处理组；
  - **自变量**通常为可度量数据。
- **判别函数**：**能够最大限度的区分因变量类别的函数**➔考查自变量的组间差异是否显著，判断那些自变量对组间差异贡献最大，评估分类的程度，根据自变量的值将样本归类。

判别分析的类型

- 根据判别中的**组数**：**两组**和**多组**判别分析；
- 根据**判别函数的形式**：**线性判别**和**非线性判别**；
- 根据**判别式处理变量的方法**不同：逐步判别、序贯判别等；
- 根据**判别标准**不同：
  - **距离判别**
  - **Fisher判别**
  - **Bayes判别**法等。

Fisher判别函数的数学含义

- **问题**：找到一系列向量，最大化多群体的组间方差（B）和组内方差（W）的比值；新样本在该系列向量对应坐标轴下离哪个类中心距离近，即属于该类。

- **假设**：
  - 群体的分布没有要求
  - 不同群体有相同的协方差矩阵
  - 判别函数是线性的

Fisher判别函数的数学含义

- 多群体Fisher判别式
  - 判别式的求解结果：$W^{-1}B$的非零特征值对应的特征向量
  - 特征值和向量的个数为类别数-1
  - 新样本在该系列向量对应坐标轴下离哪个类中心距离近，即属于该类。
- 多群体Fisher判别分析等价于比较新观测对象与各类中心之间的马氏距离

LDA的MATLAB 实现方法

	方法	主要命令	含义
1	单函数法	classify	根据训练数据的属性数据(矩阵)和类别(向量)，求出待判数据类别(向量)
3	双函数法	fitcdiscr	根据训练数据的属性数据(矩阵)和类别(向量)，拟合判别分析模型
		predict	根据拟合好的判别分析模型，通过待判别数据的属性，求出判别数据的类别(向量)。
3	多步定义法	mean, cov 矩阵运算	1）求样本均值 2）求样本协方差；3）求LDA函数；4）求样本得分；
		检验	5）样本显著性差异的F检验 6）等方差性检验
4	回归分析法		判别函数的X是属性；Y是马氏距离平方差；用回归分析求解

classify函数的调用格式

格式	用途
class = classify(sample, training,group)	将sample数据中的每一行归入training数据所属的组之一。training的组 由group 指定。该函数返回class，其中包含为sample 的每一行分配的组。
class = classify(sample, training,group,type,prior)	还指定了每组type的判别函数和 prior概率。
[class,err,posterior,logp,coeff] = classify(___)	还返回表观错误率（err)、训练观察的后验概率（posterior)、样本观察的无条件概率密度的对数（logp) 和边界曲线的系数（coeff)，使用之前任何输入参数组合。

fitcdiscr函数的调用格式

格式	用途
Mdl = fitcdiscr(Tbl,Res)	返回基于表中包含的输入变量Tbl（也称为自变量、特征或属性）和 Res中包含的T输出（因变量，响应或标签） 的拟合LDA模型
fitcdiscr(Tbl,formula)	返回基于表中包含的输入变量Tbl的拟合LDA模型。formula是响应的解释模型和Tbl用于拟合的预测变量子集 Mdl。
fitcdiscr(Tbl,Y)	返回基于表Tbl包含的输入变量和响应Y的拟合LDA模型。
fitcdiscr(X,Y)	返回基于输入变量X和响应Y的LDA分类器 。
fitcdiscr(___,Name,Value)	使用前面语法，使用名称-值对参数指定附加选项。如优化超参数以最小化模型的交叉验证损失，或指定错误分类的成本、每个类的先验概率或观察权重。

LDA和PCA的区别

区别	LDA	PCA
目的	分类	降维
假设	根据不同判别标准而不同 1）类之间差异显著 2）不同类协方差相等	自变量之间共线性
群体	多个（至少两个）	单个
新变量	原始自变量线性组合	原始自变量线性组合
优化目标	类别群体之间距离最大化（投影的组间方差最大化） 类内个体之间距离最小化（投影的组内方差最小化）	群体中的个体尽可能分开（投影的方差最大化）

7. 评估标准

回归模型的评价指标

指标	英文名	备注
平均绝对误差	MAE, Mean Absolute Error	绝对误差损失的预期值
平均绝对百分比误差	MAPE, Mean Absolute Percentage Error	相对误差损失的预期值.所谓相对误差,就是绝对误差和真值的百分比.
均方误差	MSE, Mean Squared Error	平方(二次)误差的期望.
均方误差根或均方根误差	RMSE, Root Mean Squared Error	均方根误差的期望
可决系数或拟合优度	R Squared或R^2 或 coefficient of determination	自变量x对因变量y的变动的解释的程度.越接近于1,说明模型拟合得越好
纳什系数	NSE，Nash-Sutcliffe efficiency coefficient	水文模型的常用评估指标

分类模型的评估：二分类的混淆矩阵

混淆矩阵		预测值	
		正例	负例
真实值	正例	a (TP)	b (FN)
	负例	c (FP)	d (TN)

真阳性（True Positive，TP）：实际是正例，预测是正例
真阴性（True Negative，TN）：实际是负例，预测是负例
假阳性（False Positive，FP）：实际是负例，预测是正例
假阴性（False Negative，FN）：实际是正例，预测是负例

精度(或positive predictive value) = TP / (TP + FP)
召回(或敏感度或真阳性率，True Positive Rate) = TP / (TP + FN)
特异度(或真阴性率，True Negative Rate) = TN / (TN + FP)

分类模型的评估：二分类的混淆矩阵

混淆矩阵（n=100）		预测值	
		正例	负例
真实值	正例（40）	35 (TP)	5 (FN)
	负例（60）	10(FP)	50(TN)

正确率（Accuracy）：被正确分类的样本比例或数量(TP+TN)/Total = (35+50)/100 = 85%

错误率（Misclassification/Error Rate）：被错误分类的样本比例或数量 (FP+FN)/Total = (5+10)/100 = 15%

真阳率（True Positive Rate）：预测为正例的样本占实际正例样本数量的比例，也叫敏感度（sensitivity）或召回率（recall）➔分类器对正例类别的敏感程度。 TP/ actual yes = 35/40 = 87%

假阳率（False Positive Rate）：预测为正例的样本占实际负例样本的比例。 FP/actual no = 10/60 = 17%

特异性（Specificity）：预测为负例的样本占实际负例样本的比例。 TN/actual no = 50/60 = 83%

精度（Precision）：在所有判别为正例的结果中，真正正例所占的比例。 TP/predicted yes = 35/45 = 77%

流行程度（Prevalence）：正例在样本中所占比例：40/100 = 40%

分类模型的评估：多分类的混淆矩阵

混淆矩阵		预测值		
		类别1	类别2	类别3
真实值	类别1	a	b	c
	类别2	d	e	f
	类别3	g	h	i

目的：分析每个类别分类正确或错误情况
每一行之和：该类别的真实样本的总数量
每一列之和：被预测为该类别的样本的总数量
第i行第j列的数字：真实值是类别i而预测为类别j的样本数
对角线的数字：模型预测正确的样本数
精确率_类别1=a/(a+d+g)
召回率_类别1=a/(a+b+c)

分类模型的评估：多分类的混淆矩阵

混淆矩阵		预测值		
		类别1	类别2	类别3
真实值	类别1	43	2	0
	类别2	5	45	1
	类别3	2	3	49

每一行之和：如类别2的真实样本的总数量是5+45+1=51
每一列之和：如被预测为类别2的样本的总数量2+45+3=50
第i行第j列的数字：真实是类别2而预测为类别1的样本是5个
对角线的数字：类别2预测正确的样本数是45个
第1行第2列为2：实际为1类而被预测为2类有2个

分类模型的评估：误判误差率

- **误判误差率的定义**
  - 误判误差率=对各个类别样本计算： 训练集中归类错误的样本数 * 该类别的先验概率值 / 训练集的样本数；再分别加和
  - 每个类别的先验概率值= 1 / 类别数（默认）或 该类别样品数/总样品数
- **误判误差率越低越好**

8. 案例研究

案例问题1：UNDP对国家的分类

UNDP的人类发展报告按照出生时预期寿命、成人识字率、人均地区生产总值（GDP）等指标将全世界的国家分为三类：高、中、低水平人类发展。

二分类问题：只考虑两类国家的数据集，其中14个（6个高水平和8个中水平）国家为**训练集**，4个国家为**验证集（待判国家）**。

选用**三个指标**：出生时预期寿命、成人识字率、人均GDP

案例问题1：UNDP对国家的分类

UNDP的人类发展报告按照出生时预期寿命、成人识字率、人均地区生产总值（GDP）等指标将全世界的国家分为三类：高、中、低水平人类发展。

三分类问题：考虑三类国家的数据集（174个国家），从高、中、低水平国家数据集中，

按照每类1/4比例分别抽取共44个国家为**训练集**，

按照每类1/10比例分别抽取共18个国家为**验证集（待判国家）**。

选用四个指标：**出生时预期寿命、成人识字率、人均GDP、城镇人口比重**

示例文件的求解方式对比

M文件	含义	因子个数
DA2C_01.m DA2C_02.m DA2C_03.m	利用线性、二次和马氏距离进行判别，二类分类	2
DA_2C_04_Full.m	多部定义法 F检验：2组间差异是否显著（F值大于临界值） 等方差性检验：不同组协方差相同（卡方值小于临界值）	2
DA_2C_05_MLR.m	回归分析法：判别函数的X是属性；Y是马氏距离平方差；用回归分析求解	2
DA_3C_01.m	线性距离进行3类分类	3
DA_3C_02_KC	K均值和判别分析联用	3

9. 小结

思考题

- 哪些常用的线性回归方法?
- 聚类、回归和分类的区别是?
- 哪些常用的判别分析方法?
- 怎么评估这些线性学习方法?