人工智能与地理数据挖掘

第七讲 k最近邻 (kNN)模型

孙伟 sunwei29@mail.sysu.edu.cn

地理科学与规划学院

中山大學 SUN YAT-SEN UNIVERSITY

2026.04

数据挖掘/机器学习的典型方法

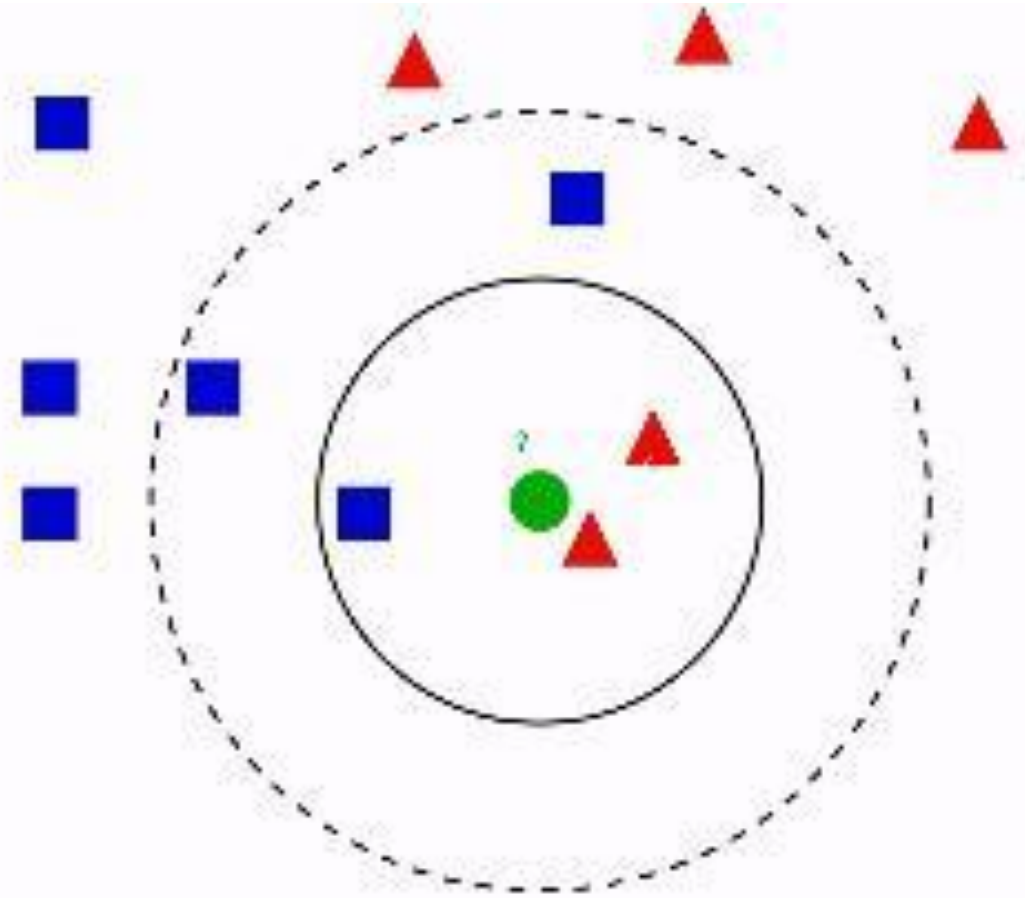
类别	聚类/降维	回归	分类	生成
线性方法	相关性 主成分分析 因子分析	多元线性回归	Logistic回归 判别分析	
最近邻	k均值聚类	kNN		
树型	层次聚类	决策树： 回归树	决策树： 分类树	深度 森林
密度	DBSCAN			
神经网络	SOM	ANN		
核函数		SVM（SVR）	SVM（SVC）	
图论	谱聚类	概率图模型	概率图模型	GNN
随机变量	高斯混合		贝叶斯分类	GAN
模糊数	模糊C 均值聚类	模糊逻辑模型 ANFIS	模糊逻辑模型	FDNN
深度学习	自动编码器	CNN，LSTM、Transformer		

目录

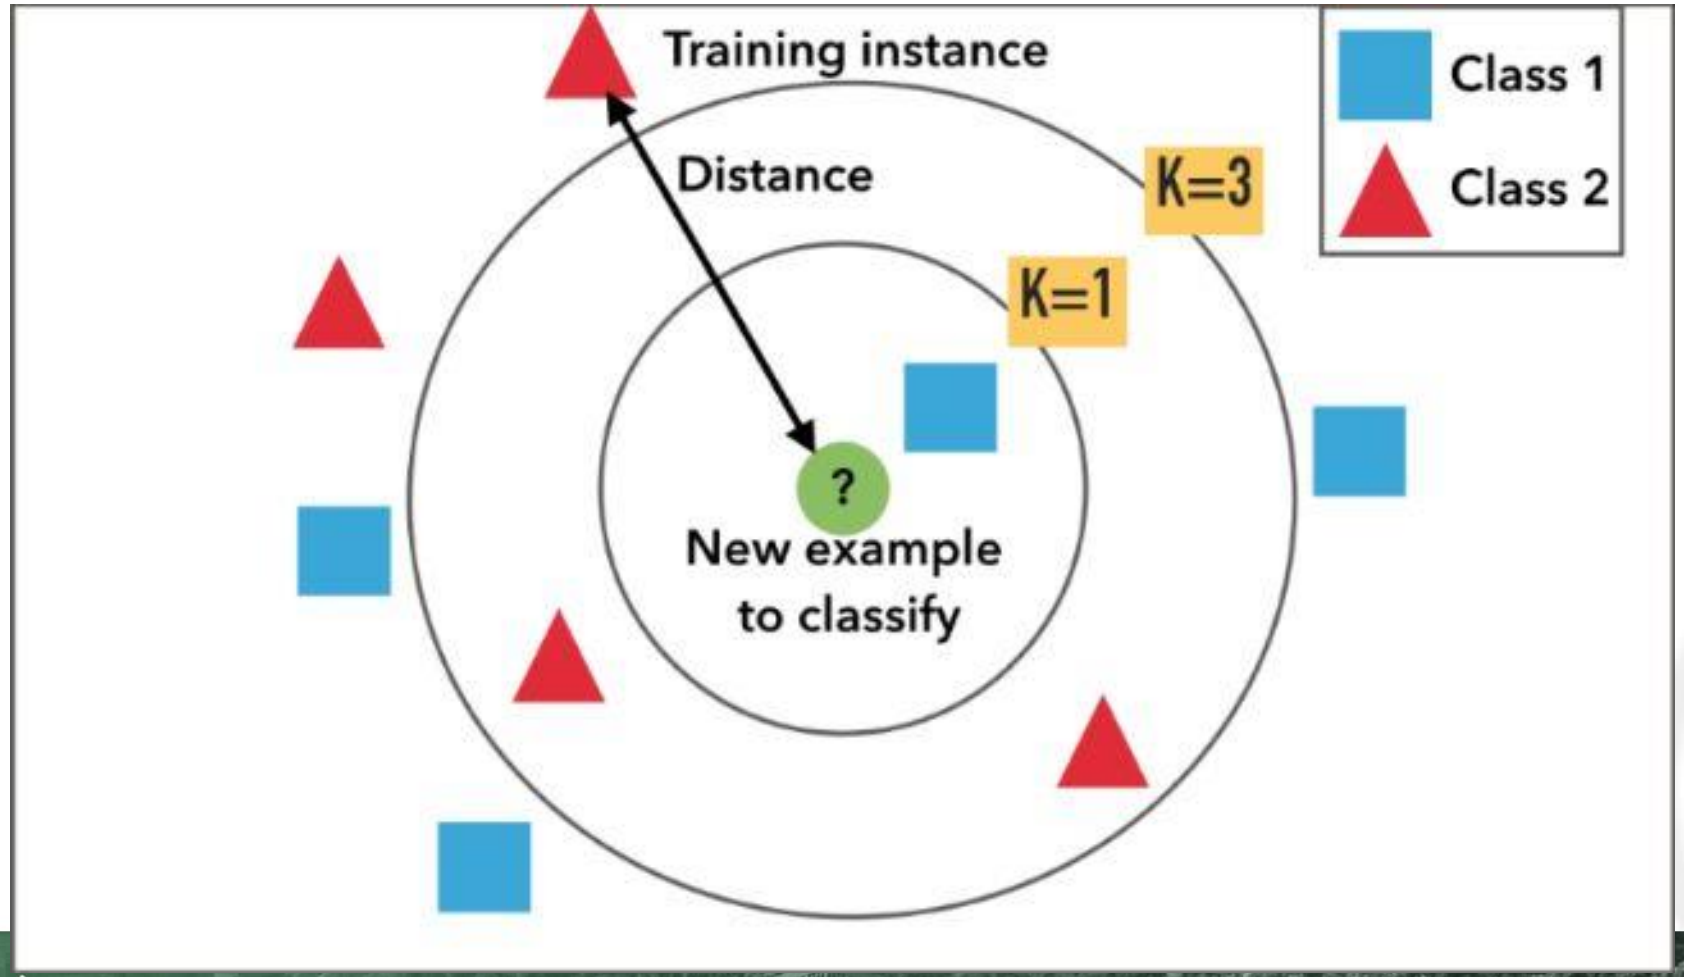
1. kNN的实例
2. kNN的概述
3. 基于kDTree的kNN
4. kNN的实现
5. 案例研究
6. 小结

1. kNN的实例

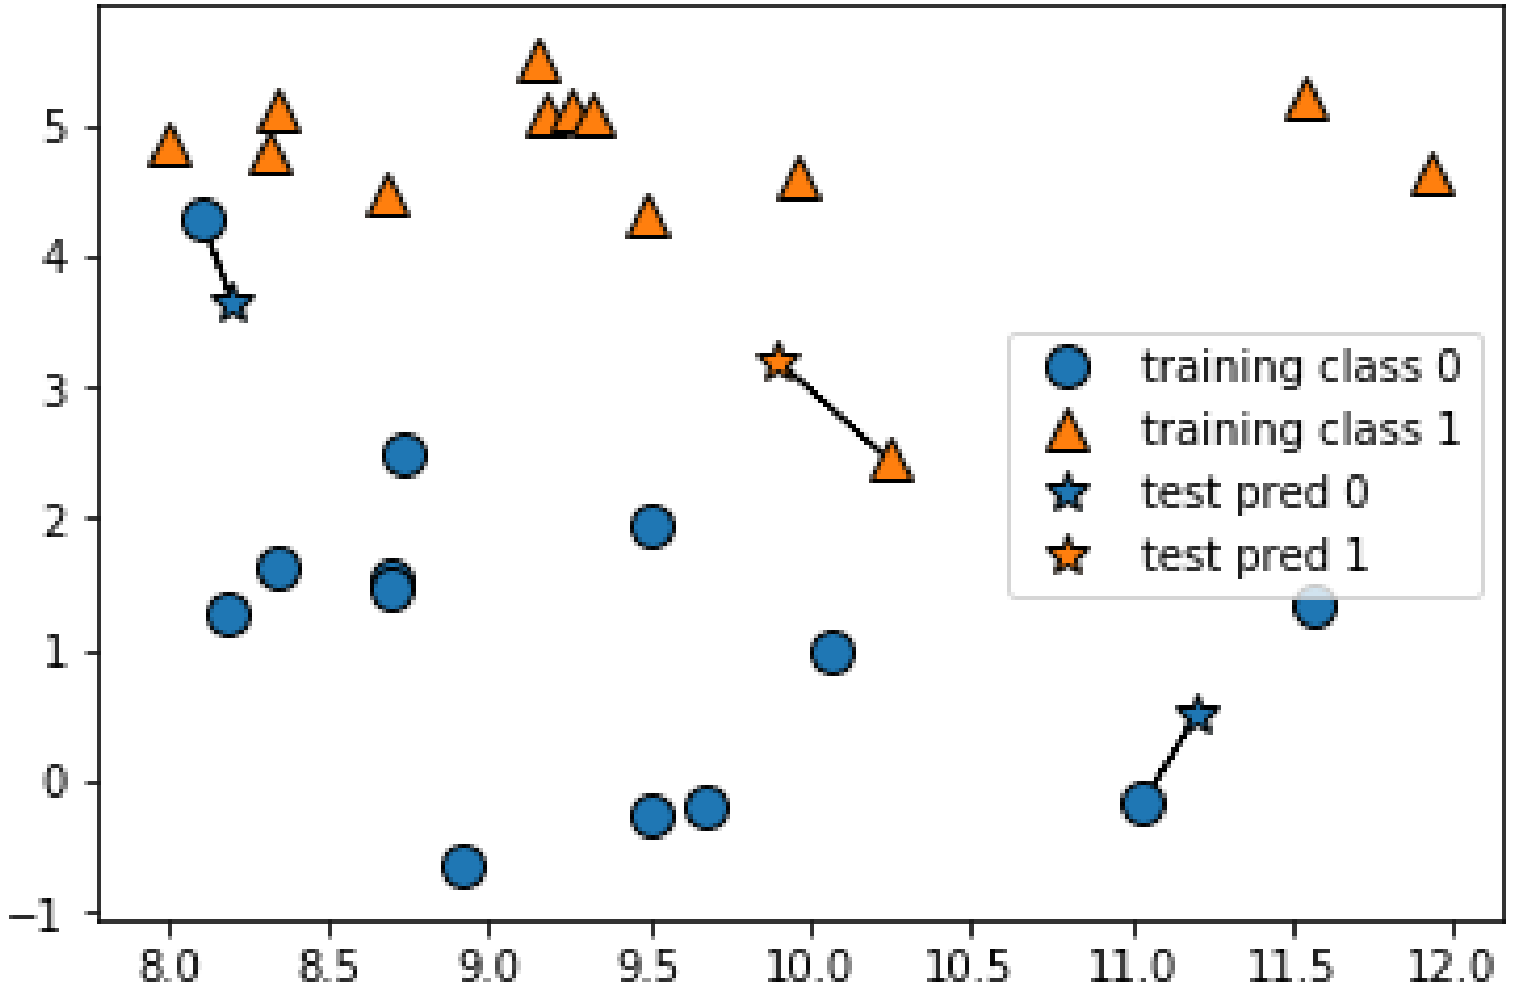
例子：根据距离的分类结果



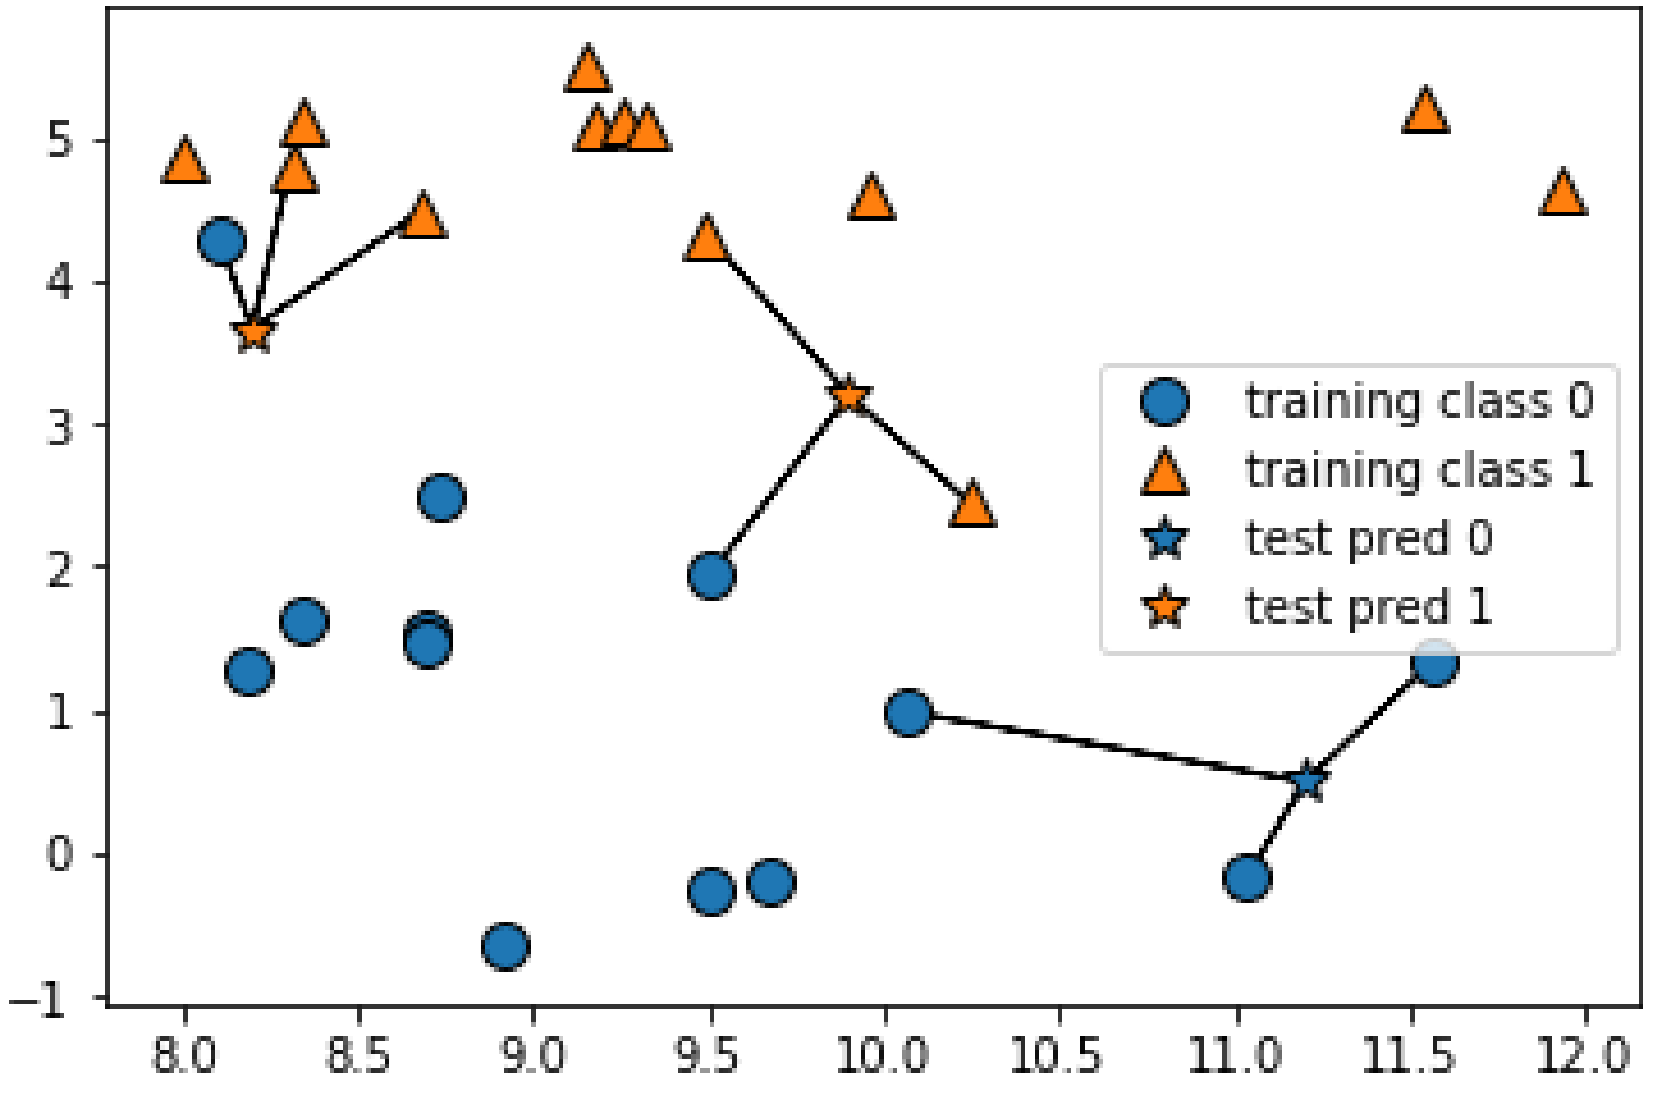
例子：根据个数的分类结果



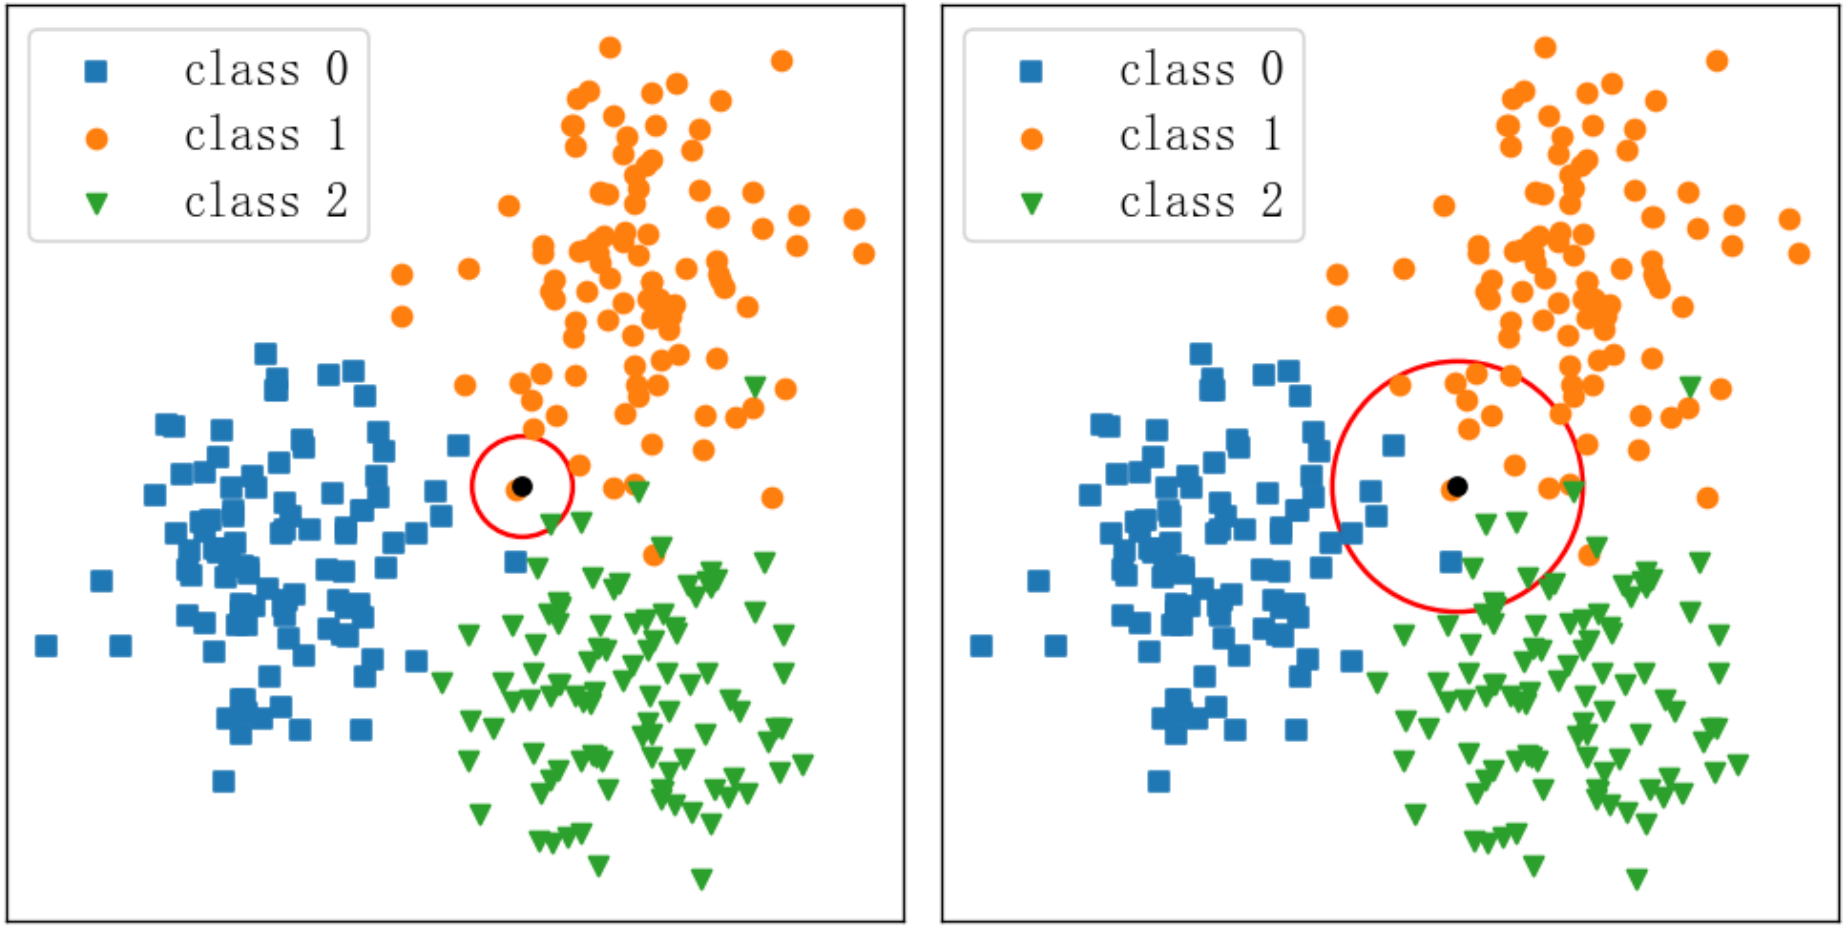
例子：K=1时的kNN分类



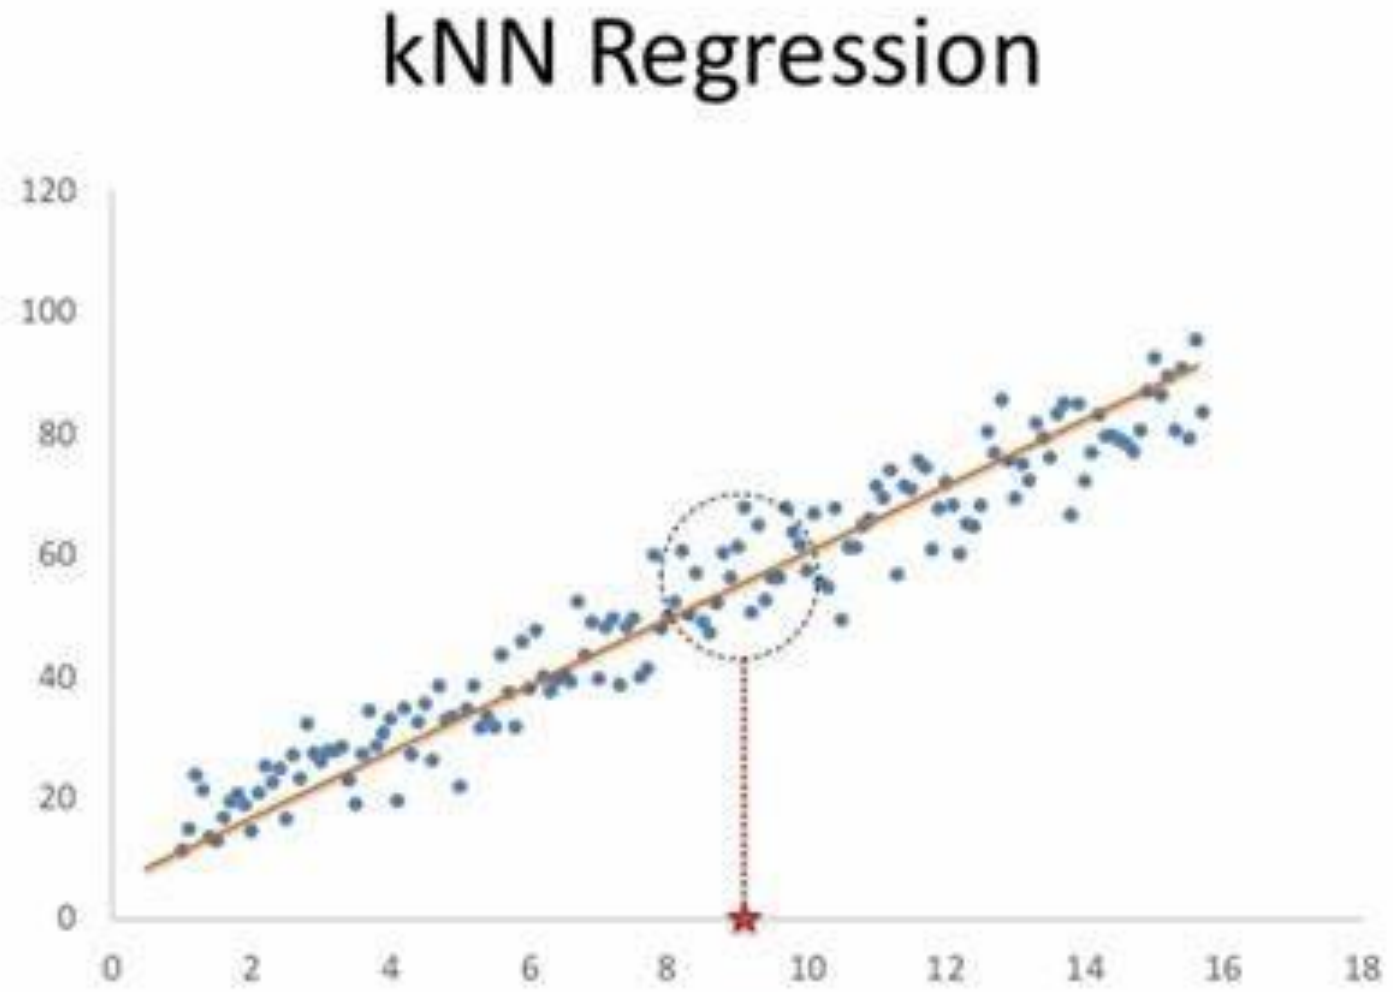
例子：K=3时的kNN分类



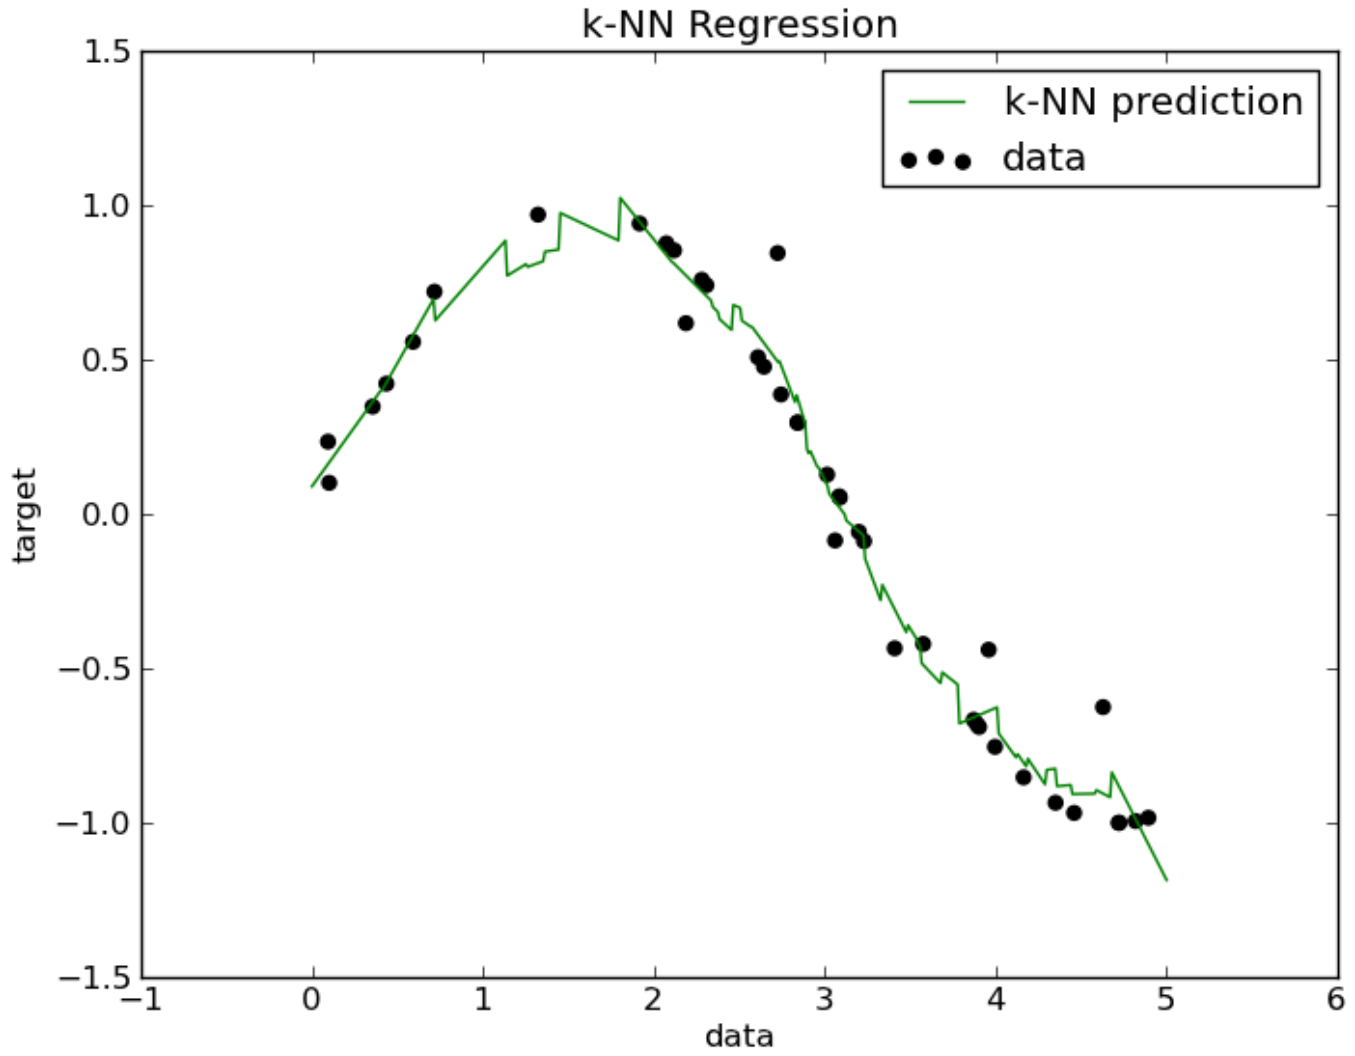
例子： k或邻域半径的选择



例子： kNN回归和线性回归的比较

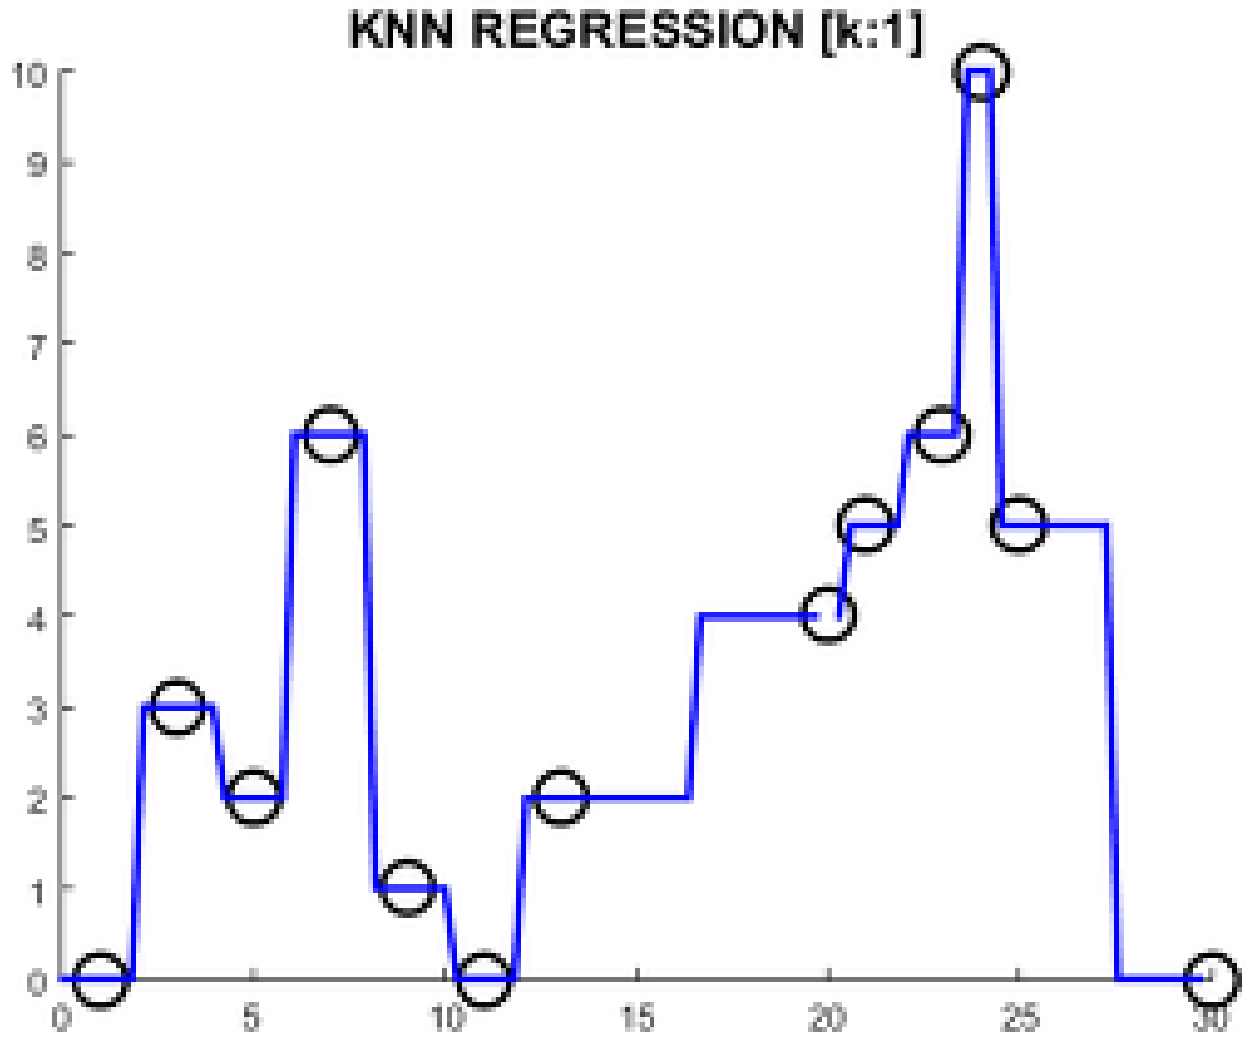


例子： kNN回归实现曲线拟合

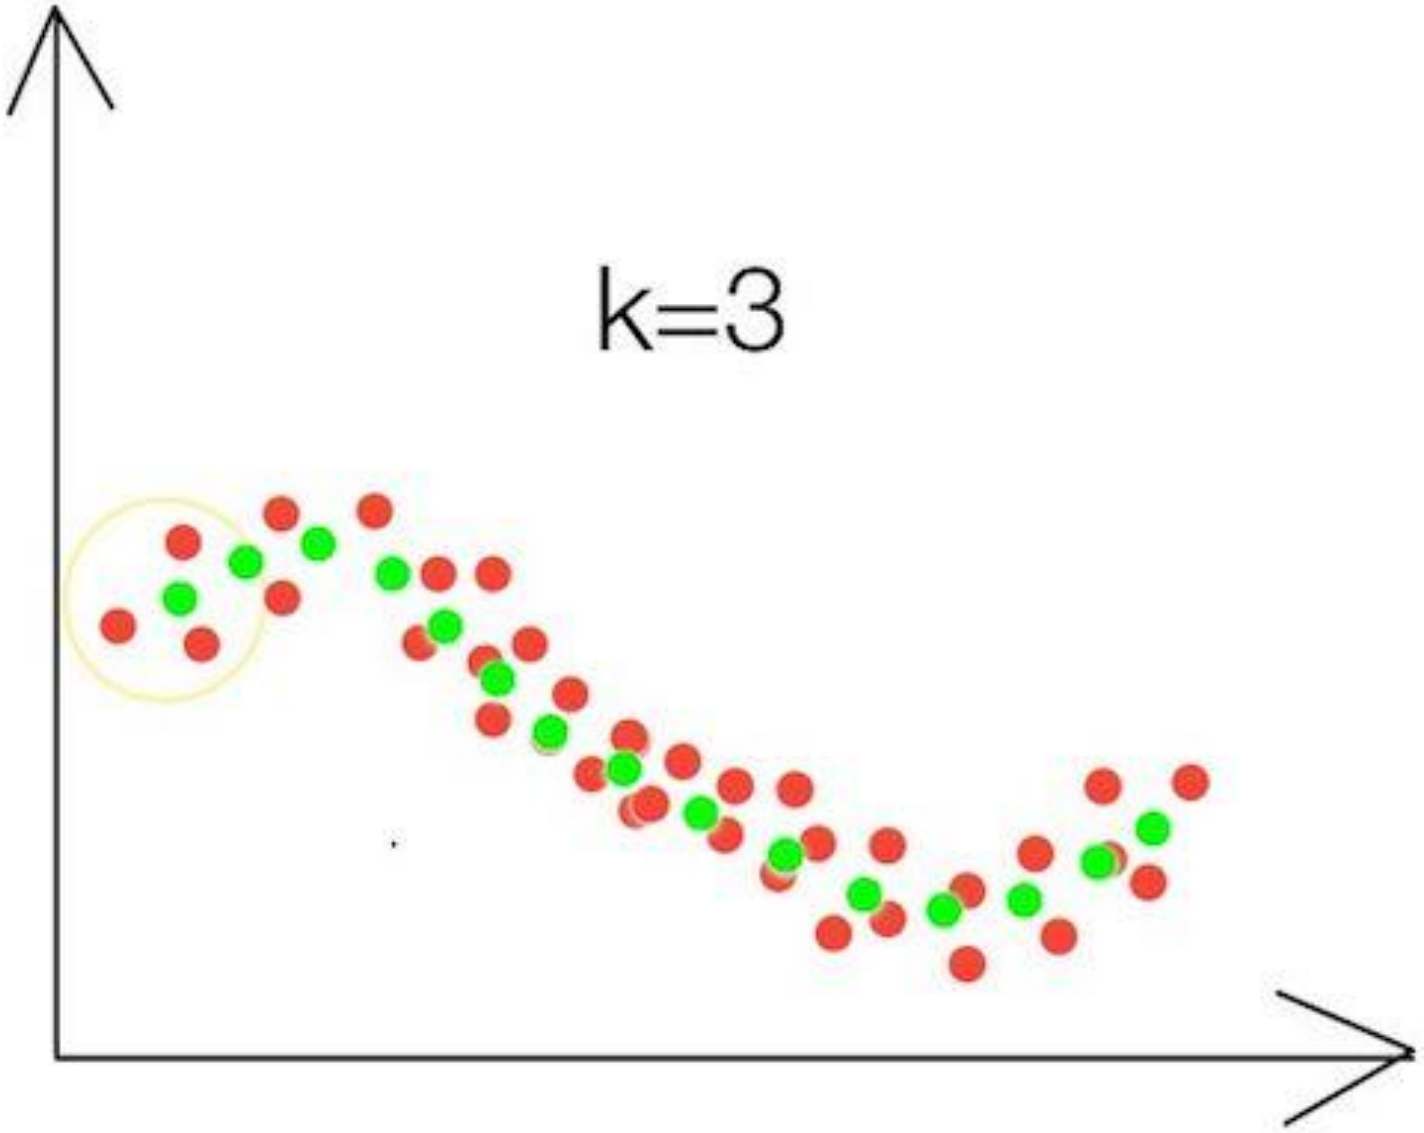


http://scikit-learn.sourceforge.net/0.6/auto_examples/plot_neighbors_regression.html

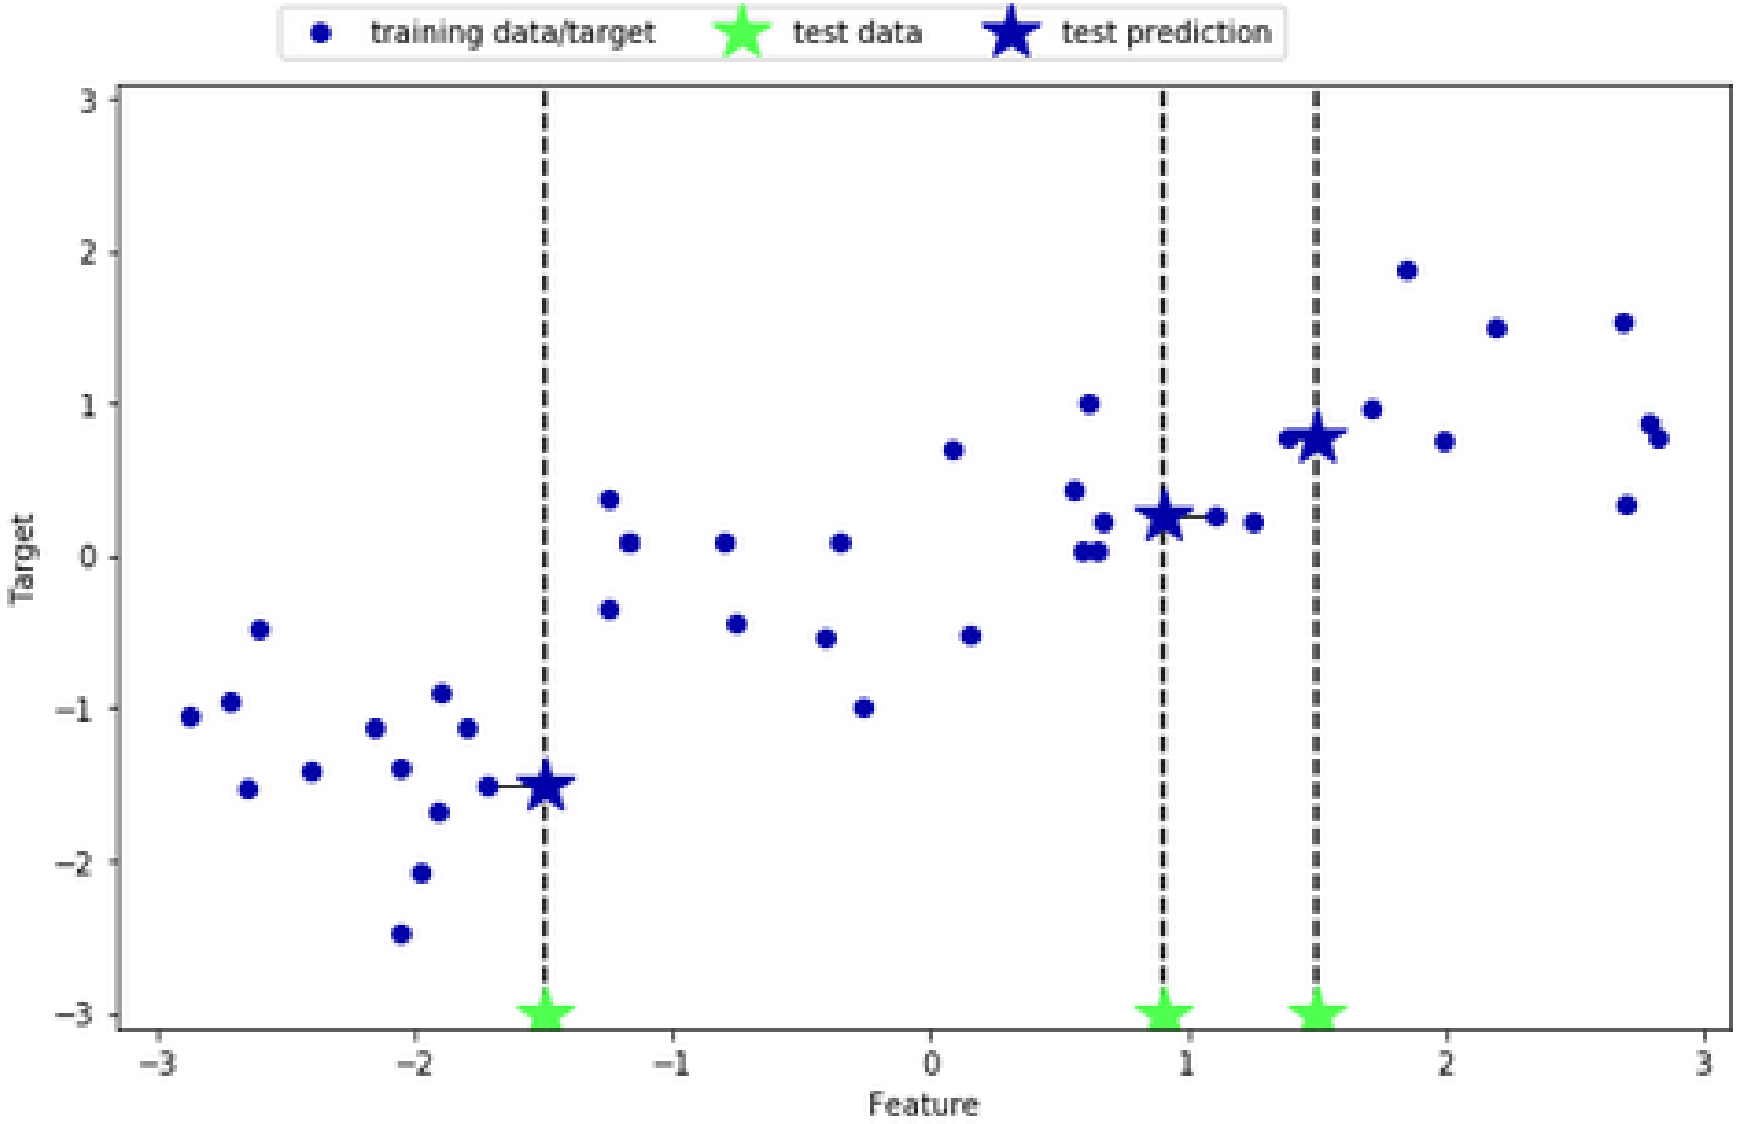
例子：K=1时的kNN回归



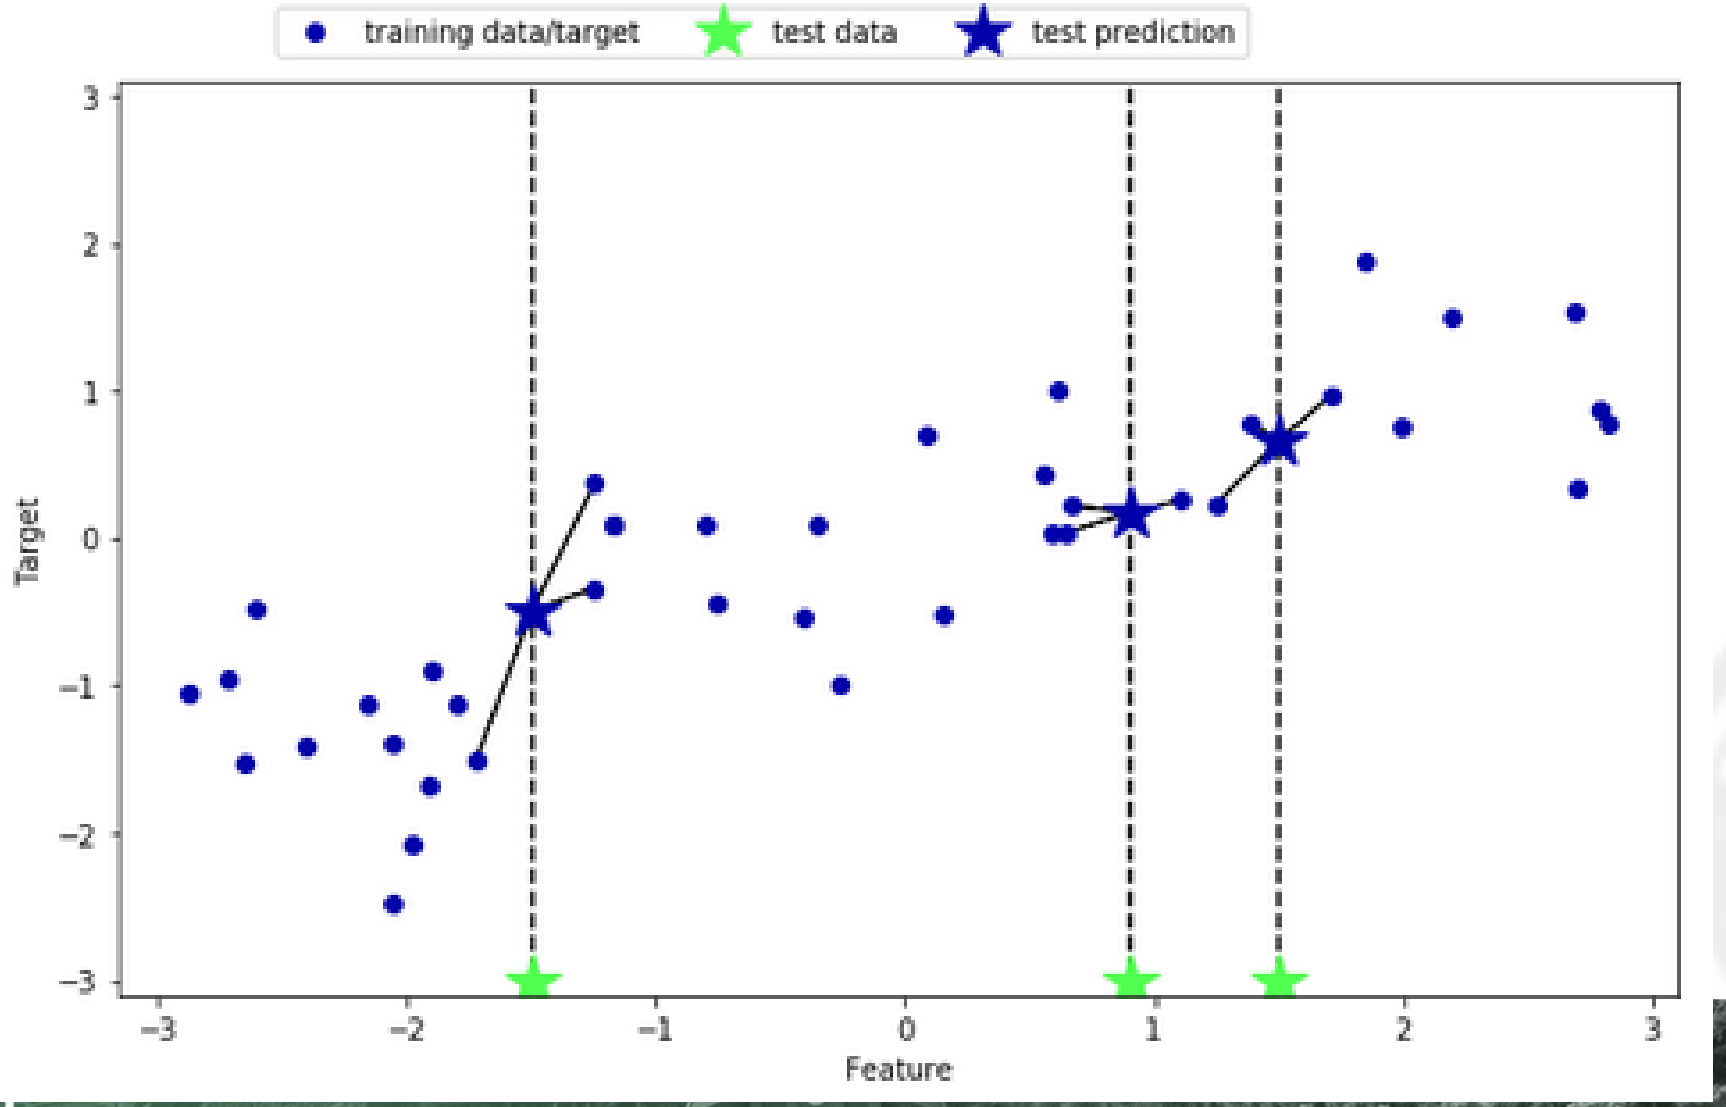
例子：kNN回归



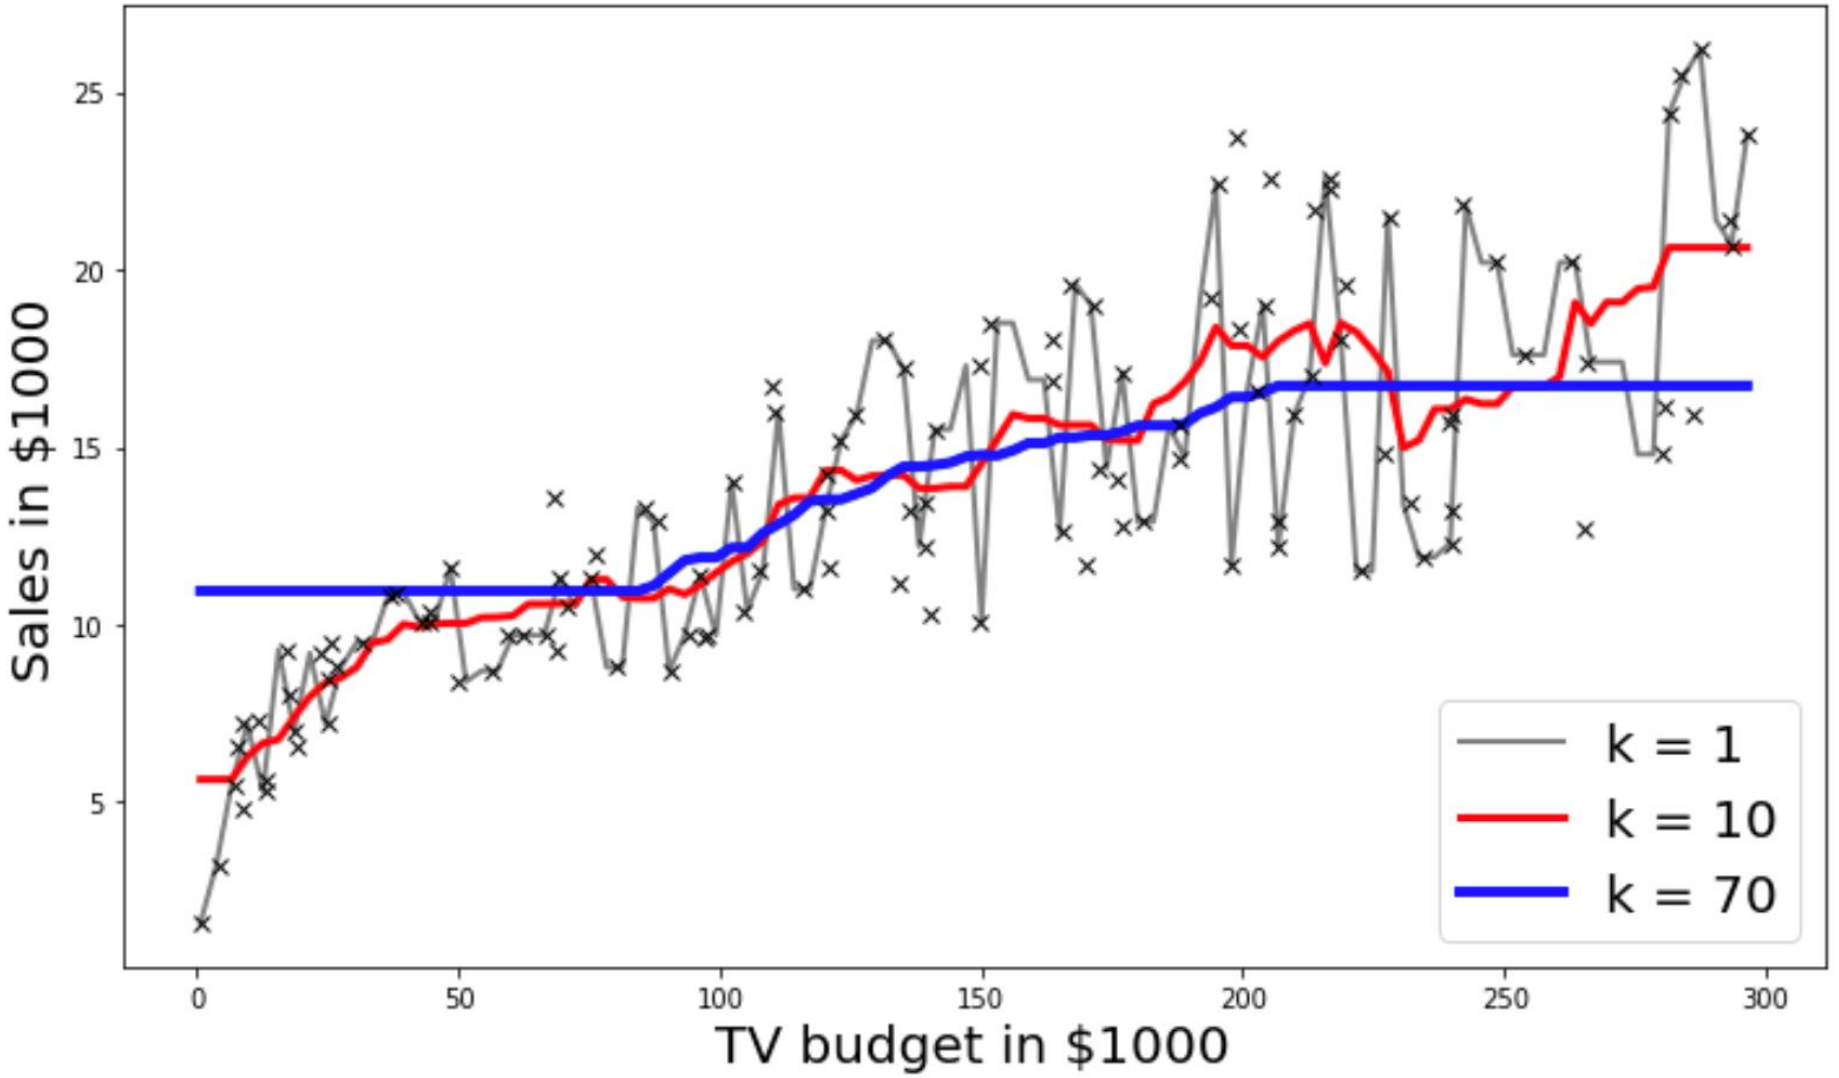
例子：1X和k=1的kNN回归



例子：1X和k=3的kNN回归

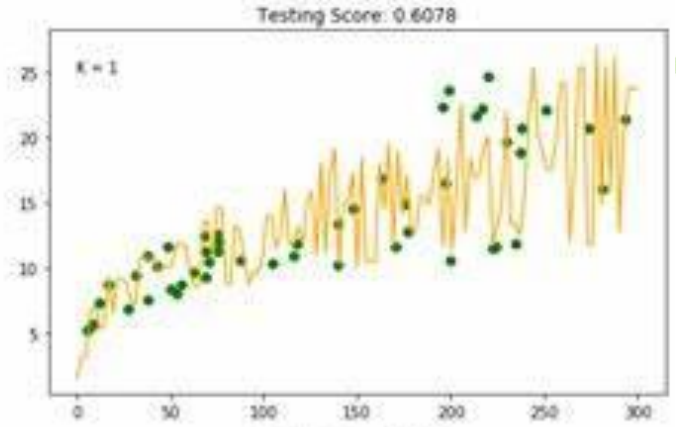


例子：k对kNN回归的影响

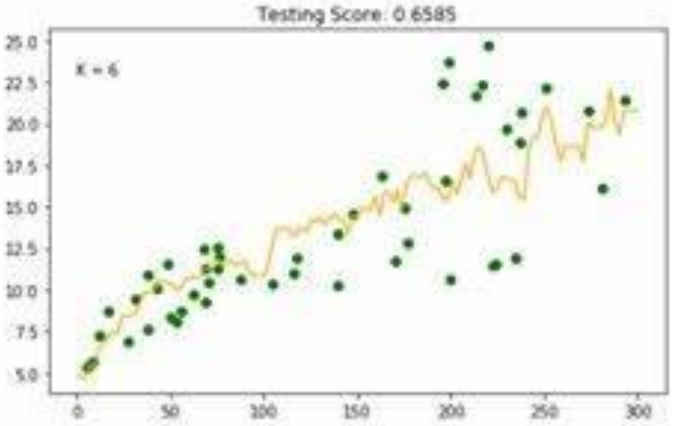


例子：k对kNN回归的影响

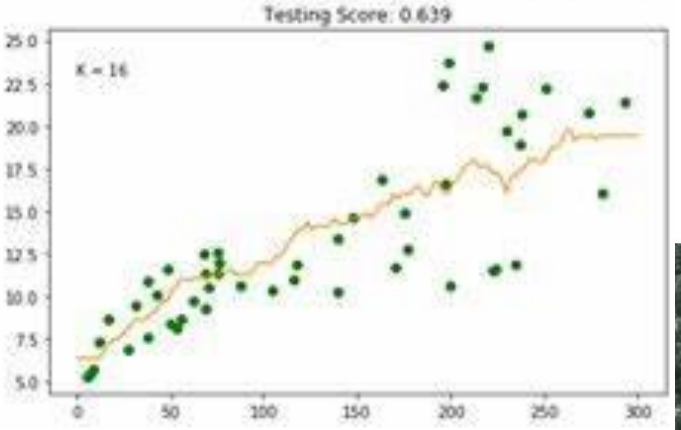




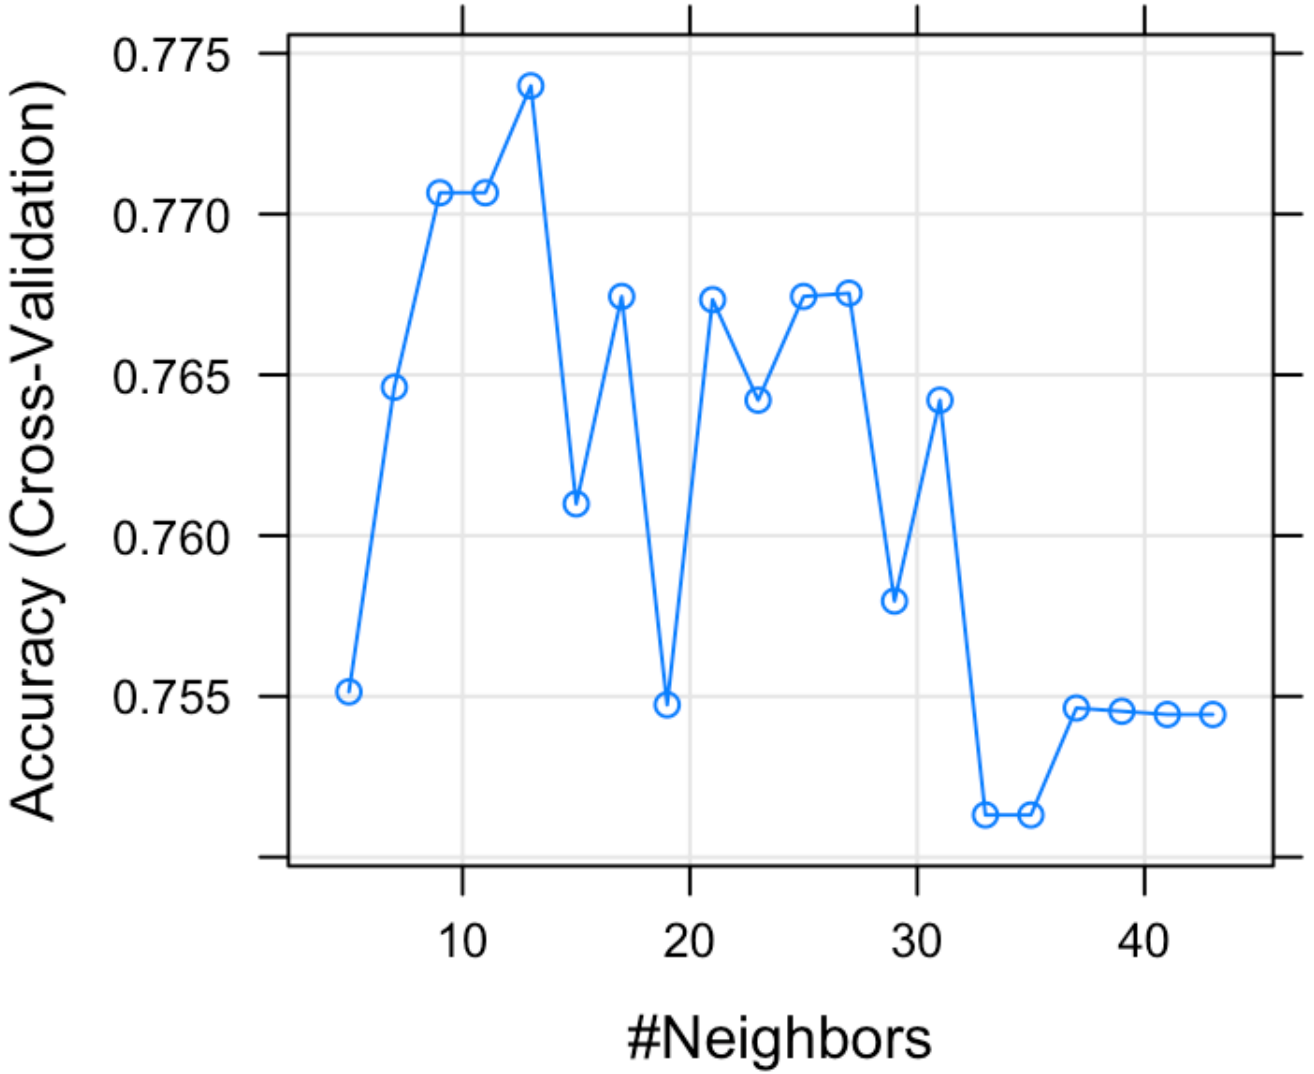




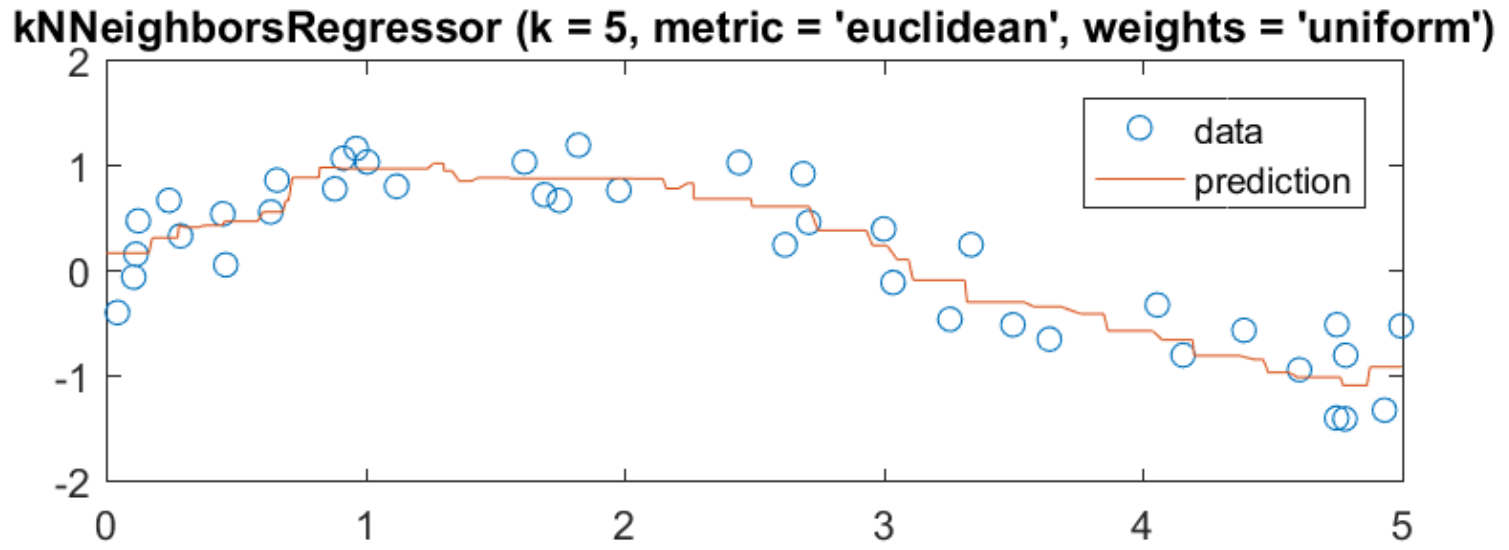


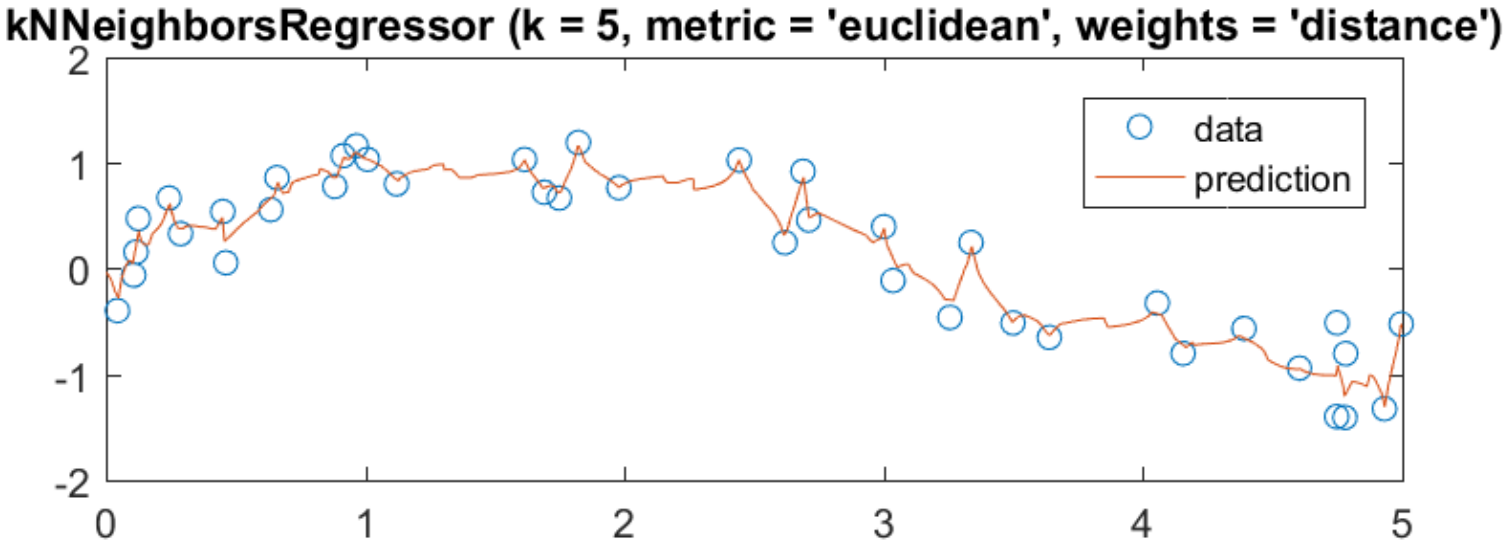


例子： k对kNN回归的影响

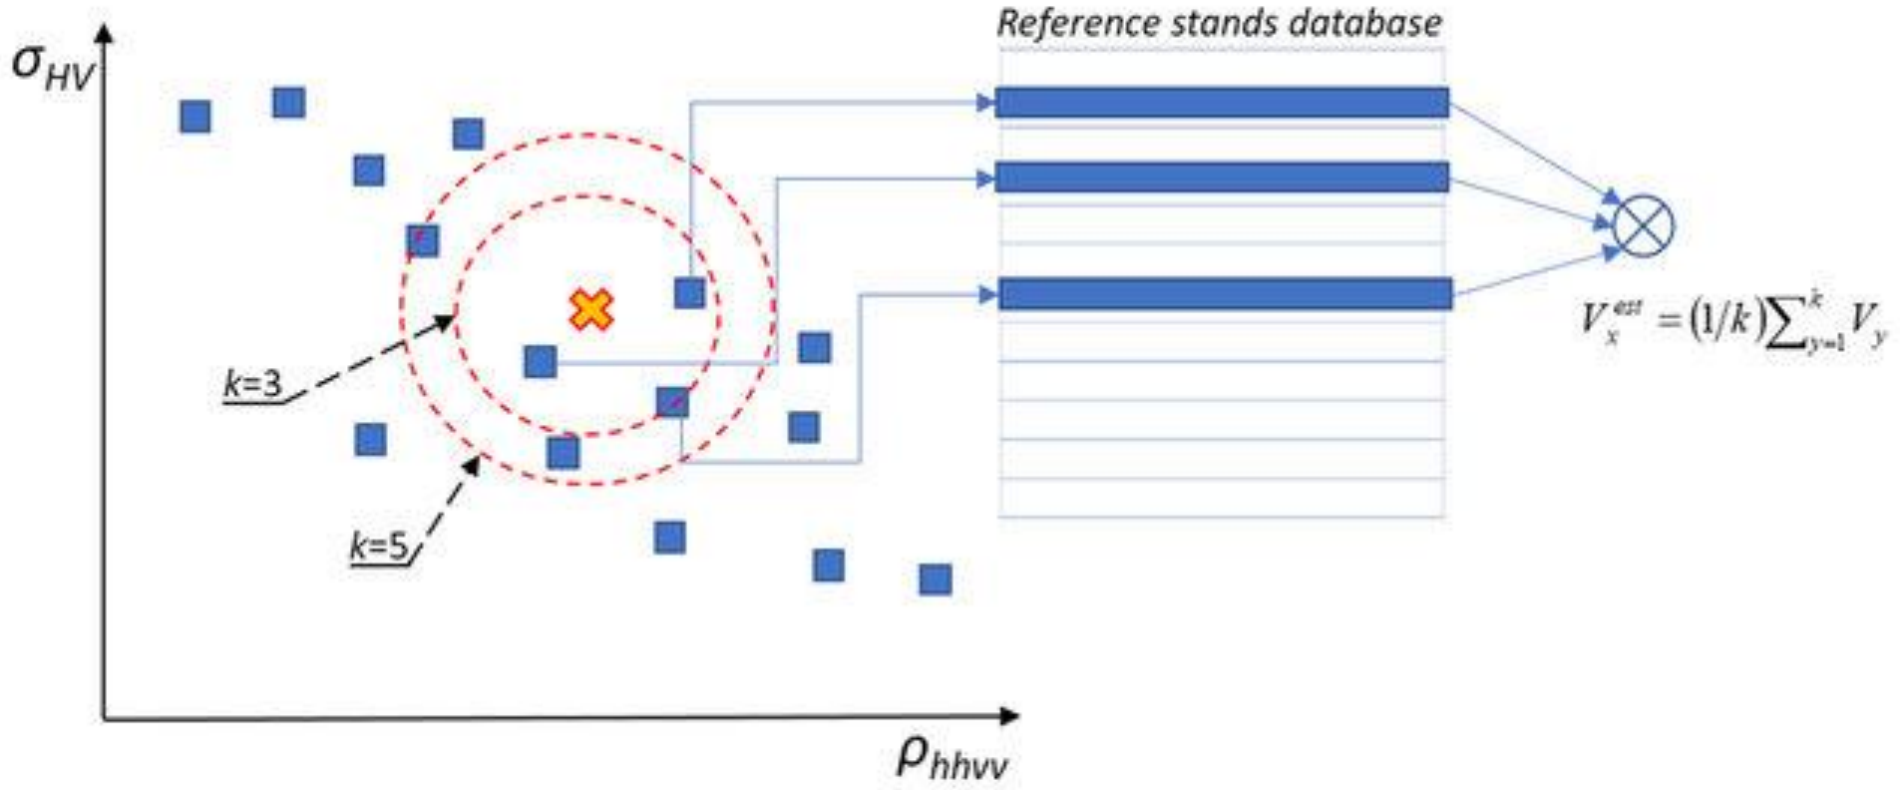


例子： 不同距离函数对kNN回归的影响





例子： kNN回归的加权平均



2. kNN的概述

kNN的含义

- **中文**：k最近邻 （或 k近邻）
- **英文**：k-Nearest Neighbor (kNN)

- **定义**：对于某个给定自变量的样本，找到训练集中距离最近的k个样本（邻居），基于这些邻居的因变量信息来预测该样本的因变量。
- **定位**：kNN属于有监督学习，解决分类或回归问题。属于**懒惰学习**。

kNN算法实现的两个阶段

训练阶段：

- 将每个训练样本保存起来

工作阶段：

- **自变量找最近邻**：给定一个待测样本， 基于某种近邻索引方法找出训练样本集中与其最靠近的k个样本
- **因变量算预测值**：基于这k个训练样本(最近邻)的因变量来预测待测样本的y值

懒惰学习和急切学习

	急切学习	懒惰学习
别名	积极学习	消极学习
英文	eager learning	lazy learning
含义	在训练阶段就对训练样本进行学习处理（训练模型实现参数率定）	没有显式的训练过程（比如在训练阶段只是把训练样本保存起来），建模工作延迟到预测（工作）阶段才进行处理

kNN用于分类的常规步骤

- **算距离**：给定待分类样本，计算它与已分类样本中的每个样本的距离；
- **找邻居**：圈定与待分类样本距离最近的 K 个已分类样本，作为该样本的近邻；
- **做分类**：根据这 K 个近邻中的大部分样本所属的类别来决定待分类样本该属于哪个分类

kNN分类三要素：k值的选择、距离度量和分类决策规则

kNN的特点

假设：

- 在输入空间上相近的样本点具有相似的Y。

优点：

- 不用显式的描述X和Y关系
- 原理简单，与人直观思维接近

缺点：

- 对大数据集问题，直接比较距离导致计算量较大➔近邻索引方法缩小搜索范围
- 对不均衡数据或者异常点敏感➔极值效果较差

kNN的几个重要问题

- 怎么选择k值?
- 怎么选择距离函数?
- 选出的k近邻的观察y怎么预报y?
- 怎么提高kNN的搜索效率?
- kNN与其他方法的结合?

问题1：kNN的k怎么选择?

- **经验**
  1. 不同k值可能导致不同的预测结果
  2. 回归问题中k=2是个很好选择
  3. 分类问题中k选择奇数

- **交叉检验法（试错法）**

  分析训练和验证集性能随着k的变化

  找到拐点

问题2：怎么选择距离函数?

可选的距离函数

连续变量之间：欧式距离、平方欧氏距离、街区距离、切比雪夫距离、马氏距离、闵可夫斯基距离

离散变量之间：Overlap Metric、 Value Difference Metric距离

选择方法

- 经验法
- **交叉检验法（试错法）**：分析训练和验证集性能随着不同距离函数的变化，找到最优选择

问题3：k近邻的y怎么预报y?

- **分类问题**：

  “投票法”获得预测结果

- **回归问题**：

  1）平均法获得预测结果（等权重法）。

  2）基于距离远近进行加权平均或加权投票，距离越近的样本权重越大。

问题4：怎么提高kNN的搜索效率?

- **问题规模：**
  - 大数据集或高维数据：可能需要
  - 小数据集：一般不需要
- **搜索方法：**

  1）kD tree法（把训练样本存储在树的叶子结点上，把待测样本划分到相关的叶子结点上）

  2）基于聚类的kNN（与聚类的中心比较距离，用最近的类中心的类别代替）

问题5：kNN与其他方法的结合?

- **变量选择是必要的**：

  样本间的距离会被大量不相关的属性所支配，从而导致相关属性的值很接近的样本相距很远➔选择最相关的自变量

- **自变量归一化是必要的**：

  某些距离函数对自变量数量级敏感；某些不敏感

- **先聚类后kNN**：

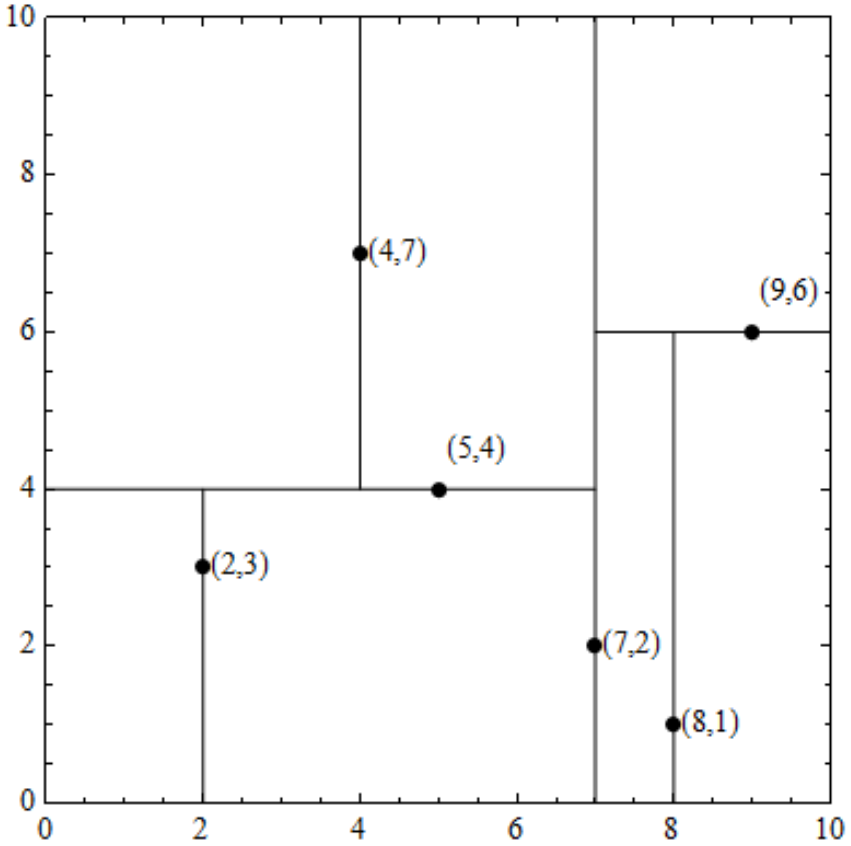
  大数据集的实际应用

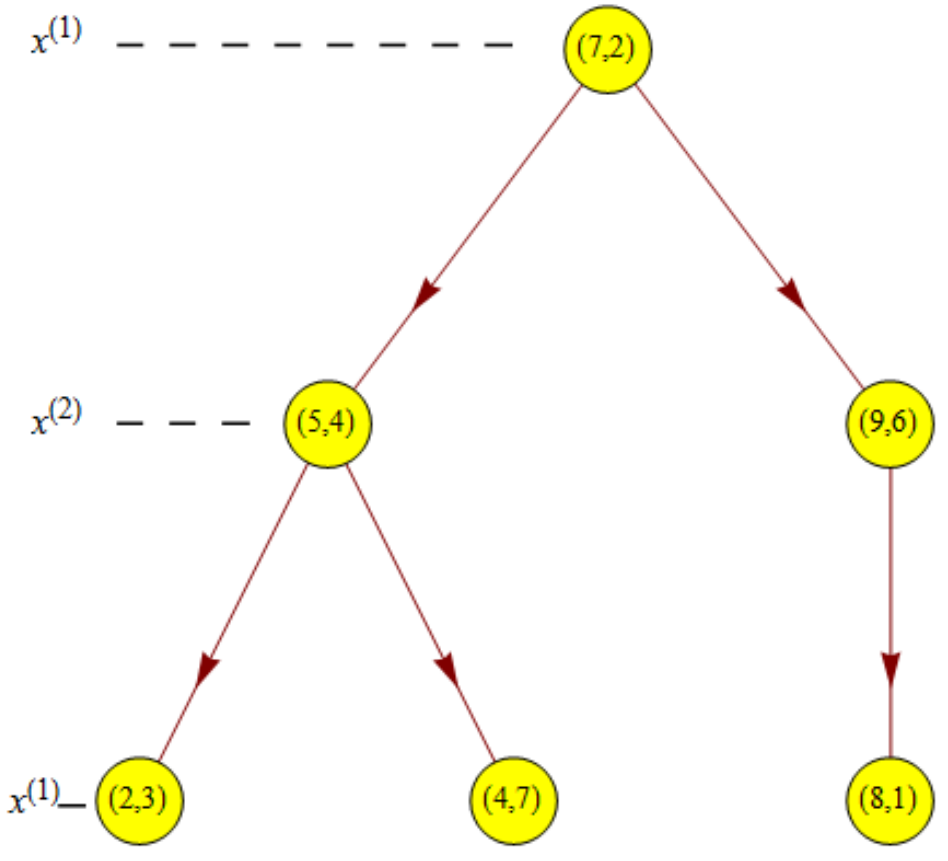
- **类似kNN的层次聚类**：

  求数据点的KNN，当距离小于阈值时，这些点就聚为一类。基于每类的中心点进行迭代。

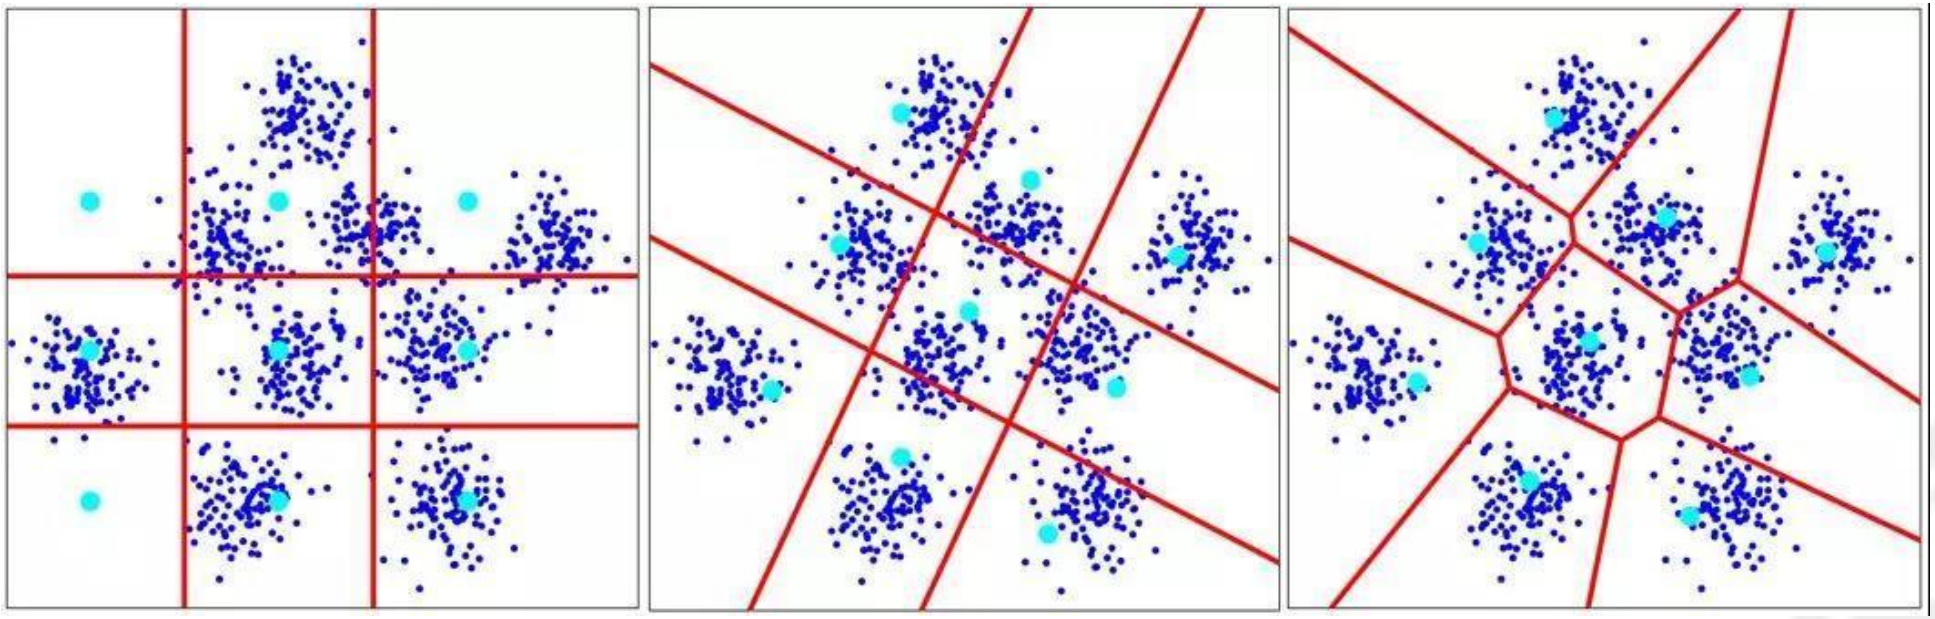
3. 基于kDTree的kNN

例子： 提高搜索效率的2维kd树





例子：基于聚类或向量量化的搜索



https://zhuanlan.zhihu.com/p/54900810

索引树和kD树的定义

- **由来：** 实际数据一般都会呈现簇状的聚类形态，因此可以建立数据索引，进行快速匹配。
- **索引树**：对搜索空间进行层次划分的一种树结构索引方法。
- **kD树（K-Dimensional Tree）：** 一种对K维空间中的实例点进行存储以便对其进行快速检索的**二叉树**形数据结构。
- kD树是索引树中的一种典型的方法。

kD树的结构

构造Kd树： 不断地用垂直于坐标轴的超平面将k维空间切分，构成一系列的k维超矩形区域。Kd树的每个结点对应于一个k维超矩形区域.

空间	类型	描述
dom_elt	树节点	kd维空间中的一个样本点
split	整数	分裂维的序号，也是垂直于分割超面的方向轴序号
left	左kD树	由位于该结点分割超面左子空间内所有数据点构成的左kD树
right	右kD树	由位于该结点分割超面右子空间内所有数据点构成的右kD树

kD树的结构

- 样本集E由kDtree的结点的集合表示，每个结点表示一个样本点，
- dom_elt就是该结点对应样本点。根据该结点的分割超平面将样本空间分为两个子空间。
- 分割超平面是一个通过点dom_elt并且垂直于split所指示的方向轴的平面
- 左子空间中的样本点集合由左子树left表示，
- 右子空间中的样本点集合由右子树right表示。

kD树的生成步骤

① **确定分割轴**（split值）：方差最大值（或最大和最下值的距离的最大值）对应的坐标轴（维）为split值

② **确定节点**：数据在split值对应轴上进行排序，中位数选为分割结点（dom_elt)

③ **左右子空间**：节点分割超平面为两部分

④ **迭代**：分别对左右子空间中的数据点重复上面的步骤，构建左右子树，直到经过划分的子样本集为空或者子样本集的样本数小于Bucksize。

基于kDTree的kNN步骤

① **搜索kD树：** 比较待查样本和节点的分裂维的值，小等于进左树，大于进右树，直到叶子

② **找到候选kNN**：计算与同一个子空间的叶子结点中样本与待查样本距离；

③ **回溯搜索路径：** 判断搜索路径上其他子结点空间中是否有距离查询点更近数据点。如果有可能，则需要跳到其他子结点空间中去搜索（将其他子结点加入到搜索路径）

④ **重复这个过程：** 直到搜索路径为空或者在搜索路径上找到k个最近邻即结束

4. kNN的实现

kNN的MATLAB 实现：3-1，3-2种方法

方法	主要命令	含义
1A	knnsearch或rangesearch	直接接受训练数据集和查询数据集作为输入
1B	ExhaustiveSearcher 或KDTreeSearcher 或createns（二合一）	穷举法或KD树法，基于训练数据集创建搜索器对象，存储这些数据集的共同信息（如存储 Kd 树）
	knnsearch或rangesearch	当您有多个查询数据集时，最好创建搜索器对象，然后将该对象和查询数据集传递给对象函数
2	矩阵运算 （如mean）	根据找到k个近邻进行投票或加权平均，获得预测的类别或具体数值

knnsearch函数的调用格式1A

格式	用途
Idx = knnsearch(X,Y)	为 Y 中的每个查询点找到 X 中的最近邻，并返回 Idx（列向量）中最近邻的索引。Idx 的行数与 Y 相同。
Idx = knnsearch(X,Y,Name,Value)	使用一个或多个名称-值的成对参数来指定附加选项。 例如，您可以指定要搜索的最近邻数和搜索中使用的距离度量。
[Idx,D] = knnsearch(___)	D 包含 Y 中的每个观测值与 X 中相应的最近观测值之间的距离。

注意：Y 是待测样本的自变量； X 是（已知）训练样本的自变量；不涉及因变量。

knnsearch函数的调用格式1B

格式	用途
Idx = knnsearch (Mdl,Y)	使用穷尽搜索或kd树，在Mdl.X中搜索到查询数据Y中的每个点的最近邻(即最近点、行或观察)，Idx是最近邻的索引列向量。
Idx = knnsearch(Mdl, Y,Name,Value)	返回Mdl中最近点的索引。X到Y，通过一个或多个名称、值参数对，指定附加选项。例如，指定要搜索的最近邻居的数量，与存储在Mdl.Distance中的不同距离度量，当最接近的距离相等时如何处理等。
[Idx,D] = knnsearch(___)	D 包含 Y 中的每个观测值与 X 中相应的最近观测值之间的距离。

注意：Mdl是采用穷举法或KD树法创建的搜索器对象（包含X）；Y 是待测样本的自变量。

使用穷举法还是Kdtree方法搜索?

- 数据有很多列(超过 10 列) ➔穷举法可能更好。
- 数据稀疏（很多值是零）➔使用穷举法。
- 特定距离（‘seuclidean’、‘mahalanobis’、‘cosine’、‘correlation’、‘spearman’、‘hamming’、‘jaccard‘或自定义）来查找最近邻吗? ➔使用穷举法
- 数据集庞大, 但少于 10 列 ➔ 使用 KDTree。
- 查询数据集庞大（大量查询点搜索） ➔使用 KDTree

ExhaustiveSearcher函数的调用格式

Mdl 是一个 ExhaustiveSearcher 模型对象，用于存储穷举最近邻搜索所需的统计信息和选项。要在训练数据中搜索查询数据的最近邻，请将查询数据和 Mdl 传递给 knnsearch 或 rangesearch。

格式	用途
Mdl = ExhaustiveSearcher(X)	一个穷举的最近邻搜索器 (Mdl)，在n×K的训练数据 (X) 矩阵中，查找查询数据的最近邻。
Mdl = ExhaustiveSearcher(X,Name,Value)	由一个或多个 Name,Value 对参数指定的附加选项。 例如，您可以指定距离度量或距离度量参数值。

KDTreeSearcher函数的调用格式

当K很小（即K≤10），训练集和查询集不稀疏，训练集和查询集有很多观察值时，Kd-tree算法比穷举搜索算法效率更高。

格式	用途
Mdl = KDTreeSearcher(X)	使用n×K的训练数据矩阵(X) 生成默认 Kd 树(Mdl)。
Mdl = KDTreeSearcher(X,Name,Value)	使用一个或多个名称-值对参数指定其他选项。 可指定每个叶节点的最大数据点数（即桶大小）和距离度量，并设置距离度量参数（DistParameter）属性。
KDTreeSearcher(X,'Distance','minkowski','BucketSize',10)	指定在搜索最近邻时使用 Minkowski 距离，并使用 10 作为叶节点最大样本数。 要指定 DistParameter，请使用 P 参数。

rangesearch函数的调用格式

格式	用途
Idx = rangesearch(X,Y,r)	找到所有在 Y 点距离 r 内的 X 点。 X 和 Y 的行对应于观测值，列对应于变量。
[Idx,D] = rangesearch(X,Y,r)	返回距离 r 内的 Y 点和 X 点之间的距离。
[Idx,D] = rangesearch(X,Y,r,Name,Value)	使用一个或多个名称-值的成对参数，用于指定其他选项。 例如，指定最近邻搜索方法和搜索中使用的距离度量。

kNN的MATLAB 实现方法3-3

方法	主要命令	含义
两步法	fitcknn	训练 k 最近邻模型
	predict	以预测标签或估计后验概率。

注意：
1）模型构建的共同角度出发
2）用于分类或回归

fitcknn函数的调用格式

格式	用途
Mdl = fitcknn(Tbl,ResVarName)	返回基于表Tbl中的输入变量(也称为预测器、特征或属性)和输出(响应)Tbl.resvarname的kNN分类模型（Mdl）。
Mdl = fitcknn(Tbl,formula)	返回基于表Tbl中的输入的kNN分类模型（Mdl）；formula是变量响应的解释模型，是Tbl中预测变量的子集。。
Mdl = fitcknn(___,Name,Value)	使用任何前面的语法，用一个或多个名称-值的参数对指定的附加选项适合模型。例如，可以指定断开连接算法、距离度量或观察权重。

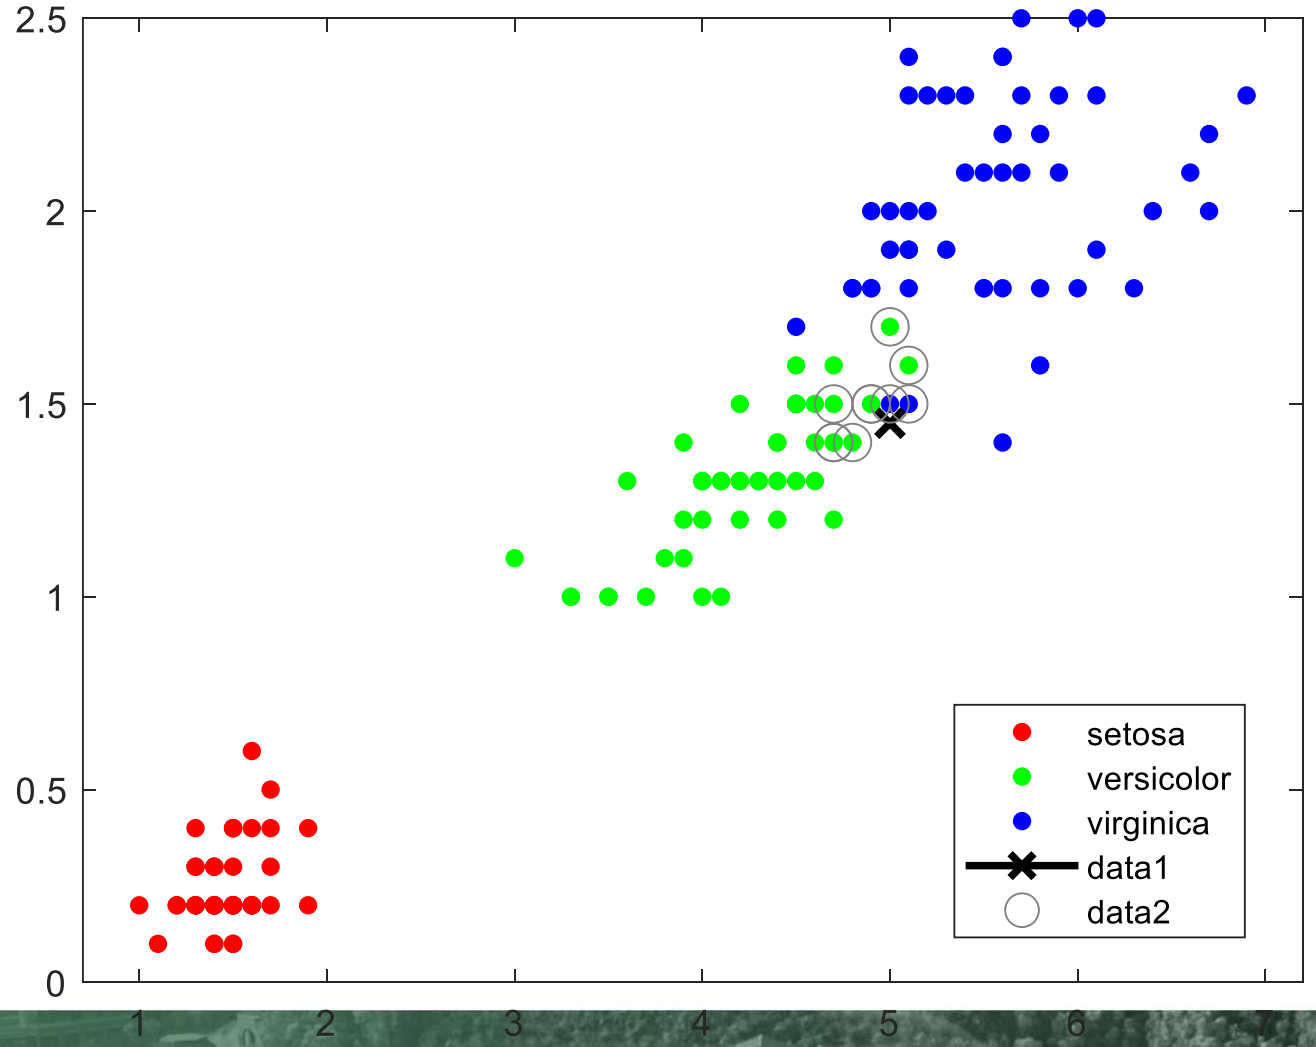
Mdl是kNN分类模型；Tbl是训练样本的自变量；ResVarName 是训练样本的的因变量（标签）。

5. 案例研究

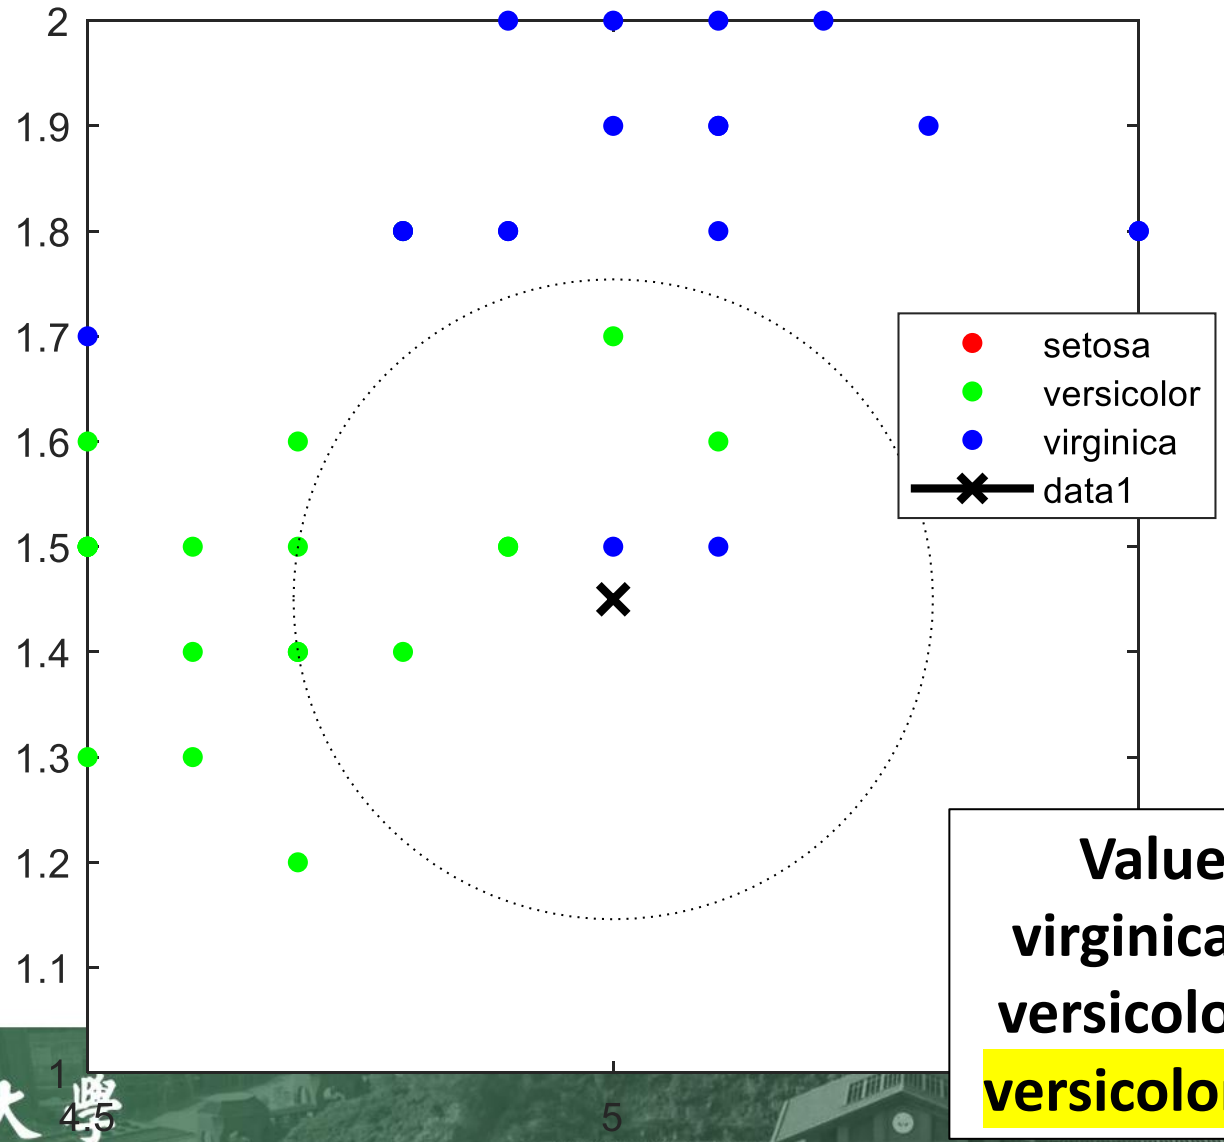
案例问题1：鸢尾花的kNN分类

- **数据**：20 世纪 20 年代，植物学家收集了 150 个鸢尾花标本（三个品种各取 50 个标本）的萼片长度、萼片宽度、花瓣长度和花瓣宽度的测量值。这些测量值被称为 Fisher 鸢尾花数据集。
- **问题**：对给定1个和3个新样本点，基于最后2个属性进行鸢尾花分类。
- **代码**：
- 中文注释和修改版：kNN_exp01.m
- 英文注释：
  openExample('stats/ClassifyingQueryDataUsingKnnsearchExample')

一个样本点的分类


2.5
2
1.5
1
0.5
0
1
2
3
4
5
6
7
setosa
versicolor
virginica
data1
data2

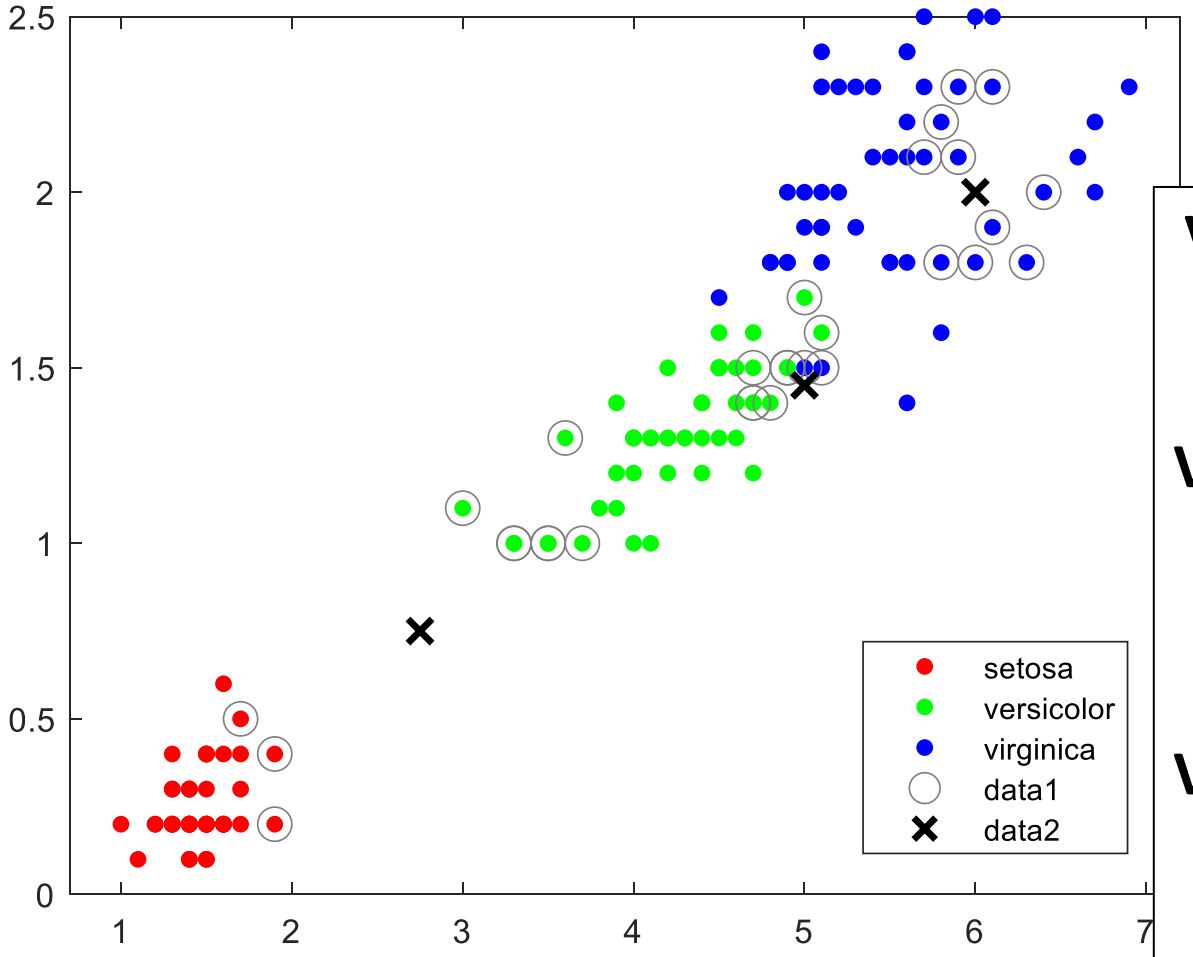
一个样本点的分类



Value	Count	Percent
virginica	2	20.00%
versicolor	8	80.00%

versicolor两个点被覆盖

3个样本点的分类



Value	Count	Percent
virginica	10	100%

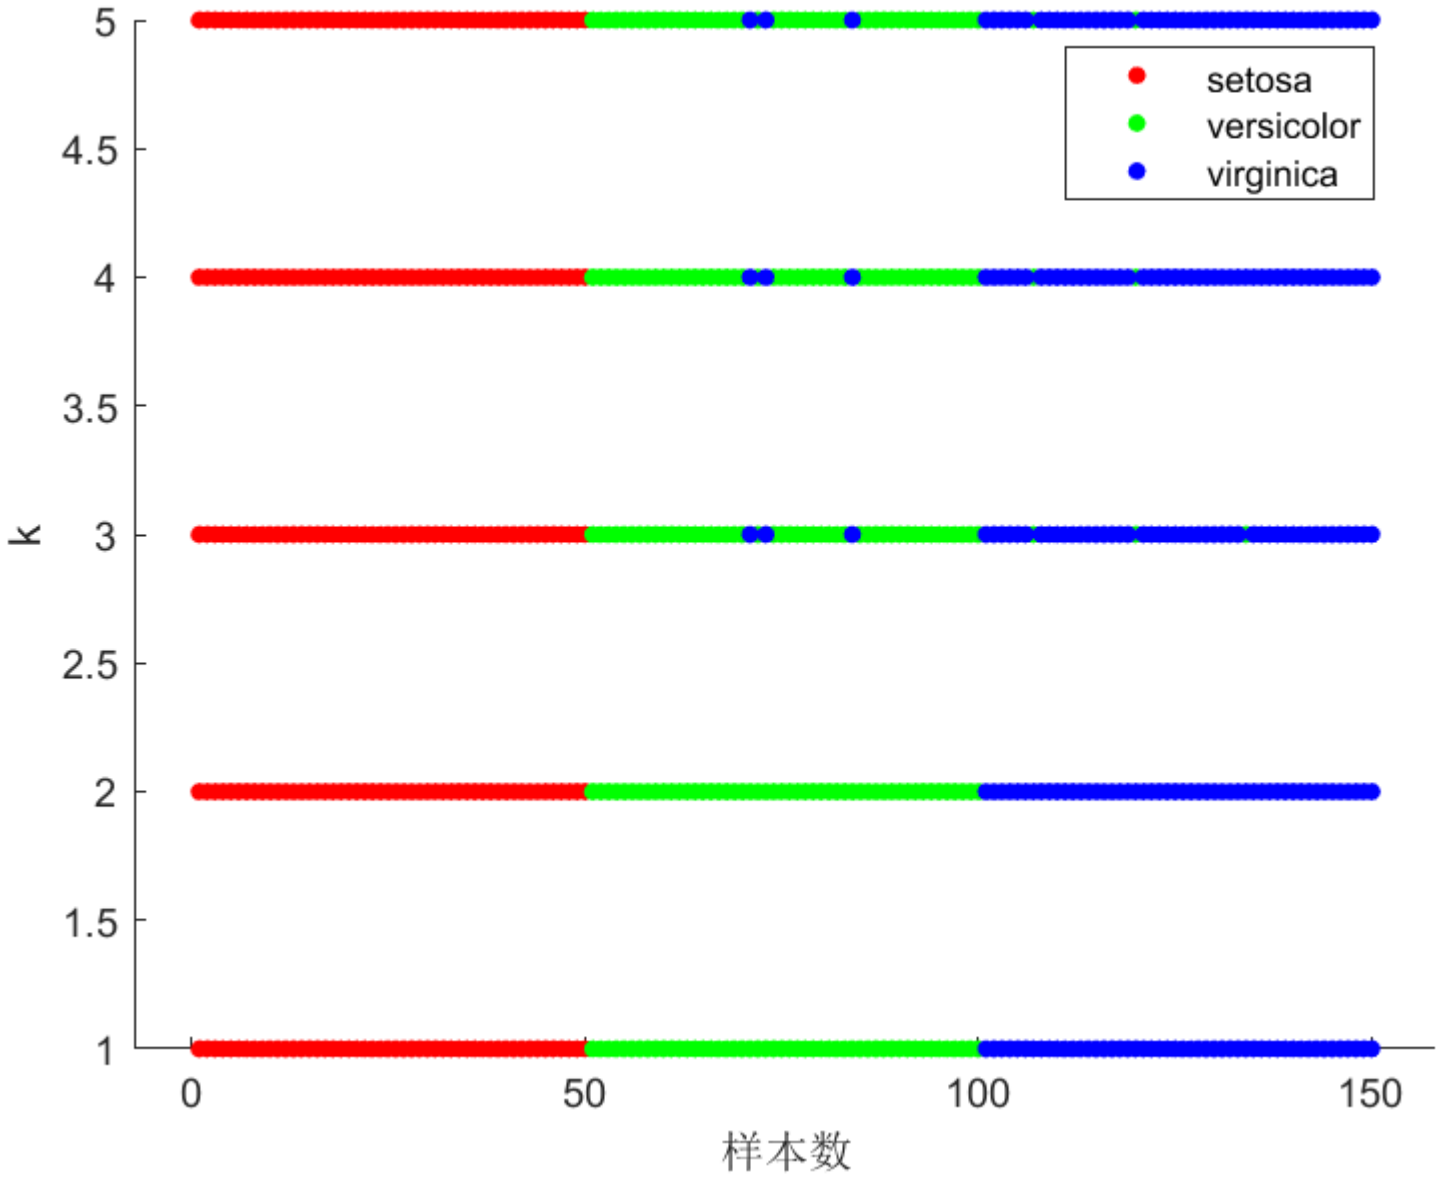
Value	Count	Percent
virginica	2	20%
versicolor	8	80%

Value	Count	Percent
versicolor	7	70%
setosa	3	30%

案例问题2：鸢尾花的kNN分类

- **数据**：20 世纪 20 年代，植物学家收集了 150 个鸢尾花标本（三个品种各取 50 个标本）的萼片长度、萼片宽度、花瓣长度和花瓣宽度的测量值。这些测量值被称为 Fisher 鸢尾花数据集。
- **问题**：以所有数据集为训练集，基于4个属性进行鸢尾花分类。观察k对模型性能影响。
- **代码**：
- 中文注释和修改版：kNN_exp01.m

k对模型性能影响


5
4.5
4
3.5
3
2.5
2
1.5
1
k
0
50
100
150
样本数
setosa
versicolor
virginica

6. 小结

使用穷举法还是Kdtree方法搜索?

- 数据有很多列(超过 10 列) ➔穷举法可能更好。
- 数据稀疏（很多值是零）➔使用穷举法。
- 特定距离（‘seuclidean’、‘mahalanobis’、‘cosine’、‘correlation’、‘spearman’、‘hamming’、‘jaccard‘或自定义）来查找最近邻吗? ➔使用穷举法
- 数据集庞大, 但少于 10 列 ➔ 使用 KDTree。
- 查询数据集庞大（大量查询点搜索） ➔使用 KDTree

kNN的MATLAB 实现方法

方法	主要命令	含义
1A	knnsearch或rangesearch	直接接受训练数据集和查询数据集作为输入
1B	ExhaustiveSearcher 或KDTreeSearcher 或createns（二合一）	穷举法或KD树法，基于训练数据集创建搜索器对象，存储这些数据集的共同信息（如存储 Kd 树）
	knnsearch或rangesearch	当您有多个查询数据集时，最好创建搜索器对象，然后将该对象和查询数据集传递给对象函数
2	矩阵运算 （如mean）	根据找到k个近邻进行投票或加权平均，获得预测的类别或具体数值

kNN的MATLAB 实现方法

方法	主要命令	含义
两步法	fitcknn	训练 k 最近邻模型
	predict	以预测标签或估计后验概率。

思考题

- kNN的功能?
- kNN的特点?
- 怎么选择kNN的搜索策略?
- 怎么选择kNN的k?
- 用k还是邻域半径来选择最近邻?

延伸阅读

Matlab官网中关于kNN分类的介绍

https://ww2.mathworks.cn/help/releases/R2021b/stats/classification-nearest-neighbors.html

Fisher 鸢尾花数据的kNN分类

https://ww2.mathworks.cn/help/releases/R2021b/stats/classification-using-nearest-neighbors.html

Python的scikit-learn 包关于kNN的介绍

https://scikit-learn.org/stable/modules/neighbors.htm