人工智能与地理数据挖掘

第八讲 决策树

孙伟 sunwei29@mail.sysu.edu.cn

地理科学与规划学院

中山大學 SUN YAT-SEN UNIVERSITY

2026.5

数据挖掘/机器学习的典型方法

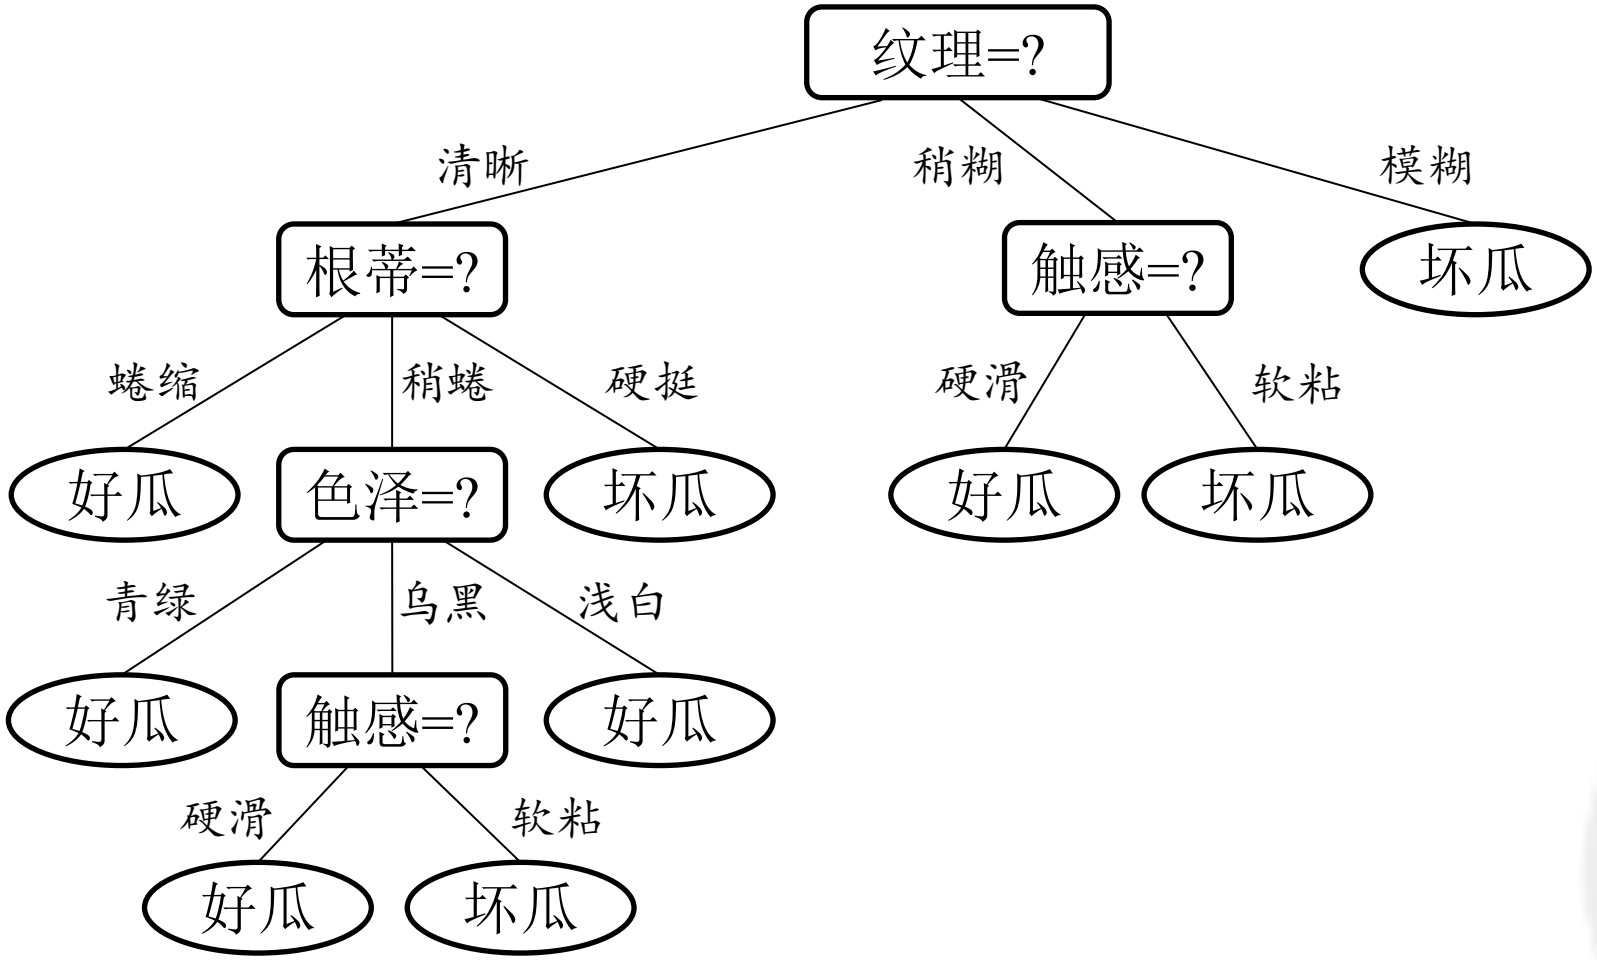
类别	聚类/降维	回归	分类	生成
线性方法	相关性 主成分分析 因子分析	多元线性回归	Logistic回归 判别分析	
最近邻	k均值聚类	kNN		
树型	层次聚类	决策树： 回归树	决策树： 分类树	深度 森林
密度	DBSCAN			
神经网络	SOM	ANN		
核函数		SVM（SVR）	SVM（SVC）	
图论	谱聚类	概率图模型	概率图模型	GNN
随机变量	高斯混合		贝叶斯分类	GAN
模糊数	模糊C 均值聚类	模糊逻辑模型 ANFIS	模糊逻辑模型	FDNN
深度学习	自动编码器	CNN，LSTM、Transformer		

主要内容

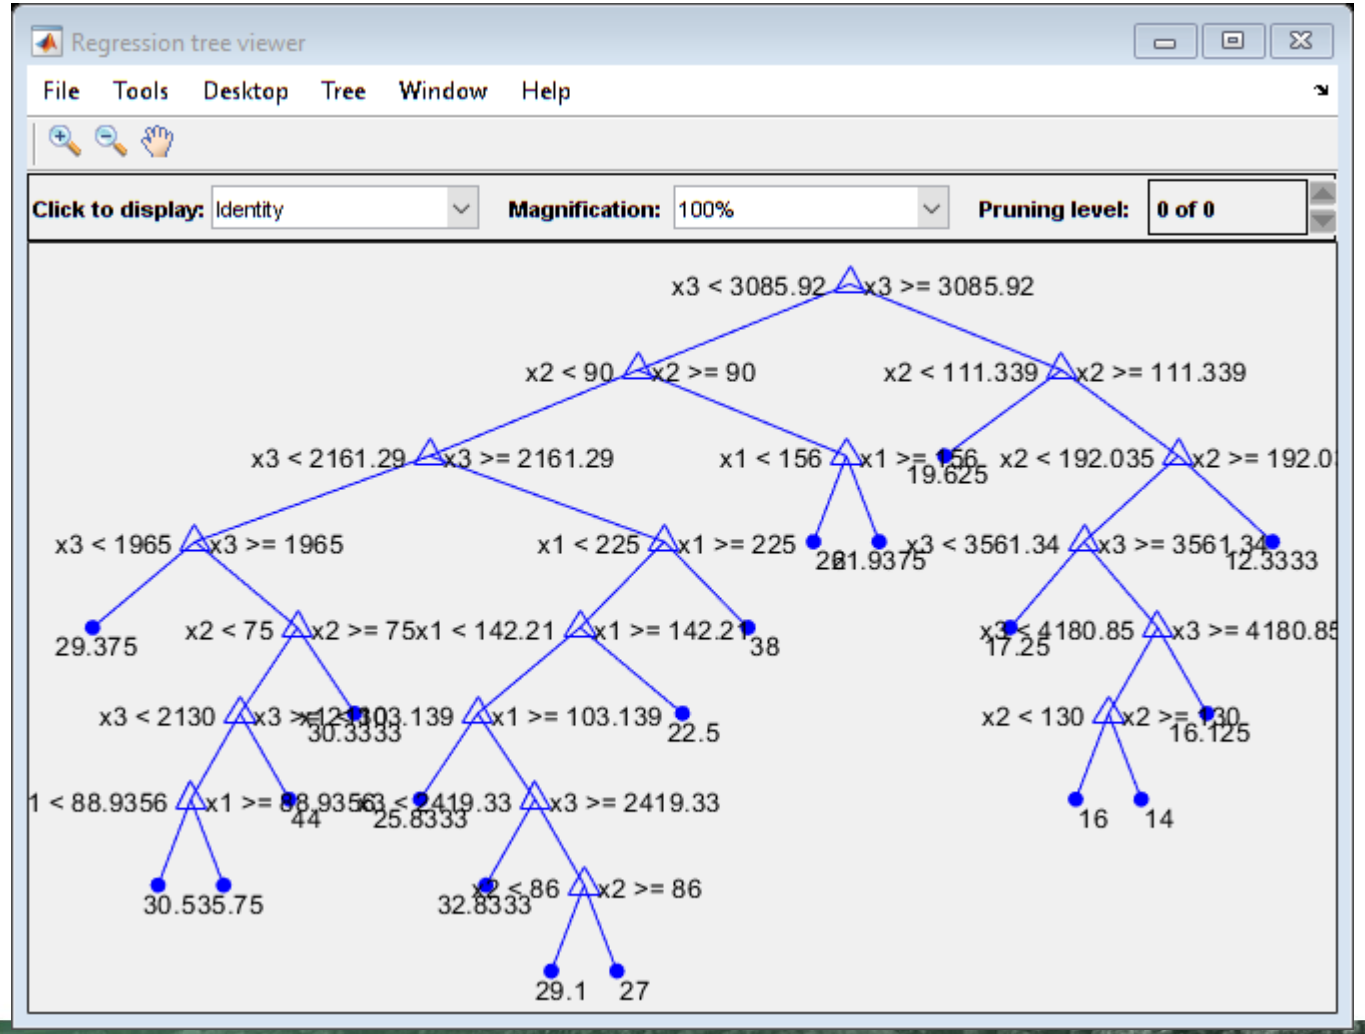
1. 决策树的实例
2. 决策树的简介
3. 典型的决策树模型
4. 决策树的剪枝处理
5. 决策树的改进
6. 决策树构建
7. 小结

决策树的实例

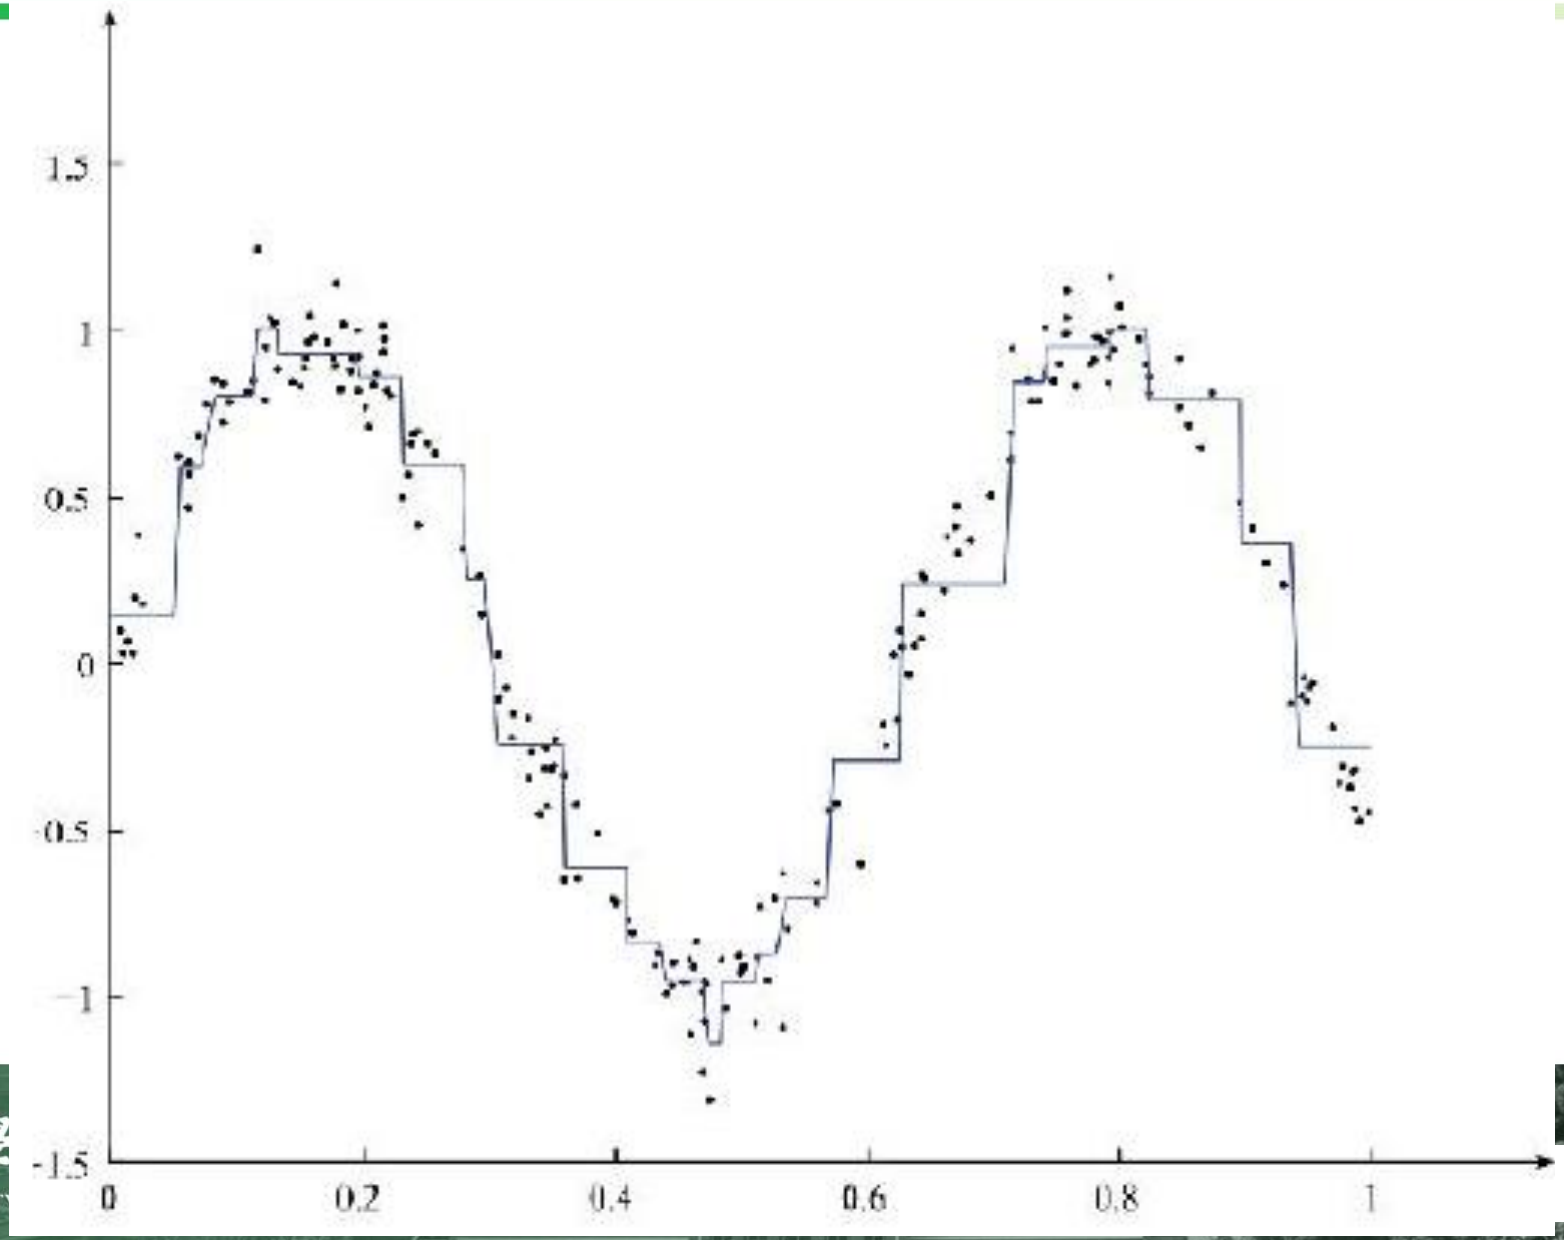
决策树分类：挑西瓜


纹理=?
清晰
稍糊
模糊
根蒂=?
触感=?
坏瓜
蜷缩
稍蜷
硬挺
硬滑
软粘
好瓜
色泽=?
坏瓜
好瓜
坏瓜
青绿
乌黑
浅白
好瓜
触感=?
好瓜
硬滑
软粘
好瓜
坏瓜

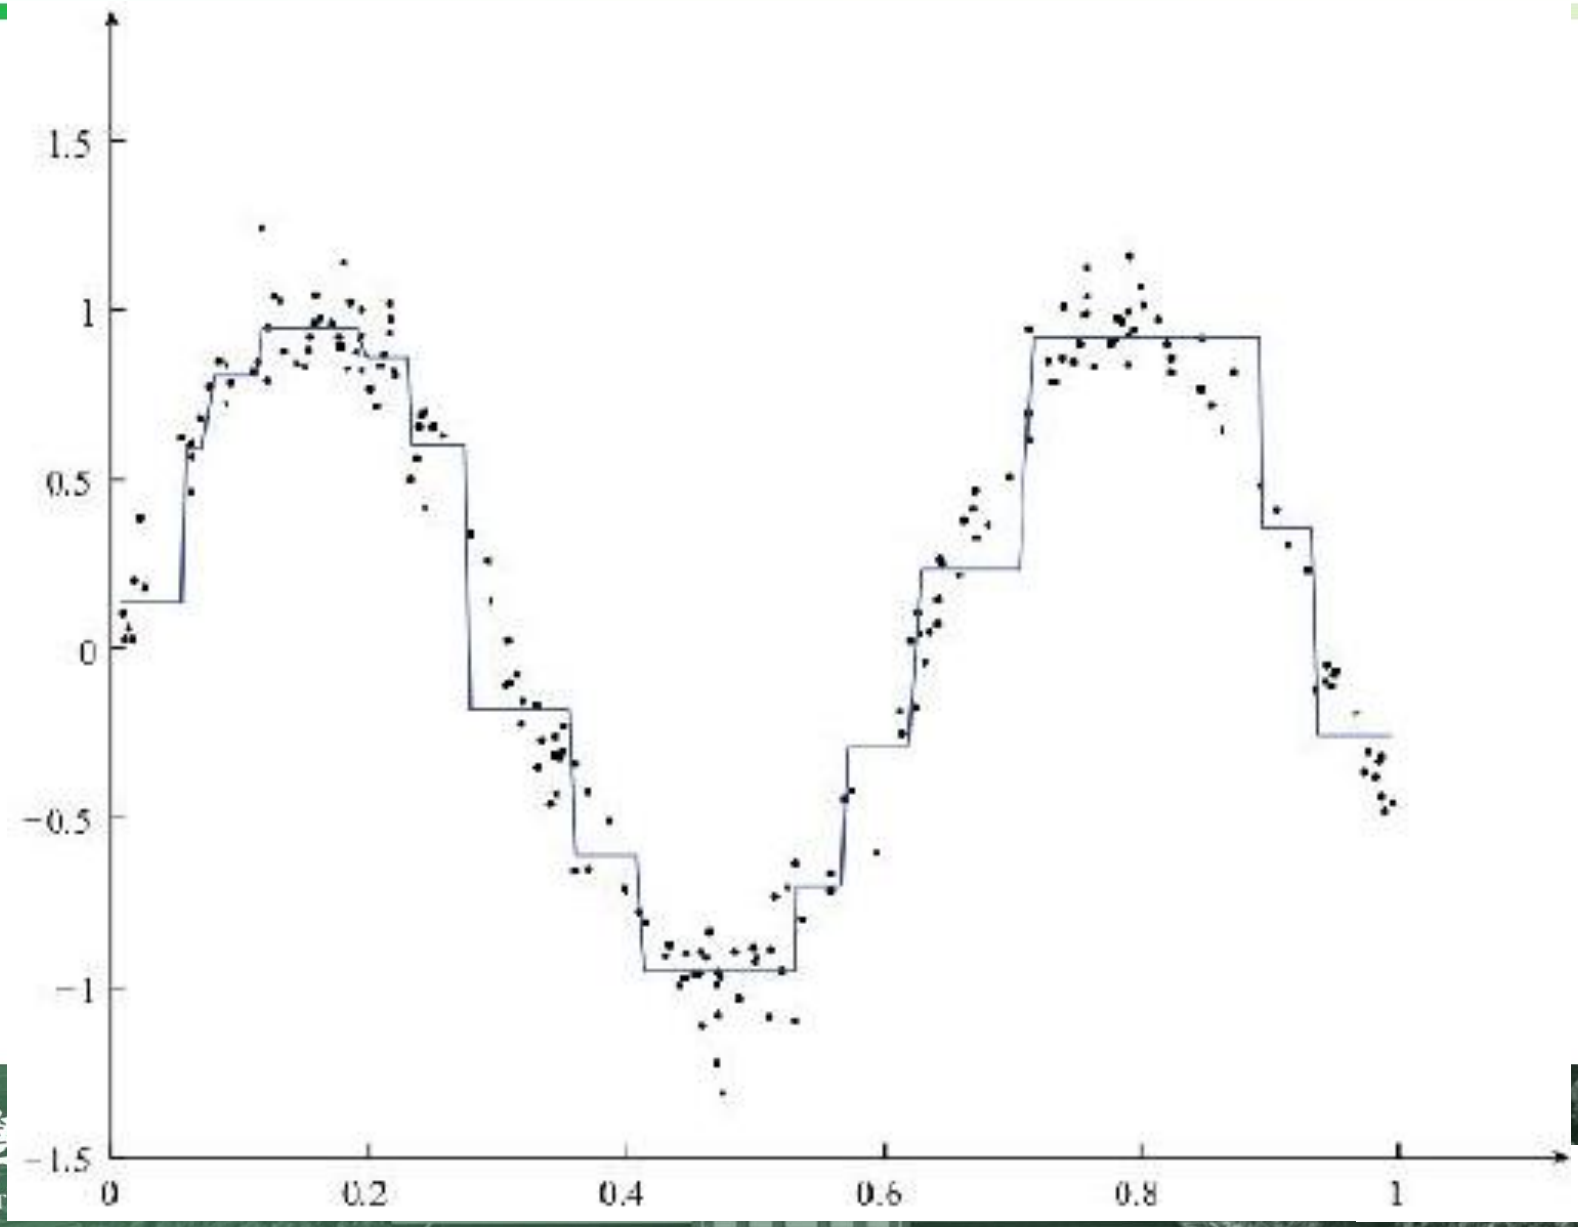
决策树回归


Regression tree viewer
File Tools Desktop Tree Window Help
Click to display: Identity
Magnification: 100%
Pruning level: 0 of 0
x3 < 3085.92
x3 >= 3085.92
x2 < 90
x2 >= 90
x2 < 111.339
x2 >= 111.339
x3 < 2161.29
x3 >= 2161.29
x1 < 156
19.625
x2 < 192.035
x3 < 1965
x3 >= 1965
x1 < 225
x1 >= 225
x3 < 3561.34
x3 >= 3561.34
12.3333
29.375
x2 < 75
x2 >= 75
x1 < 142.21
x1 >= 142.21
38
17.25
x3 < 2130
30.3333
x1 >= 103.139
22.5
x2 < 130
16.125
44
25.8333
x3 >= 2419.33
16
14
30.5
35.75
32.8333
x2 >= 86
29.1
27

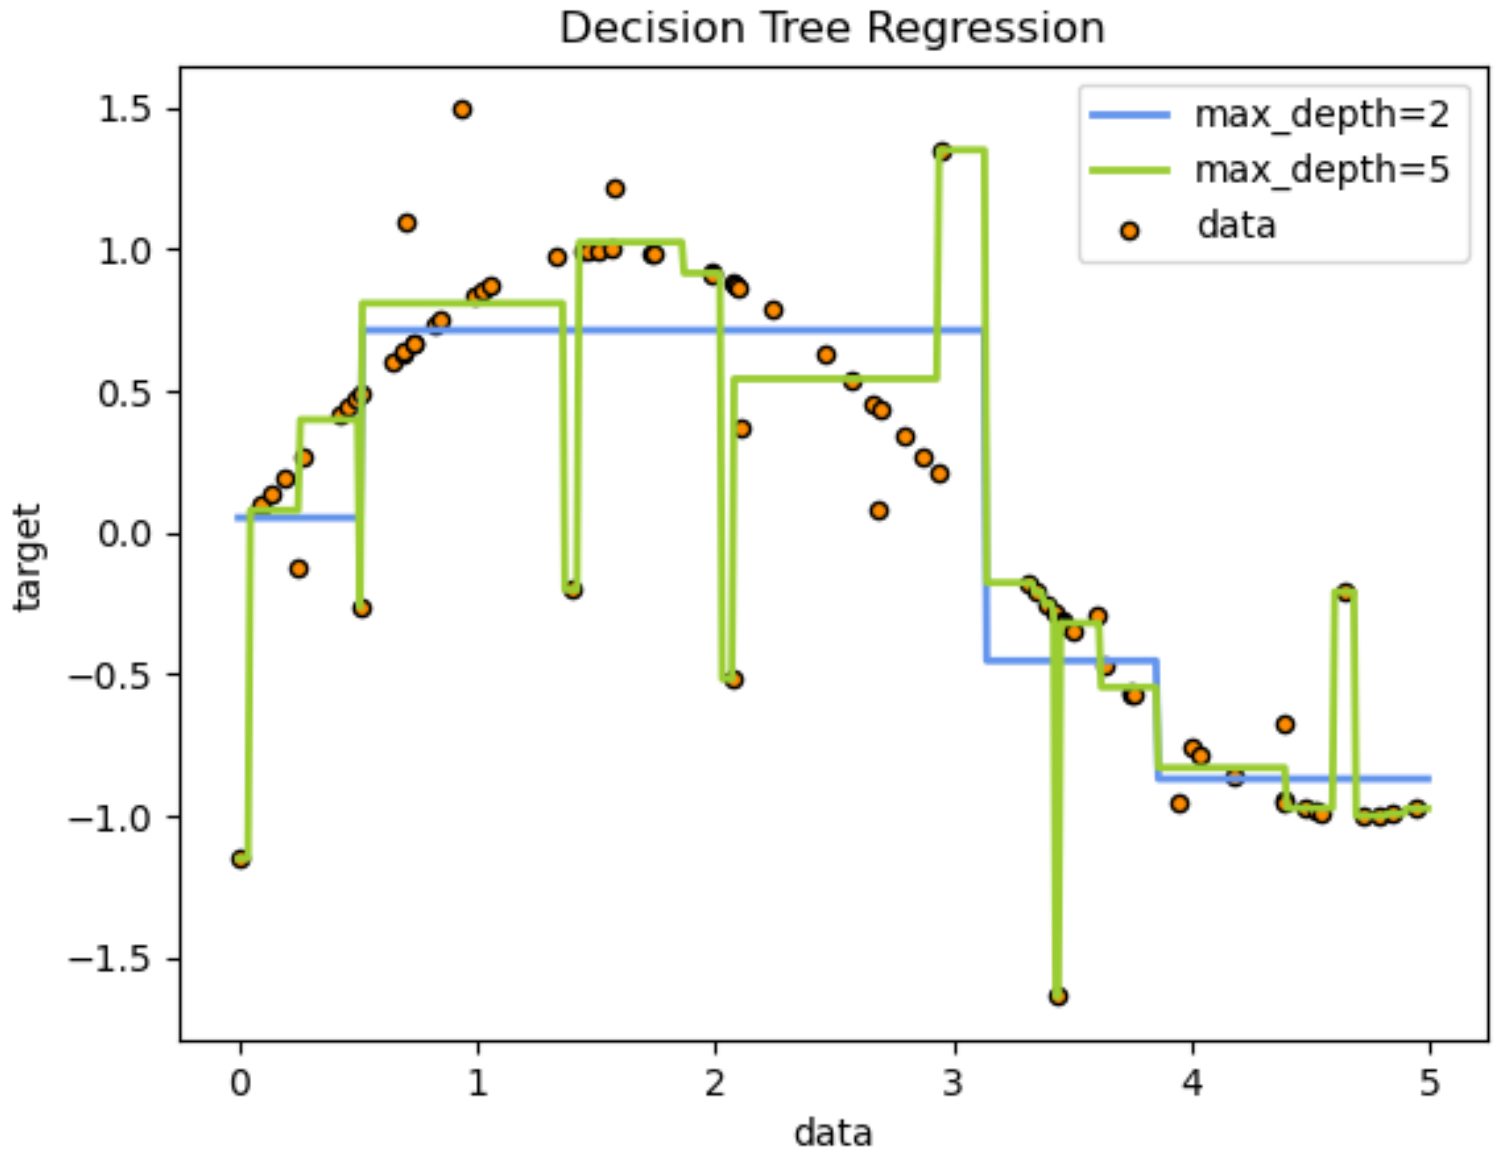
决策树回归效果与树深度关系



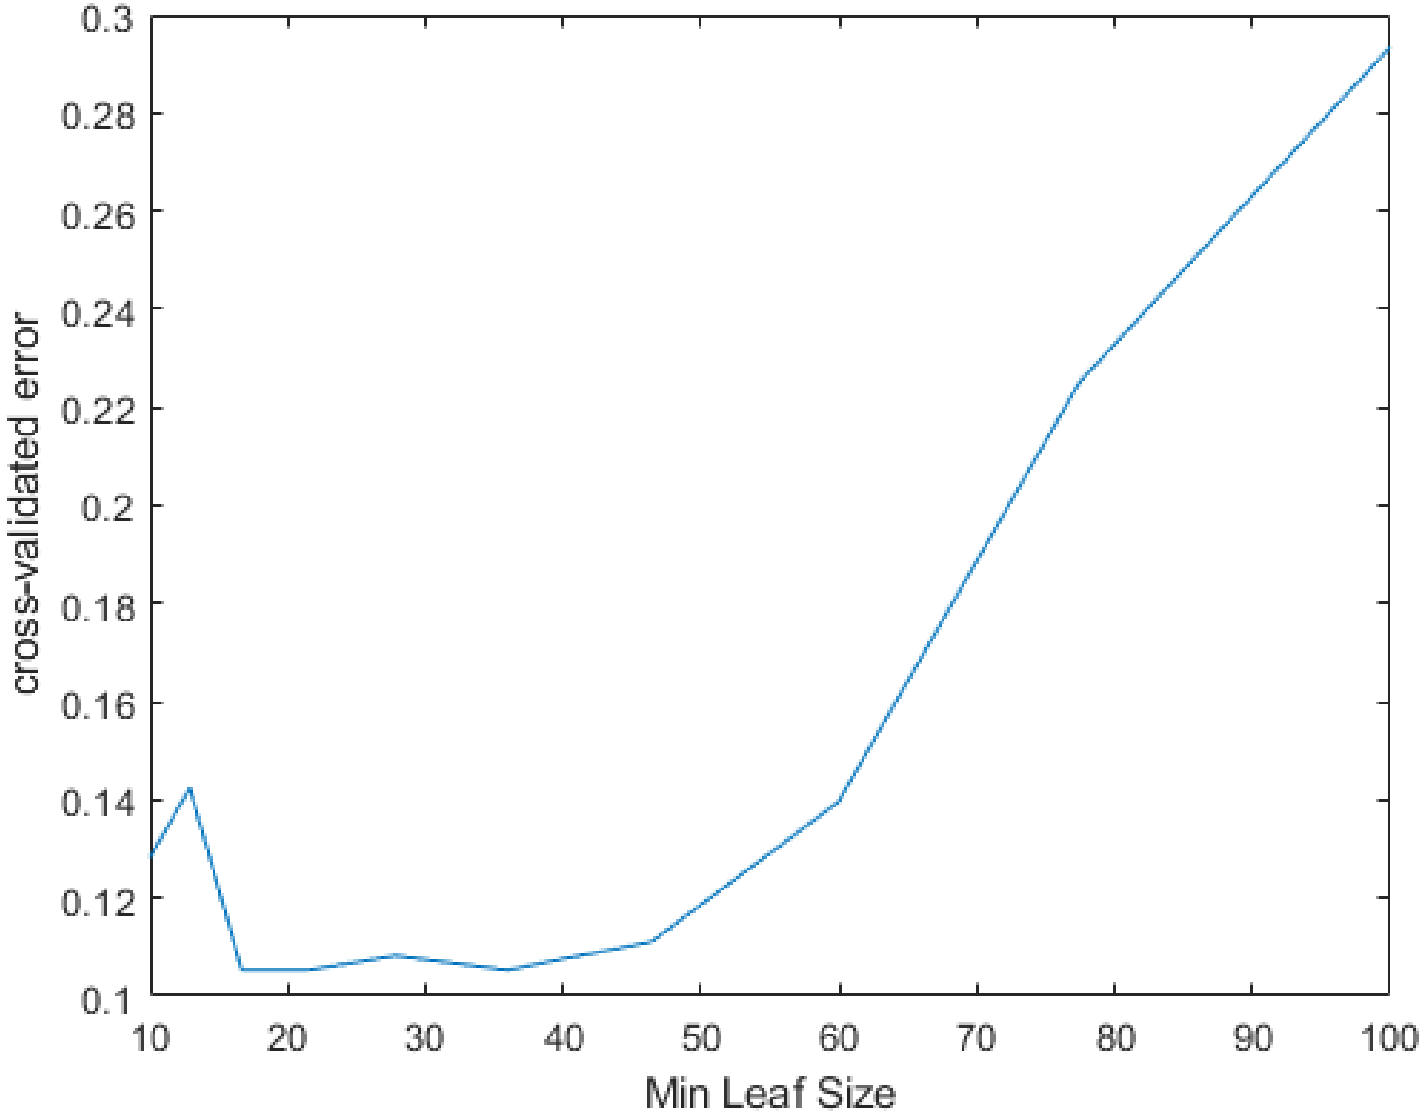
决策树回归效果与树深度关系



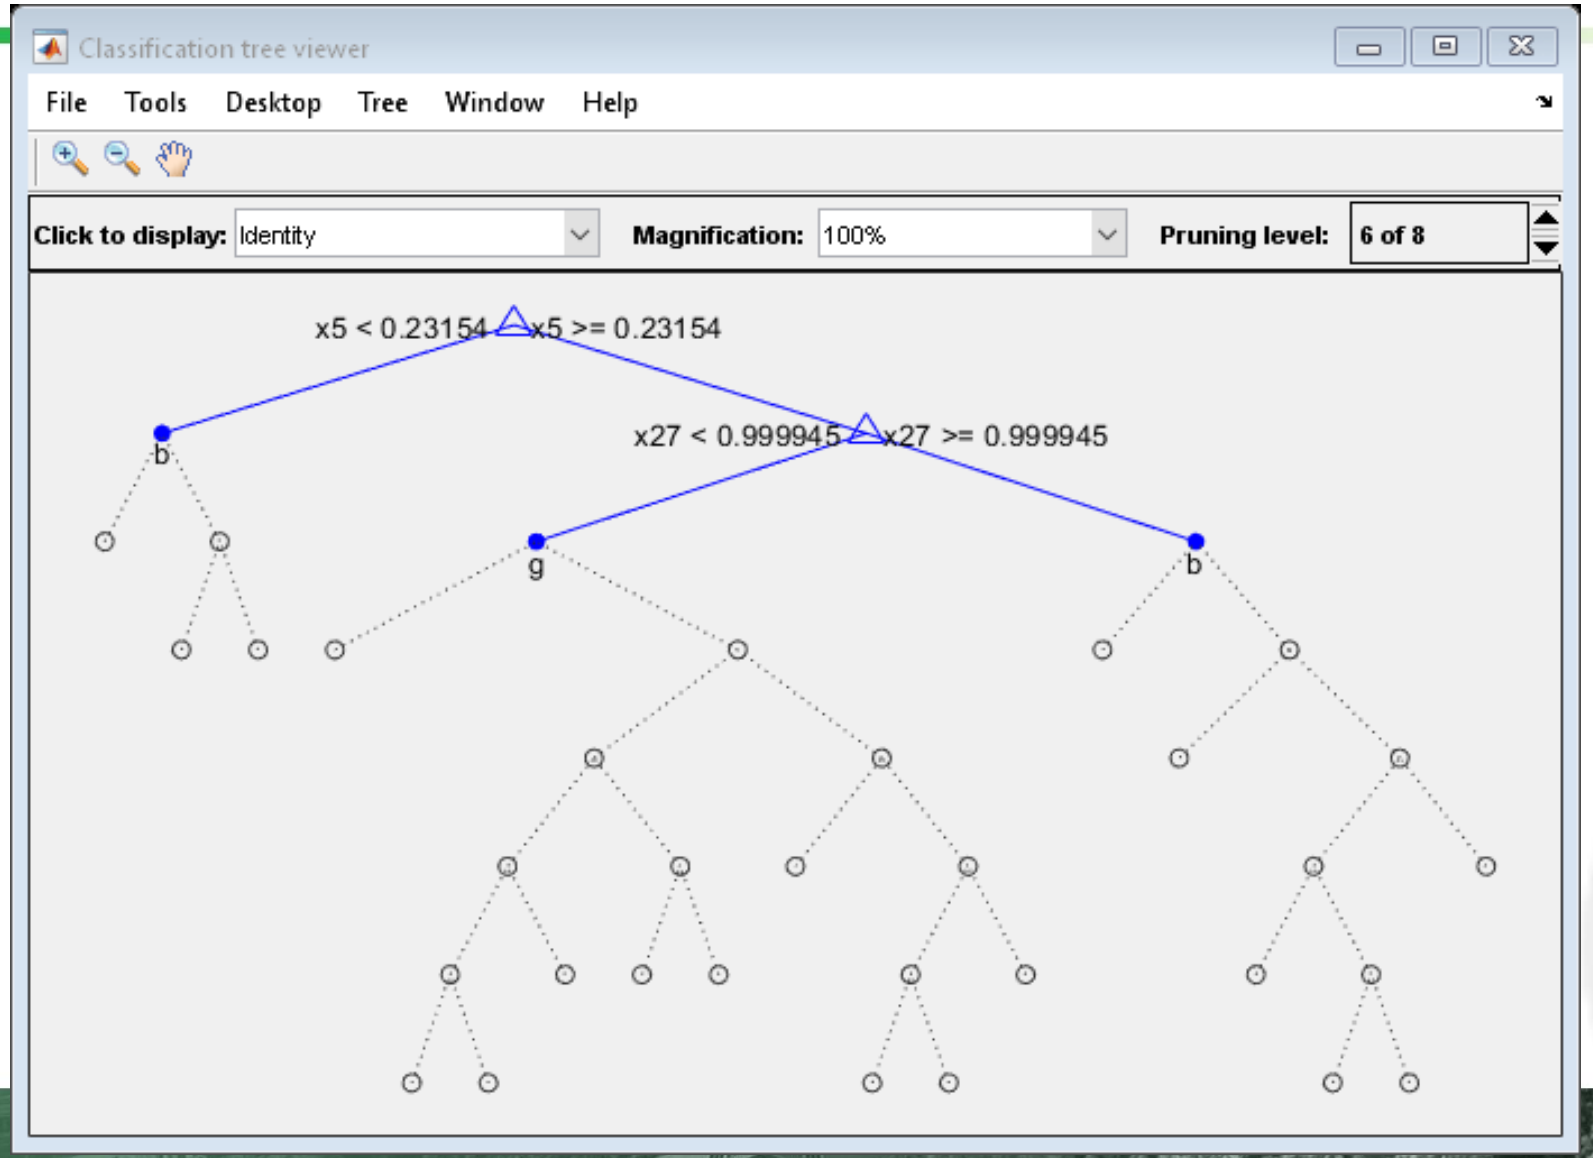
决策树回归效果与树深度关系



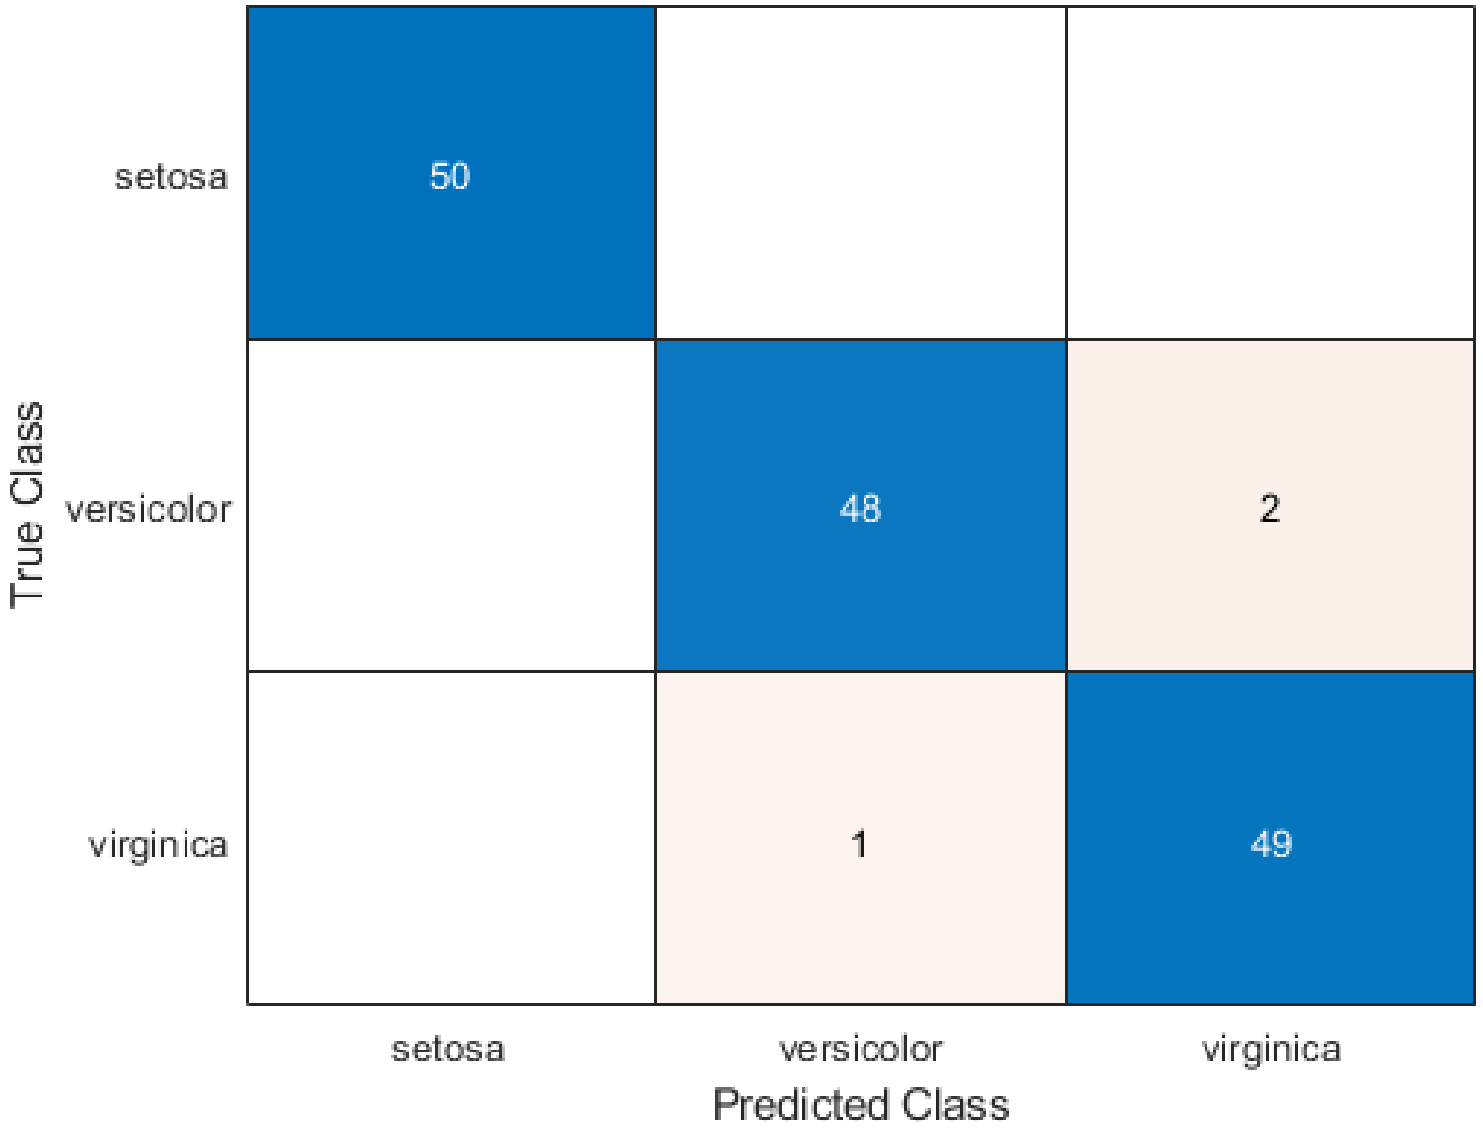
例子：叶子大小与性能的关系



决策树的裁剪


Classification tree viewer
File Tools Desktop Tree Window Help
Click to display: Identity
Magnification: 100%
Pruning level: 6 of 8
x5 < 0.23154
x5 >= 0.23154
b
x27 < 0.999945
x27 >= 0.999945
g
b

分类决策树的评估：混淆矩阵



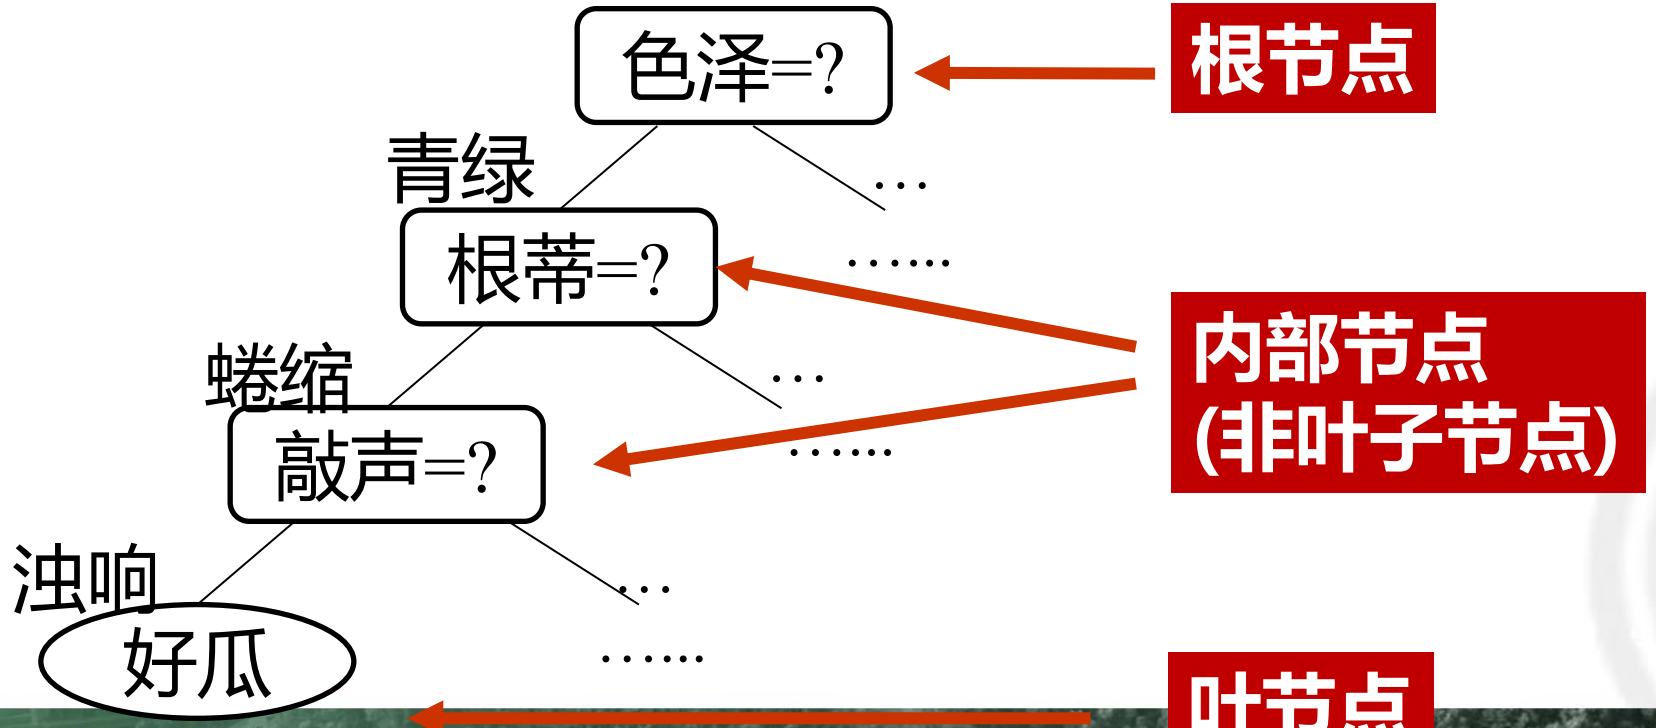
决策树的简介

什么是决策树?

- **中文**：决策树。可根据功能分为：分类树和回归树。
- **英文**：Decision Tree（Classification Tree 和Regression Tree）
- **定义**：学习用来作决策的树。或运用于分类以及回归的一种树型结构模型。
- **功能**：分类或者回归。
- **定位**：属于有监督学习，积极学习
- **步骤**：两大主要阶段：训练和预测（工作）

决策树的结构

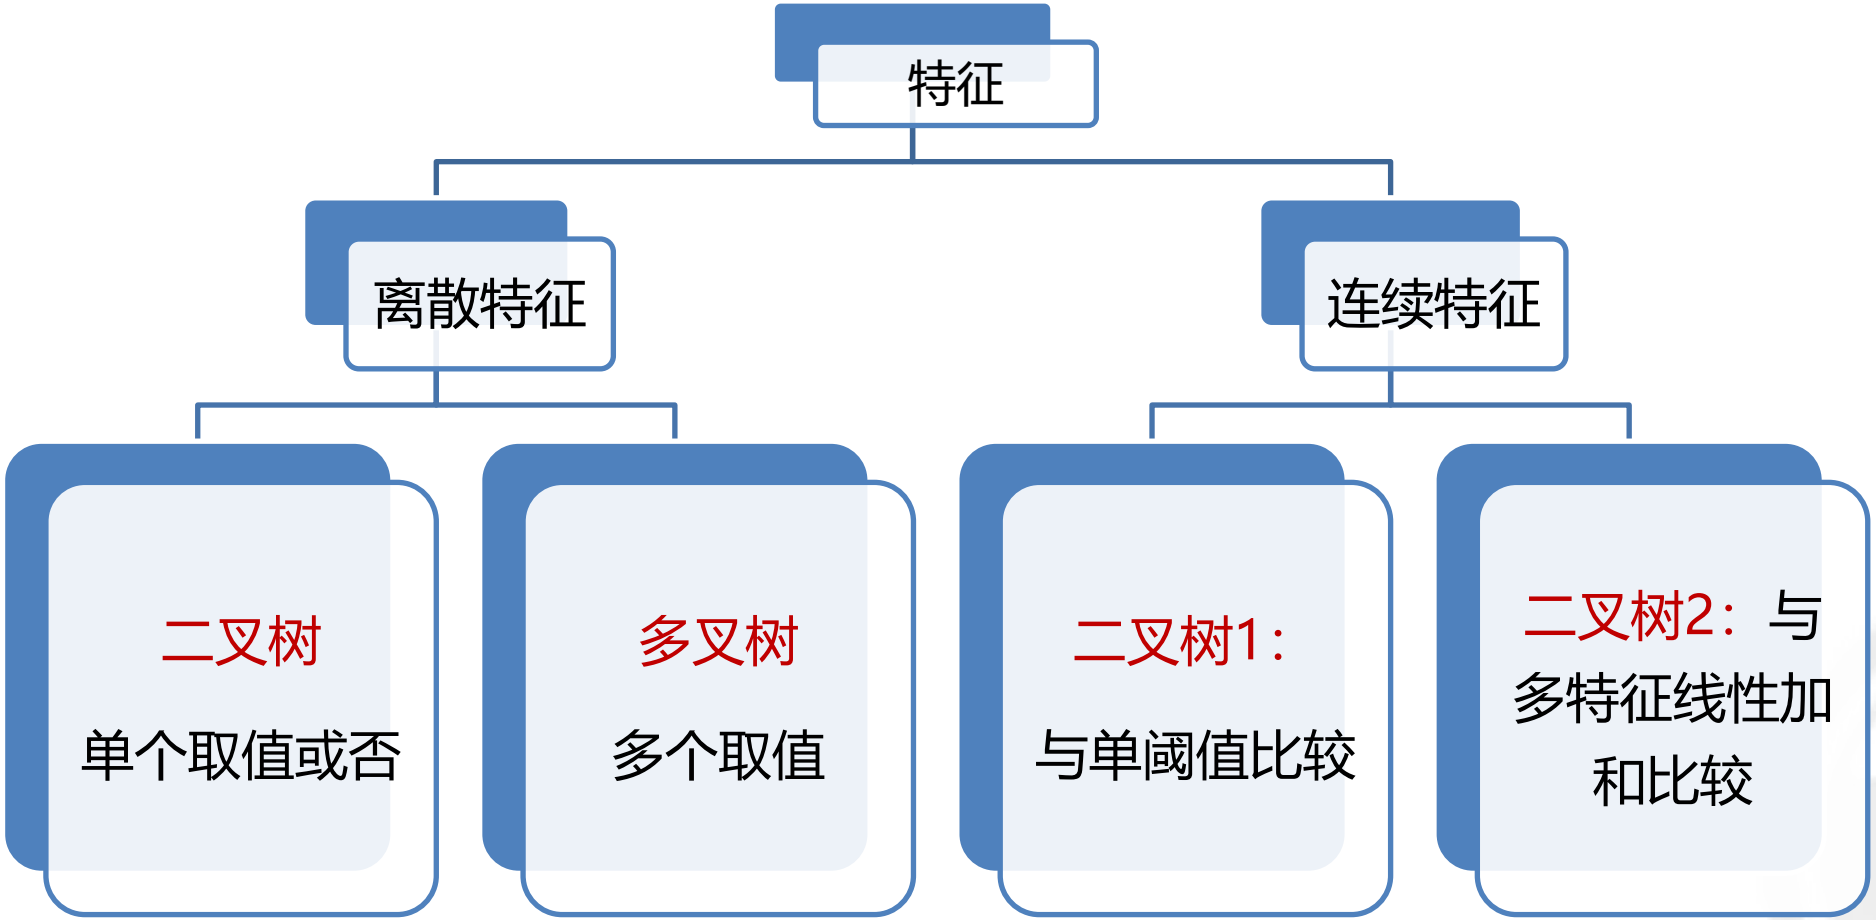
- 由节点和有向边组成，一般一棵决策树包含一个根节点、若干内部节点和若干叶子节点。



决策树结构单元的比较

结构	特点	备注
根节点	决策判断的起始点	唯一性
内部节点	表示某种作为判断条件的属性（条件属性，划分属性，测试属性，特征属性）	也叫测试结点，非叶子节点，测试条件
层次	根结点层次为1；根结点的子女结点层次为2；以此类推	树的深度
边/分支	根据条件属性取值选取的路径；一种基于此结点属性的判断（划分）结果	有向边，测试结果
叶子节点	使判断终止的结论；叶子节点通常包含若干样本	也叫叶子，叶节点

决策树特征的划分方法


特征
离散特征
连续特征
二叉树
单个取值或否
多叉树
多个取值
二叉树1：
与单阈值比较
二叉树2：与
多特征线性加
和比较

决策树的训练阶段

训练目的：产生一棵泛化能力强，即处理未见示例（新样本）能力强的决策树。

训练策略：自顶向下、分而治之。

训练步骤：

（1）在根节点上，遍历所有特征A和可能切分点a，取左右孩子结点纯度之和最高的特征与切分点对{A*，a*}，划分成两个子节点；

（2）划分满足特定策略（如叶子样本数、树深度、所有数据已划分等）即停止；

（3）对两个子节点递归调用（1）

决策树的预测阶段

- 决策树基于树结构来进行预测
- 从决策树的根节点开始
- 待测样本依次与决策树中的特征节点进行比较
- 按照比较结果选择下一比较分支，
- 直到叶子节点作为最终的决策结果。

决策树预测 = 决策

- 每个判定问题都是对**某个属性的“测试”**；
- 决策过程的最终结论对应了我们所希望的判定结果；
- 每个测试的结果或是**导出最终结论**，或者**导出进一步的判定问题**，其考虑范围是在上次决策结果的限定范围之内；
- 从根结点到每个叶结点的路径对应了一个**判定测试序列**

决策树的优点

假设：X和Y具有相关性（一般性假设）

优点：

- **决策树的结构容易理解，具有较好解释性；决策树能被表示为多条if-then形式的决策规则**
- **具有一定的自变量选择能力**
- **能够同时处理离散和连续性自变量**
- **运算速度较快，一般快于其他分类方法；**
- **预测时效率高，计算次数不超过树深度。**
- **对异常点不敏感，鲁棒性较强**

决策树的缺点

- 性能对属性划分方法敏感➔改进划分
- Y的类别太多时，树结构复杂度容易增长➔损失函数增加正则项
- 容易过拟合，泛化能力下降➔前后减枝
- 叶子节点内对回归问题的区分度不够➔叶子节点内的样本构建叶子模型
- 决策空间是单个属性线性划分而成➔非叶子节点的属性变成多个
- 单颗树的性能有限➔随机森林

决策树的几个重要问题

- **生成**：如何最佳划分决策树?
  - 如何处理连续和离散的属性?
  - 如何选择最优划分属性?
  - 如何选择最优划分属性的临界值?
- **结束**：生成决策树的结束条件?
- 如何处理**属性(x)的缺失值**?
- **叶子节点**的观察y怎么预报y?（分类：投票法；回归：平均值）
- 怎么避免决策树**过拟合**？ （减枝）

如何选择最优划分属性

- 构造决策树的关键
- 一般而言，随着划分过程不断进行，我们希望决策树的分支结点所包含的样本**尽可能属于同一类别，即结点的“纯度”(purity)越来越高**
- **问题转化**：寻找最优划分属性?➔找到划分前后纯度增加最大的情况（划分属性及其临界值）➔怎么定义一个结点的纯度?

生成决策树的结束条件

- 树深度足够或叶子全部生成
- 通常三种情形会判定为叶子结点:
  - 空叶子：当前结点中的样本集合为空，或者样本数小于某个阈值
  - 纯叶子：当前结点中的所有样本全部归属于同一类别；
  - 属性被测试完的叶子：当前结点中的所有样本在所有属性上取值相同。
  - 后面两种情形：最佳划分的度量值为0。

处理缺失属性值?

通常两个办法:

- **放弃缺失值的样本**，仅使用无缺失值的样本来进行学习➔数据信息的浪费。
- 根据此属性值已知的其他样本，来**估计这个缺失的属性值**。
  - 当前结点所有样本中该属性最常见的值
  - 当前结点同类样本中该属性最常见的值
  - 为含缺失值属性的每个可能值赋予一个概率，而不是简单地将最常见的值赋给它。

典型的决策树模型

分割标准和模型

划分方法	划分特点	公式	决策树模型	功能
信息增益	信息增益对可取值数目较多的属性有所偏好	$\mathrm{Gain}(D,a)=\mathrm{Ent}(D)-\sum_{v=1}^{V}\frac{\lvert D^v\rvert}{\lvert D\rvert}\mathrm{Ent}(D^v)$	ID3决策树学习算法[Quinlan, 1986]以信息增益为准则来选择划分属性	训练分类树
增益率	增益率准则对可取值数目较少的属性有所偏好；	$\mathrm{Gain_ratio}(D,a)=\frac{\mathrm{Gain}(D,a)}{\mathrm{IV}(a)}$ $\mathrm{IV}(a)=-\sum_{v=1}^{V}\frac{\lvert D^v\rvert}{\lvert D\rvert}\log_2\frac{\lvert D^v\rvert}{\lvert D\rvert}$	C4.5 [Quinlan, 1993] 先找出信息增益高于平均水平的属性，再选取增益率最高的	训练分类树
基尼指数或误差	基尼指数用于分类树；误差平方用于回归树	$\mathrm{Gini}(D)=\sum_{k=1}^{\lvert\mathcal{Y}\rvert}\sum_{k'\neq k}p_k p_{k'}=1-\sum_{k=1}^{\lvert\mathcal{Y}\rvert}p_k^2$ $\mathrm{Gini_index}(D,a)=\sum_{v=1}^{V}\frac{\lvert D^v\rvert}{\lvert D\rvert}\mathrm{Gini}(D^v)$	CART [Breiman et al., 1984]采用“基尼指数”来选择划分属性	训练分类树或回归树
其他指标	一般没有上述指标敏感	分类错误率/残差平方和		修剪决策树（验证）

划分选择1 - 信息增益（适用分类树）

“信息熵”是度量样本集合纯度最常用的一种指标，

- 假定当前样本集合 D 中有 k 类样本
- 第 k 类样本所占的比例有p_k
- 样本集合 D 中第 k 类样本的信息：$-\log_2 p_k$
- D 的信息熵（信息的期望）定义为

$$\mathrm{Ent}(D) = -\sum_{k=1}^{|\mathcal{Y}|} p_k \log_2 p_k \qquad (K = 1, 2, ..., |\mathcal{Y}|)$$

Ent (D) 的值越小，则D 的纯度越高

- 计算信息熵时约定：若p=0 ，则 $p \log_2 p = 0$
- Ent (D)的最小值为 0，最大值为 $\log_2 |\mathcal{Y}|$

划分选择-信息增益

$\{a^1, a^2, ..., a^V\}$

离散属性a有 V个可能的取值 $\{a_1, a_2, ..., a_V\}$ ，划分会产生V个分支结点，其中包含了D中所有在属性上取值为a_V的样本，记为D。 用属性 a对样本集D进行划分所获得的“信息增益”：

$$\mathrm{Gain}(D,a) = \mathrm{Ent}(D) - \sum_{v=1}^{V} \frac{|D^v|}{|D|} \mathrm{Ent}(D^v)$$

$|D^v|$表示v个分支结点的样本个数。

一般而言，信息增益越大，则意味着使用属性 a 来进行划分所获得的“纯度提升”越大

信息增益：根结点的信息熵

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

8个正例

9个反例

17 个样本，正例占p1=8/17 ，反例占 p2=9/17

根结点的信息熵为

$$\mathrm{Ent}(D) = -\sum_{k=1}^{2} p_k \log_2 p_k = -\left(\frac{8}{17}\log_2\frac{8}{17} + \frac{9}{17}\log_2\frac{9}{17}\right) = 0.998$$

信息增益：3 个结点信息熵

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

属性“色泽”对应的3个数据子集分别为 D^1 (色泽=青绿)，D^2 (色泽=乌黑)， D^3 (色泽=浅白). D^1 包含 {1, 4, 6, 10, 13, 17} 6个样例，正例占p1=3/6，反例占p2=3/6，同理， 3 个结点信息熵为：

$$\mathrm{Ent}(D^1) = -\left(\frac{3}{6}\log_2\frac{3}{6} + \frac{3}{6}\log_2\frac{3}{6}\right) = 1.000$$

$$\mathrm{Ent}(D^2) = -\left(\frac{4}{6}\log_2\frac{4}{6} + \frac{2}{6}\log_2\frac{2}{6}\right) = 0.918$$

$$\mathrm{Ent}(D^3) = -\left(\frac{1}{5}\log_2\frac{1}{5} + \frac{4}{5}\log_2\frac{4}{5}\right) = 0.722$$

信息增益：属性“色泽”划分前后

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

属性“色泽”的信息增益为

$$\text{Gain}(D, \text{色泽}) = \text{Ent}(D) - \sum_{v=1}^{3} \frac{|D^v|}{|D|} \text{Ent}(D^v)$$

$$= 0.998 - \left(\frac{6}{17} \times 1.000 + \frac{6}{17} \times 0.918 + \frac{5}{17} \times 0.722\right)$$

$$= 0.109$$

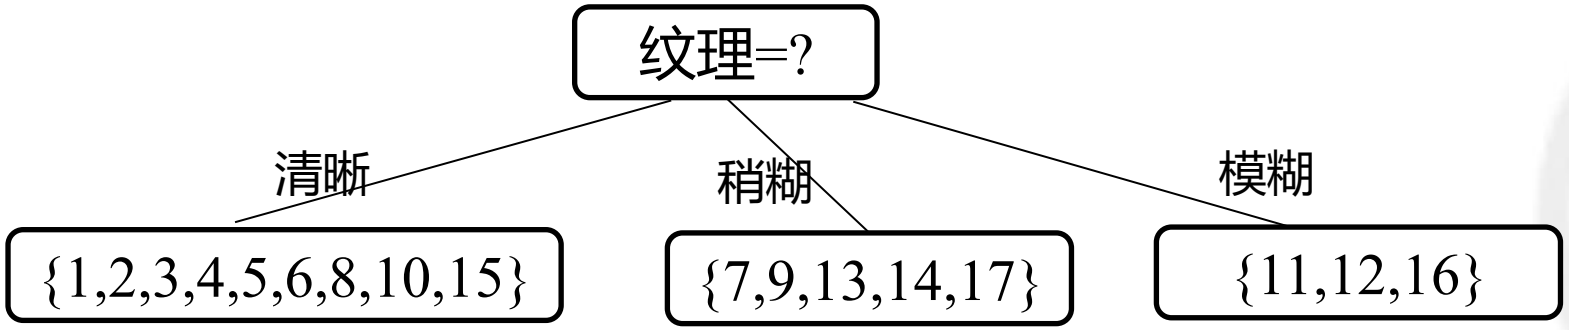
信息增益：比较其他属性划分前后

$$\text{Gain}(D, \text{根蒂}) = 0.143 \qquad \text{Gain}(D, \text{敲声}) = 0.141$$

$$\text{Gain}(D, \text{纹理}) = 0.381 \qquad \text{Gain}(D, \text{脐部}) = 0.289$$

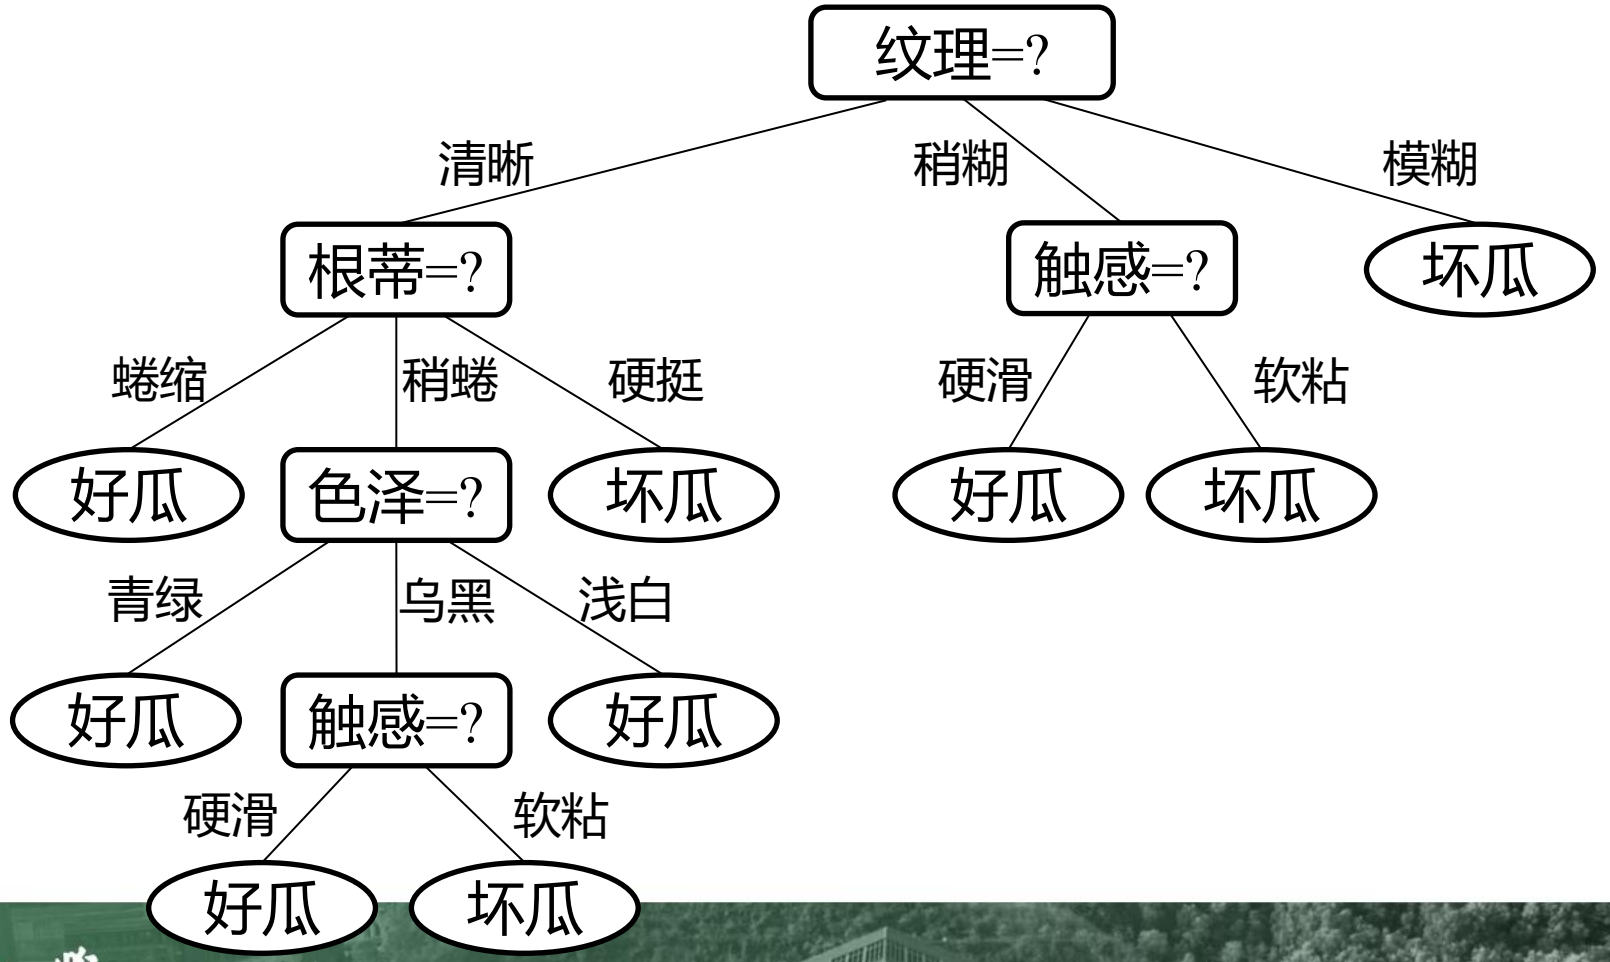
$$\text{Gain}(D, \text{触感}) = 0.006$$

- **属性“纹理”的信息增益最大，其被选为划分属性**



基于信息增益划分的决策树

- **每个分支结点做进一步划分，最终得到的决策树如图：**



信息增益存在的问题

- **若把“编号”也作为一个候选划分属性，则其信息增益一般远大于其他属性。显然，这样的决策树不具有泛化能力，无法对新样本进行有效预测**
- **信息增益：对可取值数目较多的属性有所偏好**

划分选择2 - 增益率（适用分类树）

增益率定义：

$$\text{Gain_ratio}(D,a) = \frac{\text{Gain}(D,a)}{\text{IV}(a)}$$

其中

$$\text{IV}(a) = -\sum_{v=1}^{V} \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|}$$

IV(*a*)称为属性*a* 的“固有值”，属性 *a* 的可能取值数目越多（即 V 越大），则 IV(*a*) 的值通常就越大

增益率准则对可取值数目较少的属性有所偏好

划分选择3 - 基尼指数（适用分类树）

基尼值（基尼指数）

功能：数据集D 的纯度可用“基尼值”来度量。

含义：随机抽取两个样本，其类别标记不一致的概率。

纯度：Gini(D) 越小，数据集D 的纯度越高

$$\mathrm{Gini}(D) = \sum_{k=1}^{|\mathcal{Y}|} \sum_{k' \neq k} p_k p_{k'} = 1 - \sum_{k=1}^{|\mathcal{Y}|} p_k^2$$

属性a 的基尼指数定义为：

$$\mathrm{Gini_index}(D, a) = \sum_{v=1}^{V} \frac{|D^v|}{|D|} \mathrm{Gini}(D^v)$$

应选择那个使划分后基尼指数最小的属性作为最优划分属性，即 $a_* = \underset{a \in A}{\mathrm{argmin}}\ \mathrm{Gini_index}(D, a)$

三种经典的决策树模型

算法	支持模型	树结构	特征选择	X连续值处理	X缺失值处理	剪枝	特征属性多次使用
ID3	分类	多叉树	信息增益	不支持	不支持	不支持	不支持
C4.5	分类	多叉树	信息增益率	支持	支持	支持	不支持
CART	分类/回归	二叉树	基尼指数/误差	支持	支持	支持	支持

CART 用于分类的伪代码

输入 :训练集D,特征集F,则 函数TreeGenerate(D,F) 步骤如下:

1 生成节点node，并赋予对应的训练集D

2 if $D \le T_N$ OR Gini(D)$\le T_G$ then //终止条件：T_N为样本数量阈值，T_G为基尼指数阈值

3 　　将node记为叶子节点，将类别标记为D中样本数最多的类；return

4 endif

5 for f_l in F //遍历所有特征

6 　iff_l是离散特征

7 　　for f_l的每一个取值f_l^k do//遍历当前离散特征的所有取值

8 　　根据f_l=or≠f_l^k，D分为两个子集D_{left}和D_{right}，记录加权平均基尼指数

9 　elseif f_l是连续特征

10 　for f_l的每一个分裂阈值tlkdo//遍历当前连续特征下的所有分裂阈值

11 　　根据f_l>or<t_l^k？，D分为两个子集D_{left}和D_{right}，记录加权平均基尼指数

12 根据最小加权平均基尼指数从F中选择最优划分属性f_l*及其最优分裂方案给出的D_{left}和D_{right}

13 　　$D=D_{\text{left}}$，以TreeGenerate(D,F)向下继续生长

14 　　$D=D_{\text{right}}$，以TreeGenerate(D,F)向下继续生长

15 生成以node为根节点的决策树T'，对T'进行后剪枝

输出得到最终的决策树T

CART 用于回归的伪代码

输入 :训练集D,特征集F,则 函数TreeGenerate(D,F) 步骤如下:

1 生成节点node，并赋予对应的训练集D

2 if $D \le T_N$ OR Gini(D)$\le T_G$ then //终止条件：T_N为样本数量阈值，T_G为基尼指数阈值

3 　　将node记为叶子节点，回归值为标签集合Y的平均值; 　return

4 endif

5 for f_l in F //遍历所有特征

6 　iff_l是离散特征

7 　　for f_l的每一个取值f_l^k do//遍历当前离散特征的所有取值

8 　　根据f_l=or≠f_l^k，D分为两个子集D_{left}和D_{right}，记录加权平均误差

9 　elseif f_l是连续特征

10 　for f_l的每一个分裂阈值tlkdo//遍历当前连续特征下的所有分裂阈值

11 　　根据f_l>or<t_l^k? ，D分为两个子集D_{left}和D_{right}，记录加权平均误差

12 根据最小加权平方误差从F中选择最优划分属性f_l*及其最优分裂方案给出的D_{left}和D_{right}

13 　　$D=D_{\text{left}}$，以TreeGenerate(D,F)向下继续生长

14 　　$D=D_{\text{right}}$，以TreeGenerate(D,F)向下继续生长

15 生成以node为根节点的决策树T' ，对T' 进行后剪枝

输出得到最终的决策树T

决策树的剪枝处理

剪枝处理

- 目的：对付“过拟合” ➔一定程度避免因决策分支过多，把训练集自身的一些特点当做所有数据都有的一般性质而导致的过拟合
- 基本策略
  - 预剪枝：训练中（决策树生长中）
  - 后剪枝：训练后（决策树生成后）
- 判断决策树泛化性能是否提升的方法
  - 留出法：预留一部分数据用作“验证集”以进行性能评估

剪枝处理

- 数据集

训练集

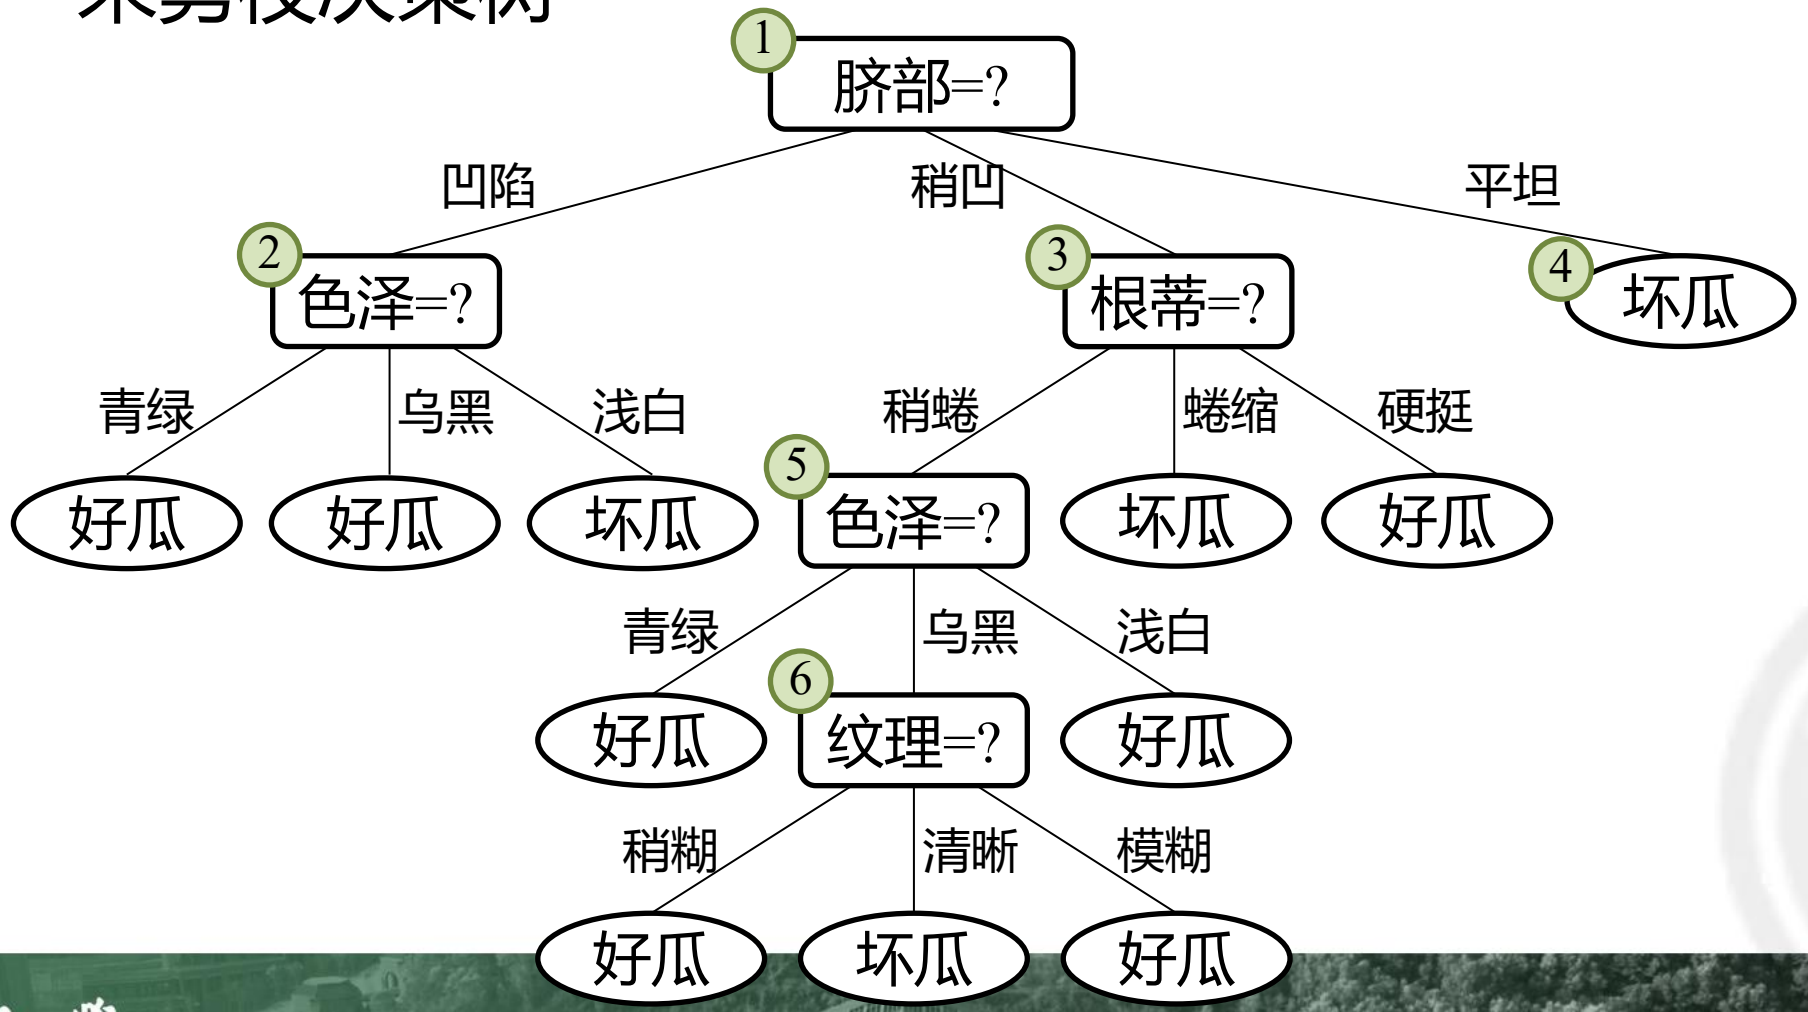
编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

剪枝处理

- 未剪枝决策树


1
脐部=?
凹陷
稍凹
平坦
2
色泽=?
3
根蒂=?
4
坏瓜
青绿
乌黑
浅白
稍蜷
蜷缩
硬挺
好瓜
好瓜
坏瓜
5
色泽=?
坏瓜
好瓜
青绿
乌黑
浅白
6
好瓜
纹理=?
好瓜
稍糊
清晰
模糊
好瓜
坏瓜
好瓜

剪枝处理-预剪枝

- **步骤：决策树生成过程中，对每个结点在划分前先进行估计，若当前结点的划分不能带来决策树泛化性能提升，则停止划分并将当前结点记为叶结点，其类别标记为训练样例数最多的类别**
- **例子：针对上述数据集，基于信息增益准则，选取属性“脐部”划分训练集。分别计算划分前（即直接将该结点作为叶结点）及划分后的验证集精度，判断是否需要划分。若划分后能提高验证集精度，则划分，对划分后的属性，执行同样判断；否则，不划分**

剪枝处理-预剪枝

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

3个正确

4个错误

验证集精度

1 脐部=?

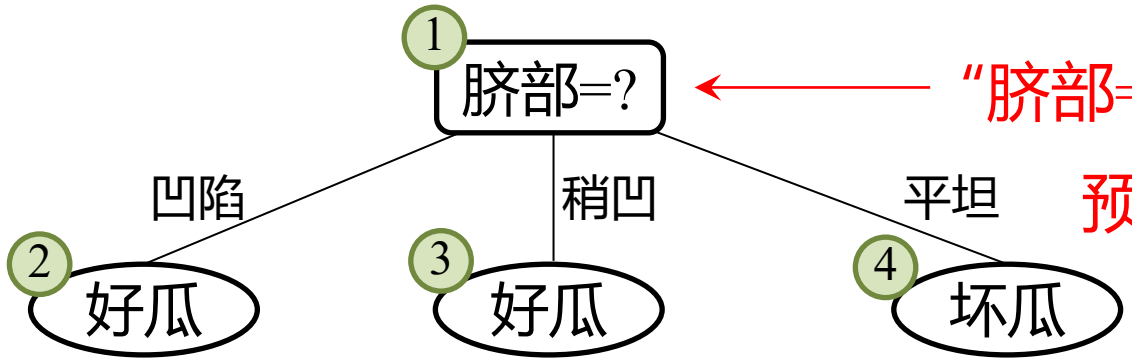
“脐部=?” 划分前: 42.9%

结点1：若不划分，则将其标记为叶结点，类别标记为训练样例中最多的类别，即好瓜。验证集中 {4,5,8}被分类正确，得到验证集精度为 3/7=42.9%

剪枝处理-预剪枝

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜	
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是	正确
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是	
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是	
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否	错误
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否	正确
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否	
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否	错误



“脐部=?”

验证集精度

划分前: 42.9%

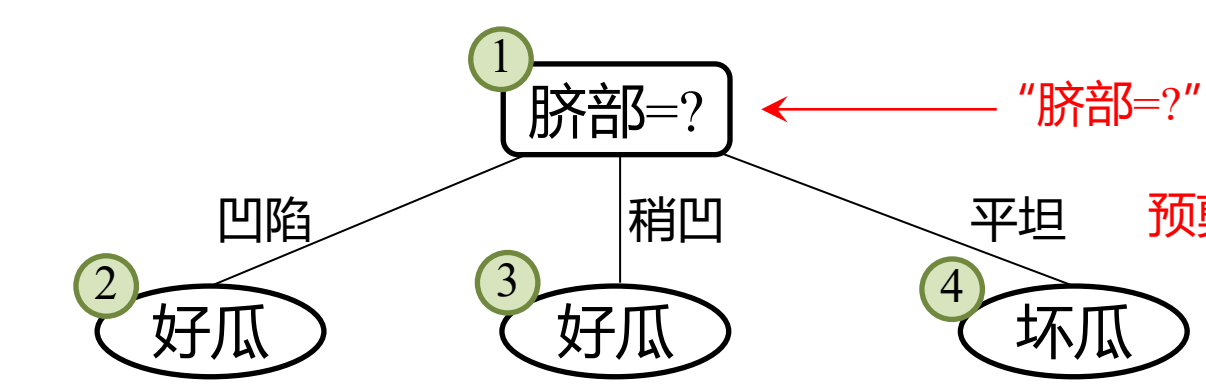
划分后: 71.4%

预剪枝决策: 划分

结点1：若划分，根据结点2，3，4的训练样例，将这3 个结点标记为“好瓜”、好瓜”、坏瓜”。此时，验证集中编号为{4，5，8，11，12} 的样例被划分正确，验证集精度为5/7 = 71.4%

剪枝处理-预剪枝

对结点2，3，4分别进行剪枝判断，结点 2，3 都禁止划分，结点4本身为叶子结点。最终得到仅有一层划分的决策树，称为“决策树桩”



验证集精度

“脐部=?” 划分前: 42.9%
划分后: 71.4%
预剪枝决策: 划分

“色泽=?”

验证集精度

划分前: 71.4%
划分后: 57.1%
预剪枝决策: 禁止划分

“根蒂=?”

验证集精度

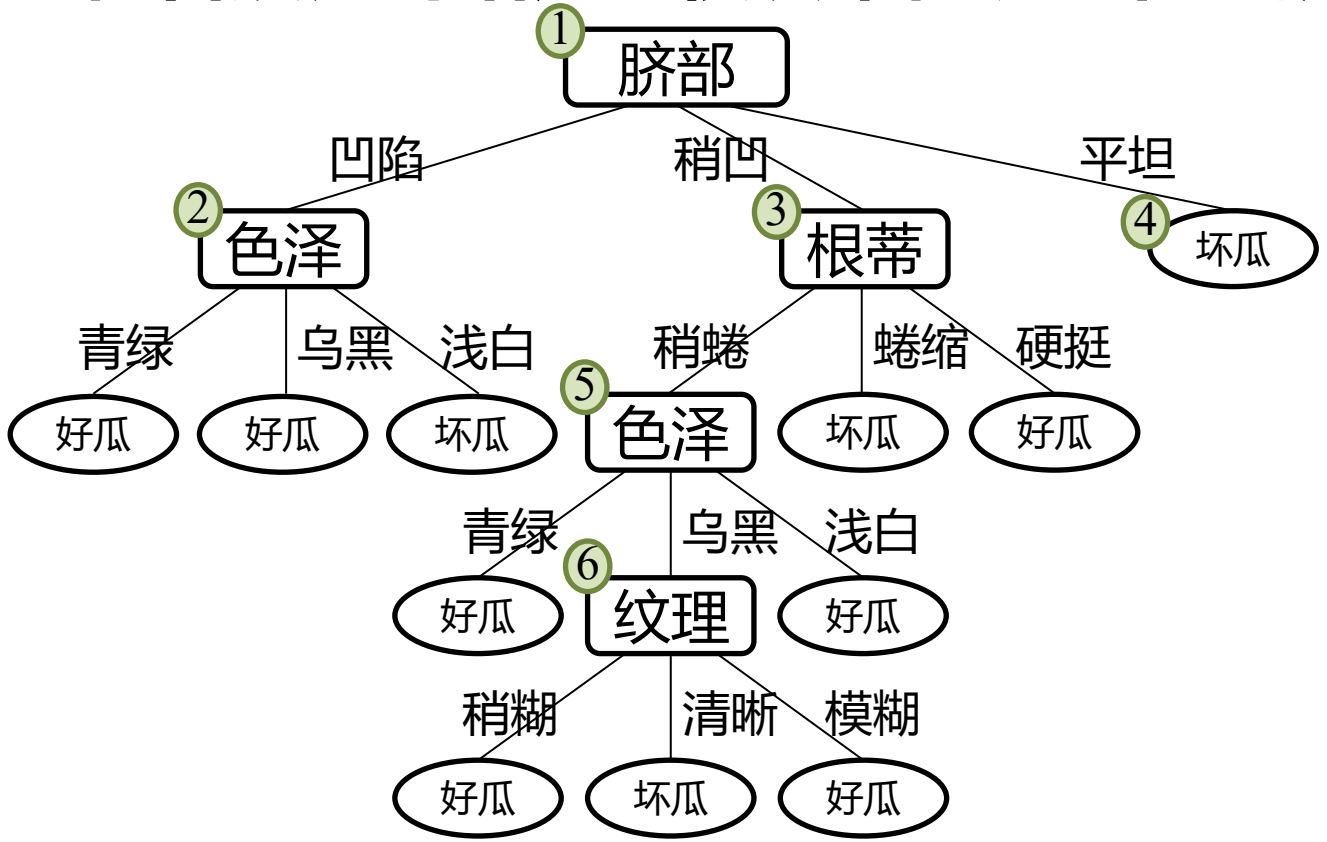
划分前: 71.4%
划分后: 71.4%
预剪枝决策: 禁止划分

预剪枝的优缺点

- 优点
  - 降低过拟合风险
  - 显著减少训练时间和测试时间开销
- 缺点
  - 欠拟合风险：有些分支的当前划分虽然不能提升泛化性能，但在其基础上进行的后续划分却有可能导致性能显著提高。
  - 预剪枝基于“贪心”本质，禁止这些分支展开，带来了欠拟合风险

剪枝处理-后剪枝

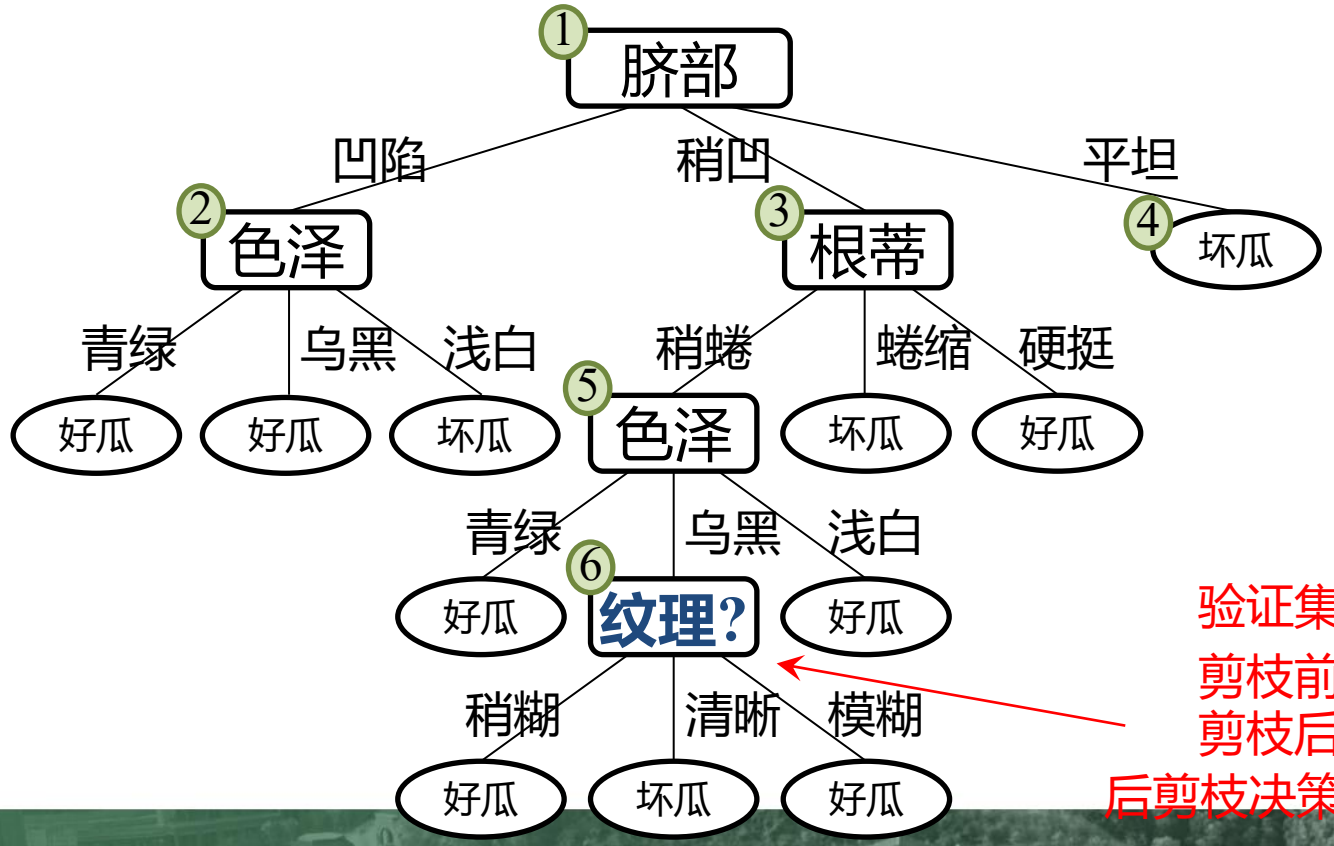
步骤：先从训练集生成完整决策树，然后自底向上地对非叶结点进行考察，若该结点对应子树替换为叶结点能使决策树泛化性能提升，则完成替换



首先生成一棵完整的决策树，该决策树的验证集精度为42.9%

剪枝处理-后剪枝

首先考虑结点(6)，若将其替换为叶结点，根据落在其上的训练样本{7,15}将其标记为“好瓜”，得到验证集精度提高至 57.1% ，则决定剪枝



验证集精度

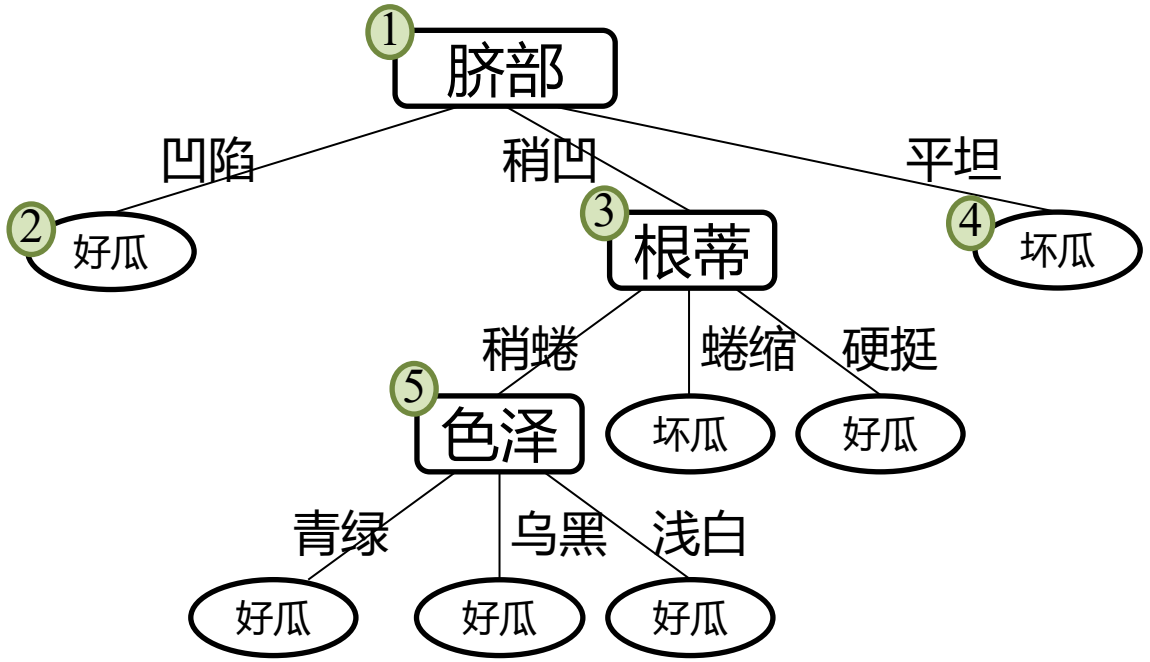
剪枝前: 42.9%

剪枝后: 57.1%

后剪枝决策: 剪枝

剪枝处理-后剪枝

最终基于后剪枝策略得到的决策树如图所示



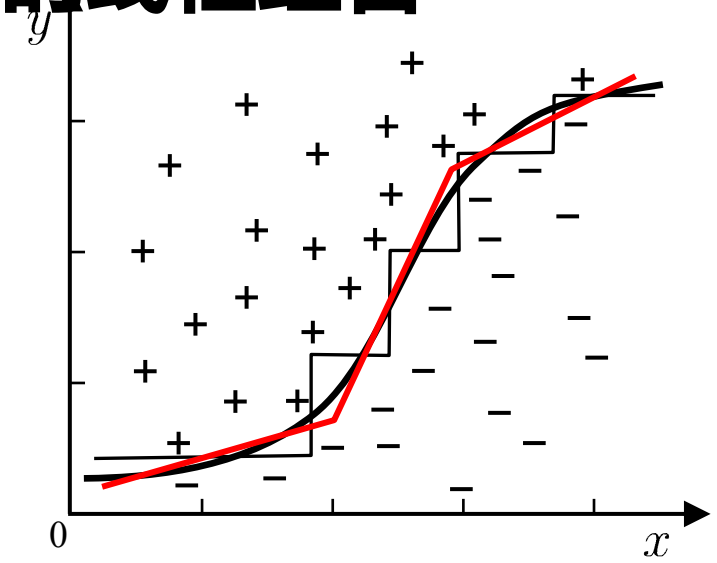
后剪枝的优缺点

- 优点
  - 后剪枝比预剪枝保留了更多的分支，**欠拟合风险小**，**泛化性能往往优于预剪枝决策树**
- 缺点
  - **训练时间开销大**：后剪枝过程是在生成完全决策树之后进行的，需要自底向上对所有非叶结点逐一考察

决策树的改进

多变量决策树

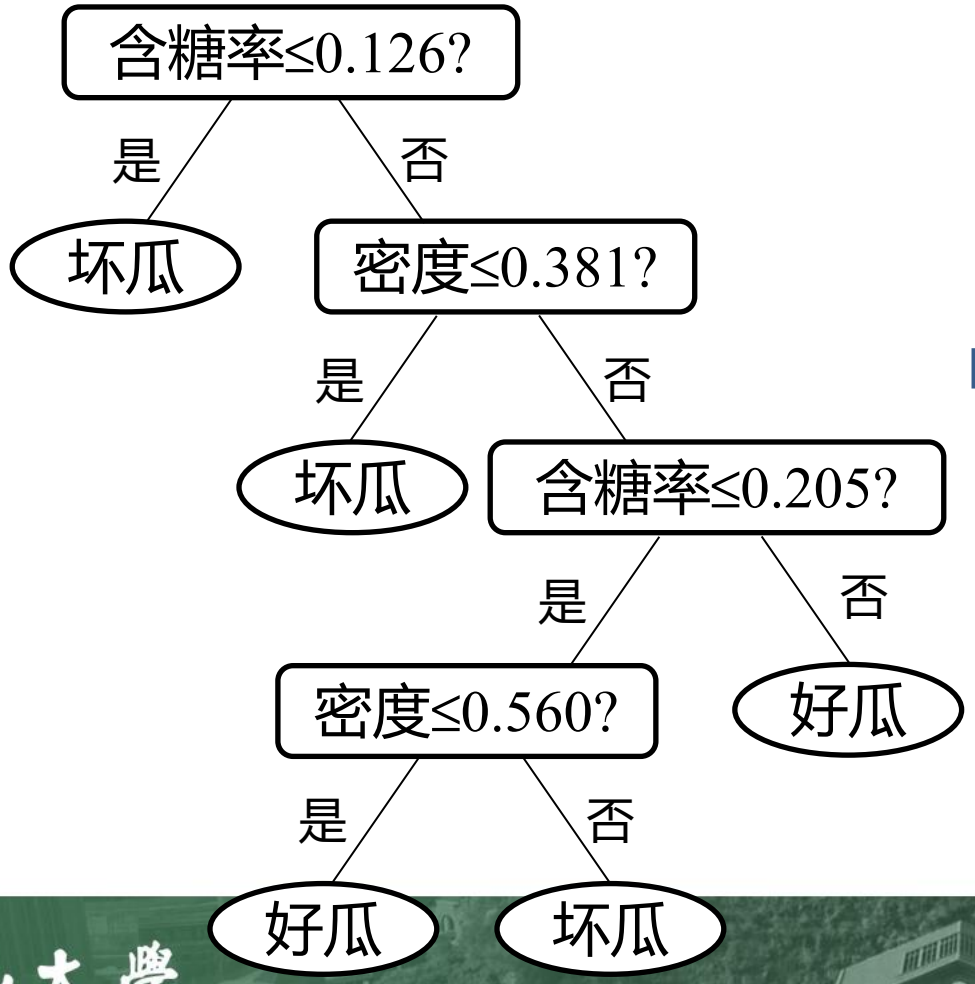
- **单变量决策树**：分类边界与轴平行
- **多变量决策树**：非叶节点不再是仅对某个属性,而是对属性的线性组合

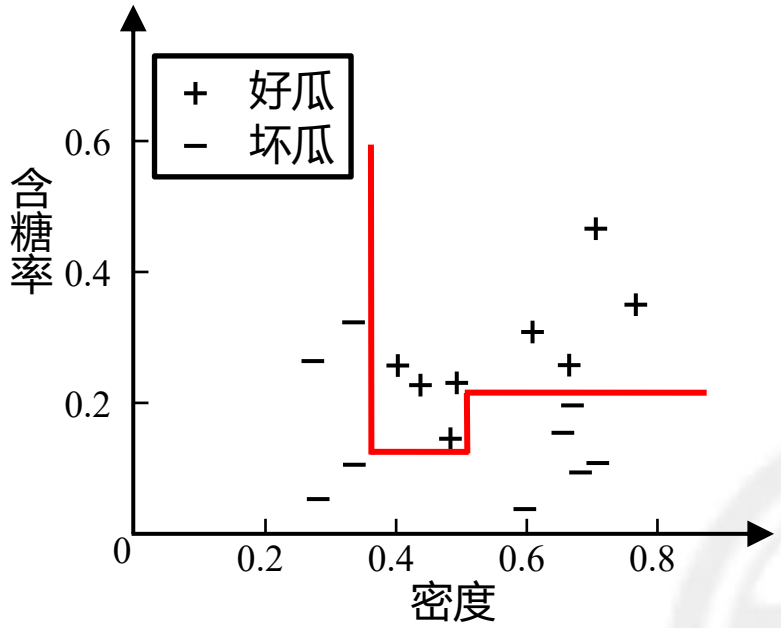


每个非叶结点是一个形如 $\sum w_i a_i = t$ $(i=1...d)$ 的线性分类器，其中 w_i 是属性a_i 的权值，w_i 和 t 可在该结点所含的样本集和属性集上学得

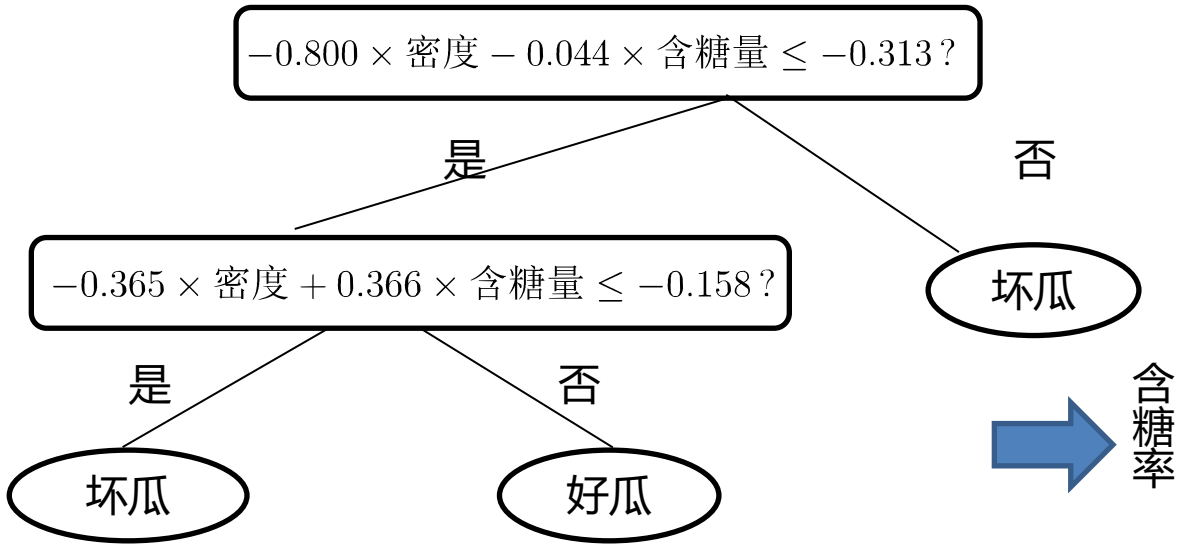
中山大学 SUN YAT-SEN UNIVERSITY

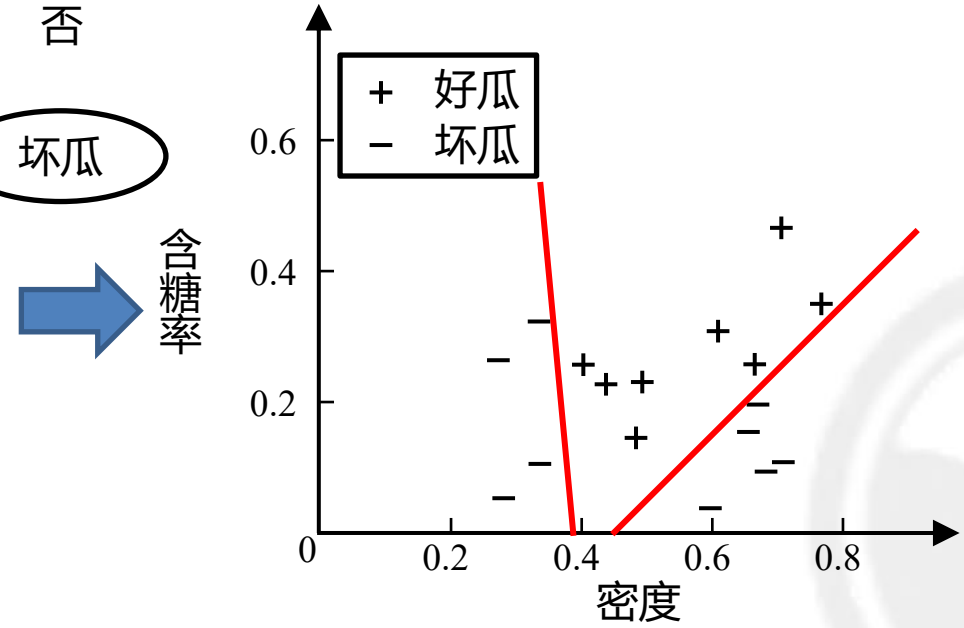
单变量决策树的本质


含糖率≤0.126?
是
否
坏瓜
密度≤0.381?
是
否
坏瓜
含糖率≤0.205?
是
否
密度≤0.560?
好瓜
是
否
好瓜
坏瓜


好瓜
坏瓜
含糖率
密度
0
0.2
0.4
0.6
0.8

多变量决策树的本质


$-0.800 \times$ 密度 $- 0.044 \times$ 含糖量 ≤ -0.313 ?
是
否
$-0.365 \times$ 密度 $+ 0.366 \times$ 含糖量 ≤ -0.158 ?
坏瓜
是
否
坏瓜
好瓜


+ 好瓜
− 坏瓜
0.6
0.4
0.2
0
0.2
0.4
0.6
0.8
密度
含糖率

决策树构建

构建决策树模型基本步骤

步骤	基本命令	功能
数据预处理		数据标准化
		将原始数据分割成练集P和验证集Q
训练模型	fitrtree ； fitctree	制定特点训练参数;训练决策树
	prune	修剪决策树
预测	predict	训练集预测
		验证集预测
性能评估		数据后处理
	view	查看决策树模型
	loss	训练集和验证集的预测性能的评估

命令的具体形式

命令	具体形式
fitrtree	https://ww2.mathworks.cn/help/stats/fitrtree.html
fitctree	https://ww2.mathworks.cn/help/stats/fitctree.html
prune	https://ww2.mathworks.cn/help/stats/classificationtree.prune.html
predict	https://ww2.mathworks.cn/help/stats/compactclassificationtree.predict.html
view	https://ww2.mathworks.cn/help/stats/compactclassificationtree.view.html
loss	https://ww2.mathworks.cn/help/stats/compactclassificationtree.loss.html

fitrtree和fitctree函数的调用格式

格式	用途
tree = fitrtree(Tbl,ResVarName)	根据表 Tbl 中的输入变量（预测变量、特征或属性）和包含在 Tbl.ResVarName 中的输出（响应）返回回归树。是二叉树，每个分支节点都根据 Tbl 列的值拆分。
tree = fitrtree(Tbl,formula)	返回基于表 Tbl 中包含的输入变量的回归树。formula 是响应的解释模型和 Tbl 中用于拟合树的预测变量子集。
tree = fitrtree(Tbl,Y)	根据表 Tbl 中包含的输入变量和向量 Y 中的输出返回一个回归树。
tree = fitrtree(X,Y)	返回基于输入变量 X 和输出 Y 的回归树。二叉树每个节点都基于 X 列的值进行拆分
tree = fitrtree(___,Name,Value)	使用一个或多个名称-值对参数指定选项。例如，可以指定观察权重或训练交叉验证模型。

prune的调用格式

格式	用途
tree= fitrtree(X,Y) 或 tree= fitctree(X,Y)	Tree由fitrtree和fitctree生成
tree1 = prune(tree)	创建回归树或分类树的副本，并填充其最佳修剪序列。
tree1 = prune(tree,Name,Value)	使用 Name,Value 对参数指定的附加选项创建一个修剪过的树。 可以按任意顺序指定多个名称-值对参数。

分类树的Predict函数的调用格式

格式	用途
label = predict(Mdl,X)	根据经过训练的完整或紧凑分类树 Mdl，返回表或矩阵 X 中预测变量数据的预测类别标签向量。
label = predict(Mdl,X,Name,Value)	由一个或多个 Name,Value 对组参数指定的附加选项。 例如，您可以指定在预测标签之前将 Mdl 修剪到特定级别。
[label,score,node,cnum] = predict(___)	另外返回：score表示标签来自特定类别的可能性的分类分数矩阵。 对于分类树，score是后验概率。对于 X 中的每个观察，预测的类标签对应于所有类中的最小预期误分类成本。用于分类的预测节点编号向量（node）。用于分类的预测类编号向量(cnum)。

回归树的Predict函数的调用格式

格式	用途
Yfit = predict(Mdl,X)	根据完整或压缩的回归树 Mdl 返回表或矩阵 X 中预测变量数据的预测响应向量Yfit。
Yfit = predict(Mdl,X,Name,Value)	使用由一个或多个 Name,Value 对参数指定的附加选项来预测响应值Yfit。 例如，您可以指定在预测响应之前将 Mdl 修剪到特定级别。
[Yfit,node] = predict(___)	还使用前面语法中的任何输入参数返回响应的预测节点编号向量（node）。

小结

思考

- 什么是决策树模型?
- 决策树模型的功能?
- 怎么评估一个决策树模型?
- 决策树的求解算法：属性划分选择 + 剪枝处理（预剪枝，后剪枝)
- 单变量决策树 VS 多变量决策树
- 每种类型的决策树用Matlab如何实现?