人工智能与地理数据挖掘

第十讲　支持向量机

孙伟 sunwei29@mail.sysu.edu.cn

地理科学与规划学院

中山大學 SUN YAT-SEN UNIVERSITY

2026.6

数据挖掘/机器学习的典型方法

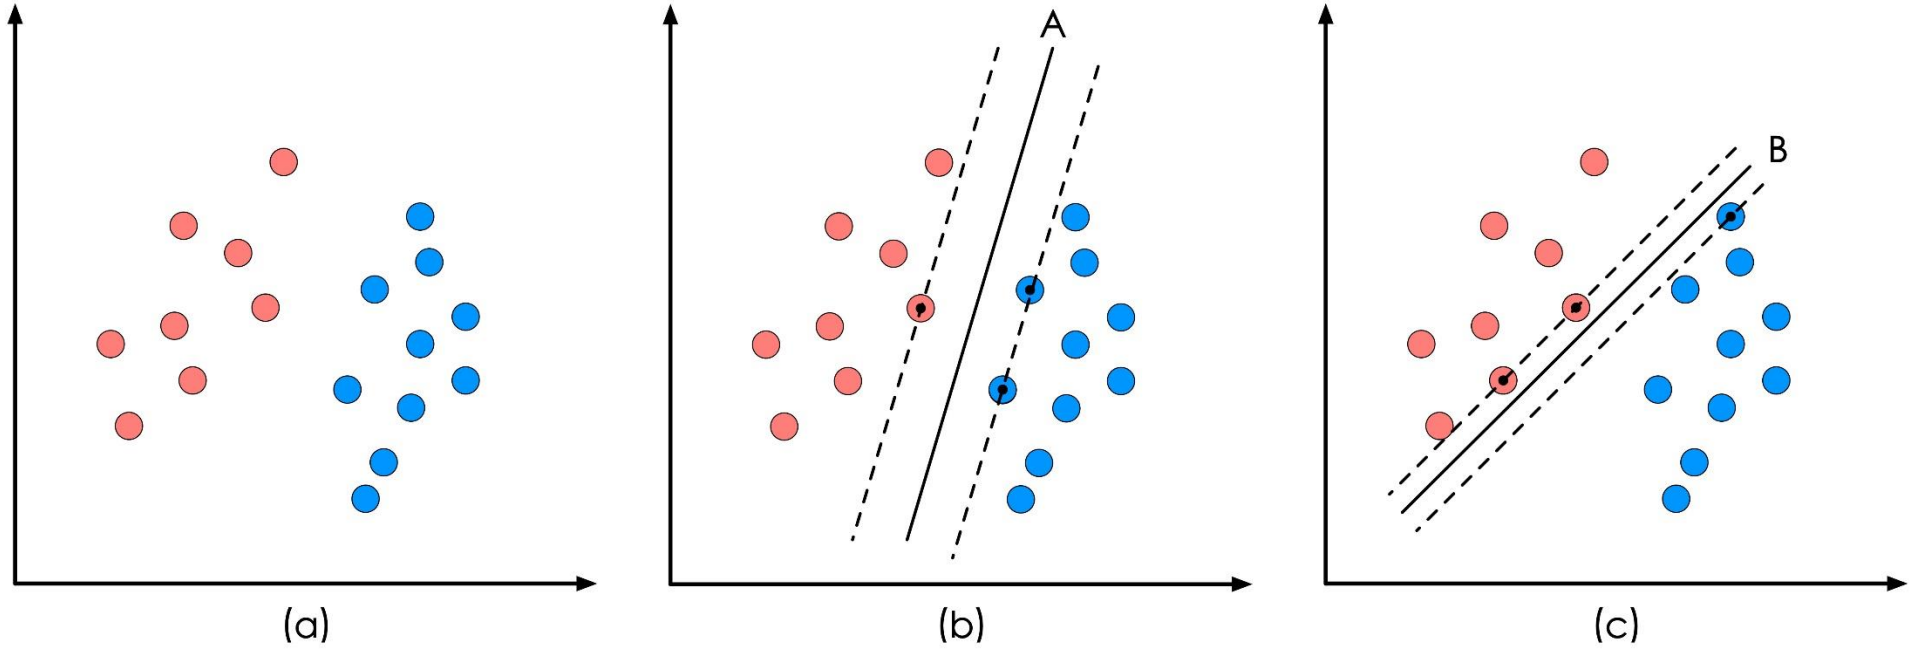
类别	聚类/降维	回归	分类	生成
线性方法	相关性 主成分分析 因子分析	多元线性回归	Logistic回归 判别分析	
最近邻	k均值聚类	kNN		
树型	层次聚类	决策树： 回归树	决策树： 分类树	深度 森林
密度	DBSCAN			
神经网络	SOM	ANN		
核函数		SVM（SVR）	SVM（SVC）	
图论	谱聚类	概率图模型	概率图模型	GNN
随机变量	高斯混合		贝叶斯分类	GAN
模糊数	模糊C 均值聚类	模糊逻辑模型 ANFIS	模糊逻辑模型	FDNN
深度学习	自动编码器	CNN，LSTM、Transformer		

主要内容

1. SVM的实例
2. SVM的发展史
3. SVM的简介
4. SVM的改进
5. 用Matlab构建SVM
6. 小结

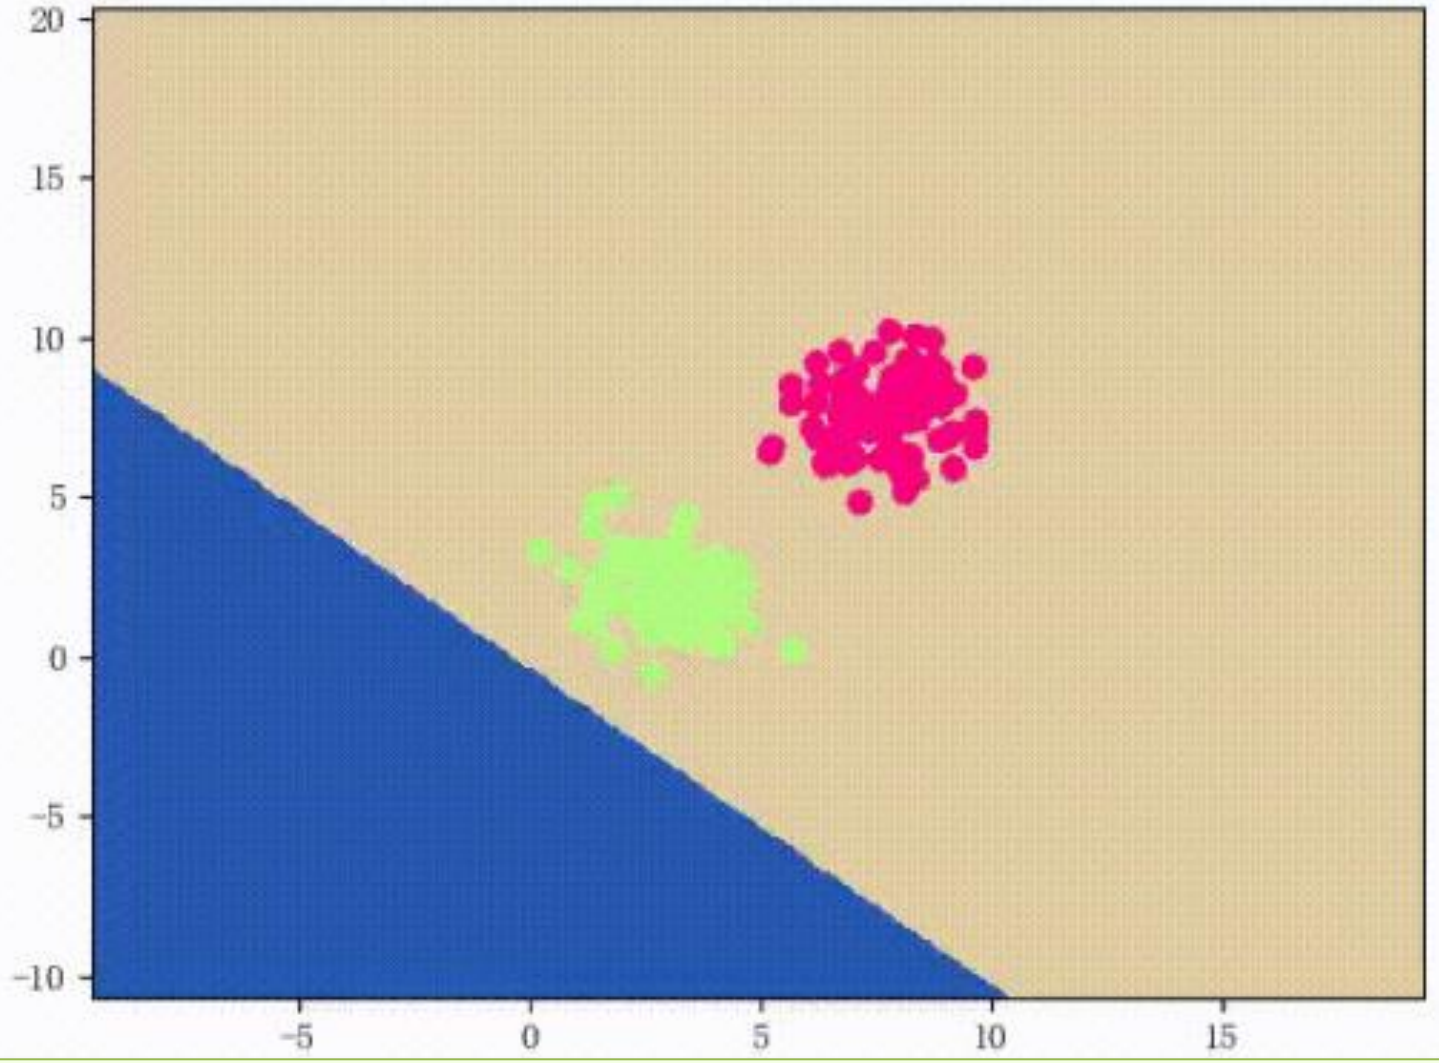
SVM的实例

SVM的例子



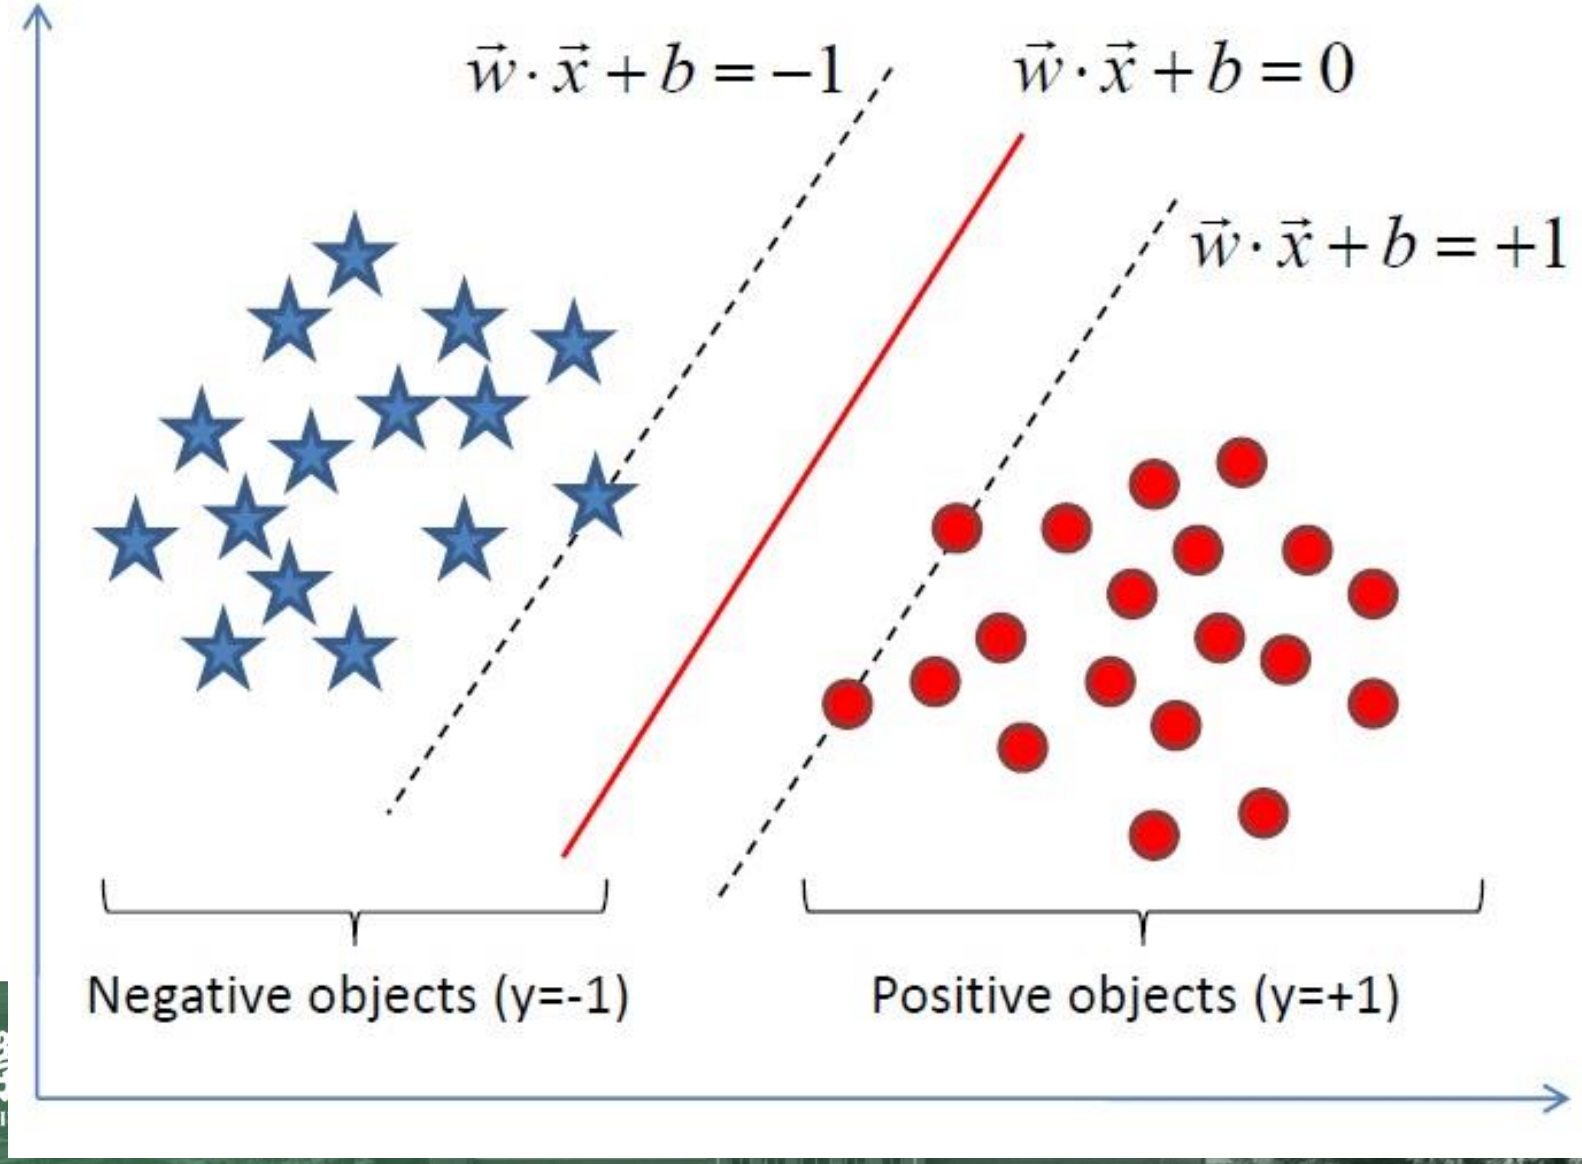
问题：哪个超平面是最好的?

SVM的例子

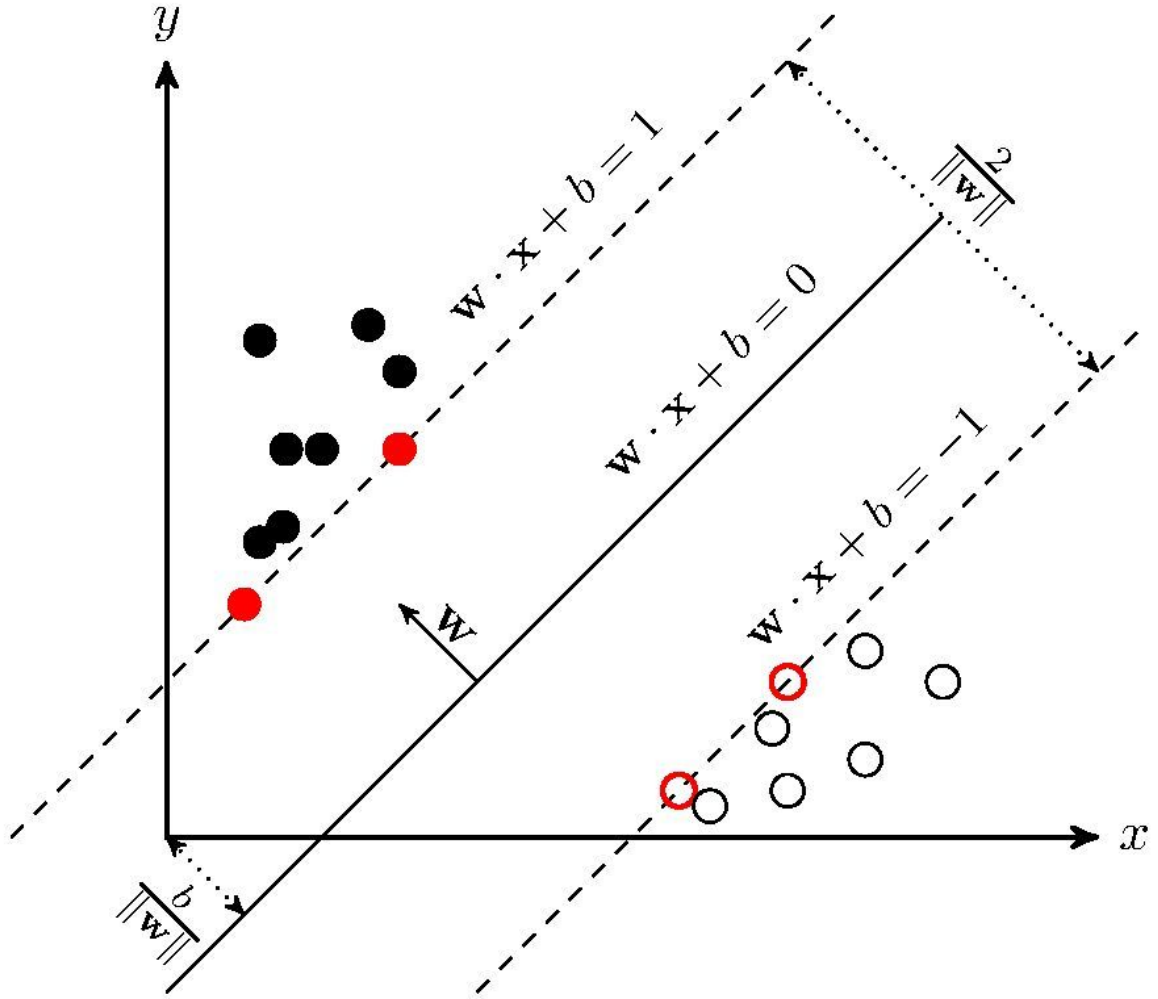


动态搜索到这个最好超平面？转化成什么问题

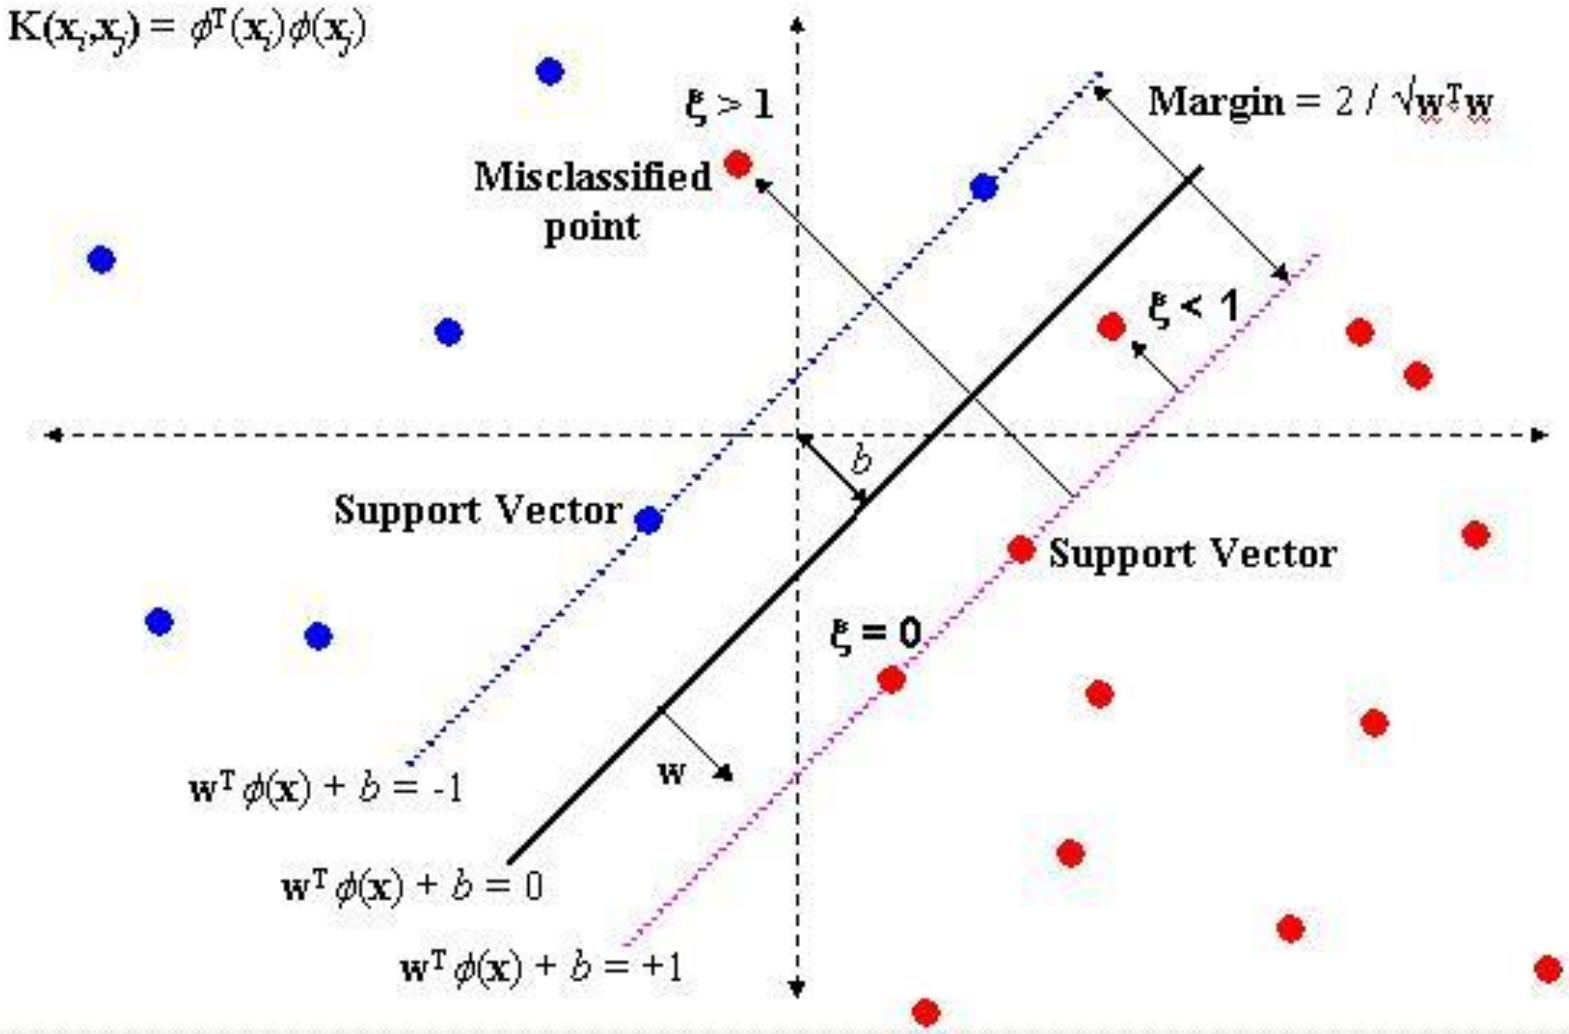
SVM的例子


$\vec{w}\cdot\vec{x}+b=-1$
$\vec{w}\cdot\vec{x}+b=0$
$\vec{w}\cdot\vec{x}+b=+1$
Negative objects (y=-1)
Positive objects (y=+1)

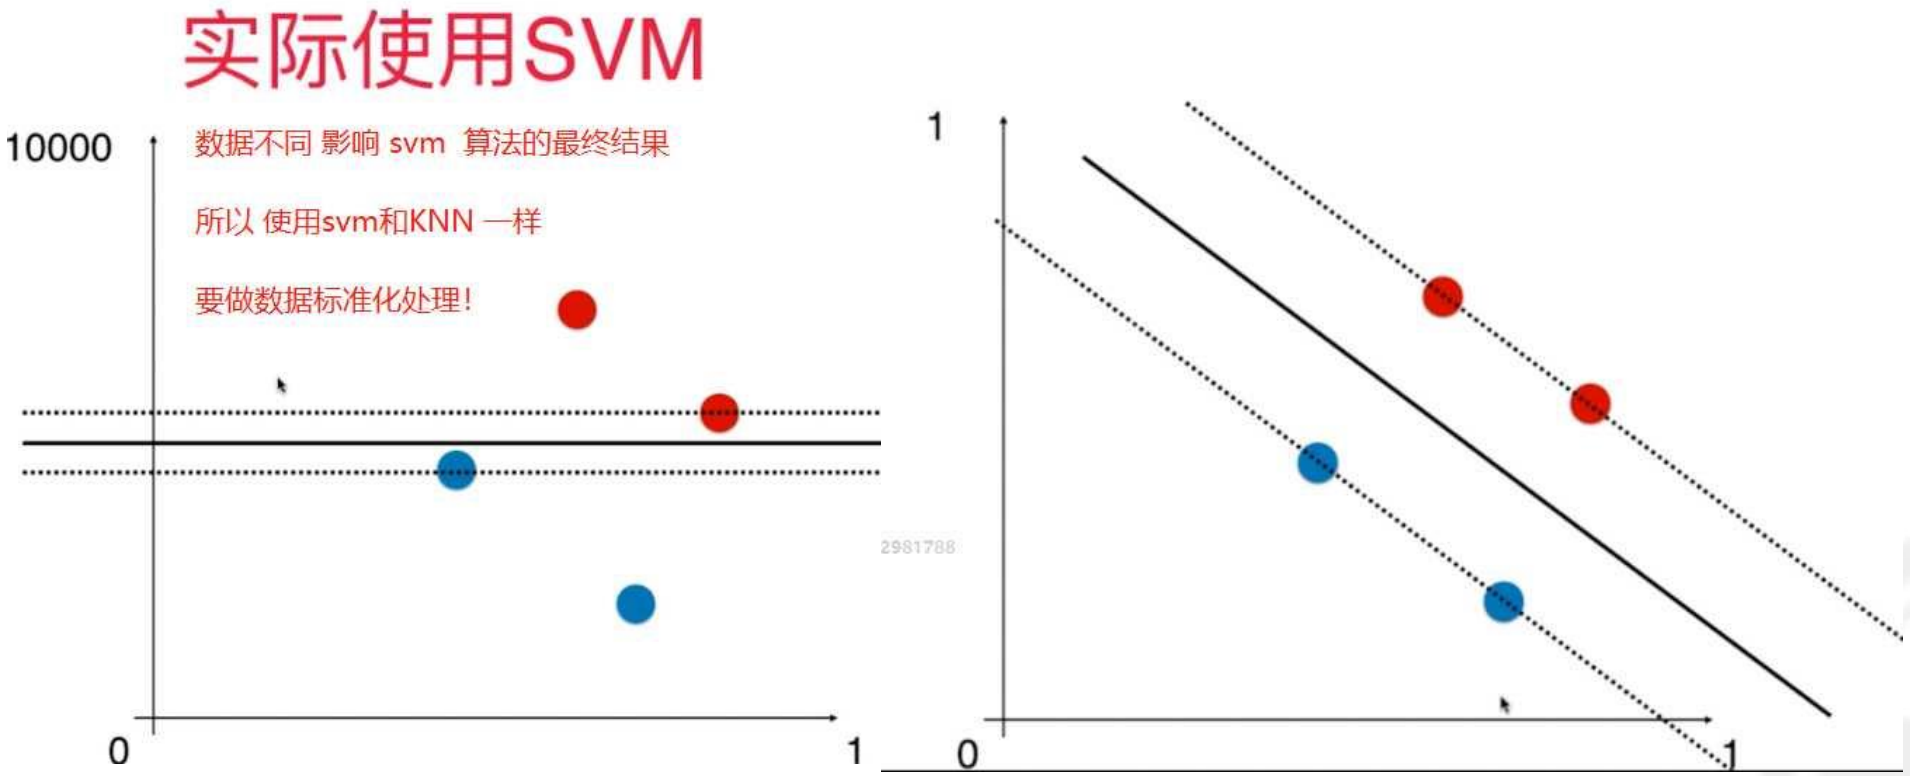
SVM的例子


y
x
$\mathbf{w}\cdot\mathbf{x}+b=1$
$\mathbf{w}\cdot\mathbf{x}+b=0$
$\mathbf{w}\cdot\mathbf{x}+b=-1$
$\mathbf{w}$
$\frac{2}{\|\mathbf{w}\|}$
$\frac{b}{\|\mathbf{w}\|}$

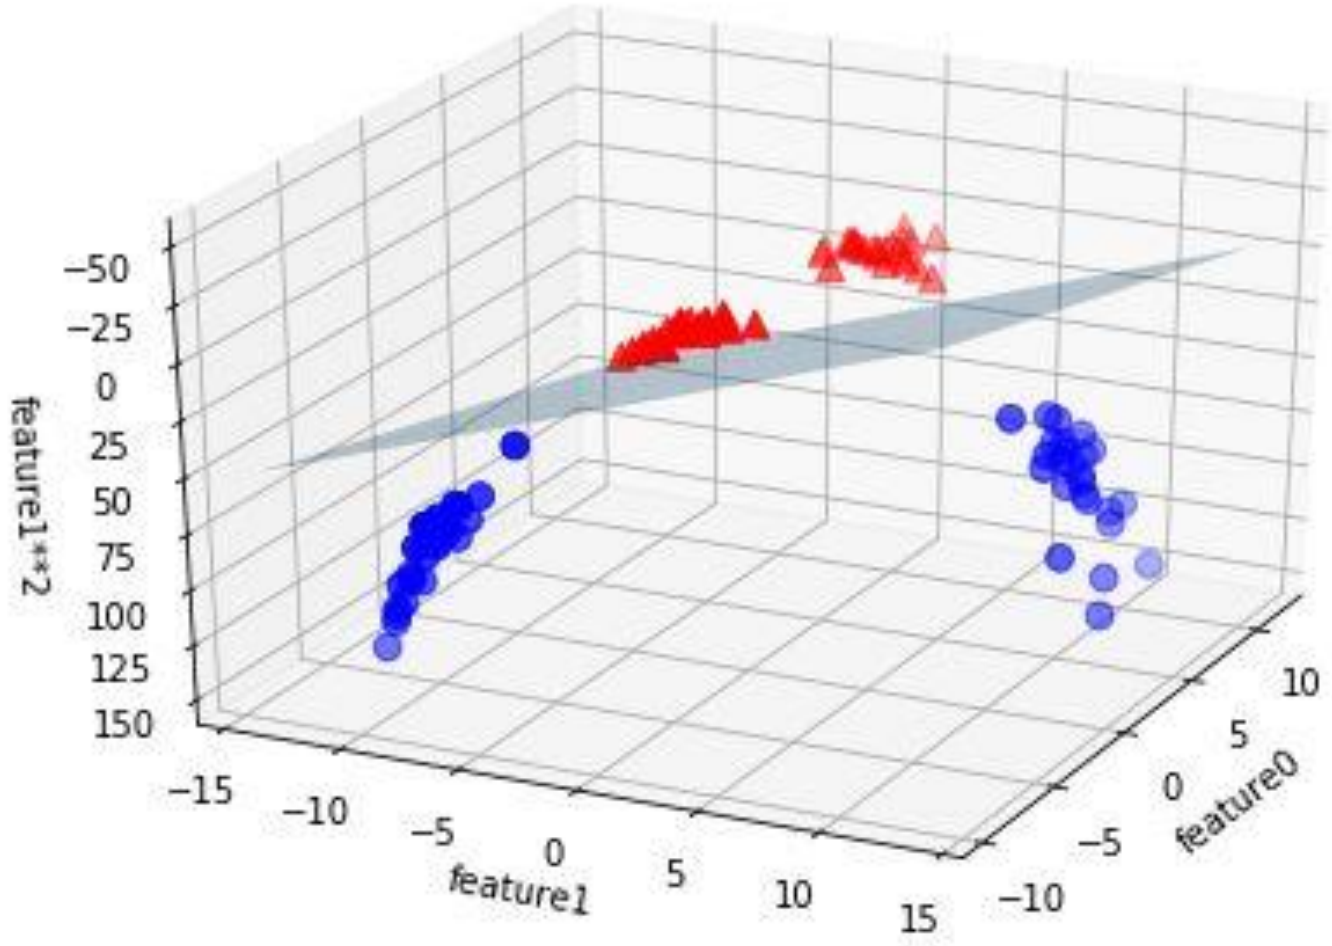
SVM的例子


$K(x_i,x_j) = \phi^T(x_i)\phi(x_j)$
$\xi > 1$
Misclassified point
Margin = $2 / \sqrt{w^T w}$
$\xi < 1$
b
Support Vector
Support Vector
$\xi = 0$
w
$w^T \phi(x) + b = -1$
$w^T \phi(x) + b = 0$
$w^T \phi(x) + b = +1$

SVM的归一化例子

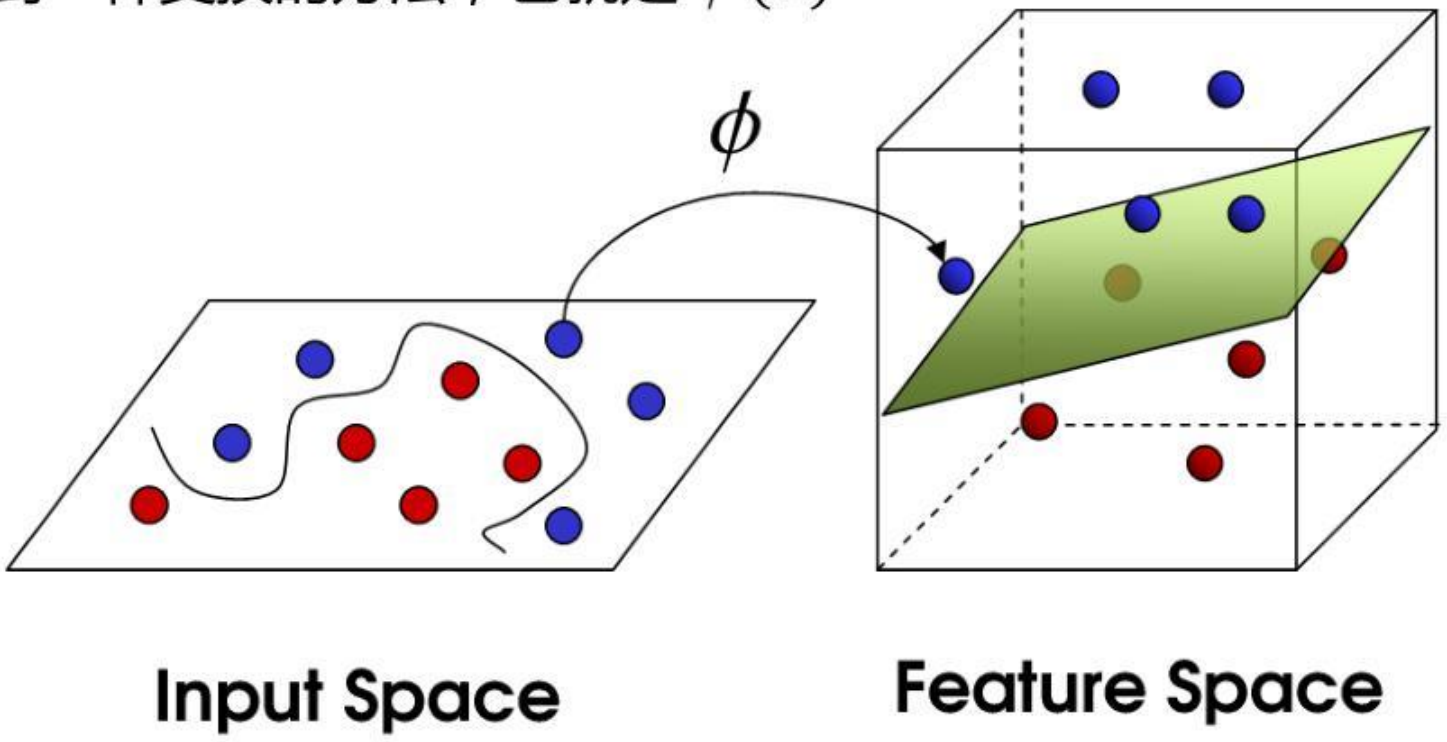

实际使用SVM
10000
数据不同 影响 svm 算法的最终结果
所以 使用svm和KNN 一样
要做数据标准化处理!
0
1
1
0
1

SVM的例子

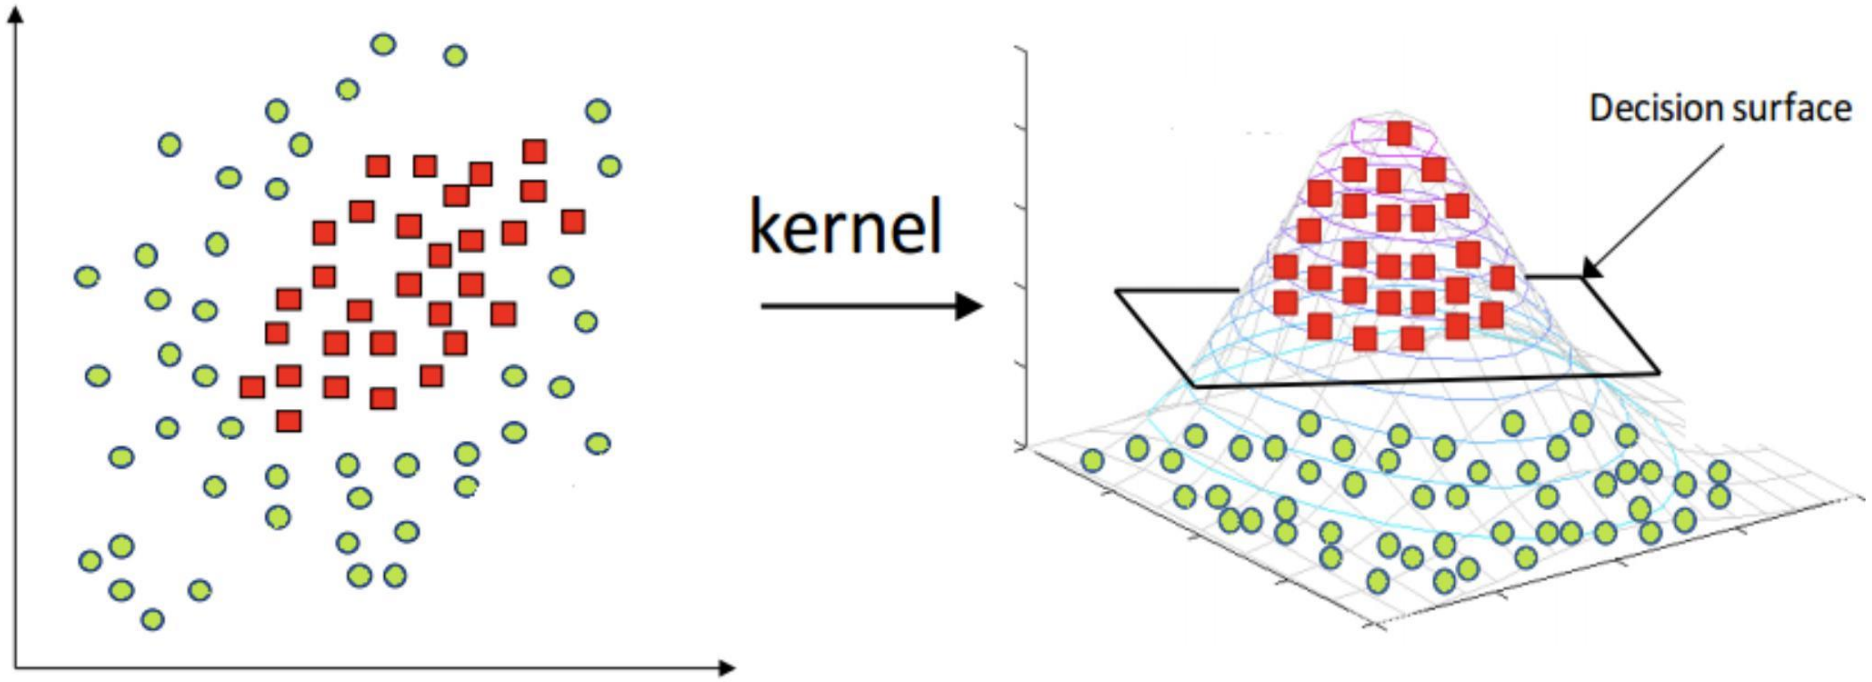

−50
−25
0
25
50
75
100
125
150
feature1**2
−15
−10
−5
0
5
10
15
feature1
10
5
0
−5
−10
feature0

SVM的高维映射例子

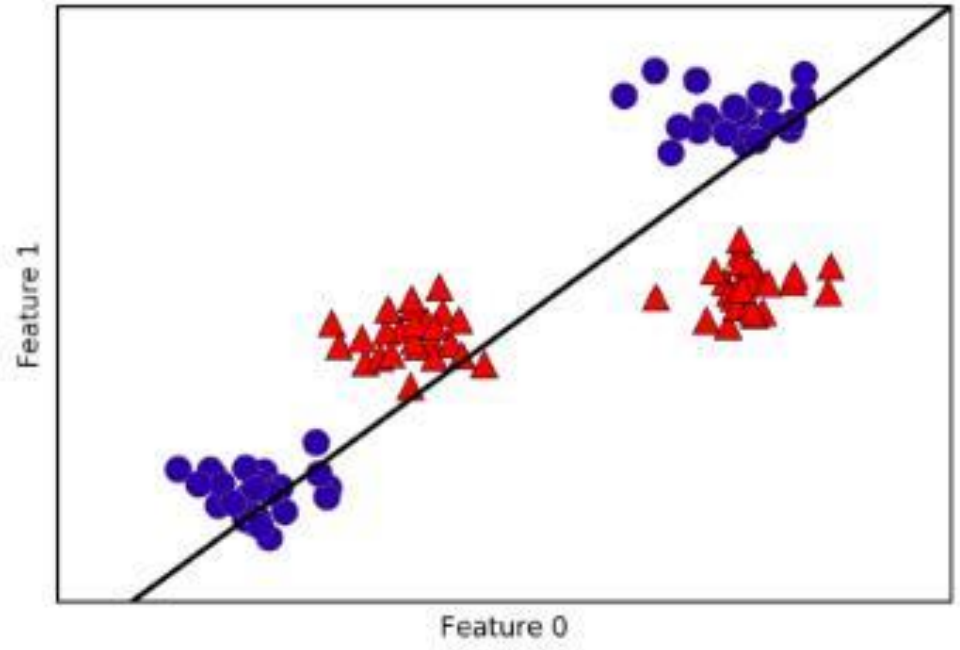
目标：找到一种变换的方法，也就是 $\phi(X)$

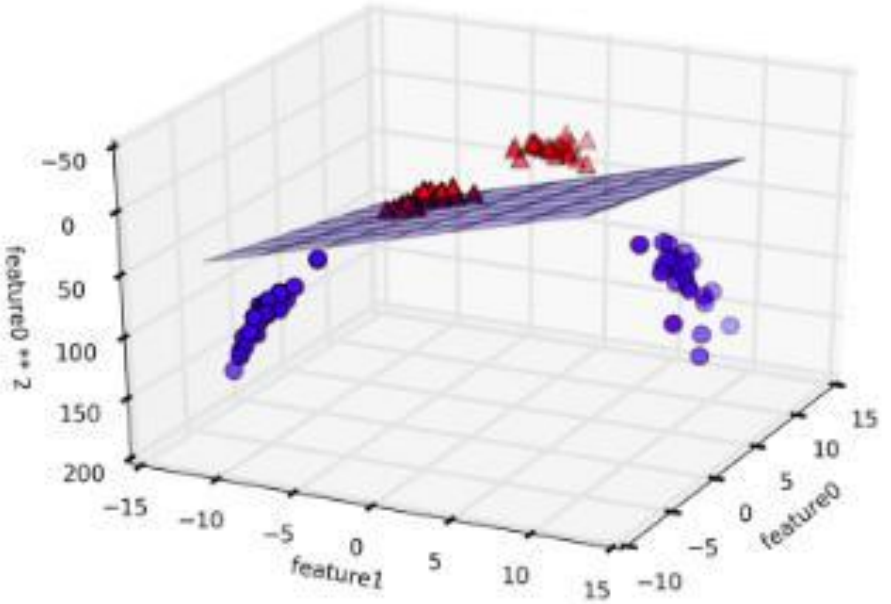


SVM的高维映射例子

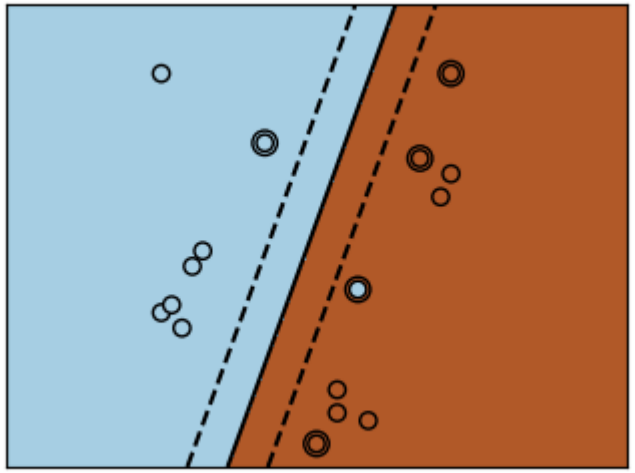


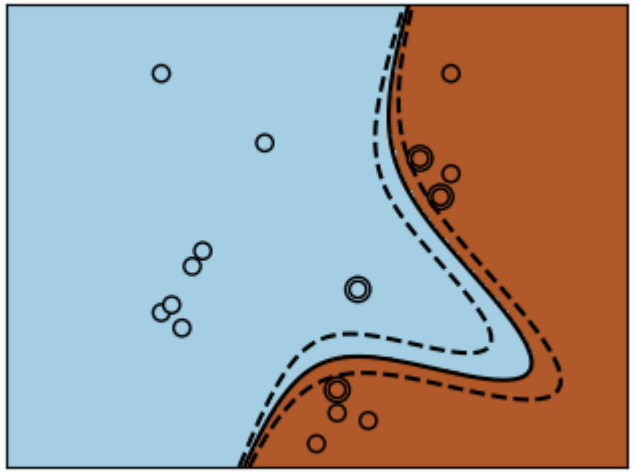
SVM的例子

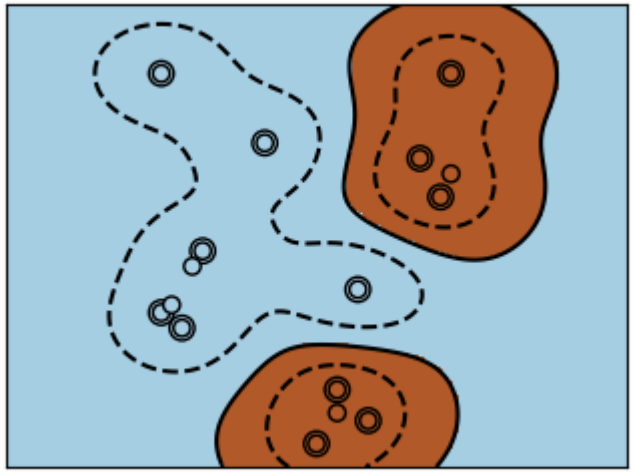

Feature 1
Feature 0


−50
0
50
100
150
200
feature0 ** 2
−15
−10
−5
0
5
10
15
feature1
15
10
5
0
−5
−10
feature0

SVM的高维映射实现非线性分类

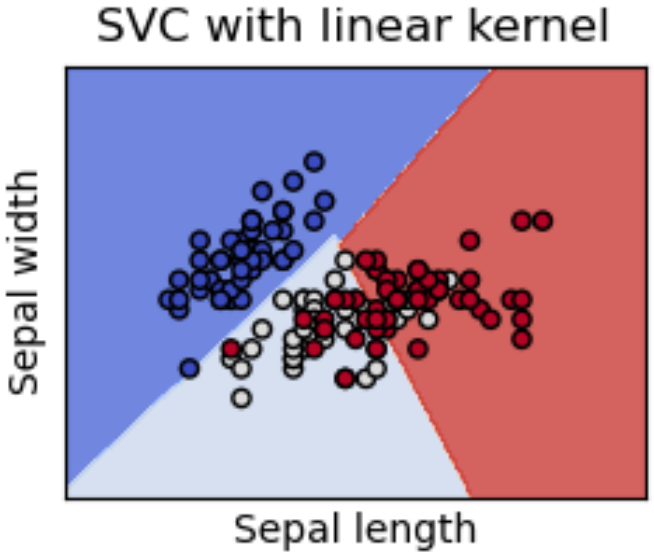


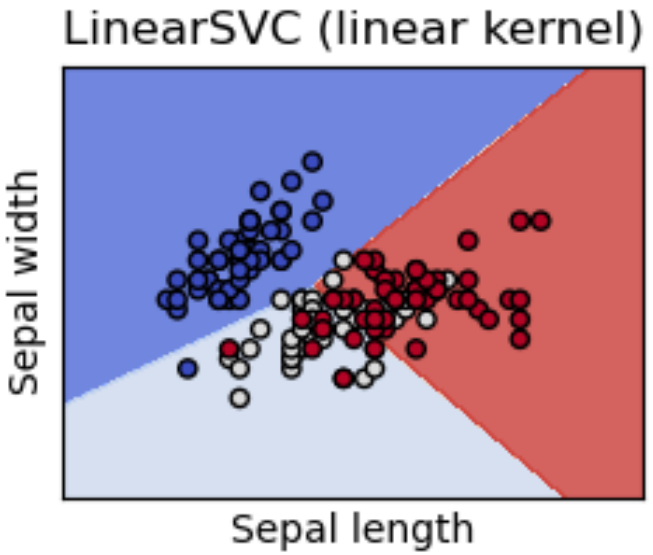


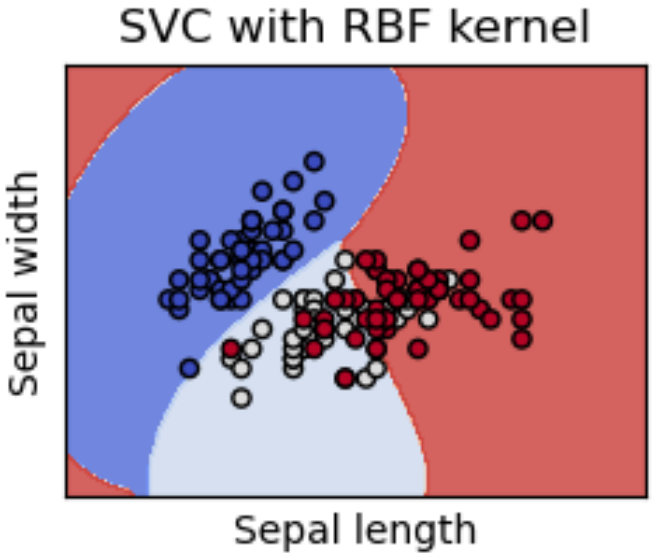


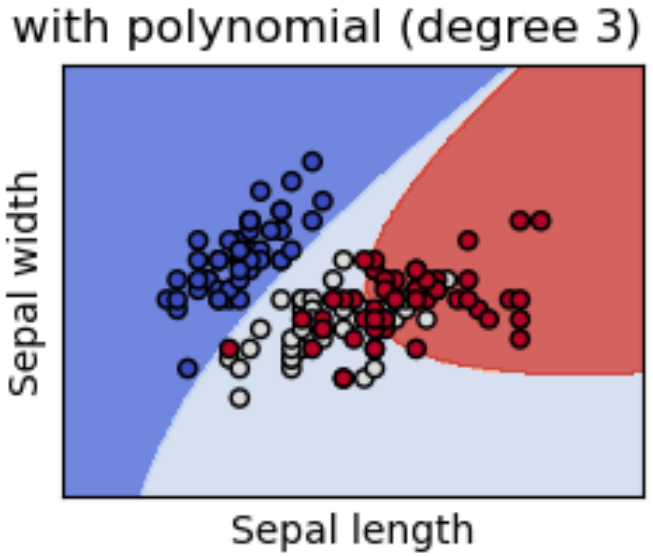
https://scikit-learn.org/stable/auto_examples/svm/plot_svm_kernels.html

SVM的高维映射实现非线性分类





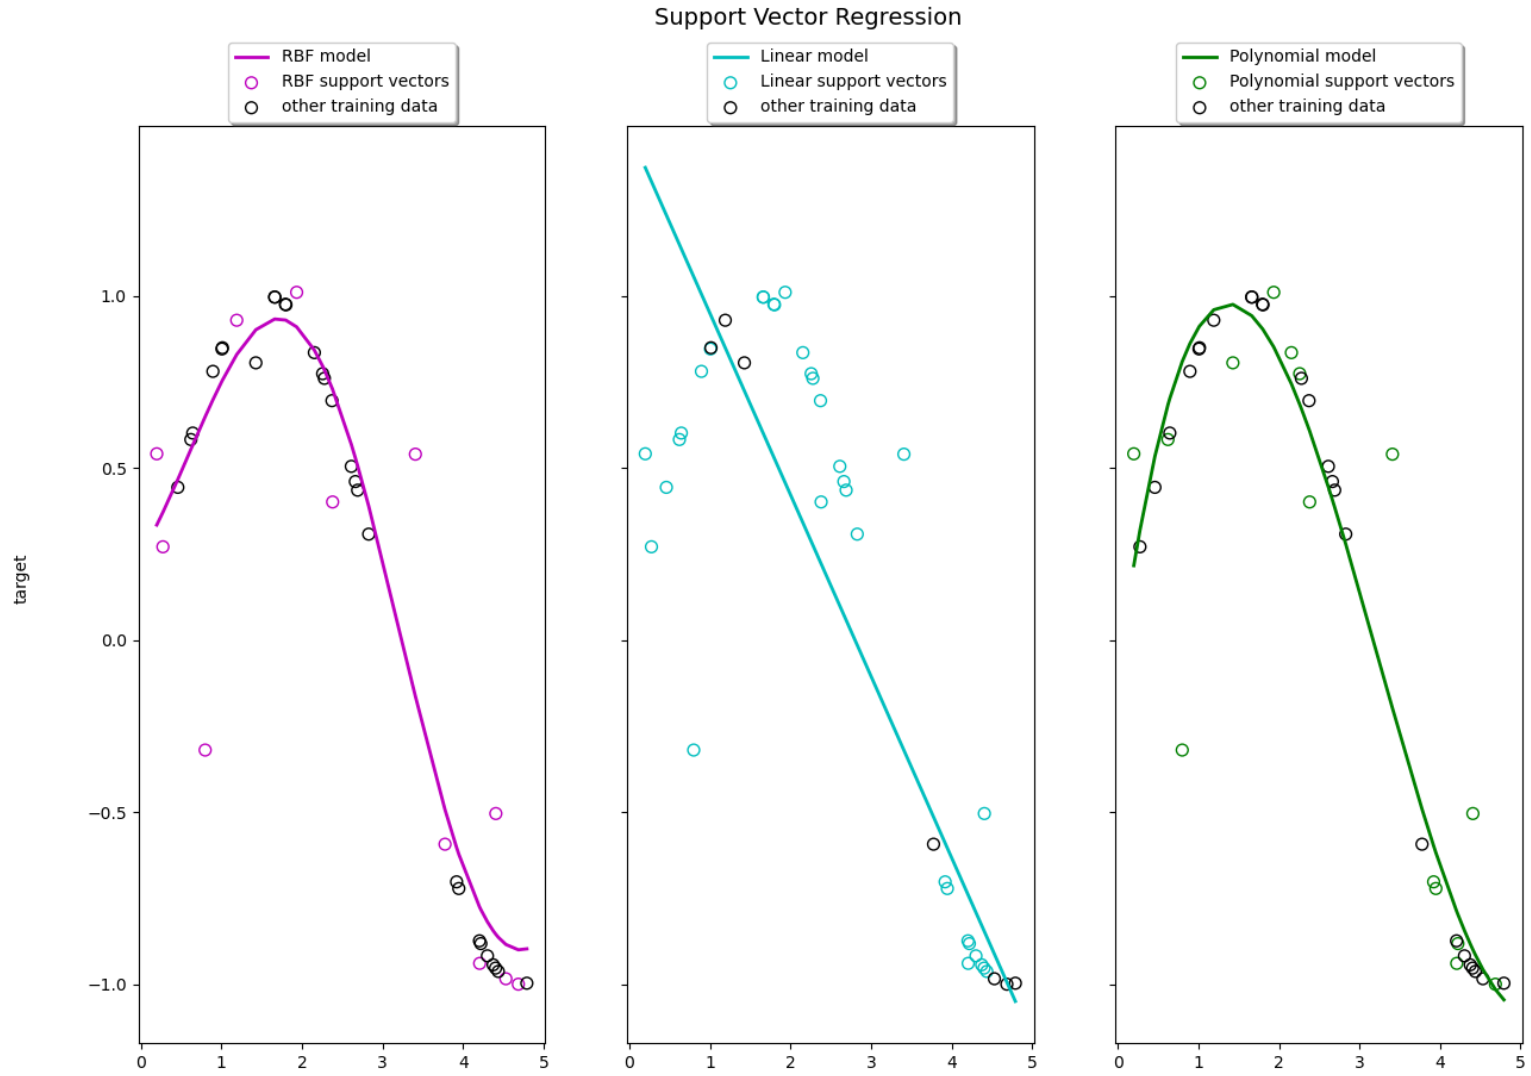




https://scikit-learn.org/stable/auto_examples/svm/plot_iris_svc.html

中山大学 SUN YAT-SEN UNIVERSITY

SVM的回归例子



https://scikit-learn.org/stable/auto_examples/svm/plot_svm_regression.html

SVM发展史

SVM发展史



Vladimir N. Vapnik

- **SVM是由模式识别中广义肖像算法发展而来的分类器，来自前苏联Vladimir N. Vapnik和Alexander Y. Lerner在1963年发表的研究。**
- **1964年，Vapnik和Alexey Y. Chervonenkis对广义肖像算法讨论并建立了硬边距的线性SVM 。**

SVM发展史



Alexey Y. Chervonenkis

在二十世纪70-80年代，出现

- **模式识别中最大边距决策边界的理论研究**
- **基于松弛变量规划问题求解技术**
- **VC维（Vapnik-Chervonenkis dimension）**

SVM被逐步理论化并成为统计学习理论的一部分 。

Vladimir N. Vapnik和Alexander Y. Lerner



SVM发展史

Bernhard E. Boser



Isabelle M. Guyon



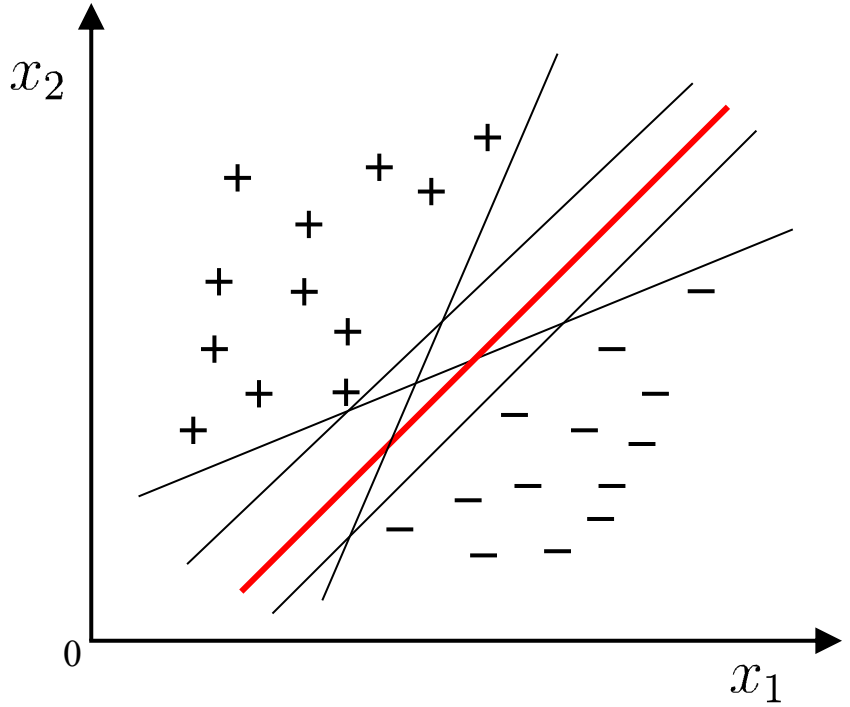
- 1992年，Bernhard E. Boser、Isabelle M. Guyon和Vapnik通过核方法得到了非线性SVM 。
- 1995年，Corinna Cortes和Vapnik提出了软边距的非线性SVM并应用于手写字符识别，得到了关注和引用，为SVM在各领域的应用提供了参考。

SVM的简介

SVM 的定义

- **中文**：支持向量机
- **英文**：Support Vector Machine, SVM
- **定义**：SVM是一类按监督学习方式对数据进行二元分类的广义线性分类器，其**决策边界**是对学习样本求解的**最大间隔超平面**（maximum-margin hyperplane）
- **功能**：
  - 支持向量分类 SVC=Support Vector Classification
  - 支持向量回归 SVR=Support Vector Regression

SVM 的概念：最大间隔超平面



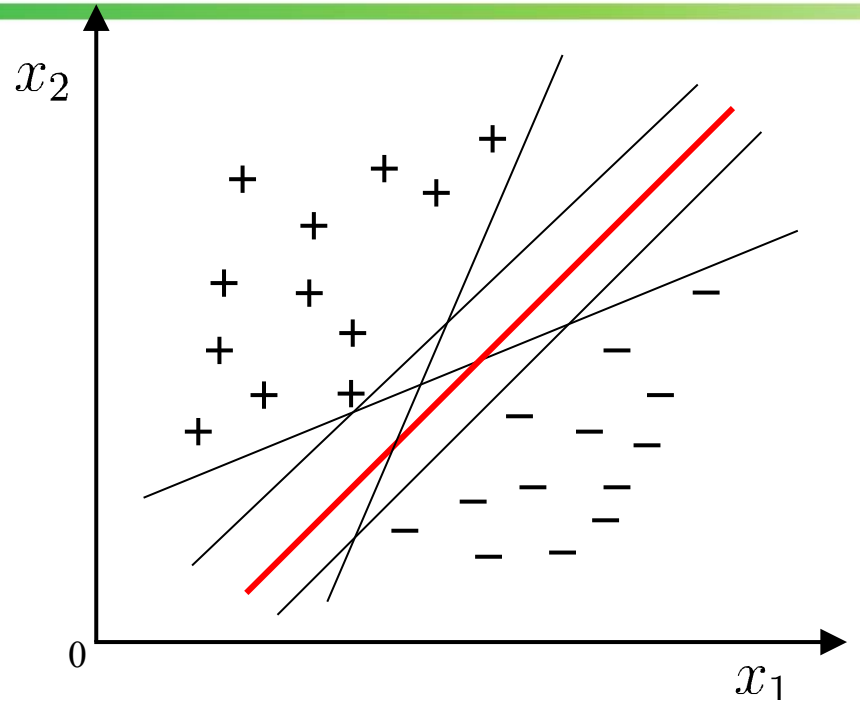
较大边缘（间隔）的决策边界比那些具有较小边缘的决策边界具有更好的泛化误差

SVM需要设计最大化决策边界间隔的线性分类器，以确保最坏情况下的泛化误差最小。

构造了2个平行的超平面作为间隔边界以分类

中山大学 SUN YAT-SEN UNIVERSITY

最大间隔超平面的性质



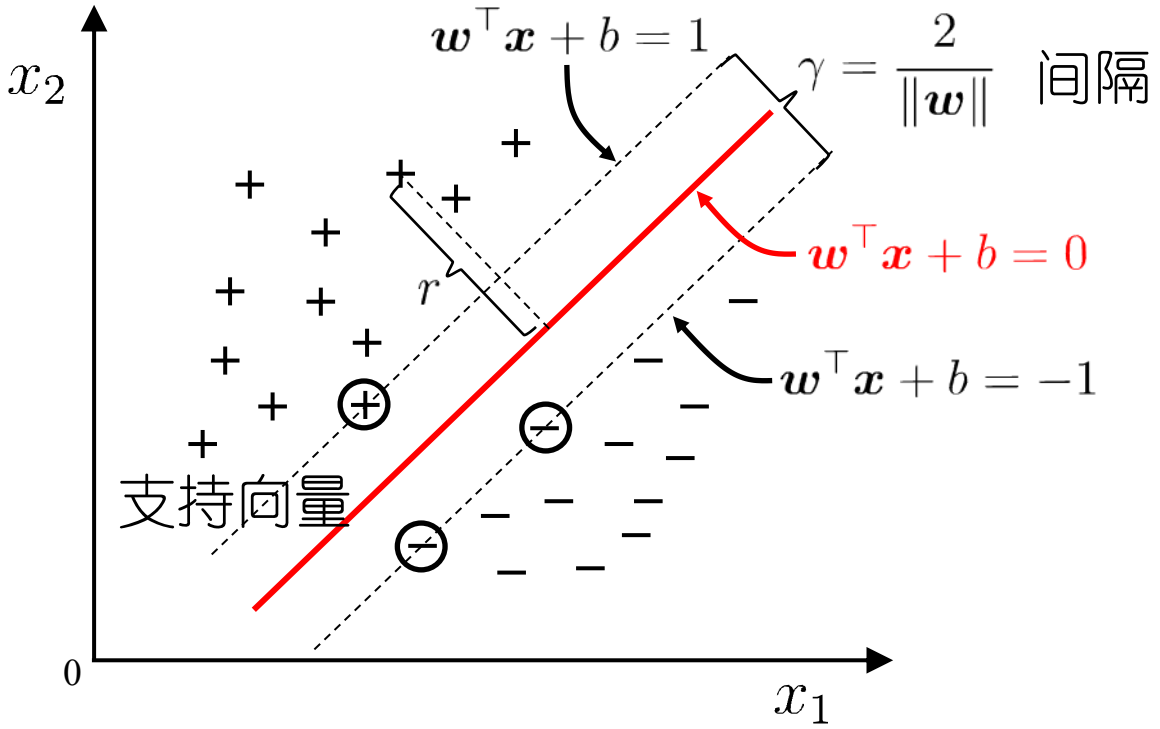
SVM寻找的最优分类超平面的性质

1）该超平面分开了两类

2）该超平面有最大化间隔

3）该超平面处于间隔的中间，到所有支持向量的距离相等。

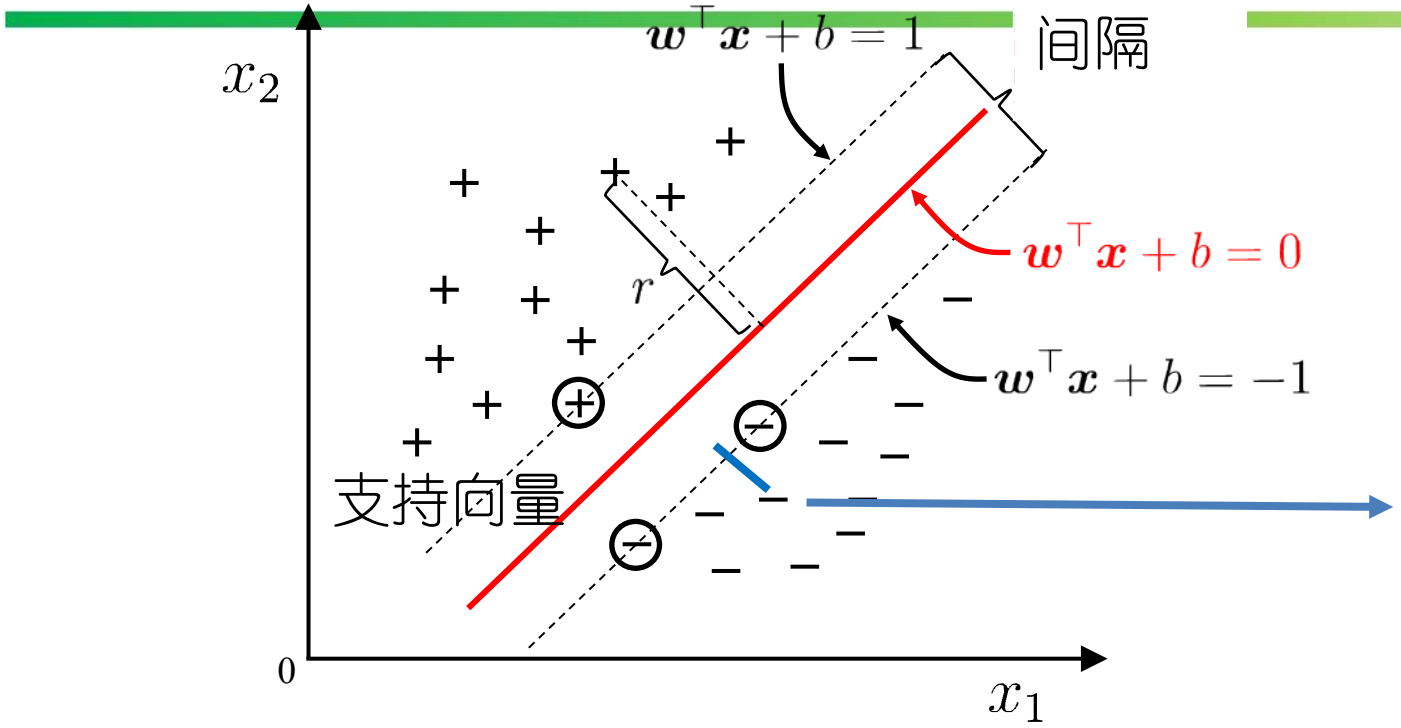
SVM 的概念：支持向量



位于间隔边界上的样本点，称为“支持向量”。

在上间隔边界上方样本属于正类，在下间隔边界下方样本属于负类。

SVM 的概念：决策边界的间隔



支持向量（点）到最大间隔超平面（面）距离

$$\frac{|w_1x_1 + w_2x_2 + b|}{\sqrt{w_1^2 + w_2^2}}$$

两个异类支持向量到决策边界距离之和被称为决策边界的间隔（或边缘, margin），等于两超平面之间的间隔γ。

间隔γ可通过点面之间的距离求得。$\gamma=2/\|\omega\|$

SVM的假设：线性可分性

模型：用于线性分类的SVM

假定：训练样本是线性可分的。

分类问题具有

- **线性可分性（linearly separable）**：即存在一个线性的决策边界能将所有的训练样本正确分类。
- **线性不可分或非线性可分（nonlinearly separable ）**：不存在一个线性的决策边界(只存在非线性的决策边界)能将所有的训练样本正确分类。

用于线性分类的SVM结构

学习目标为二元变量y，-1和+1 分别表示负类（negative class）和正类（positive class）

输入数据所在的特征空间存在作为**决策边界**（decision boundary）的**超平面**将学习目标按正类和负类分开，并使任意样本的点到平面距离大于等于1。

结构1

$$\begin{cases} \boldsymbol{w}^{\mathrm{T}}\boldsymbol{X}_i + b \geq +1, & \Rightarrow \quad y_i = +1 \\ \boldsymbol{w}^{\mathrm{T}}\boldsymbol{X}_i + b \leq -1, & \Rightarrow \quad y_i = -1 \end{cases}$$

结构2　　或者　　$y_i\left(\boldsymbol{w}^{\top}\boldsymbol{X}_i + b\right) \geq 1$

其中，参数 ω和b为超平面的**法向量**（垂直于超平面的直线）和**截距**。

线性可分的SVM 求解问题

求解：间隔γ最大化，寻找参数ω和b ,.

$$\arg\max_{\boldsymbol{w},b} \frac{2}{\|\boldsymbol{w}\|}$$

$$\text{s.t.} \quad y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1, \quad i = 1, 2, \ldots, m.$$

$$\arg\min_{\boldsymbol{w},b} \frac{1}{2}\|\boldsymbol{w}\|^2$$

等价于

$$\frac{1}{2}\sum_{i=1}^{m} \omega^2$$

$$\text{s.t.} \quad y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1, \quad i = 1, 2, \ldots, m.$$

目标函数是二次，约束条件是线性的，因此线性SVM的求解是一个凸二次优化问题，可以直接用现成的优化计算包求解，或者用更高效的拉格朗日乘子法求解。

SVM的优点

- **理论基础好**，属于统计学习方法。
- **功能强大**：处理线性和非线性分类和回归。
- 在高维空间中有效。
- **内存占用小**：在决策函数中使用训练点的子集（称为支持向量），因此它也是内存高效的。
- **稀疏性**: 训练完成后, 大部分的训练样本都不需保留, 最终模型仅与支持向量有关.
- **通用性**：可以为决策函数指定不同的内核函数。 提供了通用内核，可指定自定义内核。

SVM的缺点

- 如果特征数量远大于样本数量，在选择核函数时避免**过度拟合**，正则化项至关重要。
- SVM是基于小样本统计理论，对**大数据集**求解有一定困难。
- 对缺失数据敏感，对**参数**和**核函数**的**选择敏感**
- 经典SVM只用于二元分类，需要推广到**多元分类**。
- 不直接提供**概率估计**。

SVM的改进

SVM的改进

- **线性分类的改进求解**：SVM分类转化成**优化问题**，再转化成**对偶问题**（拉格朗日乘子法 + KKT条件）
- **线性分类效果不好**
  - **线性不可分/提高鲁棒性**➔**硬/软间隔**➔约束缩放和目标正则化
  - **非线性分类**：高维映射函数➔**内积求解**➔**核函数**
  - **非线性分类不好**➔**核函数+软间隔**
- **二元分类推广多元分类**
- **从分类推广到回归**
  - 线性回归：**软间隔**
  - 非线性回归：**核函数+软间隔**

拉格朗日乘子法和对偶问题：

– 第一步：引入拉格朗日乘子 $\alpha_i \geq 0$ 得拉格朗日函数

$$L(\boldsymbol{w}, b, \boldsymbol{\alpha}) = \frac{1}{2}\|\boldsymbol{w}\|^2 - \sum_{i=1}^{m} \alpha_i \left(y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) - 1\right)$$

– 第二步：令 $L(\boldsymbol{w}, b, \boldsymbol{\alpha})$ 对ω和b 的偏导为零可得

$$\boldsymbol{w} = \sum_{i=1}^{m} \alpha_i y_i \boldsymbol{x}_i, \quad \sum_{i=1}^{m} \alpha_i y_i = 0.$$

– 第三步：回代

$$\min_{\boldsymbol{\alpha}} \ \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j \boldsymbol{x}_i^\top \boldsymbol{x}_j - \sum_{i=1}^{m} \alpha_i$$

$$\text{s.t.} \ \sum_{i=1}^{m} \alpha_i y_i = 0, \ \alpha_i \geq 0, \ i = 1, 2, \ldots, m.$$

ω和b都消掉，只有α_i

对偶问题包含KKT条件

- 最终模型：

$$f(\boldsymbol{x}) = \boldsymbol{w}^{\top}\boldsymbol{x} + b = \sum_{i=1}^{m} \alpha_i y_i \boldsymbol{x}_i^{\top}\boldsymbol{x} + b$$

- KKT条件：

$$\begin{cases} \alpha_i \geq 0, \\ y_i f(\boldsymbol{x}_i) \geq 1, \\ \alpha_i (y_i f(\boldsymbol{x}_i) - 1) = 0. \end{cases}$$

$$y_i f(\boldsymbol{x}_i) > 1 \quad \Rightarrow \quad \alpha_i = 0$$

支持向量机解的稀疏性：训练完成后，大部分的训练样本都不需保留，最终模型仅与支持向量有关.

SVM 求解非线性分类问题

- **非线性分类**：实际应用中，在原始的样本空间内也许并不存在线性可分的的决策边界。
- **解法**：可将样本从原始空间映射到一个更高维的特征空间，使得样本在映射后的特征空间内线性可分。
- **原理**：如果原始空间是有限维，即属性数目有限，那么一定存在一个更高维的特征空间使得样本线性可分。

求解非线性分类SVM的优化问题

设样本x映射后的向量为$\phi(x)$，划分超平面为$f(x) = \omega^T\phi(x) + b$； SVM的求解如下：

原始问题

$$\min_{\boldsymbol{w},b} \ \frac{1}{2}\|\boldsymbol{w}\|^2$$

$$\text{s.t.} \ \ y_i(\boldsymbol{w}^\top\phi(\boldsymbol{x}_i) + b) \geq 1, \ \ i = 1, 2, \ldots, m.$$

对偶问题

$$\min_{\boldsymbol{\alpha}} \ \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j \phi(\boldsymbol{x}_i)^\top\phi(\boldsymbol{x}_j) - \sum_{i=1}^{m}\alpha_i$$

$$\text{s.t.} \ \ \sum_{i=1}^{m}\alpha_i y_i = 0, \ \ \alpha_i \geq 0, \ \ i = 1, 2, \ldots, m.$$

预测

$$f(\boldsymbol{x}) = \boldsymbol{w}^\top\phi(\boldsymbol{x}) + b = \sum_{i=1}^{m}\alpha_i y_i \phi(\boldsymbol{x}_i)^\top\phi(\boldsymbol{x}) + b$$

映射函数计算只以内积的形式出现（知道内积，不知道映射函数？）

用核函数来求解映射函数的计算

- **基本想法：**
  - **在对偶问题中，映射函数的计算只以内积形式出现**
  - **不显式地设计映射函数，避开映射函数的计算**
  - **而是设计核函数，用核函数计算进行求解**
- **问题：**
  - **怎么设计核函数?**
  - **怎么选择核函数?**

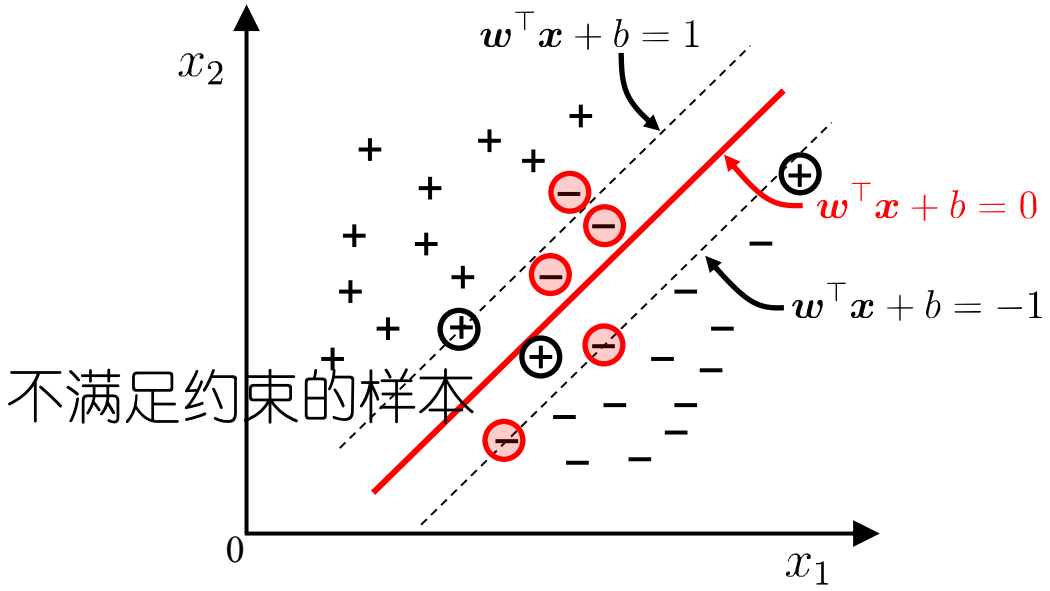
核函数的设计

- **Mercer定理(充分非必要)：只要一个对称函数所对应的核矩阵半正定, 则它就能作为核函数来使用.**
- **常用核函数列表**

名称	表达式	参数
线性核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \boldsymbol{x}_i^\top \boldsymbol{x}_j$	
多项式核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = (\boldsymbol{x}_i^\top \boldsymbol{x}_j)^d$	$d \geq 1$为多项式的次数
高斯核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \exp\left(-\frac{\|\boldsymbol{x}_i - \boldsymbol{x}_j\|^2}{2\delta^2}\right)$	$\delta > 0$为高斯核的带宽(width)
拉普拉斯核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \exp\left(-\frac{\|\boldsymbol{x}_i - \boldsymbol{x}_j\|}{\delta}\right)$	$\delta > 0$
Sigmoid核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \tanh(\beta \boldsymbol{x}_i^\top \boldsymbol{x}_j + \theta)$	tanh为双曲正切函数, $\beta > 0, \theta < 0$

SVM求解的缩放：软间隔

- Q: 现实中, 很难确定合适的核函数使得训练样本在特征空间中线性可分; 同时一个线性可分的结果也很难断定是否是有过拟合造成的.
- A: 引入"软间隔", 允许SVM在一些样本上不满足约束.



线性可分的SVM的软间隔形式

最小化目标 $\frac{1}{2}\|\omega\|^2+C\sum_{i=1}^{N}\xi_i^2$

约束

$$\begin{cases}\xi_i \geq 0 \\ y_i(\varpi^T x_i + b) \geq 1-\xi_i\end{cases}$$

软间隔的非线性分类的SVM

原始问题

$$\min_{\boldsymbol{w},b} \ \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{i=1}^{m}\max\left(0, 1 - y_i(\boldsymbol{w}^\top\phi(\boldsymbol{x}_i) + b)\right)$$

对偶问题

$$\min_{\boldsymbol{\alpha}} \ \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j \phi(\boldsymbol{x}_i)^\top\phi(\boldsymbol{x}_j) - \sum_{i=1}^{m}\alpha_i$$

$$\text{s.t.} \ \sum_{i=1}^{m}\alpha_i y_i = 0, \ 0 \le \alpha_i \le C, \ i = 1, 2, \ldots, m.$$

根据KKT条件可推得最终模型仅与支持向量有关，也即hinge损失函数依然保持了SVM解的稀疏性.

SVM的一般形式：正则化

$$\min_f \quad \Omega(f) + C \sum_{i=1}^{m} l(f(\boldsymbol{x}_i), y_i)$$

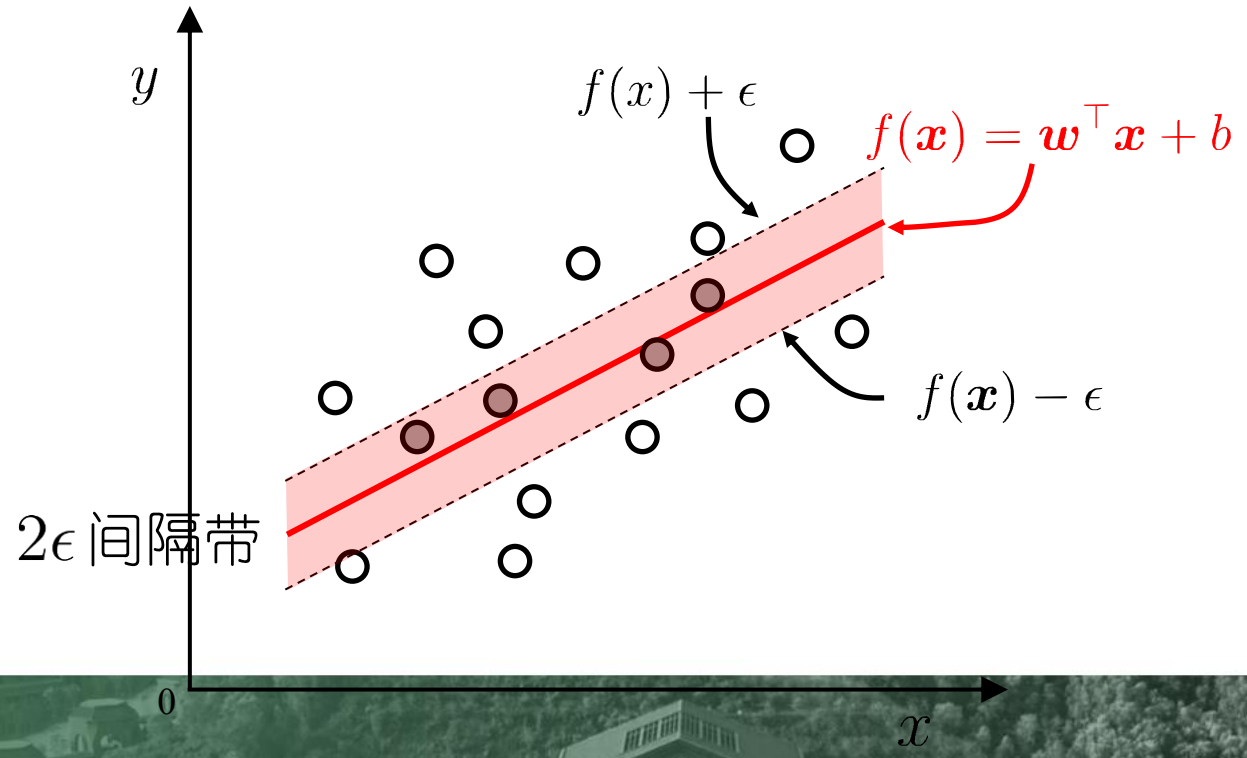
结构风险：描述模型的某些结构性质

经验风险：描述模型与训练数据的契合程度

SVM用于回归

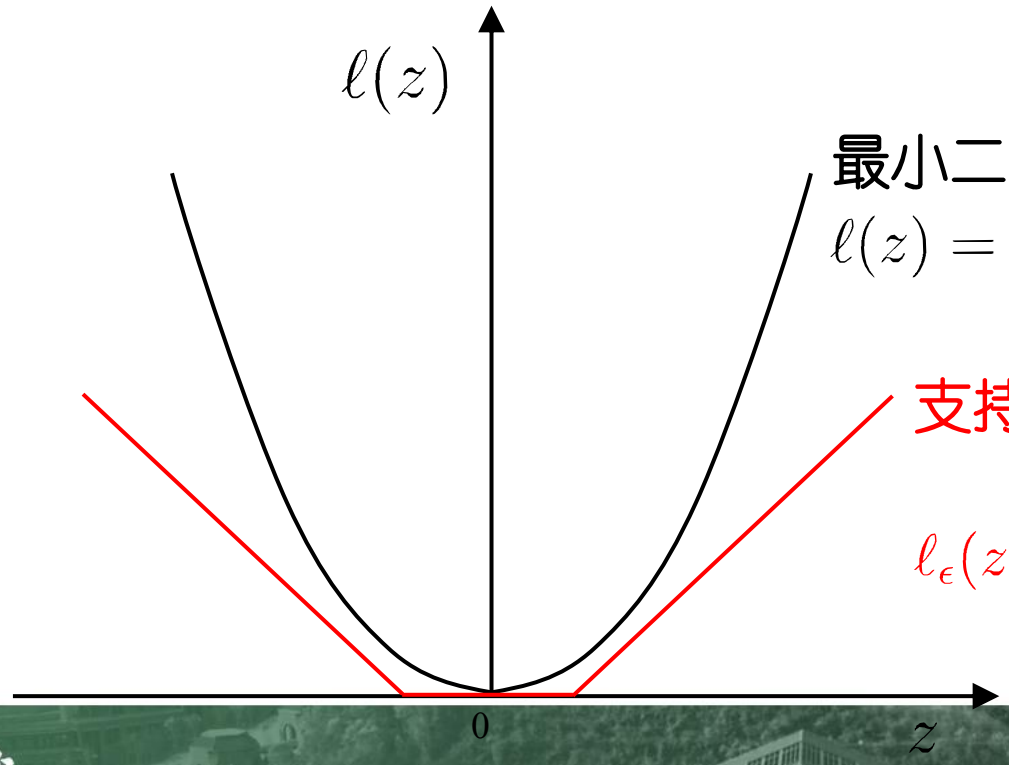
基本思想：

允许模型输出和实际输出间存的偏差.



SVM回归的损失函数

实现：落入中间2ε 间隔带的样本不计算损失, 从而使得模型获得稀疏性.



最小二乘损失函数

$$\ell(z) = z^2$$

支持向量回归损失函数

$$\ell_\epsilon(z) = \begin{cases} 0 & \text{if } |z| \le \epsilon \\ |z| - \epsilon & \text{otherwise} \end{cases}$$

SVM回归的求解

原始问题

$$\begin{aligned}\min_{\boldsymbol{w},b,\xi_i,\hat{\xi}_i} \quad & \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{i=1}^{m}(\xi_i + \hat{\xi}_i) \\ \text{s.t.} \quad & y_i - \boldsymbol{w}^\top\phi(\boldsymbol{x}_i) - b \le \epsilon + \xi_i, \\ & y_i - \boldsymbol{w}^\top\phi(\boldsymbol{x}_i) - b \ge -\epsilon - \hat{\xi}_i, \\ & \xi_i \ge 0,\ \hat{\xi}_i \ge 0,\ i = 1, 2, \ldots, m.\end{aligned}$$

上下间隔不一样

对偶问题

$$\begin{aligned}\min_{\boldsymbol{\alpha},\hat{\boldsymbol{\alpha}}} \quad & \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}(\alpha_i - \hat{\alpha}_i)(\alpha_j - \hat{\alpha}_j)\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) + \sum_{i=1}^{m}(\alpha_i(\epsilon - y_i) + \hat{\alpha}_i(\epsilon + y_i)) \\ \text{s.t.} \quad & \sum_{i=1}^{m}(\alpha_i - \hat{\alpha}_i) = 0, \\ & 0 \le \alpha_i \le C,\ 0 \le \hat{\alpha}_i \le C.\end{aligned}$$

核函数

预测

$$f(\boldsymbol{x}) = \boldsymbol{w}^\top\phi(\boldsymbol{x}) + b = \sum_{i=1}^{m}(\hat{\alpha}_i - \alpha_i)y_i\kappa(\boldsymbol{x}_i, \boldsymbol{x}) + b$$

用Matlab构建SVM

构建SVM模型基本步骤

步骤	基本命令	功能
数据预处理		数据标准化
		将原始数据分割成 训练练集P和验证集Q
训练模型	fitcsvm	训练SVM分类（SVC）模型
	fitrsvm	训练SVM回归（SVR）模型
预测	predict	训练集预测
		验证集预测
性能评估		数据后处理
		预测性能的评估

fitcsvm函数的调用格式

格式	用途
Mdl = fitcsvm(Tbl,ResponseVarName)	返回训练的支持向量机 (SVM) 分类器Mdl。该分类器使用表 Tbl 中包含的样本数据进行训练。ResponseVarName 是 Tbl 中变量的名称，包含一类或二类分类的类标签。
Mdl = fitcsvm(Tbl,formula)	该分类器使用表 Tbl 中包含的样本数据进行训练。formula 是拟合 Mdl 的解释模型，由 Tbl 中的响应和一部分预测变量构成。
Mdl = fitcsvm(Tbl,Y)	该分类器使用表 Tbl 中的预测变量和向量 Y 中的类标签进行训练。
Mdl = fitcsvm(X,Y)	该分类器使用矩阵 X 中的预测变量和向量 Y 中的一类或两类分类的类标签进行训练。
Mdl = fitcsvm(___,Name,Value)	使用一个或多个名称-值对参数指定选项。例如，可以指定交叉验证的类型、误分类的代价以及分数转换函数的类型。

fitrsvm函数的调用格式

格式	用途
Mdl = fitrsvm(Tbl,ResponseVarName)	返回使用表 Tbl 中的预测变量（X)值和 Tbl.ResponseVarName 中的响应值（Y)，训练的支持向量机 (SVM) 回归模型 Mdl。
Mdl =fitrsvm(Tbl, formula)	Tbl 中X值,formula是响应的解释模型和 Tbl 中用于拟合 Mdl 的X子集。
Mdl = fitrsvm(Tbl,Y)	使用表 Tbl 中的预测变量值和向量 Y 中的响应值进行训练。
Mdl = fitrsvm(X,Y)	该模型使用矩阵 X 中的预测变量值和向量 Y 中的响应值进行训练。
Mdl =fitrsvm(___,Name,Value)	包含由一个或多个名称-值对参数指定的附加选项.例如，您可以指定核函数或训练交叉验证模型。

5. 小结

思考?

- 什么是SVM?
- SVM的结构和功能? （具体用于解决什么类型的问题？）
- SVM如何求解?
- SVM用Matlab如何实现?

SVM模型基本类型

类型	功能	备注
硬间隔线性分类	当训练数据线性可分时，可通过硬间隔最大化，得到一个SVM。	处理线性二元可分问题
软间隔线性分类	当训练数据近似线性可分时，可通过软间隔最大化，得一个SVM	只是弱化了硬间隔SVM的条件
非线性分类	当训练数据线性不可分时，可通过核函数以及软间隔最大化，得到一个非线性SVM。	处理非线性二元可分问题
线性回归		
非线性回归		