第13章 文本分析扩展：NLP 模型在 MATLAB 中的实现

课程：人工智能与地理数据挖掘

教师：孙伟

邮箱：sunwei29@mail.sysu.edu.cn

单位：中山大学 地理科学与规划学院

日期：2026年6月



第13章 文本分析扩展 - 提纲

13.1 文本分析扩展概述

13.2 MATLAB 文本分析工具箱回顾

13.3 文本数据导入与可视化

13.4 文本数据预处理

13.5 将文本转换为数值格式

13.6 文本数据机器学习

13.7 文本数据深度学习

13.8 经典开源 NLP 模型在 MATLAB 中的使用

13.9 小结与思考题

13.1 · 文本分析扩展概述

- 文本分析完整流程：**导入** → **可视化** → **预处理** → **数值化** → **机器学习** → **深度学习**
- MATLAB 文本分析工具箱（Text Analytics Toolbox）核心函数速览
- 经典开源 NLP 模型（BERT、FinBERT、GPT-2）已由 MathWorks 转化为纯 MATLAB 代码
- 面向中文场景的可行技术路线
- 为后续大语言模型与 RAG 章节打好"文档向量化"基础

学习目标

> 文本是非结构化数据的大头——会"算"文本，才能挖掘它的价值
> 完成本章后，你将能够：

- **走通** 文本分析五步流程，说出每步的关键 MATLAB 函数
- **选择** 合适的数值化方案：词袋/tf-idf、词嵌入、文档嵌入
- **使用** LDA 做主题建模、wordcloud 做文本可视化
- **加载并微调** BERT 完成文本分类，用 GPT-2 生成摘要
- **理解** BERT 与 GPT-2 的结构差异与适用任务

扩展目标

在 MATLAB 文本分析和报告生成工具箱基础上，本部分扩展两方面内容：

- **系统讲解文本分析完整流程**
  - 文本数据导入和可视化、预处理、转换为数值格式、机器学习、深度学习
- **介绍经典开源 NLP 模型在 MATLAB 中的落地**
  - 向学生介绍 GitHub 上已转化成 MATLAB 的 BERT、GPT-2 等模型
  - 方便学生直接使用和理解，避免从零搭建

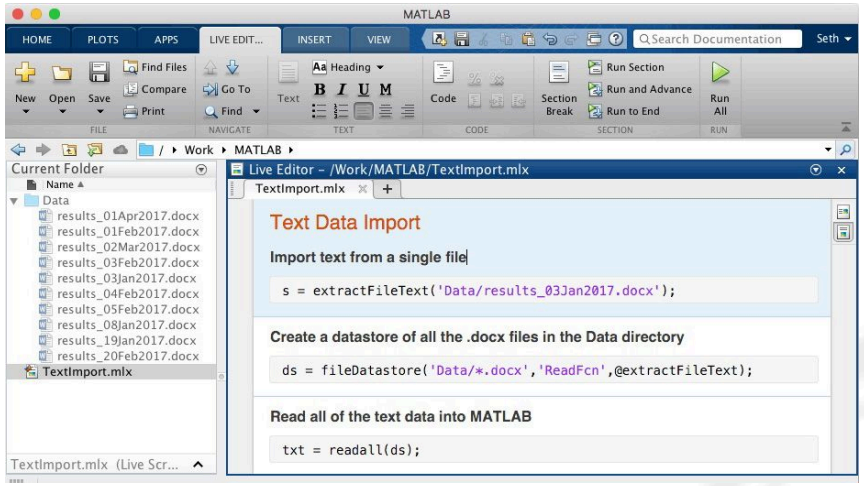
核心思想：**不重复造轮子**——站在预训练模型的肩膀上做文本挖掘

13.2 · 文本分析工具箱（Text Analytics Toolbox）

MathWorks 提供的文本分析专用工具箱，覆盖从原始文本到模型的完整流程：

官网：https://ww2.mathworks.cn/products/text-analytics.html

- **提取**：PDF、HTML、Word、Excel 文本
- **预处理**：分词、停用词、词干化/词形还原
- **数值化**：词频、tf-idf、词/文档嵌入
- **建模**：LDA/LSA 主题模型、情感分析
- **深度学习**：LSTM/CNN/BERT/GPT-2



第13章 文本分析扩展

13.1 文本分析扩展概述

13.2 MATLAB 文本分析工具箱回顾

13.3 文本数据导入与可视化

13.4 文本数据预处理

13.5 将文本转换为数值格式

13.6 文本数据机器学习

13.7 文本数据深度学习

13.8 经典开源 NLP 模型在 MATLAB 中的使用

13.9 小结与思考题

13.3.1 提取文本数据

从社交媒体、新闻提要、设备日志、报告和调查等来源提取文本：

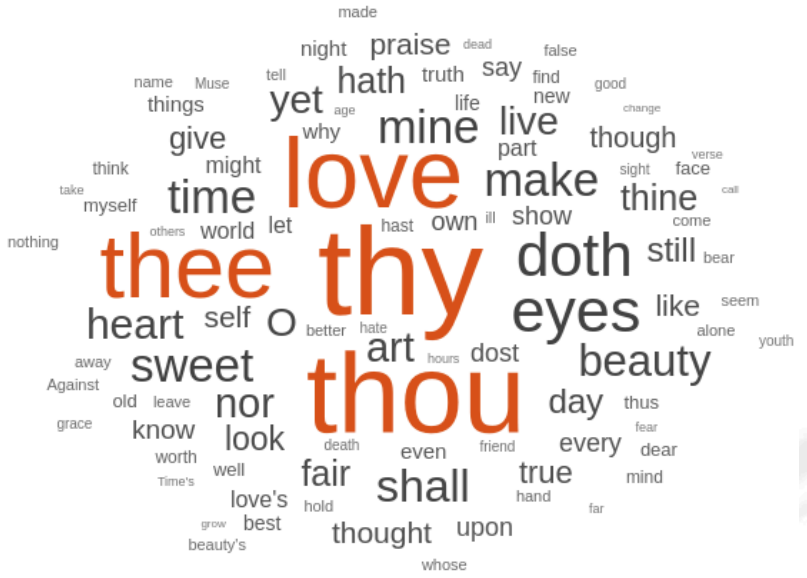
- 从 **PDF、HTML、Microsoft Word、Excel** 文件提取文本
- 解析 HTML 并提取文本内容
- 分析包含**表情符号**的文本数据
- 关键函数：**extractFileText**、readtable、htmlTree

extractFileText 直接读取 .docx/.pdf 报告，fileDatastore 批量导入整个目录——这是文本分析的第一步

13.3.2 文本可视化

使用词云和文本散点图直观探查文本数据集：

- **wordcloud**：词云，通过字体大小和颜色显示单词相对频率
- **tsne / textscatter**：文本散点图，对词嵌入降维可视化
- 可在探查阶段快速发现数据中的主题簇与异常




```
documents = tokenizedDocument(sonnets);    % 分词
figure
wordcloud(documents);                      % 一行代码生成词云
title("莎翁十四行诗词云")
```

13.3.3 语言支持

针对特定语言提供专用预处理功能：

- 支持英语、日语、德语、韩语等
- 大多数函数也适用于其他语言文本
- **中文处理**需结合分词工具（如第三方分词器）后再用 tokenizedDocument

中文注意事项：MATLAB 自带分词以西方语言为主，中文文本建议**先分词再建** tokenizedDocument

第13章 文本分析扩展

13.1 文本分析扩展概述

13.2 MATLAB 文本分析工具箱回顾

13.3 文本数据导入与可视化

13.4 文本数据预处理

13.5 将文本转换为数值格式

13.6 文本数据机器学习

13.7 文本数据深度学习

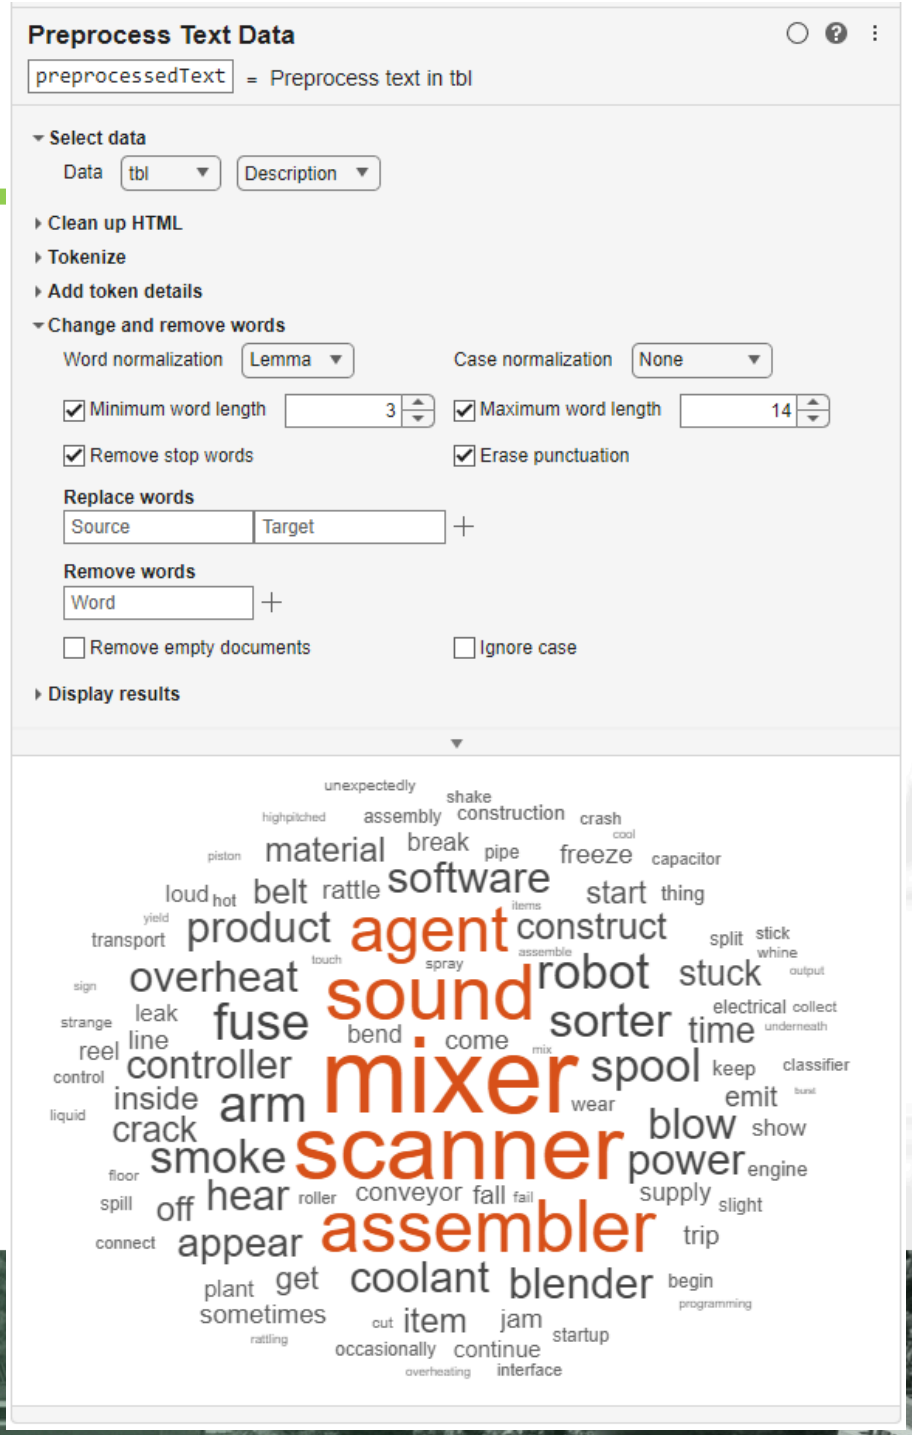
13.8 经典开源 NLP 模型在 MATLAB 中的使用

13.9 小结与思考题

13.4.1 清理文本数据

目的：删除无关内容，纠正拼写

- 删除标点符号、HTML 标记
- 删除 HTTP/HTTPS URL
- 纠正文档中的拼写
- 关键函数：**erasePunctuation、removeHTMLTags、eraseURLs、correctSpelling**
- 可用实时编辑器任务 **Preprocess Text Data** 交互式完成



13.4.2 过滤停用词与词形归一化

目的：优先分析有意义的文本数据，减少词汇量

- 删除停用词：**removeStopWords**（the / is / of ...）
- 删除出现频率过高/过低、过长/过短的单词
- 词干提取：tokenizedDocument + **stemWords**，获取词根
- 词形还原：将单词转化为**原形**（lemma）

预处理没有万能配方：停用词表、词长阈值都应结合语料特点调整，预处理前后用词云对比效果

13.4.3 提取语言特征

目标：用标记化算法拆分文本并添加上下文信息

- tokenizedDocument：将原始文本拆分为单词集合
- addPartOfSpeechDetails：添加词性标签
- addEntityDetails：命名实体识别
- addDependencyDetails：语法依存关系解析

> 这些"语言学特征"可直接作为机器学习的附加特征列

第13章 文本分析扩展

13.1 文本分析扩展概述

13.2 MATLAB 文本分析工具箱回顾

13.3 文本数据导入与可视化

13.4 文本数据预处理

13.5 将文本转换为数值格式

13.6 文本数据机器学习

13.7 文本数据深度学习

13.8 经典开源 NLP 模型在 MATLAB 中的使用

13.9 小结与思考题

13.5.1 词频与 n-gram 计数

目的：以数值形式表示文本

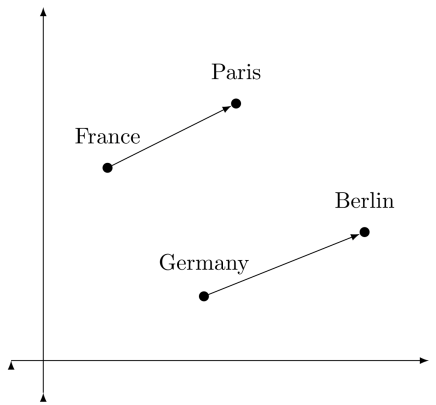
- **bagOfWords / bagOfNgrams**：构建词袋与 n-gram 模型
- **tfidf**：词频-逆文档频率矩阵
- 关键函数：encode、tfidf、topkwords
- 适合传统机器学习方法（SVM、随机森林等）

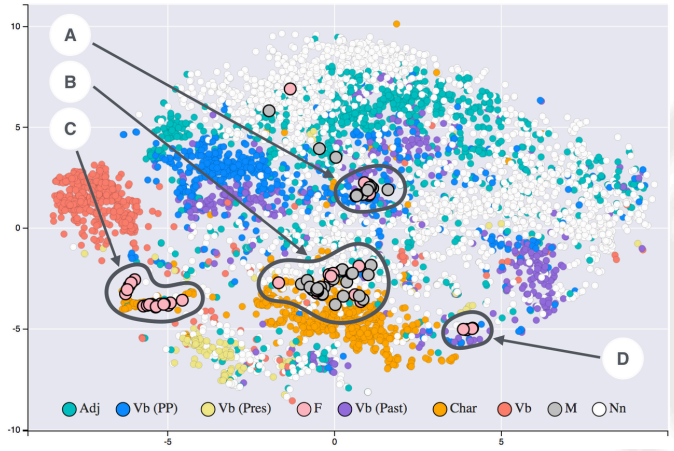
方法	优点	缺点
词袋 / tf-idf	简单快速、可解释	忽略语序、维度高、稀疏
词嵌入	语义相似度、低维稠密	训练成本、一词多义弱

13.5.2 词嵌入

方法类别：

- **训练词嵌入模型**：word2vec（CBOW 与 skip-gram）
- **导入预训练模型**：fastText、GloVe
- 关键函数：fastTextWordEmbedding、word2vec、wordEmbeddingLayer
- 词嵌入为低维实数向量，使语义相似的词在距离上接近

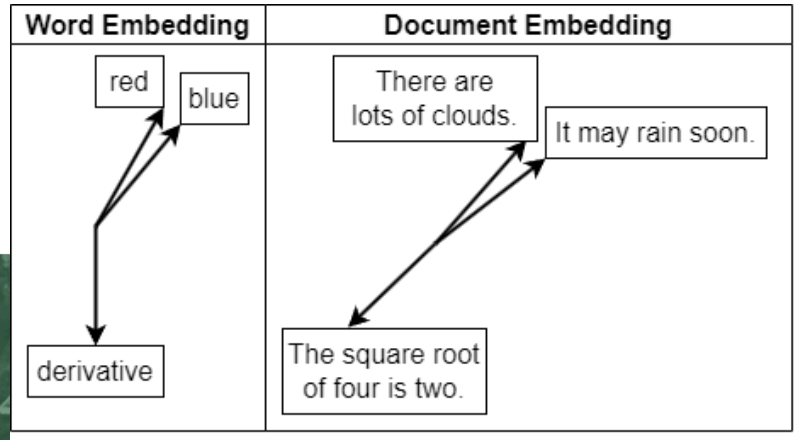




13.5.3 文档嵌入（R2024a 新增）

- **documentEmbedding**：加载文档嵌入模型
  - 默认 **all-MiniLM-L6-v2**（Sentence-BERT，1×384 维）
- `embed(emb, documents)`：文档映射为向量
- **cosineSimilarity**：相似度检索与聚类
  - 需支持包 all-MiniLM-L6-v2 Network

```
emb = documentEmbedding;                    % all-MiniLM-L6-v2
vec = embed(emb, documents);                % 文档向量化
s = cosineSimilarity(vec(1,:), vec(2,:)); % 文档相似度
```



第13章 文本分析扩展

13.1 文本分析扩展概述

13.2 MATLAB 文本分析工具箱回顾

13.3 文本数据导入与可视化

13.4 文本数据预处理

13.5 将文本转换为数值格式

13.6 文本数据机器学习

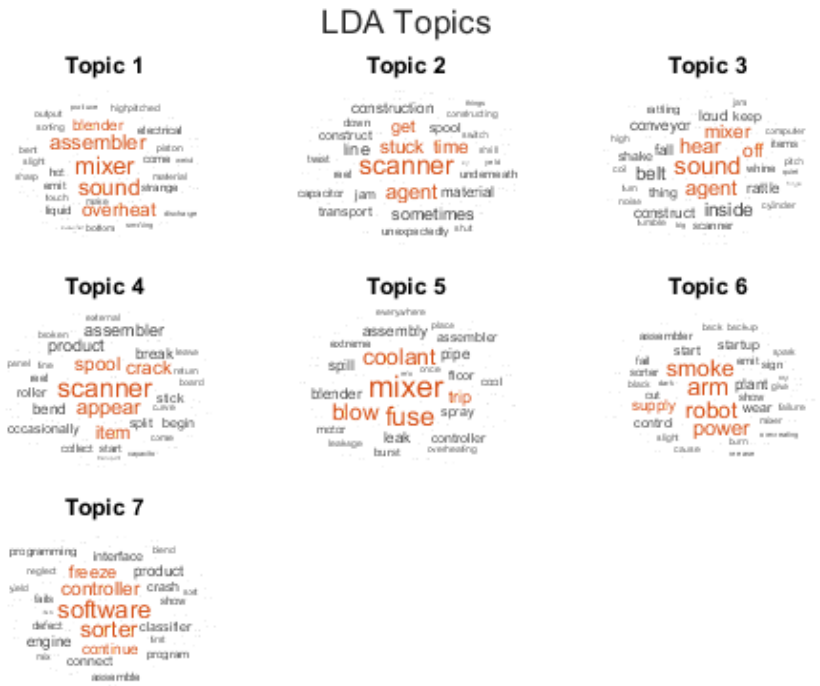
13.7 文本数据深度学习

13.8 经典开源 NLP 模型在 MATLAB 中的使用

13.9 小结与思考题

13.6.1 主题建模

- 使用 LDA（隐含狄利克雷分布）、LSA（隐含语义分析）发现文本集中的潜在主题
- 关键函数：lda、fitlsa、decode
- 可视化主题词、选择主题数、比较求解器



13.6.2 文档摘要与关键字提取

- 从文档中提取摘要：**extractSummary**
- **TextRank** 关键字提取与文档评分
- **BM25** 算法计算文档相似度

这些"无训练"方法拿来即用，适合作为文本挖掘项目的**第一版基线**

13.6.3 情感分析

- 识别文本态度：**正面、中立、负面**
- 训练情感分类器、生成**领域专用情感词典**
- 经典方法：基于词典（VADER 等）
- 进阶方法：**FinBERT 等深度模型**（见 13.8 节）

方法	优点	局限
情感词典	无需标注、速度快	无法处理否定/语境
机器学习分类器	领域自适应	需要标注数据
预训练模型（FinBERT）	精度高、语境敏感	计算资源要求高

第13章 文本分析扩展

13.1 文本分析扩展概述

13.2 MATLAB 文本分析工具箱回顾

13.3 文本数据导入与可视化

13.4 文本数据预处理

13.5 将文本转换为数值格式

13.6 文本数据机器学习

13.7 文本数据深度学习

13.8 经典开源 NLP 模型在 MATLAB 中的使用

13.9 小结与思考题

13.7.1 LSTM 文本分类

官方示例 "Classify Text Data Using Deep Learning"：

- tokenizedDocument 预处理 → **wordEncoding** → **doc2sequence** 转序列
- 构建 **wordEmbeddingLayer** + **lstmLayer** + **全连接层**的网络
- 用 **trainnet** 训练，对工厂报告等文本分类

```
layers = [
    wordEmbeddingLayer(50,enc.NumWords)
    lstmLayer(80,"OutputMode","last")
    fullyConnectedLayer(numClasses)
    softmaxLayer];
net = trainnet(docsTrain, YTrain, layers, "crossentropy", options);
```

13.7.2 CNN 文本分类 · 13.7.3 文本生成

13.7.2 CNN 文本分类

- 官方示例 "Classify Text Data Using Convolutional Neural Network"
- 用**一维卷积**捕获局部 n-gram 模式
- 训练效率高，适合短文本分类

13.7.3 文本生成

- 官方示例 "Generate Text Using Deep Learning"
- 基于**字符级 LSTM** 序列预测生成新文本
- 进阶：使用 **GPT-2 生成式摘要**（见 13.8 节）

从 LSTM/CNN 到 BERT/GPT-2：模型越强，需要自己训练的部分越少

第13章 文本分析扩展

13.1 文本分析扩展概述

13.2 MATLAB 文本分析工具箱回顾

13.3 文本数据导入与可视化

13.4 文本数据预处理

13.5 将文本转换为数值格式

13.6 文本数据机器学习

13.7 文本数据深度学习

13.8 经典开源 NLP 模型在 MATLAB 中的使用

13.9 小结与思考题

转化 MATLAB 的 NLP 模型现状

MathWorks 官方仓库 **transformer-models** 已将经典 NLP 模型转化为纯 MATLAB 代码：

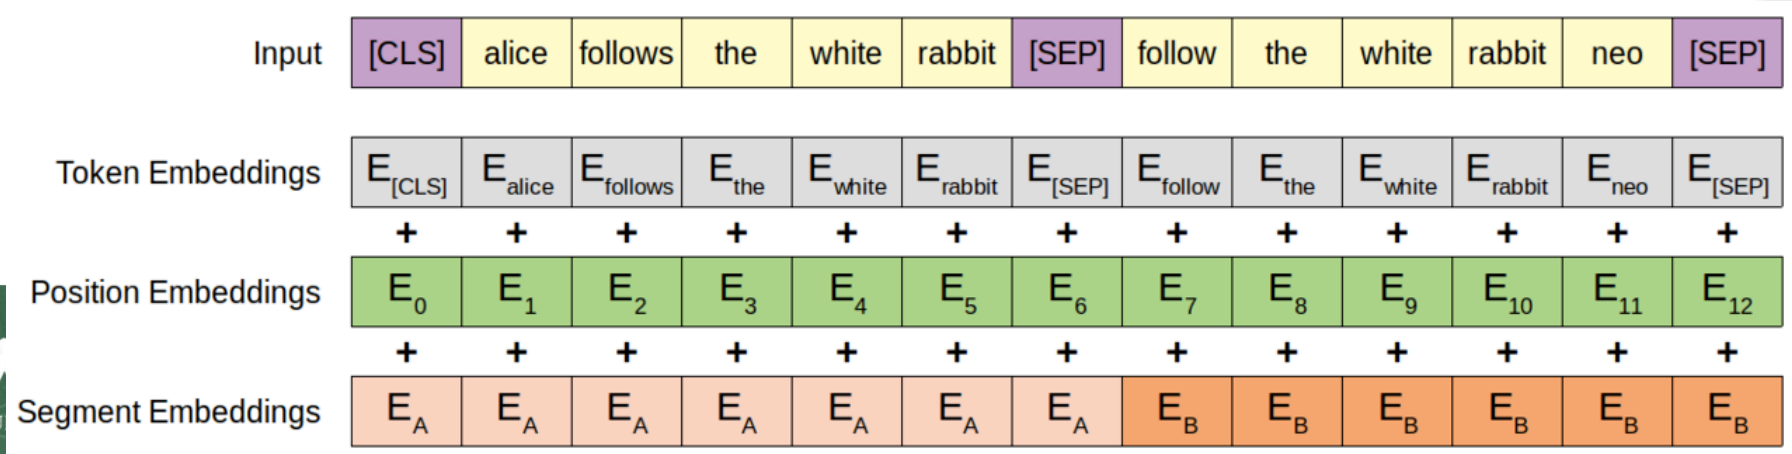
- 仓库：https://github.com/matlab-deep-learning/transformer-models
- File Exchange：https://ww2.mathworks.cn/matlabcentral/fileexchange/107375-transformer-models
- 三大模型：**BERT、FinBERT、GPT-2**
- 文档嵌入：**all-MiniLM-L6-v2 / L12-v2**（documentEmbedding）

与上一章呼应：Transformer 原理 + 这些纯 MATLAB 实现 = 可读、可改、可用的完整学习闭环

BERT：双向编码器表示

- **仅编码器结构，双向注意力**，适合文本理解
- MATLAB 用法：
  - `mdl = bert`：加载预训练 BERT
  - `bert("Model","multilingual-cased")`：多语言含中文
  - `Z = mdl.model(X, parameters)`：提取 token 嵌入
- 典型任务：分类、掩码预测、句对推理

BERT 输入表示（Devlin et al., 2018）：



在 MATLAB 中微调 BERT

官方示例 FineTuneBERT.m：

- 加载预训练 BERT 作为**特征提取器**或**端到端微调**
- 在小规模标注数据上做**迁移学习**
- 显著优于从零训练的 LSTM/CNN
- 日文版示例 FineTuneBERTJapanese.m（需 R2023a 及以上）

迁移学习直觉：BERT 已"读过"数十亿词，我们只需教它"最后一层判断"——**小数据也能达到高精度**

BERT 文本分类示例流程

1. 用 **mdl.Tokenizer** 对文本分词并编码
2. **bert.model** 提取句向量或 token 嵌入
3. 接**全连接层与 softmax** 构建分类头
4. 用 **trainnet** 在标注数据上微调
5. 评估分类性能（confusionchart 等）

> 中文任务路线：tokenizedDocument 分词 → bert("Model","multilingual-cased") 提特征 → 全连接层微调

FinBERT：金融情感分析

- 面向**金融领域**的 BERT 变体
- MATLAB 用法：`finbert.sentimentModel(X, parameters)`
- 输出：**positive / neutral / negative** 类别 + [-1,1] 分值
- 适合金融新闻、财报、舆情文本的情感分析
- 入门门槛低，适合作为**迁移学习教学案例**

GPT-2：生成式预训练

- **解码器结构，自回归生成**文本
- MATLAB 用法：
  - `mdl = gpt2`：加载预训练 GPT-2
  - `summary = generateSummary(mdl, text)`：基于 "TL;DR" 技巧生成摘要
  - 参数：MaxSummaryLength、TopK、Temperature、StopCharacter
- 仓库 +sampling 包支持 top-k、temperature 采样
- 注：MATLAB 中 GPT-2 主要用于**摘要生成**，非通用对话

文档嵌入与语义检索

- documentEmbedding 基于 **Sentence-BERT**，输出文档向量
- 应用：语义搜索、聚类、去重、**RAG 检索**（第18章实战）
- 与 BERT token 嵌入互补：

表示层级	代表模型	适合任务
token 级	BERT	分类、序列标注
文档级	documentEmbedding（MiniLM）	检索、相似度、聚类

记住这组互补关系：**BERT 管"理解"，documentEmbedding 管"查找"**

NLP 模型在 MATLAB 中的可用性总结

模型	MATLAB 可用性	用途
BERT	官方支持	文本理解、分类、微调
FinBERT	官方支持	金融情感分析
GPT-2	官方支持	文本生成、摘要
Sentence-BERT / MiniLM	官方支持	文档嵌入、语义检索
T5	无原生支持	需 ONNX/Python 接口
现代大模型	通过 API	见 LLM 工具箱章节（第18章）

第13章 文本分析扩展

13.1 文本分析扩展概述

13.2 MATLAB 文本分析工具箱回顾

13.3 文本数据导入与可视化

13.4 文本数据预处理

13.5 将文本转换为数值格式

13.6 文本数据机器学习

13.7 文本数据深度学习

13.8 经典开源 NLP 模型在 MATLAB 中的使用

13.9 小结与思考题

小结

- MATLAB 文本分析工具箱覆盖**导入、预处理、数值化、机器学习、深度学习**全流程
- R2024a 新增 **documentEmbedding**，提供文档级语义嵌入，支撑检索与相似度计算
- 经典开源 NLP 模型（**BERT、FinBERT、GPT-2**）已由 MathWorks 转化为纯 MATLAB 代码，可直接使用与微调
- 中文场景可通过 **multilingual-cased** 模型支持
- T5 等模型暂无原生支持，可通过 **ONNX 导入**或 Python 接口扩展

思考题

- 文本分析中，词袋/tf-idf 与词嵌入、文档嵌入各有何优劣?
- BERT 的 token 嵌入与 documentEmbedding 的文档嵌入，分别适合什么任务?
- 如何用 FinBERT 完成一批金融新闻的情感分析?
- 在 MATLAB 中如何对中文文本使用 BERT 进行分类?

参考文献

- MathWorks. Text Analytics Toolbox. https://ww2.mathworks.cn/products/text-analytics.html
- MathWorks. Transformer Models for MATLAB. https://github.com/matlab-deep-learning/transformer-models
- MathWorks. documentEmbedding 文档. https://www.mathworks.com/help/textanalytics/ref/documentembedding.html
- MathWorks. Classify Text Data Using Deep Learning. https://www.mathworks.com/help/textanalytics/ug/classify-text-data-using-deep-learning.html
- Devlin J, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. 2018. https://arxiv.org/abs/1810.04805

谢谢

延伸阅读

- MathWorks Text Analytics Toolbox 官方示例库
- Devlin et al., *BERT*, NAACL 2019
- Radford et al., *Language Models are Unsupervised Multitask Learners*（GPT-2）