第14章 大语言模型

课程：人工智能与地理数据挖掘

教师：孙伟

邮箱：sunwei29@mail.sysu.edu.cn

单位：中山大学 地理科学与规划学院

日期：2026年6月

第14章 大语言模型 - 目录

14.1 大语言模型概述

14.2 常用 LLM 模型结构

14.3 训练数据集与模型训练过程

14.4 模型评估与改进

14.5 挑战与未来发展

14.6 小结与思考题

14.1 · 大语言模型概述

- 什么是大语言模型（LLM），从语言模型到 LLM 的发展脉络
- 缩放定律与涌现能力：LLM 的"大"为什么有效
- 常用 LLM 模型结构：三种 Transformer 架构与关键技术组件
- 训练数据集与三阶段训练过程：预训练 → SFT → 对齐
- 如何评估 LLM 性能，如何通过微调、迁移学习和正则化改进效果
- 挑战与未来：模型尺寸、计算资源、隐私、幻觉与安全

学习目标

> 理解 LLM 的"能"与"不能"，才能在数据挖掘项目中把它用对、用好
> 完成本章后，你将能够：

- **说清** LLM 的定义、缩放定律与涌现能力
- **比较** 编码器-only / 解码器-only / 编码器-解码器三种架构
- **描述** 预训练、SFT、对齐三阶段各自解决什么问题
- **列举** LLM 的主流评估基准与四种改进手段
- **分析** LLM 面临的五大挑战，展望地学领域的应用方向

什么是大语言模型

大语言模型（Large Language Model, LLM）：

- **定义**：
  - 基于Transformer 架构，进行下一个（或多个）词元预测
  - 参数规模巨大（数十亿至万亿级）
  - 在海量文本上预训练的概率语言模型
- **核心能力**：涌现出理解、生成、推理、翻译、代码等通用能力
- **典型国外代表**：GPT 系列（OpenAI）、BERT、LLaMA、PaLM/Gemini、Claude
- **典型国内代表**：Deepseek、GLM、Kimi、Qwen、豆包、文心、混元等

一句话：LLM = Transformer + **海量数据** + **超大规模** 逼出来的通用能力

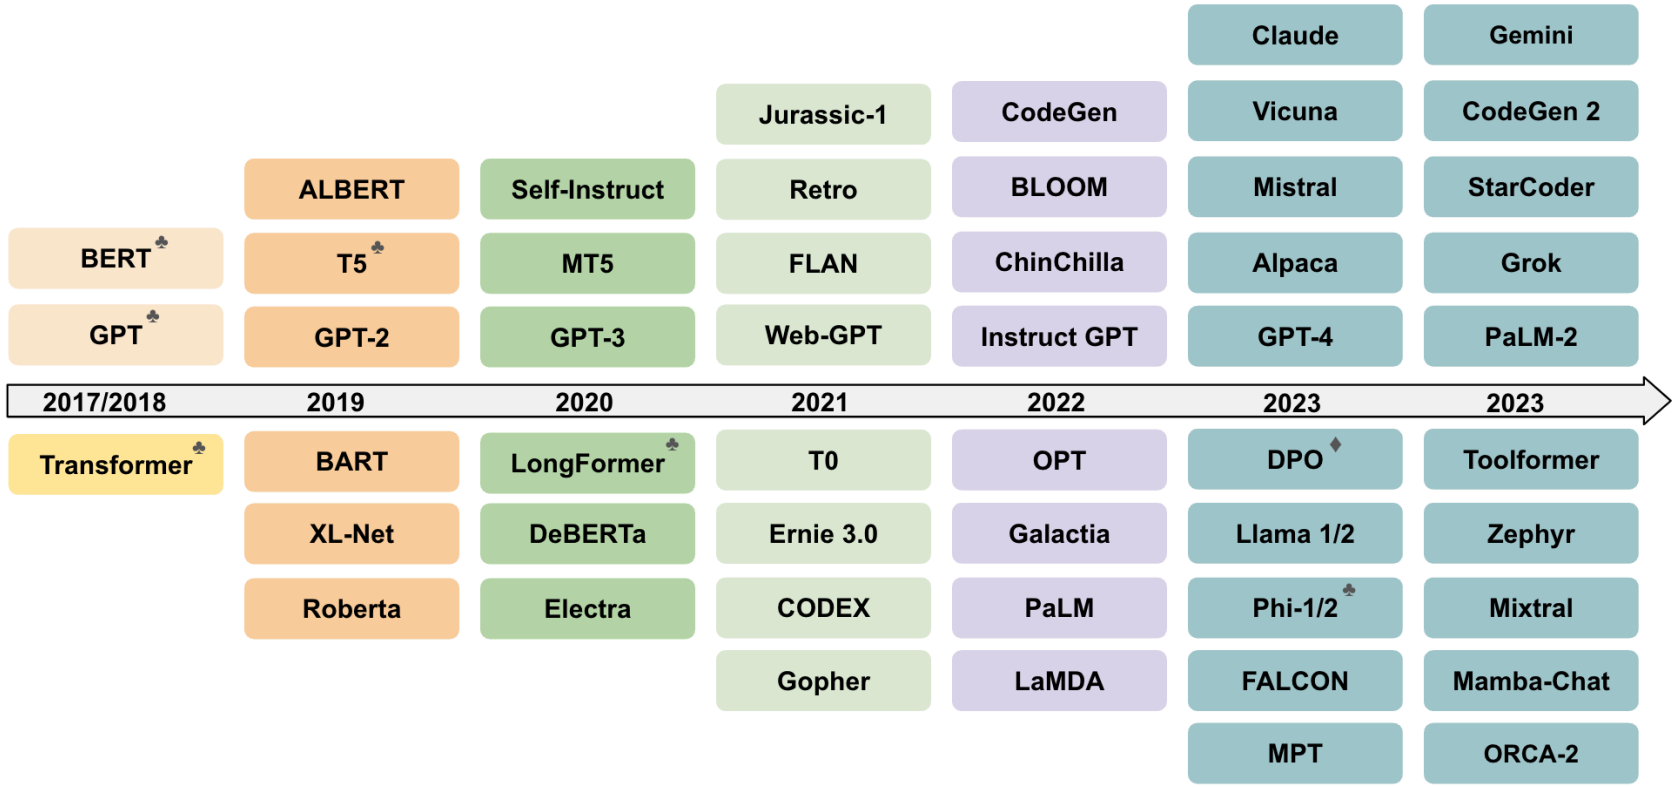
从语言模型，到大语言模型，再到智能体

语言模型的发展脉络：

阶段	代表	关键变化
统计语言模型	n-gram	自由参数多、数据稀疏
神经网络语言模型	NNLM	神经网络替代指数级自由参数
预训练语言模型	BERT / GPT 1~2	Transformer + 预训练-微调范式
大语言模型	GPT，Claude，Deepseek, Kimi	**规模扩展带来能力涌现**
编程智能体	Codex，Claude Code	**以编程为突破口**
助理智能体	Openclaw, Hermess, Grok Bot	**个人助理机器人**

从语言模型到大语言模型

语言模型的发展脉络

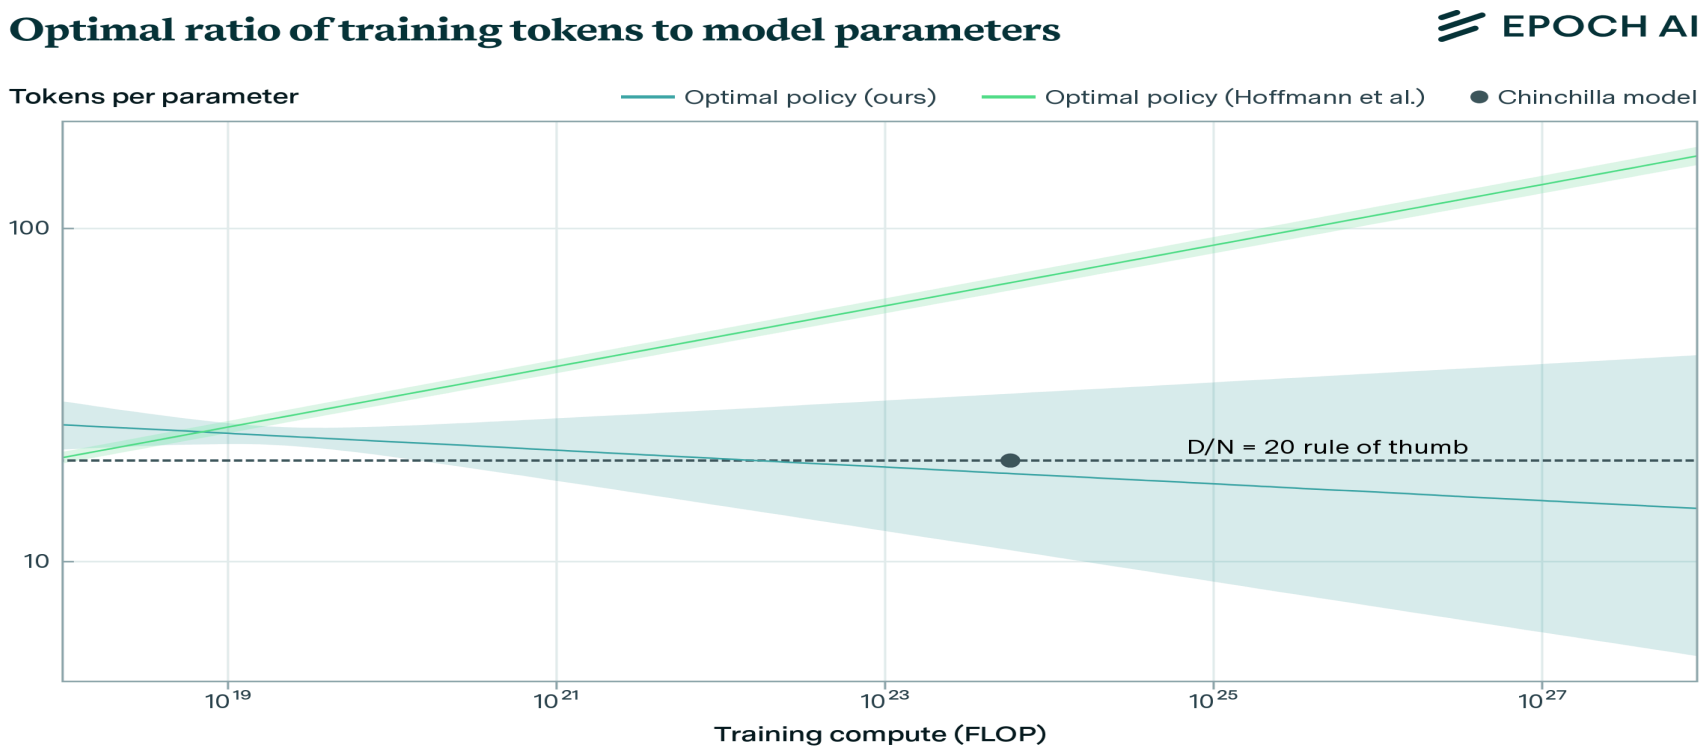


缩放定律（Scaling Laws）

- 模型性能随**参数量、数据量、算力**的增加呈幂律提升
- Kaplan 等人（2020）提出缩放定律：损失随这三个因素可预测下降
- **Chinchilla**（2022）进一步指出：在固定算力下，数据与参数应按比例增长（约 20 token/参数）
- 缩放定律是 LLM 规模化发展的理论依据

缩放定律（Scaling Laws）

Chinchilla 缩放定律：最优 token/参数配比

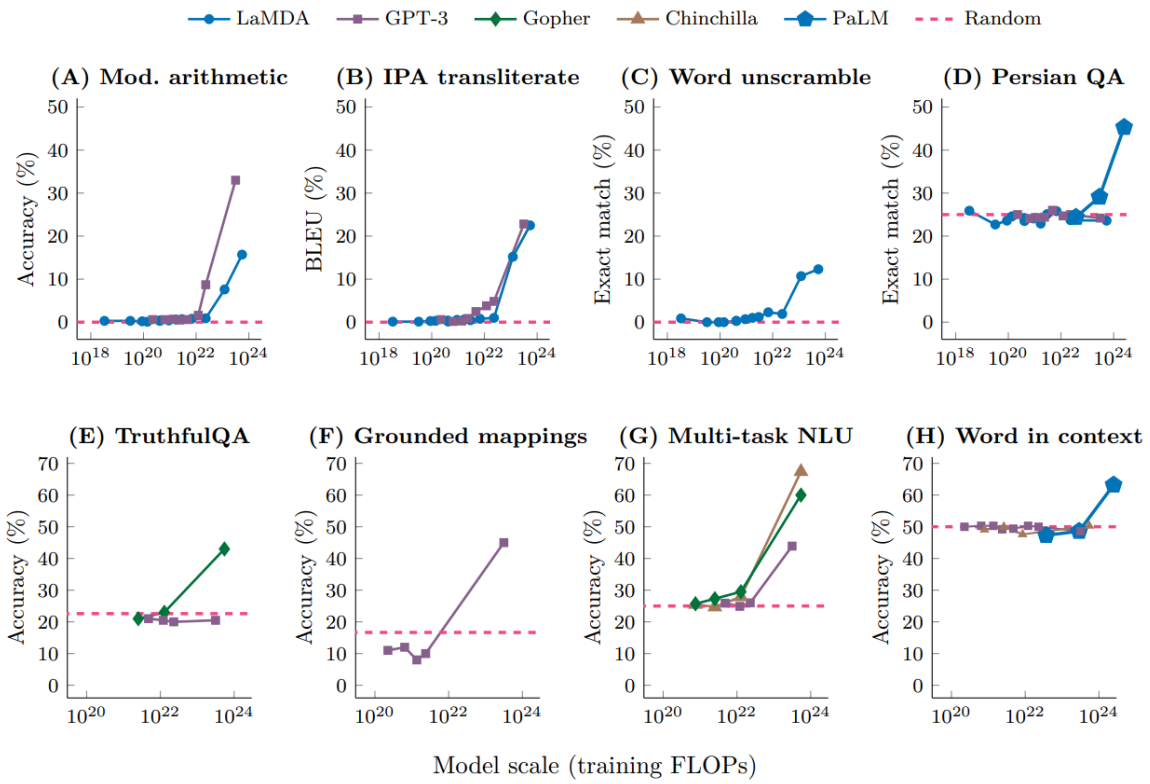


图片来源：Epoch AI（CC BY）

涌现能力

- 什么时候出现
  - 当模型规模超过某一阈值后，会出现**小模型不具备的能力**
- 什么是涌现能力
  - 典型涌现能力：少样本/零样本学习、思维链推理、指令遵循
  - 涌现能力难以从小模型外推，是 LLM 区别于传统模型的关键

涌现能力



图片来源：Wikimedia Commons（Wei et al. 2022 风格涌现曲线）

第14章 大语言模型

14.1 大语言模型概述

14.2 常用 LLM 模型结构

14.3 训练数据集与模型训练过程

14.4 模型评估与改进

14.5 挑战与未来发展

14.6 小结与思考题

三种主流架构

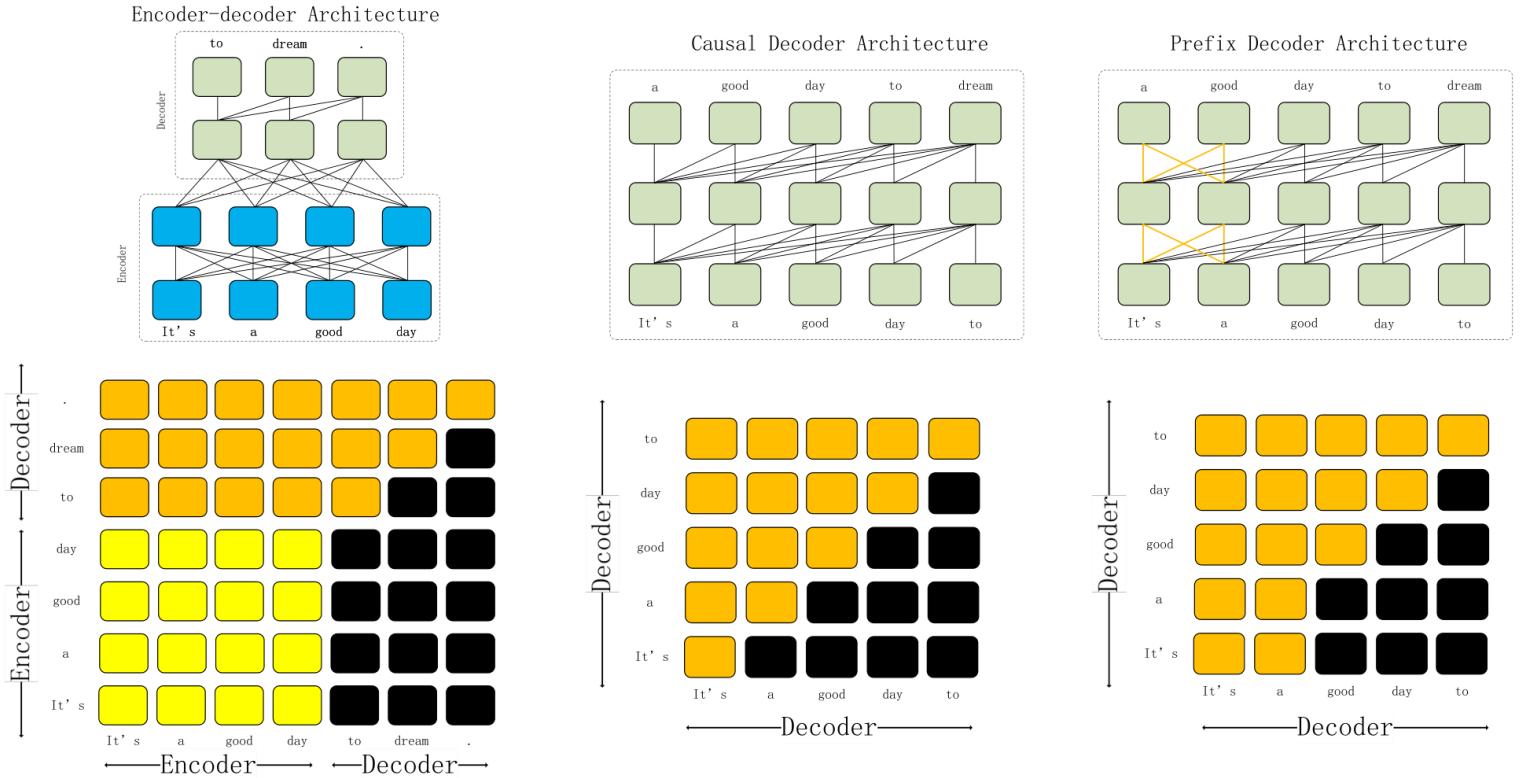
基于 Transformer 的 LLM 主要有三种架构：

架构	注意力	代表模型	适合任务
编码器-only	双向	BERT 及变体	理解任务（分类、检索）
解码器-only	因果掩蔽	**GPT 系列、LLaMA**	**生成任务**
编码器-解码器	编码双向+解码因果	T5、BART	序列到序列（翻译、摘要）

当前主流大语言模型（GPT、Claude、LLaMA 等）多采用**解码器-only** 架构。

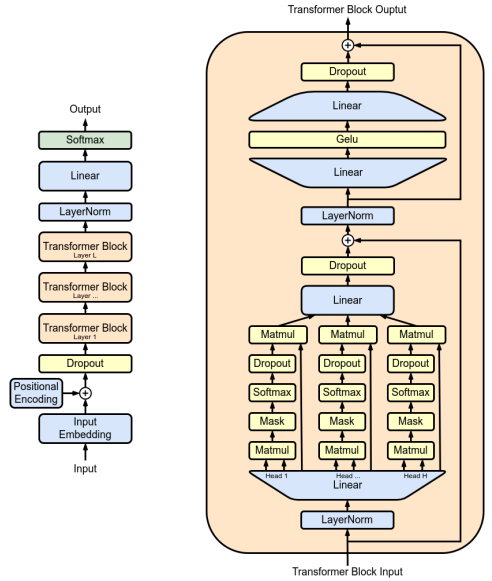
三种主流架构

基于 Transformer 的 LLM 主要有三种架构：



解码器-only 架构要点

- **因果（掩蔽）自注意力**：每个位置只能看到自身及之前位置，保证自回归生成
- 多头注意力 + 前馈网络 + 残差连接 + 层归一化
- **Pre-Norm 与 Post-Norm**：现代 LLM 多采用 Pre-Norm 以提升训练稳定性
- 位置编码：绝对位置编码、相对位置编码、**RoPE 旋转位置编码**



关键技术组件

现代 LLM 的"零件清单"：

组件	常用方案
注意力优化	Flash Attention、Multi-Query Attention、Grouped-Query Attention
激活函数	GELU、SwiGLU
归一化	LayerNorm、RMSNorm
位置编码	RoPE、ALiBi
分词词表	BPE、SentencePiece

认识开源模型 config.json 里的这些组件，就能看懂模型的"身份证"

代表性 LLM 一览

模型	机构	架构	特点
GPT-4 / GPT-4o	OpenAI	解码器	通用能力强，多模态
Claude	Anthropic	解码器	长上下文、安全对齐
LLaMA	Meta	解码器	开源、可本地部署
DeepSeek	深度求索	解码器（MoE）	高性价比、开源权重
BERT	Google	编码器	文本理解基准
T5	Google	编码器-解码器	文本到文本统一框架

第14章 大语言模型

14.1 大语言模型概述

14.2 常用 LLM 模型结构

14.3 训练数据集与模型训练过程

14.4 模型评估与改进

14.5 挑战与未来发展

14.6 小结与思考题

训练数据集

LLM 预训练数据来源广泛、规模巨大：

- **网页**：Common Crawl、WebText
- **书籍**：Books3、Gutenberg
- **代码**：GitHub
- **学术**：arXiv、Wikipedia
- **对话与指令**：ShareGPT、开源指令数据集

数据规模从数百 GB 到数十 TB，token 数从**数千亿到万亿级**。

数据预处理流程

- **采集**：从多来源抓取原始文本
- **清洗**：去重、去噪、过滤低质内容、隐私脱敏
- **分词**：用 BPE/SentencePiece 切分为 token
- **配比**：按比例混合不同来源数据，平衡领域分布

数据质量直接决定模型上限——"垃圾进，垃圾出"在 LLM 时代依然成立

模型训练过程：三阶段

LLM 训练通常分为三个阶段：

阶段	名称	数据	教会模型什么
1	预训练 Pre-training	海量无标注文本	语言规律与世界知识
2	监督微调 SFT	高质量指令-回答对	听懂并遵循指令
3	对齐 Alignment	人类偏好比较数据	有用、诚实、无害

> 预训练最贵（算力），SFT 与对齐最"巧"（数据质量）

阶段一：预训练

- **目标**：最大化似然 $L = \Sigma \log P(u_i \mid u_{i-k}, \ldots, u_{i-1}; \theta)$
- **数据**：海量无标注文本，自监督学习
- **算力**：千卡/万卡 GPU 集群训练数周至数月
- **结果**：得到基座模型（base model），具备语言能力但**不擅长对话**

> 基座模型会"续写"，但你问它问题，它可能继续"写问题"——它还没学会"听指令"

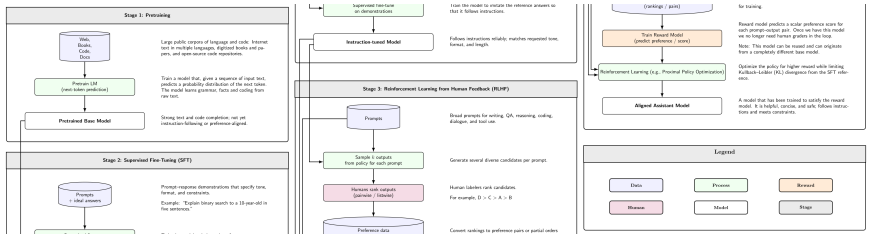
阶段二：监督微调（SFT）

- **数据**：人工编写的高质量指令-回答对
- **目标**：让模型学会按指令格式输出
- **方法**：在预训练模型上继续做有监督训练
- **产物**：指令模型（instruct model），能遵循指令完成任务

指令示例	目标回答
"克罗地亚首都是什么？"	"萨格勒布（Zagreb）……"

阶段三：对齐（RLHF / DPO）

- RLHF（基于人类反馈的强化学习）：
  - 训练奖励模型，建模人类偏好
  - 用 PPO 等强化学习算法优化策略
- DPO（直接偏好优化）：无需奖励模型，直接用偏好对优化
- **目标**：使模型输出更有用、诚实、无害（HHH）



分布式训练与并行策略

万亿参数模型的训练离不开系统工程：

- **数据并行**：切分数据到多卡
- **张量并行**：切分单个层到多卡
- **流水线并行**：按层切分到多卡
- **混合精度训练**：FP16/BF16 降低显存与加速
- **ZeRO 优化**：分片优化器状态、梯度、参数

类比：数据并行"多人读不同书"，张量并行"多人合抬一根梁"，流水线并行"多人接力加工序"

第14章 大语言模型

14.1 大语言模型概述

14.2 常用 LLM 模型结构

14.3 训练数据集与模型训练过程

14.4 模型评估与改进

14.5 挑战与未来发展

14.6 小结与思考题

如何评估 LLM 性能

LLM 评估是多维度、开放性的难题：

维度	代表基准
知识与推理	MMLU、GSM8K、MATH
语言理解	GLUE、SuperGLUE
代码	HumanEval、MBPP
对话与指令	AlpacaEval、MT-Bench
综合基准	HELM、LMSYS Chatbot Arena（人类盲评）

评估方法的挑战

- **数据污染**：测试集可能已混入预训练数据
- **开放生成难评分**：需人工或 LLM-as-judge
- **评价指标**：BLEU/ROUGE 适合翻译/摘要，不适合开放对话
- **复现性**：模型推理随机性、提示敏感

看榜单要"祛魅"：榜单分数 ≠ 你的任务上的真实表现，**用自己的数据实测**才靠谱

改进方法一：微调（Fine-tuning）

- **全参数微调**：更新所有参数，效果最好但成本高
- **参数高效微调（PEFT）**：
  - **LoRA**：低秩适配，只训练少量附加参数
  - **QLoRA**：量化 + LoRA，进一步降显存
  - Adapter、Prefix Tuning 等
- 在垂直领域（如地学、金融）小数据上有效

全参数微调

全部参数更新（数千亿）

LoRA

仅训练低秩增量（常 <1%）

改进方法二：迁移学习

- 利用预训练模型已学到的**通用语言知识**
- 在目标任务上继续训练，迁移已有表示
- MATLAB 中的体现：
  - 用预训练 BERT 提取特征，再训练分类头
  - **FineTuneBERT.m** 示例展示端到端迁移学习

> 与第16章呼应：BERT 微调就是"预训练+迁移学习"范式的 MATLAB 实操

改进方法三：正则化

- **Dropout**：随机丢弃神经元，防止过拟合
- **权重衰减**（L2 正则）：约束参数规模
- **层归一化与残差连接**：稳定深层网络训练
- **早停**（Early Stopping）：在验证集性能下降时停止
- **标签平滑**：缓解过自信，提升泛化

这些"经典武器"在 LLM 时代依然有效——深度学习的地基从未改变

其他改进技术

- **提示工程**（Prompt Engineering）：设计更好的指令
- **思维链**（Chain-of-Thought）：引导分步推理
- **检索增强生成（RAG）**：引入外部知识，减少幻觉
- **工具调用（Tool Calling）**：让模型使用计算器、数据库等外部工具
- **模型量化与蒸馏**：压缩模型，降低部署成本

> 教学提示：RAG 与工具调用将在第 18 章"MATLAB LLM 工具箱指南与地学应用"中动手实践

第14章 大语言模型

14.1 大语言模型概述

14.2 常用 LLM 模型结构

14.3 训练数据集与模型训练过程

14.4 模型评估与改进

14.5 挑战与未来发展

14.6 小结与思考题

挑战一：模型尺寸与计算资源

- 模型参数从数十亿到万亿，**训练与推理成本巨大**
- 需要专用 GPU/TPU 集群，能耗与碳排放显著
- 中小机构难以独立训练大模型，依赖 **API 或开源模型**
- 推理延迟与显存仍是部署瓶颈

规模	量级	训练门槛
十亿级（7B）	单卡可推理	实验室可微调
千亿级（100B+）	多卡集群	大厂主导
万亿级（1T+）	专用集群	极少数机构

挑战二：数据与隐私

- 高质量公开数据趋于耗尽，**"数据墙"问题**显现
- 训练数据可能包含个人隐私信息
- 用户交互数据的使用需符合法规（如 GDPR）
- 模型可能**记忆并泄露**训练数据

教学红线：涉及保密、个人信息的**敏感数据不要发给云端模型**——用本地部署（第18章 Ollama）

挑战三：幻觉与可靠性

- **幻觉**（Hallucination）：模型生成看似合理但错误的内容
- 缺乏事实核查能力，难以自我纠正
- 在医疗、法律、**地学**等高风险领域影响显著
- 缓解手段：**RAG、工具调用、事实校验、对齐训练**

> 对数据挖掘的警示：让 LLM"心算"统计量或编造文献引用，都是幻觉高发区——数值与事实交给 MATLAB 与数据库

挑战四：安全与对齐 / 挑战五：可解释性与公平性

挑战四：安全与对齐

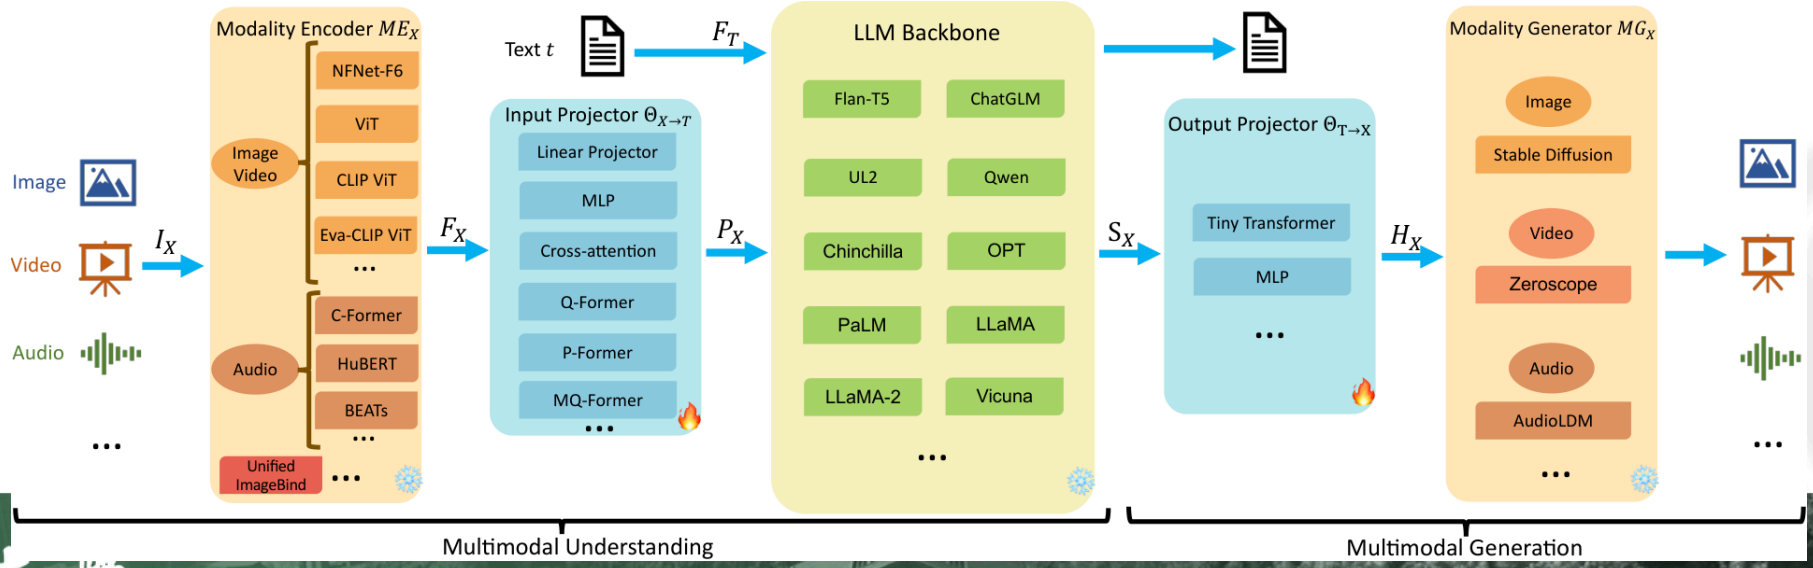
- 有害内容生成：偏见、歧视、暴力、违法信息
- **越狱攻击**：诱导模型绕过安全限制
- 滥用风险：深度伪造、自动化攻击、虚假信息
- 对齐难题：不同文化、价值观难以统一

挑战五：可解释性与公平性

- LLM 是**黑箱**，决策过程难以解释
- 内部机制理解仍不充分（机制可解释性研究中）
- 可能放大数据中的社会偏见
- 评估公平性缺乏统一标准

未来发展方向

- **多模态**：统一处理文本、图像、音视频
- **长上下文**：百万级 token 上下文窗口
- **智能体与具身智能**：自主规划调用工具、与物理世界交互
- **小模型高效化**：蒸馏量化、能力下沉端侧
- **科学发现**：辅助生物、材料、地学科研



地学领域的 LLM 应用展望

- 地学文献检索与知识抽取
- 时空数据的自然语言交互分析
- 地质灾害、气象、水文事件的智能问答与报告生成
- 多模态遥感图像与文本的联合理解
- 地学 Agent 自动编排数据处理工作流

与第 18 章衔接：以上每个方向都对应一个可动手的 MATLAB 实验——文献 RAG、工具调用、可视化 Agent、报告生成、工作流编排

第14章 大语言模型

14.1 大语言模型概述

14.2 常用 LLM 模型结构

14.3 训练数据集与模型训练过程

14.4 模型评估与改进

14.5 挑战与未来发展

14.6 小结与思考题

小结

- LLM 基于 Transformer，经**预训练-SFT-对齐**三阶段训练，规模扩展带来涌现能力
- 主流架构为**解码器-only**，配合 RoPE、SwiGLU、RMSNorm 等技术组件
- 评估是多维度难题，需结合自动基准与人类评估
- 改进手段包括**微调、迁移学习、正则化、RAG、工具调用**等
- 面临模型尺寸、算力、隐私、幻觉、安全等多重挑战
- 未来向多模态、长上下文、智能体、具身智能与科学发现方向发展

思考题

- 为什么解码器-only 架构成为主流大语言模型的选择?
- 预训练-SFT-对齐三阶段各自解决什么问题?
- LoRA 等参数高效微调为何在小数据场景下有优势?
- 在地学领域，RAG 与工具调用分别能解决什么问题?
- 如何缓解大语言模型的幻觉?

参考文献

- Vaswani A, et al. Attention is All You Need. NeurIPS 2017
- Kaplan J, et al. Scaling Laws for Neural Language Models. 2020
- Hoffmann J, et al. Training Compute-Optimal Large Language Models (Chinchilla). 2022
- Ouyang L, et al. Training language models to follow instructions with human feedback (InstructGPT). 2022
- Hu E J, et al. LoRA: Low-Rank Adaptation of Large Language Models. 2021
- Wei J, et al. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. 2022

谢谢

延伸阅读

- 《大语言模型》第1–2章，上海交通大学出版社（LLM-TAP）
- Zhao et al., *A Survey of Large Language Models*, 2023
- Hoffmann et al., *Training Compute-Optimal Large Language Models*, 2022