人工智能与地理数据挖掘

第二十四讲　地学应用四：地球系统篇

孙伟 sunwei29@mail.sysu.edu.cn

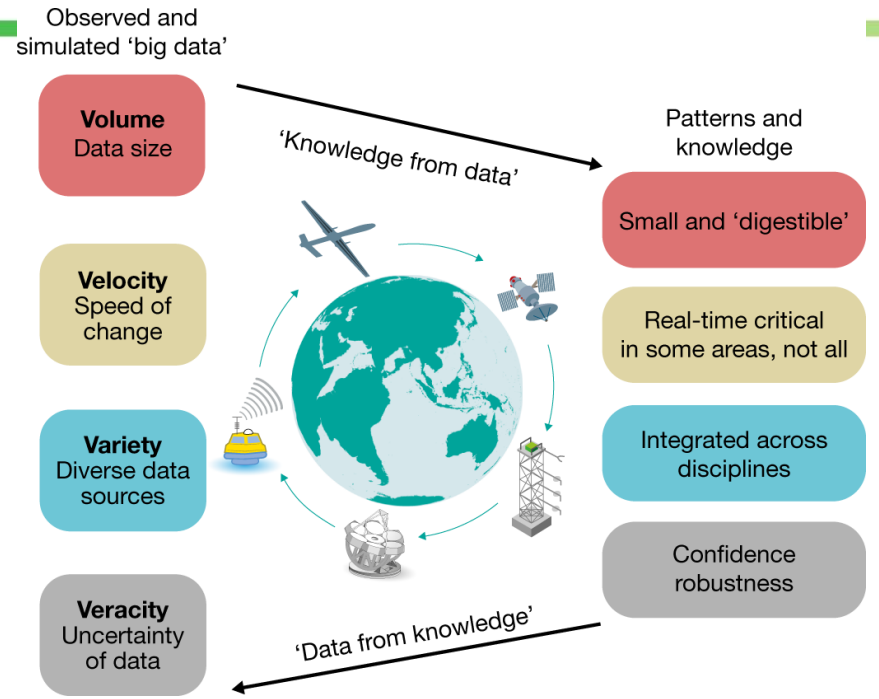
地理科学与规划学院

中山大學 SUN YAT-SEN UNIVERSITY

2026年6月

地球系统科学

地球科学背景下的大数据特点



- **遥感+实地观测+观察➔地球系统数据激增，存储量已经远远超过了几十PB，并且传输速率迅速增加**
- **大数据四大特征：volume, velocity, variety and veracity（体积，速度，多样性和准确性）**
- **数据源可以是一维到四维的，空间集成的，从器官层次(例如叶子)到全球层次。**



挑战和任务

- **关键的挑战**：从可能实时的或不同学科之间整合的大数据中提取可解释的信息和知识。

- **两大任务**

任务	解决方法
提取海量激增数据中的有用信息	机器学习和人工智能许多工具可以使用，但需要进一步发展，并适应地球科学分析。
遵循相关的物理定律前提下，相比于传统的同化方法能够从数值模式中获取更多有效特征。	将机器学习与物理建模相结合

- **地球系统科学中不同类型的典型问题**

  分类/异常检测、回归/状态预测、动态建模

地学常见分类和异常检测问题的方法比较

领域	气象	土地
科学任务	查找极端天气模式	土地利用和变化检测
传统方法	基于阈值的多变量检测	逐像素光谱分类
传统方法的局限性	启发式方法，使用的临时标准	使用浅层空间背景，或不使用
新兴或潜在方法	监督和半监督卷积神经网络	卷积神经网络

地学常见回归问题的方法比较

领域	气象	植被	水文
科学任务	根据大气条件预测通量	根据大气条件预测植被属性	预测未计量集水区的河流径流
传统方法	随机森林、核方法、前馈神经网络	半经验算法（温度总和、缺水）	具有人工选择的地形特征的过程模型或统计模型
传统方法局限性	不考虑内存和滞后效应	功能形式和动态假设方面的规定性	空间环境的考虑仅限于人工选择的特征
新兴或潜在方法	循环神经网络，长短期记忆（LSTM）	递归神经网络，可能具有空间上下文	卷积神经网络与循环网络的组合

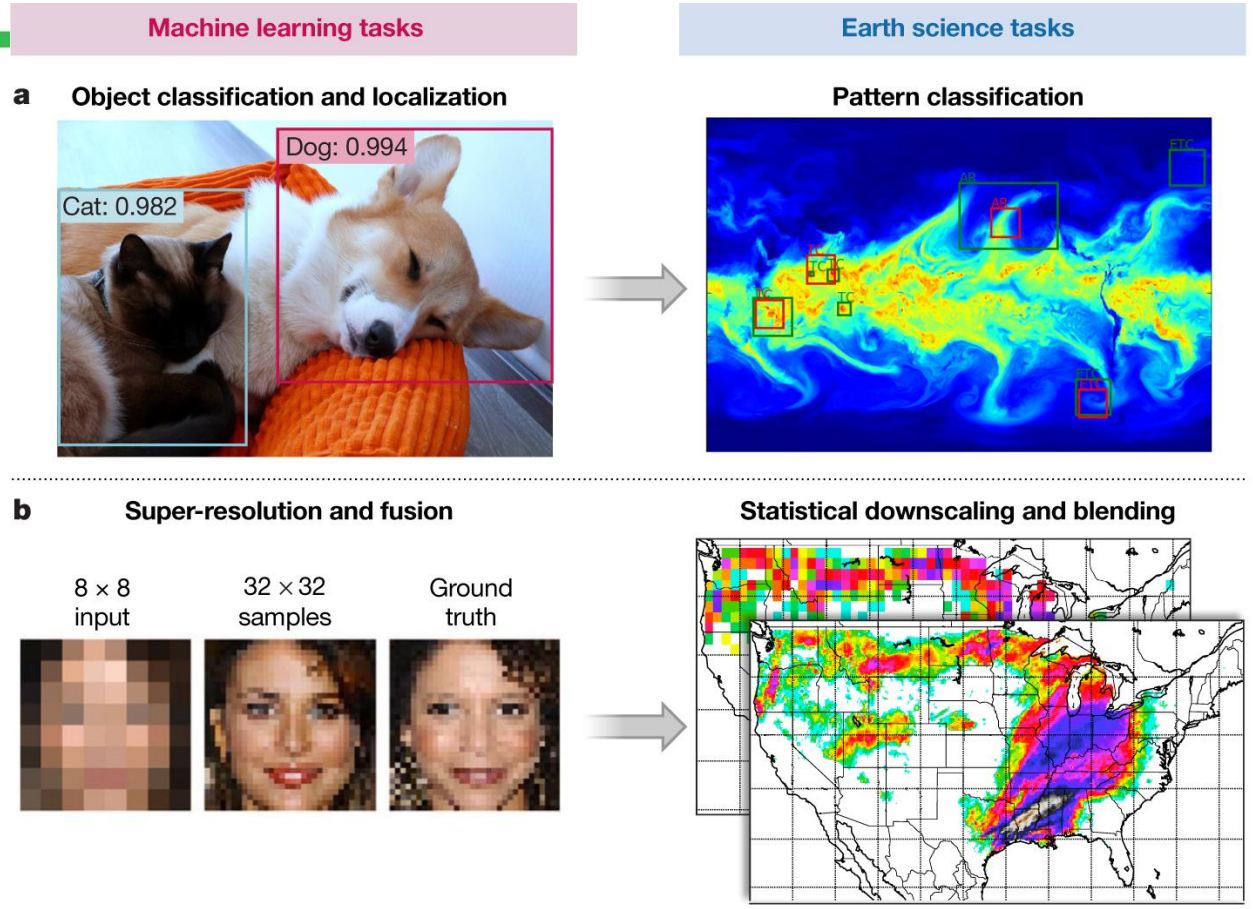
地球系统状态预测的方法比较

领域	短期	长期	中长期	机理
科学任务	降水临近预报	降尺度和偏差校正预测	季节性预测	传输模型
传统方法	具有数据同化的物理建模	动态建模和统计方法	根据数据进行初始条件的物理建模	传输的物理建模
传统方法局限性	分辨率导致的计算限制，数据仅用于更新状态	计算极限，主观特征选择	完全依赖物理模型，目前技能相对较弱	完全依赖于物理模型，计算限制
新兴或潜在方法	卷积–LSTM网络（短期空间背景）	卷积网络、条件生成对抗网络 （cGAN）	具有远程空间背景的卷积–LSTM网络	混合物理卷积网络模型

传统机器学习在地学应用的现状

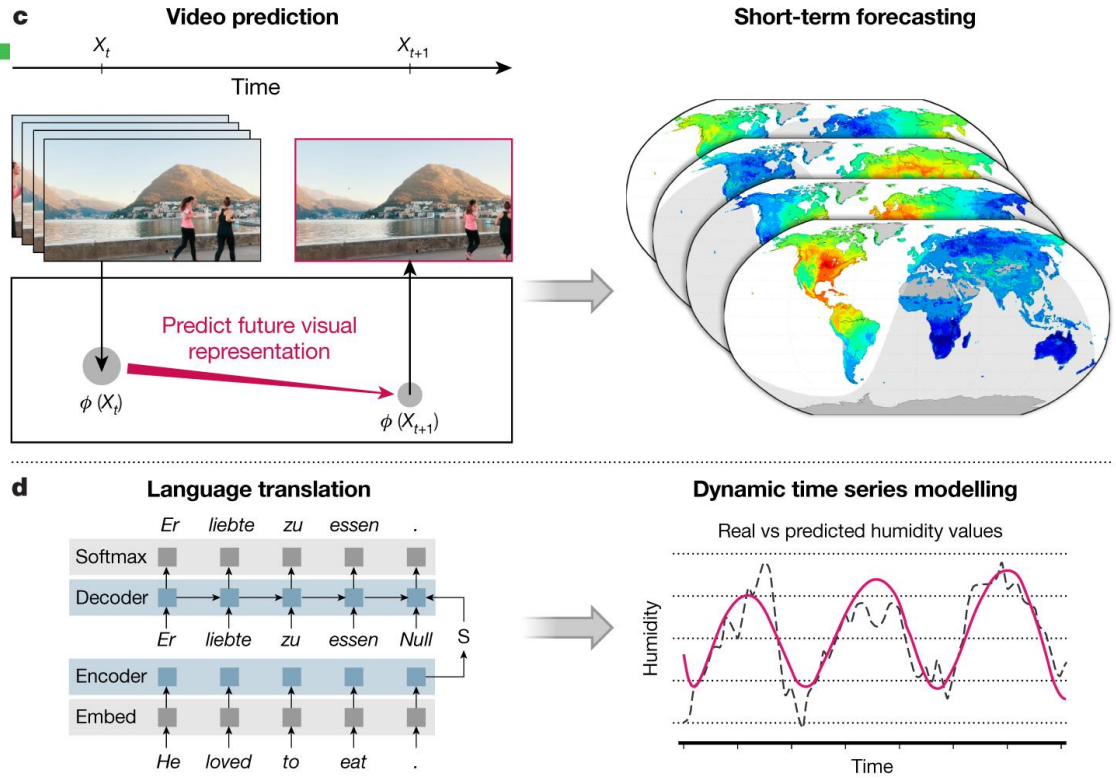
	含义
优点	• 多种有影响力的机器学习方法已经应用于地球系统科学的所有主要子领域 • 越来越多地被集成到操作方案中 • 被用于发现模式，以提高机理理解和评估综合物理模型。
缺点	• 天真的外推风险、抽样或其他数据偏差、忽视混淆因素、将统计关联解释为因果关系或多重假设检验的根本缺陷。 • 受益于特定领域的、人工选定的特性 • 没有很好的反映先前的时间步长和邻近的网格单元包含了隐藏的系统状态信息
趋势	在过去的几年里，地球科学已经开始使用深度学习来更好地利用数据中的空间和时间结构，这些特征对于传统的机器学习提取来说通常是有问题的。

为什么深度学习适用于地球科学？相似性



- **图像**类似于**二维数据**矩阵，其中包含特定变量，类似于照片中彩色三原色(rgb 值)，
- **视频**与**一系列图像**联系在一起，从而与**随时间演变的二维矩阵**联系在一起。

为什么深度学习适用于地球科学？相似性



- **视频和运动预测与许多动态地球科学问题**惊人地相似➔时间演变的多维结构，
- **自然语言信号和语音信号**具有相同的地球系统变量动态时间序列的多分辨率特征。
- **分类、回归、异常检测和动态建模**是计算机视觉和地球科学中的典型问题。

深度学习与地球科学？差异性举例

差异	计算机视觉	地球科学
不同的统计特性	处理的照片有三个通道(红、绿、蓝)	• 数百个光谱通道，变量有空间依赖性和相互依赖性，违背了独立同分布的重要假设。 • 集成多传感器数据表现出不同的几何、时空统计特征。 • 卫星观测序列也有不同的噪声源，不确定性水平, 数据缺失差距
数量级	图像大小为512*512像素	等分辨率(约1公里)的全局域大小约为40000*20000像素
标签	ImageNet带有标签的大量数据集	• 带有标签的训练集有限 • 情况和超出其有效范围的数据偏离很大(外推问题),

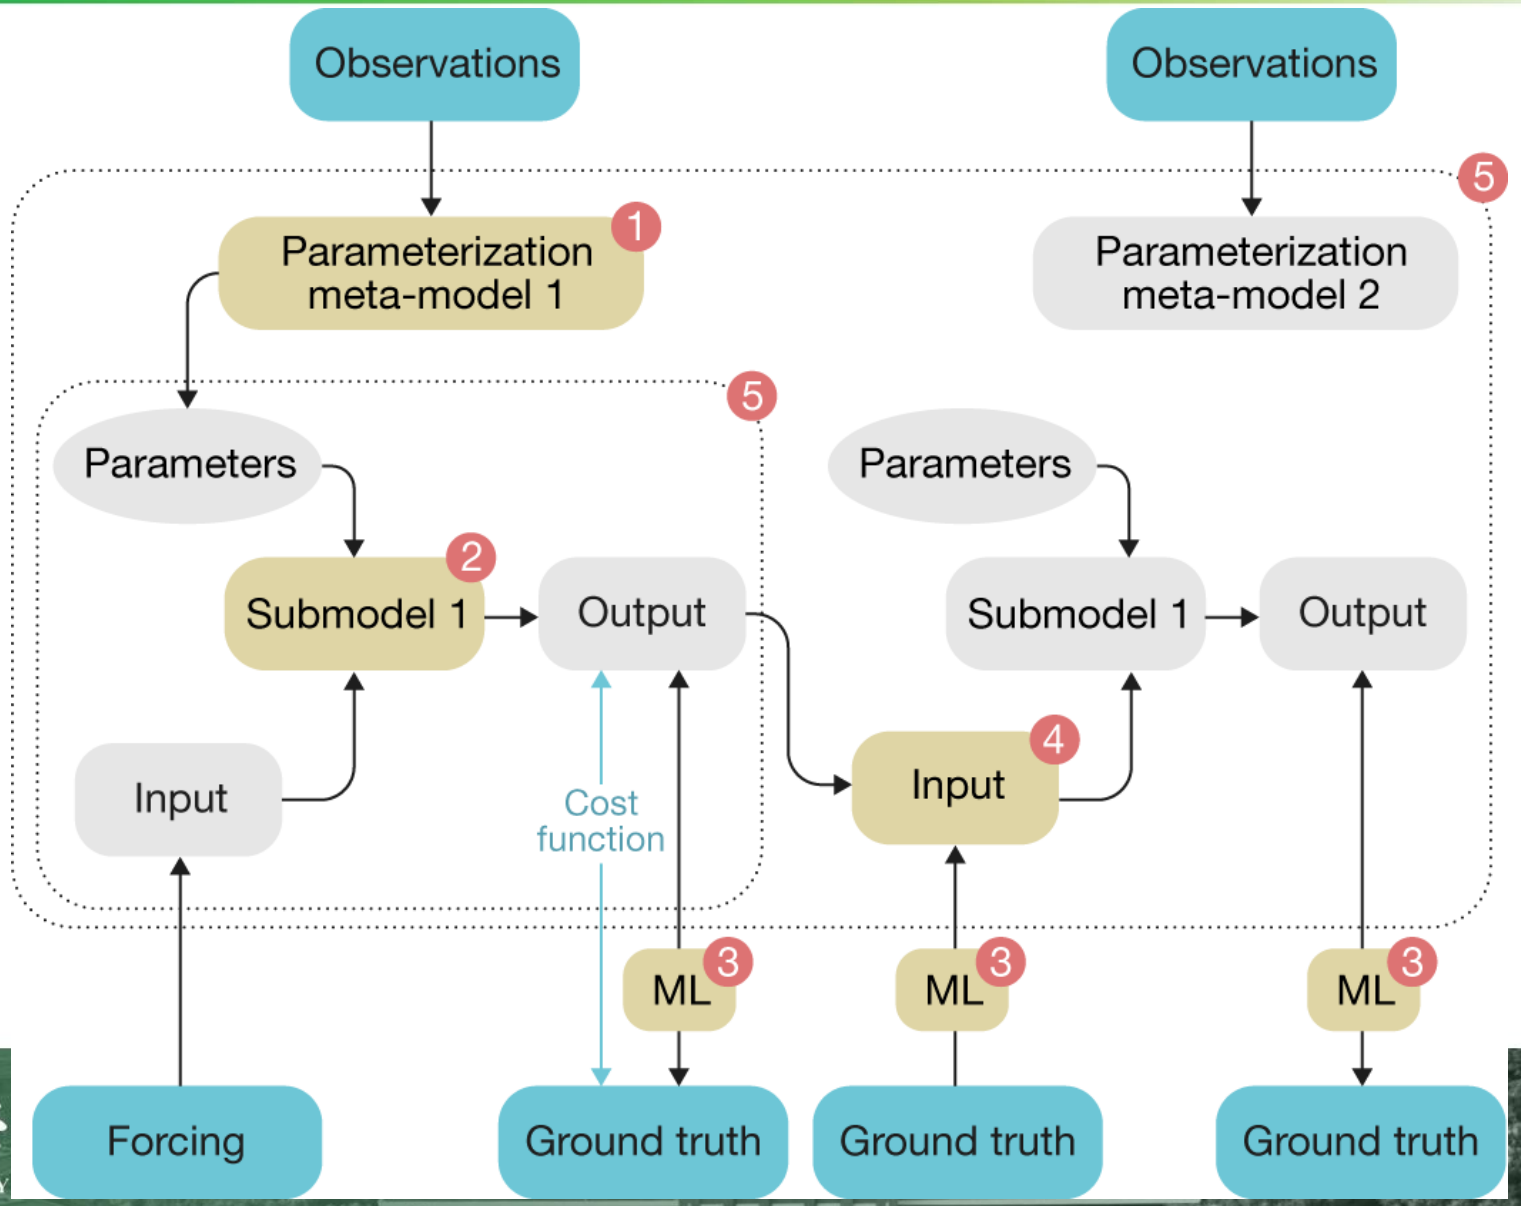
地学中成功应用DL的五个主要挑战和途径

英文	挑战	途径
Interpretability	可解释性	• 提高预测精度很重要，但还不够。当然，可解释性和理解是至关重要的 • 可解释性已被确定为深度神经网络的一个潜在弱点 • 该领域还远未实现自解释模型，也远未从观测数据中发现因果关系
Physical consistency	物理一致性	• 深度学习模型可以很好地与观测结果吻合，但由于外推或观测偏差等原因，预测可能在物理上不一致或不可信。 • 通过学习地球系统支配物理规律的模型来整合领域知识和实现物理一致性，在观测基础上提供非常强的理论约束。

地学中成功应用DL的五个主要挑战和途径

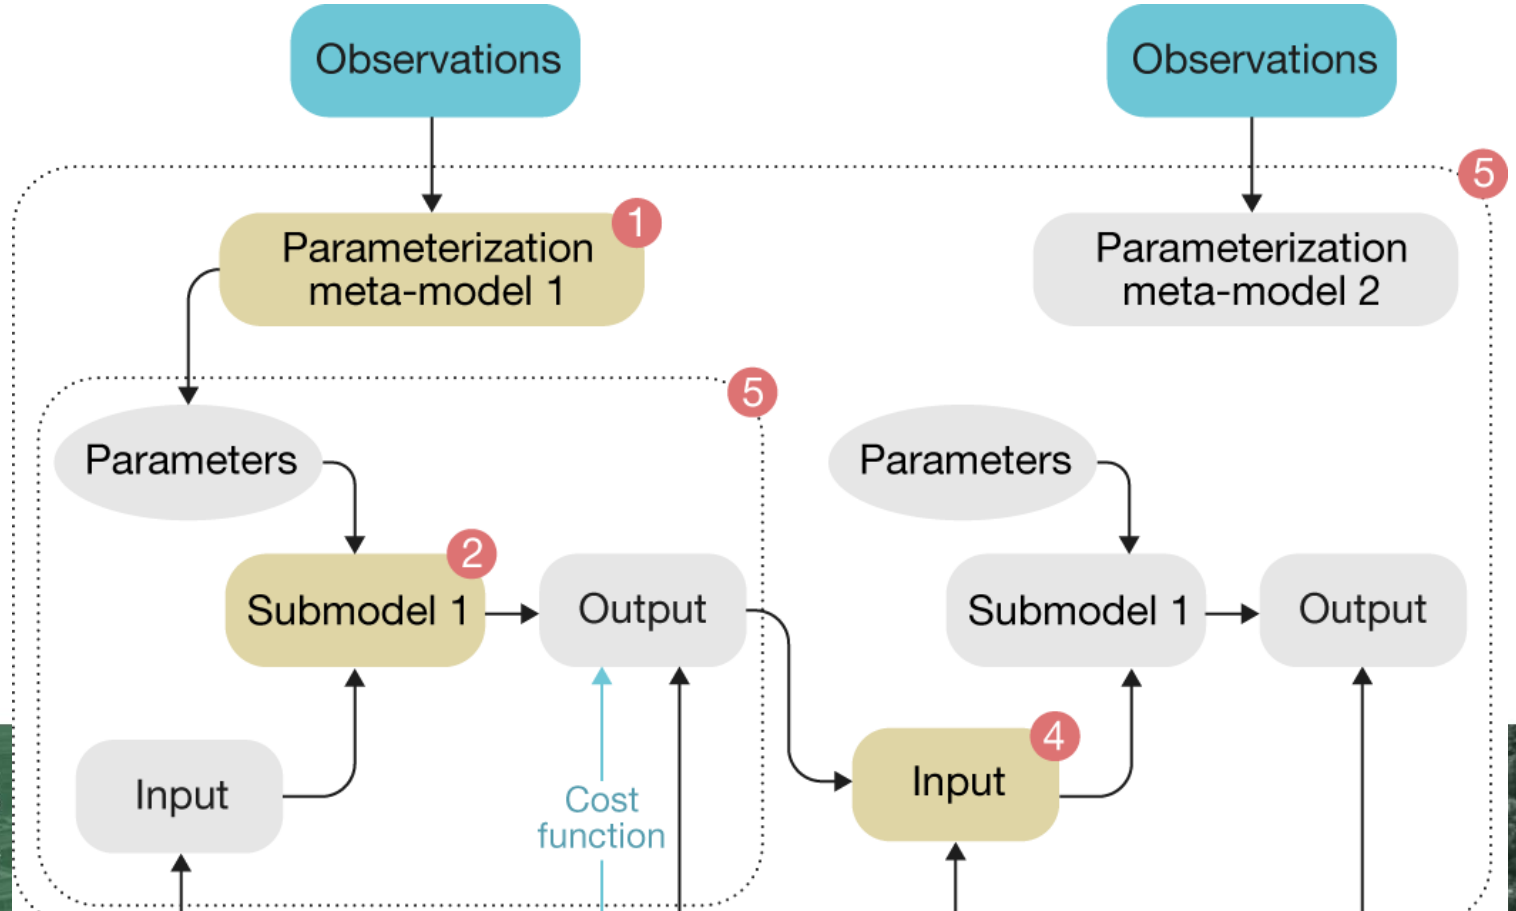
英文	挑战	途径
Complex and uncertain data	复杂不确定的数据	• DL需要处理复杂的统计量、多种输出、不同的噪声源和高维空间。 • 地学迫切需要新的网络拓扑结构，不仅利用局部邻近(在不同的尺度上)，而且利用遥相关关系，但是变量之间的确切因果关系并不清楚，需要发现。 • 地学缺少部分全球性常识，以选择特征
Limited labels	有限标签	• 需要从少数有标记的例子中学习，同时利用相关无标记数据的丰富信息。 • 采用无监督密度建模、特征提取、半监督学习和领域自适应。。
Computational demand	计算需求	• 地学问题的高计算成本面临着巨大的技术挑战

耦合物理模型和机器学习： 5种方式



方式1： ML改进参数化

- 圈1所示， **物理模型需要参数，但许多参数不能简单地从第一原理推导出来。**
- **机器学习可以学习参数化，以最佳地描述真实值，可以通过观察或依据第一原则从详细的高分辨率模型中生成。**



中山大學 SUN YAT-SEN UNIVERSITY

方式1： ML改进参数化的例子

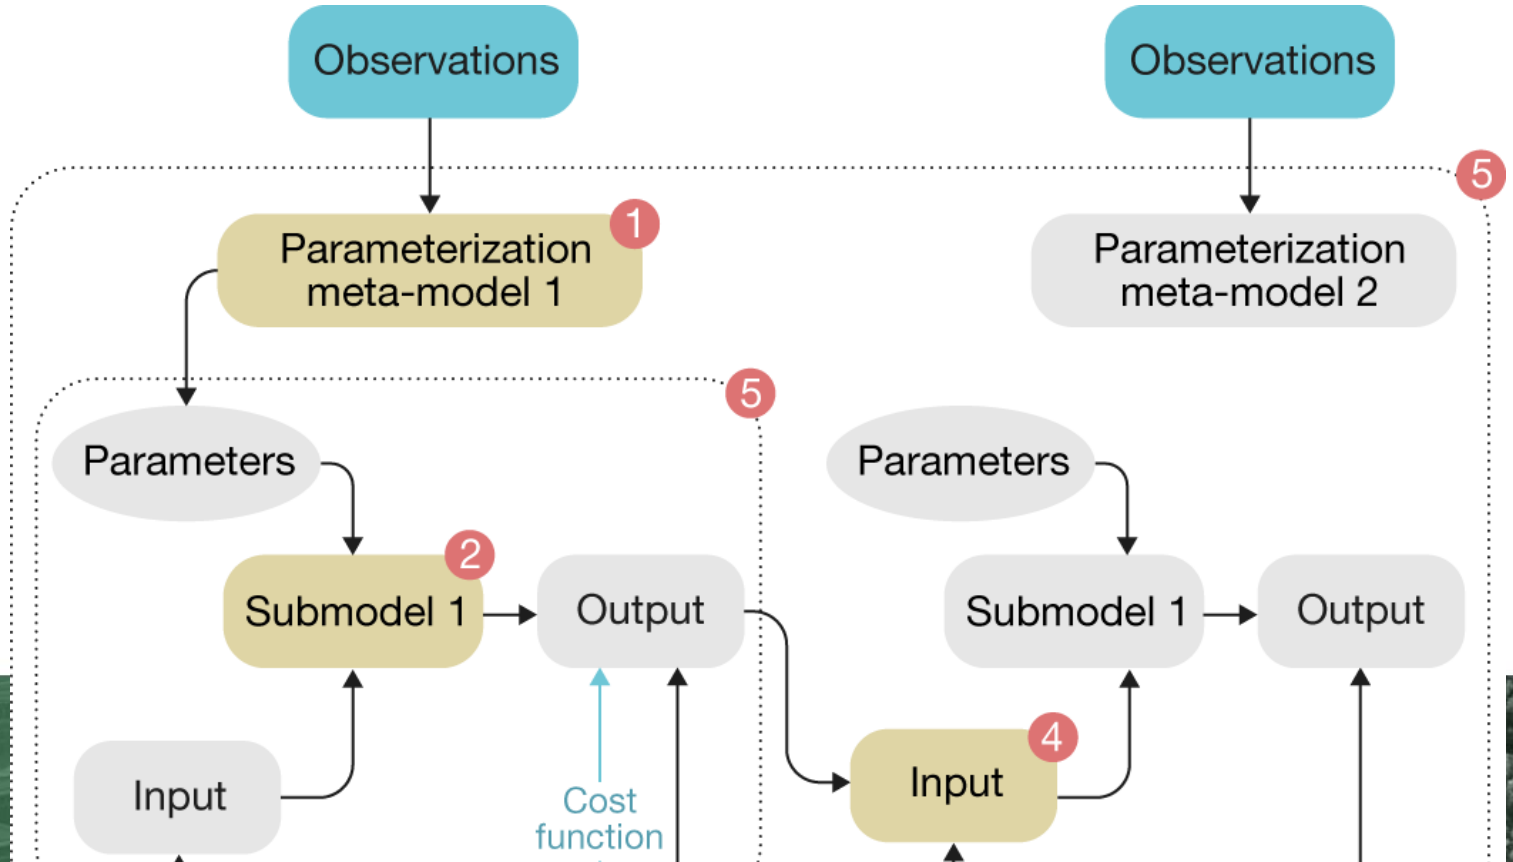
- **地球系统模型**中的植被参数不分配给植物功能类型(大多数全球陆地表面模型中的一个共同的临时决定)，而是允许从适当的统计协变量集中学习这些参数，使它们更具动态性、相互依存性和背景关系。

- **水文学**中从几千个集水区学习环境变量（例如，降水量和地表坡度）到集水区参数（如**平均流量、最小流量和最大流量**）的映射，并应用于全球水文模型。

- **全球大气模式**从数据或高分辨率模式中**学习降水对流的有效粗尺度物理参数**（例如，在对流过程中从云中析出的水的比例），高分辨率模型太昂贵，不能运行，这就是为什么需要粗尺度的参数化。这些可学习参数可以导致更好的热带对流表示。

方式2： 用ML取代“物理”子模型

圈2所示，**如果子模型的公式是半经验性质的，其中函数形式几乎没有理论基础(例如，生物过程)，如果有足够数量的观测数据，这个子模型可以用机器学习模型来代替。 这产生了一个混合模型，它结合了物理建模(理论基础，可解释的部分)和机器学习(数据适应性)的优势。**



中山大學 SUN YAT-SEN UNIVERSITY

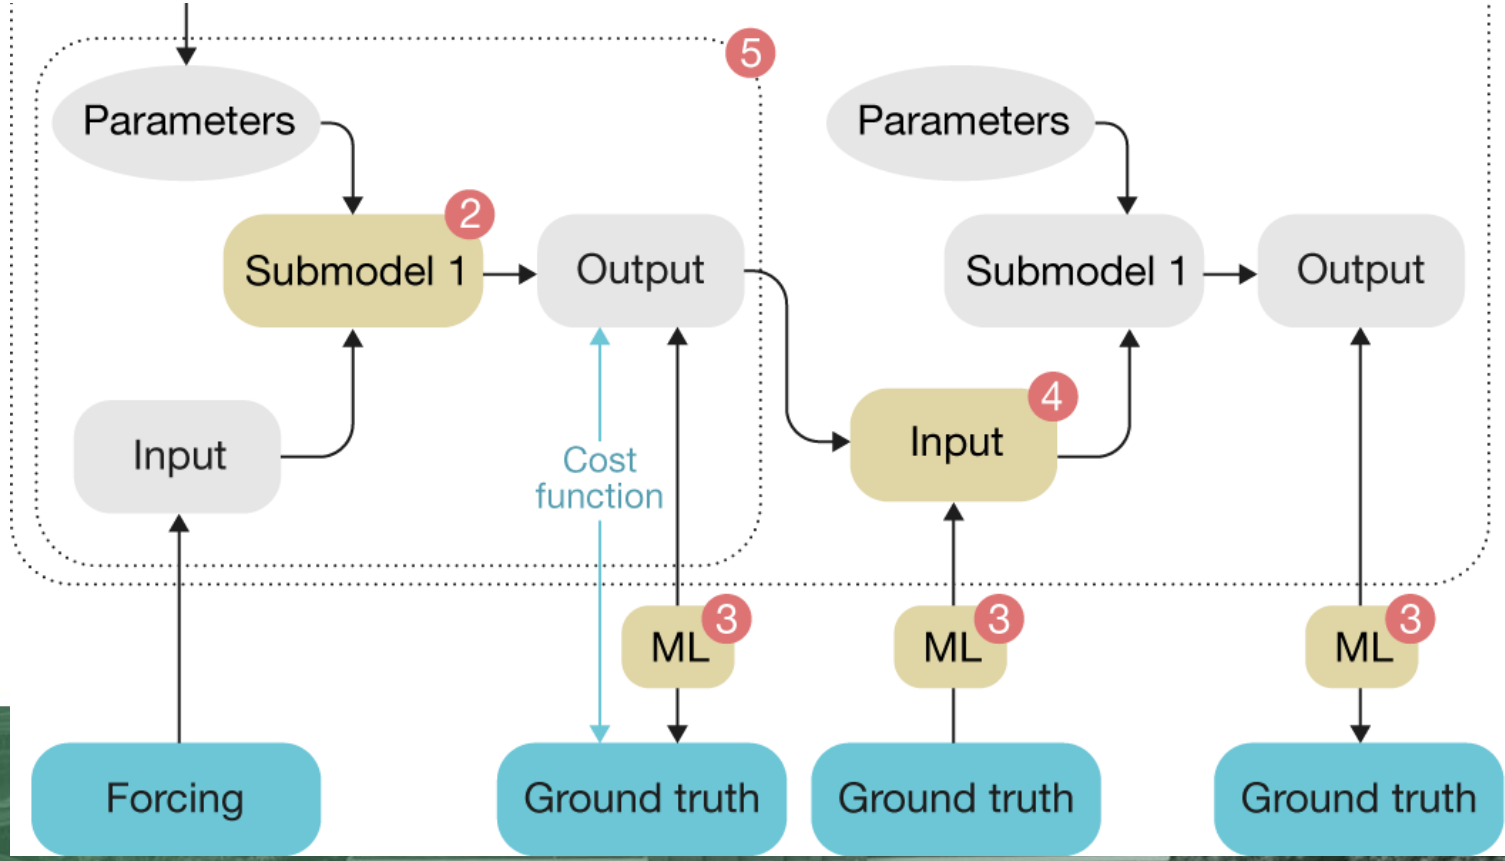
方式2：ML取代“物理”子模型的例子

- 例如，我们可以将建立好的水分在植物中传输的物理(微分)扩散方程与对水分传输的生物调节了解甚少的机器学习联系起来。它遵循公认的质量和能量守恒定律，产生一个更为“物理”的模型，但是它的调节(生物学的)是灵活的，可以从数据中学习。

- 如果**同时估计物理模型和机器学习参数，同时保持可解释性，特别是若干子模型被机器学习方法取代**，问题可能会变得更加复杂。在化学领域，这种方法已用于校准练习，描述未知动力学速率的变化，同时在生化反应堆模拟中保持质量平衡，这种模拟不太复杂，与水文和生物地球化学模拟有许多相似之处。

方式3：模型观测不匹配分析

圈3所示，假设没有观测偏差，物理模型与观测值的偏差可以被认为是不完善的知识导致模型误差。机器学习可以帮助识别，可视化和理解模型错误的模式，这使我们也可以相应地修正模型输出。



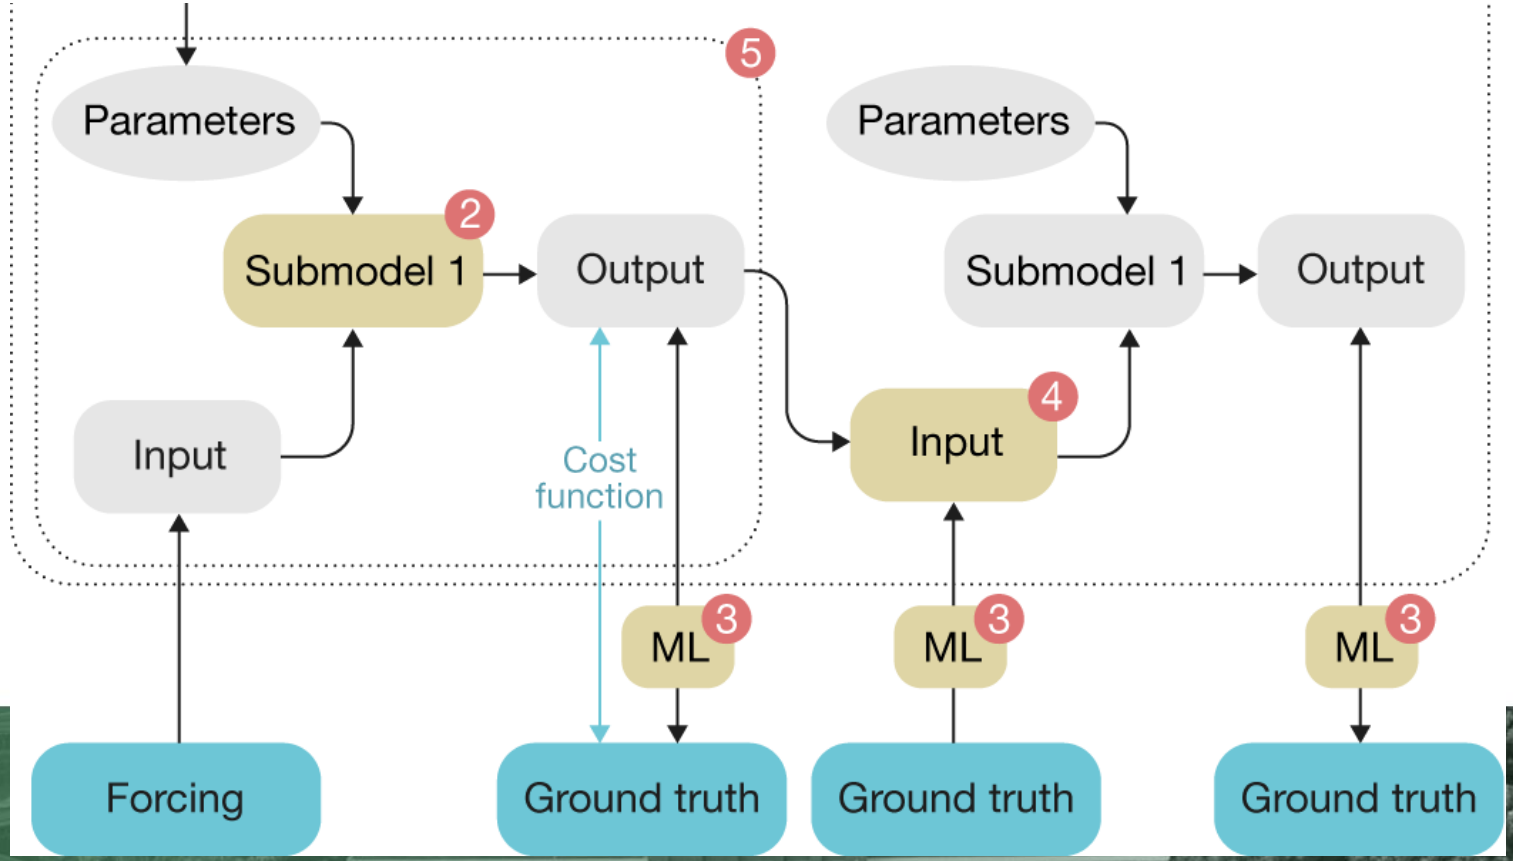
方式3：模型观测不匹配分析

- 例如，机器学习可以从数据中自动提取模式，并识别那些在物理模型中没有明确表示的模式。这种方法有助于改进物理模型和理论。

- 在实践中，它还可以用来纠正动态变量的模型偏差，或者它可以促进改进向更精细的空间尺度下降，而不是单调和特别的手工设计的方法。

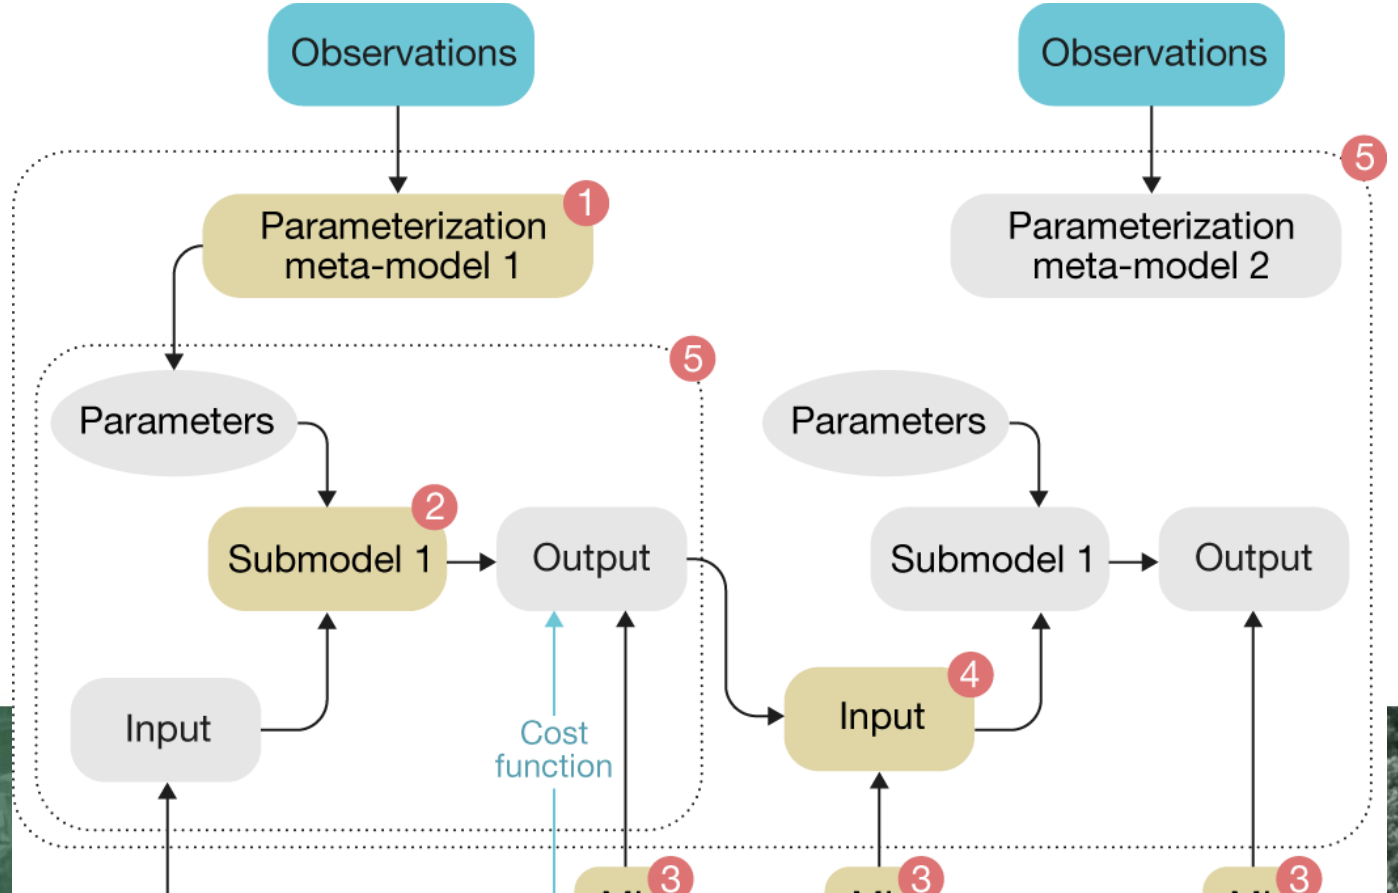
方式4：约束子模型

- 圈4所示：用机器学习算法的输出来驱动一个子模型，而不是在离线模拟中驱动另一个(可能存在偏差的)子模型。
- 有助于减少模型由耦合子模块引起的误差。简化和减少了模型参数校正或观测系统状态变量同化中的偏差和不确定性。



方式5：替代建模或模仿

对物理模型的完整(或特定部分)的模拟对于计算效率和可处理性是有用的。机器学习仿真器一旦经过训练，可以比原始物理模型更快地实现仿真，而不会牺牲太多的准确率➔快速的敏感度分析，模型参数校准和估计的置信区间的推导。



中山大學 SUN YAT-SEN UNIVERSITY

方式5：替代建模或模仿的例子

- 例如，机器学习仿真器被用来取代昂贵的、基于物理学的辐射传输模型，该模型描述了辐射、植被和大气之间的相互作用，它们对于模式中陆面遥感的解释和同化至关重要。

- 模拟器也用于状态演变的动态建模。 例如，在气候模型和最近探索的植被动态模型。鉴于物理模型的复杂性，仿真挑战是非常好的测试平台，探索机器学习和深度学习方法的潜力，以外推训练条件之外范围。

思考题

思考

- 机器学习方法在土地/地质/土壤中还有哪些应用?